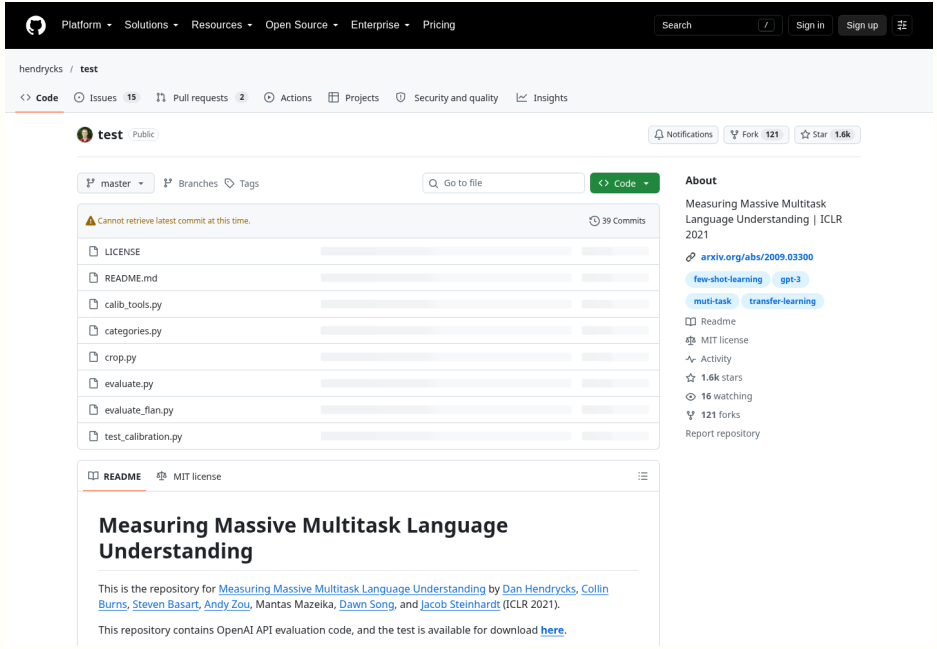
MMLU

Massive Multitask Language Understanding

57 分野の知識と問題解決を測る四択問題

sasakiy84

MMLU の公開ページ



[1] MMLU 公式公開ページ。 2026-10-18 参照。 https://github.com/hendrycks/test

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

57 科目を、同じ四択形式で評価する

- 初等数学から法律、医学、歴史まで、幅広い分野の問題を集めた英語の評価集合である。科目ごとの知識と問題解決を調べる。
- 既存の MMMLU は多言語化した別の配布物であり、ここでは元になる英語の MMLU を扱う。

[1] Dan Hendrycks et al. (2021). Measuring Massive Multitask Language Understanding. ICLR 2021. https://arxiv.org/abs/2009.03300

入力・出力と配布フィールド

フィールド	意味
question	設問
choices	四つの選択肢
answer / subject	0 〜 3 の正解位置と科目

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 https://huggingface.co/datasets/cais/mmlu

実例 1 ：抽象代数

関連する入力・回答／左：原文　右：日本語

Question: The element (4, 2) of Z_12 x Z_8 has order
A. 4
B. 8
C. 12
D. 6

正解： C

質問： Z_12 × Z_8 の元 (4, 2) の位数はいくつか。
A ：選択肢： 4
B ：選択肢： 8
C ：選択肢： 12
D ：選択肢： 6

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 abstract_algebra / test 行 98 。 https://huggingface.co/datasets/cais/mmlu

実例２：情報セキュリティ

関連する入力・回答／左：原文　右：日本語

Question: In MD-5 the length of the message digest is
A. 160
B. 128
C. 64
D. 54

正解： B

質問： MD-5 のメッセージダイジェストの長さはいくつか。
A ：選択肢： 160
B ：選択肢： 128
C ：選択肢： 64
D ：選択肢： 54

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 computer_security / test 行 1487 。 https://huggingface.co/datasets/cais/mmlu

実例３：天文学

関連する入力・回答／左：原文　右：日本語

Question: A Mars year is approximately how many Earth years long?
A. 1/2
B. 1
C. 2
D. 4

正解： C

質問：火星の 1 年は、地球の何年分におよそ相当するか。
A ：選択肢： 1/2
B ：選択肢： 1
C ：選択肢： 2
D ：選択肢： 4

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 astronomy / test 行 314 。 https://huggingface.co/datasets/cais/mmlu

作成方法とデータの構成

作成の背景

- 言語モデルの評価が、日常的な常識や特定の文章理解に集中していた。
- 学習中に幅広い情報を読んだモデルが、専門的な問いへ知識を適用できるかを測るため、 57 科目を集めた。

[1] Dan Hendrycks et al. (2021). Measuring Massive Multitask Language Understanding. ICLR 2021. https://arxiv.org/abs/2009.03300

収集と品質の確認

- 公開の教育資料、オンライン問題、書籍などから、さまざまな水準の多肢選択問題を人手で収集した。
- 各科目で 5 問を少数例提示用に確保し、開発集合とテスト集合を分けた。特定科目の微調整だけを目標にした大規模学習集合ではない。

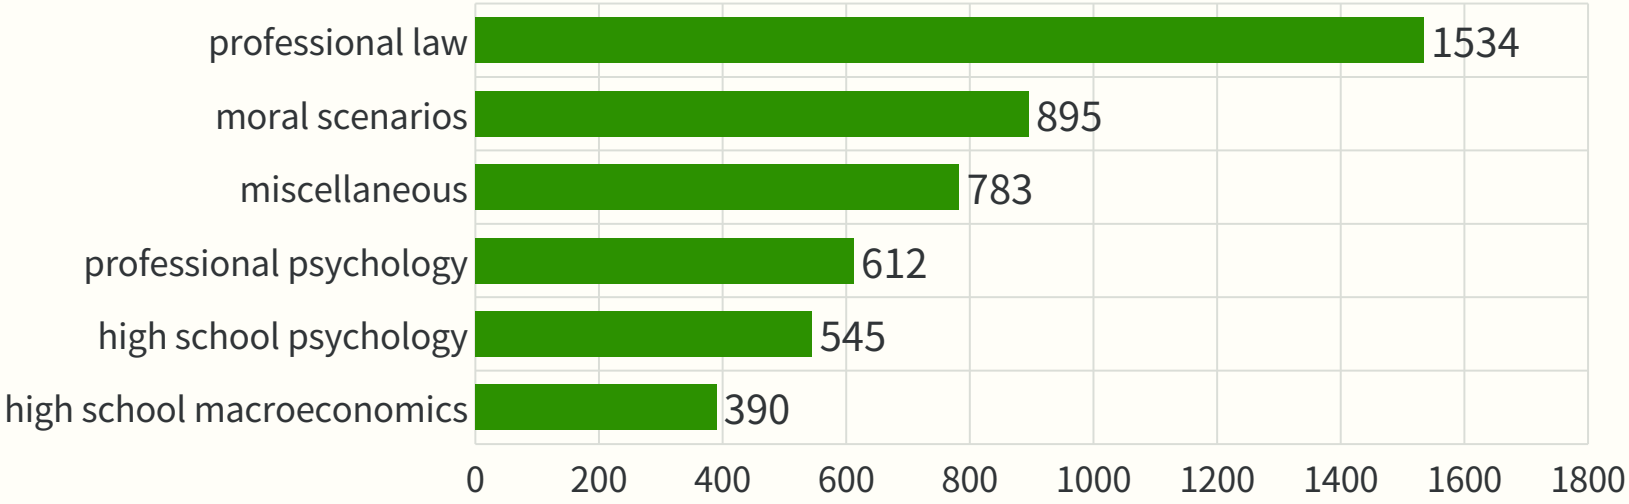
[1] Dan Hendrycks et al. (2021). Measuring Massive Multitask Language Understanding. ICLR 2021. https://arxiv.org/abs/2009.03300

分割と件数

集合・対象	件数	役割
dev	285	各科目 5 問の提示例
validation	1,531	設定選択用
test	14,042	57 科目の最終評価

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。
https://huggingface.co/datasets/cais/mmlu

問題数が多い 6 科目



固定改訂の test 全 14,042 問、 57 科目から上位 6 。横軸は問題数。

[1] MMLU 、 all/test 全 14,042 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/cais/mmlu

採点方法とモデルの成績

何を 1 件として、どう採点するか

- 各問の候補 A ～ D から一つを選び、正解なら 1 点とする。20 問中 15 問正解なら、正解率は 75% 。
- 全問をまとめた平均と、科目ごとの正解率を同じ重みで平均する方法では、科目の重みが異なる。ここでは結果ごとの集約範囲を明記する。

[1] Dan Hendrycks et al. (2021). Measuring Massive Multitask Language Understanding. ICLR 2021. https://arxiv.org/abs/2009.03300

初期の代表的な評価

2020 年の報告／ 2021 年発表	全体の正解率（ % ）
GPT-3 175B （ few-shot ）	43.9
UnifiedQA 11B	48.9
無作為選択の期待値	25.0

論文 Table 1 の重み付き平均。 UnifiedQA は他の QA 集合で学習したモデル。

[1] Dan Hendrycks et al. (2021). Measuring Massive Multitask Language Understanding. ICLR 2021. https://arxiv.org/abs/2009.03300

HELM での評価条件

- HELM Classic が実行したのは、抽象代数・大学化学・情報セキュリティ・計量経済学・米国外交の 5 科目。
- 表では computer_security の test 100 問を示す。最大 5 例提示、 3 試行、候補を並べて回答記号の尤度を比べる joint 方式。

[1] Stanford CRFM. HELM Classic v0.4.0. 公開 run_specs 。 2023-11-17 のリリース。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

HELM Classic v0.4.0 の結果

モデル	正解率（%）	試行数
text-davinci-003 （2022）	76.33	3
Anthropic v4-s3 （2022）	67.00	3

computer_security の test 100 問、最大 5 例提示。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

利用の変化と入手方法

専門知識を測る共通の指標になった

- 2020 年の公開後、 MMLU は大規模言語モデルの知識を測る代表的な評価に使われた。科目別の正解率から、得意分野と不得意分野を比べられる。
- 2026-10-18 時点の Evaluation Harness には MMLU の評価定義があり、 57 科目と集約方法を指定して実行できる。

[1] EleutherAI. Language Model Evaluation Harness. 2026-10-18 参照。 https://github.com/EleutherAI/lm-evaluation-harness

入手方法と利用条件

- 公式 GitHub は問題データと科目一覧を案内している。ここでは cais/mmlu の固定改訂を取得した。
- データカードと元の問題資料の条件を確認して利用する。dev は各科目 5 問で、テスト問題と同じ用途には使わない。
- 公式リポジトリのライセンスは MIT 。収録問題の出典情報も公開されている。

[1] MMLU 公式公開ページ。 2026-10-18 参照。 https://github.com/hendrycks/test

MMLU の要点

- 英語の 57 科目、 test 14,042 問で、幅広い知識の適用を調べる。
- モデルの値を読む際は、 57 科目全体か特定科目か、提示例の数と集約方法を確認する。

[1] Dan Hendrycks et al. (2021). Measuring Massive Multitask Language Understanding. ICLR 2021. https://arxiv.org/abs/2009.03300

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例１：高校生物

関連する入力・回答／左：原文　右：日本語

Question: Which of the following is an example of a detritivore?
A. Cactus
B. Algae
C. Bat
D. Fungus

正解： D

質問：次のうち、デトリタス食者の例はどれか。
A ：選択肢：サボテン
B ：選択肢：藻類
C ：選択肢：コウモリ
D ：選択肢：菌類

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 high_school_biology / test 行 2954 。 https://huggingface.co/datasets/cais/mmlu

実例の補足：高校生物

- 配布正解は D （ Fungus ）。菌類は通常「分解者」と呼び、デトリタスを摂食する動物と区別する。この設問では用語の範囲が広い。

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 https://huggingface.co/datasets/cais/mmlu

追加例２：計量経済学

関連する入力・回答／左：原文　右：日本語

Question: What are the dimensions of $\hat{u}^t \hat{u}?
A. T x k
B. T x 1
C. k x 1
D. 1 x 1

正解： D

質問： $\hat{u}^t \hat{u}$ の次元はいくつか。
A ：選択肢： T × k
B ：選択肢： T × 1
C ：選択肢： k × 1
D ：選択肢： 1 × 1

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 econometrics / test 行 1824 。 https://huggingface.co/datasets/cais/mmlu

追加例３：形式論理

関連する入力・回答／左：原文　右：日本語

Question: Select the best translation into predicate logic: Johnny came late.
A. jL
B. Lj
C. Cj ∨ Lj
D. Lx

正解： B

質問：「ジョニーは遅れて来た」を述語論理に訳したものとして最も適切なのはどれか。
A ：選択肢： jL
B ：選択肢： Lj
C ：選択肢： Cj ∨ Lj
D ：選択肢： Lx

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 formal_logic / test 行 2554 。 https://huggingface.co/datasets/cais/mmlu

追加例 4 ：世界の宗教

関連する入力・回答／左：原文　右：日本語

Question: How many books are in the New Testament?
A. 30
B. 29
C. 27
D. 47

正解： C

質問：新約聖書には何巻の書があるか。
A ：選択肢： 30
B ：選択肢： 29
C ：選択肢： 27
D ：選択肢： 47

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 world_religions / test 行 13941 。 https://huggingface.co/datasets/cais/mmlu

追加例 5 ：高校地理

関連する入力・回答／左：原文　右：日本語

Question: The global lingua franca is
A. Chinese.
B. English.
C. French.
D. Arabic.

正解： B

質問：世界的な共通語はどれか。
A ：選択肢：中国語
B ：選択肢：英語
C ：選択肢：フランス語
D ：選択肢：アラビア語

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 high_school_geography / test 行 3638 。 https://huggingface.co/datasets/cais/mmlu

追加例 6 ：栄養学

関連する入力・回答／左：原文　右：日本語

Question: What are histones?

A. Lipids
B. Carbohydrates
C. Nucleotides
D. Proteins

正解： D

質問：ヒストンとは何か。
A ：選択肢：脂質
B ：選択肢：炭水化物
C ：選択肢：ヌクレオチド
D ：選択肢：タンパク質

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 nutrition / test 行 9563 。 https://huggingface.co/datasets/cais/mmlu

追加例７：経営管理

関連する入力・回答／左：原文　右：日本語

Question: What is the optimal span of control?
A. 2
B. 5
C. 7
D. None of the above

正解： D

質問：最適な管理範囲、すなわち 1 人の管理者が直接管理する部下の人数はどれか。
A ：選択肢： 2
B ：選択肢： 5
C ：選択肢： 7
D ：選択肢：上のいずれでもない

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 management / test 行 7006 。 https://huggingface.co/datasets/cais/mmlu

追加例 8 ：マーケティング

関連する入力・回答／左：原文　右：日本語

Question: McDonald's and KFC are good examples of:
A. Distributors.
B. Franchising.
C. Merchant.
D. Retailers.

正解： B

質問：マクドナルドと KFC は、何の好例か。
A ：選択肢：流通業者
B ：選択肢：フランチャイズ
C ：選択肢：商人
D ：選択肢：小売業者

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 marketing / test 行 7174 。 https://huggingface.co/datasets/cais/mmlu

追加例９：解剖学

関連する入力・回答／左：原文　右：日本語

Question: The anatomic location of the spinal canal is
A. caudal
B. dorsal
C. frontal
D. transverse

正解： B

質問：脊柱管は、解剖学的にどの側に位置するか。
A ：選択肢：尾側
B ：選択肢：背側
C ：選択肢：前側
D ：選択肢：横断方向

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 anatomy / test 行 153 。 https://huggingface.co/datasets/cais/mmlu

追加例 10 ：マクロ経済学

関連する入力・回答／左：原文　右：日本語

Question: The government measures inflation using the
A. GNP
B. URL
C. CPI
D. FED

正解： C

質問：政府は、何を使って物価上昇を測定するか。
A ：選択肢： GNP
B ：選択肢： URL
C ：選択肢： CPI
D ：選択肢： FED

[1] cais/mmlu 、改訂 c30699e8 。 2026-10-18 参照。 high_school_macroeconomics / test 行 3899 。 https://huggingface.co/datasets/cais/mmlu

集計と評価条件

test の全 57 科目（ 1/10 ）

科目	問題数
abstract algebra	100
anatomy	135
astronomy	152
business ethics	100
clinical knowledge	265
college biology	144

[1] MMLU 、 all/test 全 14,042 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/cais/mmlu

test の全 57 科目（ 2/10 ）

科目	問題数
college chemistry	100
college computer science	100
college mathematics	100
college medicine	173
college physics	102
computer security	100

[1] MMLU 、 all/test 全 14,042 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/cais/mmlu

test の全 57 科目（ 3/10 ）

科目	問題数
conceptual physics	235
econometrics	114
electrical engineering	145
elementary mathematics	378
formal logic	126
global facts	100

[1] MMLU 、 all/test 全 14,042 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/cais/mmlu

test の全 57 科目（ 4/10 ）

科目	問題数
high school biology	310
high school chemistry	203
high school computer science	100
high school european history	165
high school geography	198
high school government and politics	193

[1] MMLU 、 all/test 全 14,042 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/cais/mmlu

test の全 57 科目（ 5/10 ）

科目	問題数
high school macroeconomics	390
high school mathematics	270
high school microeconomics	238
high school physics	151
high school psychology	545
high school statistics	216

[1] MMLU 、 all/test 全 14,042 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/cais/mmlu

test の全 57 科目（ 6/10 ）

科目	問題数
high school us history	204
high school world history	237
human aging	223
human sexuality	131
international law	121
jurisprudence	108

[1] MMLU 、 all/test 全 14,042 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/cais/mmlu

test の全 57 科目（ 7/10 ）

科目	問題数
logical fallacies	163
machine learning	112
management	103
marketing	234
medical genetics	100
miscellaneous	783

[1] MMLU 、 all/test 全 14,042 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/cais/mmlu

test の全 57 科目（ 8/10 ）

科目	問題数
moral disputes	346
moral scenarios	895
nutrition	306
philosophy	311
prehistory	324
professional accounting	282

[1] MMLU 、 all/test 全 14,042 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/cais/mmlu

test の全 57 科目（ 9/10 ）

科目	問題数
professional law	1534
professional medicine	272
professional psychology	612
public relations	110
security studies	245
sociology	201

[1] MMLU 、 all/test 全 14,042 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/cais/mmlu

test の全 57 科目（ 10/10 ）

科目	問題数
us foreign policy	100
virology	166
world religions	171

[1] MMLU 、 all/test 全 14,042 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/cais/mmlu

研究と参考文献

研究者と発表の位置付け

- 第一著者 Dan Hendrycks 、最終著者 Jacob Steinhardt を含む 7 名の研究。 ICLR 2021 で発表した。
- 公開問題を科目横断で整理し、言語モデルの知識評価を広げた。初期の公開は 2020 年。

[1] Dan Hendrycks et al. (2021). Measuring Massive Multitask Language Understanding. ICLR 2021. https://arxiv.org/abs/2009.03300

参考文献

Measuring Massive Multitask Language Understanding

Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, Jacob Steinhardt / ICLR 2021

MMLU の目的、作成方法、評価をまとめた研究。

https://arxiv.org/abs/2009.03300

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

複数のシナリオと指標で、言語モデルを比較する HELM の研究。

https://arxiv.org/abs/2211.09110

参考文献

MMLU ：公開データ

cais/mmlu / 改訂 c30699e8 / 2026-10-18 参照

原文・正解の 13 例と、対象集合の全件集計に用いた公開資源。

https://huggingface.co/datasets/cais/mmlu