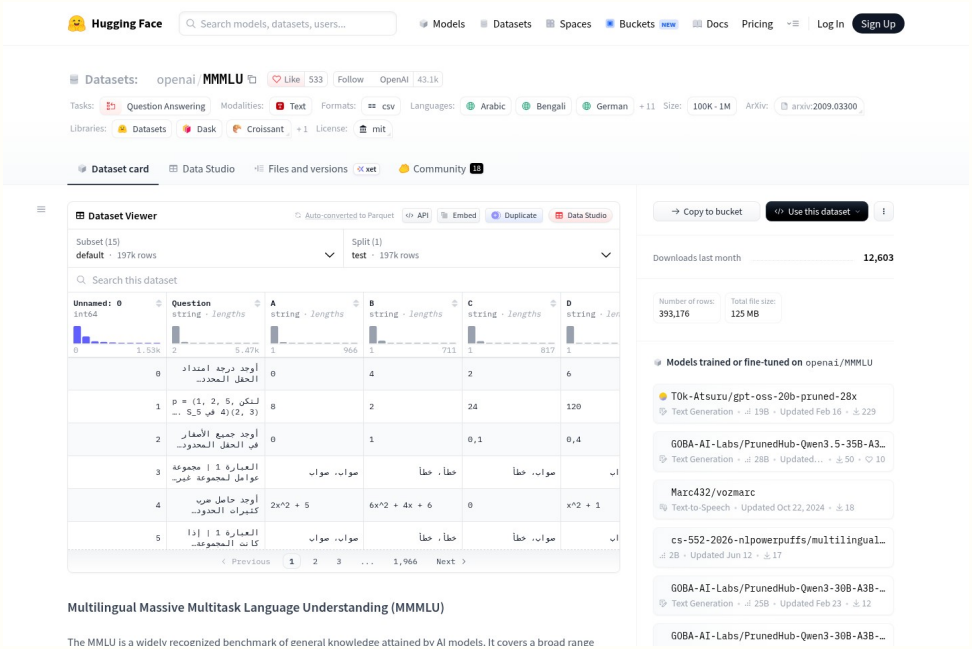
MMMLU

Multilingual Massive Multitask
Language Understanding

専門翻訳者が 14 言語へ訳した知識問題
57 科目を 4 択で評価する多言語データセット

sasakiy84

MMMLU の公式配布ページ



OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

1. 多言語の知識問題と実例

2. 採点とモデルの成績

3. 作成方法とデータの構成

4. 利用方法とまとめ

1. 多言語の知識問題と実例

同じ知識領域を、 14 言語の問題で評価する

- MMMLU は、知識と推論を測る MMLU のテスト問題を、専門翻訳者が 14 言語へ訳したデータセット。 OpenAI が 2024 年 9 月に公開した。
- 入力は一つの言語の設問と四つの選択肢。モデルが選んだ記号を、配布された参照正解 A ～ D と比較する。
- 日本語、スペイン語、スワヒリ語、ヨルバ語などを含み、同じ評価体系で言語別の成績を調べる。

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

出発点の MMLU は、幅広い科目の試験問題

- MMLU は、初等数学から専門法律学・医学まで 57 科目を含む、英語の多肢選択式評価。 2020 年に公開され、 ICLR 2021 で発表された。
- 大学生・大学院生が、オンラインで公開された練習問題、資格試験向け教材、大学の授業などから設問を人手で収集した。
- MMMLU では、そのテスト集合を翻訳して、英語以外での知識問題への応答を評価できるようにした。

Hendrycks et al. (2021). Measuring Massive Multitask Language Understanding. ICLR 。 https://arxiv.org/abs/2009.03300

日本語の実例と、同じ問題の他言語版を見る

- 本編では、機械学習、統計学、国際法の 3 問を示す。続いて機械学習の同じ問題を、スペイン語とスワヒリ語で読む。
- Appendix では、天文学、情報セキュリティ、数学、会計など、別の 10 問を追加する。
- 設問と選択肢は公式 CSV の全文。正解は配布記号を示し、その下に短い説明を添える。

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

実例１：機械学習：教師あり学習を見分ける

設問（配布日本語・全文）

次のうち教師あり学習でないものはどれか。

A) PCA
B) 決定木
C) 線形回帰
D) ナイーブベイズ

配布正解： A) PCA

PCA （主成分分析）は教師ラベルを使わず、データの分散を説明する軸を求める。

OpenAI. MMMLU / JA-JP / machine_learning / 科目内番号 95 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=6930

実例２：統計学：カイ二乗検定の自由度

設問（配布日本語・全文）

3×4 の分割表で独立性のカイ二乗検定を行います。この検定の自由度は、次のうちのどれですか？

A) 6
B) 8
C) 10
D) 11

配布正解： A) 6

独立性の検定では、自由度は $(3-1)\times(4-1)=6$ 。

OpenAI. MMMLU / JA-JP / high_school_statistics / 科目内番号 101 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=5533

実例３：国際法：条約が保障する権利

設問（配布日本語・全文）

欧州人権条約は主に以下のどれを対象としていますか？

A) 経済的および社会的権利
B) 環境権
C) 市民的および政治的権利
D) 経済的自由

配布正解： C) 市民的および政治的権利

欧州人権条約は、生命・自由・公正な裁判などの権利を扱う。

OpenAI. MMMLU / JA-JP / international_law / 科目内番号 70 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=6513

同じ機械学習の問題を、スペイン語で読む

設問（配布原文・全文）

¿Cuál de las siguientes opciones NO es aprendizaje supervisado?

A) PCA
B) Árbol de decisión
C) Regresión lineal
D) Naive Bayes

配布正解： A) PCA

NO es aprendizaje supervisado は「教師あり学習ではない」。

OpenAI. MMMLU / ES-LA / machine_learning / 科目内番号 95 。
https://huggingface.co/datasets/openai/MMMLU/viewer/ES_LA/test?row=6930

同じ機械学習の問題を、スワヒリ語で読む

設問（配布原文・全文）

Kati ya yafuatayo, ipi SIO ujifunzaji ulioongozwa?

A) PCA
B) Mti wa maamuzi
C) Urejeshi wa laini
D) Bayesian Mjinga

配布正解： A) PCA

ujifunzaji ulioongozwa は「教師あり学習」。

OpenAI. MMMLU / SW-KE / machine_learning / 科目内番号 95 。
https://huggingface.co/datasets/openai/MMMLU/viewer/SW_KE/test?row=6930

2. 採点とモデルの成績

回答から記号を取り出し、正解と照合する

段階	OpenAI の公開実装
入力を構成	設問と A 〜 D の選択肢を、英語の指示文へ埋め込む
出力を指定	末尾を Answer: A のような形式にする
記号を抽出	各言語の「答え」に対応する表現も認識する
採点を集計	抽出した記号が参照正解と一致すれば 1 点

OpenAI. MMLU evaluation / simple-evals. 改訂 652c89d 、 MIT 。 https://github.com/openai/simple-evals/blob/652c89d/mmlu_eval.py

採点の例：正解が A の設問に回答する

応答（説明用）	抽出記号	得点
Answer: A	A	1
Answer: B	B	0
A	抽出されない	0

OpenAI. MMLU evaluation / simple-evals. 改訂 652c89d 、 MIT 。 https://github.com/openai/simple-evals/blob/652c89d/mmlu_eval.py

問題数の違いが、全体の正答率の重みになる

科目の例	問数	構成比
専門法律学	1,534	10.92%
抽象代数学	100	0.71%

日本語全 14,042 問。公開実装は問題単位の得点を平均する。

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

OpenAI. MMLU evaluation / simple-evals. 改訂 652c89d 、 MIT 。 https://github.com/openai/simple-evals/blob/652c89d/mmlu_eval.py

Google の MMMLU 比較（2026 年 2 月）

モデル	思考設定	正答率
Gemini 3.1 Pro	High	92.6%
Gemini 3 Pro	High	91.8%
Claude Opus 4.6	Max	91.1%
GPT-5.2	High	89.6%
Claude Sonnet 4.6	Max	89.3%

Google DeepMind (2026). Gemini 3.1 Pro: Model Card. 2026 年 2 月の評価。 https://deepmind.google/models/model-cards/gemini-3-1-pro/

Google の比較では、 Gemini は自社で評価した

- Google の 2026 年 2 月のモデルカードは、 Gemini 3.1 Pro の MMMLU 正答率を 92.6% と報告する。 3 Pro は 91.8% で、差は 0.8 ポイント。
- 評価手順書は、 Multilingual MMLU の Gemini 3.1 Pro と 3 Pro の値を自社で計算したと記す。他社モデルの値は、原則として各提供元の公表値を採用する。

Google DeepMind (2026). Gemini 3.1 Pro: Evaluation Methodology. https://deepmind.google/models/evals-methodology/gemini-3-1-pro/

OpenAI の公開比較では、言語ごとの幅がある

言語	GPT-4o	GPT-4.1	o3-high
日本語	83.5%	85.6%	89.0%
スペイン語	84.3%	87.6%	91.1%
スワヒリ語	77.9%	79.5%	86.0%
ヨルバ語	62.1%	64.7%	78.0%

GPT-4o は 2024-11-20 、 GPT-4.1 は 2025-04-14 。 o3 は high 設定。

OpenAI. Multilingual MMLU Benchmark Results. 2025 年モデル、改訂 652c89d 。
https://github.com/openai/simple-evals/blob/652c89d/multilingual_mmlu_benchmark_results.md

3. 作成方法とデータの構成

元の設問を収集し、専門翻訳者が多言語化

工程	担当・内容
素材の収集	学生が公開教材・試験の練習問題を収集
科目の整理	難度の異なる 57 科目へ整理
人手で翻訳	専門翻訳者が 14 言語へ翻訳
CSV で公開	設問・選択肢・正解・科目を収録

Hendrycks et al. (2021). Measuring Massive Multitask Language Understanding. ICLR 。 https://arxiv.org/abs/2009.03300

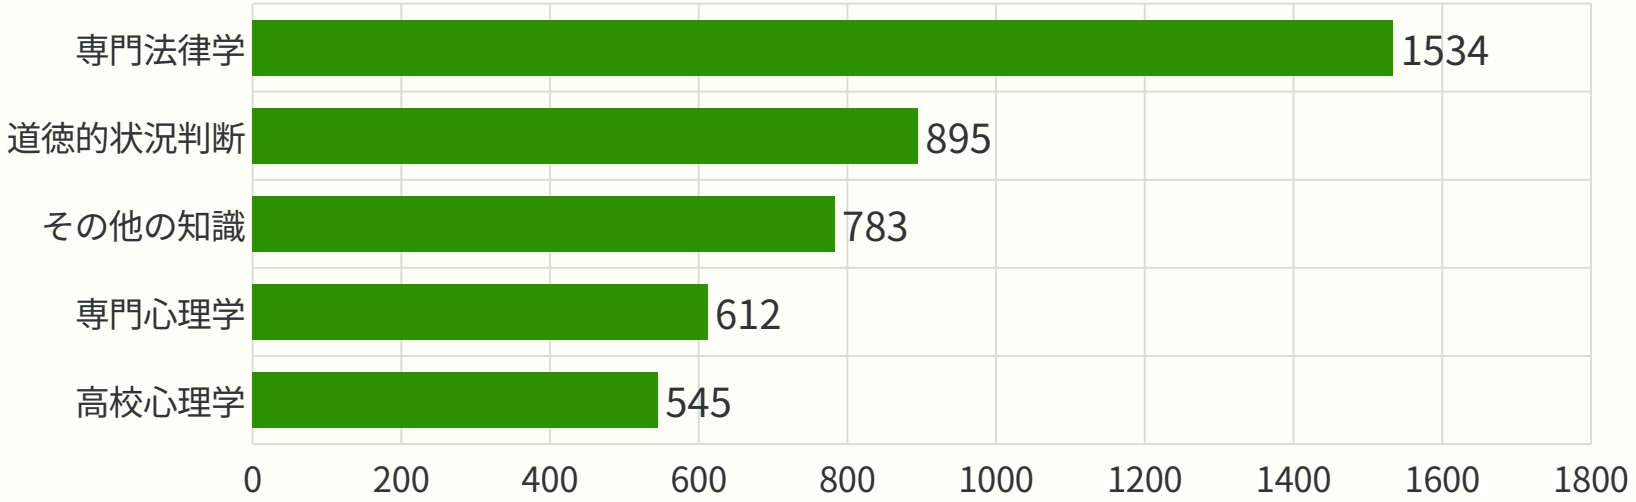
OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

1 言語 14,042 問、 14 言語で延べ 196,588 件

対象	配布 CSV の実数
言語・ロケール	14
各言語のレコード数	14,042
14 言語の延べレコード数	196,588
日本語の科目ラベル数	57

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

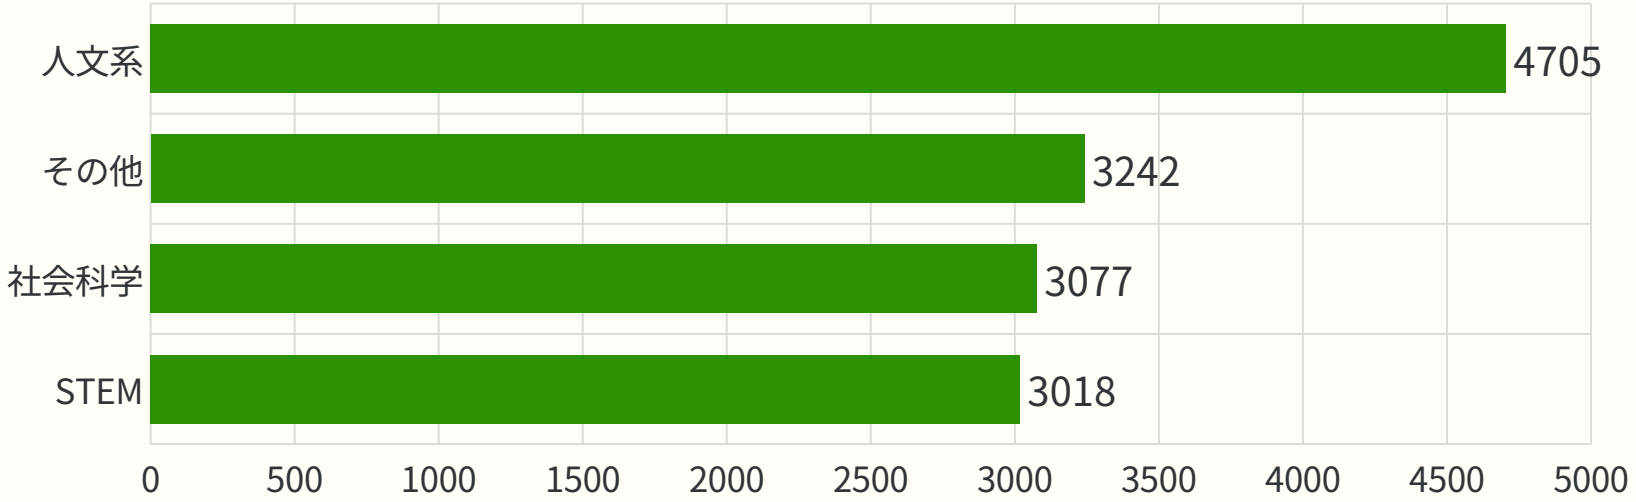
日本語では、専門法律学の問題が最も多い



日本語 CSV 全 14,042 問を集計。件数上位 5 科目。

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

公開実装の 4 領域では、人文系が最大となる



STEM は科学・技術・工学・数学。日本語の全 14,042 問を集計。

OpenAI. MMLU evaluation / simple-evals. 改訂 652c89d 、 MIT 。 https://github.com/openai/simple-evals/blob/652c89d/mmlu_eval.py

公開された 14 言語と設定名（ 1/2 ）

設定名	言語
AR_XY	アラビア語
BN_BD	ベンガル語
DE_DE	ドイツ語
ES_LA	スペイン語
FR_FR	フランス語
HI_IN	ヒンディー語
ID_ID	インドネシア語

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

公開された 14 言語と設定名（ 2/2 ）

設定名	言語
IT_IT	イタリア語
JA_JP	日本語
KO_KR	韓国語
PT_BR	ポルトガル語（ブラジル）
SW_KE	スワヒリ語
YO_NG	ヨルバ語
ZH_CN	中国語（簡体字）

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

CSV は設問・選択肢・正解・科目を持つ

列	内容
先頭の無名列	科目内の番号（例： 95 ）
Question	翻訳済みの設問本文
A / B / C / D	四つの選択肢
Answer	正解を表す A ～ D の記号
Subject	科目名（例： machine_learning ）

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

MMLU から、多言語と文化の評価へ広がった

- MMLU は 2020 年に英語の幅広い知識評価として登場し、MMMLU は 2024 年にそのテスト問題を 14 言語へ展開した。
- 後続の Global MMLU は、 42 言語の翻訳と文化依存性の注釈を公開した。米国の制度や文化的知識を要する設問などを分析している。
- Global MMLU の研究は、元の MMLU 問題の 28% に文化依存の知識が必要だと報告した。

Singh et al. (2025). Global MMLU: Understanding and Addressing Cultural and Linguistic Biases in Multilingual Evaluation. v2 。 https://arxiv.org/abs/2412.03304v2

4. 利用方法とまとめ

日本語のテスト集合を読み込む

```
from datasets import load_dataset

ds = load_dataset(
    "openai/MMMLU", "JA_JP", split="test",
    revision="325a01dc3e173cac1578df94120499aaca2e2504",
)
row = ds[6930]
print(row["Question"], row["Answer"])
```

JA_JP は日本語の設定名。 row には設問・選択肢・正解・科目が入る。

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

人手翻訳した知識問題を、言語別に評価する

- MMMLU は、英語の知識評価 MMLU を専門翻訳者が 14 言語へ訳した、四択問題のデータセット。各言語 14,042 問を収録している。
- 入力は設問と四つの選択肢、出力は回答記号。公開実装は記号の一致を採点し、問題単位で正答率を集計する。
- Gemini 3.1 Pro などの公式評価に使われ、モデル間だけでなく、同じモデルの言語別の成績を調べる資料にもなる。

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

Appendix

1. 科目の異なる追加例

2. 言語別・科目別の詳細

3. 制作機関と参考文献

1. 科目の異なる追加例

追加例 1 ：天文学：火星の公転周期

設問（配布日本語・全文）

火星の 1 年はおよそ地球の何年ですか。

A) 1/2
B) 1
C) 2
D) 4

配布正解： C) 2

火星の公転周期は約 687 日で、地球の約 1.88 年。

OpenAI. MMMLU / JA-JP / astronomy / 科目内番号 79 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=314

追加例 2 ：情報セキュリティ：認証の方式

設問（配布日本語・全文）

認証方式は次のうちどれか。

A) 秘密の質問
B) 生体認証
C) SMS コード
D) 上記のすべて

配布正解： D) 上記のすべて

知識、身体的な特徴、受信できるコードなどを、本人確認に使う。

OpenAI. MMMLU / JA-JP / computer_security / 科目内番号 34 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=1505

追加例３：栄養学：ヒストンの種類

設問（配布日本語・全文）

ヒストンとは何ですか？

A) 脂質
B) 炭水化物
C) ヌクレオチド
D) タンパク質

配布正解： D) タンパク質

ヒストンは DNA と結び付き、クロマチンを構成するタンパク質。

OpenAI. MMMLU / JA-JP / nutrition / 科目内番号 155 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=9563

追加例 4 ：高校生物学：受精が起こる場所

設問（配布日本語・全文）

ヒトにおいて、通常受精が起こるのは

A) 卵巣
B) 卵管
C) 子宮
D) 胎盤

配布正解： B) 卵管

受精卵は卵管から子宮へ移動する。

OpenAI. MMMLU / JA-JP / high_school_biology / 科目内番号 48 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=2717

追加例 5 ：大学数学：複素数の累乗

設問（配布日本語・全文）

(1+i)^10 =

A) 1
B) i
C) 32
D) 32i

配布正解： D) 32i

$(1 + i)^2 = 2i$ を使うと、$(1 + i)^{10} = (2i)^5 = 32i$ 。

OpenAI. MMMLU / JA-JP / college_mathematics / 科目内番号 94 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=1190

追加例 6 ：世界の宗教：中国古典の著者

設問（配布日本語・全文）

女誡の著者は誰ですか。

A) 班昭
B) 老子
C) メニクス
D) 劉向

配布正解： A) 班昭

『女誡』は、後漢の学者・班昭が著した教訓書。

OpenAI. MMMLU / JA-JP / world_religions / 科目内番号 66 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=13937

追加例７：ミクロ経済学：独占的競争の価格

設問（配布日本語・全文）

独占的競争の特徴は、次のうちのどれですか？

A) P > MC
B) 効率性
C) ほとんどが価格競争
D) P =MR

配布正解： A) P > MC

P は価格、 MC は限界費用、 MR は限界収入を表す。

OpenAI. MMMLU / JA-JP / high_school_microeconomics / 科目内番号 76 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=4574

追加例 8 ：会計学：将来受け取る金額の現在価値

設問（配布日本語・全文）

割引率が 9% のとき、 2 年後に受け取る $10 の現在の価値はいくらですか。

A) $9
B) $11
C) $8.26
D) $8.42

配布正解： D) $8.42

現在価値は $10 \div 1.09^2 \approx 8.42$ ドル。

OpenAI. MMMLU / JA-JP / professional_accounting / 科目内番号 168 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=10517

追加例 9 ：論理学：帰謬法の別名

設問（配布日本語・全文）

帰謬法の他の用語

A) お前だって論法
B) 脅迫論証
C) 人身攻撃
D) 背理法

配布正解： D) 背理法

仮定から矛盾を導いて論証する方法を、背理法とも呼ぶ。

OpenAI. MMMLU / JA-JP / logical_fallacies / 科目内番号 44 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=6716

追加例 10 ：地理：化石燃料の種類

設問（配布日本語・全文）

最も豊富に存在する化石燃料はどれか。

A) リン酸塩
B) 油
C) 石油
D) 石炭

配布正解： D) 石炭

OpenAI. MMMLU / JA-JP / high_school_geography / 科目内番号 91 。
https://huggingface.co/datasets/openai/MMMLU/viewer/JA_JP/test?row=3538

2. 言語別・科目別の詳細

OpenAI の言語別正答率（ 1/2 ）

言語	GPT-4o	GPT-4.1	o3-high
アラビア語	83.1%	84.4%	90.4%
ベンガル語	80.1%	82.7%	87.8%
中国語（簡体字）	84.2%	86.1%	89.3%
フランス語	84.6%	87.0%	90.6%
ドイツ語	83.6%	85.5%	90.5%
ヒンディー語	81.9%	84.2%	89.8%
インドネシア語	84.0%	85.9%	89.8%

OpenAI. Multilingual MMLU Benchmark Results. 2025 年モデル、改訂 652c89d 。
https://github.com/openai/simple-evals/blob/652c89d/multilingual_mmlu_benchmark_results.md

OpenAI の言語別正答率（ 2/2 ）

言語	GPT-4o	GPT-4.1	o3-high
イタリア語	84.5%	86.9%	91.2%
日本語	83.5%	85.6%	89.0%
韓国語	82.9%	84.9%	89.3%
ポルトガル語（ブラジル）	83.6%	87.0%	91.0%
スペイン語	84.3%	87.6%	91.1%
スワヒリ語	77.9%	79.5%	86.0%
ヨルバ語	62.1%	64.7%	78.0%

OpenAI. Multilingual MMLU Benchmark Results. 2025 年モデル、改訂 652c89d 。
https://github.com/openai/simple-evals/blob/652c89d/multilingual_mmlu_benchmark_results.md

日本語の全 57 科目と問題数（ 1/3 ）

科目	問数	科目	問数
抽象代数学	100	大学物理学	102
解剖学	135	情報セキュリティ	100
天文学	152	概念物理学	235
企業倫理	100	計量経済学	114
臨床知識	265	電気工学	145
大学生物学	144	初等数学	378
大学化学	100	形式論理学	126
大学計算機科学	100	世界の事実	100
大学数学	100	高校生物学	310
大学医学	173	高校化学	203

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

日本語の全 57 科目と問題数（ 2/3 ）

科目	問数	科目	問数
高校計算機科学	100	高校アメリカ史	204
高校ヨーロッパ史	165	高校世界史	237
高校地理	198	人間の加齢	223
高校政治・統治	193	人間の性	131
高校マクロ経済学	390	国際法	121
高校数学	270	法理学	108
高校ミクロ経済学	238	論理的誤謬	163
高校物理学	151	機械学習	112
高校心理学	545	経営管理	103
高校統計学	216	マーケティング	234

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

日本語の全 57 科目と問題数（ 3/3 ）

科目	問数	科目	問数
医学遺伝学	100	専門心理学	612
その他の知識	783	広報	110
道徳上の論争	346	安全保障研究	245
道徳的状況判断	895	社会学	201
栄養学	306	アメリカ外交政策	100
哲学	311	ウイルス学	166
先史学	324	世界の宗教	171
専門会計学	282		
専門法律学	1,534		
専門医学	272		

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

世界史では、言語によって設問の並びが違う

- 公開 CSV の行 5853 は、日本語では欧州と中国の火薬兵器、簡体字中国語ではダリオの詩、韓国語では古代の死後世界を扱っている。
- 同じ科目内番号 1 でも、設問本文と選択肢が異なる。いずれも高校世界史の問題として配布されている。
- 本資料の言語間の比較例は、設問と選択肢の対応を確認した機械学習の 1 問を使った。

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

公開データは 2024 年の改訂で固定している

- 初回公開は 2024 年 9 月 13 日。 2024 年 10 月 3 日の README 改訂で、各言語の分割名を test へそろえた。
- 参照した最新改訂は 2024 年 10 月 16 日の 325a01d 。中国語設定名の表記を ZH_CH から ZH_CN へ修正した。
- 14 CSV の取得サイズは合計 124,869,536 bytes 、約 119.09 MiB 。公式データカードは MIT を指定している。

OpenAI. MMMLU: 公式データの改訂履歴。 2024 年 9 月初公開。 https://huggingface.co/datasets/openai/MMMLU/commits/main

3. 制作機関と参考文献

OpenAI が、専門翻訳者による翻訳を公開した

- MMMLU の公開元は OpenAI 。データカードは専門翻訳者を用いたと説明し、ヨルバ語などデータ資源が少ない言語も対象にしている。
- 元の MMLU は Dan Hendrycks 、 Collin Burns らの研究。最終著者は Jacob Steinhardt で、英語の知識評価を 57 科目へ広げた。

OpenAI (2024). Multilingual Massive Multitask Language Understanding (MMMLU). MIT 、改訂 325a01d 。 https://huggingface.co/datasets/openai/MMMLU

Hendrycks et al. (2021). Measuring Massive Multitask Language Understanding. ICLR 。 https://arxiv.org/abs/2009.03300

参考文献

Multilingual Massive Multitask Language Understanding (MMMLU)

OpenAI / Hugging Face Datasets / 2024 / MIT

専門翻訳者による 14 言語の設問、四つの選択肢、正解と科目を配布する。

https://huggingface.co/datasets/openai/MMMLU

Measuring Massive Multitask Language Understanding

Dan Hendrycks, Collin Burns et al. / ICLR 2021

57 科目の知識評価を提案し、問題の収集、分割、初期モデルの成績を報告する。

https://arxiv.org/abs/2009.03300

参考文献

Multilingual MMLU Benchmark Results

OpenAI / simple-evals / 2025 年モデル / 改訂 652c89d

言語別のモデル成績を掲載し、同じリポジトリで入力・回答抽出・採点の実装を公開する。

https://github.com/openai/simple-evals/blob/652c89d/multilingual_mmlu_benchmark_results.md

Gemini 3.1 Pro: Model Card

Google DeepMind / 2026 年 2 月の評価

MMMLU を含むモデル評価と、モデルの仕様・利用条件を掲載する。

https://deepmind.google/models/model-cards/gemini-3-1-pro/

参考文献

Gemini 3.1 Pro: Evaluation Methodology

Google DeepMind / 2026 年 2 月

Gemini の自社評価と他社の公表値の採用、思考設定などの比較条件を説明する。

https://deepmind.google/models/evals-methodology/gemini-3-1-pro/

Global MMLU: Understanding and Addressing Cultural and Linguistic Biases in Multilingual Evaluation

Shivalika Singh et al. / 2024 初稿・ 2025 改訂 / arXiv:2412.03304v2

42 言語の評価と文化依存性の注釈を公開し、多言語評価の偏りを分析する。

https://arxiv.org/abs/2412.03304v2