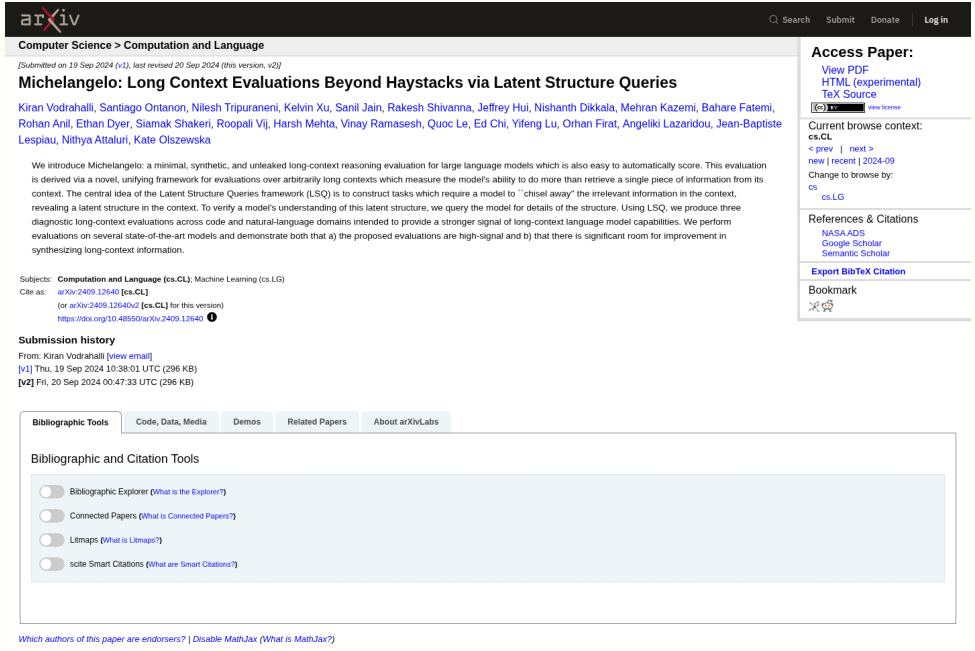
MRCR v2

Multi-round Coreference Resolution

長い会話の中で、似た依頼の順序をたどる
指定された過去の応答を再掲する評価

sasakiy84

MRCR を説明する原著の公開ページ



Vodrahalli et al. (2024). Michelangelo: Long Context Evaluations Beyond Haystacks via Latent Structure Queries. arXiv v2 。
https://arxiv.org/abs/2409.12640v2

1. 長い会話から、指定した応答を探す

2. 類似度による採点とモデル比較

3. 会話の作成とデータの構成

4. 公開と利用方法

1. 長い会話から指定した応答を探す

同じ依頼の「何番目か」を、長い会話で追う

- MRCR は、長い会話の中で繰り返される依頼を見分け、指定された出現順の応答を再掲する評価。 Google DeepMind が公開した v2 を扱う。
- 依頼は「形式・題材・文体」の組で決まる。同じ組の依頼が 2 ・ 4 ・ 8 回現れ、毎回異なる文章が応答として付いている。
- 最後に「 4 番目の、改まった文体の宇宙探査エッセイ」のように指定する。モデルは 12 文字の指定文字列を先頭へ付け、該当する応答を返す。

Google DeepMind (2026). MRCR v2: 公式データ・生成手順・評価実装。
https://github.com/google-deepmind/eval_hub/tree/master/eval_hub/mrcr_v2

名前だけの検索から、条件と順序の追跡へ

- 長文から一つの目印を探すだけの評価に対して、 MRCR は似た依頼を複数置く。同じ題材でも、文章の形式や文体が異なる。
- 形式・題材・文体がすべて同じ依頼について、何回目の応答かまで数える。手掛かりが同じでも、再掲すべき文章は回ごとに変わる。
- 会話を長くしながら、同じ処理を続けられるかを調べる。MRCR は Multi-round Coreference Resolution の略。

Google DeepMind (2026). MRCR v2: 公式データ・生成手順・評価実装。
https://github.com/google-deepmind/eval_hub/tree/master/eval_hub/mrcr_v2

公開 CSV から、本編 3 問と追加 10 問を選ぶ

- 本編では、２・４・8-needle の各 1 問を示す。 needle は、指定の条件に合う依頼への応答を指し、 2-needle ならその応答が 2 件ある。
- 掲載例は、公式 v2p1 の 4K ～ 8K トークン区間から選んだ。会話表は、条件に一致する応答の冒頭を、出現順に抜き出している。
- 最終指示は全文、参照応答は冒頭の連続抜粋。 Appendix は、異なる形式・題材・文体を指定する別の 10 問。

Google DeepMind (2026). MRCR v2: download.sh が指定する v2p1 の CSV 。
https://github.com/google-deepmind/eval_hub/blob/master/eval_hub/mrcr_v2/download.sh

実例 1 ：園芸の短編小説が 2 回現れる

出現順	応答の冒頭（抜粋）
1	Look, I get it. You’re a numbers guy. ROI, …
2	**Alright, listen up! We’re facing a formidable …**

一致する依頼への応答を出現順に抜粋。太字が指定対象。

Google DeepMind. MRCR v2 / v2p1 / 2-needle / 4K–8K 区間 / CSV 行 0 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_2needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

実例１：２番目の園芸の短編小説を返す

最終指示（配布原文・全文）

Prepend 7XXicgRFSQWl to the second short story about gardening tips in a informal style. Do not include any other text in your response.

「園芸のコツ」を題材にした、くだけた文体の短編小説の２番目を再掲する。

参照応答の冒頭（連続抜粋）

> 7XXicgRFSQWlAlright, listen up! We’re facing a formidable enemy. Not dragons, not goblins… weeds. And slugs.

Google DeepMind. MRCR v2 / v2p1 / 2-needle / 4K–8K 区間 / CSV 行 0 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_2needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

実例２：神話のエッセイが４回現れる

出現順	応答の冒頭（抜粋）
1	**## Oh. My. Gods! Ancient Myths are *Amazing*! ...**
2	## So, You Want to Invest in...Ancient Myths? A ...
3	## So You Want to Live Like a Myth? A Word of ...
4	## Why Did Zeus Need So Many Dates? A Humorous ...

一致する依頼への応答を出現順に抜粋。太字が指定対象。

Google DeepMind. MRCR v2 / v2p1 / 4-needle / 4K–8K 区間 / CSV 行 0 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_4needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

実例２：最初の神話エッセイを返す

最終指示（配布原文・全文）

Prepend JclDh94LsQ5l to the first essay about ancient myths in a humorous style. Do not include any other text in your response.

「古代の神話」を題材にした、ユーモラスな文体のエッセイの１番目を再掲する。

参照応答の冒頭（連続抜粋）

JclDh94LsQ5l## Oh. My. Gods! Ancient Myths are *Amazing*!

Google DeepMind. MRCR v2 / v2p1 / 4-needle / 4K–8K 区間 / CSV 行 0 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_4needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

実例３：宇宙探査（１～４番目）

出現順	応答の冒頭（抜粋）
1	## The Ascendant Horizon: Charting Future …
2	## Is Humanity’s Future Written in the Stars? …
3	## The Imperative and Imminent Challenges of …
4	**## To the Threshold of the Infinite: A Call to …**

一致する依頼への応答を出現順に抜粋。太字が指定対象。

Google DeepMind. MRCR v2 / v2p1 / 8-needle / 4K–8K 区間 / CSV 行 0 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_8needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

実例３：宇宙探査（５～８番目）

出現順	応答の冒頭（抜粋）
5	## The Dawning of a Universe Within Reach: A …
6	## The Prudent Expansion: Justifying Investment …
7	## Reaching for the Stars: Why We Explore Space …
8	## MEMORANDUM: Project Nightingale – Current …

一致する依頼への応答を出現順に抜粋。太字が指定対象。

Google DeepMind. MRCR v2 / v2p1 / 8-needle / 4K–8K 区間 / CSV 行 0 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_8needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

実例３：４番目の宇宙探査エッセイを返す

最終指示（配布原文・全文）

Prepend HROIt7tHWU5j to the fourth essay about space exploration in a formal style. Do not include any other text in your response.

「宇宙探査」を題材にした、改まった文体のエッセイの４番目を再掲する。

参照応答の冒頭（連続抜粋）

HROIt7tHWU5j## To the Threshold of the Infinite: A Call to Exploration

Google DeepMind. MRCR v2 / v2p1 / 8-needle / 4K–8K 区間 / CSV 行 0 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_8needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

2. 類似度による採点とモデル比較

指定文字列の後ろを、参照応答と比べる

段階	公開実装の処理
指定文字列を探す	応答内で最後に現れる 12 文字の指定文字列を探す
本文を切り出す	その直後の文章を取り出し、前後の空白を除く
類似度を計算	参照本文と SequenceMatcher で比較する
平均を取る	各問の 0 〜 1 の類似度を平均して報告する

Google DeepMind (2026). MRCR v2: run_evaluation.py / mrcr_v2_metric 。
https://github.com/google-deepmind/eval_hub/blob/master/eval_hub/mrcr_v2/run_evaluation.py

短い文字列で、採点の動きを見る

応答本文（説明用）	参照本文	得点
cat	cat	1.00
cut	cat	0.67
指定文字列がない	cat	0.00

指定文字列が見つからなければ 0 。 cat と cut は 3 文字中 2 文字が一致する。

Google DeepMind (2026). MRCR v2: run_evaluation.py / mrcr_v2_metric 。
https://github.com/google-deepmind/eval_hub/blob/master/eval_hub/mrcr_v2/run_evaluation.py

MRCR v2 ： 128K までの平均類似度（ % ）

モデル	思考設定	得点
Gemini 3.1 Pro	High	84.9
Claude Sonnet 4.6	Max	84.9
Claude Opus 4.6	Max	84.0
GPT-5.2	High	83.8
Gemini 3 Pro	High	77.0

Google DeepMind (2026). Gemini 3.1 Pro: Model Card. 2026 年 2 月の比較。
https://deepmind.google/models/model-cards/gemini-3-1-pro/

128K までの累積評価と、 1M での点評価

- Google の 2026 年 2 月のモデルカードは、 8-needle で 128K までの累積得点と、 1M 付近の長さでの点評価を報告する。
- Gemini 3.1 Pro は、 128K までで 84.9% 、 1M で 26.3% 。 Gemini 3 Pro は、それぞれ 77.0% と 26.3% だった。
- 評価手順書は、再現用データの公開先として Google DeepMind の eval_hub にある mrcr_v2 を指定している。

Google DeepMind (2026). Gemini 3.1 Pro: Evaluation Methodology. MRCR v2 は 8-needle 。
https://deepmind.google/models/evals-methodology/gemini-3-1-pro/

3. 会話の作成とデータの構成

文章を生成し、順序を変えて会話へ埋め込む

工程	公開コードでの作り方
素材の文章を生成	形式・題材・文体ごとに異なる文章を用意
応答を組にする	同じ依頼に対する２・４・８個の応答を選ぶ
他の依頼を混ぜる	別の題材や形式のやり取りを挿入する
順序と長さを調整	会話内の配置を変え、長さの区間へ合わせる
最終指示を付ける	指定の出現順と、参照応答を対応させる

Google DeepMind (2026). MRCR v2: 形式・題材・文体と会話の組み立て。
https://github.com/google-deepmind/eval_hub/blob/master/eval_hub/mrcr_v2/mrcr_utils.py

三つの条件の組で、依頼を識別する

条件	公開生成コードの設定例
形式	メール、短編小説、ブログ、ツイート、詩など
題材	宇宙探査、園芸、架空の製品発表、神話など
文体	改まった、くだけた、ユーモラス、技術的、古風

例えば「詩 × ペンギン × ユーモラスな文体」が一つの依頼になる。

Google DeepMind (2026). MRCR v2: 公開の文章生成コードの設定。
https://github.com/google-deepmind/eval_hub/blob/master/eval_hub/mrcr_v2/generate_mrcr_texts.py

会話を長くする区間と、 needle 数を選べる

設定	公式ダウンローダーでの構成
needle 数	2 / 4 / 8
長さの最短区間	4,096 より長く、 8,192 トークン以下
128K まで	131,072 トークンまでの累積データも配布
長い区間	1M 、 2M 、 4M 、 8M に向かう区間を配布

Google DeepMind (2026). MRCR v2: download.sh が指定する v2p1 の CSV 。
https://github.com/google-deepmind/eval_hub/blob/master/eval_hub/mrcr_v2/download.sh

4. 公開と利用方法

2024 年の MRCR から、公開 v2 の再現評価へ

- 2024 年の Michelangelo 論文は、形式と題材を手掛かりに、会話中の順序をたどる MRCR を説明した。
- Google DeepMind の公開 v2 は、文体も条件に加えた会話と、２・４・8-needle のデータを提供する。
- 2026 年の Gemini 3.1 Pro は、 8-needle の MRCR v2 を公式評価に採用。公開データを再現用に案内する。

Google DeepMind (2026). MRCR v2: 公式データ・生成手順・評価実装。
https://github.com/google-deepmind/eval_hub/tree/master/eval_hub/mrcr_v2

CSV から最終指示と参照応答を読む

```
import csv

csv.field_size_limit(100_000_000)
with open("mrcr_v2.csv", newline="") as f:
    rows = list(csv.DictReader(f))
row = rows[0]
print(row["view_ops"])
print(row["answer"][:120])
```

公式 CSV を mrcr_v2.csv として保存し、先頭行を読む。

Google DeepMind (2026). MRCR v2: download.sh が指定する v2p1 の CSV 。
https://github.com/google-deepmind/eval_hub/blob/master/eval_hub/mrcr_v2/download.sh

長文の中で、似た依頼と順序を保って追えるか

- MRCR v2 は、長い会話から条件と出現順に合う過去の応答を再掲する評価。形式・題材・文体を組み合わせた依頼が繰り返される。
- 応答には 12 文字の指定文字列を付け、参照本文との文字列類似度で採点する。公開実装と、長さ・ needle 数を変えた CSV を入手できる。
- Gemini 3.1 Pro の公式比較では、 8-needle の 128K までで 84.9% 、 1M で 26.3% 。会話が長くなったときの追跡能力を調べる資料になる。

Google DeepMind (2026). MRCR v2: 公式データ・生成手順・評価実装。
https://github.com/google-deepmind/eval_hub/tree/master/eval_hub/mrcr_v2

Appendix

1. 形式・題材の異なる追加例
2. 実データと採点の詳細
3. 制作機関と参考文献

1. 形式・題材の異なる追加例

追加例 1 ：ペンギンの技術的なツイート

最終指示（配布原文・全文）

Prepend Q7jYVGPcnz10 to the second tweet about penguins in a technical style. Do not include any other text in your response.

「ペンギン」を題材にした、技術的な文体のツイートの 2 番目を再掲する。

参照応答の冒頭（連続抜粋）

Q7jYVGPcnz10Penguin locomotion: not "waddling inefficiency" as you suggest. Highly optimized for glacial/ice

Google DeepMind. MRCR v2 / v2p1 / 2-needle / 4K–8K 区間 / CSV 行 2 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_2needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

追加例２：宇宙探査を題材にした古風な詩

最終指示（配布原文・全文）

Prepend h4z2lNFlIUaU to the first poem about space exploration in a archaic style. Do not include any other text in your response.

「宇宙探査」を題材にした、古風な文体の詩の１番目を再掲する。

参照応答の冒頭（連続抜粋）

h4z2lNFlIUaUHark, ye bold hearts, and lend thine ear!

Google DeepMind. MRCR v2 / v2p1 / 2-needle / 4K–8K 区間 / CSV 行４（０始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_2needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

追加例３：フラミンゴのなぞなぞ

最終指示（配布原文・全文）

Prepend sG29eA0kcEo0 to the first riddle about flamingoes in a informal style. Do not include any other text in your response.

「フラミンゴ」を題材にした、くだけた文体のなぞなぞの１番目を再掲する。

参照応答の冒頭（連続抜粋）

> sG29eA0kcEo0Okay, here's a riddle about flamingos, informal style, emphasizing challenges:

Google DeepMind. MRCR v2 / v2p1 / 2-needle / 4K–8K 区間 / CSV 行 6 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_2needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

追加例 4 ：架空の製品発表の詩

最終指示（配布原文・全文）

Prepend ekKyY8Sdf6gC to the second poem about a fictional product launch in a informal style. Do not include any other text in your response.

「架空の製品発表」を題材にした、くだけた文体の詩の 2 番目を再掲する。

参照応答の冒頭（連続抜粋）

ekKyY8Sdf6gCOkay, look, I know what you're thinking. Another gadget? Seriously?

Google DeepMind. MRCR v2 / v2p1 / 4-needle / 4K–8K 区間 / CSV 行 4 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_4needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

追加例 5 ：古風な園芸の短編小説

最終指示（配布原文・全文）

Prepend X5SOAJjpF9d2 to the second short story about gardening tips in a archaic style. Do not include any other text in your response.

「園芸のコツ」を題材にした、古風な文体の短編小説の 2 番目を再掲する。

参照応答の冒頭（連続抜粋）

X5SOAJjpF9d2Old Man Tiber, they called me, though my bones creaked less from age than from years spent bent

Google DeepMind. MRCR v2 / v2p1 / 4-needle / 4K–8K 区間 / CSV 行 8 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_4needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

追加例 6 ：ユーモラスな園芸の詩

最終指示（配布原文・全文）

Prepend fha9KZF3rN1k to the first poem about gardening tips in a humorous style. Do not include any other text in your response.

「園芸のコツ」を題材にした、ユーモラスな文体の詩の 1 番目を再掲する。

参照応答の冒頭（連続抜粋）

fha9KZF3rN1kRight, you want ROI? Forget tech stocks, listen close,

Google DeepMind. MRCR v2 / v2p1 / 4-needle / 4K–8K 区間 / CSV 行 12 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_4needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

追加例 7 ：ペンギンを題材にした詩

最終指示（配布原文・全文）

Prepend DpyaXA527tK7 to the fifth poem about penguins in a humorous style. Do not include any other text in your response.

「ペンギン」を題材にした、ユーモラスな文体の詩の 5 番目を再掲する。

参照応答の冒頭（連続抜粋）

DpyaXA527tK7Right then, listen up, you feathered fiends!

Google DeepMind. MRCR v2 / v2p1 / 8-needle / 4K–8K 区間 / CSV 行 8 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_8needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

追加例 8 ：技術的な文体の神話の短編小説

最終指示（配布原文・全文）

Prepend OUo3LHB6CN19 to the fourth short story about ancient myths in a technical style. Do not include any other text in your response.

「古代の神話」を題材にした、技術的な文体の短編小説の 4 番目を再掲する。

参照応答の冒頭（連続抜粋）

OUo3LHB6CN19## Project: Mythological Resonance – Preliminary Report

Google DeepMind. MRCR v2 / v2p1 / 8-needle / 4K–8K 区間 / CSV 行 16 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_8needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

追加例 9 ：改まった文体の製品発表ブログ

最終指示（配布原文・全文）

Prepend 1XzzaxnaJc94 to the second blog post about a fictional product launch in a formal style. Do not include any other text in your response.

「架空の製品発表」を題材にした、改まった文体のブログ記事の 2 番目を再掲する。

参照応答の冒頭（連続抜粋）

1XzzaxnaJc94## Is the Future of Personal Climate Control... Wearable? Introducing the ‘Aura’ by Chronosync.

Google DeepMind. MRCR v2 / v2p1 / 8-needle / 4K–8K 区間 / CSV 行 24 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_8needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

追加例 10 ：古風な文体の製品発表ツイート

最終指示（配布原文・全文）

Prepend R8joP68qUWGv to the first tweet about a fictional product launch in a archaic style. Do not include any other text in your response.

「架空の製品発表」を題材にした、古風な文体のツイートの 1 番目を再掲する。

参照応答の冒頭（連続抜粋）

R8joP68qUWGvHark! Doth thy visage yearn for luminescence beyond compare?

Google DeepMind. MRCR v2 / v2p1 / 8-needle / 4K–8K 区間 / CSV 行 32 （0 始まり）。
https://storage.googleapis.com/mrcr_v2/mrcr_v2p1_8needle_in_%284096%2C8192%29_dynamic_fewshot_text_style_fast.csv

2. 実データと採点の詳細

取得した 4K ～ 8K 区間の公開 CSV

needle 数	行数	会話数	平均長
2	82	6	6,357.6
4	84	8	6,488.0
8	80	6	6,643.3

平均長は CSV の context_len （トークン）。会話は最終指示を除いて重複排除。

Google DeepMind (2026). MRCR v2: download.sh が指定する v2p1 の CSV 。
https://github.com/google-deepmind/eval_hub/blob/master/eval_hub/mrcr_v2/download.sh

CSV の 1 行は、最終指示と参照応答の一組

- 同じ長い会話から、異なる依頼や出現順を指定した複数の問題を作れる。 CSV の各行は、会話・最終指示・正しい参照応答を一組として持つ。
- この資料の実例は、形式・題材・文体の指定が異なる 13 問。参照応答が、会話内の指定された順序の文章と一致することを確認した。
- queries は先頭の解答例と本番の会話、 view_ops は最後の指示、 answer は指定文字列と再掲する文章を持つ。

Google DeepMind (2026). MRCR v2: 公式データ・生成手順・評価実装。
https://github.com/google-deepmind/eval_hub/tree/master/eval_hub/mrcr_v2

CSV に含まれる主な情報

列	内容
queries	会話と最終指示を含む入力文字列
answer	指定文字列＋正しい応答全文
view_ops	出現順・形式・題材・文体の指定
context_len	配布された入力長のトークン数
num_relevant	一致する依頼への応答の数
relevant_context_positions	一致する応答が置かれた会話内の位置

Google DeepMind (2026). MRCR v2: 形式・題材・文体と会話の組み立て。
https://github.com/google-deepmind/eval_hub/blob/master/eval_hub/mrcr_v2/mrcr_utils.py

指定文字列を探し、最後の出現より後ろを採点

- 課題の指示は、 12 文字の指定文字列を応答の先頭に置く形式。公開採点関数は、その文字列の最後の出現を rfind で探している。
- 採点関数は、見つけた位置より後ろを切り出し、前後の空白を除いて参照本文と比較する。指定文字列が応答中にない場合は 0 点。
- 冒頭に余分な文章があっても、指定文字列が後で現れれば本文を切り出す実装になっている。

Google DeepMind (2026). MRCR v2: run_evaluation.py / mrcr_v2_metric 。
https://github.com/google-deepmind/eval_hub/blob/master/eval_hub/mrcr_v2/run_evaluation.py

公開 v2 と、 OpenAI 版 MRCR の配布先

- この資料で使ったのは、 Google DeepMind の eval_hub が公開する MRCR v2 。公式ダウンローダーが指定する v2p1 の CSV を取得した。
- OpenAI も 2025 年に、別の MRCR データを Hugging Face で公開している。こちらは、 2025 年 12 月に対象応答の数と正解の誤りを修正した。
- Gemini 3.1 Pro の手順書が再現用として案内するのは、 Google DeepMind 版の mrcr_v2 。実例とモデル比較の出典をこの公開先に合わせた。

Google DeepMind (2026). Gemini 3.1 Pro: Evaluation Methodology. MRCR v2 は 8-needle 。
https://deepmind.google/models/evals-methodology/gemini-3-1-pro/

評価条件と、データの入手先

- 公式 README は、コード実行ツールの有無を評価条件に記すよう求める。会話をコードで検索する場合と、モデルが会話を読む場合で、課題の処理が変わる。
- 公開モジュールのライセンスは Apache 2.0 。生成・採点のコードを参照でき、 CSV は Google Cloud Storage から取得する。
- 本資料は最短の 4K ～ 8K 区間の CSV3 本を取得した。より長い区間は download.sh で選んで取得できる。

Google DeepMind (2026). MRCR v2: 公式データ・生成手順・評価実装。
https://github.com/google-deepmind/eval_hub/tree/master/eval_hub/mrcr_v2

3. 制作機関と参考文献

Google DeepMind の長文評価

- MRCR を説明した Michelangelo 論文の第一著者は Kiran Vodrahalli 、最終著者は Kate Olszewska 。 Google DeepMind と Google Research の研究として 2024 年に公開された。
- 論文は、長い入力の中で不要な情報を除き、必要な構造を取り出す評価を扱う。 MRCR は、そのうち自然言語の会話を使う課題。
- 公開 v2 は Google DeepMind の eval_hub に収録され、モデルカードの数値を再現するためのデータと評価コードを提供する。

Vodrahalli et al. (2024). Michelangelo: Long Context Evaluations Beyond Haystacks via Latent Structure Queries. arXiv v2 。
https://arxiv.org/abs/2409.12640v2

参考文献

Michelangelo: Long Context Evaluations Beyond Haystacks via Latent Structure Queries

Kiran Vodrahalli et al. / Google DeepMind ・ Google Research / 2024

長い入力の構造を問う枠組みと、 MRCR の課題・採点・初期評価を説明する。

https://arxiv.org/abs/2409.12640v2

MRCR v2: Official Data and Code

Google DeepMind / eval_hub / 2026 / Apache 2.0 （実装）

v2p1 の CSV 、形式・題材・文体を使う会話生成、採点と集計の実装を公開する。

https://github.com/google-deepmind/eval_hub/tree/master/eval_hub/mrcr_v2

参考文献

Gemini 3.1 Pro: Model Card

Google DeepMind / 2026 年 2 月の評価

8-needle の MRCR v2 について、モデル比較と長さを変えた得点を掲載する。

https://deepmind.google/models/model-cards/gemini-3-1-pro/

Gemini 3.1 Pro: Evaluation Methodology

Google DeepMind / 2026 年 2 月

128K の累積評価と 1M の点評価を定義し、再現用の公開データを案内する。

https://deepmind.google/models/evals-methodology/gemini-3-1-pro/