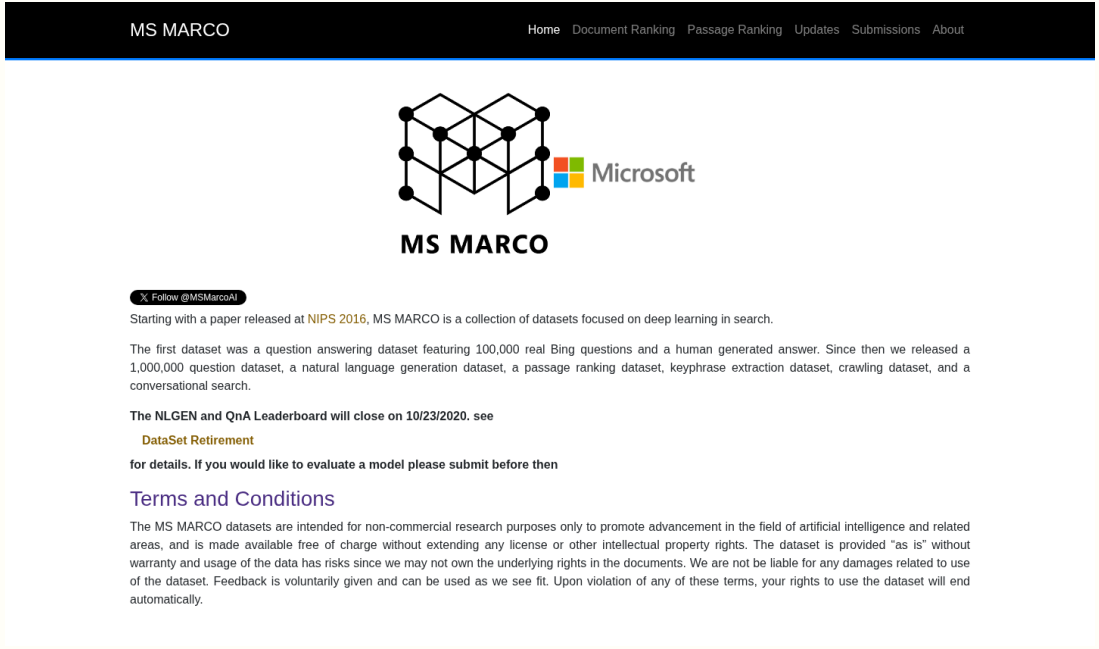
MS MARCO

Microsoft MAchine Reading COmprehension

検索質問に答える文章を上位に並べる

sasakiy84

公式サイト



[1] Microsoft. MS MARCO. https://microsoft.github.io/msmarco/

1. 検索質問と関連する文章
2. 順位の採点と HELM の成績
3. データの成立と構成
4. 検索研究での利用と入手

1. 検索質問と関連する文章

検索質問に合わせて文章を並べ替える

- Bing で実際に使われた質問と、 Web から集めた文章を対応させたデータセット群。 2016 年に読解・質問応答用として登場した。
- ここでは、質問に答える文章を上位に並べる passage ranking を中心に扱う。 HELM の regular と TREC は、この課題の評価集合が異なる。

[1] Bajaj et al. (2016). MS MARCO: A Human Generated MAchine Reading COmprehension Dataset. https://arxiv.org/abs/1611.09268

回答の文章を生成する課題から広がった

- 初期の質問応答課題では、検索で得た文章を読み、人が自然言語の回答を書いた。
- ランキング課題では、約 884 万件の文章から質問に関連する文章を探す。入力は質問と候補の文章、出力は文章の順位になる。
- HELM は、候補の文章ごとに Yes か No を出力する。その出力と対数確率から順位を作る。

[1] Bajaj et al. (2016). MS MARCO: A Human Generated MAchine Reading COmprehension Dataset. https://arxiv.org/abs/1611.09268
[2] Stanford CRFM. HELM v0.3.0, ranking_metrics.py / msmarco_scenario.py. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

実例１：メガネグマの体重

regular / HELM id5748 / passage 7967212 ／ 文章・質問の全文

原文

Query: how much does a spectacled bear weigh
Passage: Male spectacled bears are much larger than female spectacled bears, giving local farmers the impression that they live with more than one species of bear. Male bears weigh from 120 to 340 pounds 54 to 154 kg); females weigh 60 to 180 pounds (27 to 82 kg). At birth, cubs weigh from 10 to 11 ounces (284 to 312 grams).

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例１：メガネグマの体重（訳）

regular / HELM id5748 / passage 7967212 ／文章・質問の全文

質問：メガネグマの体重はどのくらいか。
文章：オスのメガネグマはメスよりはるかに大きく、地元の農家には複数種のクマがいるように思われる。オスの体重は120～340ポンド（54～154 kg）、メスは60～180ポンド（27～82 kg）。生まれたときの子グマの体重は10～11オンス（284～312 g）である。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

同じ動物の説明にも未判定がある

- この質問で関連と注釈されたのは、オス・メス・子グマの体重を説明した passage 7967212 。
- 同じ候補集合の passage 5047774 にも体重の説明があるが、関連ラベルがない。
- 未判定の文章にも答えを含むものがある。 regular の判定は疎で、関連ラベルを得た文章を上位に置けるかを測る。

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例２：価格を尋ねる検索質問

regular / HELM id7792 / passage 7791768 ／ 文章・質問の全文

原文

Query: what is wholesale price dungeness crab
Passage: Dungeness Crab Prices 2014/2015 Season. DezzerSF | Nov 17, 2014. New May Wah on Clement was selling dungeness for $4.99/lb last Saturday night. I bought two for a total of 4.6lbs. 1 was lively, the other not so much. I've had sweeter, but not sure where the crabs were from, didn't ask.

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例２：価格を尋ねる検索質問（訳）

regular / HELM id7792 / passage 7791768 ／文章・質問の全文

質問：ダンジネスクラブの卸売価格はいくらか。
文章： 2014 ／ 2015 年シーズンのダンジネスクラブ価格。 DezzerSF 、 2014 年 11 月 17 日。クレメント通りの New May Wah では、先週土曜の夜に 1 ポンド 4.99 ドルで販売していた。 2 匹を買い、合計 4.6 ポンドだった。 1 匹は元気で、もう 1 匹はそうでもなかった。もっと甘いものを食べたことはあるが、産地は聞かなかったので分からない。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

検索質問と注釈にはずれも残る

- 卸売価格を尋ねる質問に対し、関連ラベルの文章は店頭で買った価格の体験談になっている。
- 文章には 2014 年の価格と場所が含まれる。元の質問は短く、時点や場所を明示していない。
- 利用者が書いた検索質問と、人が付けた関連ラベルの組を、そのまま評価材料にする。

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例３：法律名の定義と段階的な関連度

trec / HELM id1000 / passage 8536118 ／文章・質問の全文

原文

Query: lps laws definition
Passage: LPS Act. LPS Act. a California law named for sponsors of the legislation (Lanterman, Petris, and Short) that provides for the protection and treatment of persons judged to be gravely disabled and thus unable to provide food, clothing, or shelter for themselves.

関連度：３（完全に関連）

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例３：法律名の定義と段階的な関連度（訳）

trec / HELM id1000 / passage 8536118 ／ 文章・質問の全文

質問： LPS 法の定義。
文章： LPS 法。 LPS 法。法案の提案者 Lanterman 、 Petris 、 Short にちなむカリフォルニア州法。重度の障害があると判断され、そのために食料、衣服、住居を自力で確保できない人々の保護と治療を定める。

関連度： 3 （完全に関連）

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

TREC では関連の強さを 4 段階で付ける

- TREC 2019 Deep Learning Track は、同じ文章コレクションに対して、評価担当者が多くの候補を判定した。
- 関連度 0 は非関連、 1 は質問に関連するが答えを含まない、 2 は高度に関連、 3 は完全に関連。
- HELM では、 Yes ／ No の学習例と二値の指標には 2 ・ 3 を正例として使い、 NDCG には元の段階的な値を使う。

[1] Craswell et al. (2020). Overview of the TREC 2019 Deep Learning Track. https://arxiv.org/abs/2003.07820
[2] Stanford CRFM. HELM v0.3.0, ranking_metrics.py / msmarco_scenario.py. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

2. 順位の採点と HELM の成績

最初の関連文章が何位かを測る

- RR@10 は、最初の関連文章が r 位なら 1/r 、 10 位までにない場合は 0 。
- 例として、最初の関連文章が 1 位なら 1 、 2 位なら 0.5 、 10 位なら 0.1 になる。
- 質問ごとの値を平均する。 regular の代表指標は MRR@10 で、 HELM の集計名は RR@10 。

[1] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking
[2] Stanford CRFM. HELM v0.3.0, ranking_metrics.py / msmarco_scenario.py. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

TREC は上位全体の関連度も測る

- NDCG@10 は、上位 10 件の関連度を順位に応じて割り引いて足し、理想的な順位の値で正規化する。
- HELM の実装では pytrec_eval の ndcg_cut を使う。関連度 0 〜 3 を段階的な利得として扱う。
- 1 件目の正例だけを見る RR と異なり、上位に複数の強く関連する文章を並べたかが得点に反映される。

[1] Stanford CRFM. HELM v0.3.0, ranking_metrics.py / msmarco_scenario.py. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

HELM の候補集合には qrels の文章を加える

- HELM は前処理済みの文章コレクションを CodaLab から読む。 qrels は、質問・文章 ID と関連度を記録した判定ファイル。
- HELM は BM25 の上位 30 件と、 qrels に含まれる全文章の和集合を候補にする。各文章を別々のプロンプトで評価する。
- 通常の指標は和集合全体の順位を採点する。「 topk=30 」付きの指標は、 BM25 上位 30 件に候補を限定する。

[1] Stanford CRFM. HELM v0.3.0, ranking_metrics.py / msmarco_scenario.py. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

HELM regular ： RR@10 で比較

モデル	全候補	BM25 上位 30
Anthropic-LM (2022)	0.3820	0.2167
text-davinci-003 (2022)	0.3677	0.1992
OPT-175B (2022)	0.2878	0.1553

valid 1,000 質問、各 3 試行の平均。 HELM Classic v0.4.0 掲載、実行 suite v0.3.0 。

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

HELM TREC ： NDCG@10 で比較

モデル	全候補	BM25 上位 30
text-davinci-003 (2022)	0.6438	0.6020
Anthropic-LM (2022)	0.6417	0.6115
OPT-175B (2022)	0.4481	0.5178

TREC 2019 の 43 質問、各 3 試行の平均。関連度判定済み文章を含む候補集合を使用。

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

同じモデルでも集合をまたぐ順位は変わる

- regular は質問数が多く関連判定が疎で、 TREC は 43 質問に対して関連の強さまで判定する。質問数と関連度判定の密度が異なる。
- 2 組の表は、それぞれの条件でモデルを比べたもの。データセット全体の難しさを単一の得点差に置き換えることはできない。
- 公開値は 2023 年の HELM Classic のスナップショットに属する。

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/
[2] Craswell et al. (2020). Overview of the TREC 2019 Deep Learning Track. https://arxiv.org/abs/2003.07820

3. データの成立と構成

Bing の検索質問から人が回答を書く

- 匿名化した実際の Bing 検索ログから、質問として使える英語の検索語を集めた。
- 検索結果から得た文章を人が読み、回答を書く。人が回答を書く際に選んだ文章を、関連する文章として使った。
- その後、重複する文章を除いて約 884 万件のコレクションを作り、 BM25 で各質問の候補を取得した。

[1] Bajaj et al. (2016). MS MARCO: A Human Generated MAchine Reading COmprehension Dataset. https://arxiv.org/abs/1611.09268
[2] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking

文章検索用コレクションと質問の規模

配布物	件数	単位
文章コレクション	8,841,823	文章
全質問	1,010,916	質問
train の質問	808,731	質問
regular dev.small	6,980	質問
TREC 2019 判定対象	43	質問

[1] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking
[2] Craswell et al. (2020). Overview of the TREC 2019 Deep Learning Track. https://arxiv.org/abs/2003.07820

同じ名称の下に複数の課題がある

- 質問応答では、提示された文章から自然言語の答えを作る。 well-formed answer では、文として整った回答も扱う。
- passage ranking は短い文章を、 document ranking は Web 文書を検索する。文書版は本文の単位やコレクションが異なる。
- この資料の実例と HELM の結果は、 v1 の passage ranking に対応する。

[1] Microsoft. MS MARCO. https://microsoft.github.io/msmarco/
[2] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking

regular と TREC は判定の作り方が異なる

- regular は、質問応答の回答作成で使った文章から関連ラベルを得る。候補の全文章を網羅的に判定したわけではない。
- TREC は、参加システムの出力を集めたプールなどに対し、評価担当者が関連度 0 ～ 3 を付ける。
- HELM の regular は公開 dev.small を使い、 TREC は 2019 年の公開判定を使う。

[1] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking
[2] Craswell et al. (2020). Overview of the TREC 2019 Deep Learning Track. https://arxiv.org/abs/2003.07820

4. 検索研究での利用と入手

教師あり再ランキングの代表的な成績

手法	dev MRR@10
BM25	0.184
BM25 + BERT-large	0.372
BM25 + T5-base	0.363
BM25 + T5-large	0.383

2020 年報告。 BM25 の候補を、 MS MARCO で学習したモデルが再ランキング。

[1] Nogueira, Jiang & Lin (2020). Document Ranking with a Pretrained Sequence-to-Sequence Model. https://arxiv.org/abs/2003.06713

検索モデルの学習と評価に使われる

- BERT を使う cross-encoder は、質問と文章をまとめて読み、関連度を予測する。 T5 を使う方式は、関連／非関連を表す文字列を生成する。
- これらは MS MARCO で重みを学習する。 HELM の表は、例をプロンプトに示す評価であり、学習方式と候補集合が異なる。
- Sentence Transformers は、 MS MARCO の正例・負例を用い、交差エントロピーなど複数の損失関数で学習する公開例を提供している（ 2026-10-18 確認）。

[1] Nogueira, Jiang & Lin (2020). Document Ranking with a Pretrained Sequence-to-Sequence Model. https://arxiv.org/abs/2003.06713
[2] Sentence Transformers. MS MARCO cross-encoder training example (accessed 2026-10-18). https://github.com/huggingface/sentence-transformers/tree/master/examples/cross_encoder/training/ms_marco

必要なファイルを課題に合わせて選ぶ

- 文章本文には collection 、質問には queries 、関連度の正解には qrels 、既存候補の再ランキングには top1000 を使う。
- 公式配布表では、 collection.tar.gz は約 2.9 GB 、queries.tar.gz は約 42 MB 。圧縮配布物の掲載値である。
- 公式の評価用集合では正解ラベルを公開していない。公開 dev で検証し、公式評価には所定の形式で順位を提出する。

[1] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking

非商用の研究目的で配布される

- 公式の条件は、人工知能と関連分野の進展を目的とする非商用研究での利用を対象としている。
- 文章には Web 由来の内容が含まれ、配布は元文書の知的財産権の許諾を追加するものではない。
- 配布先の条件を読み、使うコレクション・質問集合・qrels をそろえて取得する。

[1] Microsoft. MS MARCO. https://microsoft.github.io/msmarco/

検索質問と文章の対応を測るデータ

- MS MARCO は、実際の検索質問と Web の文章を結び付け、質問応答から大規模な文章検索へ発展した。
- regular は多数の質問と疎な関連判定、 TREC 2019 は少数の質問と段階的な判定を提供する。
- HELM では文章が質問に答えているかを判定する。候補集合・正例の定義・指標をそろえると、公開得点の意味を追える。

[1] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking
[2] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

Appendix

1. 追加の実例
2. 実行条件の詳細
3. 研究と参考文献

実例 4 ：燃料の利点を説明する文章

regular / HELM id3090 / passage 7657714 ／ 文章・質問の全文

原文

Query: what are the benefits of fossil fuels
Passage: Benefits of fossil fuels. Fossil fuels are basically the remains of animals and plants and these are good energy resources. The three main fossil fuels are natural gas, oil, and coal. Fossil fuels are low in cost and are very important resources for our economy. Fossil fuels are used to generate electricity used as fuels for transportation. Because of their low costs, they are available to one and all.

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 4 ：燃料の利点を説明する文章（訳）

regular / HELM id3090 / passage 7657714 ／ 文章・質問の全文

質問：化石燃料にはどのような利点があるか。
文章：化石燃料の利点。化石燃料は基本的に動植物の遺骸であり、よいエネルギー資源である。主な 3 種類は天然ガス、石油、石炭。化石燃料は低コストで、経済にとって非常に重要な資源である。発電や輸送用の燃料として使われる。低コストなので、誰もが利用できる。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 5 ：相関と回帰の違い

regular / HELM id2237 / passage 3165836 ／ 文章・質問の全文

原文

Query: can a correlational study use regression analysis
Passage: It is important to recognize that regression analysis is fundamentally different from. ascertaining the correlations among different variables. Correlation determines the. strength of the relationship between variables, while regression attempts to describe that. relationship between these variables in more detail.

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 5 ：相関と回帰の違い（訳）

regular / HELM id2237 / passage 3165836 ／ 文章・質問の全文

質問：相関研究で回帰分析を使えるか。
文章：回帰分析は、複数の変数の相関を確かめることとは根本的に異なると理解する必要がある。相関は変数間の関係の強さを決める。一方、回帰はその変数間の関係を、より詳しく記述しようとする。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 6 ：金利の質問と費用の説明

regular / HELM id2142 / passage 5680372 ／ 文章・質問の全文

原文

Query: is home improvement interest deductible
Passage: If you use your home purely as your personal residence, you cannot deduct the cost of home improvements. These costs are nondeductible personal expenses. However, this doesn't mean that home improvements do not have a tax benefit.

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 6 ：金利の質問と費用の説明（訳）

regular / HELM id2142 / passage 5680372 ／ 文章・質問の全文

質問：住宅改修の利息は控除できるか。
文章：自宅を純粋に個人の住居として使う場合、住宅改修費用は控除できない。これらは控除できない個人的な支出である。ただし、住宅改修に税務上の利点がないという意味ではない。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例７：感嘆の表現を定義する

regular / HELM id3126 / passage 7192489 ／ 文章・質問の全文

原文

Query: harumph define
Passage: Harumph is defined as an expression of dissatisfaction, disdain or unhappiness. When someone tells you do to something you don't want to do, this is an example of a situation where you might say harumph.

関連ラベル： 1

日本語訳

質問： harumph を定義せよ。
文章： harumph は、不満、軽蔑、または不幸の表現と定義される。やりたくないことをするよう誰かに言われた場合は、 harumph と言うかもしれない状況の一例である。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 8 ：カバが息を止める長さ

regular / HELM id3591 / passage 5729188 ／ 文章・質問の全文

原文

Query: how long can a hippo hold its breath underwater
Passage: Quick Answer. When submerged underwater, hippos can hold their breath for 5 minutes or even longer if needed. Hippos have nostrils located on the top of their heads, which allows them to breathe even if the rest of their body is under water. Continue Reading.

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 8 ：カバが息を止める長さ（訳）

regular / HELM id3591 / passage 5729188 ／ 文章・質問の全文

質問：カバは水中でどのくらい息を止めていられるか。
文章：簡潔な答え。カバは水に潜ると、 5 分間、必要ならそれ以上も息を止められる。鼻孔は頭の上にあるので、体のほかの部分が水中にあっても呼吸できる。続きを読む。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例９：天文学者の定義

regular / HELM id7215 / passage 7231901 ／文章・質問の全文

原文

Query: define astronomers
Passage: The definition of an astronomer is a scientist who studies matter and objects in outer space. Someone who observes the stars and makes notes about their movements is an example of an astronomer. an expert in astronomy. noun.

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例９：天文学者の定義（訳）

regular / HELM id7215 / passage 7231901 ／文章・質問の全文

質問：天文学者を定義せよ。
文章：天文学者とは、宇宙空間の物質や天体を研究する科学者である。星を観測し、その動きを記録する人は天文学者の一例である。天文学の専門家。名詞。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 10 ：ルーターの役割

regular / HELM id4312 / passage 7160664 ／ 文章・質問の全文

原文

Query: what is a router meaning
Passage: Router (computing) A router is a networking device that forwards data packets between computer networks. Routers perform the traffic directing functions on the Internet. A data packet is typically forwarded from one router to another router through the networks that constitute the internetwork until it reaches its destination node.

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 10 ：ルーターの役割（訳）

regular / HELM id4312 / passage 7160664 ／ 文章・質問の全文

質問：ルーターとは何か。
文章：ルーター（コンピューティング）。ルーターは、コンピューターネットワーク間でデータパケットを転送するネットワーク機器である。インターネット上で通信の流れを制御する。通常、データパケットは、相互接続されたネットワークを構成するネットワークを通って、あるルーターから次のルーターへ転送され、宛先のノードに届く。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 11 ：水深を測る単位

regular / HELM id2411 / passage 7261226 ／ 文章・質問の全文

原文

Query: when would you use a fathom measurement
Passage: A fathom is a unit of length in the imperial and the U.S. customary systems equal to 6 feet (1.8288 m), used especially for measuring the depth of water. There are two yards (6 feet) in an imperial fathom.

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 11 ：水深を測る単位（訳）

regular / HELM id2411 / passage 7261226 ／ 文章・質問の全文

質問：どのようなときにファゾムを使うか。
文章：ファゾムは、ヤード・ポンド法と米国慣用単位系の長さの単位で、 6 フィート（ 1.8288 m ）に等しい。特に水深の測定に使われる。 1 ファゾムは 2 ヤード（ 6 フィート）である。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 12 ：地名の位置関係

regular / HELM id5519 / passage 7269235 ／ 文章・質問の全文

原文

Query: where is south easton ma
Passage: South Easton is in Bristol, Massachusetts in the New England region of the USA. It is located about 23 miles south of MA's capital city of Boston.

関連ラベル： 1

日本語訳

質問：マサチューセッツ州サウスイーストンはどこか。
文章：サウスイーストンは、米国ニューイングランド地方のマサチューセッツ州ブリストルにある。州都ボストンから南へ約 23 マイルに位置する。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 13 ：火成岩ができる過程

regular / HELM id3188 / passage 2495184 ／ 文章・質問の全文

原文

Query: what processes are needed to form igneous rock
Passage: In essence, igneous rocks are formed through the cooling and solidification of magma (or lava). As hot, molten rock rises to the surface, it undergoes changes in temperature and pressure that cause it to cool, solidify, and crystallize.

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 13 ：火成岩ができる過程（訳）

regular / HELM id3188 / passage 2495184 ／ 文章・質問の全文

質問：火成岩ができるにはどのような過程が必要か。
文章：基本的に火成岩は、マグマ（または溶岩）が冷却して固まることでできる。高温の溶融した岩石が地表へ上昇すると、温度と圧力の変化によって冷え、固まり、結晶化する。

関連ラベル： 1

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

HELM は 2 質問の正例・負例を提示する

- max_train_instances は 2 。各訓練質問から正例と負例を 1 件ずつ選ぶため、通常は 4 組の質問・文章・ Yes ／ No を提示する。
- 確認した 3 モデルは、 regular と TREC のいずれも平均提示質問数 2.0 、 prompt_truncated は 0.0 、 3 試行。
- 出力は温度 0 、最大 5 トークン、改行で停止。全候補を同じ文脈に並べる listwise 方式ではない。

[1] Stanford CRFM. HELM v0.3.0, ranking_metrics.py / msmarco_scenario.py. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark
[2] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

出力と対数確率で文章を並べる

- Yes を出した文章を最上位群に置き、対数確率の高い順に並べる。
- No の文章はその後に置き、対数確率の低い順に並べる。Yes ／ No 以外の出力は、さらに後の群になる。
- 大小文字と空白を正規化して出力を判定する。この並べ方は、 Yes の確率だけを全候補で直接比較する方式とは異なる。

[1] Stanford CRFM. HELM v0.3.0, ranking_metrics.py / msmarco_scenario.py. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

上位 30 件の外にある正例も通常値へ入る

- 追加例 9 の「天文学者」は BM25 で 435 位、例 10 の「ルーター」は 666 位、例 11 の「ファゾム」は 34 位にある。
- HELM は qrels の文章を加えるので、これらも通常のランキング候補に含まれる。上位 30 件だけの指標では対象外になる。
- 例 13 の火成岩の正例には、公開 run の参照タグに BM25 順位が付いていない。

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

原レコードと公開実行をたどる識別子

- 各実例は、 HELM suite v0.3.0 の text-davinci-003 の公開入力から取得した。原文は摂動前の最初のレコードを使う。
- ページに HELM の instance ID と passage ID を示した。instance ID は HELM 内部の ID で、元データの query ID とは別の識別子。
- 1 ページには、候補のうち 1 文章と質問の全文を示す。実際のプロンプトには訓練例も含まれ、候補ごとに別の要求を送る。

[1] Stanford CRFM. HELM Classic v0.4.0; MS MARCO published run inputs (v0.3.0). https://crfm.stanford.edu/helm/classic/v0.4.0/

Microsoft の研究者らが検索ログから構築

- Payal Bajaj は 2016 年の MS MARCO 論文の第一著者。検索質問と人が書く回答を組み合わせた大規模な読解データを報告した。
- 最終著者は Tong Wang 。著者には、情報検索を研究する Daniel Campos 、 Nick Craswell 、 Jianfeng Gao らが含まれる。
- TREC 2019 では、 Nick Craswell らが深層学習を用いた検索システムを共通の集合・判定で評価した。

[1] Bajaj et al. (2016). MS MARCO: A Human Generated MAchine Reading COmprehension Dataset. https://arxiv.org/abs/1611.09268
[2] Craswell et al. (2020). Overview of the TREC 2019 Deep Learning Track. https://arxiv.org/abs/2003.07820

参考文献

MS MARCO: A Human Generated MAchine Reading COmprehension Dataset

Payal Bajaj et al. (2016). arXiv:1611.09268.

実際の検索質問、検索結果の文章、人が書いた回答からなる読解データセットを報告する。

https://arxiv.org/abs/1611.09268

Overview of the TREC 2019 Deep Learning Track

Nick Craswell, Bhaskar Mitra, Emine Yilmaz, Daniel Campos, Ellen M. Voorhees (2020). TREC 2019 Proceedings.

文章・文書検索の共通評価、関連度判定、参加システムの結果をまとめる。

https://arxiv.org/abs/2003.07820

参考文献

Document Ranking with a Pretrained Sequence-to-Sequence Model

Rodrigo Nogueira, Zhiying Jiang, Jimmy Lin (2020). Findings of EMNLP 2020.

T5 で関連性を表す文字列を生成し、 BM25 の候補を再ランキングする方法を示す。

https://arxiv.org/abs/2003.06713

Holistic Evaluation of Language Models

Percy Liang et al. (2023). Transactions on Machine Learning Research.

共通の適応法と複数の指標で言語モデルを評価する枠組み HELM を示す。

https://arxiv.org/abs/2211.09110

参考文献

MS MARCO Passage Ranking

Microsoft. Official dataset documentation (accessed 2026-10-18).

v1 文章コレクション、質問、関連度判定、候補集合と公式の評価形式を説明する。

https://github.com/microsoft/MSMARCO-Passage-Ranking

MS MARCO Cross-Encoder Training

Sentence Transformers. Documentation (accessed 2026-10-18).

MS MARCO の質問と正例・負例を用いた cross-encoder の学習手順を示す。

https://github.com/huggingface/sentence-transformers/tree/master/examples/cross_encoder/training/ms_marco