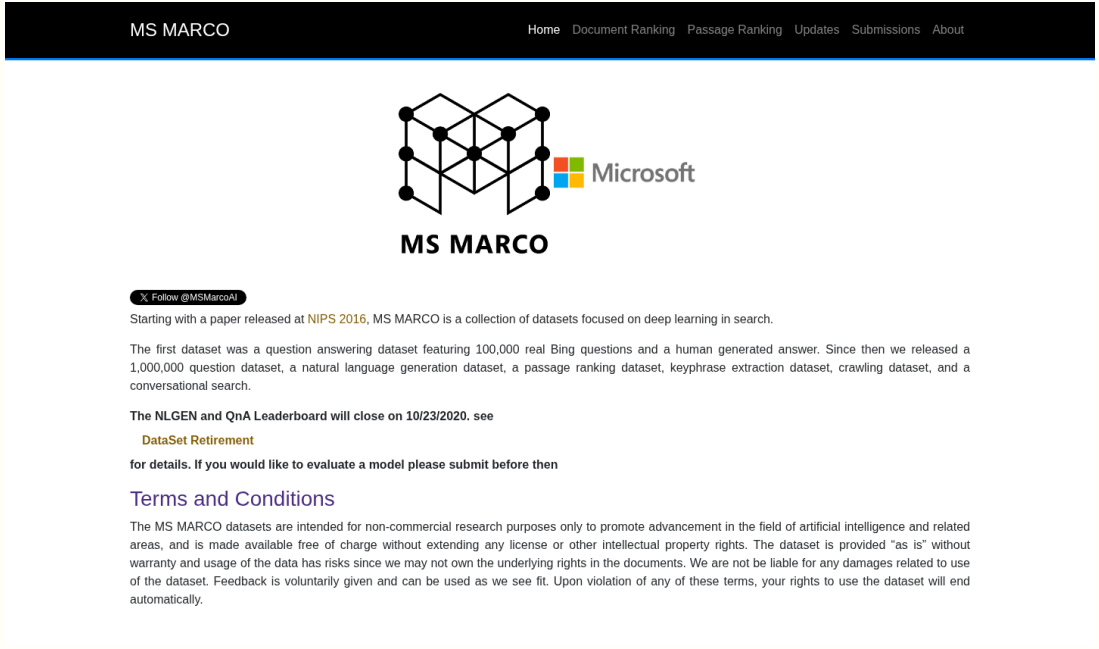
MS MARCO

Microsoft MAchine Reading COmprehension

検索質問に答える文章を上位に並べる

sasakiy84

公式サイト



[1] Microsoft. MS MARCO. https://microsoft.github.io/msmarco/

1. 検索質問と関連する文章
2. 順位の採点と HELM の成績
3. データの成立と構成
4. 検索研究での利用と入手

1. 検索質問と関連する文章

検索質問に答える文章を上位に並べる

- Bing で実際に使われた質問と、 Web から集めた文章を対応させたデータセット群。 2016 年に読解・質問応答用として登場した。
- 文章検索（ passage ranking ）では、約 884 万件の文章から、質問に関連する文章を上位に並べる。ここでは、この課題の regular と TREC 2019 を扱う。
- HELM では質問と候補の文章を 1 組ずつ読み、答えを含むかを Yes ／ No で判定する。その出力と確からしさから順位を作る。

[1] Bajaj et al. (2016). MS MARCO: A Human Generated MAchine Reading COmprehension Dataset. https://arxiv.org/abs/1611.09268
[2] Stanford CRFM. HELM: MS MARCO passage ranking. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

実例１：メガネグマの体重

英語原文（質問・文章の全文）

Query: how much does a spectacled bear weigh
Passage: Male spectacled bears are much larger than female spectacled bears, giving local farmers the impression that they live with more than one species of bear. Male bears weigh from 120 to 340 pounds 54 to 154 kg); females weigh 60 to 180 pounds (27 to 82 kg). At birth, cubs weigh from 10 to 11 ounces (284 to 312 grams).

日本語訳（全文）

質問：メガネグマの体重はどのくらいか。
文章：オスのメガネグマはメスよりはるかに大きく、地元の農家には複数種のクマがいるように思われる。オスの体重は 120 ～ 340 ポンド（ 54 ～ 154 kg ）、メスは 60 ～ 180 ポンド（ 27 ～ 82 kg ）。生まれたときの子グマの体重は 10 ～ 11 オンス（ 284 ～ 312 g ）である。

正解：関連する（１）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

答えを含んでも、未判定の文章がある

- メガネグマの質問では、オス・メス・子グマの体重を説明した文章に、関連するというラベルが付いている。
- 候補には別のメガネグマの説明もあり、体重が書かれているが、関連ラベルは付いていない。
- regular では、回答作成に使った一部の文章から関連ラベルを得ている。全候補の関連性を判定した集合ではない。

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例２：価格を尋ねる検索質問

英語原文（質問・文章の全文）

Query: what is wholesale price dungeness crab
Passage: Dungeness Crab Prices 2014/2015 Season. DezzerSF | Nov 17, 2014. New May Wah on Clement was selling dungeness for $4.99/lb last Saturday night. I bought two for a total of 4.6lbs. 1 was lively, the other not so much. I've had sweeter, but not sure where the crabs were from, didn't ask.

正解：関連する（１）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例２：価格を尋ねる検索質問（日本語訳）

日本語訳（質問・文章の全文）

質問：ダンジネスクラブの卸売価格はいくらか。
文章： 2014 ／ 2015 年シーズンのダンジネスクラブ価格。 DezzerSF 、 2014 年 11 月 17 日。クレメント通りの New May Wah では、先週土曜の夜に 1 ポンド 4.99 ドルで販売していた。 2 匹を買い、合計 4.6 ポンドだった。 1 匹は元気で、もう 1 匹はそうでもなかった。もっと甘いものを食べたことはあるが、産地は聞かなかったので分からない。

正解：関連する（１）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

検索質問と注釈にはずれも残る

- 卸売価格を尋ねる質問に対し、関連ラベルの文章は店頭で買った価格の体験談になっている。
- 文章には 2014 年の価格と場所が含まれる。元の質問は短く、時点や場所を明示していない。
- 利用者が書いた検索質問と、人が付けた関連ラベルの組を、そのまま評価材料にする。

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例３：法律名の定義と段階的な関連度

英語原文（質問・文章の全文）

Query: lps laws definition
Passage: LPS Act. LPS Act. a California law named for sponsors of the legislation (Lanterman, Petris, and Short) that provides for the protection and treatment of persons judged to be gravely disabled and thus unable to provide food, clothing, or shelter for themselves.

日本語訳（全文）

質問： LPS 法の定義。
文章： LPS 法。 LPS 法。法案の提案者 Lanterman 、 Petris 、 Short にちなむカリフォルニア州法。重度の障害があると判断され、そのために食料、衣服、住居を自力で確保できない人々の保護と治療を定める。

正解：関連度３（完全に関連）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

TREC では関連の強さを 4 段階で付ける

- TREC 2019 Deep Learning Track は、同じ文章コレクションに対して、評価担当者が多くの候補を判定した。
- 関連度 0 は非関連、 1 は質問に関連するが答えを含まない、 2 は高度に関連、 3 は完全に関連。
- HELM では、 Yes ／ No の学習例と二値の指標には 2 ・ 3 を正例として使い、 NDCG には元の段階的な値を使う。

[1] Craswell et al. (2020). Overview of the TREC 2019 Deep Learning Track. https://arxiv.org/abs/2003.07820
[2] Stanford CRFM. HELM: MS MARCO passage ranking. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

2. 順位の採点と HELM の成績

最初の関連文章が何位かを測る

- RR@10 は、最初の関連文章が r 位なら 1/r 、 10 位までにない場合は 0 。
- 例として、最初の関連文章が 1 位なら 1 、 2 位なら 0.5 、 10 位なら 0.1 になる。
- 質問ごとの値を平均する。 regular の代表指標は MRR@10 で、 HELM の集計名は RR@10 。

[1] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking
[2] Stanford CRFM. HELM: MS MARCO passage ranking. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

上位 10 件の関連度と順位をまとめて測る

- NDCG@10 は、上位 10 件の関連度を順位に応じて割り引いて足し、理想的な順位の値で正規化する。
- TREC では、非関連の 0 から完全に関連する 3 までの段階的な値を使う。強く関連する文章を上位に置くほど高得点になる。
- 最初の関連文章だけを見る RR と異なり、上位に複数の関連文章を並べたかも反映される。

[1] Stanford CRFM. HELM: MS MARCO passage ranking. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

HELM は検索候補に判定済みの文章を加える

- HELM は前処理済みの文章コレクションを使う。 qrels は質問・文章 ID と関連度を記録した判定ファイルである。
- 候補は、検索手法 BM25 の上位 30 件と、 qrels に含まれる全文章の和集合。通常の指標は、この候補全体の順位を採点する。
- 「 topk=30 」付きの指標は、候補を BM25 の上位 30 件に限定する。モデルには、 2 つの訓練質問から正例・負例を 1 件ずつ、通常 4 組の判定例を示す。

[1] Stanford CRFM. HELM: MS MARCO passage ranking. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

HELM regular ： RR@10 で比較

モデル	全候補	BM25 上位 30
Anthropic-LM (2022)	0.3820	0.2167
text-davinci-003 (2022)	0.3677	0.1992
OPT-175B (2022)	0.2878	0.1553

検証用 1,000 質問、各 3 試行の平均。 2023 年の HELM Classic 公開結果。

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

HELM TREC ： NDCG@10 で比較

モデル	全候補	BM25 上位 30
text-davinci-003 (2022)	0.6438	0.6020
Anthropic-LM (2022)	0.6417	0.6115
OPT-175B (2022)	0.4481	0.5178

TREC 2019 の 43 質問、各 3 試行の平均。関連度判定済み文章を含む候補集合を使用。

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

3. データの成立と構成

Bing の検索質問から人が回答を書く

- 匿名化した実際の Bing 検索ログから、質問として使える英語の検索語を集めた。
- 検索結果から得た文章を人が読み、回答を書く。人が回答を書く際に選んだ文章を、関連する文章として使った。
- その後、重複する文章を除いて約 884 万件のコレクションを作り、 BM25 で各質問の候補を取得した。

[1] Bajaj et al. (2016). MS MARCO: A Human Generated MAchine Reading COmprehension Dataset. https://arxiv.org/abs/1611.09268
[2] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking

文章検索用コレクションと質問の規模

配布物	件数	単位
文章コレクション	8,841,823	文章
全質問	1,010,916	質問
train の質問	808,731	質問
regular dev.small	6,980	質問
TREC 2019 判定対象	43	質問

[1] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking
[2] Craswell et al. (2020). Overview of the TREC 2019 Deep Learning Track. https://arxiv.org/abs/2003.07820

同じ名称の下に複数の課題がある

- 質問応答では、提示された文章から自然言語の答えを作る。 well-formed answer では、文として整った回答も扱う。
- passage ranking は短い文章を、 document ranking は Web 文書を検索する。文書版は本文の単位やコレクションが異なる。
- この資料の実例と HELM の結果は、 v1 の passage ranking に対応する。

[1] Microsoft. MS MARCO. https://microsoft.github.io/msmarco/
[2] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking

regular は疎な判定、 TREC は段階的な判定を使う

- regular は、質問応答の回答作成で使った文章から関連ラベルを得る。候補の全文章を網羅的に判定したわけではない。
- TREC は、参加システムの出力を集めたプールなどに対し、評価担当者が関連度 0 ～ 3 を付ける。
- HELM の regular は公開 dev.small 、 TREC は 2019 年の公開判定を使う。質問数、判定の密度、指標が異なるため、それぞれの条件でモデルを比べる。

[1] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking
[2] Craswell et al. (2020). Overview of the TREC 2019 Deep Learning Track. https://arxiv.org/abs/2003.07820

4. 検索研究での利用と入手

教師あり再ランキングの代表的な成績

手法	dev MRR@10
BM25	0.184
BM25 + BERT-large	0.372
BM25 + T5-base	0.363
BM25 + T5-large	0.383

2020 年報告。 BM25 の候補を、 MS MARCO で学習したモデルが再ランキング。

[1] Nogueira, Jiang & Lin (2020). Document Ranking with a Pretrained Sequence-to-Sequence Model. https://arxiv.org/abs/2003.06713

質問と文章をまとめて読むモデルの学習に使う

- BERT を使う cross-encoder は、質問と文章をまとめて読み、関連度を予測する。 T5 を使う方式は、関連／非関連を表す文字列を生成する。
- これらは MS MARCO でモデルの重みを学習する。 HELM は例をプロンプトに示す方式で、学習方法と候補集合が異なる。
- Sentence Transformers では、 MS MARCO の質問と正例・負例を使った cross-encoder の学習例を公開している。

[1] Nogueira, Jiang & Lin (2020). Document Ranking with a Pretrained Sequence-to-Sequence Model. https://arxiv.org/abs/2003.06713
[2] Sentence Transformers. MS MARCO cross-encoder training example (accessed 2026-10-18). https://github.com/huggingface/sentence-transformers/tree/master/examples/cross_encoder/training/ms_marco

必要なファイルを課題に合わせて選ぶ

- 文章本文には collection 、質問には queries 、関連度の正解には qrels 、既存候補の再ランキングには top1000 を使う。
- 公式配布表では、 collection.tar.gz は約 2.9 GB 、queries.tar.gz は約 42 MB 。圧縮配布物の掲載値である。
- 公式の評価用集合では正解ラベルを公開していない。公開 dev で検証し、公式評価には所定の形式で順位を提出する。

[1] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking

非商用の研究目的で配布される

- 公式の条件は、人工知能と関連分野の進展を目的とする非商用研究での利用を対象としている。
- 文章には Web 由来の内容が含まれ、配布は元文書の知的財産権の許諾を追加するものではない。

[1] Microsoft. MS MARCO. https://microsoft.github.io/msmarco/

実際の検索質問で、文章の探し方を評価する

- MS MARCO は、実際の検索質問と Web の文章を結び付け、質問応答から大規模な文章検索へ発展した。
- regular は多数の質問と疎な関連判定、 TREC 2019 は少数の質問と段階的な判定を提供する。
- 検索モデルの学習や再ランキングに使われ、 HELM では文章ごとの Yes ／ No 判定を文章の順位へ変換して評価する。

[1] Microsoft. MS MARCO Passage Ranking. https://github.com/microsoft/MSMARCO-Passage-Ranking
[2] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

Appendix

1. 追加の実例
2. ランキングの補足
3. 参考文献

追加の実例

実例４：燃料の利点を説明する文章

英語原文（質問・文章の全文）

Query: what are the benefits of fossil fuels
Passage: Benefits of fossil fuels. Fossil fuels are basically the remains of animals and plants and these are good energy resources. The three main fossil fuels are natural gas, oil, and coal. Fossil fuels are low in cost and are very important resources for our economy. Fossil fuels are used to generate electricity used as fuels for transportation. Because of their low costs, they are available to one and all.

日本語訳（全文）

質問：化石燃料にはどのような利点があるか。
文章：化石燃料の利点。化石燃料は基本的に動植物の遺骸であり、よいエネルギー資源である。主な３種類は天然ガス、石油、石炭。化石燃料は低コストで、経済にとって非常に重要な資源である。発電や輸送用の燃料として使われる。低コストなので、誰もが利用できる。

正解：関連する（１）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例５：相関と回帰の違い

英語原文（質問・文章の全文）

Query: can a correlational study use regression analysis
Passage: It is important to recognize that regression analysis is fundamentally different from. ascertaining the correlations among different variables. Correlation determines the. strength of the relationship between variables, while regression attempts to describe that. relationship between these variables in more detail.

日本語訳（全文）

質問：相関研究で回帰分析を使えるか。
文章：回帰分析は、複数の変数の相関を確かめることとは根本的に異なると理解する必要がある。相関は変数間の関係の強さを示す。一方、回帰はその変数間の関係を、より詳しく記述しようとする。

正解：関連する（１）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例６：利息の質問と費用の説明

英語原文（質問・文章の全文）

Query: is home improvement interest deductible
Passage: If you use your home purely as your personal residence, you cannot deduct the cost of home improvements. These costs are nondeductible personal expenses. However, this doesn't mean that home improvements do not have a tax benefit.

日本語訳（全文）

質問：住宅改修の利息は控除できるか。
文章：自宅を純粋に個人の住居として使う場合、住宅改修費用は控除できない。これらは控除できない個人的な支出である。ただし、住宅改修に税務上の利点がないという意味ではない。

正解：関連する（１）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 7 ：不満を表す harumph の意味

英語原文（質問・文章の全文）

Query: harumph define
Passage: Harumph is defined as an expression of dissatisfaction, disdain or unhappiness. When someone tells you do to something you don't want to do, this is an example of a situation where you might say harumph.

日本語訳（全文）

質問： harumph を定義せよ。
文章： harumph は、不満、軽蔑、または不機嫌な気持ちの表現と定義される。例えば、やりたくないことをするよう誰かに言われたときに、harumph と言うことがある。

正解：関連する（ 1 ）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例８：カバが息を止めていられる時間

英語原文（質問・文章の全文）

Query: how long can a hippo hold its breath underwater
Passage: Quick Answer. When submerged underwater, hippos can hold their breath for 5 minutes or even longer if needed. Hippos have nostrils located on the top of their heads, which allows them to breathe even if the rest of their body is under water. Continue Reading.

日本語訳（全文）

質問：カバは水中でどのくらい息を止めていられるか。
文章：簡潔な答え。カバは水に潜ると、５分間、必要ならそれ以上も息を止められる。鼻孔は頭の上にあるので、体のほかの部分が水中にあっても呼吸できる。続きを読む。

正解：関連する（１）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例９：天文学者の定義

英語原文（質問・文章の全文）

Query: define astronomers
Passage: The definition of an astronomer is a scientist who studies matter and objects in outer space. Someone who observes the stars and makes notes about their movements is an example of an astronomer. an expert in astronomy. noun.

日本語訳（全文）

質問：天文学者を定義せよ。
文章：天文学者とは、宇宙空間の物質や天体を研究する科学者である。星を観測し、その動きを記録する人は天文学者の一例である。天文学の専門家。名詞。

正解：関連する（１）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 10 ：ルーターの役割

英語原文（質問・文章の全文）

Query: what is a router meaning
Passage: Router (computing) A router is a networking device that forwards data packets between computer networks. Routers perform the traffic directing functions on the Internet. A data packet is typically forwarded from one router to another router through the networks that constitute the internetwork until it reaches its destination node.

日本語訳（全文）

質問：ルーターとは何か。
文章：ルーター（コンピューティング）。ルーターは、コンピューターネットワーク間でデータパケットを転送するネットワーク機器である。インターネット上で通信の流れを制御する。通常、データパケットは、相互接続されたネットワークを通り、あるルーターから次のルーターへ転送されて、宛先のノードに届く。

正解：関連する（1）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 11 ：水深を測る単位

英語原文（質問・文章の全文）

Query: when would you use a fathom measurement
Passage: A fathom is a unit of length in the imperial and the U.S. customary systems equal to 6 feet (1.8288 m), used especially for measuring the depth of water. There are two yards (6 feet) in an imperial fathom.

日本語訳（全文）

質問：どのようなときにファゾムを使うか。
文章：ファゾムは、ヤード・ポンド法と米国慣用単位系の長さの単位で、 6 フィート（ 1.8288 m ）に等しい。特に水深の測定に使われる。 1 ファゾムは 2 ヤード（ 6 フィート）である。

正解：関連する（ 1 ）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 12 ：地名の位置関係

英語原文（質問・文章の全文）

Query: where is south easton ma
Passage: South Easton is in Bristol, Massachusetts in the New England region of the USA. It is located about 23 miles south of MA's capital city of Boston.

日本語訳（全文）

質問：マサチューセッツ州サウスイーストンはどこか。
文章：サウスイーストンは、米国ニューイングランド地方のマサチューセッツ州ブリストルにある。州都ボストンから南へ約 23 マイルに位置する。

正解：関連する（1）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

実例 13 ：火成岩ができる過程

英語原文（質問・文章の全文）

Query: what processes are needed to form igneous rock
Passage: In essence, igneous rocks are formed through the cooling and solidification of magma (or lava). As hot, molten rock rises to the surface, it undergoes changes in temperature and pressure that cause it to cool, solidify, and crystallize.

日本語訳（全文）

質問：火成岩ができるにはどのような過程が必要か。
文章：基本的に火成岩は、マグマ（または溶岩）が冷却して固まることでできる。高温の溶融した岩石が地表へ上昇すると、温度と圧力の変化によって冷え、固まり、結晶化する。

正解：関連する（1）

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

ランキングの補足

Yes ／ No と出力の確からしさから順位を作る

- HELM では、 Yes と答えた文章を先に置く。その中では、出力の対数確率が高い文章ほど上位になる。
- No の文章はその後に置き、対数確率が低い順に並べる。No という出力への確信が弱い文章を先に置く並べ方である。
- Yes ／ No 以外の出力は、最後の群に置く。各文章を 1 組ずつ判定した結果から、質問ごとの順位を作る。

[1] Stanford CRFM. HELM: MS MARCO passage ranking. https://github.com/stanford-crfm/helm/tree/v0.3.0/src/helm/benchmark

最初の検索で 30 位より下の正例も、候補に加わる

- 実例 9 の「天文学者」は BM25 で 435 位、実例 10 の「ルーター」は 666 位、実例 11 の「ファゾム」は 34 位にある。
- HELM は qrels の文章を加えるので、これらも通常のランキング候補に含まれる。一方、 BM25 上位 30 件だけの指標では対象外になる。

[1] Stanford CRFM (2023). HELM Classic: MS MARCO. https://crfm.stanford.edu/helm/classic/v0.4.0/

参考文献

参考文献

MS MARCO: A Human Generated MAchine Reading COmprehension Dataset

Payal Bajaj et al. (2016). arXiv:1611.09268.

実際の検索質問、検索結果の文章、人が書いた回答からなる読解データセットを報告する。

https://arxiv.org/abs/1611.09268

Overview of the TREC 2019 Deep Learning Track

Nick Craswell, Bhaskar Mitra, Emine Yilmaz, Daniel Campos, Ellen M. Voorhees (2020). TREC 2019 Proceedings.

文章・文書検索の共通評価、関連度判定、参加システムの結果をまとめる。

https://arxiv.org/abs/2003.07820

参考文献

Document Ranking with a Pretrained Sequence-to-Sequence Model

Rodrigo Nogueira, Zhiying Jiang, Jimmy Lin (2020). Findings of EMNLP 2020.

T5 で関連性を表す文字列を生成し、 BM25 の候補を再ランキングする方法を示す。

https://arxiv.org/abs/2003.06713

Holistic Evaluation of Language Models

Percy Liang et al. (2023). Transactions on Machine Learning Research.

共通の適応法と複数の指標で言語モデルを評価する枠組み HELM を示す。

https://arxiv.org/abs/2211.09110

参考文献

MS MARCO Passage Ranking

Microsoft (n.d.). Official dataset documentation (accessed 2026-10-18).

v1 文章コレクション、質問、関連度判定、候補集合と公式の評価形式を説明する。

https://github.com/microsoft/MSMARCO-Passage-Ranking

MS MARCO Cross-Encoder Training

Sentence Transformers (n.d.). Documentation (accessed 2026-10-18).

MS MARCO の質問と正例・負例を用いた cross-encoder の学習手順を示す。

https://github.com/huggingface/sentence-transformers/tree/master/examples/cross_encoder/training/ms_marco