Multi-LexSum

Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities

民事の人権訴訟を、三つの詳しさで要約する

sasakiy84

公式サイト



[1] Multi-LexSum. 公式サイト。 https://multilexsum.github.io/

1. 実例から見る要約の粒度
2. 事件・文書・要約の作成方法
3. 採点と 2022 年の到達水準
4. 公開配布と利用条件

実例から見る要約の粒度

同じ事件を、長文・１段落・１文で捉える

- 米国の連邦裁判所で扱われた民事の人権訴訟を集めた、英語の要約データセット。訴状や判決など複数の文書と、専門家が書いた事件の要約を対応させる。
- Long は経過と結果を説明する複数段落、 Short は要点をまとめる 1 段落、 Tiny は事件を紹介する短い文。長さごとに、残す情報が変わる。
- 2022 年に公開。 4,539 事件に計 9,280 件の要約があり、すべての事件に三つの要約がそろうわけではない。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

文書群の要約と、要約文の圧縮を扱う

入力	出力	課題
文書群 D	L / S / T	複数文書の情報を統合
Long L	Short S / Tiny T	詳しい事件説明を圧縮
Short S	Tiny T	紹介に残す情報を選択

基本は D→L/S/T と L→S/T 、 S→T の 6 課題。 D は 1 事件に属する文書の集合。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

実例は、短要約から極短要約への 13 組

- 本編 3 件と追加 10 件は、 2022 年版の test にある異なる 13 事件から選んだ。 Short を入力、 Tiny を参照要約とし、どちらも全文を示す。
- Tiny は専門家が書いた短い紹介で、 SNS への投稿を意識した表現や、事件のある時点を切り取った文も含まれる。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 1 ：押収後の審理をめぐる訴訟

入力： Short 全文

In 2012, U.S. District Court of D.C. found that the policy of seizing and retaining private vehicles pending civil forfeiture proceedings without providing a post-deprivation hearing was unconstitutional.

参照要約： Tiny

D.C. resident challenges policy of private vehicle seizure without providing prompt post-deprivation hearing (D.D.C.)

入力： Short 全文（訳）

2012 年、コロンビア特別区の連邦地裁は、民事没収手続が終わるまで私有車を押収・留置しながら、押収後の審理を設けない方針を違憲と判断した。

参照要約： Tiny （訳）

D.C. 住民が、速やかな事後審理を設けずに私有車を押収する方針を争う（ D.C. 連邦地裁）。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

結果まで残すか、争点の紹介に絞るか

- 実例 1 の Short は、車の押収後に審理を設けない方針を裁判所が違憲としたことまで説明する。 Tiny は、住民がその方針を争う事件であることを紹介する。
- 短くするときには、争点の紹介と裁判の結果のうち、どの情報を残すかが変わる。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例２：年齢差別訴訟の和解

入力： Short 全文

> Plaintiffs sued Sprint, alleging ADEA violations pursuant to 29 U.S.C. § 621, the ADA, and 42 U.S.C. §12203. Class comprised just under 1,700 members. Eventually, parties reached $57 million settlement agreement.

参照要約： Tiny

Plaintiffs sue Sprint for age discrimination; 1,697-member class wins $57 million settlement (D. Kan.)

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例２：年齢差別訴訟の和解（訳）

入力： Short 全文（訳）

> 原告らは Sprint を訴え、米国法典第 29 編 621 条に基づく年齢差別禁止法、障害を持つアメリカ人法、および第 42 編 12203 条への違反を主張した。集団は 1,700 人弱。最終的に 5,700 万ドルの和解に達した。

参照要約： Tiny （訳）

原告らが年齢差別で Sprint を訴え、 1,697 人の集団が 5,700 万ドルの和解を得る（カンザス連邦地裁）。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例３：乗船券拒否をめぐる集団訴訟

入力： Short 全文

A class action lawsuit was filed in federal court against Carnival Corporation after two Cuban-born Americans were denied a ticket to Cuba. Plaintiffs voluntarily dismissed the case after Carnival changed its discriminatory policy.

参照要約： Tiny

A class action lawsuit was filed against a company after Cuban-born Americans were denied a ticket to Cuba.

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例３：乗船券拒否をめぐる集団訴訟（訳）

入力： Short 全文（訳）

キューバ生まれの米国人２人がキューバ行きの乗船券を拒否されたため、 Carnival 社を相手に連邦裁判所へ集団訴訟が提起された。同社が差別的な方針を変更した後、原告らは自発的に訴えを取り下げた。

参照要約： Tiny （訳）

キューバ生まれの米国人がキューバ行きの乗船券を拒否された後、その会社を相手に集団訴訟が提起された。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

参照文には、入力より細かな情報もある

- 実例 2 の Short は集団を「 1,700 人弱」と書くが、 Tiny は 1,697 人と特定する。 Tiny は、 Short とは別に事件の情報を要約した文である。
- 実例 3 の Short には方針変更と取下げまであるが、 Tiny は乗船券の拒否と訴訟提起に絞る。参照要約には、事件の異なる時点や詳しさが反映される。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

事件・文書・要約の作成方法

法律の専門家が、事件を読み、書き、更新する

- Civil Rights Litigation Clearinghouse は、訴訟の文書と情報を公開するプロジェクト。法律家と訓練を受けた法学生が、訴訟記録や主要文書を読んで事件の経過を整理する。
- 新しい事件の要約には通常 1 〜 4 時間を要する。複雑な事件では、経験ある弁護士でも 10 時間以上かかることがある。
- 事件が進むと要約も更新される。データは、この継続的な実務で書かれた要約から作られた。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

一つの事件に、異なる役割の文書がある

文書	主な役割
Docket	提出文書と出来事を時系列で記録
Complaint	当事者と訴えの根拠を示す訴状
Motion / Brief	申立てや主張を示す書面
Opinion / Order	裁判官の判断・命令
Settlement	当事者間の和解内容

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

主要文書の選択と、別の専門家の査読を挟む

- 担当者は多数の裁判文書から、主要な出来事を説明する文書を選ぶ。 Long を先に書き、文書や長い要約を参照して Short と Tiny を作る。
- 事実のチェックリストには、原告・被告、裁判所、提訴日、法的根拠、求める救済、和解や命令、その後の動きなどがある。
- 経験と追加訓練のある別の法律家・法学生が、事実の正しさと読みやすさを確認し、必要に応じて編集する。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

4,539 事件に、 9,280 件の要約がある

対象	v20220616 の件数
事件	4,539
原文書の ID	40,119
Long	4,539
Short	3,138
Tiny	1,603

2022 年版。 Long は全事件にあり、 Short と Tiny は一部の事件にある。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

事件ごとに、学習・検証・テストへ分ける

分割	事件	Short	Tiny
train	3,177	2,210	1,130
validation	454	312	161
test	908	616	312

事件の 70% / 10% / 20% 。 Long は各分割の全事件にある。 validation は配布の dev.json 。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

長い入力と、集められた事件の偏りがある

- 原文書群は 1 事件あたり平均約 75,500 語。 Long の平均は約 650 語、 Short は約 130 語、 Tiny は約 25 語である。
- 長い訴訟の中から、当事者・主張・決定・結果をつなげる必要がある。各文書の冒頭だけでは、その後の和解や命令を落としやすい。
- オンラインで訴訟記録を入手できる連邦事件が対象。原告が勝つ事件が集まりやすく、事件の構成には偏りがある。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

採点と 2022 年の到達水準

表現の重なりと、事件説明の有用性を測る

- ROUGE-1 は単語、 ROUGE-2 は連続する 2 語、 ROUGE-L は順序を保つ共通部分を比べる。公表結果は、生成文と参照文の F1 をテスト全件で平均した値。
- BERTScore は文脈を反映した語の表現を対応させ、意味的な重なりを測る。評価には DeBERTa を使い、こちらも F1 を報告した。
- 語句や意味の重なりだけでは、提訴日・裁判所・結末の誤りや、作業に役立つかまでは分からない。人による評価を併せて見る。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

原文書群からの生成は、粒度で難しさが変わる

モデル（発表年）	D→L	D→S	D→T
BART (2020)	23.78	19.98	8.19
LED-16,384 (2020)	25.17	22.08	9.84
PRIMERA (2022)	27.32	21.04	9.26

2022 年の ROUGE-2 F1 （×100）。各課題で利用できる参照要約を持つ test 事件を採点。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

要約を入力にすると、情報選択の負担が減る

モデル（発表年）	L→S	L→T	S→T
PEGASUS (2020)	35.62	14.44	16.15
BART (2020)	37.02	13.05	15.20

同じ 2022 年評価の ROUGE-2 F1 （×100）。人が書いた要約を入力とする。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

モデルの文脈長が、読める文書の範囲を決める

- BART と PEGASUS の入力上限は 1,024 トークン。 LED は 4,096 と 16,384 、 PRIMERA は 4,096 トークンを扱い、長い文書群の一部を入力にする。
- モデルは、それぞれの要約課題で追加学習した。複数文書からの生成と、人が書いた要約の圧縮では、入力に含まれる情報量が大きく異なる。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

自動得点が高くても、専門家の修正は多い

- 人手評価は、新しい 40 事件の D→Long が対象。 2 人の訓練済み執筆者が、関連箇所を選び、 BART が段落ごとに生成した文を編集した。作業は合計 180 時間。
- 0 ＝使用不能、 1 ＝半分超の修正が必要、 2 ＝半分未満の修正が必要、 3 ＝修正不要、という尺度で、平均は 0.43 だった。
- 生成文と編集後の文の ROUGE-2 は 30.0 だったが、 1 段落あたり平均 87 トークンの編集があり、元の段落長の 76% に相当した。誤った重要事項と情報の欠落が問題だった。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

公開配布と利用条件

2023 年版は、事件と原文書のメタデータを加えた

- 2022 年版が初期公開版。 2023 年版の v1.1 は、事件名・提訴日・事件 URL などの事件情報と、文書種別・題名・ OCR かどうか・文書 URL などを追加した。
- 公式サイトから Hugging Face へ進み、版を指定して取得できる。公式 GitHub はローダーと、粒度別に追加学習した BART ・ LED ・ PRIMERA などのモデルを案内している。
- ここで示す実例と集計は 2022 年版、現在の配布の説明は v1.1 までを対象とする。

[1] Multi-LexSum. 公式データカード・ v1.1 配布。 https://huggingface.co/datasets/allenai/multi_lexsum
[2] Multi-LexSum. 公式配布・ローダー。 https://github.com/multilexsum/dataset

要約・データベース・コードで利用条件が異なる

- データセットの配布は ODC-By 。事件要約とメタデータには CC BY-NC 4.0 が適用され、原文書はパブリックドメインと案内されている。
- 要約を商用利用する場合の別ライセンスは、 Clearinghouse へ連絡して確認する方式である。
- ダウンロードと読み込みのコードは Apache-2.0 。データベース・要約本文・コードのそれぞれに利用条件がある。

[1] Multi-LexSum. 公式データカード・ v1.1 配布。 https://huggingface.co/datasets/allenai/multi_lexsum

詳しさを変えたとき、何を残すかを評価する

- Multi-LexSum は、専門家の読解・執筆・査読を経た、民事の人権訴訟の要約を三つの粒度で提供する。複数文書の統合と、要約の圧縮を扱える。
- 要約の種類によって利用できる事件数は異なる。長い原文書や事件の偏りも、このデータの特徴である。
- 参照との重なりに加え、当事者・経過・結末の正しさと、人の作業に役立つかを評価する。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956

Appendix

1. 追加の実例
2. 評価・分割・配布の詳細
3. 研究と参考文献

追加の実例

実例 4 ：抗議参加者と警察活動

入力： Short 全文

> Six named plaintiffs filed a class-action lawsuit against the city of Pittsburgh and various elected officials and police officials alleging that actions taken against non-violent protestors constituted violations of their First and Fourth Amendment rights.

参照要約： Tiny

Added to the Clearinghouse: Lawsuit filed by @AbolitionistLC in 2020 alleging that the Pittsburgh police violated non-violent protestors First and Fourth Amendment rights.

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 4 ：抗議参加者と警察活動（訳）

入力： Short 全文（訳）

6 人の原告がピッツバーグ市、複数の公職者・警察幹部を相手に集団訴訟を提起した。非暴力の抗議参加者への行為が、憲法修正第 1 条・第 4 条の権利を侵害したと主張した。

参照要約： Tiny （訳）

Clearinghouse に追加： @AbolitionistLC が 2020 年に提起し、ピッツバーグ警察による非暴力の抗議参加者の修正第 1 条・第 4 条の権利侵害を訴えた事件。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 5 ：国境での民兵協力記録

入力： Short 全文

> On Oct. 24, 2017, the Protect Democracy Project sued DHS and CBP in D.D.C. under FOIA. Plaintiff sought disclosure of agency records on the extent to which defendants cooperate with armed private militia groups along the U.S.-Mexico border. This case is ongoing.

参照要約： Tiny

This is a case brought by the Protect Democracy Project, seeking disclosure of records on the extent to which defendants cooperate with armed private militia groups along the U.S.-Mexico border

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 5 ：国境での民兵協力記録（訳）

入力： Short 全文（訳）

2017 年 10 月 24 日、 Protect Democracy Project は、情報自由法に基づき国土安全保障省と税関・国境警備局を D.C. 連邦地裁へ訴えた。米墨国境で武装した民兵組織と両機関がどの程度協力しているかを示す記録の公開を求めた。事件は係属中。

参照要約： Tiny （訳）

Protect Democracy Project が、米墨国境の武装民兵組織と被告機関の協力の程度を示す記録の公開を求めた事件。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 6 ：抗議活動と過剰な実力行使

入力： Short 全文

> Individual plaintiffs sued the city of Columbus, Ohio and multiple police officers after protesting the murder of George Floyd. The plaintiffs alleged that the defendants violated their First and Fourth Amendment rights by using excessive force to infringe upon their freedom to assemble.

参照要約： Tiny

In E.D. Ohio case, plaintiffs secure preliminary injunction to prevent police from using excessive force against non-violent protestors. In granting the injunction, Judge Marbley recounted how "formal policing took its earliest form in slave patrols."

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 6 ：抗議活動と過剰な実力行使（訳）

入力： Short 全文（訳）

ジョージ・フロイドの殺害に抗議した原告らが、オハイオ州コロンバス市と複数の警察官を訴えた。集会の自由を侵害する過剰な実力行使が、修正第 1 条・第 4 条の権利に違反したと主張した。

参照要約： Tiny （訳）

E.D. Ohio の事件で、非暴力の抗議参加者への過剰な実力行使を禁じる仮差止めを原告らが得た。 Marbley 判事は命令に際し「制度としての警察活動は、奴隷巡察隊という形で最初に現れた」と述べた。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 7 ：差別申立て後の報復的解雇

入力： Short 全文

In December 2013, the EEOC brought this suit against Bright Petroleum for scrutinizing, disciplining and discharging against its female employee who filed a charge of sex discrimination with the EEOC. The EEOC and Bright Petroleum entered a three-year consent decree on December 12, 2014.

参照要約： Tiny

EEOC brought claim of retaliatory discharge against Bright Petroleum in December 2013. Parties reached a consent decree in 2014 (S.D. Ind.)

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 7 ：差別申立て後の報復的解雇（訳）

入力： Short 全文（訳）

2013 年 12 月、雇用機会均等委員会は、性差別を同委員会へ申し立てた女性従業員を監視・懲戒・解雇したとして Bright Petroleum を訴えた。 2014 年 12 月 12 日に、両者の間で 3 年間有効な同意判決が成立した。

参照要約： Tiny （訳）

雇用機会均等委員会が 2013 年 12 月に Bright Petroleum を報復的解雇で訴え、 2014 年に同意判決が成立した（インディアナ南部地区）。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 8 ：大統領令の実施記録

入力： Short 全文

> On Mar. 3, 2017, plaintiffs The James Madison Project and the news website The Daily Beast's executive editor sued various federal agencies under FOIA, seeking disclosure of agency records related to the implementation of President Trump's Jan. 27, 2017 Executive Order. Production is ongoing as of June 6.

参照要約： Tiny

In this case, the James Madison Project and the news website The Daily Beast sought disclosure of agency records related to the implementation of President Trump's Jan. 27, 2017 Executive Order

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 8 ：大統領令の実施記録（訳）

入力： Short 全文（訳）

2017 年 3 月 3 日、 James Madison Project とニュースサイト Daily Beast の編集責任者が、情報自由法に基づき複数の連邦機関を訴えた。トランプ大統領の同年 1 月 27 日の大統領令の実施に関する記録の公開を求めた。 6 月 6 日時点で資料の提出は継続中。

参照要約： Tiny （訳）

James Madison Project と Daily Beast が、トランプ大統領の 2017 年 1 月 27 日の大統領令の実施に関する記録の公開を求めた事件。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 9 ：空港での入国禁止の実施

入力： Short 全文

On Apr. 12, 2017, the ACLUs of Virginia, Maryland, Pennsylvania, and Delaware sued DHS under FOIA, for information on the implementation of the travel ban Executive Orders at regional airports. Defendants were unable to consolidate all nationwide ACLU cases in multidistrict litigation, and this case is proceeding here.

参照要約： Tiny

Final updates on @ACLUVA, @ACLU_MD, @aclupa, and @ACLUDeleware lawsuit against @DHSgov demanding document production re the Muslim Ban. Plaintiffs brought the suit under FOIA in 2017.

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 9 ：空港での入国禁止の実施（訳）

入力： Short 全文（訳）

2017 年 4 月 12 日、バージニア・メリーランド・ペンシルベニア・デラウェアの ACLU が情報自由法に基づき国土安全保障省を訴えた。地域の空港での入国禁止大統領令の実施に関する情報を求めた。全米の ACLU 事件を広域係属訴訟へ統合する被告の試みは成功せず、この事件は当地で進行中。

参照要約： Tiny （訳）

@ACLUVA 、 @ACLU_MD 、 @aclupa 、 @ACLUDeleware がイスラム教徒の入国禁止に関する資料の提出を @DHSgov へ求めた訴訟の最終更新。原告らは 2017 年に情報自由法に基づき提訴した。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 10 ：保釈金と資力に基づく勾留

入力： Short 全文

> Civil Rights Corps sued Tulsa County and various judicial officers, alleging that the court system operated a wealth-based detention system by detaining arrestees without inquiring into their ability to pay bail. While the plaintiffs motion for preliminary injunction was denied, the plaintiffs motion for class certification is still pending.

参照要約： Tiny

Just added to the Clearinghouse: One of @CivRightsCorps cases focusing on criminalization of poverty. This case involves an alleged wealth-based detention scheme in Tulsa County, Oklahoma.

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 10 ：保釈金と資力に基づく勾留（訳）

入力： Short 全文（訳）

Civil Rights Corps は、保釈金を支払えるか確認せずに被逮捕者を拘束する、資力に基づく勾留制度があるとして、タルサ郡と複数の司法関係者を訴えた。仮差止めの申立ては却下されたが、集団訴訟としての認定の申立ては係属中。

参照要約： Tiny （訳）

Clearinghouse に追加：貧困の犯罪化を扱う @CivRightsCorps の事件の一つ。オクラホマ州タルサ郡の資力に基づく勾留制度が争われている。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 11 ：大学による逆情報公開訴訟

入力： Short 全文

Princeton sued U.S. Department of Education and OCR in a "reverse FOIA" to stop them from releasing documents related to an OCR compliance review to Students for Fair Admissions, Inc., which had submitted a FOIA request and filed a lawsuit against the DOE to compel disclosure. Parties voluntarily dismissed case.

参照要約： Tiny

Princeton sues DOE in reverse FOIA action to stop disclosure. (D.D.C.)

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 11 ：大学による逆情報公開訴訟（訳）

入力： Short 全文（訳）

Princeton は、教育省の公民権局による審査資料を Students for Fair Admissions へ公開させないため、教育省と同局を「逆情報自由法」訴訟で訴えた。同団体は情報公開を請求し、公開を求めて教育省を訴えていた。当事者は自発的に訴えを取り下げた。

参照要約： Tiny （訳）

Princeton が、資料公開を止めるため逆情報自由法訴訟で教育省を訴える（ D.C. 連邦地裁）。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 12 ：移民被収容者の釈放請求

入力： Short 全文

This is a habeas action seeking the release of immigration detainees housed in ICE facilities in Maryland. The court initially denied the detainees' TRO, but eventually granted two preliminary injunctions that ordered the release of several detainees from their respective detention centers. The court also granted the petitioners' motion for class certification.

参照要約： Tiny

Documents now posted for Maryland litigation brought on behalf of ICE detainees seeking release from detention due to COVID-19

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 12 ：移民被収容者の釈放請求（訳）

入力： Short 全文（訳）

メリーランド州の移民・税関捜査局施設の被収容者が、釈放を求めた人身保護手続である。裁判所は当初、一時的差止命令の申立てを却下したが、後に 2 件の仮差止命令で複数人の釈放を命じた。集団訴訟としての認定の申立ても認めた。

参照要約： Tiny （訳）

COVID-19 を理由に拘束からの解放を求める移民・税関捜査局の被収容者のために提起された、メリーランド州の訴訟資料を掲載。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 13 ：サンノゼ市の警察活動

入力： Short 全文

> The NAACP and individual people sued the city of San Jose and political officials for policing tactics that allegedly deprived them of their First, Fourth, and Fourteenth Amendment rights. The plaintiffs, protesting systemic racism in policing, alleged that the police used excessive force in a racially motivated manner to end the protests.

参照要約： Tiny

Just added to the Clearinghouse - @NAACP sued the city of San Jose for allegedly unconstitutional police practices being used against peaceful protestors.

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

実例 13 ：サンノゼ市の警察活動（訳）

入力： Short 全文（訳）

NAACP と個人の原告らは、修正第 1 条・第 4 条・第 14 条の権利を侵害する警察活動があったとして、サンノゼ市と公職者を訴えた。警察の構造的人種差別に抗議していた原告らは、抗議を終わらせるために人種差別的な動機で過剰な実力が用いられたと主張した。

参照要約： Tiny （訳）

Clearinghouse に追加：平和的な抗議参加者に対する違憲とされる警察活動をめぐり、 @NAACP がサンノゼ市を訴えた。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

評価・分割・配布の詳細

欠ける粒度により、評価できる集合が変わる

課題の参照	train	validation	test
Long	3,177	454	908
Short	2,210	312	616
Tiny	1,130	161	312

参照欄の非空数。 S→T は両欄がある組を使い、 train 1,129 / validation 161 / test 312 。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

分割は、公式ローダーが読むファイルに従う

- 公式ローダーは train.json 、 dev.json 、 test.json を、それぞれ学習用・検証用・テスト用として読む。
- 2022 年版のレコードには古い subset 欄も残り、この三つのファイルとは一致しない。モデルの学習や評価では、配布ファイルによる分割を使う。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

Tiny には、短い入力にない情報も含まれる

- Tiny には「 Clearinghouse に追加」「資料を掲載」など、事件を SNS で紹介する表現がある。
- 実例 6 の Tiny は仮差止めの成立や判事の発言まで含むが、 Short にはない。 Tiny の作成には、 Short 以外の事件情報も使われる。
- 参照文の情報が短い入力の外にあることも、 Short→Tiny を評価するときの制約になる。

[1] Shen et al. Multi-LexSum (2022). https://huggingface.co/datasets/allenai/multi_lexsum

要約の組を JSONL から読み出す

```
import json
with open("test.jsonl", encoding="utf-8") as f:
    cases = (json.loads(line) for line in f)
    case = next(c for c in cases
                if c.get("summary/short")
                and c.get("summary/tiny"))
print(case["summary/short"])
print(case["summary/tiny"])
```

2022 年版の test.json を test.jsonl として保存し、 Short と Tiny の両方がある事件の要約全文を表示する。

[1] Multi-LexSum. 公式データカード・ v1.1 配布。 https://huggingface.co/datasets/allenai/multi_lexsum

研究と参考文献

法律実務の執筆と、要約モデルの研究を結ぶ

- Zejiang Shen 、 Kyle Lo らが Allen Institute for AI と、ミシガン大学の Civil Rights Litigation Clearinghouse などの協力で構築した。法学者 Margo Schlanger と Doug Downey も参加した。
- 数百人の法学生らが事件要約の執筆に関わる。論文は NeurIPS 2022 の Datasets and Benchmarks Track に採択された。

[1] Shen et al. (2022). Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities. NeurIPS. https://doi.org/10.52202/068431-0956
[2] Multi-LexSum. 公式サイト。 https://multilexsum.github.io/

参考文献

Multi-LexSum: Real-world Summaries of Civil Rights Lawsuits at Multiple Granularities

Shen et al. ・ 2022 ・ NeurIPS 35

三粒度の専門家要約を構築し、複数文書・要約圧縮の実験と人手評価を報告する。

https://doi.org/10.52202/068431-0956

Multi-LexSum Dataset Sheet

Multi-LexSum team ・ 2022 ・公式データシート

構成、収集過程、利用目的、偏りと配布条件を記述する。

https://multilexsum.github.io/datasheet

参考文献

Multi-LexSum dataset and loader

Multi-LexSum team · n.d.· 公式 GitHub （2026-10-18 参照）

配布の読み込み方法と、粒度別の追加学習済みモデルを案内する。

https://github.com/multilexsum/dataset

allenai/multi_lexsum

Multi-LexSum team · n.d. · v1.0 / v1.1 ・ Hugging Face （2026-10-18 参照）

要約と文書を配布し、版ごとのメタデータと利用条件を示す。

https://huggingface.co/datasets/allenai/multi_lexsum