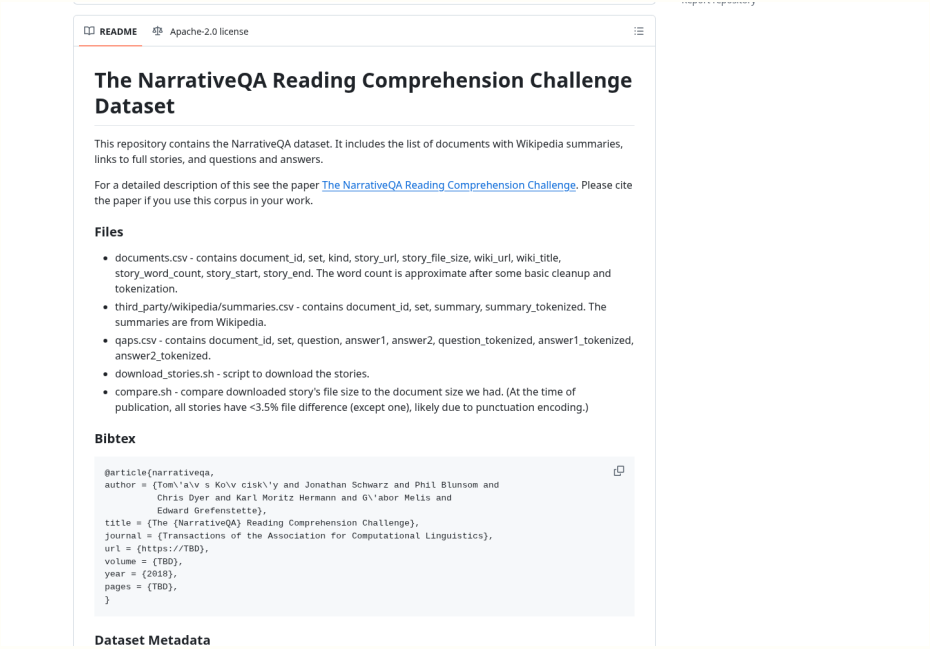
NarrativeQA

The NarrativeQA Reading Comprehension Challenge

物語を読んで、自由な言葉で答える

sasakiy84

公式配布ページ



README Apache-2.0 license

The NarrativeQA Reading Comprehension Challenge Dataset

This repository contains the NarrativeQA dataset. It includes the list of documents with Wikipedia summaries, links to full stories, and questions and answers.

For a detailed description of this see the paper The NarrativeQA Reading Comprehension Challenge. Please cite the paper if you use this corpus in your work.

Files

- documents.csv - contains document_id, set, kind, story_url, story_file_size, wiki_url, wiki_title, story_word_count, story_start, story_end. The word count is approximate after some basic cleanup and tokenization.
- third_party/wikipedia/summaries.csv - contains document_id, set, summary, summary_tokenized. The summaries are from Wikipedia.
- qaps.csv - contains document_id, set, question, answer1, answer2, question_tokenized, answer1_tokenized, answer2_tokenized.
- download_stories.sh - script to download the stories.
- compare.sh - compare downloaded story's file size to the document size we had. (At the time of publication, all stories have <3.5% file difference (except one), likely due to punctuation encoding.)

Bibtex

```
@article{narrativeqa,
author = {Tom\'a\v s Ko\v cisk\'y and Jonathan Schwarz and Phil Blunsom and
          Chris Dyer and Karl Moritz Hermann and G\'abor Melis and
          Edward Grefenstette},
title = {The {NarrativeQA} Reading Comprehension Challenge},
journal = {Transactions of the Association for Computational Linguistics},
url = {https://TBD},
volume = {TBD},
year = {2018},
pages = {TBD},
}
```

Dataset Metadata

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 https://github.com/google-deepmind/narrativeqa

1. 物語の理解を問う実例
2. 作成方法とデータの全体像
3. 採点とモデルの到達水準
4. 利用の変化と入手方法

物語の理解を問う実例

本や映画の物語について答える

- 入力は物語と質問。登場人物の行動や出来事の理由を読み取り、短い回答を生成する。
- 物語全文を読む条件と、 Wikipedia の要約を読む条件がある。 HELM は要約を使う。
- 各質問に、人が書いた 2 つの参照回答が付いている。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

実例で示す入力の範囲

- 以下の 13 例は、公開テスト集合の異なる 13 作品から選んだ。
- 画面には、質問の根拠を含む要約の連続した抜粋と、質問・参照回答の全文を示す。
- HELM がモデルに渡すのは、抜粋前の要約全文と質問。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 https://github.com/google-deepmind/narrativeqa

実例１：旅の後で一人になる

原文（要約抜粋・質問）

Maskull, a man longing for adventures, accepts an invitation from Krag, an acquaintance of his friend Nightspore, to travel to Tormance after a seance. The three set off in a crystal ship from an abandoned observatory in Scotland but Maskull awakens to find himself alone on Tormance.
Question: When Maskull wakes up in Tormance, how many of his friends are with him?

1. None

2. None.

日本語訳

冒険に憧れるマスカルは、交霊会の後、友人ナイトスポアの知人クラグからトーマンスへの旅に誘われ、それを受け入れる。３人はスコットランドの廃天文台から水晶の船で出発するが、目を覚ましたマスカルはトーマンスに一人でいることに気づく。
質問：マスカルがトーマンスで目を覚ましたとき、友人は何人一緒にいるか。

参照回答：誰もいない。／誰もいない。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 014de1a8802c05ff64efa047e9290fb7fccea2b4 / QA 3 （0 始まり）
https://github.com/google-deepmind/narrativeqa

出発時の人数と到着後の状態

- 旅に出たのは３人だが、質問は「目を覚ましたとき」に一緒にいる友人の人数を尋ねている。
- 根拠は最後の alone 。「一人でいる」から「友人は誰もいない」と言い換えて答える。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

実例２：意図と結果を区別する

原文：公開要約の連続抜粋・質問 ／ 赤字 1 ・ 2 は参照回答

However, it soon becomes clear that the teenagers who play the game and lose are being imprisoned inside the virtual reality world by the central villain: "Arcade". It would seem that "Arcade" was once a little boy who was beaten to death by his mother, and the computer company felt it would be a good idea to use some of the boy's brain cells in order to make the game's villain more realistic. Instead, it made the game deadly.
Question: Why did Vertigo/Tronics include the boy's brain cells into the game?

1. To make the villain character of the game more realistic.

2. To make the Villian more realistic.

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 9d9741c1e26478633f439ec30de0329a5f4c02a7 / QA 6 （0 始まり）
https://github.com/google-deepmind/narrativeqa

実例２：意図と結果を区別する（訳）

要約抜粋・質問・参照回答の日本語訳

しかし、ゲームに負けた若者たちが、中心となる悪役「アーケード」によって仮想現実の世界に閉じ込められていることが、やがて明らかになる。アーケードは、かつて母親に殴り殺された少年だったらしい。コンピューター会社は、ゲームの悪役をより現実的にするため、その少年の脳細胞の一部を使うとよいと考えた。ところが、それによってゲームは命に関わるものになってしまった。
質問：ヴァーティゴ／トロニクス社は、なぜ少年の脳細胞をゲームに組み込んだのか。

参照回答：ゲームの悪役をより現実的にするため。／悪役をより現実的にするため。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 9d9741c1e26478633f439ec30de0329a5f4c02a7 / QA 6
https://github.com/google-deepmind/narrativeqa

会社の目的と起きた結果を分ける

- 脳細胞を使った目的は、悪役をより現実的にすること。
- ゲームが命に関わるものになったのは、その結果。質問の why が何を尋ねているかを追う。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

実例３：二つの参照回答が食い違う

原文：公開要約の連続抜粋・質問 ／ 赤字 1 ・ 2 は参照回答

Kitty's social activities start to affect Ashe's political career; she strains Ashe's relationship with Lord Parham, the prime minister, and also flirts with the dashing but unprincipled Geoffrey Cliffe. After their child dies, Kitty is left a physical wreck and goes with Ashe to Italy to try to recover her health. Kitty meets Cliffe in Italy and runs off with him, while Ashe is in England trying to suppress a salacious book Kitty has written.
Question: WHERE DID KITTY BEGIN HER AFFAIR WITH GEOFFERY CLIFFE?

1. IN ITALY

2. London

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 3dddbcc83358a72adfd1c957ae3cbfc1d194a143 / QA 7 （0 始まり）
https://github.com/google-deepmind/narrativeqa

実例３：二つの参照回答が食い違う（訳）

要約抜粋・質問・参照回答の日本語訳

キティの社交活動はアッシュの政治家としての仕事に影響し始める。彼女は首相パラム卿とアッシュの関係を悪化させ、魅力的だが節操のないジェフリー・クリフとも浮ついた関係になる。子どもを亡くしたキティはすっかり体を壊し、健康を取り戻そうとアッシュとイタリアへ行く。キティはそこでクリフと会い、彼と駆け落ちする。その間、アッシュはイギリスで、キティが書いた扇情的な本の出版を差し止めようとしていた。
質問：キティはどこでジェフリー・クリフと不倫関係を始めたか。

参照回答：イタリア。／ロンドン。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 3dddbcc83358a72adfd1c957ae3cbfc1d194a143 / QA 7
https://github.com/google-deepmind/narrativeqa

二つの回答が一致するとは限らない

- 参照回答は「イタリア」と「ロンドン」で食い違っている。
- 要約には、先にクリフと浮ついた関係になり、後でイタリアで駆け落ちしたとある。
- 「関係を始めた」時点の解釈が曖昧。２つの回答を集めることと、合意を取ることは違う。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 https://github.com/google-deepmind/narrativeqa

作成方法とデータの全体像

そのまま抜き出すだけでは答えにくい

- 短い文章から答えの位置を選ぶ課題に対し、長い物語を理解して答える課題として作られた。
- 質問は要約を見て作り、回答は自分の言葉で書くよう求めた。
- 回答が連続した文字列として現れる割合は、要約で 44.05% 、物語全文で 29.57% 。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

作品と、その作品の要約をそろえる

- 書籍は Project Gutenberg 、映画は脚本サイトなどから物語を集めた。
- Wikipedia の要約を対応付け、人が同じ作品かどうかを確認した。
- 映画化作品・異なる公開年の作品・シリーズの別の作品を取り違えないように照合した。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

要約を読んで質問と最初の回答を書く

- 作業者に見せたのは要約。物語全文を読む人に尋ねるつもりで、１回の作業につき 10 問を作る。
- 回答は自分の言葉で書き、要約からのコピーを画面上で抑止した。
- はい・いいえで答える質問や、作者・俳優に関する質問は避けるよう指示した。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

別の人が答えられるかを確かめる

- 別の作業者が、要約を読んで質問に答えられるかを判定し、独立した回答を追加した。
- 答えられないと判断された質問は 2.3% 。
- 同じ作品の質問を、学習・開発・テストの間にまたがらせず、作品ごとに分割した。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

1,572 作品、 46,765 問

分割	作品数	質問数
学習	1,102	32,747
開発	115	3,461
テスト	355	10,557
合計	1,572	46,765

公開 CSV の全件集計。 1 作品に複数の質問が付く。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 https://github.com/google-deepmind/narrativeqa

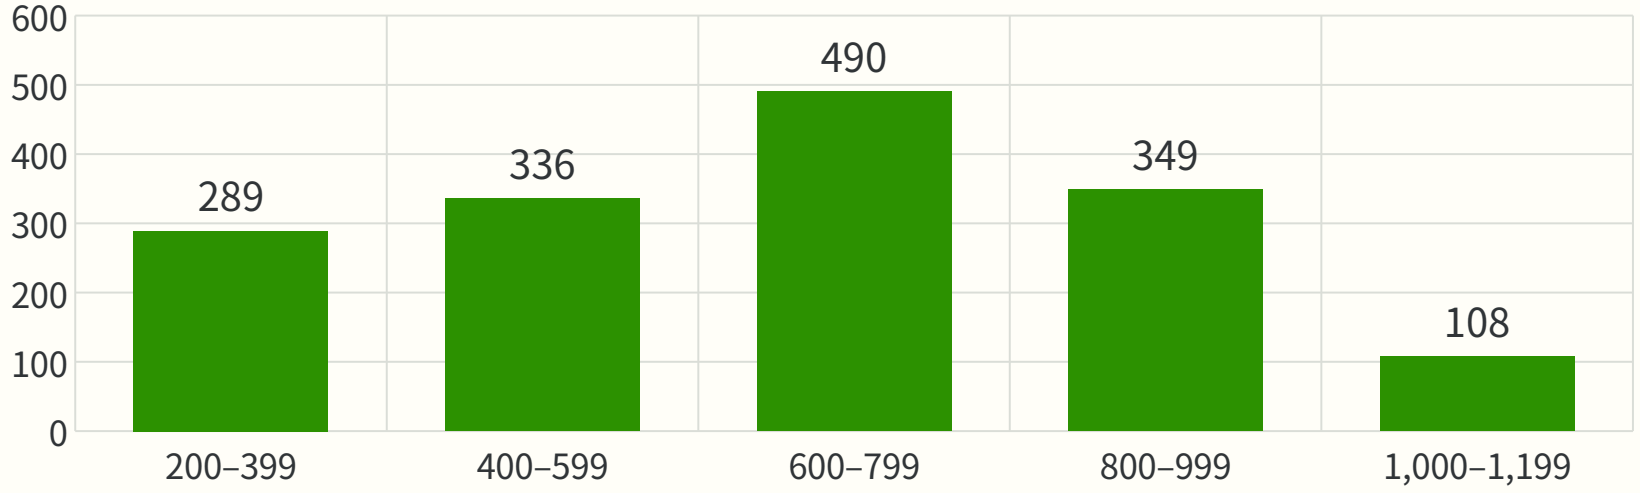
書籍と映画がほぼ半数ずつ

素材	作品数	割合
書籍	783	49.8%
映画	789	50.2%

全 1,572 作品。書籍は Gutenberg 、映画は脚本を元にしている。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 https://github.com/google-deepmind/narrativeqa

要約は数百語の文章



横軸：要約の単語数。縦軸：作品数。全 1,572 作品を各 1 回集計。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 https://github.com/google-deepmind/narrativeqa

物語全文は要約より大幅に長い

テスト集合の入力	平均単語数
要約	654
物語全文	57,780

2018 年の公表値。物語全文の平均は要約の約 88 倍。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

採点とモデルの到達水準

ROUGE-L ：語の並びの重なりを測る

- 生成した回答と参照回答の、順序を保った語の共通部分を使って採点する。
- 異なる言い回しでも意味が近ければ必ず高得点になる、という指標ではない。
- 2018 年の評価では、 BLEU ・ METEOR ・ ROUGE-L などを併用した。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

2018 年：要約から答える条件

方式	ROUGE-L
文脈なしの生成モデル	13.15
語を選ぶ Attention Sum Reader	22.26
回答範囲を選ぶ Span Prediction	36.30
人の参照回答同士	57.02

テスト集合。人の値は、一方の参照回答をもう一方で採点。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

同じ範囲選択方式でも、全文は難しい

入力	ROUGE-L
要約	36.30
物語全文	6.22

2018 年の Span Prediction 、テスト集合。全文条件は検索した文章片を利用。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

HELM では作品ごとに 1 問を使う

- 各作品に付いた質問から、固定乱数で 1 問を選ぶ。テストは 355 作品・ 355 問。
- 入力は要約全文と質問。 2 つの参照回答を使い、自由生成した回答を採点する。
- 2023 年の固定版を確認した。以下は最新モデルの順位ではなく、同版の記録。

[1] HELM Classic v0.4.0, NarrativeQA. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/narrative_qa

F1 ：回答中の語の重なりを測る

- 適合率は生成した語のうち参照回答と重なる割合、再現率は参照回答の語を拾えた割合。
- 小文字化し、句読点・冠詞・余分な空白を除いて計算する。両者の調和平均を F1 とする。
- 2 つの参照回答のうち高い得点を使い、全問の平均を百分率で示す。完全一致（ EM ）も併記する。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

HELM の同じテスト集合で比較する

モデル	F1	完全一致
OPT-175B	67.10	27.61
text-davinci-003	72.71	30.14
Llama 2 70B	76.99	33.24

v0.4.0 、要約入力 355 問。 OPT ・ davinci は 3 試行平均、 Llama 2 は 1 試行。単位は % 。

[1] HELM Classic v0.4.0, NarrativeQA. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/narrative_qa

最大 5 例でも、実際の提示例数は変わる

モデル	平均提示例数
OPT-175B	1.65
text-davinci-003	4.53
Llama 2 70B	4.41

入力上限に合わせて例を減らす。 test 統計。 OPT ・ davinci は 3 試行、 Llama 2 は 1 試行。

[1] HELM Classic v0.4.0, NarrativeQA. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/narrative_qa

得点から読み取れること

- 同じ質問でも、 F1 と完全一致では値が大きく異なる。短い回答の表現の違いも効く。
- 要約を読む成績から、数万語の物語全文を理解できるとは判断できない。
- 作品をまたいだ分割でも、事前学習でその物語を見たかどうかまでは保証しない。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

利用の変化と入手方法

長文読解から、言語モデルの共通評価へ

- 2018 年には、物語全文を読んで答えることが中心の挑戦だった。要約条件も併せて評価した。
- HELM では要約入力の質問応答として、多様な言語モデルを共通の枠組みで比較する。
- 2026-10-18 時点の HELM 公開コードにも、要約と 2 つの回答を読む実装が残っている。

[1] Stanford CRFM, HELM NarrativeQA scenario. 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/narrativeqa_scenario.py

3 つの CSV を作品 ID で結び付ける

- documents.csv ：作品の種類、分割、原文・ Wikipedia の URL 。
- summaries.csv ： Wikipedia 要約と、その分かち書き済みの列。
- qaps.csv ：質問、 2 つの回答、分かち書き済みの列。 document_id で対応させる。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （ 2026-10-18 取得）。 https://github.com/google-deepmind/narrativeqa

配布ファイルと権利の範囲

- 取得した 3 つの CSV は合計約 22.6 MB 。物語本文のファイルは含まれない。
- リポジトリの LICENSE は Apache 2.0 。 Wikipedia 要約は CC BY-SA 3.0 で、各記事への出典表記がある。
- 物語全文は各 URL から取得する仕組み。利用時は、要約と元の作品それぞれの条件を確かめる。

[1] NarrativeQA, Wikipedia summaries: LICENSE / ATTRIBUTION. https://github.com/google-deepmind/narrativeqa/tree/master/third_party/wikipedia

物語の理解と回答表現を一緒に見る

- 書籍・映画の 1,572 作品に、 46,765 問と 2 つずつの参照回答がある。
- 質問の意図、人物や出来事のつながりを読み取り、短く言い換えて答える。
- 入力が要約か物語全文かをそろえ、語の重なりの得点と回答の意味を併せて読む。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

Appendix

1. 追加の実例
2. 統計と評価条件
3. 研究と参考文献

追加の実例

実例４：ジェイコブの仕事

原文（要約抜粋・質問）

Her brother, Jacob, also goes to Nordrum farm to become a herdsman there.
Question: Jacob goes to Nordrum farm to become what?

1. a herdsman
2. a herdsman

日本語訳

彼女のきょうだいのジェイコブも、家畜の世話をする仕事に就くため、ノルドルム農場へ行く。
質問：ジェイコブは何になるためにノルドルム農場へ行くか。

参照回答：家畜の世話をする人。／家畜の世話をする人。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 019a9611dd8e1b822bd0a58f075cc4a30bdd0797 / QA 9 （0 始まり）
https://github.com/google-deepmind/narrativeqa

実例５：姉妹が再会する場所

原文（要約抜粋・質問）

The final part, "What Life Is", details how the two sisters are eventually reunited. Sophia returns to England and the house of her childhood, where Constance still lives.
Question: Where do Sophia and Constance reunite?

1. In their old childhood home in England.
2. England.

日本語訳

最後の部「人生とは」では、姉妹がついに再会するまでが描かれる。ソフィアはイギリスに帰り、コンスタンスが今も住む子ども時代の家に戻る。
質問：ソフィアとコンスタンスはどこで再会するか。

参照回答：イギリスにある子ども時代の家。／イギリス。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 03690ff2154ebecb454ea267cec529358ab6923b / QA 7 （0 始まり）
https://github.com/google-deepmind/narrativeqa

実例 6 ：社会階層の違い

原文：公開要約の連続抜粋・質問 ／ 赤字 1 ・ 2 は参照回答

The killer's identity is not as significant a revelation in the story as are the roles of the influential and secretive Frettlby family, and their secret: they have an illegitimate daughter living on the streets. The class divide between Melbourne's wealthy and less fortunate is addressed throughout the plot. Question: What significant differences of people in Melbourne is highlighted through the story?

1. The class divide between the wealthy and the poor.

2. Wealth versus poverty

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 6b92f0057a67fe3d24cce544969e5e17fec0b45c / QA 8 （0 始まり）
https://github.com/google-deepmind/narrativeqa

実例 6 ：社会階層の違い（訳）

要約抜粋・質問・参照回答の日本語訳

物語では、犯人の正体よりも、影響力を持ち秘密の多いフレットルビー家の役割と、その一家に婚外子の娘がいて路上生活をしているという秘密の方が、重大な事実として明かされる。メルボルンの富裕層と恵まれない人々との階級の隔たりが、物語を通して扱われる。
質問：物語では、メルボルンの人々のどのような大きな違いが浮き彫りになるか。

参照回答：裕福な人々と貧しい人々との階級の隔たり。／富と貧困。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 6b92f0057a67fe3d24cce544969e5e17fec0b45c / QA 8
https://github.com/google-deepmind/narrativeqa

実例７：病気から回復する

原文（要約抜粋・質問）

Tancred falls ill, and is released at the instigation of Eva, who nurses him back to health.
Question: What did Eva do with Tancred when he was released?

1. She nursed him back to health.
2. After Tancred was released, Eva nurses him back to health.

日本語訳

タンクレッドは病気になり、エヴァの働きかけで釈放される。エヴァは彼を看病し、健康を回復させる。
質問：タンクレッドが釈放されたとき、エヴァは彼に何をしたか。

参照回答：看病して健康を回復させた。／釈放されたタンクレッドを看病し、健康を回復させた。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 4ff62e050b4eba11e273a060f0e5b0080746ea79 / QA 7 （0 始まり）
https://github.com/google-deepmind/narrativeqa

実例 8 ：隠していた身分

原文：公開要約の連続抜粋・質問 ／ 赤字 1 ・ 2 は参照回答

Several years after her marriage, Émilie discovers that Maximilien is not a clothier at all, but in fact a Vicomte de Longueville who has become a Peer of France. The young man finally explains why he secretly tended a store: he did it in order to support his family, sacrificing himself for his sick sister and for his brother, who had departed the country.
Question: What does Emilie find out several years after being married?

1. Maximilie is a Peer of France not a cloth merchant.

2. Maximilien is not a clothier; he is a Vicomte de Longueville and a Peer of France.

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 2584ef223f762658333799d37f593530f02ada28 / QA 5 （0 始まり）
https://github.com/google-deepmind/narrativeqa

実例８：隠していた身分（訳）

要約抜粋・質問・参照回答の日本語訳

結婚から数年後、エミリーは、マクシミリアンが布商人ではなく、貴族院議員となったロングヴィル子爵だと知る。彼は、ひそかに店を切り盛りしていた理由をようやく説明する。病気のきょうだいや、国外へ去ったきょうだいのために身を犠牲にし、家族を支えていたのだった。
質問：エミリーは結婚から数年後、何を知るか。

参照回答：マクシミリアンは布商人ではなく、フランスの貴族院議員だった。／布商人ではなく、ロングヴィル子爵でフランスの貴族院議員だった。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 2584ef223f762658333799d37f593530f02ada28 / QA 5
https://github.com/google-deepmind/narrativeqa

実例９：子どもたちへの脅し

原文（要約抜粋・質問）

By such means, as the play's plot unfolds, the children are guaranteed new, credible lives. "Act or die," he commands. But if they fail to perform the play to its conclusion, or if they rebel, they will be killed by jealous Hera.
Question: Who will kill the children if they rebel ?

1. Jealous Hera 2. Hera will kill them.

日本語訳

こうして劇の筋書きが進むにつれ、子どもたちには、もっともらしい新たな人生が保証される。「演じるか、死ぬかだ」と彼は命じる。だが、劇を最後まで演じ切れなかったり、反抗したりすれば、嫉妬に燃えるヘラに殺されてしまう。
質問：子どもたちが反抗したら、誰が彼らを殺すか。

参照回答：嫉妬に燃えるヘラ。／ヘラ。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 0269408ac78193a0e13f1033bec6f658b00437b3 / QA 0 （0 始まり）
https://github.com/google-deepmind/narrativeqa

実例 10 ：セッションを打ち切る理由

原文：公開要約の連続抜粋・質問 ／ 赤字 1 ・ 2 は参照回答

They begin their sessions, but soon it is clear that they are developing romantic feelings for each other. Cheryl's husband, who loves her deeply, fights to suppress his jealousy, at first withholding a love poem that Mark has sent by mail to Cheryl, which she eventually finds. After several attempts, Mark and Cheryl are able to have mutually satisfying sex, but decide to cut the sessions short on account of their burgeoning feelings.
Question: Why do Mark and Cheryl stop their sessions?

1. They are becoming emotionally attached to one another.

2. They are developing feelings for each other.

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / e292eae2486862f6df6ff388cb2dd6777bc73f27 / QA 6 （0 始まり）
https://github.com/google-deepmind/narrativeqa

実例 10 ：セッションを打ち切る理由（訳）

要約抜粋・質問・参照回答の日本語訳

2 人はセッションを始めるが、やがて互いに恋愛感情を抱いていることが明らかになる。シェリルを深く愛する夫は嫉妬を抑えようとし、マークから彼女に郵送された恋の詩を初めは隠すが、彼女は結局それを見つける。何度か試みた後、マークとシェリルは互いに満足できる性交を持つが、気持ちが高まりつつあるため、セッションを予定より早く切り上げることにする。
質問：マークとシェリルは、なぜセッションをやめるか。

参照回答：互いに情が移り始めているから。／互いに恋愛感情を抱くようになったから。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / e292eae2486862f6df6ff388cb2dd6777bc73f27 / QA 6
https://github.com/google-deepmind/narrativeqa

実例 11 ：抜擢された理由

原文（要約抜粋・質問）

Tom Grunick (Hurt), a local news anchorman who until recently was a sports anchorman, is likeable and telegenic, but lacks news experience and knows that he was only hired for his good looks and charm. He is attracted to Jane, although he is also intimidated by her skills and intensity.
Question: Who got promoted mainly because of their good looks?

日本語訳

つい最近までスポーツ担当だった地方局のニュースキャスター、トム・グルニック（ハート）は、感じがよくテレビ映えするが、ニュースの経験は乏しい。容姿と魅力だけを買われて採用されたと自覚している。彼はジェーンに引かれる一方、その力量と熱意には気後れもしている。
質問：主に容姿のよさを理由に昇進したのは誰か。

1. Tom

2. Tom Grunick.

参照回答：トム。／トム・グルニック。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / e46daf966d764e1ef9d880884efa3b17a636e65d / QA 8 （0 始まり）
https://github.com/google-deepmind/narrativeqa

実例 12 ：悪役が狙う祝祭

原文：公開要約の連続抜粋・質問 ／ 赤字 1 ・ 2 は参照回答

Jews and African-Americans have enjoyed a tenuous peace with the White Christians over the previous few decades, because the current Santa (the son of the cruel Santa who stomped Mordechai's dreidel years earlier) has pursued a policy of inclusion and tolerance. This Santa is murdered and replaced by his son, Damian, who seeks to destroy Hanukkah and Kwanzaa thus reserving December for Christmas alone.
Question: Which holidays did Damian want to destroy?

1. Kwanzaa and Hanukkah. **2. Hanukkah and Kwanzaa**

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 1718768b5be4356b36704d5876db8009916ecd0c / QA 3 （0 始まり）
https://github.com/google-deepmind/narrativeqa

実例 12 ：悪役が狙う祝祭（訳）

要約抜粋・質問・参照回答の日本語訳

ここ数十年、ユダヤ系の人々とアフリカ系アメリカ人は、白人のキリスト教徒と、かろうじて平和を保ってきた。現在のサンタは、昔モルデカイのドレイドルを踏みつけた残酷なサンタの息子で、包摂と寛容を方針としているからだ。このサンタは殺され、息子ダミアンに取って代わられる。ダミアンはハヌカーとクワンザをなくし、 12 月をクリスマスだけの月にしようとする。
質問：ダミアンはどの祝祭をなくそうとしたか。

参照回答：クワンザとハヌカー。／ハヌカーとクワンザ。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 1718768b5be4356b36704d5876db8009916ecd0c / QA 3
https://github.com/google-deepmind/narrativeqa

実例 13 ：助けを断った理由

原文（要約抜粋・質問）

Gordon asks Ben for help. After Ben refuses to help because of his trust in the police, Gordon gets caught by the police as well and is tortured.
Question: Why does Ben not agree to help Gordon?

1. Ben trusts the police too much to help.
2. He trusts the police

日本語訳

ゴードンはベンに助けを求める。ベンは警察を信頼しているため、助けを断る。その後、ゴードンも警察に捕まり、拷問される。
質問：ベンはなぜゴードンを助けることに同意しないか。

参照回答：ベンが警察を信頼しすぎているから。／警察を信頼しているから。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 test / 08ac6c0dca91fee93d27c7caf85bb57e17d4fc46 / QA 3 （0 始まり）
https://github.com/google-deepmind/narrativeqa

統計と評価条件

配布列を使った全件の長さ集計

対象	平均	中央値	母標準偏差
要約（作品単位）	656.03	682.5	233.06
質問（問単位）	9.83	9	3.41
第 1 回答（問単位）	5.14	4	4.22

単位は単語。 *_tokenized 列を空白で分割。要約 1,572 件、質問・回答各 46,765 件。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 https://github.com/google-deepmind/narrativeqa

この資料の実例の選び方

- 本編 3 作品、追加 10 作品。書籍 7 作品・映画 6 作品から、質問と回答の性質が異なる例を選んだ。
- 質問と両方の参照回答は、配布の綴り・大文字・表記の揺れを含めて保持した。
- 要約の抜粋位置、要約全文、元の QA レコード、固定改訂とハッシュは検証記録に保存した。

[1] Google DeepMind, NarrativeQA. 公式配布 CSV （2026-10-18 取得）。 https://github.com/google-deepmind/narrativeqa

HELM の実行条件

- Classic v0.4.0 （ 2023-11-17 ）の canonical 実行。元の実行スイートは v0.3.0 。
- 提示例は最大 5 例。 OPT ・ davinci は 3 試行、 Llama 2 は 1 試行。
- temperature 0 、最大出力 100 トークン。表は未改変の test 指標で、摂動の結果とは分けている。

[1] HELM Classic v0.4.0, NarrativeQA. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/narrative_qa

研究と参考文献

DeepMind と Oxford による読解課題

- 第一著者は Tomáš Kočiský 、最終著者は Edward Grefenstette 。 DeepMind と University of Oxford の研究。
- 言語理解・質問応答の研究として、文章から回答範囲を抜き出すだけでない課題を提案した。
- 2017 年にプレプリントを公開し、 2018 年に TACL で発表された。

[1] Kočiský et al. (2018), The NarrativeQA Reading Comprehension Challenge. TACL 6:317–328. https://aclanthology.org/Q18-1023/

参考文献

The NarrativeQA Reading Comprehension Challenge

Kočiský et al. · 2018 · TACL 6:317–328

作品の選定、質問の作成方法、物語全文と要約の評価を報告する。

https://aclanthology.org/Q18-1023/

Holistic Evaluation of Language Models

Liang et al. · 2023 · TMLR

多数の課題と指標を通して言語モデルを比較する評価設計。

https://arxiv.org/abs/2211.09110

参考文献

NarrativeQA dataset

Google DeepMind · 公式配布リポジトリ

3 つの CSV 、物語の取得スクリプト、利用条件を公開する。

https://github.com/google-deepmind/narrativeqa