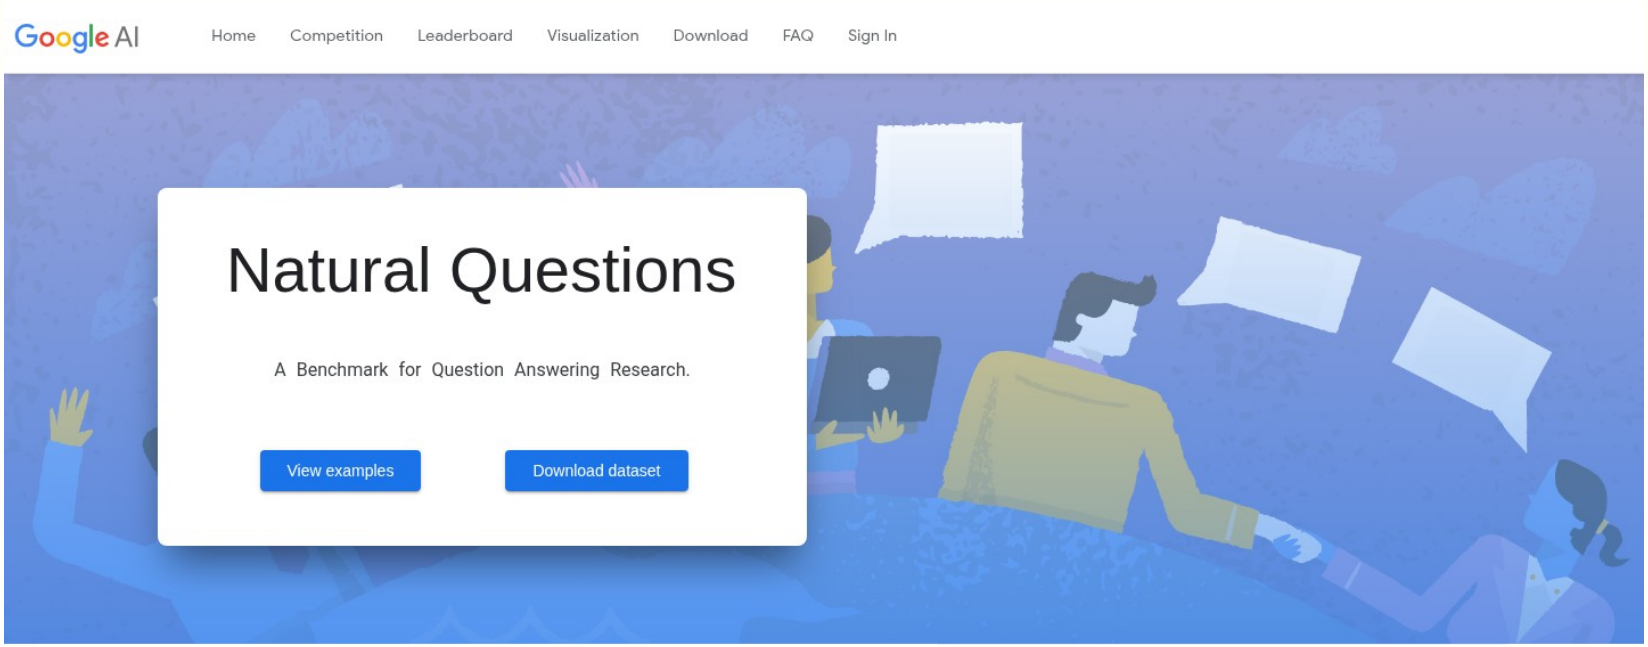
NQ

Natural Questions

検索で実際に尋ねられた質問に答える

sasakiy84

公式サイト



[1] Google Research, Natural Questions. 公式サイト。 2026-10-18 参照。 https://ai.google.com/research/NaturalQuestions

1. 検索質問と実際の回答
2. 収集・注釈とデータの全体像
3. 採点と HELM での使われ方
4. 利用の変化と入手方法

検索質問と実際の回答

検索質問と Wikipedia のページが入力

- Google 検索で実際に使われた英語の質問に、検索上位の Wikipedia ページを対応させた。
- 文章・表・リストなどから、根拠となる範囲と短い答えを選ぶ。
- ページに答えがなければ、回答なし（ NULL ）も正解になる。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

長い回答は根拠、短い回答は答え

- long answer は、答えを導ける段落・表・リストなどの範囲。
- short answer は、その中の 1 つ以上の文字列、または yes ／ no 。長い回答だけがある例もある。
- 以下の実例では、注釈された long answer 全体をタグ除去・空白整形して示す。記事名と質問も添える。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

実例１：米国上院の議員数

原文： Current members of the United States Senate

The United States Senate consists of 100 members, two from each of the 50 states. Below is a list of the current U.S. Senators, sitting in the 115th United States Congress.
Question: how many senators are there in the us senate

100

訳：現在の米国上院議員

米国上院は、 50 州それぞれから 2 人ずつ、計 100 人の議員で構成される。以下は、第 115 議会で在職中の米国上院議員の一覧である。
質問：米国上院には何人の議員がいるか。

100 人

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 8594030243394572667
https://huggingface.co/datasets/google-research-datasets/natural_questions

数字を含む範囲を選ぶ

- long answer は、米国上院の構成を説明した段落全体。 short answer は「 100 」の範囲。
- 元の課題では、短い文字列を生成するだけでなく、記事内のどこが答えかを指定する。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

実例２：四つの州をまとめて答える

記事： Commonwealth (U.S. state) ／ long answer 全文・質問・正解注釈

Commonwealth is a designation used by four of the 50 states of the United States in their full official state names: Kentucky[1] (the law creating Kentucky names it the "State of Kentucky"[2] but it was originally part of the land grant of the Colony of Virginia), Massachusetts,[3] Pennsylvania,[4] and Virginia.[5] Each was, prior to 1776, a British colony, or parts thereof, and share a strong influence of English common law in some of their laws and institutions.[6][7]
Question: how many us states are commonwealths and which states are they

Kentucky
Massachusetts
Pennsylvania
Virginia

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 8095779539186493860
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例２：四つの州をまとめて答える（訳）

記事：コモンウェルス（米国の州） ／ 日本語訳・正解注釈

コモンウェルスは、米国 50 州のうち 4 州が正式な州名に使っている呼称である。ケンタッキー [1] （同州を設置した法律では「ケンタッキー州」と呼ぶが [2] 、もともとはバージニア植民地に与えられた土地の一部だった）、マサチューセッツ [3] 、ペンシルベニア [4] 、バージニア [5] が該当する。いずれも 1776 年以前はイギリスの植民地かその一部だった。法や制度の一部は、共通してイングランドのコモン・ローの強い影響を受けている。 [6][7]
質問：コモンウェルスと呼ぶ米国の州はいくつあり、どの州か。

ケンタッキー
マサチューセッツ
ペンシルベニア
バージニア

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 8095779539186493860
https://huggingface.co/datasets/google-research-datasets/natural_questions

短い回答が複数の箇所に分かれる

- ４つの州名が、それぞれ離れた範囲にある。配布注釈では、この４範囲の集合が短い回答。
- コモンウェルスは州の正式名称に使われる呼称で、別種の行政区分を意味しない。
- ここでは１人分の注釈を示した。他の作業者の注釈も検証記録に保持している。

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 https://huggingface.co/datasets/google-research-datasets/natural_questions

回答なしの例では記事冒頭を抜粋する

- 次の例は、 5 人とも long answer を付けていない。表示する本文は記事冒頭の抜粋。
- 実際の課題では記事全文を読む。画面に示した抜粋だけで、不在を判定した注釈ではない。

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 https://huggingface.co/datasets/google-research-datasets/natural_questions

実例３：回答なしも正解になる

記事： Industrial robot ／ 冒頭の抜粋・質問・正解注釈

> Typical applications of robots include welding, painting, assembly, pick and place for printed circuit boards, packaging and labeling, palletizing, product inspection, and testing; all accomplished with high endurance, speed, and precision. They can assist in material handling.
> Question: which of this following is not an activity typically performed by robots in the automotive industry

NULL (all 5 annotators)

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: -7006867114426353780
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例３：回答なしも正解になる（訳）

記事：産業用ロボット ／ 日本語訳・正解注釈

ロボットの典型的な用途には、溶接、塗装、組み立て、プリント基板用の部品の取り上げと配置、包装とラベル貼り、パレット積み、製品検査、試験などがあり、いずれも高い耐久性、速度、精度で行われる。資材の取り扱いを支援することもできる。
質問：次のうち、自動車産業のロボットが通常行わない作業はどれか。

回答なし（５人全員）

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: -7006867114426353780
https://huggingface.co/datasets/google-research-datasets/natural_questions

質問の前提がそろっているか

- 質問は「次のうち」と尋ねるが、選択肢は書かれていない。
- 記事にロボットの用途は並んでいても、この質問には 5 人とも回答なしの注釈を付けた。
- 答えを作らず、回答しないと判断することも評価の一部になる。

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 https://huggingface.co/datasets/google-research-datasets/natural_questions

収集・注釈とデータの全体像

答えを見て作った質問から離れる

- SQuAD （2016 年）では、文章を見て作業者が質問を書いた。 NQ は情報を探す利用者の検索質問を使う。
- 答えを含む一段落を渡すのではなく、 HTML 構造を持つ記事全体を入力にする。
- 答えが見つからない質問も残し、回答の可否を判断する課題にした。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

8 語以上の検索質問を集める

- 短い期間に複数の利用者が検索した、 8 語以上の英語の質問を対象にした。
- 疑問詞や文の形などの条件で、事実を尋ねる質問を選んだ。 how to で始まる質問は対象外。
- 検索の上位 5 件に Wikipedia がある質問を採り、最上位の Wikipedia ページを組にした。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

人が質問・根拠・短い答えを順に確認

- まず記事を見ずに、事実を尋ねる理解可能な質問かを判断する。
- 次に記事内で、回答に必要な情報がそろう最小の HTML 要素を選ぶ。複数あれば先に出るものを選ぶ。
- その範囲から短い回答を選び、 yes ／ no や、短い回答なしも指定する。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

複数の注釈で判断の揺れを捉える

- 約 50 人の作業者が担当し、 1 件当たりの平均作業時間は 80 秒。
- 学習データは各 1 人、開発・テストは各 5 人が注釈した。別の標本には 25 人分を集めた。
- 4 人の専門家が独立に正しさを評価し、判断が割れた例を議論して合意を取った。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

30 万件を超える学習データ

分割	質問・記事ペア	注釈者数／件
学習	307,373	1
開発	7,830	5
テスト	7,842	5

2019 年の公表値。テストの正解注釈は非公開。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

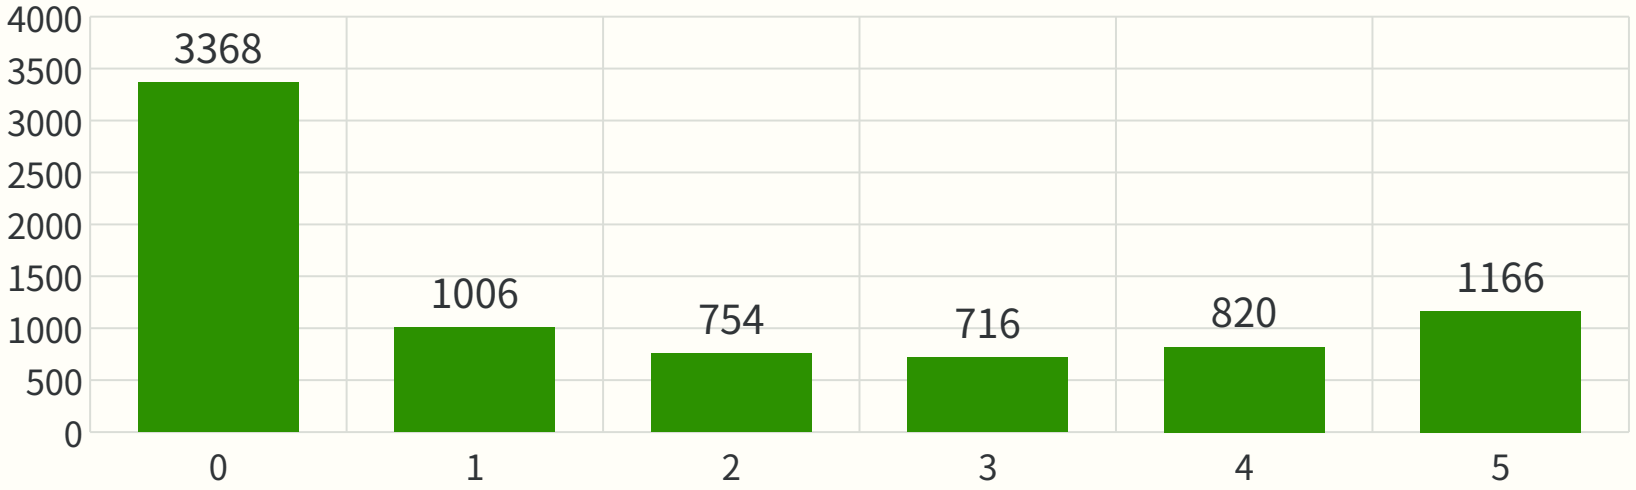
開発集合では、回答なしも多い

5 注釈中 2 人以上が回答あり	質問数
long answer あり	4,608
short answer あり（yes ／ no を含む）	3,456
うち yes ／ no	120

公開開発集合 7,830 件の全件集計。各行の対象は重複する。

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 https://huggingface.co/datasets/google-research-datasets/natural_questions

短い答えの有無も判断が割れる



横軸：回答ありとした人数。縦軸：質問数。全 7,830 件。

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 https://huggingface.co/datasets/google-research-datasets/natural_questions

採点と HELM での使われ方

NQ の採点：回答するか、範囲は一致するか

- 5 人中 2 人以上が回答ありとしたら、回答すべき例とする。
- long answer は、いずれか 1 人の非 NULL の範囲と一致すれば正解。 short answer は範囲の集合か yes ／ no で照合する。
- 正しく回答した件数から適合率・再現率を求め、集合全体の F1 を計算する。

[1] Google Research, Natural Questions. 注釈仕様と評価コード。 https://github.com/google-research-datasets/natural-questions

2019 年のベースライン

方式	long F1	short F1
DocumentQA	46.1	35.7
DecAtt + DocReader	54.8	31.4

開発集合、単位は % 。回答なしを含む、範囲選択の評価。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

HELM では短い回答の生成に使う

- 公開開発集合のうち、少なくとも 1 人が短い回答のスパンを付けた 4,289 例を利用対象にする。
- 回答なしの例と、 yes ／ no の専用フィールドは使わない。元の学習集合も使わない。
- 各ファイル内で交互に提示例用と評価用へ分け、公開実行では評価側から 1,000 件を採点した。

[1] Stanford CRFM, HELM NaturalQA scenario. 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/natural_qa_scenario.py

HELM の二つの入力条件

条件	モデルへ渡す情報
closed-book	質問だけ
open-book longans	質問と、注釈された long answer

open-book は正解の根拠を与える設定。検索器で文章を探す評価ではない。

[1] Stanford CRFM, HELM NaturalQA scenario. 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/natural_qa_scenario.py

HELM の F1 は回答文の語の重なり

- 回答を小文字化し、句読点・冠詞・余分な空白を除き、語の重なりから各問の F1 を計算する。
- 短い回答の各スパンを別々の参照回答として扱い、最も高い得点を使う。
- この平均値は、回答なしも扱う NQ の範囲選択 F1 とは課題と計算方法が異なる。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

根拠を渡すと回答の得点が上がる

モデル	質問のみ	根拠あり
OPT-175B	29.66	61.49
text-davinci-003	40.64	77.02
Llama 2 70B	45.84	67.42

v0.4.0 、各 1,000 件の token F1 （ % ）。 OPT ・ davinci は 3 試行平均、Llama 2 は 1 試行。

[1] HELM Classic v0.4.0, NaturalQuestions (open-book). 2023-11-17 の固定版。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/natural_qa_openbook_longans

根拠ありでも、記事から探す課題とは違う

- long answer の注釈を使うので、記事全体から根拠を探す段階は省かれている。
- 本文がない条件では、学習済みの知識などから短い答えを生成する。
- 最大提示例数は 5 。根拠あり条件では入力上限のため例数が減り、一部の入力が切り詰められた。

[1] HELM Classic v0.4.0, NaturalQuestions (open-book). 2023-11-17 の固定版。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/natural_qa_openbook_longans

利用の変化と入手方法

範囲選択から、知識と文脈利用の比較へ

- 2019 年の課題は、実際の検索質問に対して、記事から答えを見つけ、回答できるかを決めること。
- HELM では質問のみ・根拠ありの条件を使い、言語モデルが知識と与えられた文脈をどう使うかを比べる。
- 2026-10-18 時点の公開 HELM コードにも、この 2 条件の実装がある。

[1] Stanford CRFM, HELM NaturalQA scenario. 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/natural_qa_scenario.py

公開データから実例と注釈を読む

- 公式サイトから課題の仕様と公開データへ進める。学習・開発データは公開、テスト正解は非公開。
- 今回取得した Hugging Face の dev 配布は、 7 個の Parquet ファイルで約 1.34 GB 。全 7,830 例が入る。
- 各例には質問、 Wikipedia の HTML 、長い回答の候補、注釈者ごとの長い回答・短い回答・ yes ／ no がある。

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 https://huggingface.co/datasets/google-research-datasets/natural_questions

データの条件と元記事の条件を確認する

- 公式リポジトリのライセンスは Apache 2.0 。
- 収録 Wikipedia 本文の HTML には、 CC BY-SA 3.0 の表示がある。元記事の URL も付いている。
- 元記事を更新後の内容で読み直す場合は、配布時点の本文や注釈と分けて扱う。

[1] Google Research, Natural Questions. 注釈仕様と評価コード。 https://github.com/google-research-datasets/natural-questions

答えを探すことと、答えない判断を測る

- 検索から集めた質問と記事に、根拠の範囲・短い答え・回答なしの注釈がある。
- 表やリスト、複数箇所の答え、注釈者間の揺れも課題の一部。
- HELM で使う場合は、短い回答がある例への絞り込みと、質問のみ・根拠ありの条件を押さえる。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

Appendix

1. 追加の実例
2. 注釈と実行条件の補足
3. 研究と参考文献

追加の実例

追加例には yes ／ no の注釈も含める

- 以下の 10 例は、本編とは異なる 10 記事から選んだ。元の NQ の課題を示すため、 HELM が使わない yes ／ no も含める。
- 短い回答は、 1 人の注釈の範囲集合を表示する。 yes ／ no は 5 人のうち最も多い非 NULL の注釈を示す。
- 本文は、その注釈に対応する long answer の全文。記事名も原文と訳に添えている。

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 4 ：二つの呼び名を抽出する

記事： Deposition (phase transition) ／ long answer 全文・質問・正解注釈

Deposition is a thermodynamic process, a phase transition in which gas transforms into solid without passing through the liquid phase. The reverse of deposition is sublimation and hence sometimes deposition is called desublimation.
Question: phase change from gas to solid is called

Deposition **desublimation**

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: -7161763639005120 91
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 4 ：二つの呼び名を抽出する（訳）

記事：凝華（相転移） ／ 日本語訳・正解注釈

凝華は熱力学的な過程で、気体が液体の状態を経ずに固体へ変わる相転移である。凝華の逆は昇華なので、凝華は desublimation と呼ばれることもある。
質問：気体から固体への相転移は何と呼ばれるか。

deposition （凝華）　　**desublimation （凝華）**

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: -7161763639005120 91
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 5 ：シーズンで歌い手が変わる

記事： That '70s Show ／ long answer 全文・質問・正解注釈

Opening theme "In the Street" by Big Star as performed by; Todd Griffin (season 1) Cheap Trick (seasons 2–8)
Question: who sang the theme song to that 70s show

Todd Griffin (season 1)

Cheap Trick (seasons 2–8)

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 1318031841813121387
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 5 ：シーズンで歌い手が変わる（訳）

記事：ザット '70s ショー ／ 日本語訳・正解注釈

オープニング曲は Big Star の「 In the Street 」。歌唱はトッド・グリフィン（シーズン 1 ）、チープ・トリック（シーズン 2 ～ 8 ）。
質問：「ザット’70s ショー」の主題歌を歌ったのは誰か。

トッド・グリフィン（シーズン 1 ）　　**チープ・トリック（シーズン 2 ～ 8 ）**

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 1318031841813121387
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 6 ：病気と微生物の関係

記事： Germ theory of disease ／ long answer 全文・質問・正解注釈

The Italian Agostino Bassi was the first person to prove that a disease was caused by a microorganism when he conducted a series of experiments between 1808 and 1813, demonstrating that a "vegetable parasite" caused a disease in silkworms known as calcinaccio—this disease was devastating the French silk industry at the time. The "vegetable parasite" is now known to be a fungus pathogenic to insects called Beauveria bassiana (named after Bassi).
Question: who established the idea that microorganisms play a role in disease

Agostino Bassi

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 8852834747561852791
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 6 ：病気と微生物の関係（訳）

記事：病原菌説 ／ 日本語訳・正解注釈

イタリア人のアゴスティーノ・バッシは、 1808 年から 1813 年にかけて一連の実験を行い、病気が微生物によって引き起こされることを初めて証明した。「植物性の寄生体」がカイコの calcinaccio という病気を引き起こすことを示したのである。この病気は当時、フランスの絹産業に壊滅的な被害を与えていた。この「植物性の寄生体」は現在、昆虫に病気を起こす菌類 Beauveria bassiana （バッシにちなむ命名）と分かっている。
質問：微生物が病気に関わるという考えを確立したのは誰か。

アゴスティーノ・バッシ

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 8852834747561852791
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 7 ：データベースの種類

記事： Library Literature and Information Science ／ long answer 全文・質問・正解注釈

Library Literature and Information Science is a bibliographic database that indexes over 410 library and information science periodicals published internationally. It also covers books, chapters within books, library school theses, and pamphlets. In 2011, the H. W. Wilson Company, the firm that created the index, sold it to EBSCO Publishing along with other H.W. Wilson indexes and databases.[1]
Question: what type of database is library literature and information science

bibliographic

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: -6938473913955258O4
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 7 ：データベースの種類（訳）

記事： Library Literature and Information Science ／ 日本語訳・正解注釈

Library Literature and Information Science は、国際的に発行される図書館学・情報科学の定期刊行物 410 誌以上を索引化した書誌データベースである。書籍、書籍の章、図書館学の学位論文、パンフレットも扱う。 2011 年、索引を作った H. W. Wilson 社は、他の索引やデータベースとともに、これを EBSCO Publishing へ売却した。 [1]
質問： Library Literature and Information Science は、どのような種類のデータベースか。

書誌データベース

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: -6938473913955258O4
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 8 ：胃から小腸への通り道

原文： Chyme

Chyme or chymus (/kaɪm/; from Greek χυμός khymos, "juice"[1][2]) is the semi-fluid mass of partly digested food that is expelled by the stomach, through the pyloric valve, into the duodenum[3] (the beginning of the small intestine).
Question: what allows chyme to enter the small intestine

pyloric valve

訳：食糜

食糜（ chyme 、 chymus 、発音 / kaɪm/ 。ギリシャ語 χυμός khymos 「汁」に由来 [1][2] ）は、消化途中の食物が半流動状になったもので、胃から幽門弁を通り、十二指腸 [3] （小腸の始まり）へ送り出される。
質問：食糜を小腸へ通すのは何か。

幽門弁

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: -5109077199816756661
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例９：実話に基づく映画か

記事： Draft Day ／ long answer 全文・質問・正解注釈

Draft Day is a 2014 American sports drama film directed by Ivan Reitman and starring Kevin Costner. The premise revolves around the fictional general manager of the Cleveland Browns (Costner) deciding what to do after his team acquires the number one draft pick in the upcoming National Football League draft.
Question: is draft day the movie based on a true story

NO

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 9100188456643224075
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例９：実話に基づく映画か（訳）

記事：ドラフト・デイ ／ 日本語訳・正解注釈

「ドラフト・デイ」は、アイヴァン・ライトマン監督、ケビン・コスナー主演の 2014 年の米国のスポーツドラマ映画である。クリーブランド・ブラウンズの架空のゼネラルマネジャー（コスナー）が、次の NFL ドラフトの全体 1 位指名権を獲得した後、何をするかを決めるという筋書きである。
質問：映画「ドラフト・デイ」は実話に基づいているか。

いいえ（NO）

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 9100188456643224075
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 10 ：過去に発生したことがあるか

原文： Tornadoes in the United States

Alaska has only been hit by 2 tornadoes between 1950 and 2006 (the first being November 4, 1959[38] and the other was August 2, 2005[39]); both were only F0. Hawaii has only been hit by 49 tornadoes since 1950. Question: has there ever been a tornado in alaska

YES

訳：米国の竜巻

アラスカで 1950 年から 2006 年までに発生した竜巻は 2 件だけで、最初は 1959 年 11 月 4 日 [38] 、もう 1 件は 2005 年 8 月 2 日 [39] だった。いずれも F0 にすぎなかった。ハワイでは 1950 年以降、 49 件の竜巻しか発生していない。
質問：アラスカで竜巻が発生したことはあるか。

はい（ YES ）

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: -2051272193055915930
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 11 ：通行方向を記事名から読む

記事： List of countries with left-hand traffic ／ long answer 全文・質問・正解注釈

Title: List of countries with left-hand traffic
Australia Christmas Island (Australia) Cocos (Keeling) Islands (Australia) Cook Islands (New Zealand) Fiji Kiribati Nauru New Zealand Niue Norfolk Island (Australia) Papua New Guinea Pitcairn Islands (U.K. Overseas Territory) Solomon Islands Samoa (since September 1, 2009) Tokelau (New Zealand) Tonga Tuvalu
Question: does australia drive on the right side of the road

NO

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 3525408608203192577
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 11 ：通行方向を記事名から読む（訳）

記事：左側通行の国・地域の一覧 ／ 日本語訳・正解注釈

記事名：左側通行の国・地域の一覧
オーストラリア、クリスマス島（オーストラリア）、ココス（キーリング）諸島（オーストラリア）、クック諸島（ニュージーランド）、フィジー、キリバス、ナウル、ニュージーランド、ニウエ、ノーフォーク島（オーストラリア）、パプアニューギニア、ピトケアン諸島（英国海外領土）、ソロモン諸島、サモア（2009 年 9 月 1 日から）、トケラウ（ニュージーランド）、トンガ、ツバル。
質問：オーストラリアでは道路の右側を通行するか。

いいえ（NO）

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 3525408608203192577
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 12 ：複数の州を拾う

記事： Dust Bowl ／ long answer 全文・質問・正解注釈

The drought and erosion of the Dust Bowl affected 100,000,000 acres (400,000 km2) that centered on the panhandles of Texas and Oklahoma and touched adjacent sections of New Mexico, Colorado, and Kansas.[5]
Question: what states were most affected by the dust bowl

Texas
Oklahoma
New Mexico
Colorado
Kansas

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 7354980942032766409
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 12 ：複数の州を拾う（訳）

記事：ダストボウル ／ 日本語訳・正解注釈

ダストボウルによる干ばつと侵食は、テキサス州とオクラホマ州のパンハンドル地域を中心に、隣接するニューメキシコ州、コロラド州、カンザス州の一部にも及ぶ 1 億エーカー（ 40 万 km2 ）の土地に影響した。 [5]
質問：ダストボウルの被害が最も大きかったのはどの州か。

テキサス
オクラホマ
ニューメキシコ
コロラド
カンザス

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: 7354980942032766409
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 13 ：複数の機能を答える

記事： Pericardium ／ long answer 全文・質問・正解注釈

Sets heart in mediastinum and limits its motion Protects it from infections coming from other organs (such as lungs) Prevents excessive dilation of the heart in cases of acute volume overload Lubricates the heart
Question: what is the function of the pericardial sac

Sets heart in mediastinum and limits its motion
Protects it from infections coming from other organs (such as lungs)

Prevents excessive dilation of the heart in cases of acute volume overload
Lubricates the heart

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: -7044678620071639460
https://huggingface.co/datasets/google-research-datasets/natural_questions

実例 13 ：複数の機能を答える（訳）

記事：心膜 ／ 日本語訳・正解注釈

心臓を縦隔内に固定し、動きを制限する。他の臓器（肺など）からの感染を防ぐ。急激な容量負荷の際に心臓が過度に拡張するのを防ぐ。心臓の動きを滑らかにする。
質問：心嚢にはどのような働きがあるか。

心臓を縦隔内に固定し、動きを制限する
他の臓器（肺など）からの感染を防ぐ

急激な容量負荷時の心臓の過度な拡張を防ぐ
心臓の動きを滑らかにする

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 dev / example_id: -7044678620071639460
https://huggingface.co/datasets/google-research-datasets/natural_questions

注釈と実行条件の補足

検索質問の長さ

全開発集合の質問	単語数
平均	9.39
中央値	9
母標準偏差	1.89

7,830 件。配布 question.tokens の個数を数えた。

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 https://huggingface.co/datasets/google-research-datasets/natural_questions

人の得点は別の標本で推定した

- 25 人が注釈した別標本から、 1 人の注釈者の得点と、人の判断から得られる上限を推定した。
- 1 人の注釈者は long F1 73.4 、 short F1 57.5 。上限の推定はそれぞれ 87.2 、 75.7 。
- 通常の開発集合で全注釈者の回答をそのまま平均した得点ではない。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

HELM の完全一致も確認する

モデル	質問のみ	根拠あり
OPT-175B	17.60	40.40
text-davinci-003	22.53	48.53
Llama 2 70B	30.90	43.80

各 1,000 件、 EM （ % ）。 OPT ・ davinci は 3 試行平均、 Llama 2 は 1 試行。

[1] HELM Classic v0.4.0, NaturalQuestions (open-book). 2023-11-17 の固定版。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/natural_qa_openbook_longans

根拠あり条件の実際の入力

モデル	平均提示例数	切り詰め率
OPT-175B	4.69	3.6%
text-davinci-003	4.88	2.0%
Llama 2 70B	4.83	2.6%

最大 5 例、 temperature 0 、最大出力 100 トークン。切り詰め率は prompt_truncated の平均。

[1] HELM Classic v0.4.0, NaturalQuestions (open-book). 2023-11-17 の固定版。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/natural_qa_openbook_longans

取得データと公開実行記録を照合した

- 旧 GCS の dev URL は匿名アクセスで 403 になったため、公開 Hugging Face 配布を取得した。
- HELM の公開 scenario_state から、摂動なし・第 1 試行の 1,000 例を取り出した。
- 取得した開発集合と質問・参照回答を照合し、 1,000 例すべてで一致を確認した。

[1] Google Research, Natural Questions. dev / Hugging Face 公開配布。 https://huggingface.co/datasets/google-research-datasets/natural_questions

研究と参考文献

Google Research による検索質問の課題

- 第一著者は Tom Kwiatkowski 、最終著者は Slav Petrov 。Google Research のチームが構築した。
- 検索に使われる質問を基に、読解と回答の可否を扱う大規模な注釈付きデータを公開した。
- 2019 年に TACL で発表。注釈者の判断が割れることも、評価設計の中心に置いた。

[1] Kwiatkowski et al. (2019), Natural Questions: A Benchmark for Question Answering Research. TACL 7:453–466. https://aclanthology.org/Q19-1026/

参考文献

Natural Questions: A Benchmark for Question Answering Research

Kwiatkowski et al. · 2019 · TACL 7:453–466

検索質問の収集、 HTML 上の回答注釈、複数人の判断を使う採点を提案する。

https://aclanthology.org/Q19-1026/

Holistic Evaluation of Language Models

Liang et al. · 2023 · TMLR

多数の課題と指標を通して言語モデルを比較する評価設計。

https://arxiv.org/abs/2211.09110

参考文献

Natural Questions

Google Research · 公式リポジトリ

注釈仕様、回答範囲のデータ形式、採点コードを公開する。

https://github.com/google-research-datasets/natural-questions