# Numeracy

多項式の規則推論

入出力の例から、未知の値を予測する

sasakiy84

1. 入出力の例から規則を推測する
2. 多項式と入力点を生成する
3. 予測値と正解を比べる
4. 生成器を使って試す

# 1. 入出力の例から規則を推測する

# 式を示さず、数の対応を示す

- Numeracy は、入力と出力の数値の組から多項式の規則を推測し、新しい入力に対応する値を答える人工生成課題である。
- Stanford CRFM を中心とする研究チームが 2022 年に設計した。公開生成器で式の係数と入力点を選び、学習用・評価用の数値を作る。
- モデルには数値の対応を見せる。式そのものは示さず、新しい入力に対する数値を予測させる。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110
[2] Stanford CRFM. NumeracyScenario （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 数値の対応を見せ、別の入力の答えを尋ねる

- 学習用の数値の組と、予測対象にする評価用の入力を生成する。モデルは、提示された入出力例を手掛かりに規則を推測する。
- 次の実例では、学習用 100 組から抜粋した 4 〜 6 組と、評価用の入力 1 件を示す。各例の正解は、生成時に保存された式から計算できる。

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py
[2] Stanford CRFM. get_numeracy_spec （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/run_specs.py

# 実例 1 ：一次式の未知の値を求める

式の種類： linear

学習用 100 組から 4 組を抜粋

```
x, y
-82, -324
70, 284
7, 32
-2, -4
```

予測する入力

```
15
```

**正解： 64**

x=15 のときの y を予測する。

正解の計算に使う式

**y = 4x + 4**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 一次式では変化の割合が一定になる

- この例を生成した式は y=4x+4 。 x=15 なら、 4×15+4=64 になる。
- モデルに見せるのは、−82→−324 、 70→284 などの数値の対応である。例の間で共通する規則を見つけ、新しい入力へ適用する。

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 実例２：二次式の増え方を推測する

式の種類： parabola

学習用 100 組から 4 組を抜粋

```
x, y
18, 667
170, 57971
107, 23006
98, 19307
```

予測する入力

```
115
```

**正解： 26566**

x=115 のときの y を予測する。

正解の計算に使う式

**y = 2x^2 + x + 1**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 二次式では入力の大きさが強く効く

- この例の参照式は $y=2x^2+x+1$ 。 $x=115$ なら 26,566 になる。
- 訓練用の $x=107$ に対する値は 23,006 。入力が 8 増えると出力は 3,560 増え、一次式の一定の増え方とは異なる。
- 式の形や係数を入力に直接示さず、数値の対応から推測させる。

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 実例３：二つの入力から出力を求める

式の種類： plane

学習用 100 組から 6 組を抜粋

```
x, y, z
6, 8, 57
-2, 1, -3
0, 6, 25
2, 3, 21
-3, 7, 17
-3, 1, -7
```

予測する入力

```
6, 7
```

**正解： 53**

x=6 、 y=7 のときの z を予測する。

正解の計算に使う式

**z = 4x + 4y + 1**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 入力の変数を二つに増やす

- この例を生成した式は z=4x+4y+1 。 x=6 、 y=7 を代入すると 53 になる。
- 一つの入力が二つの値を持つため、 x と y が出力にどう影響するかを、数値の組から推測する。
- 一次・二次、 1 変数・ 2 変数を組み合わせた 4 種類の式を用意している。

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 2. 多項式と入力点を生成する

# 4 種類の式で次数と変数の数を変える

| コードの型名 | 変数の数 | 次数 | 固定された参照式 |
|---|---|---|---|
| linear | 1 | 1 | $y = 2x + 5$ |
| parabola | 1 | 2 | $y = x^2 + 2$ |
| plane | 2 | 1 | $z = 2x + y + 5$ |
| paraboloid | 2 | 2 | $z = 2x^2 + y^2 + 2$ |

右列は example モードの式。 standard モードでは係数を範囲内で抽選する。

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 整数係数と整数の入力点を抽選する

- 式の種類ごとに、整数の係数を選ぶ範囲を決める。必要な次数と変数の数を持ち、定数項が 0 でない式を作る。
- 式に整数の入力点を代入し、対応する出力を計算する。学習用と評価用は同じ式から作る。
- 係数を固定した式で試す方法と、範囲内から係数を抽選して別の式を作る方法がある。

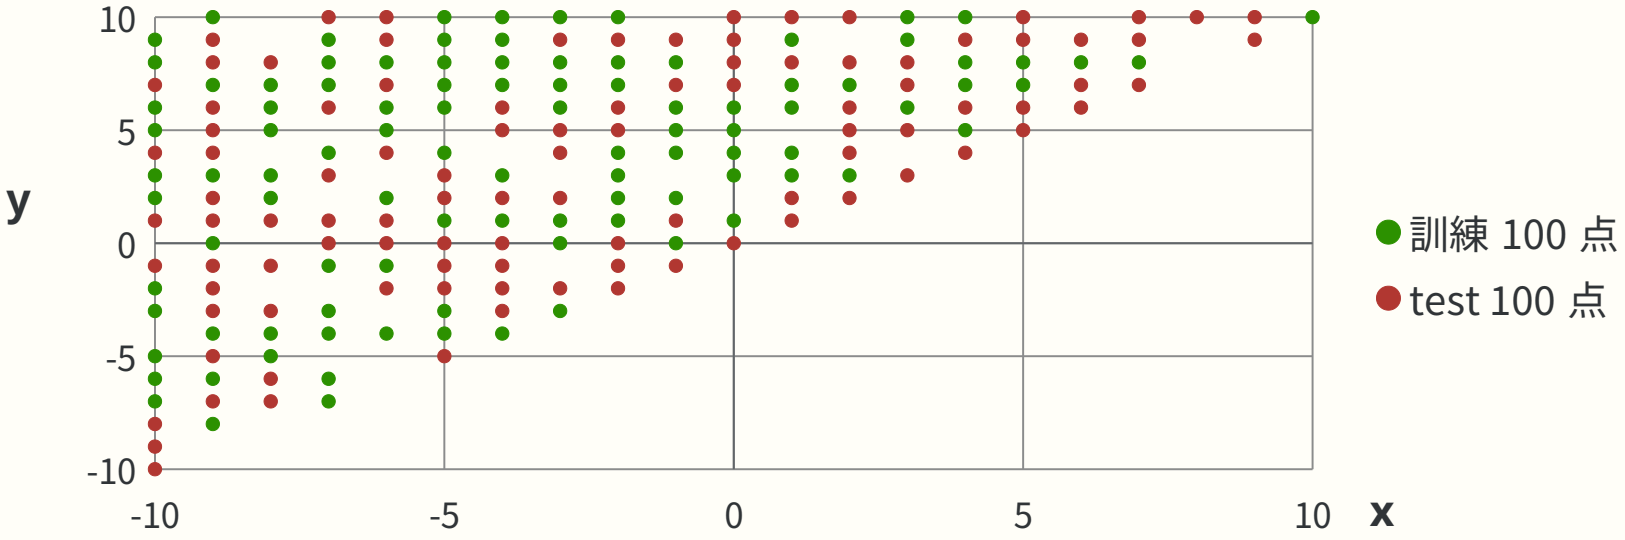
[1] Stanford CRFM. NumeracyScenario （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 入力範囲は関数型に合わせて変える

- 公開生成器の標準設定では、 linear は−100 〜 100 、 parabola は 0 〜 200 の整数を使う。二次式の入力は非負にしている。
- plane は二つの変数が−10 〜 10 、 paraboloid は 0 〜 20 の整数を使う。どちらも x が y 以下となる点を選ぶ。
- 学習用と評価用を同じ領域から選び、同じ入力点が両方に入らないようにする。

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 2 変数の入力は三角形の範囲にある




plane の生成例。学習 100 点、評価 100 点を、 231 候補点から選ぶ。

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# モードごとに式の扱いを変える

| モード | 式の選び方 | v0.3.0 の生成件数 |
|---|---|---|
| example | 型ごとに固定された式 | train 100 ＋ test 100 |
| standard | 1 個の式を抽選する | train 100 ＋ test 100 |
| function | 問題ごとに式を替える設計 | 0 （生成処理は未実装） |

公開生成器 v0.3.0 。 function モードの生成処理は未実装である。

[1] Stanford CRFM. NumeracyScenario （ v0.3.0 ）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 3. 予測値と正解を比べる

# 正答率と、予測値のずれで評価する

- 予測した整数が正解と一致する割合で、規則を正しく適用できたかを見る。数値としてどれほど近いかは、予測値と正解値の差の絶対値で測れる。
- 絶対誤差 = | 予測値 − 正解値 |
- 実例 1 の正解 64 に対して 65 を出力すると、一致せず、絶対誤差は 1 になる。出力の大きさが式ごとに異なるため、式の種類や入力範囲と合わせて評価する。

[1] Stanford CRFM. get_numeracy_spec （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/run_specs.py
[2] Stanford CRFM. BasicMetric （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/basic_metrics.py

# 4. 生成器を使って試す

# 例の数や入力範囲を変えて、推論を調べる

- 一つの式について、学習用の例を何組見せれば、新しい入力に正しく答えられるかを調べられる。
- 係数の範囲、入力の範囲、例の数や並び順を決めると、モデルを同じ条件で比較できる。
- 1 変数から 2 変数へ、一次式から二次式へと、規則の形を変えて推論の違いを見ることもできる。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110
[2] Stanford CRFM. NumeracyScenario （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 公式生成器でレコードを作る

```
task = NumeracyScenario(
    relation_type="linear", mode="standard", seed=0
)
records = task.get_instances("output")
example = next(r for r in records if r.split == "test")
print(example.input.text)
print(example.references[0].output.text)
```

公開生成器の NumeracyScenario を読み込んだ後の例。学習用・評価用の数値を作り、最初の評価入力と正解を表示する。

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 公開コードを使って人工データを生成する

- 公開生成器は Apache License 2.0 で提供される。式の種類、係数を選ぶ方法、乱数の seed を指定して、数値の組と正解を作れる。
- 同じ数値を再現するときは、生成器のバージョンと実行環境も記録する。ここで示す実例は v0.3.0 の生成器を使っている。

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py
[2] Stanford CRFM. Apache License 2.0 。 https://github.com/stanford-crfm/helm/blob/v0.3.0/LICENSE

# 数値の対応から未知の値を予測する

- Numeracy は、多項式から作った入出力の例を見せ、未知の入力に対応する数値を予測させる課題である。
- 一次・二次、１変数・２変数の式を使い、既知の計算式を直接与えずに、数の対応から規則を見つけられるかを調べる。
- 生成器の条件をそろえることで、正答率や数値誤差を使った比較実験を組み立てられる。

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# Appendix

1. 追加の実例
2. 式とデータ形式の補足
3. 研究と参考文献

# 実例 4 ：交差項を含む二次式

式の種類： paraboloid

学習用 100 組から 6 組を抜粋

```
x, y, z
16, 18, 1128
8, 11, 341
10, 16, 620
12, 13, 617
7, 17, 510
7, 11, 300
```

予測する入力

```
16, 17
```

**正解： 1077**

x=16 、 y=17 のときの z を予測する。

正解の計算に使う式

**z = 2x^2 + xy + y^2 + 4**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 実例 5 ：固定された一次式

式の種類： linear

学習用 100 組から 4 組を抜粋

```
x, y
-82, -159
70, 145
7, 19
-2, 1
```

予測する入力

```
15
```

**正解： 35**

x=15 のときの y を予測する。

正解の計算に使う式

**y = 2x + 5**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 実例 6 ：固定された二次式

式の種類： parabola

学習用 100 組から 4 組を抜粋

```
x, y
18, 326
170, 28902
107, 11451
98, 9606
```

予測する入力

```
115
```

**正解： 13227**

x=115 のときの y を予測する。

正解の計算に使う式

**y = x^2 + 2**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 実例 7 ：固定された平面の式

式の種類： plane

学習用 100 組から 6 組を抜粋

```
x, y, z
6, 8, 25
-2, 1, 2
0, 6, 11
2, 3, 12
-3, 7, 6
-3, 1, 0
```

予測する入力

```
6, 7
```

**正解： 24**

x=6 、 y=7 のときの z を予測する。

正解の計算に使う式

**z = 2x + y + 5**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 実例 8 ：固定された二次曲面

式の種類： paraboloid

学習用 100 組から 6 組を抜粋

```
x, y, z
16, 18, 838
8, 11, 251
10, 16, 458
12, 13, 459
7, 17, 389
7, 11, 221
```

予測する入力

```
16, 17
```

**正解： 803**

x=16 、 y=17 のときの z を予測する。

正解の計算に使う式

**z = 2x^2 + y^2 + 2**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 実例９：正解が 0 になる入力

式の種類： linear

学習用 100 組から 4 組を抜粋

```
x, y
-82, -324
70, 284
7, 32
-2, -4
```

予測する入力

```
-1
```

**正解： 0**

x=-1 のときの y を予測する。

正解の計算に使う式

**y = 4x + 4**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 実例 10 ：二次式の隣の入力点

式の種類： parabola

学習用 100 組から 4 組を抜粋

```
x, y
18, 667
170, 57971
107, 23006
98, 19307
```

予測する入力

```
99
```

**正解： 19702**

x=99 のときの y を予測する。

正解の計算に使う式

**y = 2x^2 + x + 1**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 実例 11 ：二つの入力がともに大きい

式の種類： plane

学習用 100 組から 6 組を抜粋

```
x, y, z
6, 8, 57
-2, 1, -3
0, 6, 25
2, 3, 21
-3, 7, 17
-3, 1, -7
```

予測する入力

```
7, 10
```

**正解： 69**

x=7 、 y=10 のときの z を予測する。

正解の計算に使う式

**z = 4x + 4y + 1**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 実例 12 ：二次曲面の別の入力点

式の種類： paraboloid

学習用 100 組から 6 組を抜粋

```
x, y, z
16, 18, 1128
8, 11, 341
10, 16, 620
12, 13, 617
7, 17, 510
7, 11, 300
```

予測する入力

```
17, 20
```

**正解： 1322**

x=17 、 y=20 のときの z を予測する。

正解の計算に使う式

**z = 2x^2 + xy + y^2 + 4**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 実例 13 ：一次式の近い入力点

式の種類： linear

学習用 100 組から 4 組を抜粋

```
x, y
-82, -324
70, 284
7, 32
-2, -4
```

予測する入力

```
14
```

**正解： 60**

x=14 のときの y を予測する。

正解の計算に使う式

**y = 4x + 4**

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# standard モードの係数範囲

| 型 | 式と係数（両端を含む整数） |
|---|---|
| linear | $y=Ax+B$ ： A, B は 1 〜 5 |
| parabola | $y=Ax^2+Bx+C$ ： A は 1 〜 2 、 B は 0 〜 2 、 C は 1 〜 5 |
| plane | $z=Ax+By+C$ ： A, B, C は 1 〜 5 |
| paraboloid | $z=Ax^2+Bxy+Cy^2+F$<br>A, C は 1 〜 2 、 B は 0 〜 1 、 F は 1 〜 5 |

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# レコードには正解と参照式を保存する

- 生成した各問題には、入力の整数列と、数値の正解が含まれる。参照式と式の種類も、正解を確かめるために保存される。
- 入力は input.text 、参照は references に入る。 correct タグは数値の正解、 solution は参照式、 class は式の種類を表す。

[1] Stanford CRFM. NumeracyScenario （v0.3.0）。 https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py

# 参考文献

## Holistic Evaluation of Language Models

Percy Liang et al. (2023). Transactions on Machine Learning Research.

幅広いシナリオと指標で言語モデルを評価する枠組みと、数値関係の帰納を含む推論課題を示す。

https://arxiv.org/abs/2211.09110

## NumeracyScenario

Stanford CRFM (n.d.). NumeracyScenario v0.3.0 （2026-10-18 参照）。

多項式の係数・入力点の生成、 train ／ test の構成、参照式と正解の記録を実装する。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/numeracy_scenario.py