OCNLI

Original Chinese Natural Language Inference

原生中国語で、前提から仮説を判断する

sasakiy84

公式リポジトリ

README

OCNLI: Original Chinese Natural Language Inference

OCNLI stands for **Original** Chinese Natural Language Inference. It is corpus for Chinese Natural Language Inference, collected following closely the procedures of MNLI, but with enhanced strategies aiming for more challenging inference pairs. We want to emphasize we did not use human/machine translation in creating the dataset, and thus our Chinese texts are *original* and not translated.

OCNLI has roughly 50k pairs for training, 3k for development and 3k for test. We only release the test data but not its labels. See our paper for details.

OCNLI is part of the CLUE benchmark.

OCNLI，即原生中文自然语言推理数据集，是第一个非翻译的、使用原生汉语的大型中文自然语言推理数据集。 OCNLI包含5万余训练数据，3千验证数据及3千测试数据。除测试数据外，我们将提供数据及标签。测试数据仅提供数据。OCNLI为中文语言理解基准测评（CLUE）的一部分。更多细节请参考我们的论文。

Data format 数据格式

Our dataset is distributed in json format. Here's an example from OCNLI.dev:

[1] Hu et al. OCNLI 公式リポジトリ。固定版 b53efdee1725 、 2026-10-18 取得。 https://github.com/CLUEbenchmark/OCNLI

1. 二つの文の関係を判定する
2. 原生中国語での収集と検証
3. 2020 年の評価と残る手掛かり
4. CLEVA での採用と現在の配布

二つの文の関係を判定する

中国語で書かれた、前提と仮説のペア

- OCNLI は、中国語の文章から選んだ前提に対し、中国語の母語話者が仮説を書いた自然言語推論データセット。
- 入力は前提と仮説の順序付きペア。前提を真としたときに仮説をどう判断するかを、含意・矛盾・中立の 3 種類で答える。
- 2020 年に公開。英語の推論データを訳す方法ではなく、5 文体の中国語から集めた前提と、人が書いた仮説を使う。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

前提を真としたときの三つの関係

配布ラベル	仮説との関係
entailment	前提から仮説が成り立つ
contradiction	前提と仮説が両立しない
neutral	前提だけでは仮説の真偽が決まらない

3 種類のラベルが元の課題の出力。 OCNLI の原票には、 A/B/C の選択肢は付いていない。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

実例１：値段の発言から販売を読み取る

原文（前提・仮説とも全文）

前提：
篮子嘛 , 一块钱 , 一块钱啊 .
仮説：
这个篮子是可以卖的。

日本語訳

前提：
かごね、１元、１元だよ。
仮説：
このかごは売ることができる。

配布正解：含意（ entailment ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 1162 / id 1162 / phone
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

販売の場面を、発話から読み取る

- 値段を繰り返す発話を、かごを販売できる状況として解釈する。 CLEVA の公開論文例と同じ原票。
- 前提は短い電話会話の断片。仮説は同じ語を写すだけではなく、値段を伝える発話の意味を表現している。
- 本編 3 例と追加 10 例は、ラベル公開済みの dev から選んだ異なるペア。 5 文体、 3 ラベル、作成順の異なる仮説を含む。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/
[2] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

実例２：向かい合わせと背中合わせ

原文（前提・仮説とも全文）

前提：
咖啡馆里面对面坐的年轻男女也是上一代的故事，她已是过来人了
仮説：
男人和女人是背对背坐着的

日本語訳

前提：
喫茶店で向かい合って座る若い男女というのも、もう一世代前の話で、彼女はすでにそうした経験をしてきたのだ。
仮説：
男性と女性は背中合わせに座っている。

配布正解：矛盾（ contradiction ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 2627 / id 2627 / lit
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

配布正解は、注釈者の多数決で決まる

- 座り方が食い違う。配布正解は contradiction だが、 5 人の内訳は矛盾 3 ・中立 2 で、全員一致ではない。
- 5 人中 3 人以上が同じラベルを選んだ場合、その多数決ラベルを正解とする。
- 作成者のラベルに 4 人の独立した判断を加える。多数決が成立しない例は「 - 」として残し、通常の学習・評価から除く。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

実例３：実際の開催日と、当初の予定

原文（前提・仮説とも全文）

前提：
今天，这一受人关注的会议终于在波恩举行
仮説：
这一会议原定于昨天举行

日本語訳

前提：
今日、注目を集めていたこの会議が、ついにボンで開催された。
仮説：
この会議は当初、昨日開催される予定だった。

配布正解：中立（ neutral ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 1060 / id 1060 / news
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

中立は、前提だけで予定を確定できない

- neutral （中立）は、前提だけでは仮説が成り立つとも、成り立たないとも決められない関係。
- 今日開催されたことから、昨日が当初の予定日だったとは決まらない。予定が昨日だった可能性も、別の日だった可能性も残る。
- 「ついに」という語があっても、当初の予定日が具体的に与えられたことにはならない。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

原生中国語での収集と検証

英語から訳す代わりに、中国語で作る

- SNLI と MNLI は、前提を示して人に仮説を書かせる英語の推論コーパス。 OCNLI は MNLI の作成・再注釈の手順を中国語へ展開した。
- XNLI は英語の推論問題を多言語へ翻訳した資源。 OCNLI では、翻訳調の表現や元の文化的背景への偏りを避けるため、中国語の素材と母語話者を使う。
- 翻訳の品質と、注釈者が自然に使う語や推論の手掛かりは、それぞれ検討の対象になる。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/
[2] Conneau et al. (2018). XNLI: Evaluating Cross-lingual Sentence Representations. EMNLP. https://aclanthology.org/D18-1269/

書き言葉と話し言葉を、 5 文体から集める

文体	前提の素材
gov	中国政府の年次政府活動報告
news	LCMC （中国語コーパス）のニュース部分
lit	現代小説 2 作品
tv	対談番組「鏘鏘三人行」の書き起こし
phone	中国語 Callhome 電話会話の書き起こし

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

同じ前提から、複数の推論を引き出す

- 前提は 8 〜 50 文字の文から選ぶ。電話会話の転記記号を取り除く。素材の文を、仮説の言い換えで作り直す方式ではない。
- Single は、 1 前提につき各ラベルの仮説を 1 文ずつ作る。Multi は、各ラベルについて最大 3 文、合計最大 9 文を作る。
- Multi Encourage は多様な推論や否定語を使わない矛盾を奨励する。 Multi Constraint は、矛盾 3 文のうち否定語を含むものを 1 文までに制限する。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

easy ・ medium ・ hard は、仮説を書く順序

- easy ・ medium ・ hard は、同じ前提とラベルについて、作成者が仮説を書いた 1 番目・ 2 番目・ 3 番目を表す。
- 複数の仮説を書くことで、最初に思いつく単純な言い換え・否定以外の推論を引き出すことを狙った。すべての前提で 3 文目まで作れたわけではない。
- どの条件でも、仮説が前提と 70% を超えて重ならないよう指示した。文字の重なりだけで解ける問題を減らす意図がある。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

言語を学ぶ母語話者が書き、別の人が確かめる

- 中国語または他言語を専攻する、中国語母語話者の大学生・大学院生 145 人が仮説を作成した。作成は 1 ペア約 0.3 元、再注釈は約 0.2 元。
- 各作成条件の一部を無作為に選び、 4 人が独立にラベルを付け直す。作成時のラベルを合わせて 5 票とし、 3 票以上の一致を採用する。
- 再注釈した Multi Encourage と Multi Constraint の計 6,000 組を、 dev ・ test へ各 3,000 組ずつ割り当てた。残りと Single ・ Multi を学習集合に使う。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

公開 50k 版の行数と、有効な正解ラベル

分割	全行数	3 ラベルがある行
train.50k	50,486	50,437
dev	3,000	2,950
test	3,000	非公開

全行数は 56,486 組。 train の 49 組、 dev の 50 組は「 - 」。 test は入力のみを公開し、正解は含まない。

[1] Hu et al. OCNLI 公式リポジトリ。固定版 b53efdee1725 、 2026-10-18 取得。 https://github.com/CLUEbenchmark/OCNLI

50k 版は、前提を共有して異なる仮説を評価する

- 公開 50k 学習集合と dev では、同じ前提文が複数の分割に現れる。
- 固定公開版では、 train.50k と dev が共有する前提文は 2,184 種類。同じ前提・仮説の完全一致ペアは 0 組だった。
- 前提の重複を除く学習用の train.30k も提供される。実測 30,286 組で、 dev と同じ前提文は 0 種類。 10k ・ 3k 版も同じ dev ・ test を使う。

[1] Hu et al. OCNLI 公式リポジトリ。固定版 b53efdee1725 、 2026-10-18 取得。 https://github.com/CLUEbenchmark/OCNLI

2020 年の評価と残る手掛かり

正解率は、ラベルが一致したペアの割合

- 多数決が成立しない「 - 」を除き、配布正解と予測ラベルが一致する割合を正解率とする。
- 公開 dev なら 2,950 組で評価できる。常に neutral と答える基準は、 1,103 ÷ 2,950 = 37.39% 。公式評価関数と公開原票から再計算した。
- 2020 年のモデル成績は、学習集合で訓練・微調整したモデルを非公開ラベルの test で評価した値。 5 回の学習試行の平均と標準偏差を報告する。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/
[2] Hu et al. OCNLI 公式 baseline 評価コード、 evaluate_classifier 。 https://github.com/CLUEbenchmark/OCNLI/blob/main/ocnli/mnli_code/util/evaluate.py

2020 年： 50k 版で学習したモデルの test 正解率

方式	正解率（%）
常に neutral	38.1
CBOW ：文字表現の平均	55.7 ± 0.5
biLSTM ：双方向の系列モデル	59.2 ± 0.5
ESIM ：文どうしの相互照合	59.8 ± 0.4
BERT-base （中国語）	72.2 ± 0.7
RoBERTa-large （中国語・全単語マスク）	78.2 ± 0.7

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

人手評価は、別の 300 組を 5 人で判定した

- 収集・検証に参加していない中国語母語話者の学生 5 人へ、 20 例で練習した後、 test から無作為に選んだ 300 組を提示した。
- 5 人の多数決を配布正解と比較し、 90.3% の正解率を得た。多数決が成立しない 2 組には、 test で最多の neutral を割り当てた。
- 2020 年の RoBERTa 78.2% との差は約 12.1 ポイント。人手は 300 組、モデルは有効な test 全体という、異なる評価範囲を記した比較である。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

仮説だけでも残る、注釈の手掛かり

モデル	dev （%）	test （%）
BERT	65.3	64.3
RoBERTa	65.7	65.0

前提を同じ無意味語へ置き換えて学習・評価する hypothesis-only 条件。仮説に残った手掛かりだけで 3 ラベルを予測する。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

複数仮説と制約だけで、手掛かりは消えない

- 仮説の「任何（どんな〜も）」「从来（これまで／かつて）」は矛盾、「至少（少なくとも）」は含意と結び付きやすかった。
- Multi Constraint では、矛盾と結び付く上位の語に否定語が現れず、代わりに「只有」「只」（〜だけ）が現れた。
- 語の手掛かりを抑える収集方法と、前提・仮説の関係を測る評価の両方が研究課題になる。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

CLEVA での採用と現在の配布

CLEVA は OCNLI を、多肢選択の推論課題に採用

- 2023 年の CLEVA は、 commonsense_reasoning の textual_entailment で OCNLI から標本を選び、多肢選択形式にして正解率を測る。
- 公開論文の「篮子嘛，一块钱…」と「这个篮子是可以卖的。」は、 OCNLI dev の id1162 に全文一致し、配布ラベルも entailment だった。
- CLEVA が選んだ OCNLI の全原票・分割・テンプレート本文は、今回の取得範囲では確認できなかった。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/
[2] Stanford CRFM. HELM v0.4.0 CLEVAScenario / CLEVACommonsenseReasoningScenario. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

CLEVA の公開例：三つの選択肢へ変換

論文の原文・全選択肢

是否可以从“篮子嘛，一块钱，一块钱啊。”中推断出“这个篮子是可以卖的。”？
A. 总是可以
B. 有时可以
C. 不可以

日本語訳

「かごね、 1 元、 1 元だよ。」から「このかごは売ることができる。」と推論できるか。
A. 常にできる
B. 場合によってはできる
C. できない

公開例の正解： A （总是可以／常にできる）

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. OCNLI dev id1162 との照合。
https://aclanthology.org/2023.emnlp-demo.17/

HELM には実装と設定があり、公開実行は 0 件

- HELM Classic v0.4.0 は、 CLEVA の version ・ subtask ・ prompt_id を受け取り、 prompts.json で入力と選択肢を変換する。 textual_entailment の設定は prompt_id 0 〜 5 の 6 種類。
- 2023-11-17 の固定公開版に含まれる 8,526 実行を調べると、 CLEVA の実行は 0 件。 OCNLI の公開 HELM 成績や実要求出力は、この版からは得られない。
- 実装先の CLEVA 配布 URL は今回も取得できなかった。元 OCNLI の 50k 学習・ dev ・ test を、 CLEVA の抽出・提示例数と同一の条件には置き換えない。

[1] Stanford CRFM. HELM v0.4.0 、 CLEVA v1 の課題・ prompt_id 設定。
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf

現在の入手先と、引用文の利用条件

- 公式リポジトリは 50k ・ 30k ・ 10k ・ 3k の学習集合と、共通の dev ・ラベル非公開 test を公開する。 CLUE の公開 ZIP は 50k ・ dev ・ test を収録する。
- OCNLI は CC BY-NC 2.0 を掲示する。帰属を示し、非商用の条件を守る。 news の前提は LCMC から ELRA の許可を得て採用したと記される。
- 前提には政府報告、ニュース、小説、番組・電話会話が含まれる。原資料の出所と、データセットの作成者・ライセンスを区別して利用する。

[1] Hu et al. OCNLI 公式リポジトリ。固定版 b53efdee1725 、 2026-10-18 取得。 https://github.com/CLUEbenchmark/OCNLI

中国語の推論を、作成法と分割を含めて捉える

- OCNLI は、原生中国語の 5 文体の前提と、人が書いた仮説を含意・矛盾・中立で結ぶ。複数仮説と否定語への制約で、多様な推論を引き出した。
- 公開版は 56,486 組で、学習・開発には多数決不成立の例が残る。 50k 版の前提共有と、 30k 版の前提非共有は、評価条件の違いになる。
- 2020 年の教師あり評価、仮説のみの分析、 CLEVA の多肢選択化は、それぞれ入力・分母・学習の仕方を確認して解釈する。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

Appendix

1. 文体と推論の追加例
2. 分割・注釈・実装の補足
3. 研究と参考文献

文体と推論の追加例

実例 4 ：衣服の記述と「少なくとも」

原文（前提・仮説とも全文）

前提：
身上裹一件工厂发的棉大衣 , 手插在袖筒里
仮説：
身上至少一件衣服

日本語訳

前提：
工場から支給された綿入りの外套を身にまとい、両手を袖の中へ差し入れている。
仮説：
少なくとも 1 着の服を身につけている。

配布正解：含意（ entailment ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 0 / id 0 / lit
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

実例 5 ：帰宅を待って外食へ行く

原文（前提・仮説とも全文）

前提：
等他回来 , 我们就出去吃啊 .
仮説：
我们在等他

日本語訳

前提：
彼が帰ってきたら、私たちは外へ食べに行くんだよ。
仮説：
私たちは彼を待っている。

配布正解：含意（ entailment ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 4 / id 4 / phone
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

実例 6 ：植林の量と、質を確保する義務

原文（前提・仮説とも全文）

前提：
要狠抓造林质量不放松
仮説：
种的树越多越好，至于成活率和质量并不需要考虑

日本語訳

前提：
植林の質の確保に、手を緩めず取り組まなければならない。
仮説：
植える木は多ければ多いほどよく、活着率や質を考慮する必要はない。

配布正解：矛盾（ contradiction ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 12 / id 12 / news
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

実例 7 ：二つの謎の比較

原文（前提・仮説とも全文）

前提：
他们的生活起居是一个谜，他们的生平遭际更是一个谜
仮説：
他们的生平遭际比生活起居还难知道

日本語訳

前提：
彼らの日々の暮らしぶりは謎だが、これまでの人生で経験してきたことは、それ以上に謎だ。
仮説：
彼らのこれまでの人生での経験は、日々の暮らしぶりよりも、いっそう分かりにくい。

配布正解：含意（ entailment ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 15 / id 15 / lit
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

実例 8 ：社会との接触と時代の変化

原文（前提・仮説とも全文）

前提：
我现在觉得 , 有些事你要是老不出去接触社会 , 山中方七日 , 世上已千年
仮説：
要出去多接触社会 , 才能跟上时代。

日本語訳

前提：
今は思うんだ。社会に触れに出かけないでいると、山の中ではたった 7 日でも、世間ではもう千年が過ぎている、ということがある。
仮説：
社会にもっと出て触れなければ、時代についていけない。

配布正解：含意（ entailment ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 26 / id 26 / tv
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

実例９：番組への再登場と初出演

原文（前提・仮説とも全文）

前提：
因为咱们请来了一个真正的专家，李玫瑾老师，每次观众都知道李老师一来，大的案件就发生了
仮説：
李玫瑾老师第一次参加这个节目。

日本語訳

前提：
本当の専門家である李玫瑾先生をお招きしたからだ。視聴者はいつも、李先生が来ると大きな事件が起きたのだと分かる。
仮説：
李玫瑾先生はこの番組に初めて出演する。

配布正解：矛盾（ contradiction ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 35 / id 35 / tv
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

実例 10 ：畏れと、怖さの言い換え

原文（前提・仮説とも全文）

前提：
心里有些生畏，又不知畏惧什么
仮説：
有点感到害怕

日本語訳

前提：
心の中で少し畏れを感じるが、何を畏れているのかは分からない。
仮説：
少し怖いと感じている。

配布正解：含意（ entailment ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 36 / id 36 / lit
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

実例 11 ：政策の改善と、優先順位

原文（前提・仮説とも全文）

前提：
完善加工贸易政策体系
仮説：
完善加工贸易政策体系是当下最重要的任务

日本語訳

前提：
加工貿易の政策体系を改善する。
仮説：
加工貿易の政策体系を改善することは、今、最も重要な任務である。

配布正解：中立（ neutral ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 937 / id 937 / gov
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

実例 12 ：曜日の発言と持ち物

原文（前提・仮説とも全文）

前提：
嗯 , 今天星期六我们这儿 , 嗯哼 .
仮説：
说话人有一本日历

日本語訳

前提：
うん、今日はこちらでは土曜日なんだ、うん。
仮説：
話し手はカレンダーを 1 冊持っている。

配布正解：中立（ neutral ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 227 / id 227 / phone
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

実例 13 ：国有資産の管理と資産評価

原文（前提・仮説とも全文）

前提：
要切实加强国有资产管理，做好清产核资工作，保证国有资产保值增值
仮説：
清产核资工作做不好，国有资产增值保值也可以实现。

日本語訳

前提：
国有資産の管理を確実に強化し、資産の調査・評価を適切に行い、国有資産の価値の維持と増大を保証しなければならない。
仮説：
資産の調査・評価を適切に行わなくても、国有資産の価値の維持と増大は実現できる。

配布正解：矛盾（ contradiction ）

[1] Hu et al. OCNLI 公開 dev 、 CC BY-NC 2.0 。前提の出所は各文体資料。 dev row 34 / id 34 / gov
https://github.com/CLUEbenchmark/OCNLI/blob/main/data/ocnli/dev.json

分割・注釈・実装の補足

四つの学習用配布：行数と有効ラベル

配布名	全行数	有効ラベル
train.50k	50,486	50,437
train.30k	30,286	30,237
train.10k	10,000	9,985
train.3k	3,000	2,994

30k ・ 10k ・ 3k は 50k の部分集合。各配布名の k は概数で、有効ラベルの件数とは分けて数えた。

[1] Hu et al. OCNLI 公式リポジトリ。固定版 b53efdee1725 、 2026-10-18 取得。 https://github.com/CLUEbenchmark/OCNLI

公開 50k と dev の、文体別ペア数

文体	train.50k	dev
gov	10,402	622
news	10,680	662
lit	10,606	609
tv	9,803	615
phone	8,992	492
genre 欠測	3	0

[1] Hu et al. OCNLI 公式リポジトリ。固定版 b53efdee1725 、 2026-10-18 取得。 https://github.com/CLUEbenchmark/OCNLI

dev のラベルを、全行で数える

配布ラベル	件数	3 ラベル中の割合
entailment	947	32.10%
neutral	1,103	37.39%
contradiction	900	30.51%
-	50	分母から除く

5 票のうち既定の 3 ラベルの票を照合。 dev id2092 には unrelated の票が 3 つあり、配布正解は「 - 」のまま保持した。

[1] Hu et al. OCNLI 公式リポジトリ。固定版 b53efdee1725 、 2026-10-18 取得。 https://github.com/CLUEbenchmark/OCNLI

作成条件の内訳と、公開分割の総数に差がある

- 論文の 4 作成条件の件数は 11,986 、 12,328 、 16,584 、 15,627 で、合計 56,525 。表示された総数 56,486 および公開 3 分割の合計との差は 39 組ある。
- 今回の全件集計は、公式公開版の 50,486 + 3,000 + 3,000 = 56,486 組を分母とした。表の内訳を推測で補正しない。
- 公開 30k と dev は同じ前提文 0 種類だが、 prem_id は 2 種類共通する。識別子が同じでも文が異なる例があり、前提文そのものでも照合した。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/
[2] Hu et al. OCNLI 公式リポジトリ。固定版 b53efdee1725 、 2026-10-18 取得。 https://github.com/CLUEbenchmark/OCNLI

公開 dev で、常に中立と答える基準を再計算

```
import json
from pathlib import Path
rows = [json.loads(s) for s in
        Path('dev.json').read_text().splitlines()]
valid = [r for r in rows if r['label'] != '-']
correct = sum(r['label'] == 'neutral' for r in valid)
print(correct, len(valid), correct / len(valid))
# 1103 2950 0.3738983050847457 5
```

正解率の定義と照合する短い再現コード。公式評価関数にも同じ固定予測を渡し、一致を確認した。

[1] Hu et al. OCNLI 公式 baseline 評価コード、 evaluate_classifier 。 https://github.com/CLUEbenchmark/OCNLI/blob/main/ocnli/mnli_code/util/evaluate.py

CLEVA のテンプレート設定と、確認できた範囲

- 公開設定は commonsense_reasoning / textual_entailment / v1 で、 prompt_id 0 〜 5 。設定数は 6 で、 6 個の元コーパスを意味しない。
- HELM の Converter は、 choices の各項目を Reference へ変換し、正解 index の項目へ correct を付ける。元 OCNLI のラベル文字列と、そのまま同じ表現ではない。
- 公開論文例は A/B/C 形式。コードの説明例は別の文で、正解 C 。完全なテンプレート本文と採用原票を取得できていないため、一律の選択肢順や全件数を断定しない。

[1] Stanford CRFM. HELM v0.4.0 、 CLEVA v1 の課題・ prompt_id 設定。
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/presentation/run_specs_cleva_v1.conf

研究と参考文献

言語・論理・評価を結び付けた共同研究

- Hai Hu 、 Kyle Richardson 、 Liang Xu 、 Lu Li 、 Sandra Kübler 、 Lawrence S. Moss による、 Indiana University ・ Allen Institute for AI ・ CLUE の共同研究。
- Findings of EMNLP 2020 で発表された。翻訳へ依存せず、母語話者の推論と再注釈を中国語の基準として整備した。
- 教師ありモデルの成績だけでなく、仮説のみの語彙的な手掛かりや、翻訳学習データからの転移を分析した。

[1] Hu et al. (2020). OCNLI: Original Chinese Natural Language Inference. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.314/

参考文献

OCNLI: Original Chinese Natural Language Inference

Hai Hu, Kyle Richardson, Liang Xu, Lu Li, Sandra Kübler, Lawrence S. Moss · 2020 · Findings of EMNLP, pp.3512–3526

原生中国語の前提と仮説を収集し、多数決による検証、モデル成績、注釈の手掛かりを分析する。

https://aclanthology.org/2020.findings-emnlp.314/

OCNLI — Original Chinese Natural Language Inference

CLUEbenchmark / Hu et al.· 公式リポジトリ · 固定版 b53efdee1725

学習用 4 規模、共通 dev ・入力のみの test 、形式・ baseline ・ CC BY-NC 2.0 の条件を公開する。

https://github.com/CLUEbenchmark/OCNLI

参考文献

A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference

Adina Williams, Nikita Nangia, Samuel R. Bowman · 2018 · NAACL-HLT, pp.1112–1122

複数文体の英語を前提に、仮説の作成と再注釈で構築した MultiNLI を報告する。

https://aclanthology.org/N18-1101/

XNLI: Evaluating Cross-lingual Sentence Representations

Alexis Conneau, Ruty Rinott, Guillaume Lample, Adina Williams, Samuel R. Bowman, Holger Schwenk, Veselin Stoyanov · 2018 · EMNLP, pp.2475–2485

英語の推論問題を 15 言語へ展開し、言語をまたぐ文表現の評価に用いる。

https://aclanthology.org/D18-1269/

参考文献

CLEVA: Chinese Language Models EVAluation Platform

Yanyang Li, Jianqiao Zhao, Duo Zheng, Zi-Yuan Hu, Zhi Chen, Xiaohui Su, Yongfeng Huang, Shijia Huang, Dahua Lin, Michael R. Lyu, Liwei Wang · 2023 · EMNLP System Demonstrations, pp.186–217

中国語モデルの 31 課題を統一評価し、 OCNLI 由来の自然言語推論を多肢選択として採用する。

https://aclanthology.org/2023.emnlp-demo.17/

CLEVA Scenarios — HELM v0.4.0

Stanford CRFM · 2023-11-17 固定公開版

CLEVA のデータとテンプレートを読み、入力・選択肢・正解を HELM の Instance へ変換する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py