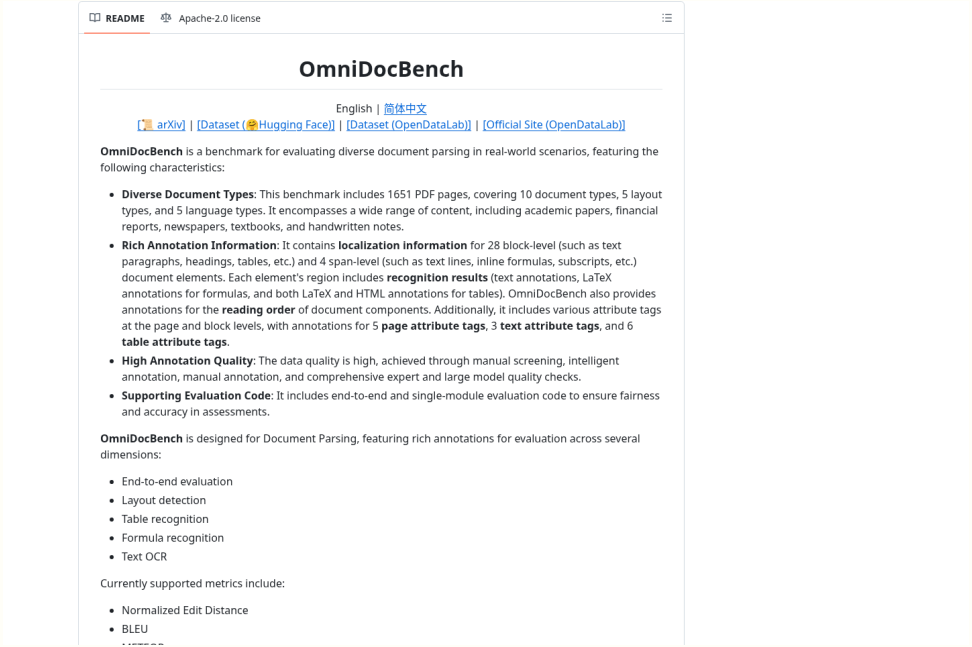
OmniDocBench

PDF のページから本文・表・数式を取り出す
文書解析の正解注釈と評価方法を読む

sasakiy84

OmniDocBench の公式リポジトリ



README Apache-2.0 license

OmniDocBench

English | 简体中文

[arXiv] | [Dataset (Hugging Face)] | [Dataset (OpenDataLab)] | [Official Site (OpenDataLab)]

OmniDocBench is a benchmark for evaluating diverse document parsing in real-world scenarios, featuring the following characteristics:

- **Diverse Document Types**: This benchmark includes 1651 PDF pages, covering 10 document types, 5 layout types, and 5 language types. It encompasses a wide range of content, including academic papers, financial reports, newspapers, textbooks, and handwritten notes.
- **Rich Annotation Information**: It contains **localization information** for 28 block-level (such as text paragraphs, headings, tables, etc.) and 4 span-level (such as text lines, inline formulas, subscripts, etc.) document elements. Each element's region includes **recognition results** (text annotations, LaTeX annotations for formulas, and both LaTeX and HTML annotations for tables). OmniDocBench also provides annotations for the **reading order** of document components. Additionally, it includes various attribute tags at the page and block levels, with annotations for 5 **page attribute tags**, 3 **text attribute tags**, and 6 **table attribute tags**.
- **High Annotation Quality**: The data quality is high, achieved through manual screening, intelligent annotation, manual annotation, and comprehensive expert and large model quality checks.
- **Supporting Evaluation Code**: It includes end-to-end and single-module evaluation code to ensure fairness and accuracy in assessments.

OmniDocBench is designed for Document Parsing, featuring rich annotations for evaluation across several dimensions:

- End-to-end evaluation
- Layout detection
- Table recognition
- Formula recognition
- Text OCR

Currently supported metrics include:

- Normalized Edit Distance
- BLEU

https://github.com/opendatalab/OmniDocBench#readme

1. ページから本文・表・数式を取り出す

2. 採点とモデルの到達水準

3. 作成工程とバージョンの更新

4. 配布形式と利用方法

1. ページから本文・表・数式を取り出す

文書の見た目から、読みやすい構造を復元する

- OmniDocBench は、 PDF のページ画像から、本文、表、数式などを取り出す文書解析の評価データ。 2024 年に公開され、 CVPR 2025 で発表された。
- 文字を認識するだけでなく、どの部分が見出しや本文か、表のセルがどう並ぶか、どの順序で読むかを扱う。
- 正解は、領域の位置、種類、読む順番と内容。ページ全体を Markdown へ変換するモデルや、要素ごとの認識を評価できる。

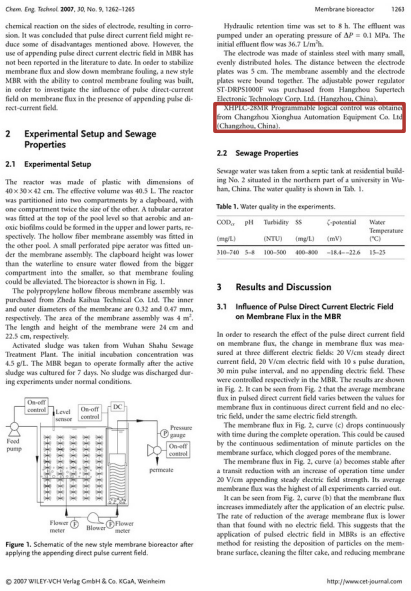
Ouyang et al. (2025). OmniDocBench: Benchmarking Diverse PDF Document Parsing with Comprehensive Annotations. CVPR.
https://arxiv.org/abs/2412.07626

入力はページ画像、出力は Markdown

- 公式の汎用モデル向け実装は、ページ画像と変換の指示を渡し、見出し・段落・リストを保った Markdown を出力させる。
- 本文は文字列、数式は LaTeX 、表は HTML で表す。画像の内容は記述せず、本文や表などの読み取りに集中する。
- 以下は公式配布から選んだ 3 ページ。赤枠の領域と、その正解注釈を続けて示す。 Appendix には別の 10 ページを載せる。

OpenDataLab. OmniDocBench: GPT-5.2 PDF image → Markdown inference script.
https://github.com/opendatalab/OmniDocBench/blob/main/tools/model_infer/gpt_5.2_img2md.py

実例１：２段組みの学術論文



Chem. Eng. Technol. 2007, 30, No. 9, 1262–1265 Membrane bioreactor 1263

chemical reaction on the sides of electrode, resulting in corrosion. It was concluded that pulse direct current field might reduce some of disadvantages mentioned above. However, the use of appending pulse direct current electric field in MBR has not been reported in the literature to date. In order to stabilize membrane flux and slow down membrane fouling, a new style MBR with the ability to control membrane fouling was built, in order to investigate the influence of pulse direct-current field on membrane flux in the presence of appending pulse direct-current field.

2 Experimental Setup and Sewage Properties

2.1 Experimental Setup

The reactor was made of plastic with dimensions of 40 × 30 × 42 cm. The effective volume was 40.5 L. The reactor was partitioned into two compartments by a clapboard, with one compartment twice the size of the other. A tubular aerator was fitted at the top of the pool level so that aerobic and anoxic biofilms could be formed in the upper and lower parts, respectively. The hollow fiber membrane assembly was fitted in the other pool. A small perforated pipe aerator was fitted under the membrane assembly. The clapboard height was lower than the waterline to ensure water flowed from the bigger compartment into the smaller, so that membrane fouling could be alleviated. The bioreactor is shown in Fig. 1.

The polypropylene hollow fibrous membrane assembly was purchased from Zhuda Kaihua Technical Co. Ltd. The inner and outer diameters of the membrane are 0.32 and 0.47 mm, respectively. The area of the membrane assembly was 4 m^2. The length and height of the membrane were 24 cm and 22.5 cm, respectively.

Activated sludge was taken from Wuhan Shahu Sewage Treatment Plant. The initial incubation concentration was 4.5 g/L. The MBR began to operate formally after the active sludge was cultured for 7 days. No sludge was discharged during experiments under normal conditions.

Figure 1. Schematic of the new style membrane bioreactor after applying the appending direct pulse current field.

Hydraulic retention time was set to 8 h. The effluent was pumped under an operating pressure of $\Delta P = 0.1$ MPa. The initial effluent flow was 36.7 L/m^{2}h.

The electrode was made of stainless steel with many small, evenly distributed holes. The distance between the electrode plates was 5 cm. The membrane assembly and the electrode plates were bound together. The adjustable power regulator ST-DRPS1000F was purchased from Hangzhou Supertech Electronic Technology Corp. Ltd. (Hangzhou, China). XHPLC-28MR Programmable logical control was obtained from Changzhou Xionghua Automation Equipment Co. Ltd. (Changzhou, China).

2.2 Sewage Properties

Sewage water was taken from a septic tank at residential building No. 2 situated in the northern part of a university in Wuhan, China. The water quality is shown in Tab. 1.

Table 1. Water quality in the experiments.

COD_{Cr} (mg/L)	pH	Turbidity (NTU)	SS (mg/L)	ζ-potential (mV)	Water Temperature (°C)
310–740	5–8	100–500	400–800	−18.4–−22.6	15–25

3 Results and Discussion

3.1 Influence of Pulse Direct Current Electric Field on Membrane Flux in the MBR

In order to research the effect of the pulse direct current field on membrane flux, the change in membrane flux was measured at three different electric fields: 20 V/cm steady direct current field, 20 V/cm electric field with 10 s pulse duration, 30 min pulse interval, and no appending electric field. These were controlled respectively in the MBR. The results are shown in Fig. 2. It can be seen from Fig. 2 that the average membrane flux in pulsed direct current field varies between the values for membrane flux in continuous direct current field and no electric field, under the same electric field strength.

The membrane flux in Fig. 2, curve (c) drops continuously with time during the complete operation. This could be caused by the continuous sedimentation of minute particles on the membrane surface, which clogged pores of the membrane.

The membrane flux in Fig. 2, curve (a) becomes stable after a transit reduction with an increase of operation time under 20 V/cm appending steady electric field strength. Its average membrane flux was the highest of all experiments carried out.

It can be seen from Fig. 2, curve (b) that the membrane flux increases immediately after the application of an electric pulse. The rate of reduction of the average membrane flux is lower than that found with no electric field. This suggests that the application of pulsed electric field in MBRs is an effective method for resisting the deposition of particles on the membrane surface, cleaning the filter cake, and reducing membrane

© 2007 WILEY-VCH Verlag GmbH & Co. KGaA, Weinheim

英語の学術論文

赤枠：本文の一領域

段組みの中の一段落を取り出す。改行位置が変わっても、語と順序を保つ。

OpenDataLab. OmniDocBench / JSON 行 433 （0 始まり） / 注釈 22 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

実例 1 ：領域の正解注釈

配布の正解注釈（選択した領域の全文）

> XHPLC-28MR Programmable logical control was obtained from Changzhou Xionghua Automation Equipment Co. Ltd. (Changzhou, China).

内容の要約： XHPLC-28MR という制御装置の入手先を述べた文。

OpenDataLab. OmniDocBench / JSON 行 433 （0 始まり） / 注釈 22 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

実例２：講義スライドの表

Copyright © The McGraw-Hill Companies, Inc. Permission required for reproduction or display.

Example: Symbol Table

Name	Type	Offset	Scope
inGlobal	int	0	global
inLocal	int	0	main
outLocalA	int	-1	main
outLocalB	int	-2	main

12-28

英語の講義スライド

赤枠：表の全領域

行と列を保ち、変数名、型、オフセット、スコープを表のセルへ対応させる。

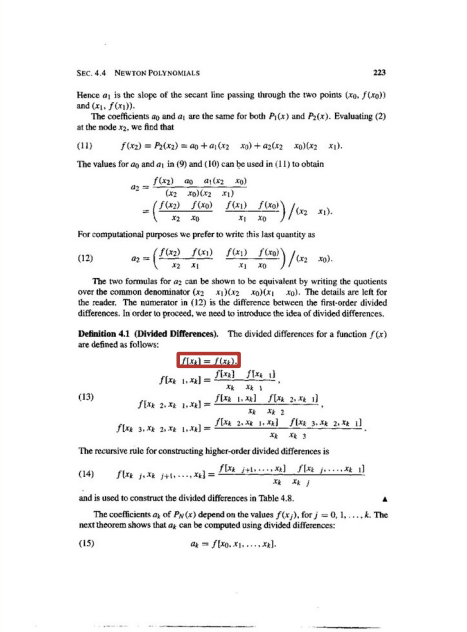
OpenDataLab. OmniDocBench / JSON 行 300 （0 始まり） / 注釈 1 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

実例２：表の正解をセルの対応で読む

Name	Type	Offset	Scope
inGlobal	int	0	global
inLocal	int	0	main
outLocalA	int	-1	main
outLocalB	int	-2	main

OpenDataLab. OmniDocBench / JSON 行 300 （0 始まり） / 注釈 1 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

実例３：数値計算の独立数式



SEC. 4.4 NEWTON POLYNOMIALS 223

Hence a_1 is the slope of the secant line passing through the two points $(x_0, f(x_0))$ and $(x_1, f(x_1))$.

The coefficients a_0 and a_1 are the same for both $P_1(x)$ and $P_2(x)$. Evaluating (2) at the node x_2, we find that

$$f(x_2) = P_2(x_2) = a_0 + a_1(x_2 - x_0) + a_2(x_2 - x_0)(x_2 - x_1). \tag{11}$$

The values for a_0 and a_1 in (9) and (10) can be used in (11) to obtain

$$a_2 = \frac{f(x_2) - a_0 - a_1(x_2 - x_0)}{(x_2 - x_0)(x_2 - x_1)} = \left(\frac{f(x_2) - f(x_0)}{x_2 - x_0} - \frac{f(x_1) - f(x_0)}{x_1 - x_0} \right) \Big/ (x_2 - x_1).$$

For computational purposes we prefer to write this last quantity as

$$a_2 = \left(\frac{f(x_2) - f(x_1)}{x_2 - x_1} - \frac{f(x_1) - f(x_0)}{x_1 - x_0} \right) \Big/ (x_2 - x_0). \tag{12}$$

The two formulas for a_2 can be shown to be equivalent by writing the quotients over the common denominator $(x_2 - x_1)(x_2 - x_0)(x_1 - x_0)$. The details are left for the reader. The numerator in (12) is the difference between the first-order divided differences. In order to proceed, we need to introduce the idea of divided differences.

Definition 4.1 (Divided Differences). The divided differences for a function $f(x)$ are defined as follows:

$$f[x_k] = f(x_k),$$

$$f[x_{k-1}, x_k] = \frac{f[x_k] - f[x_{k-1}]}{x_k - x_{k-1}},$$

$$f[x_{k-2}, x_{k-1}, x_k] = \frac{f[x_{k-1}, x_k] - f[x_{k-2}, x_{k-1}]}{x_k - x_{k-2}}, \tag{13}$$

$$f[x_{k-3}, x_{k-2}, x_{k-1}, x_k] = \frac{f[x_{k-2}, x_{k-1}, x_k] - f[x_{k-3}, x_{k-2}, x_{k-1}]}{x_k - x_{k-3}}.$$

The recursive rule for constructing higher-order divided differences is

$$f[x_{k-j}, x_{k-j+1}, \ldots, x_k] = \frac{f[x_{k-j+1}, \ldots, x_k] - f[x_{k-j}, \ldots, x_{k-1}]}{x_k - x_{k-j}} \tag{14}$$

and is used to construct the divided differences in Table 4.8. ▲

The coefficients a_i of $P_N(x)$ depend on the values $f(x_j)$, for $j = 0, 1, \ldots, k$. The next theorem shows that a_k can be computed using divided differences:

$$a_k = f[x_0, x_1, \ldots, x_k]. \tag{15}$$

英語の書籍

赤枠：独立した数式

角括弧、丸括弧、下付きの k を LaTeX で表す。本文中の式から独立数式の領域を分ける。

OpenDataLab. OmniDocBench / JSON 行 8 （0 始まり） / 注釈 box_id_9 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

実例 3 ：領域の正解注釈

配布の正解注釈（選択した領域の全文）

```
$$f[x_k] = f(x_k),$$
```

LaTeX 注釈： f[x_k] = f(x_k) 。角括弧と丸括弧の違いを残す。

OpenDataLab. OmniDocBench / JSON 行 8 （ 0 始まり） / 注釈 box_id_9 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

2. 採点とモデルの到達水準

ページの出力と正解の領域を対応させる

- モデルが出した Markdown を、本文・数式・表などへ分ける。正解の各領域に、対応する予測を割り当てて採点する。
- 同じ段落でも、モデルによって一つにまとめたり、複数へ分けたりする。現在の照合は、正解を固定し、予測側の分割の細かさを調整する。
- 本文、数式、表をそれぞれ採点し、総合点を作る。読む順番の編集距離は、別の指標として報告する。

OpenDataLab (2026 年 10 月参照). OmniDocBench: 更新履歴・評価実装・公式比較。
https://github.com/opendatalab/OmniDocBench

本文：編集距離が小さいほどよい

- 編集距離（ ED ）は、正解の文字列へ直すために必要な、文字の挿入・削除・置換の回数。文字列の長さで正規化して比較する。
- 説明用の例では、正解 abc に対する予測 adc は 1 文字の置換。最大長 3 で割ると、正規化した編集距離は 1/3 になる。
- 総合点に反映する際は、 (1 − 編集距離) × 100 に換算する。この例の本文の得点は約 66.7 点となる。

OpenDataLab (2026 年 10 月参照). OmniDocBench: 更新履歴・評価実装・公式比較。
https://github.com/opendatalab/OmniDocBench

表：セルの構造と中身を比べる

- TEDS は、表を HTML の木構造へ変換し、予測を正解へ直す編集の量から類似度を求める。値が大きいほどよい。
- 行、セル、結合セルの構造と、セル内の文字を比べる。先ほどの表では、 outLocalA と− 1 が同じ行の対応するセルへ入る必要がある。
- TEDS-S は、セル内の文字を除き、表の構造を比べる指標。文字認識の誤りと、表の組み立ての誤りを分けて見られる。

OpenDataLab (2026 年 10 月参照). OmniDocBench: 更新履歴・評価実装・公式比較。
https://github.com/opendatalab/OmniDocBench

数式： LaTeX を描画し、文字と位置を照合する

- CDM は Character Detection Matching 。予測と正解の LaTeX を画像へ描画し、数式内の文字とその位置を対応させる。
- 同じ数式でも LaTeX の書き方は複数ある。描画結果を使い、どの文字がどの位置に現れるかを比べる。
- 実例 3 では、 f 、 x 、 k 、括弧、等号の認識と配置が対象になる。下付き k を通常の大きさで並べる出力も、位置の違いとして扱える。

OpenDataLab. Image Over Text: Transforming Formula Recognition Evaluation with Character Detection Matching.
https://github.com/opendatalab/OmniDocBench/tree/main/metrics/cdm

総合点は、本文・表・数式の 3 成分の平均

- Overall = ((1 − 本文の編集距離) × 100 + 表の TEDS + 数式の CDM) / 3 。各成分を 0 〜 100 の尺度でそろえる。
- 説明用に、本文 90 点、表 80 点、数式 100 点なら、総合点は (90 + 80 + 100) / 3 = 90 点となる。
- 次ページの表は、公式比較の v1.6_full 、全 1,651 ページの評価。 2026 年 10 月参照の同じ公開表から、汎用モデルと文書専用モデルを選んだ。

OpenDataLab (2026 年 10 月参照). OmniDocBench: 更新履歴・評価実装・公式比較。
https://github.com/opendatalab/OmniDocBench

公式評価：汎用モデルと文書専用モデル

モデル	種類	Overall ↑
TeleOCR	文書専用	96.91
Gemini 3 Pro	汎用	92.91
Gemini 3 Flash	汎用	92.62
GPT-5.2	汎用	86.59

OpenDataLab (2026 年 10 月参照). OmniDocBench: 更新履歴・評価実装・公式比較。
https://github.com/opendatalab/OmniDocBench

3 成分を分けると、残る誤りが見える

モデル	本文 ED ↓	数式 CDM ↑	表 TEDS ↑
TeleOCR	0.0267	96.5895	96.8183
Gemini 3 Pro	0.064	95.99	89.15
Gemini 3 Flash	0.066	95.16	89.29
GPT-5.2	0.114	88.21	82.95

OpenDataLab (2026 年 10 月参照). OmniDocBench: 更新履歴・評価実装・公式比較。
https://github.com/opendatalab/OmniDocBench

3. 作成工程とバージョンの更新

多様な PDF を集め、自動注釈を人手で直す

- 初期制作では、 Common Crawl 、検索サービス、内部データから 20 万件超の PDF を収集。見た目の特徴をクラスタリングし、6,000 ページを候補に選んだ。
- 作業者が文書の種類、レイアウト、言語などを確認し、構成を調整して 981 ページを採用。本文・表・数式などの領域と内容を注釈した。
- レイアウトは LayoutLMv3 、文字は PaddleOCR 、数式は UniMERNet 、表は GPT-4o で事前注釈し、人手の修正と研究者による確認を行った。

Ouyang et al. (2025). OmniDocBench: Benchmarking Diverse PDF Document Parsing with Comprehensive Annotations. CVPR.
https://arxiv.org/abs/2412.07626

バージョンごとにページと注釈を更新

バージョン	ページ数	主なデータの更新
1.0 （2024）	981	9 種類の文書で初期公開
1.5 （2025）	1,355	374 ページ追加・画像と注釈を改善
1.6 （2026）	1,651	高難度 296 ページを追加・注釈修正

OpenDataLab (2026 年 10 月参照). OmniDocBench: 更新履歴・評価実装・公式比較。
https://github.com/opendatalab/OmniDocBench

現在のデータと評価ツールの更新点

- 1.6 で加わった 296 ページは、複雑な表、密な数式、特殊なレイアウトを含む。全体は 1,355 + 296 = 1,651 ページになった。
- 評価ツール側でも、本文と数式の対応付けや予測の分割単位の調整方法を改善。 1.5 以降の総合点は、本文・表・数式の 3 成分を平均して算出する。
- 2026 年 4 月の v1.7 更新では、評価実行用のスキルなどを追加。公式比較表の対象名は現在も v1.6_full と表記されている。

OpenDataLab (2026 年 10 月参照). OmniDocBench: 更新履歴・評価実装・公式比較。
https://github.com/opendatalab/OmniDocBench

現在の 1,651 ページ：英語と中国語が中心

ページの言語ラベル	ページ数
簡体字中国語	765
英語	755
英語・中国語の混在	116
繁体字中国語	13
その他	2

OpenDataLab (2026 年 10 月取得). OmniDocBench: OmniDocBench.json / 全 1,651 ページを集計。
https://huggingface.co/datasets/opendatalab/OmniDocBench

4. 配布形式と利用方法

ページ画像と JSON から、入力と正解を読む

- Hugging Face の images にページ画像、 OmniDocBench.json に領域の注釈とページ属性がある。配布カードは研究目的・非商用の利用を指定する。
- page_info は画像名、寸法、文書種別、言語など。 layout_dets には領域の種類、座標、順番と本文・ LaTeX ・ HTML が入る。
- 公式コードは Apache 2.0 。画像ごとの Markdown を用意し、照合方法・指標を指定して評価する。数式 CDM には描画用の実行環境も用意する。

OpenDataLab (2026 年 10 月参照). OmniDocBench: 公式配布・データカード。
https://huggingface.co/datasets/opendatalab/OmniDocBench

ページ全体を、構造のあるテキストへ戻せるか

- OmniDocBench は、文字の認識、表や数式の復元、読む順番を、同じページの注釈へ結び付けた文書解析の評価ベンチマークである。
- 現在の全 1,651 ページには、書籍、論文、スライド、新聞、手書きノートなどが含まれ、難しい表・数式・配置も追加されている。
- 公式比較には Gemini 3 Pro や GPT-5.2 が含まれ、文書専用モデルも高い得点を示す。総合点と 3 成分から、どの要素に課題が残っているかを読み取れる。

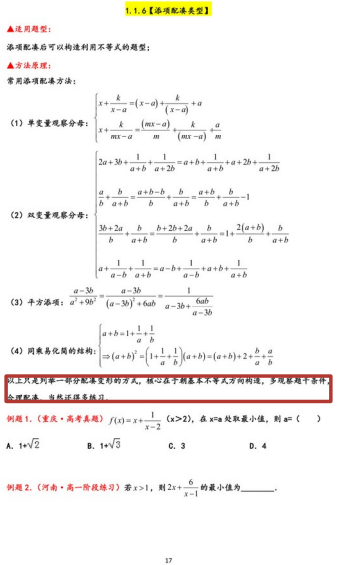
OpenDataLab (2026 年 10 月参照). OmniDocBench: 更新履歴・評価実装・公式比較。
https://github.com/opendatalab/OmniDocBench

Appendix

1. 文書の異なる追加 10 例
2. データ構成と注釈の詳細
3. 制作機関と参考文献

1. 文書の異なる追加 10 例

追加例 1 ：色付き教材の本文



1.1.6【添项配凑类型】

▲适用题型：

添项配凑后可以构造利用不等式的题型：

▲方法原理：

常用添项配凑方法：

（1）单变量观察分母：

$$\begin{cases} x+\dfrac{k}{x-a}=(x-a)+\dfrac{k}{(x-a)}+a \\ x+\dfrac{k}{mx-a}=\dfrac{(mx-a)}{m}+\dfrac{k}{(mx-a)}+\dfrac{a}{m} \end{cases}$$

（2）双变量观察分母：

$$\begin{cases} 2a+3b+\dfrac{1}{a+b}+\dfrac{1}{a+2b}=a+b+\dfrac{1}{a+b}+a+2b+\dfrac{1}{a+2b} \\ \dfrac{a}{b}+\dfrac{b}{a+b}=\dfrac{a+b-b}{b}+\dfrac{b}{a+b}=\dfrac{a+b}{b}+\dfrac{b}{a+b}=1 \\ \dfrac{3b+2a}{b}+\dfrac{b}{a+b}=\dfrac{b+2b+2a}{b}+\dfrac{b}{a+b}=1+\dfrac{2(a+b)}{b}+\dfrac{b}{a+b} \\ a+\dfrac{1}{a-b}+\dfrac{1}{a+b}=a-b+\dfrac{1}{a-b}+a+b+\dfrac{1}{a+b} \end{cases}$$

（3）平方添项：$\dfrac{a-3b}{a^2+9b^2}=\dfrac{a-3b}{(a-3b)^2+6ab}=\dfrac{1}{a-3b+\dfrac{6ab}{a-3b}}$

（4）同乘易化简的结构：

$$\begin{cases} a+b=1+\dfrac{1}{a}+\dfrac{1}{b} \\ \Rightarrow (a+b)^2=\left(1+\dfrac{1}{a}+\dfrac{1}{b}\right)(a+b)=(a+b)+2+\dfrac{b}{a}+\dfrac{a}{b} \end{cases}$$

以上只是列举一部分配凑变形的方式，核心在于利基本不等式方向构造，多观察题干条件，合理配凑，当然还很多练习。

例题 1.（重庆·高考真题）$f(x)=x+\dfrac{1}{x-2}$（x>2），在 x=a 处取最小值，则 a=（　）

A. $1+\sqrt{2}$　　B. $1+\sqrt{3}$　　C. 3　　D. 4

例题 2.（河南·高一阶段练习）若 $x>1$，则 $2x+\dfrac{6}{x-1}$ 的最小值为_____.

17

中国語のカラー教材

赤枠：本文の一領域

色付きの見出しや数式群から、下側の説明文を取り出す。

OpenDataLab. OmniDocBench / JSON 行 23 （0 始まり） / 注釈 box-6s09k9l9 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 1 ：領域の正解注釈

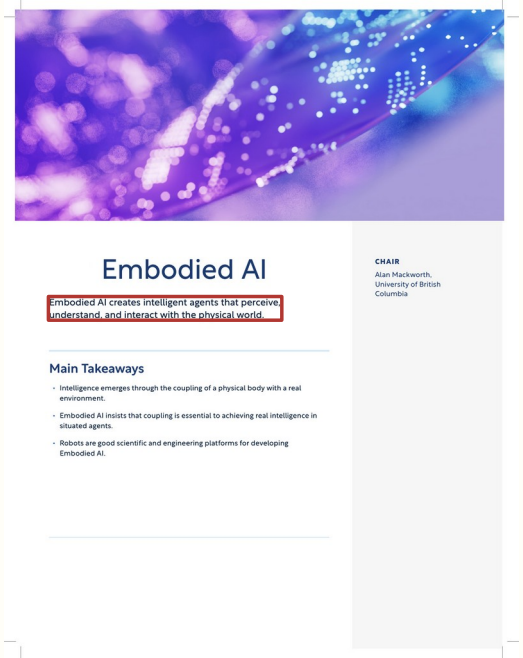
配布の正解注釈（選択した領域の全文）

以上只是列举一部分配凑变形的方式，核心在于朝基本不等式方向构造，多观察题干条件，合理配凑，当然还得多练习 .

内容の要約：式変形の考え方、問題の条件への着目と練習を促す段落。

OpenDataLab. OmniDocBench / JSON 行 23 （ 0 始まり） / 注釈 box-6s09k9l9 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 2 ：写真と脇欄を持つ雑誌



英語の雑誌

赤枠：本文の一領域

写真、中央の本文、右側の人物紹介を別の領域として扱う。

OpenDataLab. OmniDocBench / JSON 行 107 （0 始まり） / 注釈 box_id_2 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 2 ：領域の正解注釈

配布の正解注釈（選択した領域の全文）

> Embodied AI creates intelligent agents that perceive, understand, and interact with the physical world.

内容の要約：身体性 AI は、物理世界を知覚・理解し、相互作用する知的なエージェントの構築を目指す。

OpenDataLab. OmniDocBench / JSON 行 107 （0 始まり） / 注釈 box_id_2 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例３：多数の記事を持つ新聞



中国語の新聞

赤枠：記事本文の一領域

複数の記事、写真、細かな表のある紙面から、記事の冒頭を取り出す。

OpenDataLab. OmniDocBench / JSON 行 1011 （0 始まり） / 注釈 11 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 3 ：領域の正解注釈

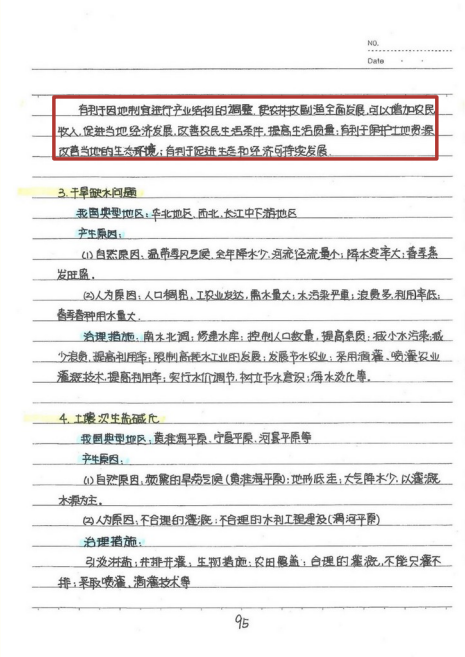
配布の正解注釈（選択した領域の全文）

据中国经济网日前报道称：“今年全国主要农作物种子供应充足，预计杂交玉米种子供大于求，杂交稻种子保持相对稳定，棉花、小麦、油菜等种子供应充足。”

内容の要約：主要作物の種子は十分に供給されると伝える記事。

OpenDataLab. OmniDocBench / JSON 行 1011 （0 始まり） / 注釈 11 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 4 ：手書きノートの段落



中国語の手書きノート

赤枠：手書き本文の一領域

罫線上の手書き文字を読み、複数行を一つの段落へまとめる。

OpenDataLab. OmniDocBench / JSON 行 895 （0 始まり） / 注釈 2 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 4 ：領域の正解注釈

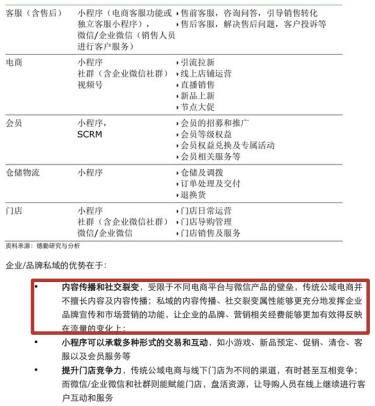
配布の正解注釈（選択した領域の全文）

> 有利于因地制宜进行产业结构的调整，使农林牧副渔全面发展，可以增加农民收入，促进当地经济发展，改善农民生活条件，提高生活质量；有利于保护土地资源改善当地的生态环境；有利于促进生态和经济可持续发展。

内容の要約：産業構成の調整が、農家の収入や地域経済、環境の改善につながると述べる段落。

OpenDataLab. OmniDocBench / JSON 行 895 （0 始まり） / 注釈 2 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 5 ：大きな表の下にある箇条書き



客服（含售后）	小程序（电商客服功能或独立客服小程序），微信/企业微信（销售人员进行客户服务）	• 售前客服，咨询问答，引导销售转化 • 售后客服，解决售后问题，客户投诉等
电商	小程序 社群（含企业微信社群） 视频号	• 引流拉新 • 线上店铺运营 • 直播销售 • 新品上新 • 节点大促
会员	小程序，SCRM	• 会员的招募和推广 • 会员等级权益 • 会员权益兑换及专属活动 • 会员相关服务等
仓储物流	小程序	• 仓储及调拨 • 订单处理及交付 • 退换货
门店	小程序 社群（含企业微信社群） 微信/企业微信	• 门店日常运营 • 门店导购管理 • 门店销售及服务

资料来源：德勤研究与分析

企业/品牌私域的优势在于：

- **内容传播和社交裂变**，受限于不同电商平台与微信产品的壁垒，传统公域电商并不擅长内容及内容传播；私域的内容传播、社交裂变属性能够更充分地发挥企业品牌宣传和市场营销的功能，让企业的品牌、营销相关经费能够更加有效得反映在流量的变化上；
- **小程序可以承载多种形式的交易和互动**，如小游戏、新品预定、促销、清仓、客服以及会员服务等
- **提升门店竞争力**，传统公域电商与线下门店为不同的渠道，有时甚至互相竞争；而微信/企业微信和社群则能赋能门店，盘活资源，让导购人员在线上继续进行客户互动和服务

中国語の調査報告

赤枠：本文の一領域

ページ上部の大きな表と、下部の箇条書きの境界を読み分ける。

OpenDataLab. OmniDocBench / JSON 行 202 （0 始まり） / 注釈 box_id_3 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 5 ：領域の正解注釈

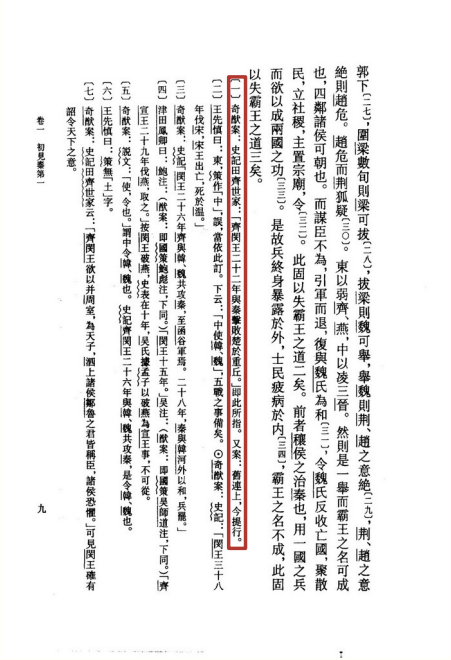
配布の正解注釈（選択した領域の全文）

- 内容传播和社交裂变，受限于不同电商平台与微信产品的壁垒，传统公域电商并不擅长内容及内容传播；私域的内容传播、社交裂变属性能够更充分地发挥企业品牌宣传和市场营销的功能，让企业的品牌、营销相关经费能够更加有效得反映在流量的变化上；

内容の要約：企業独自の顧客接点を使う情報発信や、マーケティング上の利点を説明する。

OpenDataLab. OmniDocBench / JSON 行 202 （0 始まり） / 注釈 box_id_3 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 6 ：縦書きの古典資料



繁体字中国語の歴史資料

赤枠：縦書き注釈の一領域

右から左へ進む縦組みの欄と、本文・校注の文字の大きさを読み取る。

OpenDataLab. OmniDocBench / JSON 行 111 （0 始まり） / 注釈 box-a1va37rw 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 6 ：領域の正解注釈

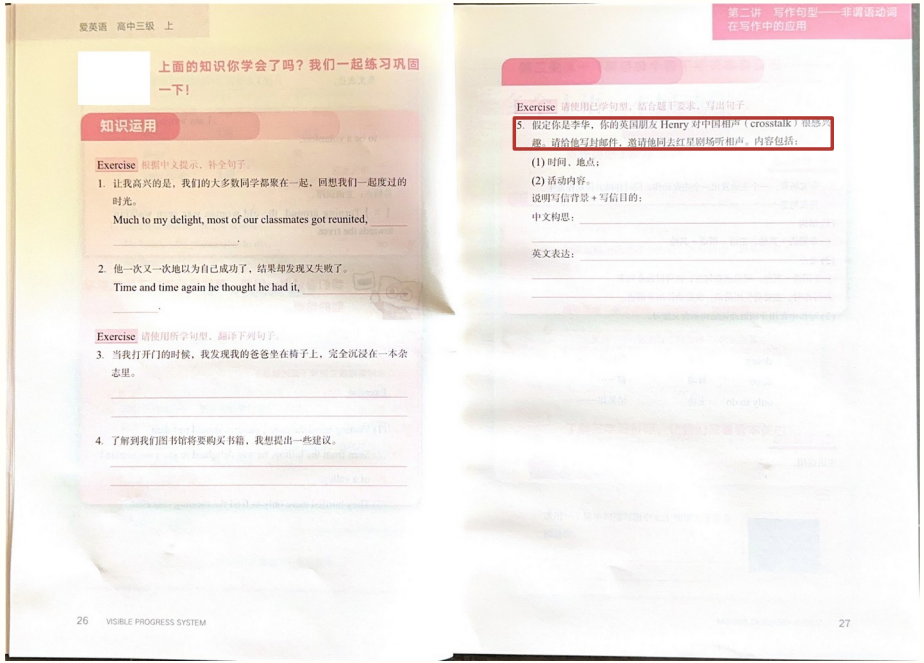
配布の正解注釈（選択した領域の全文）

〔一〕奇猷案：史記田齊世家：「齊閔王二十二年與秦擊敗楚於重丘。」即此所指。又案：舊連上，今提行。

内容の要約：史記の記述を引用し、本文との対応や改行位置を論じる校注。

OpenDataLab. OmniDocBench / JSON 行 111 （0 始まり） / 注釈 box-a1va37rw 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 7 ：見開きの作文問題



OpenDataLab. OmniDocBench / JSON 行 126 （0 始まり） / 注釈 box_id_9 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

中国語で書かれた試験教材

赤枠：問題文の一領域

折り目、傾き、薄い文字、左右のページにまたがる配置を扱う。

追加例 7 ：領域の正解注釈

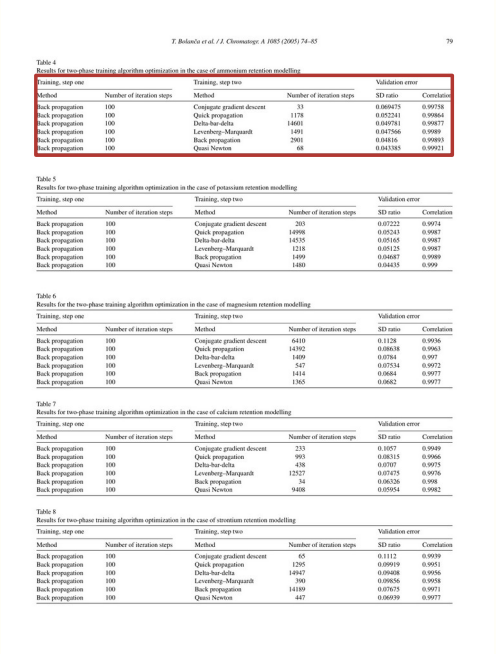
配布の正解注釈（選択した領域の全文）

> 5. 假定你是李华，你的英国朋友 Henry 对中国相声（ crosstalk ）很感兴趣。请给他写封邮件，邀请他同去红星剧场听相声。内容包括：

内容の要約：李華という設定で、英国の友人 Henry を相声の公演へ誘うメールを書く課題。

OpenDataLab. OmniDocBench / JSON 行 126 （ 0 始まり） / 注釈 box_id_9 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 8 ：結合セルを持つ論文の表



T. Bolanča et al. / J. Chromatogr. A 1085 (2005) 74–85 79

Table 4
Results for two-phase training algorithm optimization in the case of ammonium retention modelling

Training, step one		Training, step two		Validation error	
Method	Number of iteration steps	Method	Number of iteration steps	SD ratio	Correlation
Back propagation	100	Conjugate gradient descent	33	0.069475	0.99758
Back propagation	100	Quick propagation	1178	0.052241	0.99864
Back propagation	100	Delta-bar-delta	14601	0.049781	0.99877
Back propagation	100	Levenberg–Marquardt	1491	0.047566	0.9989
Back propagation	100	Back propagation	2901	0.04816	0.99893
Back propagation	100	Quasi Newton	68	0.043385	0.99921

Table 5
Results for two-phase training algorithm optimization in the case of potassium retention modelling

Training, step one		Training, step two		Validation error	
Method	Number of iteration steps	Method	Number of iteration steps	SD ratio	Correlation
Back propagation	100	Conjugate gradient descent	203	0.07222	0.9974
Back propagation	100	Quick propagation	14998	0.05243	0.9987
Back propagation	100	Delta-bar-delta	14535	0.05165	0.9987
Back propagation	100	Levenberg–Marquardt	1218	0.05125	0.9987
Back propagation	100	Back propagation	1499	0.04687	0.9989
Back propagation	100	Quasi Newton	1480	0.04435	0.999

Table 6
Results for the two-phase training algorithm optimization in the case of magnesium retention modelling

Training, step one		Training, step two		Validation error	
Method	Number of iteration steps	Method	Number of iteration steps	SD ratio	Correlation
Back propagation	100	Conjugate gradient descent	6410	0.1128	0.9936
Back propagation	100	Quick propagation	14392	0.08638	0.9963
Back propagation	100	Delta-bar-delta	1409	0.0784	0.997
Back propagation	100	Levenberg–Marquardt	547	0.07534	0.9972
Back propagation	100	Back propagation	1414	0.0684	0.9977
Back propagation	100	Quasi Newton	1365	0.0682	0.9977

Table 7
Results for two-phase training algorithm optimization in the case of calcium retention modelling

Training, step one		Training, step two		Validation error	
Method	Number of iteration steps	Method	Number of iteration steps	SD ratio	Correlation
Back propagation	100	Conjugate gradient descent	233	0.1057	0.9949
Back propagation	100	Quick propagation	993	0.08315	0.9966
Back propagation	100	Delta-bar-delta	438	0.0707	0.9975
Back propagation	100	Levenberg–Marquardt	12527	0.07475	0.9976
Back propagation	100	Back propagation	34	0.06326	0.998
Back propagation	100	Quasi Newton	9408	0.05954	0.9982

Table 8
Results for two-phase training algorithm optimization in the case of strontium retention modelling

Training, step one		Training, step two		Validation error	
Method	Number of iteration steps	Method	Number of iteration steps	SD ratio	Correlation
Back propagation	100	Conjugate gradient descent	65	0.1112	0.9939
Back propagation	100	Quick propagation	1295	0.09919	0.9951
Back propagation	100	Delta-bar-delta	14947	0.09408	0.9956
Back propagation	100	Levenberg–Marquardt	390	0.09856	0.9958
Back propagation	100	Back propagation	14189	0.07675	0.9971
Back propagation	100	Quasi Newton	447	0.06939	0.9977

英語の学術論文

赤枠：最上段の表全体

先頭行は 3 つの見出しがそれぞれ 2 列を占める。
HTML の colspan で列のまとまりを残す。

OpenDataLab. OmniDocBench / JSON 行 465 （0 始まり） / 注釈 4 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 8 ：先頭の見出し行の HTML 注釈

```
<table border="1">
<tr>
<td colspan="2">Training, step one</td>
<td colspan="2">Training, step two</td>
<td colspan="2">Validation error</td>
</tr>
</table>
```

配布 HTML の先頭行を抜粋。 colspan="2" は、セルが 2 列を占める指定。

OpenDataLab. OmniDocBench / JSON 行 465 （0 始まり） / 注釈 4 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 9 ：表と数式に挟まれた一文



RWKV-7 uses four low-rank MLPs for decay w, value residual v, in-context learning rate a and gate g respectively. The intermediate dimensions are listed in Table 16. These values are based on our mere speculation of how much information can be passed through.

Dimension (D)	d_w	d_a	d_v	d_g
768	64	64	32	128
1024	64	64	32	128
2048	96	96	64	256
2560	96	96	64	320
4096	128	128	96	480
6144	128	128	96	640

Table 16: Suggested Intermediate Dimensions for the low-rank MLPs for RWKV-7 models

The number of parameters for all RWKV-7 models can be computed by the formula:

$$\#(\text{Params}) = 2DV + 4D + LD\left(12D + 2\left(d_w + d_a + d_v + d_g\right) + 19\right) - (2Dd_v + D). \quad (26)$$

Where:

- The weights of the embeddings and head, and the Layernorms beside them, yield $2DV + 4D$ parameters;
- The weights of each layer yield $D\left(12D + 2\left(d_w + d_a + d_v + d_g\right) + 19\right)$ parameters, except for the first layer;
- The low-rank MLP for the value residual is not present in the first layer, subtracting $(2Dd_v + D)$ parameters.

Parameter Initializations Proper parameter initialization is crucial for ensuring training stability and achieving optimal performance for language models. RWKV-7 employs a carefully designed initialization strategy tailored to its architecture. The detailed initialization scheme is beyond the scope here but can be found in the official code repository. We emphasize that using the recommended initialization is essential for replicating the results in this paper. Deviations from the prescribed initialization may lead to performance degradation.

Dataset Loading The dataset used for pretraining consists of 3 119 194 079 123 tokens stored on disk, which are memory-mapped using the `mmap` mechanism. To ensure a diverse and pseudo-random sampling of training sequences, we employ a custom data loading strategy based on a mathematical function with desirable properties. Specifically, we utilize a pseudo-random number generator defined by the function $f(x) = ax^3$ over the finite field $\mathbb{Z}/p\mathbb{Z}$, where p is a prime number of the form $3n + 2$. This function is chosen because it is a bijection (full map) in $\mathbb{Z}/p\mathbb{Z}$, ensuring that all possible indices are eventually accessed exactly once within one epoch.

For pretraining with a sequence length of 4096, the relative address of the k-th sample is determined as:

$$\text{start_address} = 4096 \cdot (ak^3 \mod p), \quad \text{end_address} = \text{start_address} + 4097.$$

Here, p is chosen as the largest prime of the form $3n + 2$ smaller than $\lfloor \text{dataset_size}/4096 \rfloor$, yielding $p = 761\,521\,949$. The parameter a is set to an integer close to $0.618p$ that ensures good mixing properties of the generated addresses.

This approach guarantees both simple calculation and uniform access to the dataset while maintaining pseudo-randomness. By leveraging the properties of modular arithmetic and cubic mappings, we achieve a balance between computational efficiency and data diversity during pretraining.

Training Details All RWKV-7 models were trained under `bfloat16` format on nodes of 8× Nvidia H800. The AdamW optimizer was configured with $\beta_1 = 0.9$, $\beta_2 = 0.99$, $\epsilon = 1 \times 10^{-18}$, and a weight decay of 0.1 applied exclusively to linear layers and embedding weights. The choice of such a small ϵ value is motivated by the theory proposed by Molybog et al. (2023), which suggests that

40

英語の学術論文

赤枠：本文の一領域

上の表、説明の一文、式番号付きの数式を別の領域として扱い、読む順番を付ける。

OpenDataLab. OmniDocBench / JSON 行 10 （0 始まり） / 注釈 box_id_3 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 9 ：領域の正解注釈

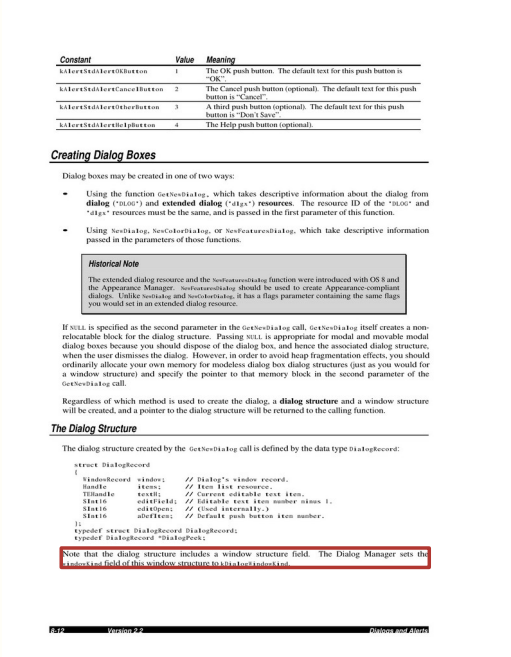
配布の正解注釈（選択した領域の全文）

> The number of parameters for all RWKV-7 models can be computed by the formula:

内容の要約：すべての RWKV-7 モデルのパラメータ数は、次の式で計算できる。

OpenDataLab. OmniDocBench / JSON 行 10 （ 0 始まり） / 注釈 box_id_3 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 10 ：コードを含む技術書



Constant	Value	Meaning
kAlertStdAlertOKButton	1	The OK push button. The default text for this push button is "OK".
kAlertStdAlertCancelButton	2	The Cancel push button (optional). The default text for this push button is "Cancel".
kAlertStdAlertOtherButton	3	A third push button (optional). The default text for this push button is "Don't Save"
kAlertStdAlertHelpButton	4	The Help push button (optional).

Creating Dialog Boxes

Dialog boxes may be created in one of two ways:

- Using the function GetNewDialog, which takes descriptive information about the dialog from **dialog** ('DLOG') and **extended dialog** ('dlgx') **resources**. The resource ID of the 'DLOG' and 'dlgx' resources must be the same, and is passed in the first parameter of this function.
- Using NewDialog, NewColorDialog, or NewFeaturesDialog, which take descriptive information passed in the parameters of those functions.

Historical Note

The extended dialog resource and the NewFeaturesDialog function were introduced with OS 8 and the Appearance Manager. NewFeaturesDialog should be used to create Appearance-compliant dialogs. Unlike NewDialog and NewColorDialog, it has a flags parameter containing the same flags you would set in an extended dialog resource.

If NULL is specified as the second parameter in the GetNewDialog call, GetNewDialog itself creates a non-relocatable block for the dialog structure. Passing NULL is appropriate for modal and movable modal dialog boxes because you should dispose of the dialog box, and hence the associated dialog structure, when the user dismisses the dialog. However, in order to avoid heap fragmentation effects, you should ordinarily allocate your own memory for modeless dialog box dialog structures (just as you would for a window structure) and specify the pointer to that memory block in the second parameter of the GetNewDialog call.

Regardless of which method is used to create the dialog, a **dialog structure** and a window structure will be created, and a pointer to the dialog structure will be returned to the calling function.

The Dialog Structure

The dialog structure created by the GetNewDialog call is defined by the data type DialogRecord:

```
struct DialogRecord
{
    WindowRecord    window;     // Dialog's window record.
    Handle          items;      // Item list resource.
    TEHandle        textH;      // Current editable text item.
    SInt16          editField;  // Editable text item number minus 1.
    SInt16          editOpen;   // (Used internally.)
    SInt16          aDefItem;   // Default push button item number.
};
typedef struct DialogRecord DialogRecord;
typedef DialogRecord *DialogPeek;
```

Note that the dialog structure includes a window structure field. The Dialog Manager sets the windowKind field of this window structure to kDialogWindowKind.

英語の技術書

赤枠：本文の一領域

表、囲み記事、コード、通常の段落が一つのページに共存する。

OpenDataLab. OmniDocBench / JSON 行 543 （0 始まり） / 注釈 1 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加例 10 ：領域の正解注釈

配布の正解注釈（選択した領域の全文）

> Note that the dialog structure includes a window structure field. The Dialog Manager sets the windowkind field of this window structure to kDialogWindowKind.

内容の要約：ダイアログ構造にはウィンドウ構造のフィールドがあり、 Dialog Manager が windowkind を設定する。

OpenDataLab. OmniDocBench / JSON 行 543 （0 始まり） / 注釈 1 。
https://huggingface.co/datasets/opendatalab/OmniDocBench

2. データ構成と注釈の詳細

現在の文書種別：書籍・教材・論文など

文書の種類	ページ数
書籍	276
スライドの PDF 化	253
学術論文	215
試験問題	193
カラー教材	159

OpenDataLab (2026 年 10 月取得). OmniDocBench: OmniDocBench.json / 全 1,651 ページを集計。
https://huggingface.co/datasets/opendatalab/OmniDocBench

現在の文書種別：新聞・雑誌・手書きなど

文書の種類	ページ数
新聞	151
雑誌	149
調査報告	132
手書きノート	118
歴史資料	5

OpenDataLab (2026 年 10 月取得). OmniDocBench: OmniDocBench.json / 全 1,651 ページを集計。
https://huggingface.co/datasets/opendatalab/OmniDocBench

段組みと、通常の段組みに収まらない配置

レイアウトのラベル	ページ数
単段	887
その他の配置	372
2 段	184
単段と複数段の混在	155
3 段	53

OpenDataLab (2026 年 10 月取得). OmniDocBench: OmniDocBench.json / 全 1,651 ページを集計。
https://huggingface.co/datasets/opendatalab/OmniDocBench

追加された高難度 296 ページの内訳

配布のサブセット名	主な対象	ページ数
equation_hard	数式	100
layout_hard	レイアウト	99
table_hard	表	97

OpenDataLab (2026 年 10 月取得). OmniDocBench: OmniDocBench.json / 全 1,651 ページを集計。
https://huggingface.co/datasets/opendatalab/OmniDocBench

一つの領域に、位置・種類・内容を対応させる

JSON の項目	役割
category_type	text_block 、 table などの領域種別
poly	領域の四隅の画像上の座標
order	ページ内の読む順番
text / latex / html	本文・数式・表の内容
anno_id	ページ内の注釈 ID

OpenDataLab (2026 年 10 月取得). OmniDocBench: OmniDocBench.json / 全 1,651 ページを集計。
https://huggingface.co/datasets/opendatalab/OmniDocBench

事前注釈を修正し、描画して再確認する

- 作業者は、検出された領域の境界を修正し、読む順番や、本文とキャプションなどの対応を付ける。認識結果は文字ごとに確認する。
- 表と数式は、 HTML や LaTeX を編集できるツールで修正する。描画できない要素を検出し、 3 人の研究者が確認・修正した。
- 初期版の 9 種類・ 981 ページから追加を重ね、現在は歴史資料も含め 10 種類・ 1,651 ページとなる。文書種別の内訳は現行 JSON の全件から数えた。

Ouyang et al. (2025). OmniDocBench: Benchmarking Diverse PDF Document Parsing with Comprehensive Annotations. CVPR.
https://arxiv.org/abs/2412.07626

正解 JSON のページと領域を読む

```
import json
from pathlib import Path

pages = json.loads(Path("OmniDocBench.json").read_text())
page = pages[300]
print(page["page_info"]["image_path"])
for region in page["layout_dets"]:
    print(region["category_type"], region["anno_id"])
```

本編の表のページを選び、画像名と注釈 ID を取り出す。

OpenDataLab (2026 年 10 月取得). OmniDocBench: OmniDocBench.json / 全 1,651 ページを集計。
https://huggingface.co/datasets/opendatalab/OmniDocBench

3. 制作機関と参考文献

OpenDataLab を中心に、文書解析を共同評価

- 第一著者は Linke Ouyang 、最終著者は Conghui He 。 Shanghai AI Laboratory 、 Abaka AI 、 2077 AI の研究者が制作した。
- 2024 年 12 月にデータと論文を公開し、 CVPR 2025 で発表。要素別の評価と、ページ全体の解析の評価を同じ注釈へまとめる。
- その後も、ページや正解注釈、照合アルゴリズム、推論用コードを更新。 2026 年の公式比較では、汎用モデルと文書専用モデルを並べて評価している。

Ouyang et al. (2025). OmniDocBench: Benchmarking Diverse PDF Document Parsing with Comprehensive Annotations. CVPR.
https://arxiv.org/abs/2412.07626

参考文献

OmniDocBench: Benchmarking Diverse PDF Document Parsing with Comprehensive Annotations

Linke Ouyang et al. / CVPR 2025 / arXiv:2412.07626

初期データの収集・注釈と、文書解析の評価設計を説明する。

https://arxiv.org/abs/2412.07626

OmniDocBench: Dataset and Annotations

OpenDataLab / Hugging Face / 2024 年初出・ 2026 年 10 月取得

ページ画像、正解 JSON 、更新履歴、データの利用条件を確認する。

https://huggingface.co/datasets/opendatalab/OmniDocBench

参考文献

OmniDocBench: Evaluation Code and Model Results

OpenDataLab / GitHub / 2026 年 10 月参照 / コード Apache 2.0

バージョンの変更、照合と採点、公式比較と推論実装を公開する。

https://github.com/opendatalab/OmniDocBench

Image Over Text: Transforming Formula Recognition Evaluation with Character Detection Matching

OpenDataLab / OmniDocBench 内の CDM 実装と解説

数式の描画結果から、文字と位置を対応させる指標を説明する。

https://github.com/opendatalab/OmniDocBench/tree/main/metrics/cdm