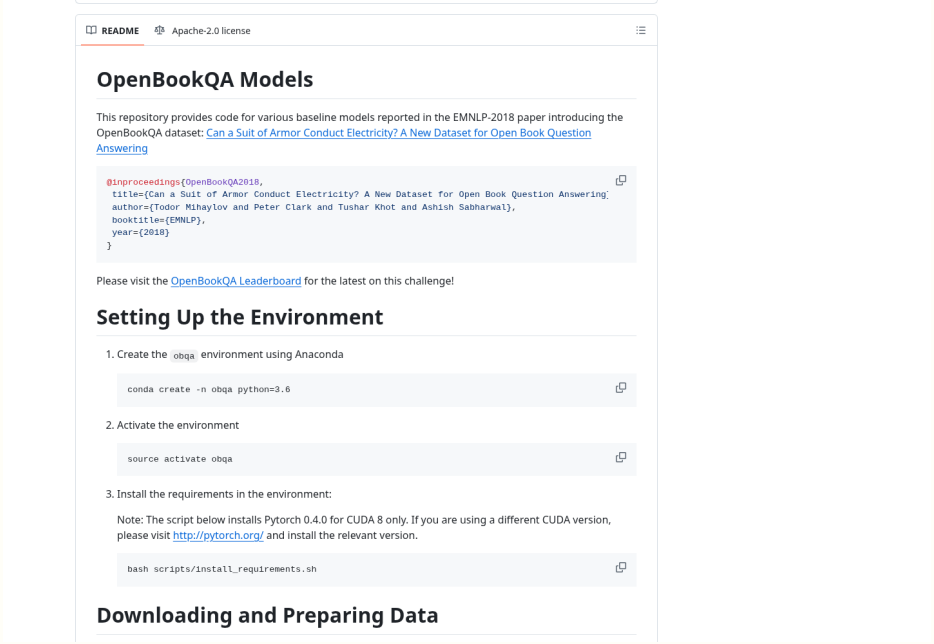
OpenBookQA

科学の事実と常識を組み合わせる四択問題

sasakiy84

OpenBookQA の公開ページ



README Apache-2.0 license

OpenBookQA Models

This repository provides code for various baseline models reported in the EMNLP-2018 paper introducing the OpenBookQA dataset: Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering

```
@inproceedings{OpenBookQA2018,
 title={Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering},
 author={Todor Mihaylov and Peter Clark and Tushar Khot and Ashish Sabharwal},
 booktitle={EMNLP},
 year={2018}
}
```

Please visit the OpenBookQA Leaderboard for the latest on this challenge!

Setting Up the Environment

1. Create the `obqa` environment using Anaconda

```
conda create -n obqa python=3.6
```

2. Activate the environment

```
source activate obqa
```

3. Install the requirements in the environment:

Note: The script below installs Pytorch 0.4.0 for CUDA 8 only. If you are using a different CUDA version, please visit http://pytorch.org/ and install the relevant version.

```
bash scripts/install_requirements.sh
```

Downloading and Preparing Data

[1] OpenBookQA 公式公開ページ。 2026-10-18 参照。 https://github.com/allenai/OpenBookQA

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

一つの科学の事実を、具体的な場面へ結び付ける

- 小学校水準の科学の事実と、日常的な常識を組み合わせて答える英語の四択問題である。各問には正解が一つある。
- 公開された科学の事実を見つけるだけでなく、ヤモリがトカゲの仲間であることなど、場面に当てはめる知識も必要になる。

[1] Todor Mihaylov et al. (2018). Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering. EMNLP 2018. https://aclanthology.org/D18-1260/

入力・出力と配布フィールド

フィールド	意味
question_stem	質問文
choices / answerKey	A 〜 D の候補と正解記号
fact1 （ additional 版）	問題作成に用いた科学の事実

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 https://huggingface.co/datasets/allenai/openbookqa

実例１：支出を減らす（原文）

正解： B

原文

Question: A person wants to start saving money so that they can afford a nice vacation at the end of the year. After looking over their budget and expenses, they decide the best way to save money is to
A. make more phone calls
B. quit eating lunch out
C. buy less with monopoly money
D. have lunch with friends
Science fact: using less resources usually causes money to be saved

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 8-343 。 https://huggingface.co/datasets/allenai/openbookqa

実例１：支出を減らす（日本語訳）

正解： B

日本語訳

質問：年末に楽しい休暇を過ごせるよう、ある人が貯金を始めようとしている。予算と支出を見直し、お金を貯める最善の方法として何を選ぶか。
A ：電話をもっとかける
B ：昼食を外で食べるのをやめる
C ：モノポリーのお金で買う量を減らす
D ：友人と昼食を食べる
関連する科学の事実：使う資源を減らすと、通常は節約になる。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 8-343 。 https://huggingface.co/datasets/allenai/openbookqa

実例２：霧の発生

原文

Question: There is most likely going to be fog around:
A. a marsh
B. a tundra
C. the plains
D. a desert
Science fact: fog is formed by water vapor condensing in the air

日本語訳

正解： A

質問：次のうち、周辺に最も霧が発生しやすい場所はどこか。
A ：湿地
B ：ツンドラ
C ：平原
D ：砂漠
関連する科学の事実：霧は、空気中の水蒸気が凝結することで生じる。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 1129 。 https://huggingface.co/datasets/allenai/openbookqa

実例３：根と歩道（原文）

正解： C

原文

Question: Oak tree seeds are planted and a sidewalk is paved right next to that spot, until eventually, the tree is tall and the roots must extend past the sidewalk, which means
A. roots may be split
B. roots may begin to die
C. parts may break the concrete
D. roots may fall apart
Science fact: if a tree is located near a sidewalk then the roots of that tree might crack the sidewalk

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 7-999 。 https://huggingface.co/datasets/allenai/openbookqa

実例３：根と歩道（日本語訳）

正解： C

日本語訳

質問：オークの種を植え、そのすぐ隣に歩道を舗装した。やがて木が高く育ち、根が歩道の先まで伸びるようになると、何が起こり得るか。
A ：根が裂けるかもしれない
B ：根が枯れ始めるかもしれない
C ：根の一部がコンクリートを壊すかもしれない
D ：根がばらばらになるかもしれない
関連する科学の事実：木が歩道の近くにあると、その根が歩道にひびを入れることがある。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 7-999 。 https://huggingface.co/datasets/allenai/openbookqa

作成方法とデータの構成

作成の背景

- 既存の質問応答では、検索した文章だけで答えが見つかったり、必要な知識が不明確だったりした。
- そこで、参照する科学の事実を小さな集合として公開し、それを常識と結び付ける課題を作った。

[1] Todor Mihaylov et al. (2018). Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering. EMNLP 2018. https://aclanthology.org/D18-1260/

収集と品質の確認

- 1,326 件の科学の事実を用意し、作業者が一つの事実を使う質問と四つの選択肢を作成した。
- 別の作業者が回答と明確さを確認し、合意の低い問題や単純な解法で解ける問題を除いた。最終的に 5,957 問を収録した。

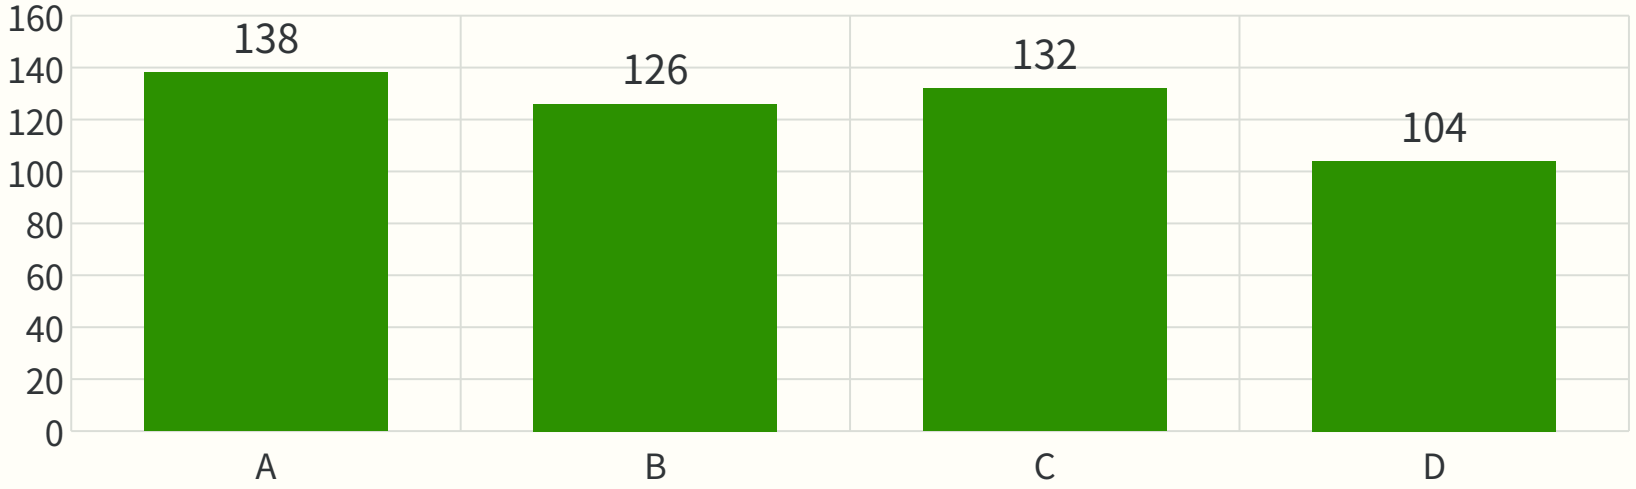
[1] Todor Mihaylov et al. (2018). Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering. EMNLP 2018. https://aclanthology.org/D18-1260/

分割と件数

集合・対象	件数	役割
train	4,957	学習用
validation	500	開発・設定選択用
test	500	性能評価用

[1] Todor Mihaylov et al. (2018). Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering. EMNLP 2018. https://aclanthology.org/D18-1260/

test の正解位置の分布



additional 版 test 全 500 問。横軸は正解の記号、縦軸は問題数。

[1] OpenBookQA 、 additional/test 全 500 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/allenai/openbookqa

採点方法とモデルの成績

何を 1 件として、どう採点するか

- 選んだ候補が answerKey と一致すれば 1 点、異なれば 0 点。 500 問中 350 問が正しければ、正解率は 70% 。
- 2018 年の比較では、 k 個の同点候補に正解が含まれる場合は 1/k 点としている。 HELM は候補を一つ選ぶ方式である。

[1] Todor Mihaylov et al. (2018). Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering. EMNLP 2018. https://aclanthology.org/D18-1260/

初期の代表的な評価

2018 年の方式	test の得点（%）
ESIM （質問・選択肢で学習）	48.9 ± 1.1
科学の正解事実 f を提示	55.8 ± 2.3
f と作成者の追加事実 k を提示	76.9 ± 0.7

5 回の学習の平均 ± 標準偏差。 f ・ k の提示は、関連事実が既知という条件。

[1] Todor Mihaylov et al. (2018). Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering. EMNLP 2018. https://aclanthology.org/D18-1260/

HELM での評価条件

- test の 500 問。質問と四つの候補を使い、科学の正解事実は入力に加えない。
- 提示例 0 件、 1 試行。各候補の尤度を、候補単独の尤度で補正して比較する separate_calibrated 方式。

[1] Stanford CRFM. HELM Classic v0.4.0. 公開 run_specs 。 2023-11-17 のリリース。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

HELM Classic v0.4.0 の結果

モデル	正解率（%）	試行数
text-davinci-003 （2022）	64.60	1
Anthropic v4-s3 （2022）	55.80	1

test 500 問、提示例 0 件、 1 試行。候補の尤度を補正して比較。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

利用の変化と入手方法

科学知識の評価から、汎用モデルの比較へ

- 登場時は、必要な事実をどこから得るかが主要な研究課題だった。 HELM では、科学の事実を入力しない少数例提示の評価にも使われた。
- 2026-10-18 時点の公開 Evaluation Harness にも OpenBookQA の定義があり、四択問題として再利用できる。

[1] EleutherAI. Language Model Evaluation Harness. 2026-10-18 参照。 https://github.com/EleutherAI/lm-evaluation-harness

入手方法と利用条件

- Allen Institute の公開ページから配布先へ進める。現在、この URL は Hugging Face の配布ページへ転送される。公式 GitHub は Apache 2.0 を掲げている。
- main 版は質問・選択肢・正解、 additional 版は fact1 や人手評価も持つ。掲載例には additional 版を使った。

[1] OpenBookQA 公式公開ページ。 2026-10-18 参照。 https://allenai.org/data/open-book-qa

OpenBookQA の要点

- 科学の事実を、常識を介して具体例に適用する 5,957 問の四択課題である。
- 正解の事実を与えるか、モデル自身に知識の利用を任せるかで、評価する能力が変わる。

[1] Todor Mihaylov et al. (2018). Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering. EMNLP 2018. https://aclanthology.org/D18-1260/

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例１：電気伝導体

原文

Question: An electric car runs on electricity via
A. gasoline
B. a power station
C. electrical conductors
D. fuel
Science fact: An electrical conductor is a vehicle for the flow of electricity

日本語訳

正解： C

質問：電気自動車では、何を通じて電気が流れるか。
A ：ガソリン
B ：発電所
C ：電気伝導体
D ：燃料
関連する科学の事実：電気伝導体は、電気の流れを伝える媒体である。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 8-464 。 https://huggingface.co/datasets/allenai/openbookqa

追加例２：夏至と月

原文

Question: The summer solstice in the northern hemisphere is four months before
A. May
B. July
C. April
D. October
Science fact: the summer solstice is on June 21st in the northern hemisphere

日本語訳

正解： D

質問：北半球の夏至から 4 か月後は何月か。
A ： 5 月
B ： 7 月
C ： 4 月
D ： 10 月
関連する科学の事実：北半球の夏至は 6 月 21 日である。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 7-1140 。 https://huggingface.co/datasets/allenai/openbookqa

追加例３：土壌の形成

関連する入力・回答／左：原文　右：日本語

Question: The main component in dirt is
A. microorganisms
B. broken stones
C. pollution
D. bacteria
Science fact: soil is formed by rocks eroding

正解： B

質問：土の主な成分は何か。
A ：選択肢：微生物
B ：選択肢：砕けた石
C ：選択肢：汚染物質
D ：選択肢：細菌
関連する科学の事実：土壌は岩石の浸食によって形成される。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 7-903 。 https://huggingface.co/datasets/allenai/openbookqa

追加例 4 ：サボテンの貯水

関連する入力・回答／左：原文　右：日本語

Question: A cactus stem is used to store
A. fruit
B. liquid
C. food
D. spines
Science fact: a cactus stem is used for storing water

正解： B

質問：サボテンの茎は、何を蓄えるために使われるか。
A ：選択肢：果実
B ：選択肢：液体
C ：選択肢：食物
D ：選択肢：とげ
関連する科学の事実：サボテンの茎は、水を蓄えるために使われる。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 9-937 。 https://huggingface.co/datasets/allenai/openbookqa

追加例 5 ：タカの獲物

原文

Question: A red-tailed hawk is searching for prey. It is most likely to swoop down on
A. an eagle
B. a cow
C. a gecko
D. a deer
Science fact: hawks eat lizards

日本語訳

正解： C

質問：アカオノスリが獲物を探している。最も襲いかかりそうなのはどれか。
A ：ワシ
B ：ウシ
C ：ヤモリ
D ：シカ
関連する科学の事実：タカはトカゲを食べる。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 8-201 。 https://huggingface.co/datasets/allenai/openbookqa

追加例 6 ：干ばつと山火事

関連する入力・回答／左：原文　右：日本語

Question: The chance of wildfires is increased by
A. parched foliage
B. torrential rain
C. lush foliage
D. careful fire maintenance
Science fact: drought may cause wildfires

正解： A

質問：何によって山火事の可能性が高まるか。
A ：選択肢：乾ききった草木
B ：選択肢：激しい雨
C ：選択肢：青々と茂った草木
D ：選択肢：慎重な火の管理
関連する科学の事実：干ばつは山火事を引き起こすことがある。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 1618 。 https://huggingface.co/datasets/allenai/openbookqa

追加例７：バイオ燃料

原文

Question: A positive effect of burning biofuel is
A. shortage of crops for the food supply
B. an increase in air pollution
C. powering the lights in a home
D. deforestation in the amazon to make room for crops
Science fact: biofuel is used to produce electricity by burning

日本語訳

正解： C

質問：バイオ燃料を燃やすことの好ましい効果は何か。
A ：食料用作物の不足
B ：大気汚染の増加
C ：家の照明に電力を供給すること
D ：作物を育てる場所を作るためのアマゾンの森林伐採
関連する科学の事実：バイオ燃料は、燃やして電気を生み出すために使われる。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 758 。 https://huggingface.co/datasets/allenai/openbookqa

追加例 8 ：代替燃料（原文）

正解： D

原文

Question: As gasoline costs rise, alternative fuels are being used, which means that
A. wind power will be expensive
B. gas costs will rise
C. oil costs will be maintained
D. gasoline will be needed less
Science fact: as the use of alternative fuels increases , the use of gasoline will decrease

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 7-414 。 https://huggingface.co/datasets/allenai/openbookqa

追加例 8 ：代替燃料（日本語訳）

正解： D

日本語訳

質問：ガソリン価格の上昇に伴って代替燃料が使われるようになると、どうなるか。
A ：風力発電が高くなる
B ：ガソリン価格が上がる
C ：石油のコストが維持される
D ：必要なガソリンが減る
関連する科学の事実：代替燃料の使用が増えると、ガソリンの使用は減る。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 7-414 。 https://huggingface.co/datasets/allenai/openbookqa

追加例 9 ：太陽光発電（原文）

正解： C

原文

Question: A person wants to be able to have more natural power in their home. They choose to cease using a traditional electric company to source this electricity, and so decide to install
A. sun grafts
B. sunlight shields
C. panels collecting sunlight
D. solar bees
Science fact: a solar panel converts sunlight into electricity

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 9-675 。 https://huggingface.co/datasets/allenai/openbookqa

追加例９：太陽光発電（日本語訳）

正解： C

日本語訳

質問：自宅で自然エネルギーによる電力をもっと使いたい人がいる。従来の電力会社から電気を得るのをやめ、何を設置することにしたか。
A ：太陽の接ぎ木
B ：日光を遮るもの
C ：太陽光を集めるパネル
D ：太陽のミツバチ
関連する科学の事実：ソーラーパネルは、太陽光を電気に変える。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 9-675 。 https://huggingface.co/datasets/allenai/openbookqa

追加例 10 ：ペンギンの羽毛

関連する入力・回答／左：原文　右：日本語

Question: What can feathers on Spheniscidae be used for?
A. keeping warm
B. flying
C. sleeping
D. eating
Science fact: thick feathers can be used for keeping warm

正解： A

質問：ペンギン科の鳥の羽毛は、何に使えるか。
A ：選択肢：体を暖かく保つこと
B ：選択肢：飛ぶこと
C ：選択肢：眠ること
D ：選択肢：食べること
関連する科学の事実：厚い羽毛は、体を暖かく保つために使える。

[1] allenai/openbookqa 、改訂 388097ea 。 2026-10-18 参照。 1189 。 https://huggingface.co/datasets/allenai/openbookqa

集計と評価条件

人手の回答一致度の分布

humanScore	問題数
1.0	368
0.8	132

test 全 500 問。 5 人中の正解者の割合で、 1.0 は 5 人、 0.8 は 4 人。

[1] OpenBookQA 、 additional/test 全 500 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/allenai/openbookqa

研究と参考文献

研究者と発表の位置付け

- Todor Mihaylov を第一著者、 Ashish Sabharwal を最終著者とする、 Heidelberg University と Allen Institute for AI の研究。
- Peter Clark 、 Tushar Khot とともに、科学の知識を使う質問応答を扱った。 EMNLP 2018 で発表。

[1] Todor Mihaylov et al. (2018). Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering. EMNLP 2018. https://aclanthology.org/D18-1260/

参考文献

Can a Suit of Armor Conduct Electricity? A New Dataset for Open Book Question Answering

Todor Mihaylov, Peter Clark, Tushar Khot, Ashish Sabharwal / EMNLP 2018

OpenBookQA の目的、作成方法、評価をまとめた研究。

https://aclanthology.org/D18-1260/

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

複数のシナリオと指標で、言語モデルを比較する HELM の研究。

https://arxiv.org/abs/2211.09110

参考文献

OpenBookQA ：公開データ

allenai/openbookqa / 改訂 388097ea / 2026-10-18 参照

原文・正解の 13 例と、対象集合の全件集計に用いた公開資源。

https://huggingface.co/datasets/allenai/openbookqa