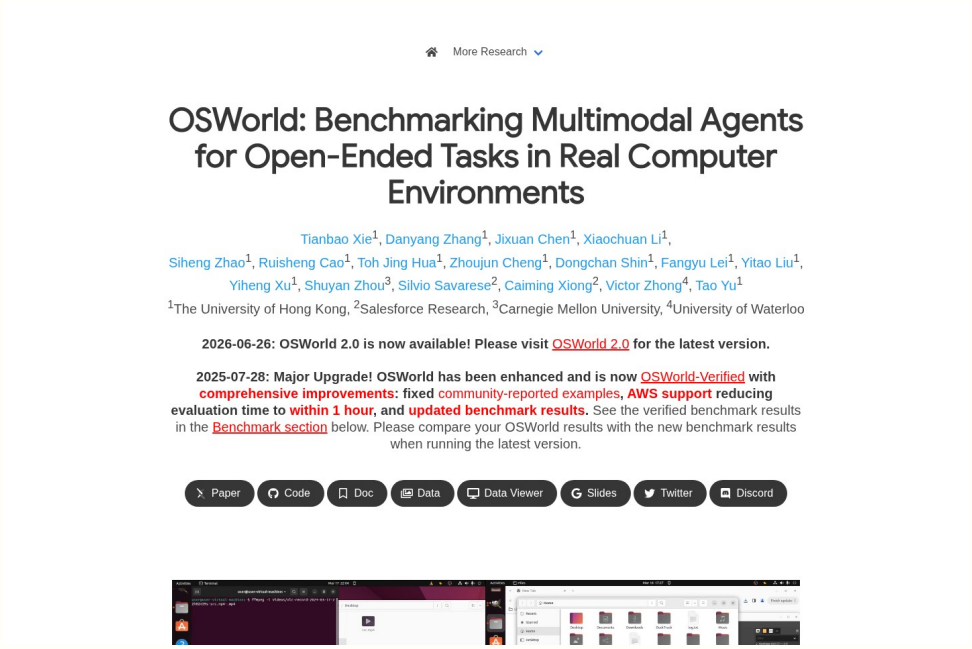
OSWorld-Verified

実際の PC を操作するエージェントの評価
課題の初期状態と、成果物による採点を読む

sasakiy84

OSWorld の公式サイト



https://osworld-v1.xlang.ai/

1. PC 操作の入力と成果物

2. 最終状態の採点とモデル評価

3. 課題の作成と Verified への更新

4. 評価環境とデータの入手

1. PC 操作の入力と成果物

依頼を読み、アプリを操作して仕事を終える

- OSWorld は、実際の PC 環境でエージェントが作業を完了できるかを評価する。表計算、文書編集、画像編集、ブラウザー操作などを扱う。
- 入力は操作の依頼と、作業途中の PC の状態。画面を見てマウスやキーボードを操作し、次の画面を見ながら作業を進める。
- OSWorld-Verified は、 2025 年に課題・採点・環境を改修した更新。ここでは現在の公開定義と、検証済みの評価結果を紹介する。

XLANG Lab (2026 年 10 月参照). OSWorld: 公開の課題定義・環境・エージェント実装。
https://github.com/xlang-ai/OSWorld

操作手順の予測から、成果物の検査へ

- 一つの正解クリック列を当てる代わりに、実際にアプリを動かし、保存ファイルや設定などの最終状態を検査する。
- 同じ目標でも操作経路は複数ある。課題ごとの採点関数が、求めた内容・形式・設定に到達したかを調べる。
- 基盤は複数の OS を扱えるが、主な 369 課題は Ubuntu の作業。 Google Drive を使う 8 課題を除いた 361 課題の評価も使われる。

Xie et al. (2024). OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments. NeurIPS.
https://arxiv.org/abs/2404.07972

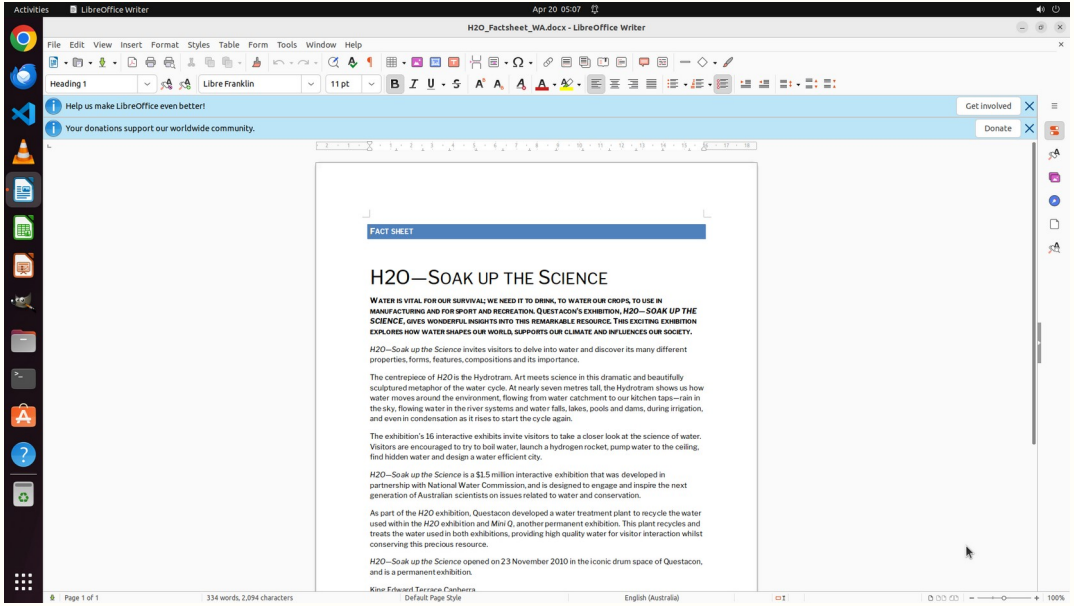
初期画面、依頼、採点条件を一組として読む

- 本編 3 課題と、追加 10 課題を示す。初期画面は、公式に公開された OpenAPA の操作ログから取得した。
- 表示する初期画面に対応する指示が、現在の課題定義と一致することを全例で確認した。指示は原文の全文と日本語訳を載せる。
- 本編の文書・表計算・ファイル結合は、配布の入力と参照成果物も読んだ。何が作業の完了に当たるかを、具体的に説明する。

XLANG Lab (2026 年 10 月参照). OSWorld-Verified Model Trajectories. 公開軌跡 / MIT 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

実例１： H2O の２を下付き文字にする

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / 0b17a146-2934-46c7-8727-73ff6b6483e8 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

実例 1 ：操作の依頼と採点

操作指示（配布原文・全文）

> Help me change the 2 in "H2O" to a subscript.

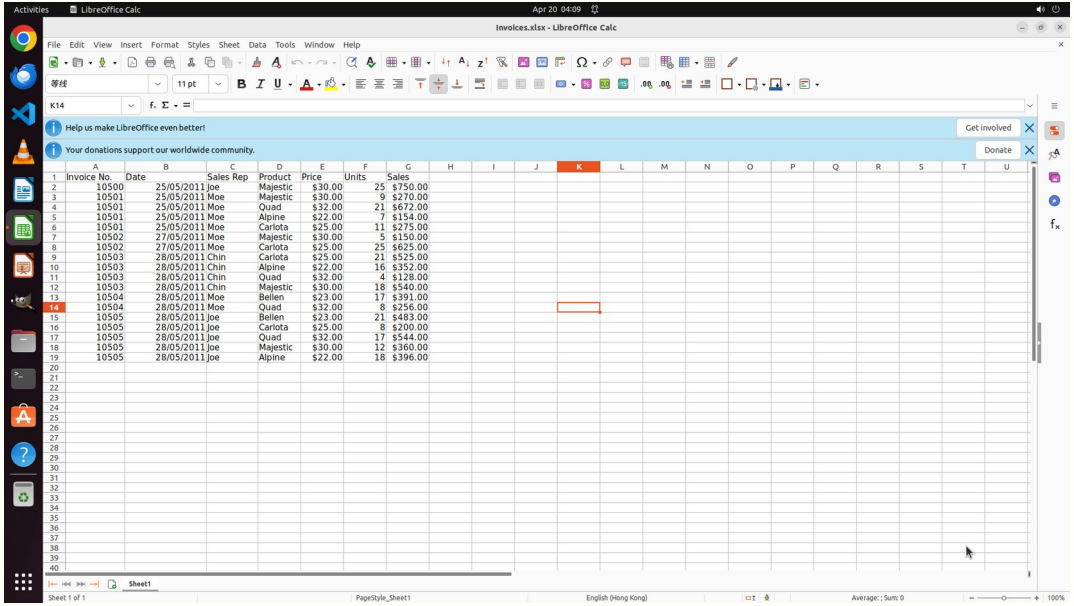
訳： H2O の「 2 」を下付き文字に変更する。

採点：文書の内容と、下付き文字を検査する。

XLANG Lab. OSWorld-Verified / libreoffice_writer / 0b17a146-2934-46c7-8727-73ff6b6483e8 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/libreoffice_writer/0b17a146-2934-46c7-8727-73ff6b6483e8.json

実例２：請求書番号ごとの件数を集計する

公式公開軌跡の初期画面（ step_0 ）



Invoice No.	Date	Sales Rep	Product	Price	Units	Sales
10500	25/05/2011	Joe	Majestic	$30.00	25	$750.00
10501	25/05/2011	Moe	Majestic	$30.00	9	$270.00
10501	25/05/2011	Moe	Quad	$32.00	21	$672.00
10501	25/05/2011	Moe	Alpine	$22.00	7	$154.00
10501	25/05/2011	Moe	Carlota	$25.00	11	$275.00
10502	27/05/2011	Moe	Majestic	$30.00	5	$150.00
10502	27/05/2011	Moe	Carlota	$25.00	25	$625.00
10503	28/05/2011	Chin	Carlota	$25.00	21	$525.00
10503	28/05/2011	Chin	Alpine	$22.00	16	$352.00
10503	28/05/2011	Chin	Quad	$32.00	4	$128.00
10503	28/05/2011	Chin	Majestic	$30.00	18	$540.00
10504	28/05/2011	Moe	Bellen	$23.00	17	$391.00
10504	28/05/2011	Moe	Quad	$32.00	8	$256.00
10505	28/05/2011	Joe	Bellen	$23.00	21	$483.00
10505	28/05/2011	Joe	Carlota	$25.00	8	$200.00
10505	28/05/2011	Joe	Quad	$32.00	17	$544.00
10505	28/05/2011	Joe	Majestic	$30.00	12	$360.00
10505	28/05/2011	Joe	Alpine	$22.00	18	$396.00

XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / 1954cced-e748-45c4-9c26-9855b97fbc5e 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

実例２：操作の依頼と採点

操作指示（配布原文・全文）

> Create a Pivot Table in a new sheet (Sheet2) to count how many times each "Invoice No." appears.

訳： Sheet2 にピボットテーブルを作り、 Invoice No. ごとの出現回数を数える。

採点： Sheet2 のピボットテーブルの構造を照合する。

XLANG Lab. OSWorld-Verified / libreoffice_calc / 1954cced-e748-45c4-9c26-9855b97fbc5e 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/libreoffice_calc/1954cced-e748-45c4-9c26-9855b97fbc5e.json

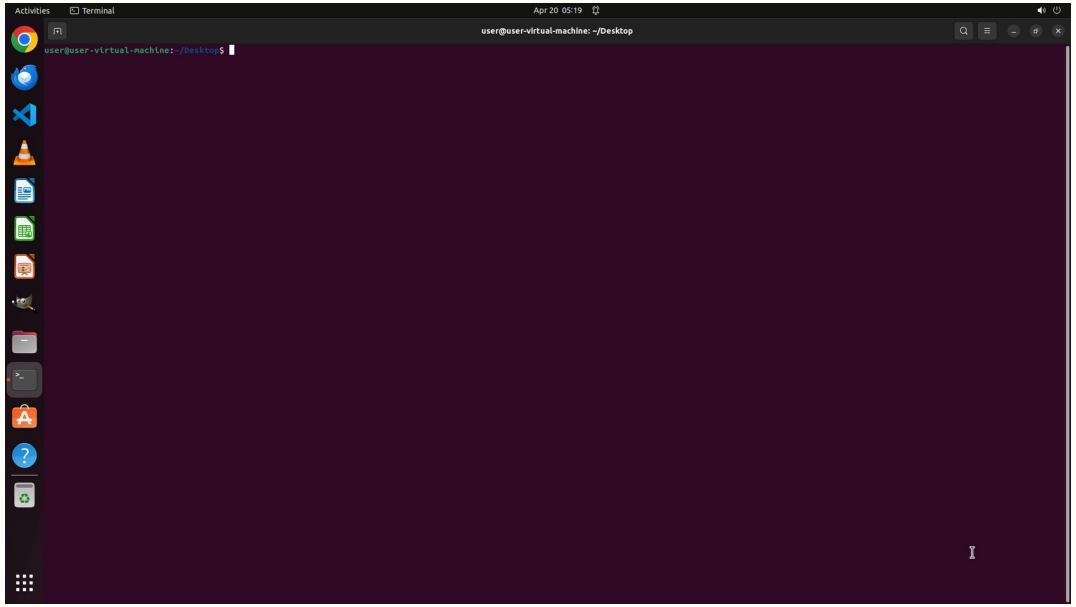
実例２：参照成果物の請求書番号別の件数

Invoice No.	件数
10500	1
10501	4
10502	2
10503	4
10504	2
10505	5

XLANG Lab (2026 年 10 月参照). Ubuntu OSWorld File Cache. 入力と参照成果物。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_file_cache

実例３：端末で２列を結合して Calc で開く

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / 3680a5ee-6870-426a-a997-eba929a0d25c 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

実例３：操作の依頼と採点

操作指示（配布原文・全文）

> I have file1.xlsx and file2.ods on my Desktop, each containing a single column. Using only the command line, help me merge these two columns into a single column by concatenating the strings from both rows, save the result as ~/Desktop/output.csv, and open it in LibreOffice Calc from the terminal

XLANG Lab. OSWorld-Verified / multi_apps / 3680a5ee-6870-426a-a997-eba929a0d25c 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/multi_apps/3680a5ee-6870-426a-a997-eba929a0d25c.json

実例 3 ：操作指示の日本語訳

- Desktop にある file1.xlsx と file2.ods は、それぞれ 1 列の表。各ファイルの同じ行にある文字列を連結し、 1 列へまとめる。
- 処理にはコマンドラインだけを使う。作った列を ~/Desktop/output.csv に保存する。
- その CSV を、端末から LibreOffice Calc で開く。

XLANG Lab. OSWorld-Verified / multi_apps / 3680a5ee-6870-426a-a997-eba929a0d25c 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/multi_apps/3680a5ee-6870-426a-a997-eba929a0d25c.json

実例 3 ： 2 ファイルの各行を一つの文字列にする

file1.xlsx	file2.ods	output_gold2.csv
Dulce	Abril	DulceAbril
Mara	Hashimoto	MaraHashimoto
Philip	Gent	PhilipGent

採点は端末からの起動と CSV 内容を検査。参照 CSV の先頭 3 データ行を示す。

XLANG Lab (2026 年 10 月参照). Ubuntu OSWorld File Cache. 入力と参照成果物。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_file_cache

2. 最終状態の採点とモデル評価

課題ごとの得点を平均し、百分率で示す

- 作業後の文書、表、画像、設定などを取り出し、課題ごとの採点関数を実行する。得点は 0 〜 1 で、部分的な達成に応じた小数もある。
- 公開表の成功率は、課題得点の平均を百分率で示す。例えば、得点の合計 256.71 を 356 課題で割ると 72.11% になる。
- 以下は最大 100 ステップの提出。共通ループでは、観測から次の操作列を予測する 1 回を 1 ステップとして数える。

XLANG Lab. OSWorld: desktop_env.py / evaluate. 最終状態からの採点。
https://github.com/xlang-ai/OSWorld/blob/main/desktop_env/desktop_env.py

画面操作と、追加のコード実行を区別する

- Claude 系の表は、画面を入力し、 GUI 操作を出す構成。追加のアクセシビリティツリー、画面操作以外のコード実行、複数試行は使わない。
- OpenAPA と Pointer Agent の表は、モデルに計画やツール処理を組み合わせた構成。画面操作に加え、ファイル処理などのコード実行を使う。
- 両表とも最大 100 ステップで、追加のアクセシビリティツリーと複数試行はなし。課題数と公開表の日付を、提出ごとに示す。

OSWorld team (2026 年 10 月参照). OSWorld-Verified Results. 公式サイトの公開評価表。
https://github.com/os-world/os-world.github.io/blob/main/static/data/osworld_verified_results.xlsx

Claude 系の公開評価：最大 100 ステップ

モデル	課題数	得点（%）	日付
Claude Sonnet 4	361	41.40	2025-07-28
Claude Sonnet 4.5	360	62.88	2025-10-31
Claude Sonnet 4.6	356	72.11	2026-03-08

OSWorld team (2026 年 10 月参照). OSWorld-Verified Results. 公式サイトの公開評価表。
https://github.com/os-world/os-world.github.io/blob/main/static/data/osworld_verified_results.xlsx

外部の計画・ツール処理を組み合わせた評価

構成	課題数	得点（%）	日付
OpenAPA + Gemini 3.1 Pro	361	78.34	2026-04-17
Pointer Agent + Sonnet 4.6	360	81.45	2026-05-21

OSWorld team (2026 年 10 月参照). OSWorld-Verified Results. 公式サイトの公開評価表。
https://github.com/os-world/os-world.github.io/blob/main/static/data/osworld_verified_results.xlsx

3. 課題の作成と Verified への更新

実際の使い方から、初期状態と採点器を作る

工程	作業の内容
利用場面を集める	公式教材、 Q&A 、ブログ、既存課題などを調査
依頼を整える	指示文と必要なファイルを用意する
初期状態を作る	VM 上でファイルを開き、作業途中を再現する
採点を実装する	成果物を取得し、内容・設定を検査する
別の人が試す	作成者以外の 2 人が実行し、問題を修正する

Xie et al. (2024). OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments. NeurIPS.
https://arxiv.org/abs/2404.07972

2025 年の Verified は、 300 件超の指摘へ対応

- 原著の制作は、計算機科学系の学生 9 人が約 3 か月、約 1,800 人時をかけた。設定、採点器、別の作業者による確認までを含む。
- Verified 更新では、約 10 人が約 2 か月をかけ、 300 件超のフィードバックを検証・修正した。ウェブの変化、依頼の曖昧さ、採点の頑健性を扱う。
- 主に採点器を直し、必要な場合に指示を変更した。 AWS での並列評価を整え、入力ファイルと参照成果物を Hugging Face へ移した。

Xie et al. (2025). Introducing OSWorld-Verified. XLANG Lab / 2025-07-28 。
https://xlang.ai/blog/osworld-verified

OSWorld から Verified へ、何を変えたか

対象	Verified 更新の具体例
依頼の範囲	ファイル形式・保存先・使用機能を明示する
許容する解法	複数の正しい文書・式・行間を受け入れる
採点の頑健性	書式や色の許容幅、文書の類似度を導入する
環境の再現	待機処理、フォント、 VM 起動を改善する

Xie et al. (2025). Introducing OSWorld-Verified. XLANG Lab / 2025-07-28 。
https://xlang.ai/blog/osworld-verified

361 課題版の内訳：五つの利用領域

領域	含まれるアプリなど	課題数
オフィス	Calc ・ Impress ・ Writer	117
日常操作	Chrome ・ VLC ・ Thunderbird	78
専門ツール	GIMP ・ VS Code	49
OS 操作	設定・ファイル・端末など	24
複数アプリ	複数の道具を使う作業	93

XLANG Lab. OSWorld: test_all.json / test_nogdrive.json. 2026-10-17 取得改訂。
https://github.com/xlang-ai/OSWorld/tree/main/evaluation_examples

4. 評価環境とデータの入手

モデルの評価から、実装と軌跡の検証へ

- 2024 年に、実際の PC 操作を課題ごとに採点する環境として登場。 2025 年には Verified 更新と、運営側で結果を確かめる評価枠を設けた。
- 2026 年の公開表には、 Claude Sonnet 4.6 や Gemini 3.1 Pro を組み込むエージェントの評価がある。モデルと制御実装の両方を比較できる。
- 操作のスクリーンショット、指示、ログ、採点結果を公開している。課題定義、実装、最終状態を対応させて調べられる。

OSWorld team (2026 年 10 月参照). OSWorld-Verified Results. 公式サイトの公開評価表。
https://github.com/os-world/os-world.github.io/blob/main/static/data/osworld_verified_results.xlsx

課題 JSON の依頼と採点関数を読む

```
import json
from pathlib import Path

root = Path("evaluation_examples/examples")
uid = "0b17a146-2934-46c7-8727-73ff6b6483e8"
path = root / "libreoffice_writer" / (uid + ".json")
task = json.loads(path.read_text())
print(task["instruction"], task["evaluator"]["func"])
```

OSWorld リポジトリのルートで読む例。課題の定義を取り出す。

XLANG Lab (2026 年 10 月参照). OSWorld: 公開の課題定義・環境・エージェント実装。
https://github.com/xlang-ai/OSWorld

操作の依頼と、作業が終わった状態を結ぶ

- OSWorld-Verified は、実際のアプリを操作し、文書・表・画像・設定などの成果を検査する評価。初期状態と課題ごとの採点器を持つ。
- 369 課題の全体版と、 Google Drive の 8 課題を除く 361 課題版がある。評価にはステップ数、追加ツール、対象課題数を対応させる。
- 画面を見て操作を続ける能力に加え、複数のアプリを組み合わせ、正しい成果物を残せるかを具体的に調べられる。

XLANG Lab (2026 年 10 月参照). OSWorld: 公開の課題定義・環境・エージェント実装。
https://github.com/xlang-ai/OSWorld

Appendix

1. アプリと操作の異なる追加例

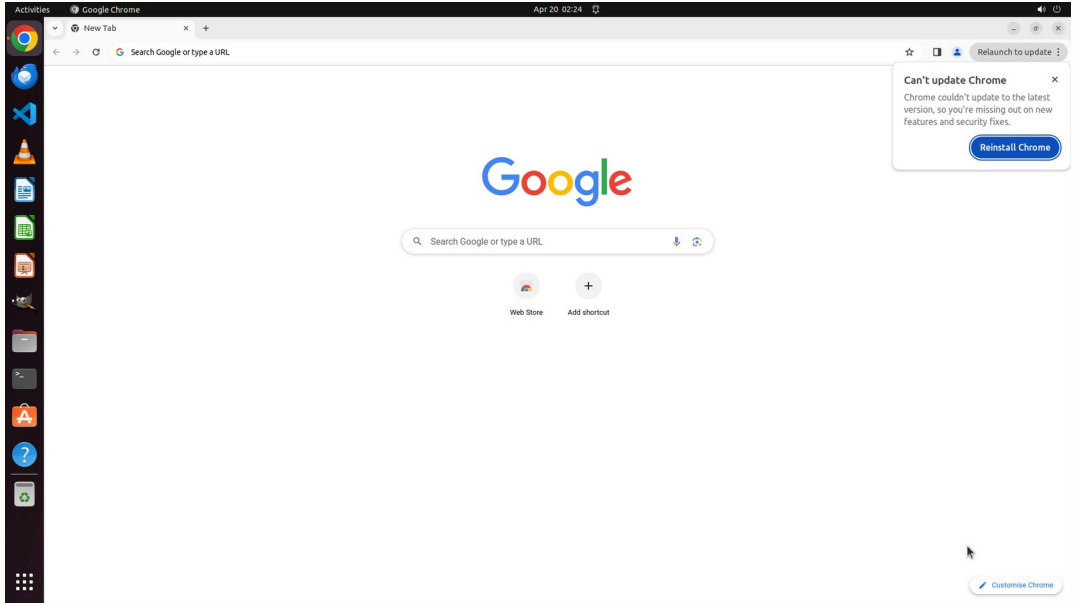
2. 課題定義と構成の詳細

3. 制作機関と参考文献

1. アプリと操作の異なる追加例

追加例 1 ：検索エンジンを Bing に変える

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / bb5e4c0d-f964-439c-97b6-bdb9747de3f4 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

追加例 1 ：操作の依頼と採点

操作指示（配布原文・全文）

> Can you make Bing the main search engine when I look stuff up on the internet?

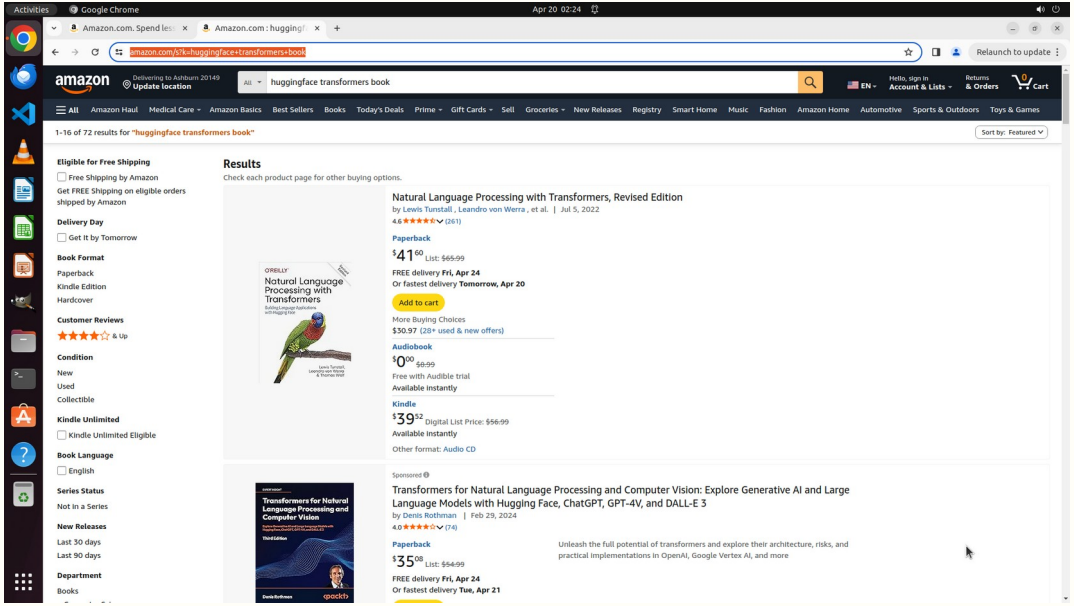
訳：インターネット検索の標準エンジンを Bing に変更する。

採点：保存された標準検索エンジンを確認する。

XLANG Lab. OSWorld-Verified / chrome / bb5e4c0d-f964-439c-97b6-bdb9747de3f4 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/chrome/bb5e4c0d-f964-439c-97b6-bdb9747de3f4.json

追加例２： Amazon の追跡情報を削除する

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / 7b6c7e24-c58a-49fc-a5bb-d57b80e5b4c3 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

追加例 2 ：操作の依頼と採点

操作指示（配布原文・全文）

> Can you help me clean up my computer by getting rid of all the tracking things that Amazon might have saved? I want to make sure my browsing is private and those sites don't remember me.

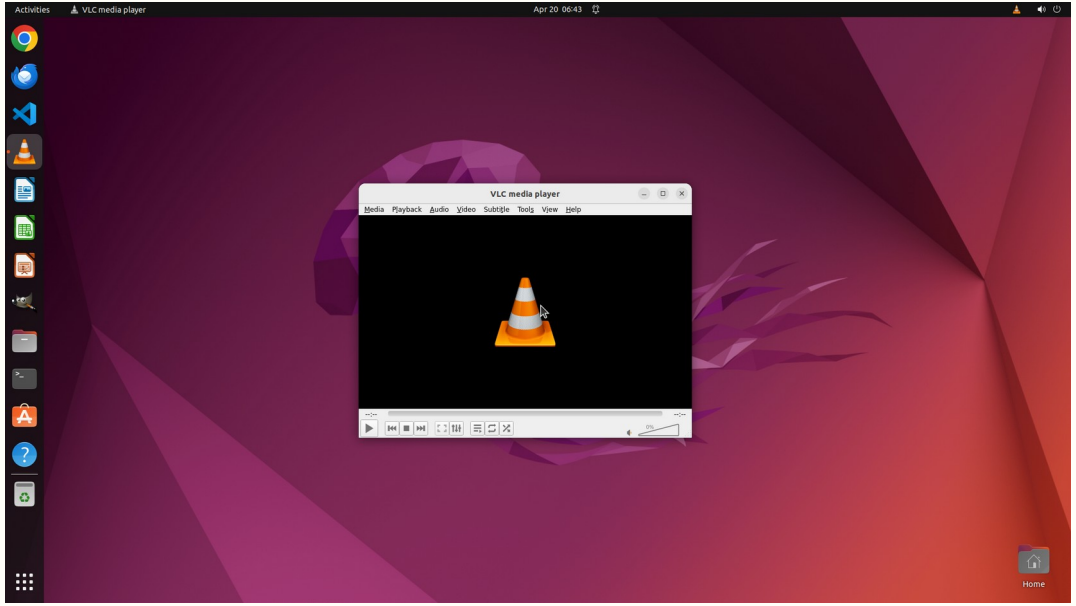
訳： Amazon が保存した追跡情報を削除し、サイトに覚えられないようにする。

採点： amazon.com の Cookie が削除されたかを検査する。

XLANG Lab. OSWorld-Verified / chrome / 7b6c7e24-c58a-49fc-a5bb-d57b80e5b4c3 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/chrome/7b6c7e24-c58a-49fc-a5bb-d57b80e5b4c3.json

追加例３： VLC の録画先を変える

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / 8ba5ae7a-5ae5-4eab-9fcc-5dd4fe3abf89 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

追加例３：操作の依頼と採点

操作指示（配布原文・全文）

> Help me modify the folder used to store my recordings to Desktop

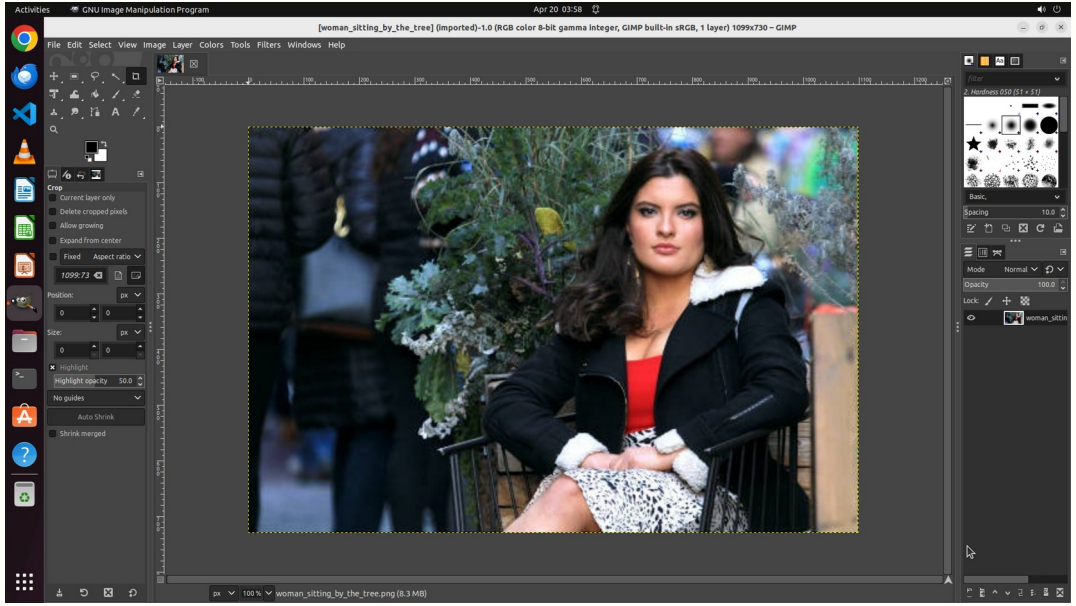
訳：録画を保存するフォルダーをデスクトップへ変更する。

採点： VLC の録画フォルダー設定を確認する。

XLANG Lab. OSWorld-Verified / vlc / 8ba5ae7a-5ae5-4eab-9fcc-5dd4fe3abf89 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/vlc/8ba5ae7a-5ae5-4eab-9fcc-5dd4fe3abf89.json

追加例 4 ：写真の明るさを下げる

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / 7a4deb26-d57d-4ea9-9a73-630f66a7b568 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

追加例 4 ：操作の依頼と採点

操作指示（配布原文・全文）

> Could you tone down the brightness of my photo?

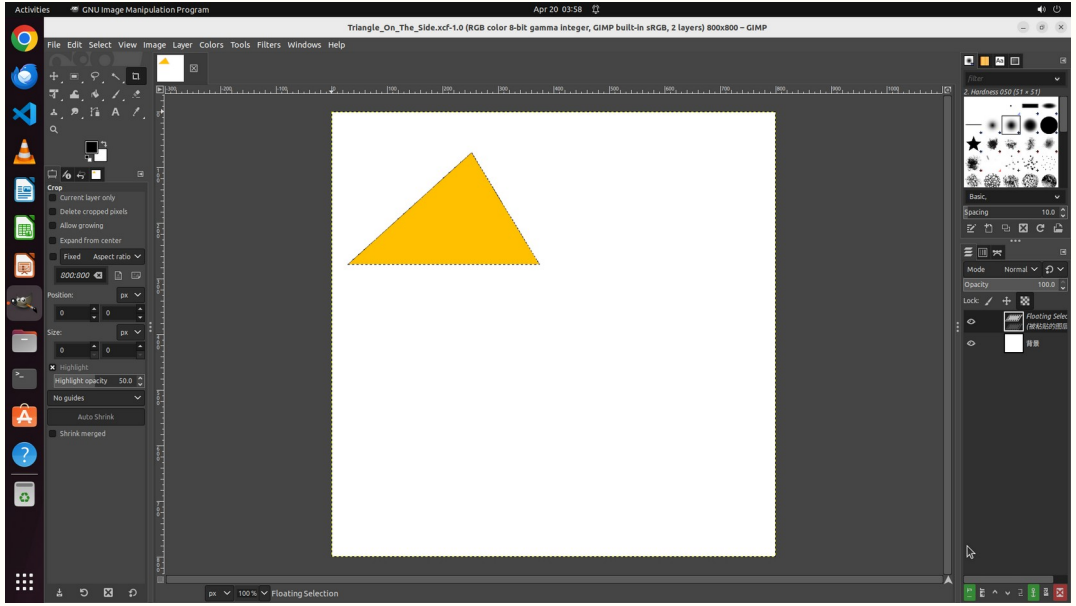
訳：写真の明るさを下げる。

採点：明るさの低下と、画像構造の保持を検査する。

XLANG Lab. OSWorld-Verified / gimp / 7a4deb26-d57d-4ea9-9a73-630f66a7b568 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/gimp/7a4deb26-d57d-4ea9-9a73-630f66a7b568.json

追加例 5 ：黄色の三角形を中央に移す

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / f4aec372-4fb0-4df5-a52b-79e0e2a5d6ce 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

追加例 5 ：操作の依頼と採点

操作指示（配布原文・全文）

> Help me choose the yellow triangle and positioning it at the center of my picture.

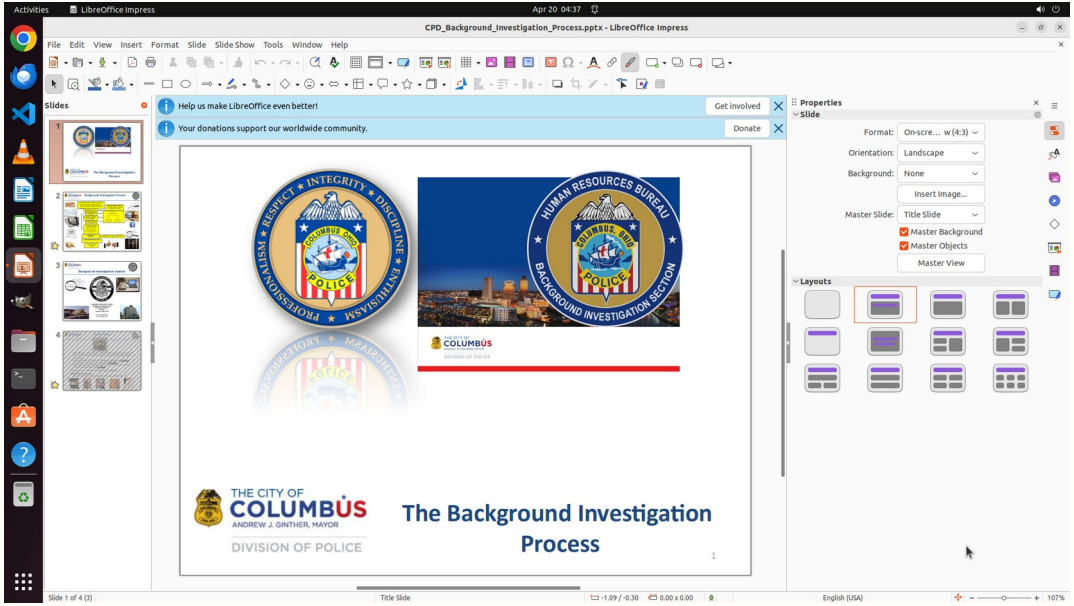
訳：黄色の三角形を選び、画像の中央へ移動する。

採点：出力画像内で、三角形の位置を検査する。

XLANG Lab. OSWorld-Verified / gimp / f4aec372-4fb0-4df5-a52b-79e0e2a5d6ce 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/gimp/f4aec372-4fb0-4df5-a52b-79e0e2a5d6ce.json

追加例 6 ：表紙画像をページ全体に広げる

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / 5d901039-a89c-4bfb-967b-bf66f4df075e 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

追加例 6 ：操作の依頼と採点

操作指示（配布原文・全文）

I want to turn the rectangular image of Columbus on the first page into a cover page. Could you help me stretch this image to fill the entire page, keeping its proportion and centering the image?

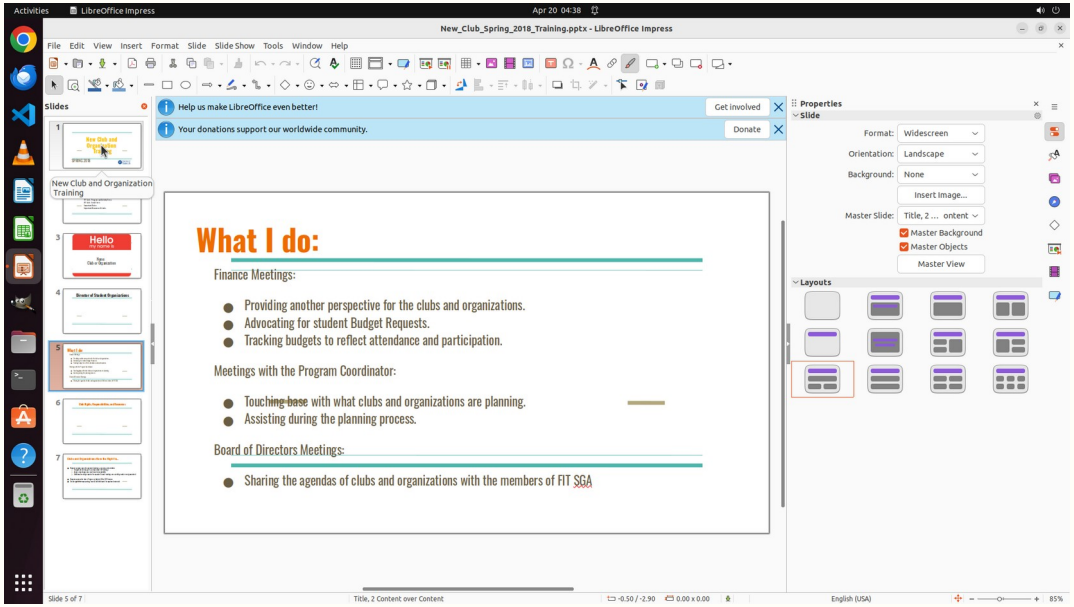
訳：先頭の画像を縦横比を保って広げ、中央に配置し、表紙にする。

採点：画像の同一性・寸法・中央配置を検査する。

XLANG Lab. OSWorld-Verified / libreoffice_impress / 5d901039-a89c-4bfb-967b-bf66f4df075e 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/libreoffice_impress/5d901039-a89c-4bfb-967b-bf66f4df075e.json

追加例７：完了項目に取り消し線を付ける

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / 550ce7e7-747b-495f-b122-acdc4d0b8e54 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

追加例 7 ：操作の依頼と採点

操作指示（配布原文・全文）

> I am checking our soccer club's to-do list for the last semester and adding strike-through sign on the line we have already accomplished. Could you help me add a strike-through on the first and second line?

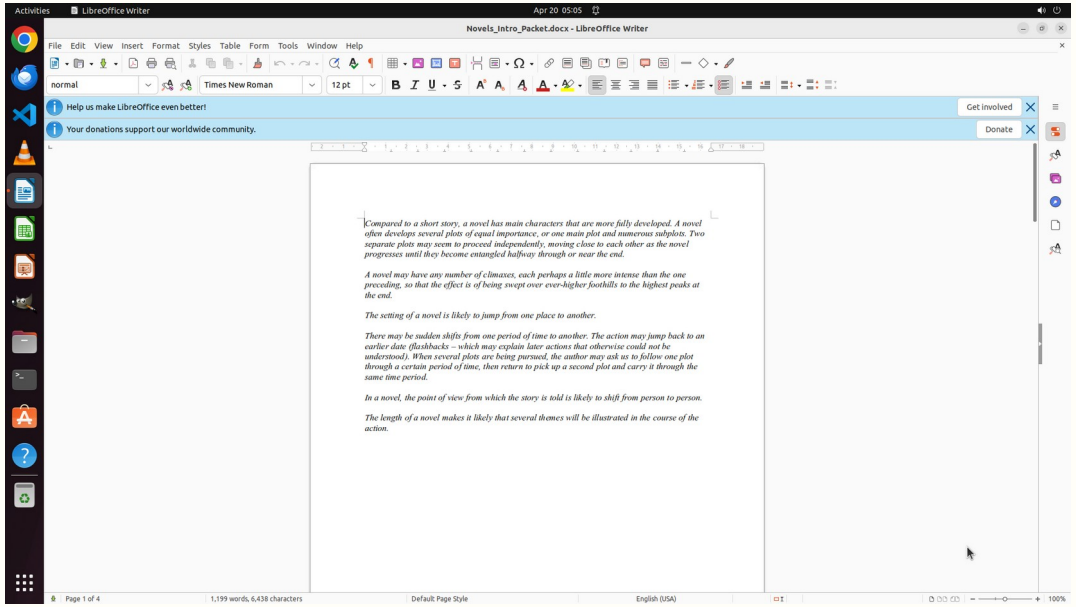
訳：サッカークラブのリストの 1 行目と 2 行目に取り消し線を付ける。

採点：保存した PPTX を参照成果物と照合する。

XLANG Lab. OSWorld-Verified / libreoffice_impress / 550ce7e7-747b-495f-b122-acdc4d0b8e54 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/libreoffice_impress/550ce7e7-747b-495f-b122-acdc4d0b8e54.json

追加例 8 ：最初の 2 段落を倍の行間にする

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / 0810415c-bde4-4443-9047-d5f70165a697 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

追加例 8 ：操作の依頼と採点

操作指示（配布原文・全文）

> Make the line spacing of first two paragraph into double line spacing

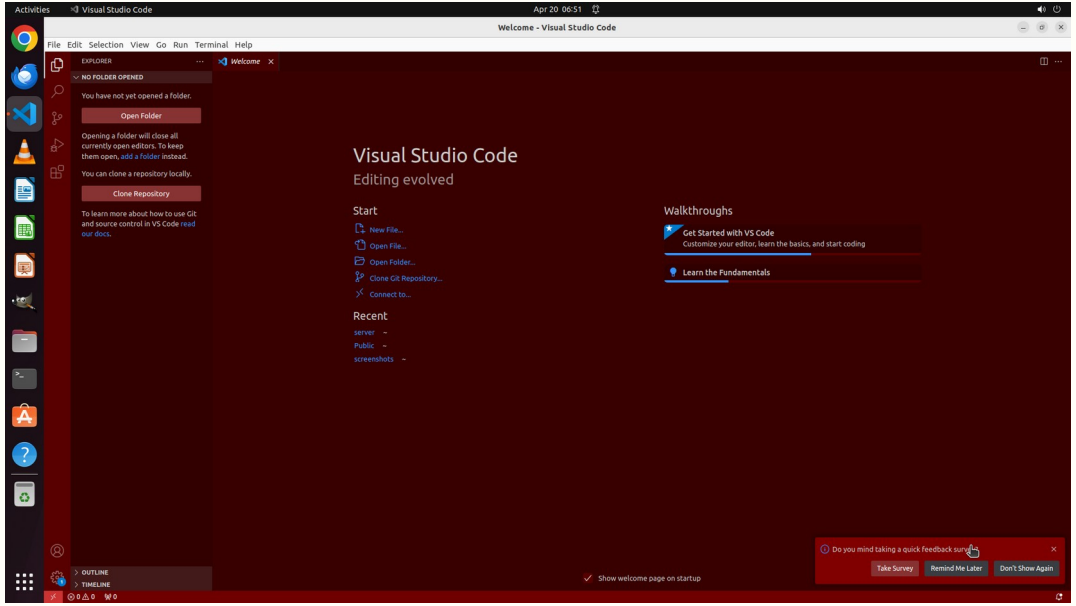
訳：最初の 2 段落をダブルスペースにする。

採点：二つの許容される参照文書と行間を比べる。

XLANG Lab. OSWorld-Verified / libreoffice_writer / 0810415c-bde4-4443-9047-d5f70165a697 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/libreoffice_writer/0810415c-bde4-4443-9047-d5f70165a697.json

追加例 9 ： VS Code のテーマを変える

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / 982d12a5-beab-424f-8d38-d2a48429e511 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

追加例 9 ：操作の依頼と採点

操作指示（配布原文・全文）

> Please help me change the color theme of VS Code to Visual Studio Dark.

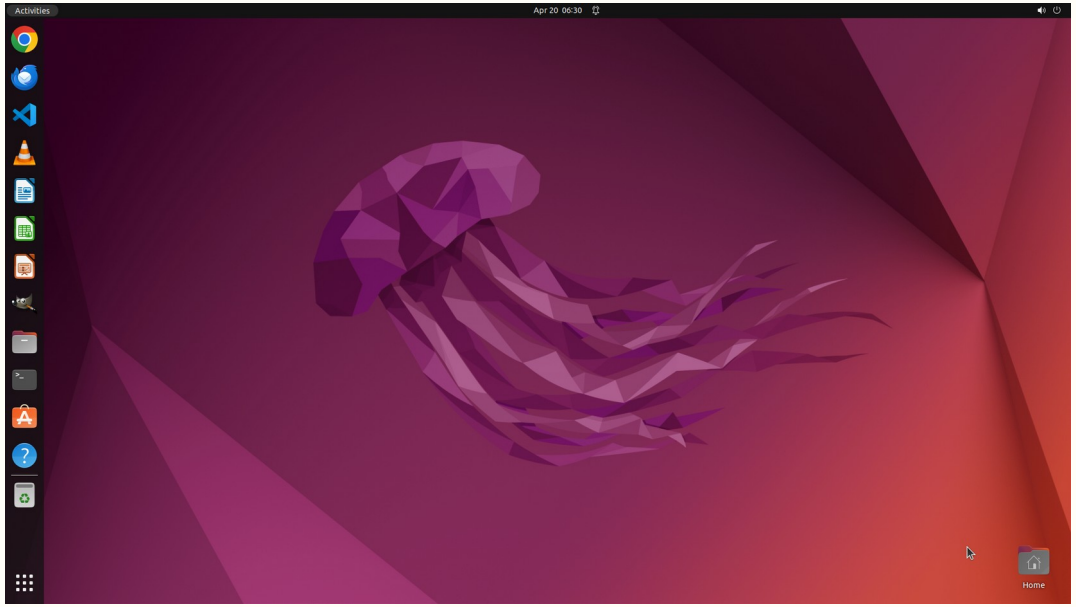
訳：配色テーマを Visual Studio Dark へ変更する。

採点：設定ファイルのテーマ名を確認する。

XLANG Lab. OSWorld-Verified / vs_code / 982d12a5-beab-424f-8d38-d2a48429e511 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/vs_code/982d12a5-beab-424f-8d38-d2a48429e511.json

追加例 10 ：実行不能な Python4 への変更

公式公開軌跡の初期画面（ step_0 ）



XLANG Lab. OSWorld-Verified: OpenAPA 公開軌跡 / 初期画面 step_0 / c288e301-e626-4b98-a1ab-159dcb162af5 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

追加例 10 ：操作の依頼と採点

操作指示（配布原文・全文）

> Please set the default Python version to Python4 on my Ubuntu system.

訳： Ubuntu の標準 Python を Python4 に変更する。

採点：配布では実行不能課題。 FAIL で終了すると 1 点。

XLANG Lab. OSWorld-Verified / os / c288e301-e626-4b98-a1ab-159dcb162af5 。
https://github.com/xlang-ai/OSWorld/blob/main/evaluation_examples/examples/os/c288e301-e626-4b98-a1ab-159dcb162af5.json

2. 課題定義と構成の詳細

課題 JSON に含まれる主な情報

項目	役割
instruction	エージェントに渡す自然言語の依頼
snapshot	初期状態を作る基準の VM 状態
config	ファイルの取得・起動などの準備
related_apps	課題に関連するアプリ
evaluator	成果の取得方法、参照値、採点関数

XLANG Lab (2026 年 10 月参照). OSWorld: 公開の課題定義・環境・エージェント実装。
https://github.com/xlang-ai/OSWorld

単一アプリ課題の内訳：オフィスと日常操作

アプリ	課題数
LibreOffice Calc	47
LibreOffice Impress	47
LibreOffice Writer	23
Chrome	46
VLC	17
Thunderbird	15

XLANG Lab. OSWorld: test_all.json / test_nogdrive.json. 2026-10-17 取得改訂。
https://github.com/xlang-ai/OSWorld/tree/main/evaluation_examples

専門ツール・ OS ・複数アプリの内訳

区分	課題数
GIMP	26
VS Code	23
OS 操作	24
複数アプリ（全体版）	101
複数アプリ（ Google Drive を除く）	93

XLANG Lab. OSWorld: test_all.json / test_nogdrive.json. 2026-10-17 取得改訂。
https://github.com/xlang-ai/OSWorld/tree/main/evaluation_examples

複数の採点と、実行不能な課題の終了

- 複数の採点関数を組み合わせられる。 AND は 0 点があれば 0 点、すべて正なら平均。 OR は最大値を採る。
- ダブルスペースの課題は、段落間の空行も変更する参照文書と、変更しない参照文書の二つを許容する。
- 実行不能課題は、 FAIL で終了すると 1 点。追加例 10 の Python4 への変更も、この形式。

XLANG Lab. OSWorld: desktop_env.py / evaluate. 最終状態からの採点。
https://github.com/xlang-ai/OSWorld/blob/main/desktop_env/desktop_env.py

全体版・ 361 課題版・小規模版を選ぶ

- test_all.json は 369 課題、 test_nogdrive.json は 361 課題。後者は、 Google Drive の操作を含む 8 課題を全体版から除く。
- test_small.json は、実装の確認などに使える 39 課題の一覧。各課題の JSON 、初期ファイル、参照成果物はそれぞれの配布先から取得する。
- 実行には VM とエージェントの設定が必要。公式リポジトリは VMware 、 Docker 、 AWS などの手順を案内する。

XLANG Lab (2026 年 10 月参照). OSWorld: 公開の課題定義・環境・エージェント実装。
https://github.com/xlang-ai/OSWorld

コード、入力ファイル、実行ログの配布先

- 環境と課題定義は GitHub の OSWorld リポジトリにあり、Apache 2.0 で公開される。課題 JSON から必要なファイルへの URL をたどれる。
- 入力と参照成果物は ubuntu_osworld_file_cache 、操作ログは ubuntu_osworld_verified_trajs で配布。後者のデータカードは MIT を指定する。
- この資料の画面は公開ログの step_0 。作業の正解条件はログ中の成否ラベルから推測せず、課題 JSON と採点コードを確認した。

XLANG Lab (2026 年 10 月参照). OSWorld-Verified Model Trajectories. 公開軌跡 / MIT 。
https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs

3. 制作機関と参考文献

XLANG Lab を中心とする、実行環境の共同制作

- 原著の第一著者は Tianbao Xie 、最終著者は Tao Yu 。香港大学、 CMU 、 Salesforce Research 、 Waterloo 大学の研究者が参加した。
- 2024 年の NeurIPS で発表。自然言語の依頼から、画面の理解、操作、成果物の検査までを、実際の PC 環境でつなぐ。
- Verified 更新は XLANG Lab と共同研究者・利用機関による改修。入力と採点器の修正を公開し、モデルの評価ログも継続して配布する。

Xie et al. (2024). OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments. NeurIPS. https://arxiv.org/abs/2404.07972

参考文献

OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments

Tianbao Xie et al. / NeurIPS 2024

実行環境の設計、 369 課題の収集・作成、初期評価を説明する。

https://arxiv.org/abs/2404.07972

Introducing OSWorld-Verified

Tianbao Xie et al. / XLANG Lab / 2025-07-28

環境、指示、採点器の改修と、検証済み評価の運営を説明する。

https://xlang.ai/blog/osworld-verified

参考文献

OSWorld: Code, Tasks and Evaluation Environment

XLANG Lab / GitHub / 2026 年 10 月参照 / Apache 2.0

課題 JSON 、準備・採点の実装、エージェントと実行手順を公開する。

https://github.com/xlang-ai/OSWorld

Ubuntu OSWorld File Cache

XLANG Lab / Hugging Face / 2026 年 10 月参照

課題を始めるための資料と、成果物を検査する参照ファイルを配布する。

https://huggingface.co/datasets/xlangai/ubuntu_osworld_file_cache

参考文献

OSWorld-Verified Results

OSWorld team / 公式サイトの評価表 / 2026 年 10 月参照

モデル・制御実装、ステップ数、ツール条件、提出日の対応を確認できる。

https://github.com/os-world/os-world.github.io/blob/main/static/data/osworld_verified_results.xlsx

OSWorld-Verified Model Trajectories

XLANG Lab / Hugging Face / 2026 年 10 月参照 / MIT

操作の初期画面と各ステップ、指示、ログ、採点結果を配布する。

https://huggingface.co/datasets/xlangai/ubuntu_osworld_verified_trajs