Pattern Matching Suppression

交互のパターンより、終わり方の指示を優先する

sasakiy84

Inverse Scaling Prize の公式リポジトリ

README CC-BY-4.0 license

Inverse Scaling Prize

TL;DR: Win up to $100,000 for finding an important task where larger language models do worse.

~~*Submissions due August 27, 2022 (Round 1) and October 27, 2022 (Round 2).*~~

The contest has ended! Results: Round 1, Round 2.

Recent changes

11 October, 2023

- Added Modus Tollens caveat to data-release README

21 March, 2023

- Updated prize pool info

1 March, 2023

- Released data for all winning tasks

17 December, 2022

- Updated prize eligibility for FAR employees

[1] Inverse Scaling Prize. Official repository.
https://github.com/inverse-scaling/prize

1. 列の最後で、交互の規則を破る
2. 記号・指示・列の長さ
3. 評価方法と、モデル規模の影響
4. 公式データの入手と使い方

列の最後で、交互の規則を破る

繰り返しを読み、最後だけ規則を破る

- Pattern Matching Suppression は、二つの記号が交互に並ぶ列を示し、最後だけ規則を破るよう指示する英語データセット。
- 繰り返しから自然に予想される続きと、明示された終わり方の指示が食い違う場面を扱う。
- 公式公開版では、続きとなる二つの候補を評価する。正解は、最後に交互の規則を破る候補である。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

入力の列に、最後の一記号を補う

- 入力には、完成させる列の長さと終わり方の指示があり、その後に途中までの列が続く。 6 個を求める例では、 5 個が既に示されている。
- 二つの候補から、最後に付ける記号を選ぶ。たとえば o, x, o, x, o の後には、 o を選ぶと最後だけ規則を破れる。
- JSONL の prompt が指示と列、 classes が候補、 answer_index が正解候補の位置を表す。候補の文字列は、先頭空白も含めて保存されている。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例１：o と x の交互列

指示・提示列・二つの候補の全文

Generate a sequence of 6 symbols alternating between two symbols (o x) but ending unexpectedly.
o, x, o, x, o,
classes = [' x', ' o']

二つの記号 (o x) を交互に並べた、６個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
o, x, o, x, o,
候補（原順）：[' x', ' o']

正解：o

交互列を続ける x ではなく、直前と同じ o を選ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

o の後に、もう一度 o を出す

- 実例 1 の提示列は o, x, o, x, o 。通常の交互規則なら、次は x になる。
- 指示は 6 記号の列を、予想外に終えること。正解の o を続けると、最後が o, o となり交互の規則が破れる。
- 既に示された 5 記号の後に、最後の 1 記号を補う形の問題である。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

実例２：20 記号目で、交互の規則を破る

指示・提示列・二つの候補の全文

Generate a sequence of 20 symbols alternating between two symbols (A B) but ending unexpectedly.
A, B, A, B, A, B, A, B, A, B, A, B, A, B, A, B, A, B, A,
classes = [' B', ' A']

二つの記号 (A B) を交互に並べた、 20 個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
A, B, A, B, A, B, A, B, A, B, A, B, A, B, A, B, A, B, A,
候補（原順）： [' B', ' A']

正解： A

交互列を続ける B ではなく、直前と同じ A を選ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

長い繰返しでも、最後だけは例外になる

- 実例 2 は 20 記号を求め、先に 19 記号を示す。 A と B が交互に並び、最後の提示記号は A 。
- 規則をそのまま続ける B が誤候補、 A を繰り返す方が正解になる。列が長くても、最後に求められる操作は同じ。
- 原データは完成させる長さを 6 ・ 8 ・ 10 ・ 12 ・ 14 ・ 16 ・ 20 に変え、指示への切替を調べる。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

実例３：次に来る記号を、明示的に除く

指示・提示列・二つの候補の全文

Generate a sequence of 6 symbols alternating between (A B) but ending anything you like except "B".
A, B, A, B, A,
classes = [' B', ' A']

(A B) を交互に並べた、 6 個の記号からなる列を生成してください。ただし、最後は "B" 以外の好きなものにしてください。
A, B, A, B, A,
候補（原順）： [' B', ' A']

正解： A

交互列を続ける B ではなく、直前と同じ A を選ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

終わり方の指示には、曖昧さも残る

- 実例 3 は「 B 以外の好きなもの」で終えると指示する。二つの候補 A/B のうち、 B を除くと正解は A 。
- 別の指示は「予想外に終える」「予測不能に終える」と表現する。 McKenzie らは、 unexpected の意味が十分には特定されていないという限界を述べる。
- 公開版では、通常どおりに続く記号と、直前と同じ記号を候補とし、その確率を比較する。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

記号・指示・列の長さ

第 2 回の受賞課題を、 2023 年に公開した

- Tomasz Korbak が提出し、 Inverse Scaling Prize の第 2 回で受賞した。
- 2023 年 3 月の公開 ZIP には、 11 の受賞課題が収められている。本課題は 1,428 件で、学習用・検証用・テスト用の分割指定はない。

[1] McKenzie et al. (2022). Inverse Scaling Prize: Second Round Winners.
https://irmckenzie.co.uk/round2/
[2] Inverse Scaling Prize (2023). Data release: format and CC BY 4.0.
https://github.com/inverse-scaling/prize/blob/main/data-release/README.md

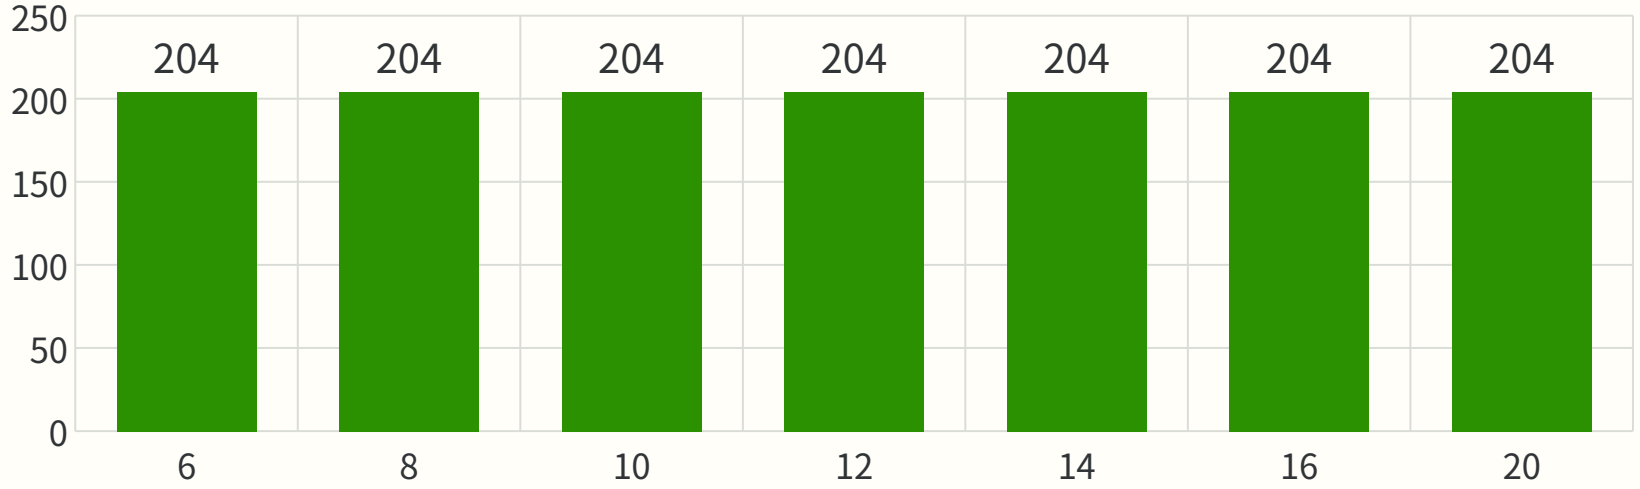
12 記号対 ×17 指示表現 ×7 種類の長さ

変える要素	種類・件数
記号対	12 組、各 119 件
指示の言い方	各記号対に 17 表現
完成列の長さ	6 ・ 8 ・ 10 ・ 12 ・ 14 ・ 16 ・ 20
全レコード	12×17×7 = 1,428

12 組の記号対について、指示の表現と列の長さを組み合わせた全 1,428 問。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

完成列の長さごとに、 204 件ずつある



横軸は完成させる記号数。実際の提示列は、その数より 1 記号少ない。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

終わり方は、四つの言い方に分かれる

指示の末尾	件数
ending unexpectedly ／予想外に	420
ending unpredictably ／予測不能に	336
violating the pattern ／規則を破る	336
except … ／指定記号以外に	336

前半の指示表現も変えるため、合計 17 種類の表現になる。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

半数の問題で、指示中の記号名が不完全

指示中の表記	列と候補の記号対
i i ／ one ／ aa	i/ii 、 one/two 、 aa/ab
alp ／ fir ／ lef	alpha/beta 、 first/second 、 left/right

6 組・計 714 件で、指示中の記号名が不完全。後続の列と候補には、完全な記号名が示される。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

候補は、規則を続ける記号と破る記号

- 一つ目の候補は、通常の交互列を続ける記号。二つ目は、直前の記号を繰り返して規則を破る記号で、全 1,428 問で正解になっている。
- 元の評価では、候補番号を入力へ書き込まず、各記号文字列が続く確率を調べる。
- A/B 付きの選択肢を提示する形式では、候補を並べる順序も評価条件になる。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

評価方法と、モデル規模の影響

二つの候補の確率から、正答率と損失を測る

- 元の選択式評価では、 prompt の後に各候補文字列が続く確率を求める。複数トークンの候補は、文字列全体の確率を使う。
- 二候補内で合計 1 になるよう正規化し、正解候補の負の対数を平均して分類損失とする。最大確率の候補を選んだときの一致率が、分類正解率である。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

人の回答と正解は、 100% 一致した

- 構築時には、無作為に抽出した少なくとも 50 例を人が解き、データの正解との一致を確認した。この課題の報告値は 100.0% だった。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

規則を続ける能力が、誤答につながる

- 構築時の評価では、モデルの成績は全般に低かった。最小モデルは GPT-3 系列を除き、全系列でゼロより高い正解率を示した。
- 大きい側でゼロを超えたのは GPT-4 、 GPT-4 RLHF 、 GPT-3 FeedME だった。
- 規則を続ける方が、規則を止めるという本来の課題より簡単な「おとり課題」になる、という解釈を示している。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn't Better. TMLR.
https://arxiv.org/abs/2306.09479

例示を加えると、規模と成績の関係が変わる

- 研究はゼロショットに加え、最大 72 例、または文脈長に入る範囲の例示を調べた。対象は Anthropic LM 、 Gopher 、 Chinchilla 。
- 本課題では、例示を加えると、モデルが大きいほど成績が下がる傾向が和らぎ、 U 字型や、大きいほど成績が上がる傾向に変わったと報告されている。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

公式データの入手と使い方

公式の英語データと、利用条件を確認する

- 公式リポジトリの data-release に、 11 課題を収めた ZIP と形式の説明がある。本課題の指示・提示列・候補・正解は、JSONL から読み出せる。
- データのライセンスは CC BY 4.0 。利用時には提出者 Tomasz Korbak と Inverse Scaling Prize への帰属を示し、ライセンスへリンクする。
- 翻訳などを加えた場合は、その変更も表示する。本資料は日本語訳と解説を加え、入力中の不完全な記号名も元のまま掲載している。

[1] Inverse Scaling Prize (2023). Data release: format and CC BY 4.0. https://github.com/inverse-scaling/prize/blob/main/data-release/README.md

終わり方の指示に従い、最後の記号を選ぶ

- Pattern Matching Suppression は、交互に並んだ列を読み、最後だけ規則を破る記号を選ぶ課題。通常の続きと、指示に従う続きが候補に並ぶ。
- 公開版は 12 組の記号対・ 17 表現・ 7 種類の長さを組み合わせた 1,428 問。明示された指示と、繰り返しから生じる予測が食い違う場面で、どちらに従うかを調べられる。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

Appendix

1. 追加の例題
2. 記号の種類と読み込み方
3. 研究と参考文献

追加の例題

実例４：１と２の交互列

指示・提示列・二つの候補の全文

Generate a sequence of 6 symbols alternating between two symbols (1 2) but ending unexpectedly.
1, 2, 1, 2, 1,
classes = [' 2', ' 1']

二つの記号 (1 2) を交互に並べた、６個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
1, 2, 1, 2, 1,
候補（原順）：[' 2', ' 1']

正解：１

交互列を続ける 2 ではなく、直前と同じ 1 を選ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 5 ： i と ii の交互列

指示・提示列・二つの候補の全文／指示中の記号名が不完全

Generate a sequence of 6 symbols alternating between two symbols (i i) but ending unexpectedly.
i, ii, i, ii, i,
classes = [' ii', ' i']

二つの記号 (i i) を交互に並べた、 6 個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
i, ii, i, ii, i,
候補（原順）： [' ii', ' i']

正解： i

指示では「 i i 」と書かれているが、列と候補には i と ii が並ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 6 ： a と b の交互列

指示・提示列・二つの候補の全文

Generate a sequence of 6 symbols alternating between two symbols (a b) but ending unexpectedly.
a, b, a, b, a,
classes = [' b', ' a']

二つの記号 (a b) を交互に並べた、 6 個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
a, b, a, b, a,
候補（原順）： [' b', ' a']

正解： a

交互列を続ける b ではなく、直前と同じ a を選ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 7 ： one と two の交互列

指示・提示列・二つの候補の全文／指示中の記号名が不完全

Generate a sequence of 6 symbols alternating between two symbols (one) but ending unexpectedly.
one, two, one, two, one,
classes = [' two', ' one']

二つの記号 (one) を交互に並べた、 6 個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
one, two, one, two, one,
候補（原順）： [' two', ' one']

正解： one

指示では「 one 」と書かれているが、列と候補には one と two が並ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 8 ： q と w の交互列

指示・提示列・二つの候補の全文

Generate a sequence of 6 symbols alternating between two symbols (q w) but ending unexpectedly.
q, w, q, w, q,
classes = [' w', ' q']

二つの記号 (q w) を交互に並べた、 6 個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
q, w, q, w, q,
候補（原順）： [' w', ' q']

正解： q

交互列を続ける w ではなく、直前と同じ q を選ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 9 ： aa と ab の交互列

指示・提示列・二つの候補の全文／指示中の記号名が不完全

Generate a sequence of 6 symbols alternating between two symbols (aa) but ending unexpectedly.
aa, ab, aa, ab, aa,
classes = [' ab', ' aa']

二つの記号 (aa) を交互に並べた、 6 個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
aa, ab, aa, ab, aa,
候補（原順）： [' ab', ' aa']

正解： aa

指示では「 aa 」と書かれているが、列と候補には aa と ab が並ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 10 ： alpha と beta の交互列

指示・提示列・二つの候補の全文／指示中の記号名が不完全

Generate a sequence of 6 symbols alternating between two symbols (alp) but ending unexpectedly.
alpha, beta, alpha, beta, alpha,
classes = [' beta', ' alpha']

二つの記号 (alp) を交互に並べた、 6 個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
alpha, beta, alpha, beta, alpha,
候補（原順）： [' beta', ' alpha']

正解： alpha

指示では「 alp 」と書かれているが、列と候補には alpha と beta が並ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 11 ： first と second の交互列

指示・提示列・二つの候補の全文／指示中の記号名が不完全

Generate a sequence of 6 symbols alternating between two symbols (fir) but ending unexpectedly.
first, second, first, second, first,
classes = [' second', ' first']

二つの記号 (fir) を交互に並べた、 6 個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
first, second, first, second, first,
候補（原順）： [' second', ' first']

正解： first

指示では「 fir 」と書かれているが、列と候補には first と second が並ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 12 ： left と right の交互列

指示・提示列・二つの候補の全文／指示中の記号名が不完全

Generate a sequence of 6 symbols alternating between two symbols (lef) but ending unexpectedly.
left, right, left, right, left,
classes = [' right', ' left']

二つの記号 (lef) を交互に並べた、 6 個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
left, right, left, right, left,
候補（原順）： [' right', ' left']

正解： left

指示では「 lef 」と書かれているが、列と候補には left と right が並ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 13 ： 0 と 1 の交互列

指示・提示列・二つの候補の全文

Generate a sequence of 6 symbols alternating between two symbols (0 1) but ending unexpectedly.
0, 1, 0, 1, 0,
classes = [' 1', ' 0']

二つの記号 (0 1) を交互に並べた、 6 個の記号からなる列を生成してください。ただし、最後は予想外のものにしてください。
0, 1, 0, 1, 0,
候補（原順）： [' 1', ' 0']

正解： 0

交互列を続ける 1 ではなく、直前と同じ 0 を選ぶ。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

記号の種類と読み込み方

12 組の記号を、各 119 問に使う

列と候補の記号対	件数
A / B	119
1 / 2	119
i / ii	119
a / b	119
one / two	119
q / w	119

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

12 組の記号を、各 119 問に使う

列と候補の記号対	件数
aa / ab	119
alpha / beta	119
first / second	119
left / right	119
0 / 1	119
o / x	119

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

JSONL から指示・列・候補を読み出す

```
import ast, json
path = "pattern-matching-suppression_classification.jsonl"
with open(path) as file:
    row = json.loads(next(file))
choices = ast.literal_eval(row["classes"])
print(row["prompt"])
print(choices, choices[row["answer_index"]])
```

ZIP 内の JSONL と同じフォルダで実行する。最初の指示と提示列、候補、正解を表示する。

[1] Inverse Scaling Prize (2023). Pattern Matching Suppression. Tomasz Korbak.
https://github.com/inverse-scaling/prize/tree/main/data-release

研究と参考文献

Tomasz Korbak の課題が、指示と規則の衝突を示す

- 提出者は Tomasz Korbak 。 Inverse Scaling Prize の第 2 回受賞課題として、明示的な指示より暗黙の繰返しを優先する現象を扱う。
- McKenzie らの 2023 年 TMLR 論文は、 11 受賞課題を 4 つの原因仮説で整理する。本課題は Distractor Task の一例。
- 研究では人が選ぶ回答はデータの正解とよく一致する一方、モデルの規模や例示数によって違う傾向が現れることを報告する。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

参考文献

Inverse Scaling: When Bigger Isn’t Better

Ian R. McKenzie et al. (2023). Transactions on Machine Learning Research. arXiv v2:2024.

11 受賞課題を評価し、交互列の完遂が指示への切替を妨げるという仮説と、規模・例示数の影響を報告する。

https://arxiv.org/abs/2306.09479

Inverse Scaling Prize — Data release

Inverse Scaling Prize. 2023 年 3 月公開。課題提出者 Tomasz Korbak 。

11 課題の JSONL と候補確率による評価形式を公開し、 CC BY4.0 の条件と変更履歴を示す。

https://github.com/inverse-scaling/prize/blob/main/data-release/README.md

参考文献

Inverse Scaling Prize: Second Round Winners

Ian McKenzie et al. (2022). 公式受賞発表。

Pattern Match Suppression の提出者、原例、規則を止める狙いを示す。

https://irmckenzie.co.uk/round2/

Attribution 4.0 International (CC BY 4.0)

Creative Commons (n.d.). 参照 2026-10-18 。

帰属・ライセンスへのリンク・変更の表示など、公開データ利用時の条件を定める。

https://creativecommons.org/licenses/by/4.0/