QuAC

Question Answering in Context

知らない話題を会話で掘り下げる読解課題

sasakiy84

公式サイト



[1] QuAC. 公式サイト。 2026-10-18 参照。 https://quac.ai/

1. 会話で質問がつながる
2. 収集・注釈とデータの全体像
3. 採点と HELM での使われ方
4. 性能の変化と入手方法

会話で質問がつながる

質問者には、本文が見えていない

- 学生役は、 Wikipedia の記事名・冒頭段落・節の見出しを見て、知りたいことを質問する。
- 教師役だけが節の本文を読み、答えの範囲を選ぶ。二人は、その場で質問と回答を重ねる。
- 答えを知ってから質問を書く方式に比べ、探索的な追質問や、本文に答えのない質問が生まれる。

[1] Choi et al. (2018), QuAC: Question Answering in Context. EMNLP, 2174–2184. https://aclanthology.org/D18-1241/

追質問は、直前の回答に依存する

- 「ほかには？」「それはいつ？」のような質問は、その一文だけでは意味が決まらない。
- 記事本文に加え、誰について何を話してきたかを使って答える。
- 以下では、異なる 3 対話から、本文の連続抜粋・直前の 1 往復・質問と教師の回答を示す。

[1] Choi et al. (2018), QuAC: Question Answering in Context. EMNLP, 2174–2184. https://aclanthology.org/D18-1241/

実例１：代名詞の指す人物を尋ねる

原文（本文抜粋）： Cheap Trick ／ Early years (1969-1974)

In 1961, Rick Nielsen began playing locally in Rockford, Illinois using an ever-increasing collection of rare and valuable guitars. He formed several local bands with names like The Boyz and The Grim Reapers.
Previous Q: Who started the band?
Previous A: He formed several local bands
Question: Who formed several local bands?

Rick Nielsen

[1] QuAC, val_v0.2.json. 公開開発データ。 C_867b2cb2cb1a45f4ac34f6ba35cba82d_1_q#2 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例１：代名詞の指す人物を尋ねる（訳）

訳（本文抜粋）： Cheap Trick ／ Early years (1969-1974)

1961 年、リック・ニールセンは、珍しく価値のあるギターのコレクションを増やしながら、イリノイ州ロックフォードの地元で演奏を始めた。 The Boyz や The Grim Reapers といった名のバンドをいくつも結成した。
直前の質問：バンドを始めたのは誰か。
直前の回答：地元でいくつものバンドを結成した。
質問：地元でいくつものバンドを結成したのは誰か。

リック・ニールセン

[1] QuAC, val_v0.2.json. 公開開発データ。 C_867b2cb2cb1a45f4ac34f6ba35cba82d_1_q#2 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

答えの範囲と、自然な返答は異なる

- 「地元でいくつものバンドを結成したのは誰か」に、本文から Rick Nielsen を選ぶ。
- 教師役は自由な要約を作らず、本文中の連続した文字列を回答にする。
- 原文の二重空白や、文の一部だけを選んだ回答も、配布データのまま保存している。

[1] QuAC, val_v0.2.json. 公開開発データ。 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例２：はい・いいえと根拠の範囲

原文（本文抜粋）：John Hartson ／ Luton Town and Arsenal

In January 1995, at 19, he joined Arsenal for PS2.5 million, a British record fee for a teenage player at the time.
Previous Q: In what year did John Hartson join Luton Town?
Previous A: 1992
Question: Did John Hartson play for Arsenal?

In January 1995, at 19, he joined Arsenal

[1] QuAC, val_v0.2.json. 公開開発データ。 C_0010955f5148430081e67b941dc3b885_1_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例２：はい・いいえと根拠の範囲（訳）

訳（本文抜粋）：John Hartson ／ Luton Town and Arsenal

1995 年 1 月、 19 歳でアーセナルに移籍した。移籍金 250 万ポンドは、当時、 10 代の選手としては英国最高額だった。
直前の質問：ジョン・ハートソンがルートン・タウンに加入したのは何年か。
直前の回答： 1992 年
質問：ジョン・ハートソンはアーセナルでプレーしたか。

1995 年 1 月、 19 歳でアーセナルに移籍した

[1] QuAC, val_v0.2.json. 公開開発データ。 C_0010955f5148430081e67b941dc3b885_1_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

回答には三つの種類の情報がある

項目	この例の注釈
回答範囲	In January 1995, at 19, he joined Arsenal
yes ／ no	y ：はい
追質問の勧め	y ：続けることを勧める

yes ／ no だけでなく、根拠となる本文の範囲も選ぶ。

[1] QuAC, val_v0.2.json. 公開開発データ。 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例３：書かれていなければ答えない

原文（本文抜粋）：William Herschel ／ Further discoveries

In his later career, Herschel discovered two moons of Saturn, Mimas and Enceladus; as well as two moons of Uranus, Titania and Oberon.
Previous Q: What is one astronomy discovery that was found by William Herschel?
Previous A: Herschel discovered two moons of Saturn, Mimas and Enceladus;
Question: Did he teach at a university?

CANNOTANSWER

[1] QuAC, val_v0.2.json. 公開開発データ。 C_761e993c8658494bba469dce01fd7b15_0_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例３：書かれていなければ答えない（訳）

訳（本文抜粋）：William Herschel ／ Further discoveries

晩年の研究で、ハーシェルは土星の二つの衛星ミマスとエンケラドゥス、および天王星の二つの衛星ティタニアとオベロンを発見した。
直前の質問：ウィリアム・ハーシェルによる天文学上の発見を一つ挙げると何か。
直前の回答：ハーシェルは土星の二つの衛星ミマスとエンケラドゥスを発見した。
質問：彼は大学で教えたことがあるか。

回答不能（ CANNOTANSWER ）

[1] QuAC, val_v0.2.json. 公開開発データ。 C_761e993c8658494bba469dce01fd7b15_0_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

回答不能は、本文全体についての注釈

- 大学で教えたかという質問に、教師は CANNOTANSWER を選んだ。
- 表示した天文学の抜粋だけで、答えがないと判定したのではない。教師は節の全文を読んでいる。
- 実際の入力には、記事の背景、節の全文、会話履歴が含まれる。表示範囲と入力全体を区別する。

[1] QuAC, val_v0.2.json. 公開開発データ。 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

収集・注釈とデータの全体像

見える情報を変えて、対話を集める

- 2018 年に公開。学生役と教師役の 2 人が、 Amazon Mechanical Turk でリアルタイムに対話した。
- 学生役が記事の全文を知らないことで、何を聞けばよいかも対話しながら決める。
- 人物を中心とする Wikipedia の節を使う。話題や人物の分布は百科事典全体を均等に覆うものではない。

[1] Choi et al. (2018), QuAC: Question Answering in Context. EMNLP, 2174–2184. https://aclanthology.org/D18-1241/

教師は範囲と対話用の印を選ぶ

- 設計上は 30 トークン以下の連続した範囲を回答とし、答えがなければ CANNOTANSWER を選ぶ。
- yes ／ no ／どちらでもないと、追質問を勧める／どちらともいえない／勧めないの印も付ける。
- 対話は最大 12 問。相手が終了したときや、回答不能が 2 問を超えたときにも終わる。

[1] Choi et al. (2018), QuAC: Question Answering in Context. EMNLP, 2174–2184. https://aclanthology.org/D18-1241/

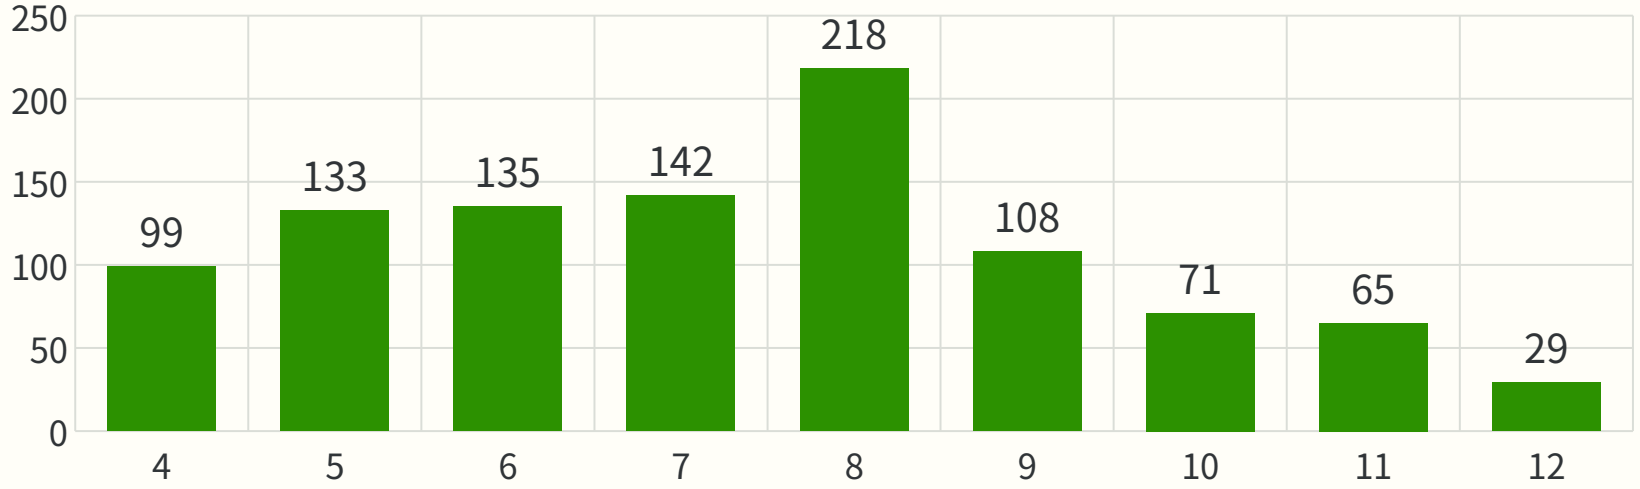
公開されている二つの集合

集合	対話数	質問数
学習	11,567	83,568
開発	1,000	7,354
テスト（本文非公開）	1,002	7,353

学習・開発は公開 v0.2 を全件集計。テストは 2018 年の報告値。

[1] Choi et al. (2018), QuAC: Question Answering in Context. EMNLP, 2174–2184. https://aclanthology.org/D18-1241/

開発集合は 8 問の対話が最も多い



横軸： 1 対話の質問数。縦軸：対話数。開発 1,000 対話を全件集計。

[1] QuAC, val_v0.2.json. 公開開発データ。 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

回答不能は例外ではない

公開集合	教師の回答不能	割合
学習 83,568 問	14,459 問	17.3%
開発 7,354 問	1,486 問	20.2%

教師の回答から集計。学習の論文値 20.2% とは差がある。

[1] QuAC, val_v0.2.json. 公開開発データ。 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

開発の参照回答は一律 5 件ではない

- 公開開発データは、質問ごとに元の回答を含む 1 〜 5 件の参照回答を持つ。
- 5 件ある質問が 3,953 問、 4 件が 2,086 問、 3 件が 1,175 問。 2 件は 132 問、 1 件は 8 問。
- 複数の人が選ぶ範囲には揺れがある。参照回答数や採点手順を固定の 5 件と決め付けない。

[1] QuAC, val_v0.2.json. 公開開発データ。 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

採点と HELM での使われ方

単語の重なりだけで終わらない採点

- 回答は英語の冠詞・句読点・大文字小文字を正規化し、単語の重なりから F1 を計算する。
- 複数参照では 1 件ずつ除き、残りとの最大 F1 を平均する。回答不能の票は先に整理する。
- 人同士の一致が低い質問を主指標から外し、人と同等以上に答えられた割合も測る。

[1] QuAC，公式評価コード。 https://s3.amazonaws.com/my89public/quac/scorer.py

HEQ は人との同等性を測る

指標	何を数えるか
F1	参照回答との単語の重なり
HEQ-Q	人の F1 以上になった質問の割合
HEQ-D	全質問で人の F1 以上になった対話の割合

主 F1 ・ HEQ は人同士の F1 が 40 未満の質問を除外。除外前の F1 All も報告。

[1] Choi et al. (2018), QuAC: Question Answering in Context. EMNLP, 2174–2184. https://aclanthology.org/D18-1241/

HELM は 1 対話から 1 問を評価する

- タイトル、記事冒頭、節の全文、会話の一部と質問を入力し、短い回答を生成させる。
- 公開開発 1,000 対話から 1 問ずつ選ぶ。最大 5 例を提示する設定だが、入力長で実提示数は減る。
- 通常の QuAC とは異なり、 1 対話の全質問や、 yes ／ no ・追質問の印を出力する課題ではない。

[1] Stanford CRFM, QuAC scenario. 公開評価入力 1,000 件とも照合。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/quac_scenario.py

公開実行では直前の 1 往復が抜ける

- HELM の実装は、評価対象の質問の一つ前の往復を履歴に含めていない。
- 例えば 5 問目を評価するときは、 1 〜 3 問目の質問・回答を入力し、 4 問目は省かれる。
- 公開評価入力 1,000 件を再現し、この形式と参照回答が全件一致した。省略による得点への影響は未測定。

[1] Stanford CRFM, QuAC scenario. 公開評価入力 1,000 件とも照合。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/quac_scenario.py

HELM の得点は公式 QuAC と区別する

条件	公式 QuAC	HELM
参照回答	1 件ずつ除いて平均	重複除去後の最大 F1
低一致の質問	主指標から除外	同じ除外は行わない
会話単位の評価	HEQ-D も測る	1 対話 1 問の生成評価

同名の F1 でも、対象質問と集計手順が一致しない。

[1] QuAC，公式評価コード。 https://s3.amazonaws.com/my89public/quac/scorer.py

HELM の F1 ：固定版の三つのモデル

モデル	F1	完全一致
OPT-175B	36.01	14.83
text-davinci-003	52.48	23.93
Llama 2 70B	48.44	26.80

開発 1,000 問。 OPT ・ davinci は 3 試行平均、 Llama 2 は 1 試行。値は % 。

[1] HELM Classic v0.4.0, QuAC. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/quac

得点差には入力条件も関係する

- 実際の提示例数は平均 0.94 ／ 3.44 ／ 3.20 例（ OPT ／ davinci ／ Llama 2 ）。最大 5 例が常に入るわけではない。
- OPT では入力の 1.6% が切り詰められた。残る二つのモデルは、この実行では 0% 。
- 2023 年 11 月公開の HELM Classic 固定版であり、 2026 年のモデル全体の順位ではない。

[1] HELM Classic v0.4.0, QuAC. 2023-11-17 の固定版。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/quac

性能の変化と入手方法

会話履歴を使うと成績が改善した

2018 年のテスト	F1 (%)	HEQ-D (%)
BiDAF++ ：履歴なし	50.2	2.2
BiDAF++ ：直前 2 往復	60.1	4.0
人の回答	81.1	100.0

QuAC の公式評価。人の HEQ-D は定義上 100 。 HELM とは採点条件が異なる。

[1] Choi et al. (2018), QuAC: Question Answering in Context. EMNLP, 2174–2184. https://aclanthology.org/D18-1241/

後のモデルでも対話全体は難しい

公式サイトの掲載モデル	F1 (%)	HEQ-D (%)
CKT-QA ensemble （2022-08）	76.3	17.9
CDQ-DeBERTa single （2022-02）	75.8	15.9

掲載日付きのテスト結果。高い質問別 F1 が、対話全体での同等性を保証するわけではない。

[1] QuAC. 公式サイト。 2026-10-18 参照。 https://quac.ai/

入手は公式サイトの公開ファイルから

- 学習・開発の JSON と公式評価コードが公開されている。非公開テストの評価は公式サイトを確認する。
- JSON には記事の背景、節本文、対話順、回答の開始位置、補助注釈が含まれる。
- データは CC BY-SA 4.0 。資料の抜粋・訳にも、出所と変更内容を記録した。

[1] QuAC. 公式サイト。 2026-10-18 参照。 https://quac.ai/

このデータで何が分かるか

- 本文に答えがあるだけでは足りない。代名詞や短い追質問を、話してきた内容につなげる必要がある。
- 質問ごとの正答と、対話を通じた安定した応答は別の見方になる。
- 利用時は、履歴をどこまで渡すか、回答不能をどう採点するかを明示する。

[1] Choi et al. (2018), QuAC: Question Answering in Context. EMNLP, 2174–2184. https://aclanthology.org/D18-1241/

Appendix

1. 追加の実例
2. 注釈と実行条件の補足
3. 研究と参考文献

追加の実例

実例４：影響の中身を掘り下げる

原文（本文抜粋）： Ursula K. Le Guin ／ Influences

In the mid-1950s, she read J. R. R. Tolkien's The Lord of the Rings, which had an enormous impact on her. But rather than making her want to follow in Tolkien's footsteps, it simply showed her what was possible with the fantasy genre.
Previous Q: what was her biggest influence?
Previous A: she read J. R. R. Tolkien's The Lord of the Rings, which had an enormous impact on her.
Question: what influence did it have?

it simply showed her what was possible with the fantasy genre.

[1] QuAC, val_v0.2.json. 公開開発データ。 C_420bfcf5d8b344a480ac654f08ee55ad_1_q#8 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例４：影響の中身を掘り下げる（訳）

訳（本文抜粋）： Ursula K. Le Guin ／ Influences

1950 年代半ば、ル＝グウィンはＪ・Ｒ・Ｒ・トールキンの「指輪物語」を読み、大きな影響を受けた。ただし、トールキンの足跡をたどりたいと思ったわけではない。ファンタジーというジャンルに何が可能なのかを示されたのだ。
直前の質問：彼女に最も大きな影響を与えたものは何か。
直前の回答：Ｊ・Ｒ・Ｒ・トールキンの「指輪物語」を読み、大きな影響を受けた。
質問：どのような影響があったのか。

ファンタジーというジャンルに何が可能なのかを示された

[1] QuAC, val_v0.2.json. 公開開発データ。 C_420bfcf5d8b344a480ac654f08ee55ad_1_q#8 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例５：短い追質問を解釈する

原文（本文抜粋）： Richard Wagner ／ Influence on music

Anton Bruckner and Hugo Wolf were greatly indebted to him, as were Cesar Franck, Henri Duparc, Ernest Chausson, Jules Massenet, Richard Strauss, Alexander von Zemlinsky, Hans Pfitzner and numerous others.
Previous Q: What else was known
Previous A: Anton Bruckner and Hugo Wolf were greatly indebted to him,
Question: Who else

as were Cesar Franck,

[1] QuAC, val_v0.2.json. 公開開発データ。 C_3a500c7651f44266a837bb7523590801_1_q#3 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例５：短い追質問を解釈する（訳）

訳（本文抜粋）： Richard Wagner ／ Influence on music

アントン・ブルックナーとフーゴ・ヴォルフは、彼から大きな影響を受けた。セザール・フランク、アンリ・デュパルク、エルネスト・ショーソン、ジュール・マスネ、リヒャルト・シュトラウス、アレクサンダー・フォン・ツェムリンスキー、ハンス・プフィッツナーら、多くの音楽家も同様だった。
直前の質問：ほかに何が分かっているか。
直前の回答：アントン・ブルックナーとフーゴ・ヴォルフは、彼から大きな影響を受けた。
質問：ほかには誰か。

セザール・フランクも同様だった

[1] QuAC, val_v0.2.json. 公開開発データ。 C_3a500c7651f44266a837bb7523590801_1_q#3 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例 6 ：年だけの答えにも文脈がある

原文（抜粋）： Sam Kinison

Kinison acquired much of his material from his difficult first two marriages, to Patricia Adkins (1975-1980) and Terry Marze (1981-1989).
Previous Q: who did he marry?
Previous A: Patricia Adkins (1975-1980)
Question: did they divorce?

1980

訳（抜粋）： Sam Kinison

キニソンは、パトリシア・アドキンス（ 1975 ～ 1980 年）とテリー・マーズ（ 1981 ～ 1989 年）との、困難を伴った最初の二度の結婚を、多くの芸の題材にした。
直前の質問：誰と結婚したのか。
直前の回答：パトリシア・アドキンス（ 1975 ～ 1980 年）
質問：二人は離婚したのか。

1980 年

[1] QuAC, val_v0.2.json. 公開開発データ。 C_c5451d72257c4c3d96e8b03362f6e051_1_q#2 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例７：引退後の別の活動を尋ねる

原文（本文抜粋）： Pedro Martínez ／ After retirement

In 2015, Martinez was hired by the MLB Network as a studio analyst and also released an autobiography, Pedro, which he coauthored with Michael Silverman of the Boston Herald.
Previous Q: What did Pedro Martinez do after he retired from baseball?
Previous A: Martinez joined the Boston Red Sox as a special assistant to general manager Ben Cherington.
Question: Did Martinez do anything else after he retired from baseball?

In 2015, Martinez was hired by the MLB Network as a studio analyst

[1] QuAC, val_v0.2.json. 公開開発データ。 C_7111b50cfc084f7aaf2aab3ea154f0ad_0_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例 7 ：引退後の別の活動を尋ねる（訳）

訳（本文抜粋）： Pedro Martínez ／ After retirement

2015 年、マルティネスは MLB ネットワークのスタジオ解説者に起用された。同年、ボストン・ヘラルド紙のマイケル・シルバーマンとの共著による自伝「 Pedro 」も刊行した。
直前の質問：ペドロ・マルティネスは野球選手を引退した後、何をしたか。
直前の回答：ボストン・レッドソックスに、ゼネラルマネジャーのベン・チェリントンを補佐する特別補佐として加わった。
質問：引退後に、ほかに何かしたか。

2015 年、 MLB ネットワークのスタジオ解説者に起用された

[1] QuAC, val_v0.2.json. 公開開発データ。 C_7111b50cfc084f7aaf2aab3ea154f0ad_0_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例８：組織を指す言い換えを読む

原文（本文抜粋）：William Shockley ／ Shockley Semiconductor

In 1956 Shockley moved from New Jersey to Mountain View, California to start Shockley Semiconductor Laboratory to live closer to his ailing mother in Palo Alto, California.
Previous Q: What did Shockley's semiconductor do?
Previous A: The company, a division of Beckman Instruments, Inc., was the first establishment working on silicon semiconductor devices in what came to be known as Silicon Valley.
Question: What year was the semiconductor made?

In 1956

[1] QuAC, val_v0.2.json. 公開開発データ。 C_0735e63bb67b49b9897e540f109ec967_0_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例 8 ：組織を指す言い換えを読む（訳）

訳（本文抜粋）： William Shockley ／ 質問の semiconductor は会社を指すと解釈

1956 年、ショックレーはニュージャージー州からカリフォルニア州マウンテンビューへ移り、ショックレー半導体研究所を設立した。パロアルトで病気療養中の母親の近くに住むためだった。
直前の質問：ショックレーの半導体の会社は何をしたのか。
直前の回答：ベックマン・インスツルメンツ社の一部門で、後にシリコンバレーと呼ばれる地域で、シリコン半導体デバイスに取り組んだ最初の事業所だった。
質問：その半導体の会社が設立されたのは何年か。

1956 年

[1] QuAC, val_v0.2.json. 公開開発データ。 C_0735e63bb67b49b9897e540f109ec967_0_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例９：反対運動の方法を尋ねる

原文（本文抜粋）： Phyllis Schlafly ／ Equal Rights Amendment

In Illinois, the anti-ERA activists used traditional symbols of the American housewife, and took homemade foods (bread, jams, apple pies, etc.) to the state legislators, with the slogans, "Preserve us from a congressional jam; Vote against the ERA sham" and "I am for Mom and apple pie."
Previous Q: what did Phyllis have to do with the Equal Rights Amendment?
Previous A: Schlafly focused political opposition to the ERA
Question: how did she oppose it?

In Illinois, the anti-ERA activists used traditional symbols of the American housewife,

[1] QuAC, val_v0.2.json. 公開開発データ。 C_b6f2f106bdee40d087e8ff4f6fb9f754_1_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例９：反対運動の方法を尋ねる（訳）

訳（本文抜粋）： Phyllis Schlafly ／ Equal Rights Amendment

イリノイ州では、平等権修正条項案（ ERA ）に反対する活動家が、米国の伝統的な主婦の象徴を用いた。自家製のパン、ジャム、アップルパイなどを州議会議員に届け、「議会のジャム〔混乱〕から私たちを守って。 ERA のまやかしに反対票を」「私は母親とアップルパイを支持する」といった標語を掲げた。
直前の質問：フィリスは平等権修正条項案とどのような関係があったか。
直前の回答：シュラフリーは ERA への政治的な反対運動を組織した。
質問：どのように反対したのか。

イリノイ州で、反対派は米国の伝統的な主婦の象徴を用いた

[1] QuAC, val_v0.2.json. 公開開発データ。 C_b6f2f106bdee40d087e8ff4f6fb9f754_1_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例 10 ：活動再開の方法を尋ねる

原文（本文抜粋）： Yanni ／ 2000s to 2010: After a hiatus, new perspectives

In 2000, after the two-year hiatus, Yanni released If I Could Tell You, his first studio album in seven years.
Previous Q: When did Yanni end his hiatus?
Previous A: In 2000, after the two-year hiatus,
Question: How did he make his comeback?

Yanni released If I Could Tell You, his first studio album in seven years.

[1] QuAC, val_v0.2.json. 公開開発データ。 C_6f20228bb4fe4b54b491c7c8930808d5_0_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例 10 ：活動再開の方法を尋ねる（訳）

訳（本文抜粋）： Yanni ／ 2000s to 2010: After a hiatus, new perspectives

2000 年、 2 年間の活動休止を経て、ヤニーは 7 年ぶりのスタジオアルバム「 If I Could Tell You 」を発表した。
直前の質問：ヤニーはいつ活動休止を終えたのか。
直前の回答： 2000 年、 2 年間の活動休止を経て
質問：どのように復帰したのか。

7 年ぶりのスタジオアルバム「 If I Could Tell You 」を発表した

[1] QuAC, val_v0.2.json. 公開開発データ。 C_6f20228bb4fe4b54b491c7c8930808d5_0_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例 11 ：著作の中身を続けて尋ねる

原文（本文抜粋）： David Hume ／ Ethics

His views on ethics are that "[m]oral decisions are grounded in moral sentiment." It is not knowing that governs ethical actions, but feelings.
Previous Q: What is most important about Hume's academics?
Previous A: Hume's writings on ethics began in the Treatise and were refined in his An Enquiry Concerning the Principles of Morals (1751
Question: What were the Principles of Morals?

It is not knowing that governs ethical actions, but feelings.

[1] QuAC, val_v0.2.json. 公開開発データ。 C_6ddf50a14de94ac9991786264f48a22f_0_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例 11 ：著作の中身を続けて尋ねる（訳）

訳（本文抜粋）： David Hume ／ Ethics

ヒュームは、道徳的な判断は道徳感情に根差すと考えた。倫理的な行為を動かすのは知識ではなく、感情である。
直前の質問：ヒュームの学問で最も重要なのは何か。
直前の回答：倫理に関する著述は「人間本性論」に始まり、「道徳原理の研究」（1751 年）で練り上げられた。
質問：「道徳原理の研究」はどのような内容か。

倫理的な行為を動かすのは知識ではなく、感情である

[1] QuAC, val_v0.2.json. 公開開発データ。 C_6ddf50a14de94ac9991786264f48a22f_0_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例 12 ：家族について追質問する

原文（抜粋）： Ban Ki-moon

They have three adult children: two daughters and a son.
Previous Q: who were ban's family?
Previous A: Ban Ki-moon married Yoo Soon-taek in 1971.
Question: did they have children

They have three adult children: two daughters and a son.

訳（抜粋）： Ban Ki-moon

二人には、成人した子どもが 3 人いる。娘が 2 人、息子が 1 人である。
直前の質問：潘氏の家族は誰か。
直前の回答：潘基文は 1971 年に柳淳澤と結婚した。
質問：二人には子どもがいたか。

成人した子どもが 3 人いる。娘が 2 人、息子が 1 人

[1] QuAC, val_v0.2.json. 公開開発データ。 C_c347eb93f081466cac8eef4c90328eb2_0_q#1 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例 13 ：政治活動の具体例を尋ねる

原文（本文抜粋）： Drew Carey ／ Political views

He made donations to Ron Paul's presidential campaign for the 2008 election.
Previous Q: Was he vocal about his political views?
Previous A: He has expressed his political philosophy in the following terms: "I believe the answers to all the problems we face as a society won't come from Washington,
Question: Did he donate money to any candidates?

He made donations to Ron Paul's presidential campaign

[1] QuAC, val_v0.2.json. 公開開発データ。 C_6c922ff8e4a340d9bf2b85558179fdde_0_q#2 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

実例 13 ：政治活動の具体例を尋ねる（訳）

訳（本文抜粋）： Drew Carey ／ Political views

2008 年の選挙では、ロン・ポールの大統領選挙運動に寄付した。
直前の質問：政治的な考えを公にしていたか。
直前の回答：自身の政治哲学について、社会が抱えるあらゆる問題への答えはワシントンからは生まれないと信じている、と述べた。
質問：候補者に寄付したことはあるか。

ロン・ポールの大統領選挙運動に寄付した

[1] QuAC, val_v0.2.json. 公開開発データ。 C_6c922ff8e4a340d9bf2b85558179fdde_0_q#2 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

注釈と実行条件の補足

補助注釈の内訳：公開開発 7,354 問

注釈	内訳
yes ／ no	y ： 1,500 、 n ： 122 、 x ： 5,732
追質問	y ： 4,255 、 m ： 1,358 、 n ： 1,741

yes ／ no の x はどちらでもない。追質問の m はどちらともいえない。

[1] QuAC, val_v0.2.json. 公開開発データ。 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

回答不能の採点には文字列の条件がある

- 公式コードは、参照回答の半数以上が CANNOTANSWER なら、回答不能の参照だけに整理する。
- この場合、公式採点は出力が厳密に CANNOTANSWER なら 1 、それ以外は 0 とする。
- HELM は回答不能に Not enough information 、 Cannot answer 、 Do not know も参照として加える。

[1] QuAC，公式評価コード。 https://s3.amazonaws.com/my89public/quac/scorer.py

同じ出力でも採点条件で値が変わる

説明用の出力	公式 QuAC	HELM
CANNOTANSWER	1	1
Cannot answer	0	1

参照がすべて CANNOTANSWER の質問を想定。実モデルの出力例ではない。

[1] QuAC，公式評価コード。 https://s3.amazonaws.com/my89public/quac/scorer.py

公開 v0.2 と論文の件数には差がある

項目	確認できた値
学習・開発・テストの合計	13,569 対話／ 98,275 問
論文の全体欄	13,594 対話／ 98,407 問
学習の回答不能率	公開 v0.2 は 17.3% ／論文は 20.2%

合計は公開学習・開発と論文のテスト値から計算。差の原因は推測していない。

[1] Choi et al. (2018), QuAC: Question Answering in Context. EMNLP, 2174–2184. https://aclanthology.org/D18-1241/

掲載した実例の範囲と選び方

- 独立した 13 対話を、追質問の形や回答形式が分かるよう意図的に選んだ。頻度を代表する標本ではない。
- 本文は連続した抜粋、会話は直前の 1 往復と対象質問。全文・全履歴・全参照回答は検証記録に保持した。
- 公開注釈には断片的な範囲や不自然な質問もある。正解を別の内容へ差し替えず、必要な意味を自然な日本語で訳した。

[1] QuAC, val_v0.2.json. 公開開発データ。 https://s3.amazonaws.com/my89public/quac/val_v0.2.json

研究と参考文献

対話の情報差に着目した共同研究

- 第一著者は Eunsol Choi 。 He He 、 Mohit Iyyer 、 Mark Yatskar との最初の 4 人が同等に貢献した。
- ワシントン大学、スタンフォード大学、 Allen Institute for AI 、マサチューセッツ大学アマースト校の共同研究。
- 2018 年の EMNLP で発表。 CoQA などと同時期に、単発の質問応答から会話型の読解へ評価を広げた。

[1] Choi et al. (2018), QuAC: Question Answering in Context. EMNLP, 2174–2184. https://aclanthology.org/D18-1241/

参考文献

QuAC: Question Answering in Context

Eunsol Choi, He He, Mohit Iyyer ほか（2018）／ EMNLP, pp.2174–2184

学生役と教師役の情報を分けて集めた対話と、回答・人との同等性の評価を提案。

https://aclanthology.org/D18-1241/

Holistic Evaluation of Language Models

Percy Liang ほか（2023）／ Transactions on Machine Learning Research

共通の評価枠組みで言語モデルを比較。 QuAC を会話付きの短文回答生成として扱う。

https://arxiv.org/abs/2211.09110

参考文献

QuAC ：公開データと評価コード

QuAC プロジェクト／学習・開発 v0.2 、 scorer.py

データの入手先、公式の評価方法、掲載日付きのテスト結果を公開。

https://quac.ai/

HELM ： QuAC シナリオの実装

Stanford CRFM ／ quac_scenario.py

記事情報と会話を生成入力へ変換。質問の選び方と回答不能の参照追加を定義。

https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/quac_scenario.py