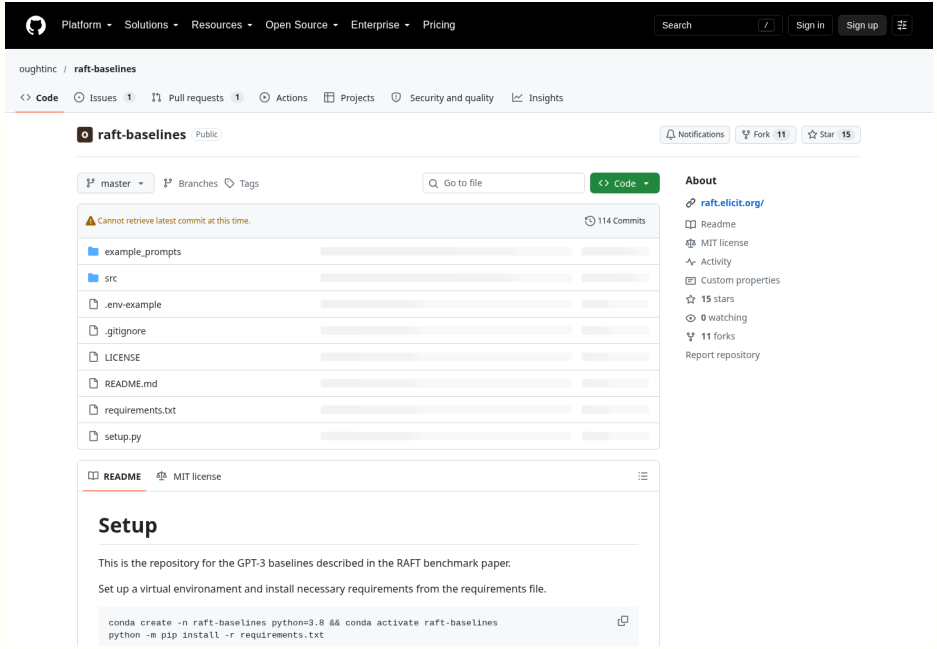
RAFT

Real-world Annotated Few-shot Tasks

各 50 件の教師から、実務的な文章分類を学ぶ

sasakiy84

RAFT の公開ページ



[1] RAFT 公式公開ページ。 2026-10-18 参照。 https://github.com/oughtinc/raft-baselines

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

少数の教師で、役に立つ分類ができるか

- 薬の有害作用、銀行への問い合わせ、利用規約、研究文献の選別など、実務に近い 11 種類の文章分類を集めた。
- 各課題に公開するラベル付き例は 50 件。長い記事や、多数のラベルを持つ課題も含め、少数の例から各課題に対応できるかを比べる。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

入力・出力と配布フィールド

フィールド	意味
課題ごとの本文	Sentence 、 Query 、 Article など。内容に応じて異なる
Label	課題ごとに定義された正解クラス
ID	課題内のレコード番号

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 https://huggingface.co/datasets/ought/raft

実例１：薬の有害作用

関連する入力・回答／原文と日本語

A closer look at septic shock.
not ADE-related

入力：敗血症性ショックを詳しく検討する。
配布ラベル：薬の有害作用とは関係がない

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 ade_corpus_v2 / train ID 20 。 https://huggingface.co/datasets/ought/raft

実例２：銀行の問い合わせ

関連する入力・回答／左：原文　右：日本語

limits on top ups	入力：チャージ額の上限
top_up_limits	配布ラベル：チャージの上限

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 banking_77 / train ID 12 。 https://huggingface.co/datasets/ought/raft

実例３：利用規約

関連する入力・回答／左：原文　右：日本語

We may revise these terms from time to time.
potentially unfair

入力：当社は、随時これらの規約を改訂することがあります。
配布ラベル：不公正な可能性あり

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 terms_of_service / train ID 37 。 https://huggingface.co/datasets/ought/raft

作成方法とデータの構成

作成の背景

- 既存の少数例評価には、短い文章や研究用に整理しやすい分類が多かった。
- 実際の仕事で価値のある分類に、少数例学習がどこまで届くかを調べるため、専門性や文章量の異なる課題を選んだ。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

収集と品質の確認

- 既存の公開課題に加え、研究の影響声明や半導体関連組織などの分類を用意し、自然言語の説明とラベルを整理した。
- 各課題から 50 件を公開し、テストの予測ラベルを提出する形式を採用した。専門知識のない人の比較評価も行った。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

分割と件数

集合・対象	件数	役割
11 課題の train	各 50	公開ラベル付き、合計 550 件
公式 test	課題ごとに異なる	正解ラベルは提出評価用
HELM 内の再分割	10 ／ 40	公開 50 件を提示候補と評価へ

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。
https://huggingface.co/datasets/ought/raft

[2] Stanford CRFM. HELM Classic v0.4.0. 公開 run_specs 。 2023-11-17 のリリース。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

50 例に対して、クラス数は 2 〜 77

- 11 課題とも公開 train は 50 件だが、分類先の数は異なる。銀行の問い合わせは 77 種類、記事の難易度と半導体関連組織は 3 種類、ほかは 2 種類である。
- banking_77 では、公開 50 件に 77 種類すべては現れない。自然言語のラベル名と課題の説明も、少数例学習の手掛かりになる。

[1] RAFT 、 11 tasks/train 全 550 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/ought/raft

採点方法とモデルの成績

何を 1 件として、どう採点するか

- クラスごとに適合率 P と再現率 R を求め、 F1 = 2PR/(P+R) を計算する。 P=0.75 、 R=0.60 なら、 F1 は約 0.667 。
- 公式の課題スコアはクラスごとの F1 を等しく平均する macro-F1 。全体は 11 課題のスコアを等しく平均する。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

初期の代表的な評価

2021 年の公式評価	11 課題の平均 F1
人（クラウドソーシング）	0.735
GPT-3 175B （ few-shot ）	0.627
AdaBoost	0.514
GPT-Neo 2.7B	0.481

各課題の macro-F1 を等しく平均した値。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

HELM での評価条件

- 公式 test の正解を使わず、公開 train の 50 件を乱数 seed 42 で 10 件と 40 件に再分割する。
- 表は twitter_complaints の 40 件、最大 5 例提示、 3 試行。 HELM の完全一致率を示し、公式の 11 課題平均 macro-F1 と区別する。

[1] Stanford CRFM. HELM Classic v0.4.0. 公開 run_specs 。 2023-11-17 のリリース。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

HELM Classic v0.4.0 の結果

モデル	正解率（%）	試行数
text-davinci-003 （2022）	91.67	3
Anthropic v4-s3 （2022）	77.50	3

twitter_complaints の再分割 40 件、最大 5 例提示。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

利用の変化と入手方法

公開の少数例から、再現可能な比較へ

- RAFT の公式評価は、仕事ごとに定義した分類と、少数例という条件を重視した。 HELM は公開ラベルだけで実行できる再分割を採用した。
- 2026-10-18 時点で、 ought/raft の 11 課題と、公式のベースライン実装・説明が公開されている。

[1] RAFT 公式公開ページ。 2026-10-18 参照。 https://github.com/oughtinc/raft-baselines

入手方法と利用条件

- ought/raft では、課題名ごとの train.csv 、test_unlabeled.csv 、 task.json を取得できる。
- 複数の元データを集めた集合なので、ライセンスは各課題の出所と条件を確認する。 banking_77 の 77 クラスは、50 例にすべて現れるわけではない。

[1] RAFT 公式公開ページ。 2026-10-18 参照。 https://github.com/oughtinc/raft-baselines

RAFT の要点

- 実務的な 11 課題を、各 50 件の公開教師で扱う少数例文章分類の集合である。
- 課題ごとに本文の形式、クラス数、専門性が異なり、同じ少数例でも難しさが変わる。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例 1 ：研究の影響声明

原文（抜粋）

Input (excerpt): Paper title: Improving Local Identifiability in Probabilistic Box Embeddings
Impact statement: This work does not present any foreseeable societal consequence.
Label: doesn't mention a harmful application

日本語訳

入力：論文名：確率的ボックス埋め込みにおける局所的な識別可能性の改善
影響声明：この研究には、予測可能な社会的影響はない。
配布ラベル：有害な応用への言及なし

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 neurips_impact_statement_risks / train ID 37 。 https://huggingface.co/datasets/ought/raft

追加例２：記事の難易度

関連する入力・回答／左：原文　右：日本語

Two mothers in South Africa have found out that they are raising each other ’s daughters after someone switched them at birth by mistake in a hospital in 2010.
elementary

入力（抜粋）：南アフリカの 2 人の母親は、 2010 年に病院で赤ちゃんを誤って取り違えられたため、互いの娘を育てていることが分かった。
配布ラベル：初級

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 one_stop_english / train ID 44 。 https://huggingface.co/datasets/ought/raft

実例の補足：記事の難易度

- 入力は記事全体。ここでは冒頭 1 段落を抜粋し、記事全体に付いた配布ラベルを示す。

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 https://huggingface.co/datasets/ought/raft

追加例３：判例の変更

関連する入力・回答／左：原文　右：日本語

we recognize that this reading of fager disapproves prior cases.
overruling

入力：このように Fager を解釈すると、従来の判例を否定することになると認める。
配布ラベル：判例の変更あり

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 overruling / train ID 10 。 https://huggingface.co/datasets/ought/raft

追加例 4 ：半導体関連組織

関連する入力・回答／左：原文　右：日本語

Paper title: Design of the Power6 Microprocessor
Organization name: IBM Systems Group,Austin,TX company

入力：論文名： Power6 マイクロプロセッサの設計
組織名： IBM Systems Group （米国テキサス州オースティン）
配布ラベル：企業

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 semiconductor_org_types / train ID 16 。 https://huggingface.co/datasets/ought/raft

追加例 5 ：レビューへの採否（原文）

原文（ Title ・ Abstract ・ Label ）

Title: Imagine being a nice guy: A note on hypothetical vs. Incentivized social preferences
We conducted an experimental study on social preferences using dictator games similar to Fehr et al. (2008).
Our results show that social preferences differ between subjects who receive low-stakes monetary rewards for their decisions and subjects who consider hypothetical stakes.
Our findings indicate that, apart from incentives, gender plays an important role for the categorization of different social preferences.
© 2015. The authors license.
Label: not included

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 systematic_review_inclusion / train ID 43 。 https://huggingface.co/datasets/ought/raft

追加例 5 ：レビューへの採否（日本語訳）

日本語訳

題名：いい人になったつもりで——仮想的な社会的選好と、報酬を伴う社会的選好について
Fehr ら（ 2008 ）と同様の独裁者ゲームを用い、社会的選好に関する実験を行った。
意思決定に対して少額の金銭報酬を受け取る参加者と、仮想的な報酬を考える参加者では、社会的選好が異なった。
報酬に加え、性別も社会的選好の分類に重要な役割を持つことが示された。
© 2015 。著者によるライセンス表記。
配布ラベル：レビューに含めない

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 systematic_review_inclusion / train ID 43 。 https://huggingface.co/datasets/ought/raft

追加例 6 ：変革的 AI の安全性

関連する入力・回答／左：原文　右：日本語

Title: Economics of the singularity
Author: Hanson, Robin
Publication Year: 2008
Publication Title: IEEE Spectrum
TAI safety research

入力（抜粋）：題名：シンギュラリティの経済学
著者：ロビン・ハンソン
発表年： 2008 年
掲載先： IEEE Spectrum
配布ラベル：
変革的 AI の安全性研究

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 tai_safety_research / train ID 12 。 https://huggingface.co/datasets/ought/raft

追加例 7 ：ヘイトスピーチ

関連する入力・回答／原文と日本語

New to Twitter-- any men on here know what the process is to get #verified?
not hate speech

入力： Twitter を始めたばかりです。ここにいる男性で、認証済みになる手続きを知っている人はいますか？
配布ラベル：ヘイトスピーチではない

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 tweet_eval_hate / train ID 0 。 https://huggingface.co/datasets/ought/raft

追加例 8 ：投稿の苦情

関連する入力・回答／左：原文　右：日本語

@Wavy2Timez for real
no complaint

入力： @Wavy2Timez 本当にそう。
配布ラベル：苦情ではない

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 twitter_complaints / train ID 46 。 https://huggingface.co/datasets/ought/raft

追加例９：銀行の問い合わせ

関連する入力・回答／左：原文　右：日本語

What currencies can I use?	入力：どの通貨を使えますか？
supported_cards_and_currencies	配布ラベル：対応するカードと通貨

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 banking_77 / train ID 24 。 https://huggingface.co/datasets/ought/raft

追加例 10 ：投稿の苦情

関連する入力・回答／左：原文　右：日本語

@TopmanAskUs please just give me my money back. complaint

入力： @TopmanAskUs お願いだから、お金を返してください。
配布ラベル：苦情

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 twitter_complaints / train ID 28 。 https://huggingface.co/datasets/ought/raft

集計と評価条件

11 課題の公開教師とクラス数（1/2）

課題	公開教師	クラス
ade corpus v2	50	2
banking 77	50	77
neurips impact statement risks	50	2
one stop english	50	3
overruling	50	2
semiconductor org types	50	3

[1] RAFT 、 11 tasks/train 全 550 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/ought/raft

11 課題の公開教師とクラス数（2/2）

課題	公開教師	クラス
systematic review inclusion	50	2
tai safety research	50	2
terms of service	50	2
tweet eval hate	50	2
twitter complaints	50	2

[1] RAFT 、 11 tasks/train 全 550 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/ought/raft

研究と参考文献

研究者と発表の位置付け

- Neel Alex と Eli Lifland は等しく貢献したと記載されている。最終著者は Andreas Stuhlmüller 。
- Ought 、 Hugging Face などの共同研究で、 NeurIPS Datasets and Benchmarks 2021 で発表した。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

参考文献

RAFT: A Real-World Few-Shot Text Classification Benchmark

Neel Alex, Eli Lifland, Lewis Tunstall, Abhishek Thakur, Pegah Maham, C. Jess Riedel, Emmie Hine, Carolyn Ashurst, Paul Sedille, Alexis Carlier, Michael Noetel, Andreas Stuhlmüller / NeurIPS Datasets and Benchmarks 2021

RAFT の目的、作成方法、評価をまとめた研究。

https://arxiv.org/abs/2109.14076

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

複数のシナリオと指標で、言語モデルを比較する HELM の研究。

https://arxiv.org/abs/2211.09110

参考文献

RAFT ：公開データ

ought/raft / 改訂 9ee50172 / 2026-10-18 参照

原文・正解の 13 例と、対象集合の全件集計に用いた公開資源。

https://huggingface.co/datasets/ought/raft