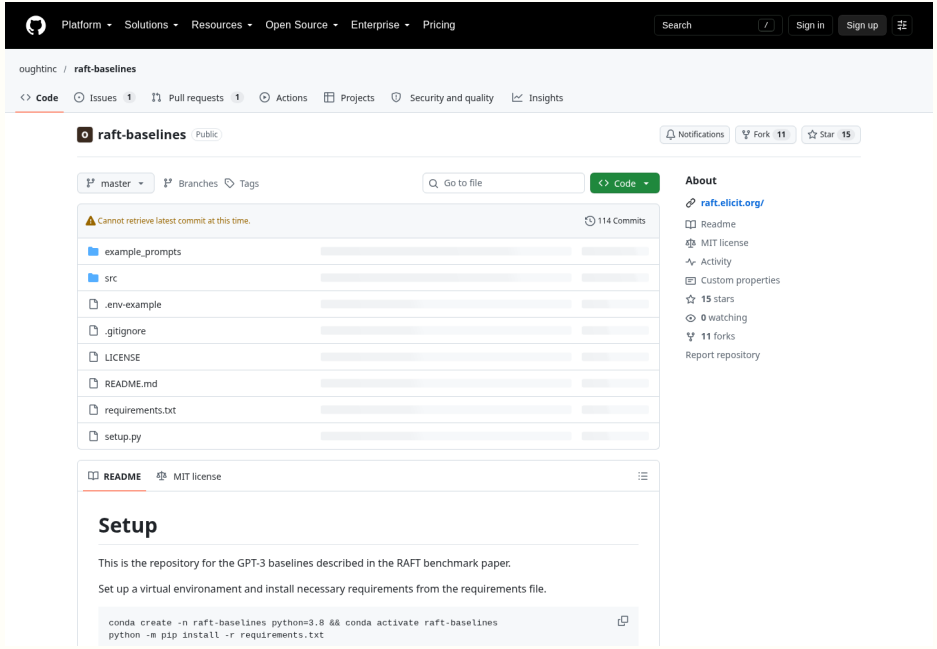
RAFT

Real-world Annotated Few-shot Tasks

各 50 件の教師から、実務的な文章分類を学ぶ

sasakiy84

RAFT の公開ページ



[1] RAFT 公式公開ページ。 2026-10-18 参照。 https://github.com/oughtinc/raft-baselines

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

少数の教師で、役に立つ分類ができるか

- 薬の有害作用、銀行への問い合わせ、利用規約、研究文献の選別など、実務に近い 11 種類の文章分類を集めた。
- 各課題に公開するラベル付き例は 50 件。長い記事や、多数のラベルを持つ課題も含め、少数の例から各課題に対応できるかを比べる。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

入力・出力と配布フィールド

フィールド	意味
課題ごとの本文	Sentence 、 Query 、 Article など。内容に応じて異なる
Label	課題ごとに定義された正解クラス
ID	課題内のレコード番号

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 https://huggingface.co/datasets/ought/raft

実例１：薬の有害作用

関連する入力・回答／原文と日本語

A closer look at septic shock.
not ADE-related

入力：敗血症性ショックを詳しく検討する。
配布ラベル：薬の有害作用とは関係がない

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 ade_corpus_v2 / train ID 20 。 https://huggingface.co/datasets/ought/raft

実例２：銀行の問い合わせ

関連する入力・回答／左：原文　右：日本語

limits on top ups	入力：チャージ額の上限
top_up_limits	配布ラベル：チャージの上限

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 banking_77 / train ID 12 。 https://huggingface.co/datasets/ought/raft

実例３：利用規約

関連する入力・回答／左：原文　右：日本語

We may revise these terms from time to time.
potentially unfair

入力：当社は、随時これらの規約を改訂することがあります。
配布ラベル：不公正な可能性あり

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 terms_of_service / train ID 37 。 https://huggingface.co/datasets/ought/raft

作成方法とデータの構成

作成の背景

- 既存の少数例評価には、短い文章や研究用に整理しやすい分類が多かった。
- 実際の仕事で価値のある分類に、少数例学習がどこまで届くかを調べるため、専門性や文章量の異なる課題を選んだ。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

収集と品質の確認

- 既存の公開課題に加え、研究の影響声明や半導体関連組織などの分類を用意し、自然言語の説明とラベルを整理した。
- 各課題から 50 件を公開し、テストの予測ラベルを提出する形式を採用した。専門知識のない人の比較評価も行った。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

分割と件数

集合・対象	件数	役割
11 課題の train	各 50	公開ラベル付き、合計 550 件
公式 test	課題ごとに異なる	正解ラベルは提出評価用
HELM 内の再分割	10 ／ 40	公開 50 件を提示候補と評価へ

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。
https://huggingface.co/datasets/ought/raft

[2] Stanford CRFM. HELM Classic v0.4.0. 公開 run_specs 。 2023-11-17 のリリース。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

50 例に対して、クラス数は 2 〜 77

- 11 課題とも公開 train は 50 件だが、分類先の数は異なる。銀行の問い合わせは 77 種類、記事の難易度と半導体関連組織は 3 種類、ほかは 2 種類である。
- banking_77 では、公開 50 件に 77 種類すべては現れない。自然言語のラベル名と課題の説明も、少数例学習の手掛かりになる。

[1] RAFT 、 11 tasks/train 全 550 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/ought/raft

採点方法とモデルの成績

何を 1 件として、どう採点するか

- クラスごとに適合率 P と再現率 R を求め、 F1 = 2PR/(P+R) を計算する。 P=0.75 、 R=0.60 なら、 F1 は約 0.667 。
- 公式の課題スコアはクラスごとの F1 を等しく平均する macro-F1 。全体は 11 課題のスコアを等しく平均する。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

初期の代表的な評価

2021 年の公式評価	11 課題の平均 F1
人（クラウドソーシング）	0.735
GPT-3 175B （ few-shot ）	0.627
AdaBoost	0.514
GPT-Neo 2.7B	0.481

各課題の macro-F1 を等しく平均した値。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

HELM での評価条件

- 公式 test の正解を使わず、公開 train の 50 件を乱数 seed 42 で 10 件と 40 件に再分割する。
- 表は twitter_complaints の 40 件、最大 5 例提示、 3 試行。 HELM の完全一致率を示し、公式の 11 課題平均 macro-F1 と区別する。

[1] Stanford CRFM. HELM Classic v0.4.0. 公開 run_specs 。 2023-11-17 のリリース。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

HELM Classic v0.4.0 の結果

モデル	正解率（%）	試行数
text-davinci-003 （2022）	91.67	3
Anthropic v4-s3 （2022）	77.50	3

twitter_complaints の再分割 40 件、最大 5 例提示。

[1] Liang et al. Holistic Evaluation of Language Models. TMLR 2023. Classic v0.4.0 （2023-11-17）。 https://crfm.stanford.edu/helm/classic/v0.4.0/

利用の変化と入手方法

公開の少数例から、再現可能な比較へ

- RAFT の公式評価は、仕事ごとに定義した分類と、少数例という条件を重視した。 HELM は公開ラベルだけで実行できる再分割を採用した。
- 2026-10-18 時点で、 ought/raft の 11 課題と、公式のベースライン実装・説明が公開されている。

[1] RAFT 公式公開ページ。 2026-10-18 参照。 https://github.com/oughtinc/raft-baselines

入手方法と利用条件

- ought/raft では、課題名ごとの train.csv 、test_unlabeled.csv 、 task.json を取得できる。
- 複数の元データを集めた集合なので、ライセンスは各課題の出所と条件を確認する。 banking_77 の 77 クラスは、50 例にすべて現れるわけではない。

[1] RAFT 公式公開ページ。 2026-10-18 参照。 https://github.com/oughtinc/raft-baselines

RAFT の要点

- 実務的な 11 課題を、各 50 件の公開教師で扱う少数例文章分類の集合である。
- 課題ごとに本文の形式、クラス数、専門性が異なり、同じ少数例でも難しさが変わる。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例 1 ：研究の影響声明（ 1/2 ）

入力（抜粋）／原文と日本語

Paper title: Improving Local Identifiability in Probabilistic Box Embeddings
Impact statement: This work does not present any foreseeable societal consequence.

論文名：確率的ボックス埋め込みにおける局所的な識別可能性の改善
影響声明：この研究には、予測可能な社会的影響はない。

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 neurips_impact_statement_risks / train ID 37 。 https://huggingface.co/datasets/ought/raft

追加例 1 ：研究の影響声明（ 2/2 ）

配布ラベル／原文と日本語

doesn't mention a harmful application

有害な応用への言及なし

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 neurips_impact_statement_risks / train ID 37 。 https://huggingface.co/datasets/ought/raft

追加例２：記事の難易度

関連する入力・回答／左：原文　右：日本語

Two mothers in South Africa have found out that they are raising each other ’s daughters after someone switched them at birth by mistake in a hospital in 2010.
elementary

入力（抜粋）：南アフリカの 2 人の母親は、 2010 年に病院で赤ちゃんを誤って取り違えられたため、互いの娘を育てていることが分かった。
配布ラベル：初級

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 one_stop_english / train ID 44 。 https://huggingface.co/datasets/ought/raft

実例の補足：記事の難易度

- 入力は記事全体。ここでは冒頭 1 段落を抜粋し、記事全体に付いた配布ラベルを示す。

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 https://huggingface.co/datasets/ought/raft

追加例３：判例の変更

関連する入力・回答／左：原文　右：日本語

we recognize that this reading of fager disapproves prior cases.
overruling

入力：このように Fager を解釈すると、従来の判例を否定することになると認める。
配布ラベル：判例の変更あり

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 overruling / train ID 10 。 https://huggingface.co/datasets/ought/raft

追加例 4 ：半導体関連組織

関連する入力・回答／左：原文　右：日本語

Paper title: Design of the Power6 Microprocessor
Organization name: IBM Systems Group,Austin,TX company

入力：論文名： Power6 マイクロプロセッサの設計
組織名： IBM Systems Group （米国テキサス州オースティン）
配布ラベル：企業

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 semiconductor_org_types / train ID 16 。 https://huggingface.co/datasets/ought/raft

追加例 5 ：レビューへの採否（ 1/3 ）

掲載フィールド： Title ・ Abstract ・ Label ／左：原文　右：日本語

Imagine being a nice guy: A note on hypothetical vs. Incentivized social preferences We conducted an experimental study on social preferences using dictator games similar to Fehr et al. (2008).

題名：いい人になったつもりで――仮想的な社会的選好と、報酬を伴う社会的選好について
要旨： Fehr ら（ 2008 ）と同様の独裁者ゲームを用い、社会的選好に関する実験を行った。

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 systematic_review_inclusion / train ID 43 。 https://huggingface.co/datasets/ought/raft

追加例 5 ：レビューへの採否（ 2/3 ）

掲載フィールド： Abstract ／原文と日本語

> Our results show that social preferences differ between subjects who receive low-stakes monetary rewards for their decisions and subjects who consider hypothetical stakes.

意思決定に対して少額の金銭報酬を受け取る参加者と、仮想的な報酬を考える参加者では、社会的選好が異なった。

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 systematic_review_inclusion / train ID 43 。 https://huggingface.co/datasets/ought/raft

追加例 5 ：レビューへの採否（ 3/3 ）

掲載フィールド： Title ・ Abstract ・ Label ／左：原文　右：日本語

Our findings indicate that, apart from incentives, gender plays an important role for the categorization of different social preferences.
© 2015. The authors license. not included

要旨：報酬に加え、性別も社会的選好の分類に重要な役割を持つことが示された。
要旨： © 2015 。著者によるライセンス表記。
配布ラベル：レビューに含めない

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 systematic_review_inclusion / train ID 43 。 https://huggingface.co/datasets/ought/raft

追加例 6 ：変革的 AI の安全性

関連する入力・回答／左：原文　右：日本語

Title: Economics of the singularity
Author: Hanson, Robin
Publication Year: 2008
Publication Title: IEEE Spectrum
TAI safety research

入力（抜粋）：題名：シンギュラリティの経済学
著者：ロビン・ハンソン
発表年： 2008 年
掲載先： IEEE Spectrum
配布ラベル：
変革的 AI の安全性研究

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 tai_safety_research / train ID 12 。 https://huggingface.co/datasets/ought/raft

追加例 7 ：ヘイトスピーチ

関連する入力・回答／原文と日本語

New to Twitter-- any men on here know what the process is to get #verified?
not hate speech

入力： Twitter を始めたばかりです。ここにいる男性で、認証済みになる手続きを知っている人はいますか？
配布ラベル：ヘイトスピーチではない

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 tweet_eval_hate / train ID 0 。 https://huggingface.co/datasets/ought/raft

追加例 8 ：投稿の苦情

関連する入力・回答／左：原文　右：日本語

@Wavy2Timez for real
no complaint

入力： @Wavy2Timez 本当にそう。
配布ラベル：苦情ではない

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 twitter_complaints / train ID 46 。 https://huggingface.co/datasets/ought/raft

追加例９：銀行の問い合わせ

関連する入力・回答／左：原文　右：日本語

What currencies can I use?	入力：どの通貨を使えますか？
supported_cards_and_currencies	配布ラベル：対応するカードと通貨

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 banking_77 / train ID 24 。 https://huggingface.co/datasets/ought/raft

追加例 10 ：投稿の苦情

関連する入力・回答／左：原文　右：日本語

@TopmanAskUs please just give me my money back. complaint

入力： @TopmanAskUs お願いだから、お金を返してください。
配布ラベル：苦情

[1] ought/raft 、改訂 9ee50172 。 2026-10-18 参照。 twitter_complaints / train ID 28 。 https://huggingface.co/datasets/ought/raft

集計と評価条件

11 課題の公開教師とクラス数（1/2）

課題	公開教師	クラス
ade corpus v2	50	2
banking 77	50	77
neurips impact statement risks	50	2
one stop english	50	3
overruling	50	2
semiconductor org types	50	3

[1] RAFT 、 11 tasks/train 全 550 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/ought/raft

11 課題の公開教師とクラス数（2/2）

課題	公開教師	クラス
systematic review inclusion	50	2
tai safety research	50	2
terms of service	50	2
tweet eval hate	50	2
twitter complaints	50	2

[1] RAFT 、 11 tasks/train 全 550 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/ought/raft

研究と参考文献

研究者と発表の位置付け

- Neel Alex と Eli Lifland は等しく貢献したと記載されている。最終著者は Andreas Stuhlmüller 。
- Ought 、 Hugging Face などの共同研究で、 NeurIPS Datasets and Benchmarks 2021 で発表した。

[1] Neel Alex et al. (2021). RAFT: A Real-World Few-Shot Text Classification Benchmark. NeurIPS Datasets and Benchmarks 2021. https://arxiv.org/abs/2109.14076

参考文献

RAFT: A Real-World Few-Shot Text Classification Benchmark

Neel Alex, Eli Lifland, Lewis Tunstall, Abhishek Thakur, Pegah Maham, C. Jess Riedel, Emmie Hine, Carolyn Ashurst, Paul Sedille, Alexis Carlier, Michael Noetel, Andreas Stuhlmüller / NeurIPS Datasets and Benchmarks 2021

RAFT の目的、作成方法、評価をまとめた研究。

https://arxiv.org/abs/2109.14076

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

複数のシナリオと指標で、言語モデルを比較する HELM の研究。

https://arxiv.org/abs/2211.09110

参考文献

RAFT ：公開データ

ought/raft / 改訂 9ee50172 / 2026-10-18 参照

原文・正解の 13 例と、対象集合の全件集計に用いた公開資源。

https://huggingface.co/datasets/ought/raft