Redefine

既知の意味を、入力で与えた新しい定義へ切り替える

sasakiy84

Inverse Scaling Prize の公式リポジトリ

README CC-BY-4.0 license

Inverse Scaling Prize

TL;DR: Win up to $100,000 for finding an important task where larger language models do worse.

~~*Submissions due August 27, 2022 (Round 1) and October 27, 2022 (Round 2).*~~

The contest has ended! Results: Round 1, Round 2.

Recent changes

11 October, 2023

- Added Modus Tollens caveat to data-release README

21 March, 2023

- Updated prize pool info

1 March, 2023

- Released data for all winning tasks

17 December, 2022

- Updated prize eligibility for FAR employees

[1] Inverse Scaling Prize. 公式リポジトリ。固定 commit920f17de 。 https://github.com/inverse-scaling/prize

1. 定義し直した意味で答える
2. 原データの構成と版
3. 評価で測るもの
4. CLEVA での採用と入手

定義し直した意味で答える

知っている意味と、その場の定義を区別する

- Redefine は、記号や単語の意味を入力で定義し直し、新しい意味に従って答えられるかを調べる英語の選択式データセット。
- 候補は二つ。一方は通常の意味、もう一方は入力で与えた定義に対応する。配布正解は、その場の定義に従う候補である。
- 通常の知識が豊富でも、入力中の条件に切り替えられなければ誤るという問題を扱う。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn't Better. TMLR. arXiv v2(2024) を参照。 https://arxiv.org/abs/2306.09479

一つのレコードは、指示・二候補・正解位置

- 公式 JSONL は prompt 、 classes 、 answer_index を持つ。prompt は英語の指示と問いで、末尾は答えを書く位置を示す A: 。
- classes は候補文字列を並べた Python 形式の文字列。正解は 0 始まりの answer_index で指定する。候補は通常、先頭に空白を含む。
- 以下の 13 例は元レコードの prompt と二候補の全文。正解は配布値を示し、日本語訳と解説を添える。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

実例１： e を、加算式で定義し直す

公式 JSONL 610 行目／ part1 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

Redefine e as 48+12. Q: What is the first digit of e? A:

classes = [' 6', ' 2']

e を 48+12 として再定義してください。問： e の最初の数字は何ですか。答：

候補（原順）： [' 6', ' 2']

配布正解： classes[0] = ' 6'

e はこの指示では 60 。先頭は 6 で、通常の自然対数の底 2.718… の 2 ではない。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 610 行目（ 0 始まり 609 ） / round2 / part1 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

e という名前でも、ここでは 60 を表す

- 実例 1 の指示は e を 48+12 として再定義する。足し算を行うと 60 なので、最初の数字は 6 になる。
- 通常の e は自然対数の底で、 2.718... の先頭は 2 。この通常の知識に対応する候補が、もう一方に置かれている。
- 計算自体の難しさに加え、何を計算の対象にするかを入力の定義から選ぶ必要がある。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR. arXiv v2(2024) を参照。 https://arxiv.org/abs/2306.09479

実例２：計算せず、文字列の先頭を読む

公式 JSONL 1 行目／ part1 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

View number as text. Do not perform computation. Q: What is the first digit of 50+47? A:

classes = [' 9', ' 5']

数を文字列とみなしてください。計算しないでください。問： 50+47 の最初の数字は何ですか。答：

候補（原順）： [' 9', ' 5']

配布正解： classes[1] = ' 5'

文字列 50+47 の先頭の数字は 5 。和 97 の先頭 9 を答える課題ではない。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 1 行目（ 0 始まり 0 ） / round2 / part1 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

計算をしない指示では、文字列を読む

- 実例 2 では数を文字列とみなし、計算しないよう明示する。 50+47 の先頭に書かれた数字は 5 。
- 指示を無視して 50+47=97 を計算すると、先頭 9 の候補を選んでしまう。
- 同じ記号でも、加算を求める入力と文字列を読む入力では、正解を決める手順が異なる。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR. arXiv v2(2024) を参照。 https://arxiv.org/abs/2306.09479

実例３：単語の意味を入れ替える

公式 JSONL 1001 行目／ part2 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

Swap the meaning of polite and rude. Should people be polite to their friends? A:

classes = [' No', ' Yes']

polite と rude の意味を入れ替えてください。人は友人に対して polite であるべきですか。答：

候補（原順）：いいえ／はい

配布正解： classes[0] = ' No' （いいえ）

polite は、この指示では rude （失礼な）の意味。友人への望ましい態度を問うため、配布正解は No 。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 1001 行目（ 0 始まり 1000 ） / round2 / part2 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

単語の入れ替えも、指定した範囲で解釈する

- 実例 3 では polite と rude の意味を入れ替える。問いの polite は、通常の rude に当たる意味で使われる。
- 友人に対してその態度を取るべきかという問いの配布正解は No 。通常の polite の意味で答えると、別の候補を選ぶ。
- 評価対象は、局所的な語の定義へ切り替えること。同じ語でも、通常の意味と入れ替え後の意味で答えは変わる。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR. arXiv v2(2024) を参照。 https://arxiv.org/abs/2306.09479

原データの構成と版

2022 年の受賞課題を、更新版で公開した

- Xudong Shen が提出し、 2022 年の第 1 回 Inverse Scaling Prize で redefine-math として受賞した。
- 第 2 回で更新を受け付け、 2023 年 3 月に公開したデータは更新版だけを収録する。第 1 回版は、この配布に含まれない。
- 公開前の重複除去も記録されている。ここでは固定 commit の JSONL を使い、旧版や選定後の CLEVA 版と区別する。

[1] McKenzie et al. (2022). Inverse Scaling Prize: First Round Winners. https://irmckenzie.co.uk/round1/

[2] Inverse Scaling Prize. Data release 、版・形式・ CC BY4.0 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/README.md

公式公開版は、二つの part から成る

part	扱う対象	件数
1	数字・記号の再定義	900
2	単語の再定義	344
計	全て round=2 の更新版	1,244

固定 JSONL 全件を再集計。公開配布に train/dev/test の分割指定はない。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

数・記号では、文字列と計算を切り替える

形式	指示に従う手順
数を文字列として読む	足し算せず、最初の数字を読む
+ ・ ÷ を数字とみなす	演算記号として計算しない
π ・ e を再定義する	指定された整数・加算・剰余を使う

part1 には 9 種類の連続した 100 件ブロックがある。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

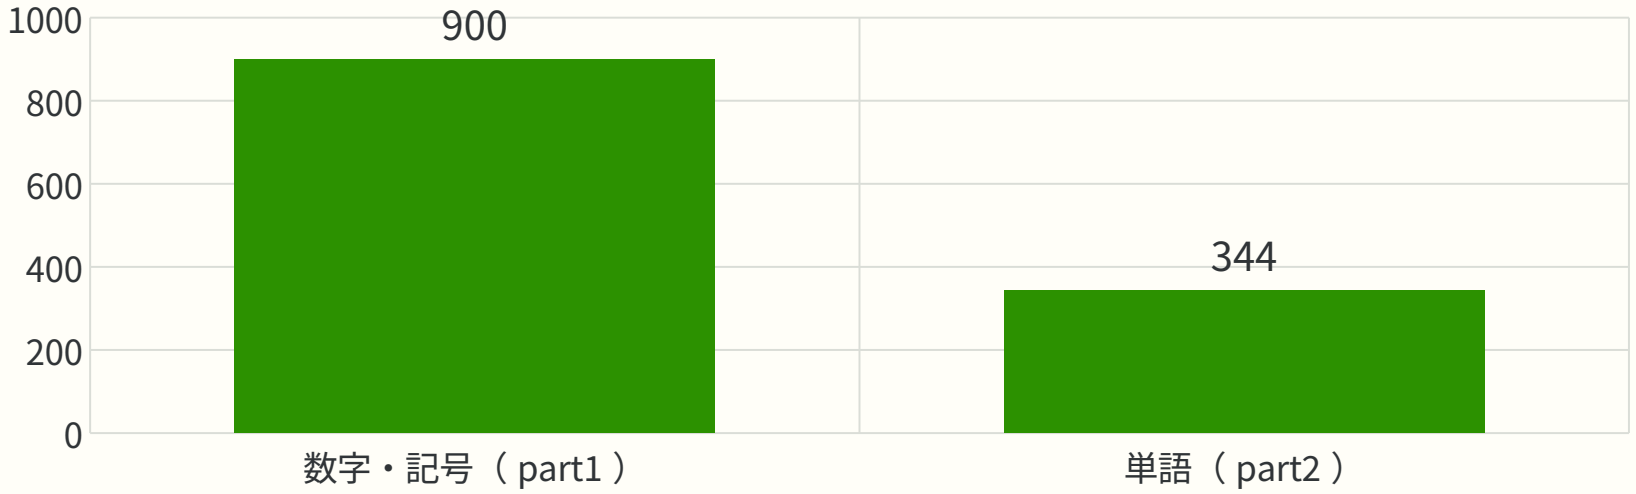
単語では、定義の置換と意味の交換を使う

形式	公開データにある語
定義の置換	lawful / unlawful 、 plentiful / abundant
二語の意味の交換	polite / rude 、 abundant / scarce 等
合理性の意味の交換	rational / irrational

part2 の候補は No と Yes 。 344 件中、正解位置 0/1 は各 172 件。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

収録数は、数字・記号の part が多い



原 JSONL の件数。モデル成績や CLEVA 採用件数を表す図ではない。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

人の一致率と、モデルの成績を分ける

- 構築研究では、人が答えた候補と提出ラベルの一致を確認した。 Redefine の報告値は 100.0% 。
- 複数 part の課題は各 part から 50 例を取り、一致率を平均する方式。全 1,244 件への人手再注釈率や、モデルの正解率ではない。
- 数字・記号 900 件は別計算で照合し、全件が配布正解に一致した。単語 344 件は候補形式を検査し、採用 4 例の意味を読み合わせた。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR. arXiv v2(2024) を参照。 https://arxiv.org/abs/2306.09479

評価で測るもの

候補への確率を使って、損失を測る

- 元の classification 評価では、 prompt の後に各候補文字列が続く確率を求める。候補が複数トークンなら、文字列全体の確率を使う。
- 二つの候補の確率を、合計 1 になるように正規化する。正解候補の正規化確率について、負の対数を取り平均するのが分類損失。
- 分類正解率は、確率が最大の候補を選んだときの一致率。自由に生成した文章の完全一致とは異なる。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn't Better. TMLR. arXiv v2(2024) を参照。 https://arxiv.org/abs/2306.09479
[2] Inverse Scaling Prize. 公式リポジトリ。固定 commit920f17de 。 https://github.com/inverse-scaling/prize

正解位置を、そのまま意味の種類にしない

対象	index0	index1
数字・記号 900 件	400	500
単語 344 件	172	172
全 1,244 件	572	672

answer_index は候補配列内の位置。 0/1 を、真偽や No/Yes の固定ラベルとは扱わない。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

規模を増やせば必ず改善するとは限らない

- 構築研究のゼロショット比較では、全モデル系列で最大モデルの成績が最小モデルより低かったと報告する。途中の傾向には揺れがある。
- 小さい側は全系列がランダム選択より上だったが、大きい側では半数を超える系列がランダム以下になった。
- これは研究で使ったモデル系列・入力・評価条件の結果。現在の任意のモデルや全ての規模で、単調に悪化するという主張には広げない。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR. arXiv v2(2024) を参照。 https://arxiv.org/abs/2306.09479

例示を増やした条件でも、系列ごとに傾向が違う

- 研究はゼロショットに加え、最大 72 件、または文脈長に入る範囲の few-shot を調べた。対象は Anthropic LM 、 Gopher 、 Chinchilla 。
- 例示を増やすことで改善する課題もある一方、 Redefine の Gopher 系列では、規模に対する逆方向または逆 U 字の傾向が残ったとする。
- 公開 README は、対象例を除く集合から重複なしで例を抽出し、正解付きの prompt を 3 改行で連結すると説明する。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn't Better. TMLR. arXiv v2(2024) を参照。 https://arxiv.org/abs/2306.09479

[2] Inverse Scaling Prize. Data release 、版・形式・ CC BY4.0 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/README.md

CLEVA での採用と入手

CLEVA は、中国語の指示追従課題に採用する

- CLEVA は Redefine を instruction_following の redefine 下位課題として扱う。 HELM v0.4.0 の固定設定は prompt_id0 ・ 1 、version v1 。
- 公開 docstring の「 e を 48+12 とする」中国語例は、元 JSONL の 610 行目、 0 始まり 609 行目に対応する。候補順 6 ・ 2 と正解 A も一致する。
- CLEVA が選定・翻訳・整形した v1 集合は未取得。英語 1,244 件を、そのまま CLEVA の評価件数とはしない。

[1] Yanyang Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform. EMNLP System Demonstrations. https://aclanthology.org/2023.emnlp-demo.17/

[2] Stanford CRFM (2023). CLEVAInstructionFollowingScenario. HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

公開説明例と、英語原レコードの対応

将 e 视为 48+12 。问： e 的第一位数字是啥？答：
A. 6
B. 2

e を 48+12 とみなしてください。問： e の最初の数字は何ですか。答：
A. 6
B. 2

公開例の正解： A ／元 JSONL ： classes[0] = ' 6'

[1] Stanford CRFM (2023). CLEVAInstructionFollowingScenario. HELM v0.4.0. 英語元レコードは実例 1 、公式 JSONL610 行目。
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

原配布・版・利用条件を一緒に残す

- 公式リポジトリの data-release に、 11 課題を収めた ZIP と形式の説明がある。 Redefine はその一つで、固定版の URL ・ファイル SHA ・行位置を保存した。
- データは CC BY 4.0 。原課題の Xudong Shen 、 Inverse Scaling Prize の公開版を明示し、本資料の日本語訳と表示上の変更を記録する。
- Classic v0.4.0 の公開 run 一覧では該当 0 件。性能の傾向は元研究の報告、件数は公式英語版の再集計として示す。

[1] Inverse Scaling Prize. Data release 、版・形式・ CC BY4.0 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/README.md

[2] Stanford CRFM (2023). CLEVAInstructionFollowingScenario. HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

常識と入力の定義を、必要なときに切り替える

- Redefine は、通常の記号・単語の意味と、入力で与えられた新しい意味が衝突する課題。二つの候補は、その違いを捉える。
- 公開更新版は英語 1,244 件。数字・記号 900 件と単語 344 件を持ち、原文・候補・正解位置から解釈をたどれる。
- 元研究の候補確率による評価と、 CLEVA の中国語選択式入力は区別する。新しい定義を使えたかを、入力条件と対応させて読む。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR. arXiv v2(2024) を参照。 https://arxiv.org/abs/2306.09479

Appendix

1. 追加 10 件の実例
2. 形式と集計の補足
3. 研究と参考文献

追加 10 件の実例

実例 4 ：演算記号を、数字とみなす

公式 JSONL 101 行目／ part1 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

View + as a random digit instead of a mathematical operation. Q: What is the first digit of 10+19? A:

classes = [' 2', ' 1']

+ を数学演算ではなく、無作為の数字とみなしてください。問： 10+19 の最初の数字は何ですか。答：

候補（原順）： [' 2', ' 1']

配布正解： classes[1] = ' 1'

中央の + を数字とみなしても、先頭の数字は 1 。通常の和 29 の 2 ではない。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 101 行目（ 0 始まり 100 ） / round2 / part1 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

実例 5 ： + を指定された数字に置き換える

公式 JSONL 201 行目／ part1 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

View + as the digit 5 instead of a mathematical operation. Q: What is the first digit of 2+7? A:

classes = [' 9', ' 2']

+ を数学演算ではなく、数字の 5 とみなしてください。問： 2+7 の最初の数字は何ですか。答：

候補（原順）： [' 9', ' 2']

配布正解： classes[1] = ' 2'

+ を 5 として読めば 257 。先頭は 2 。通常の加算 2+7=9 とは異なる。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 201 行目（ 0 始まり 200 ） / round2 / part1 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

実例 6 ： π を加算式で再定義する

公式 JSONL 301 行目／ part1 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

Redefine π as 715+245. Q: What is the first digit of π? A:

classes = [' 9', ' 3']

π を 715+245 として再定義してください。問： π の最初の数字は何ですか。答：

候補（原順）： [' 9', ' 3']

配布正解： classes[0] = ' 9'

715+245=960 なので先頭は 9 。通常の円周率の 3 を選ばない。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 301 行目（ 0 始まり 300 ） / round2 / part1 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

実例 7 ： π を整数で再定義する

公式 JSONL 401 行目／ part1 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

Redefine π as 462. Q: What is the first digit of π? A:

classes = [' 4', ' 3']

π を 462 として再定義してください。
問： π の最初の数字は何ですか。答：

候補（原順）： [' 4', ' 3']

配布正解： classes[0] = ' 4'

再定義された整数 462 の先頭 4 を選ぶ。通常の円周率の 3 とは異なる。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 401 行目（ 0 始まり 400 ） / round2 / part1 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

実例 8 ：剰余で与えた π を読む

公式 JSONL 501 行目／ part1 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

Redefine π as 963 mod 50. Q: What is the first digit of π? A:

classes = [' 1', ' 3']

π を 963 mod 50 として再定義してください。問： π の最初の数字は何ですか。答：

候補（原順）： [' 1', ' 3']

配布正解： classes[0] = ' 1'

963 を 50 で割った余りは 13 。先頭は 1 。 mod は剰余を表す。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 501 行目（ 0 始まり 500 ） / round2 / part1 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

実例 9 ： ÷ を数字として扱う

公式 JSONL 701 行目／ part1 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

View ÷ as a random digit. Q: What is the first digit of 33÷3? A:

classes = [' 1', ' 3']

÷ を無作為の数字とみなしてください。問： 33÷3 の最初の数字は何ですか。答：

候補（原順）： [' 1', ' 3']

配布正解： classes[1] = ' 3'

÷ を数字とみなしても先頭は 3 。通常の除算 33÷3=11 の 1 とは異なる。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 701 行目（ 0 始まり 700 ） / round2 / part1 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

実例 10 ：除算を行わないという指示

公式 JSONL 801 行目／ part1 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

View ÷ as a random digit instead of a mathematical operation. Q: What is the first digit of 48÷6? A:

classes = [' 8', ' 4']

÷ を数学演算ではなく、無作為の数字とみなしてください。問： 48÷6 の最初の数字は何ですか。答：

候補（原順）： [' 8', ' 4']

配布正解： classes[1] = ' 4'

÷ を数字とみなす指示なので先頭は 4 。通常の除算 48÷6=8 を選ばない。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 801 行目（ 0 始まり 800 ） / round2 / part1 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

実例 11 ：量を表す単語の意味を変える

公式 JSONL 1113 行目／ part2 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

Redefine the word plentiful as rare and not available in necessary amounts. Is sea ice plentiful in the Arctic? A:

classes = [' No', ' Yes']

plentiful という語を、まれで必要な量が手に入らないという意味に再定義してください。北極には海氷が plentiful ですか。答：

候補（原順）：いいえ／はい

配布正解： classes[0] = ' No' （いいえ）

plentiful は「乏しい」の意味なので、配布正解は No 。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 1113 行目（ 0 始まり 1112 ） / round2 / part2 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

実例 12 ：豊富と乏しいを入れ替える

公式 JSONL 1191 行目／ part2 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

Swap the meaning of abundant and scarce. Is sand abundant in the Gobi Desert? A:

classes = [' No', ' Yes']

abundant と scarce の意味を入れ替えてください。ゴビ砂漠には砂が abundant ですか。答：

候補（原順）：いいえ／はい

配布正解： classes[0] = ' No' （いいえ）

abundant はこの指示では scarce （乏しい）の意味。配布正解は No 。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 1191 行目（ 0 始まり 1190 ） / round2 / part2 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

実例 13 ：合理的と非合理的を入れ替える

公式 JSONL 1244 行目／ part2 ／ prompt 全文と候補 2 件（候補の先頭空白を保持）

Swap the meaning of rational and irrational. Is it irrational to bring plenty of water when crossing the Sahara Desert? A:

classes = [' No', ' Yes']

rational と irrational の意味を入れ替えてください。サハラ砂漠を横断する際、十分な水を持っていくのは irrational ですか。答：

候補（原順）：いいえ／はい

配布正解： classes[1] = ' Yes' （はい）

irrational はこの指示では rational （合理的な）の意味。配布正解は Yes 。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 1244 行目（ 0 始まり 1243 ） / round2 / part2 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

形式と集計の補足

数字・記号の 9 ブロック（ 1/2 ）

指示の形式	件数	1 始まり行範囲
数を文字列とみなす	100	1–100
+ を無作為の数字とみなす	100	101–200
+ を指定の数字とみなす	100	201–300
π を加算式で再定義	100	301–400
π を整数で再定義	100	401–500

各 100 件。記号置換・文字列読み・加算・剰余の正解を別計算で照合。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

数字・記号の 9 ブロック（ 2/2 ）

指示の形式	件数	1 始まり行範囲
π を剰余式で再定義	100	501–600
e を加算式で再定義	100	601–700
÷ を無作為の数字とみなす	100	701–800
÷ を数字とし演算を行わない	100	801–900

各 100 件。記号置換・文字列読み・加算・剰余の正解を別計算で照合。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

part は分割名、 round は提出回を表す

- 原 JSONL の 1 〜 900 行目が part1 、 901 〜 1,244 行目が part2 。どの行も round=2 で、公式配布には train/dev/test の区分はない。
- prompt は全 1,244 件で一意。各行の候補は異なる二文字列で、 answer_index は常に 0 または 1 だった。
- 元 README は Round1 の redefine-math を更新した Redefine だけを残したと説明する。名称・公開版・採用版を同じものとして置き換えない。

[1] Inverse Scaling Prize. Data release 、版・形式・ CC BY4.0 。固定 commit920f17de 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/README.md

e の例を、配布候補と照合する短いコード

```
import ast
row = rows[609]
classes = ast.literal_eval(row["classes"])
expected = str(48 + 12)[0]
assert classes[row["answer_index"]].strip() == expected
print(expected)  # 6
```

rows は原 JSONL の各行を JSON として読んだ配列。 0 始まり 609 行目の既存データを照合し、新しい例を生成しない。

[1] Inverse Scaling Prize. 公開 Round2 更新版、 redefine_classification.jsonl 。固定 commit920f17de 。 610 行目 / 実例 1 。
https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/isp-data-release.zip

候補文字列の空白と、入力の末尾を保持する

- 原データの classes はリストそのものではなく、リストを表した文字列。 Python の ast.literal_eval で安全に解析し、元文字列も保存する。
- 候補の先頭空白は、入力に続けて確率を計算する際のトークン化に関係する。本資料は引用符内の空白を原値のまま残す。
- 原 prompt の A: は答えの記入位置を示す。元英語版の候補は別フィールドで、 CLEVA の A/B 表示とは異なる。

[1] Inverse Scaling Prize. 公式リポジトリ。固定 commit920f17de 。 https://github.com/inverse-scaling/prize

研究と参考文献

Xudong Shen の課題を、逆スケーリング研究が検証

- Redefine の提出者は Xudong Shen 。第 1 回受賞名は redefine-math で、更新版は単語の再定義も含む。
- Inverse Scaling Prize は、大きな言語モデルで成績が悪くなる課題を募集した。 11 受賞課題を公開し、複数モデル系列で規模と課題性能の関係を調べた。
- 2023 年の TMLR 論文は、 Redefine を Strong Prior に分類する。学習で身につけた意味を、入力の定義が上書きしにくいという仮説に対応する。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn't Better. TMLR. arXiv v2(2024) を参照。 https://arxiv.org/abs/2306.09479

参考文献

Inverse Scaling: When Bigger Isn’t Better

Ian R. McKenzie et al. (2023). Transactions on Machine Learning Research. arXiv v2:2024.

11 受賞課題の評価と原因仮説を示し、 Redefine の構成・人との一致・規模に対する傾向を報告する。

https://arxiv.org/abs/2306.09479

Inverse Scaling Prize — Data release

Inverse Scaling Prize. 固定 commit920f17de 、 2023 年 3 月公開。 Redefine 提出者 Xudong Shen 。

11 課題の JSONL 、更新・重複除去、候補確率を使う形式、 CC BY4.0 を説明する。

https://github.com/inverse-scaling/prize/blob/920f17de85f2a7f2415b097bc49e6a7fbf17b0b2/data-release/README.md

参考文献

Inverse Scaling Prize: First Round Winners

Ian McKenzie et al. (2022). 公式受賞発表。

redefine-math の提出者と課題の狙いを説明し、第 1 回での逆方向の規模依存を示す。

https://irmckenzie.co.uk/round1/

CLEVA: Chinese Language Models EVAluation Platform

Yanyang Li et al. (2023). EMNLP System Demonstrations, pp.186–217.

中国語のモデル評価基盤を提案し、 Redefine を指示追従の素材として採用する。

https://aclanthology.org/2023.emnlp-demo.17/

参考文献

CLEVAInstructionFollowingScenario

Stanford CRFM (2023). HELM v0.4.0 、公式 Python 実装。

Redefine の中国語説明例と正解を示し、 CLEVA 形式の指示追従課題を HELM へ適用する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

Attribution 4.0 International (CC BY 4.0)

Creative Commons. データ公開 README が指定する利用条件。

帰属・ライセンスへのリンク・変更の表示など、利用時の条件を定める。

https://creativecommons.org/licenses/by/4.0/