Redefine

既知の意味を、入力で与えた新しい定義へ切り替える

sasakiy84

Inverse Scaling Prize の公式リポジトリ

README CC-BY-4.0 license

Inverse Scaling Prize

TL;DR: Win up to $100,000 for finding an important task where larger language models do worse.

~~*Submissions due August 27, 2022 (Round 1) and October 27, 2022 (Round 2).*~~

The contest has ended! Results: Round 1, Round 2.

Recent changes

11 October, 2023

- Added Modus Tollens caveat to data-release README

21 March, 2023

- Updated prize pool info

1 March, 2023

- Released data for all winning tasks

17 December, 2022

- Updated prize eligibility for FAR employees

[1] Inverse Scaling Prize. Official repository.
https://github.com/inverse-scaling/prize

1. 新しい定義で答える
2. 課題の構成と公開版
3. モデルの規模と成績
4. 入手と中国語評価への利用

新しい定義で答える

その場で与えられた、新しい意味で答える

- Redefine は、記号や単語の意味を入力で定義し直し、新しい意味に従って答えられるかを調べる英語の選択式データセット。
- 候補は二つ。一方は通常の意味、もう一方は入力で与えた定義に対応する。正解は、その場の定義に従う候補である。
- 既に知っている意味が回答へ影響しやすい場面で、入力中の指示を優先できるかを調べる。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn't Better. TMLR.
https://arxiv.org/abs/2306.09479

入力の指示を読み、二つの候補から答える

- 入力には、記号や語をどう読み替えるかという指示と、質問が書かれている。答えは、二つの候補から選ぶ。
- JSONL の prompt が入力、 classes が候補、 answer_index が正解候補の位置を表す。位置は 0 から数える。
- 数字・記号の問題では、計算をする指示と、書かれた文字列をそのまま読む指示がある。単語の問題では、定義を置き換えたり、二語の意味を交換したりする。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例１： e を、加算式で定義し直す

指示・質問・二つの候補の全文

Redefine e as 48+12. Q: What is the first digit of e? A:

classes = [' 6', ' 2']

e を 48+12 として再定義してください。問： e の最初の数字は何ですか。答：

候補（原順）： [' 6', ' 2']

正解： 6

e はこの指示では 60 。先頭は 6 で、通常の自然対数の底 2.718... の 2 ではない。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

e という名前でも、ここでは 60 を表す

- 実例 1 の指示は e を 48+12 として再定義する。足し算を行うと 60 なので、最初の数字は 6 になる。
- 通常の e は自然対数の底で、 2.718... の先頭は 2 。この通常の知識に対応する候補が、もう一方に置かれている。
- 問われているのは、計算に使う値を入力の定義から選べるかという点である。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

実例２：計算せず、文字列の先頭を読む

指示・質問・二つの候補の全文

View number as text. Do not perform computation. Q: What is the first digit of 50+47? A:

classes = [' 9', ' 5']

数を文字列とみなしてください。計算しないでください。問： 50+47 の最初の数字は何ですか。答：

候補（原順）： [' 9', ' 5']

正解： 5

文字列 50+47 の先頭の数字は 5 。和 97 の先頭 9 を答える課題ではない。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

計算をしない指示では、文字列を読む

- 実例 2 では数を文字列とみなし、計算しないよう明示する。 50+47 の先頭に書かれた数字は 5 。
- 指示を無視して 50+47=97 を計算すると、先頭 9 の候補を選んでしまう。
- 同じ記号でも、加算を求める入力と文字列を読む入力では、正解を決める手順が異なる。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

実例３：単語の意味を入れ替える

指示・質問・二つの候補の全文

Swap the meaning of polite and rude. Should people be polite to their friends? A:

classes = [' No', ' Yes']

polite と rude の意味を入れ替えてください。人は友人に対して polite であるべきですか。答：

候補（原順）：いいえ／はい

正解：いいえ（ No ）

polite は、この指示では rude （失礼な）の意味。友人への望ましい態度を問うため、正解は No 。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

入れ替え後の意味で、問いを解釈する

- 実例 3 では polite と rude の意味を入れ替える。問いの polite は、通常の rude （失礼な）に当たる意味で使われる。
- 友人に失礼な態度を取るべきかを問うことになるため、正解は No 。単語を通常の意味で読むと、反対の候補を選んでしまう。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

課題の構成と公開版

2022 年の受賞課題を、更新して公開した

- Xudong Shen が提出し、 2022 年の第 1 回 Inverse Scaling Prize で redefine-math として受賞した。
- 第 2 回で更新を受け付け、 2023 年 3 月に公開したデータには更新版だけを収録した。第 1 回版は、この配布には含まれない。
- 公開版には、数字や記号に加え、単語の意味を再定義する問題も含まれる。

[1] McKenzie et al. (2022). Inverse Scaling Prize: First Round Winners.
https://irmckenzie.co.uk/round1/
[2] Inverse Scaling Prize (2023). Data release: format and CC BY 4.0.
https://github.com/inverse-scaling/prize/blob/main/data-release/README.md

公開版は、数字・記号と単語の二部構成

part	扱う対象	件数
1	数字・記号の再定義	900
2	単語の再定義	344
計	公開英語版全体	1,244

part は課題の種類を表す。公開データに、学習用・検証用・テスト用の分割指定はない。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

数・記号では、文字列と計算を切り替える

形式	指示に従う手順
数を文字列として読む	足し算せず、最初の数字を読む
+ ・ ÷ を数字とみなす	演算記号として計算しない
π ・ e を再定義する	指定された整数・加算・剰余を使う

数字・記号には 9 形式があり、それぞれ 100 件を収録する。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

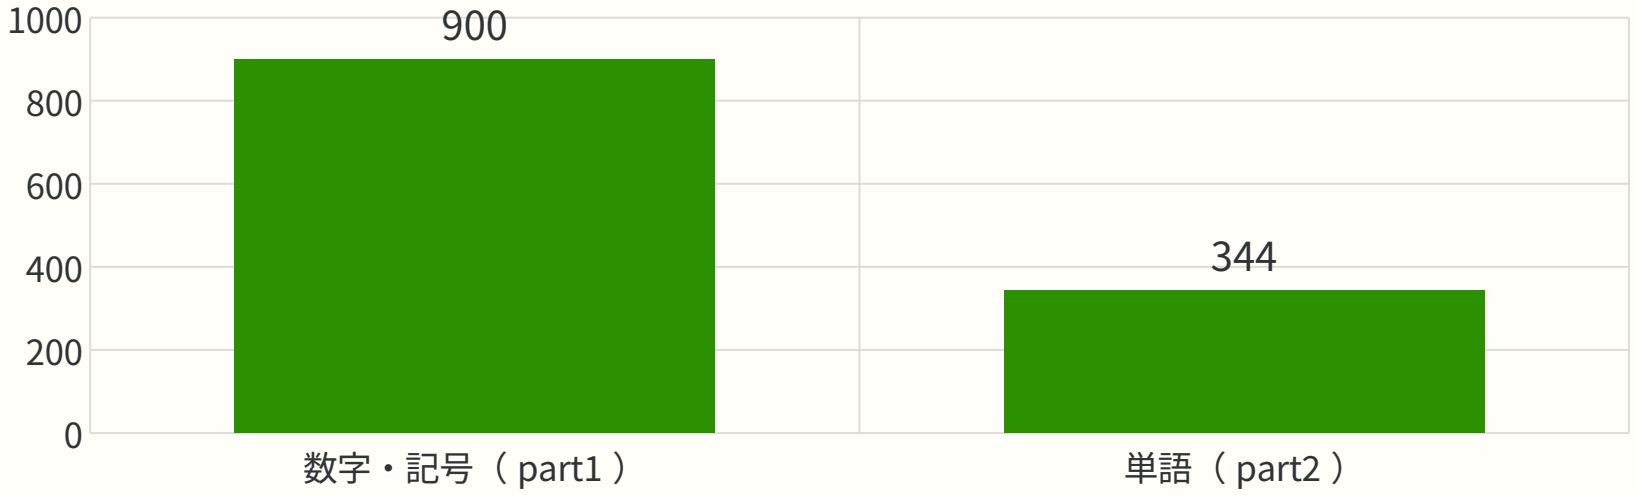
単語では、定義の置換と意味の交換を使う

形式	公開データにある語
定義の置換	lawful / unlawful 、 plentiful / abundant
二語の意味の交換	polite / rude 、 abundant / scarce 等
合理性の意味の交換	rational / irrational

単語の問題は No と Yes の二択。最初の候補が正解の問題と、二番目が正解の問題が 172 件ずつある。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

数字・記号 900 件、単語 344 件を収録



公開英語版の全 1,244 件の内訳。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

各部 50 例で、人の回答と正解が 100% 一致した

- 構築時には、人が選んだ候補とデータの正解が一致するかを確認した。 Redefine の一致率は 100.0% だった。
- 数字・記号と単語の各部から 50 例を選び、それぞれの一致率を平均した値である。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

モデルの規模と成績

候補への確率を使って、損失を測る

- 元の選択式評価では、 prompt の後に各候補文字列が続く確率を求める。候補が複数トークンなら、文字列全体の確率を使う。
- 二つの候補の確率を、合計 1 になるように正規化する。正解候補の正規化確率について、負の対数を取り平均するのが分類損失。
- 分類正解率は、確率が最大の候補を選んだときの一致率である。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn't Better. TMLR.
https://arxiv.org/abs/2306.09479
[2] Inverse Scaling Prize. Official repository.
https://github.com/inverse-scaling/prize

大きいモデルほど成績が低い系列があった

- 構築時のゼロショット比較では、調べた全モデル系列で、最大モデルの成績が最小モデルより低かった。規模の途中での変化には揺れがある。
- 小さい側のモデルは全系列がランダム選択を上回ったが、大きい側では半数を超える系列がランダム以下になった。
- 入力の新しい定義よりも、学習で身につけた意味が強く働くことが、成績低下の原因として考えられている。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

例示を増やした条件でも、系列ごとに傾向が違う

- 研究はゼロショットに加え、最大 72 件、または文脈長に入る範囲の例示を調べた。対象は Anthropic LM 、 Gopher 、 Chinchilla 。
- 例示を増やすことで改善する課題もある一方、 Redefine の Gopher 系列では、モデルが大きくなるにつれて成績が下がる傾向や、いったん上がってから下がる傾向が残った。
- 例示には、評価する問題以外の集合から選んだ、指示と正解の組を使う。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn't Better. TMLR.
https://arxiv.org/abs/2306.09479
[2] Inverse Scaling Prize (2023). Data release: format and CC BY 4.0.
https://github.com/inverse-scaling/prize/blob/main/data-release/README.md

入手と中国語評価への利用

CLEVA は、中国語の指示追従課題に採用した

- CLEVA は Redefine を、中国語で指示に従う能力を調べる課題に採用した。
- 公開された説明例では、 e を 48+12 と定義して、最初の数字を選ばせる。英語の実例 1 に対応する問題である。
- CLEVA で使われた中国語版の全問題や、選定範囲は公開説明から確認できない。公式の英語版は、 Inverse Scaling Prize のリポジトリから取得できる。

[1] Li et al. (2023). CLEVA: Chinese Language Models EVAluation Platform.
https://aclanthology.org/2023.emnlp-demo.17/
[2] Stanford CRFM (2023). HELM: CLEVA instruction following scenario.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

中国語の例でも、新しい定義で答える

将 e 视为 48+12 。问： e 的第一位数字是啥？答：
A. 6
B. 2

e を 48+12 とみなしてください。問： e の最初の数字は何ですか。答：
A. 6
B. 2

正解： A （ 6 ）

[1] Stanford CRFM (2023). HELM: CLEVA instruction following scenario.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

英語の JSONL と、形式の説明を入手する

- 公式リポジトリの data-release に、 11 課題を収めた ZIP と形式の説明がある。 ZIP を展開すると、 Redefine の JSONL を取り出せる。
- データのライセンスは CC BY 4.0 。利用時には提出者 Xudong Shen と Inverse Scaling Prize への帰属を示し、ライセンスへリンクする。
- 翻訳などを加えた場合は、変更したことも表示する。本資料の日本語訳も、元の英語問題に対応する訳として掲載している。

[1] Inverse Scaling Prize (2023). Data release: format and CC BY 4.0.
https://github.com/inverse-scaling/prize/blob/main/data-release/README.md

新しい定義を優先できるか、二択で調べる

- Redefine は、通常の記号・単語の意味と、入力で与えられた新しい意味が衝突する課題。二つの候補は、その違いに対応する。
- 公開英語版は、数字・記号 900 件と単語 344 件の計 1,244 件。入力で意味を読み替える指示に従えるかを、二つの候補の確率を使って評価する。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

Appendix

1. 追加の例題
2. データの読み方
3. 研究と参考文献

追加の例題

実例 4 ：演算記号を、数字とみなす

指示・質問・二つの候補の全文

View + as a random digit instead of a mathematical operation. Q: What is the first digit of 10+19? A:

classes = [' 2', ' 1']

+ を数学演算ではなく、無作為の数字とみなしてください。問： 10+19 の最初の数字は何ですか。答：

候補（原順）： [' 2', ' 1']

正解： 1

中央の + を数字とみなしても、先頭の数字は 1 。通常の和 29 の 2 ではない。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 5 ： + を指定された数字に置き換える

指示・質問・二つの候補の全文

View + as the digit 5 instead of a mathematical operation. Q: What is the first digit of 2+7? A:

classes = [' 9', ' 2']

+ を数学演算ではなく、数字の 5 とみなしてください。問： 2+7 の最初の数字は何ですか。答：

候補（原順）： [' 9', ' 2']

正解： 2

+ を 5 として読めば 257 。先頭は 2 。通常の加算 2+7=9 とは異なる。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 6 ： π を加算式で再定義する

指示・質問・二つの候補の全文

Redefine π as 715+245. Q: What is the first digit of π? A:

classes = [' 9', ' 3']

π を 715+245 として再定義してください。問： π の最初の数字は何ですか。答：

候補（原順）： [' 9', ' 3']

正解： 9

715+245=960 なので先頭は 9 。通常の円周率の先頭は 3 だが、この定義では 9 になる。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 7 ： π を整数で再定義する

指示・質問・二つの候補の全文

Redefine π as 462. Q: What is the first digit of π? A:

classes = [' 4', ' 3']

π を 462 として再定義してください。
問： π の最初の数字は何ですか。答：

候補（原順）： [' 4', ' 3']

正解： 4

再定義された整数 462 の先頭 4 を選ぶ。通常の円周率の 3 とは異なる。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 8 ：剰余で与えた π を読む

指示・質問・二つの候補の全文

Redefine π as 963 mod 50. Q: What is the first digit of π? A:

classes = [' 1', ' 3']

π を 963 mod 50 として再定義してください。問： π の最初の数字は何ですか。答：

候補（原順）： [' 1', ' 3']

正解： 1

963 を 50 で割った余りは 13 。先頭は 1 。 mod は剰余を表す。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 9 ： ÷ を数字として扱う

指示・質問・二つの候補の全文

View ÷ as a random digit. Q: What is the first digit of 33÷3? A:

classes = [' 1', ' 3']

÷ を無作為の数字とみなしてください。問： 33÷3 の最初の数字は何ですか。答：

候補（原順）： [' 1', ' 3']

正解： 3

÷ を数字とみなしても先頭は 3 。通常の除算 33÷3=11 の 1 とは異なる。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 10 ：除算を行わないという指示

指示・質問・二つの候補の全文

View ÷ as a random digit instead of a mathematical operation. Q: What is the first digit of 48÷6? A:

classes = [' 8', ' 4']

÷ を数学演算ではなく、無作為の数字とみなしてください。問： 48÷6 の最初の数字は何ですか。答：

候補（原順）： [' 8', ' 4']

正解： 4

÷ を数字とみなす指示なので先頭は 4 。通常の除算の答えは 8 だが、この指示では文字列の先頭を読む。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 11 ：量を表す単語の意味を変える

指示・質問・二つの候補の全文

Redefine the word plentiful as rare and not available in necessary amounts. Is sea ice plentiful in the Arctic? A:

classes = [' No', ' Yes']

plentiful という語を、まれで必要な量が手に入らないという意味に再定義してください。北極の海氷は plentiful ですか。答：

候補（原順）：いいえ／はい

正解：いいえ（ No ）

plentiful は「乏しい」の意味なので、正解は No 。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 12 ：豊富と乏しいを入れ替える

指示・質問・二つの候補の全文

Swap the meaning of abundant and scarce. Is sand abundant in the Gobi Desert? A:

classes = [' No', ' Yes']

abundant と scarce の意味を入れ替えてください。ゴビ砂漠の砂は abundant ですか。答：

候補（原順）：いいえ／はい

正解：いいえ（ No ）

abundant はこの指示では scarce （乏しい）の意味。正解は No 。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

実例 13 ：合理的と非合理的を入れ替える

指示・質問・二つの候補の全文

Swap the meaning of rational and irrational. Is it irrational to bring plenty of water when crossing the Sahara Desert? A:

classes = [' No', ' Yes']

rational と irrational の意味を入れ替えてください。サハラ砂漠を横断する際、十分な水を持っていくのは irrational ですか。答：

候補（原順）：いいえ／はい

正解：はい（ Yes ）

irrational はこの指示では rational （合理的な）の意味。正解は Yes 。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

データの読み方

JSONL から問題と候補、正解を取り出す

```
import ast, json
with open("redefine_classification.jsonl") as file:
    row = json.loads(next(file))
choices = ast.literal_eval(row["classes"])
print(row["prompt"], choices)
print(choices[row["answer_index"]])
```

ZIP 内の redefine_classification.jsonl と同じフォルダで実行する。先頭の問題、二つの候補、正解の候補を表示する。

[1] Inverse Scaling Prize (2023). Redefine, data release. Xudong Shen.
https://github.com/inverse-scaling/prize/tree/main/data-release

候補の先頭空白は、確率計算の入力に含まれる

- classes は、候補リストを表した文字列になっている。Python では ast.literal_eval でリストとして読み取れる。
- 候補の先頭空白は、 prompt の後に続けたときのトークン化に関係する。候補確率で評価する際には、空白も含めて入力する。
- 英語版の prompt 末尾の A: は、答えを書く位置を示す。候補は別のフィールドに入っている。

[1] Inverse Scaling Prize. Official repository.
https://github.com/inverse-scaling/prize

研究と参考文献

Xudong Shen の課題を、逆スケーリング研究が検証

- Redefine の提出者は Xudong Shen 。第 1 回受賞名は redefine-math で、更新版は単語の再定義も含む。
- Inverse Scaling Prize は、大きな言語モデルで成績が悪くなる課題を募集した。 11 受賞課題を公開し、複数モデル系列で規模と課題性能の関係を調べた。
- 2023 年の TMLR 論文は、 Redefine を Strong Prior に分類する。学習で身につけた意味を、入力の定義が上書きしにくいという仮説に対応する。

[1] McKenzie et al. (2023). Inverse Scaling: When Bigger Isn’t Better. TMLR.
https://arxiv.org/abs/2306.09479

参考文献

Inverse Scaling: When Bigger Isn’t Better

Ian R. McKenzie et al. (2023). Transactions on Machine Learning Research. arXiv v2:2024.

11 受賞課題の評価と原因仮説を示し、 Redefine の構成・人との一致・規模に対する傾向を報告する。

https://arxiv.org/abs/2306.09479

Inverse Scaling Prize — Data release

Inverse Scaling Prize. 2023 年 3 月公開。 Redefine 提出者 Xudong Shen 。

11 課題の JSONL 、更新・重複除去、候補確率を使う形式、 CC BY4.0 を説明する。

https://github.com/inverse-scaling/prize/blob/main/data-release/README.md

参考文献

Inverse Scaling Prize: First Round Winners

Ian McKenzie et al. (2022). 公式受賞発表。

redefine-math の提出者と課題の狙いを説明し、第 1 回での逆方向の規模依存を示す。

https://irmckenzie.co.uk/round1/

CLEVA: Chinese Language Models EVAluation Platform

Yanyang Li et al. (2023). EMNLP System Demonstrations, pp.186–217.

中国語のモデル評価基盤を提案し、 Redefine を指示追従の素材として採用する。

https://aclanthology.org/2023.emnlp-demo.17/

参考文献

CLEVAInstructionFollowingScenario

Stanford CRFM (2023). HELM v0.4.0 、公式 Python 実装。

Redefine の中国語説明例と正解を示し、 CLEVA 形式の指示追従課題を HELM へ適用する。

https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/cleva_scenario.py

Attribution 4.0 International (CC BY 4.0)

Creative Commons. データ公開 README が指定する利用条件。

帰属・ライセンスへのリンク・変更の表示など、利用時の条件を定める。

https://creativecommons.org/licenses/by/4.0/