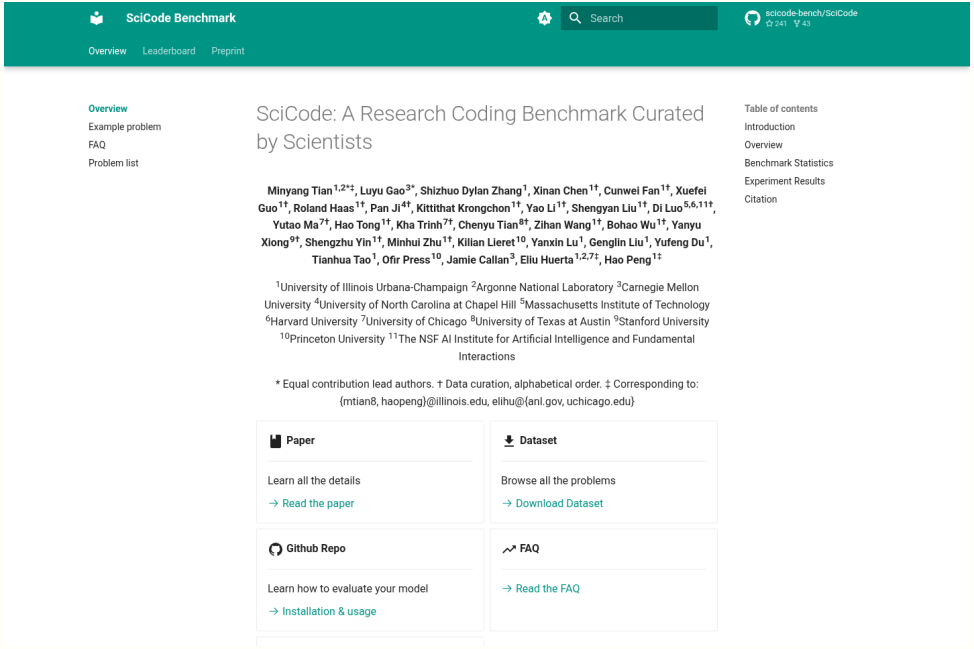
SciCode

科学研究の計算手順を Python コードにする
科学者が作成した段階的なコード生成の評価

sasakiy84

SciCode の公式サイト



https://scicode-bench.github.io/

1. 科学の計算手順とコードの実例

2. 数値テストの採点とモデル評価

3. 科学者による作成とデータの構成

4. 公開後の拡張と評価の利用

1. 科学の計算手順とコードの実例

科学の知識を、実行できる計算手順へ変える

- SciCode は、科学者が研究で使う計算やシミュレーションを Python で実装する能力を評価する。
- 数学・物理・化学・生物・材料科学の 5 分野にわたる 80 の主課題を、生成対象となる 338 の部分問題に分けている。
- 各段階で関数を生成し、前の段階のコードを利用して、最後に主課題全体の解を作る。

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

Gram–Schmidt 直交化を複数の関数に分ける

主課題 29 の段階	実装する内容
29.1 ：正規化	ベクトルを長さ 1 にそろえる
29.2 ：内積	2 つのベクトルの内積を求める
29.3 ：直交化	前の関数を使い、直交する基底を作る

主課題 29 は Gram–Schmidt 直交化。
部分問題の関数を組み合わせて主課題を解く。

Tian et al. SciCode. Hugging Face 公式配布データ、改訂 4510f6a 。 2026-10-16 参照。 https://huggingface.co/datasets/SciCode1/SciCode

実例は開発用 15 主課題から 13 件を選ぶ

- 本資料は、参照解が公開されている開発用集合（Hugging Face の validation）の 15 主課題から、 13 主課題の部分問題を 1 件ずつ紹介する。
- 本編では正規化、原子間のポテンシャル、振り子の運動の 3 件を扱い、 Appendix に他の 10 件を置く。
- テスト集合は別の 65 主課題。公開されている問題文とテストの形式も、開発用集合と合わせて説明する。

Tian et al. SciCode. Hugging Face 公式配布データ、改訂 4510f6a 。 2026-10-16 参照。 https://huggingface.co/datasets/SciCode1/SciCode

実例 1 ：ベクトルを長さ 1 にそろえる

公開された部分問題（原文の抜粋）

Provide a fucntion that normalizes the input vector. The input should be a numpy array and the output should be a numpy array with the same shape.

主課題 29 の最初の段階。入力と同じ形の配列を返し、次の内積・直交化の計算で使えるようにする。

Tian et al. SciCode / validation. 主課題 29 、部分問題 29.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

正規化：入力 [3, 4] を [0.6, 0.8] に変換する

公開参照解（関数本体）

```
def normalize(v):
    norm = np.linalg.norm(v)
    n = v / norm if norm else v
    return n
```

配布テストの入力は v = [3, 4] 。参照解を実行すると [0.6, 0.8] となる。参照解ではノルムで割り、ゼロベクトルは変更しない。

Tian et al. SciCode / validation. 主課題 29 、部分問題 29.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

実例２：原子間のポテンシャルを計算する

公開された部分問題（原文の抜粋）

Write a function to get lennard jones potential with potential well depth epislon that reaches zero at distance sigma between pair of atoms with distance r.

Lennard–Jones ポテンシャルは、２原子間の距離から相互作用エネルギーを計算する。σ は値が 0 となる距離、ε は井戸の深さを表す。

Tian et al. SciCode / validation. 主課題 47 、部分問題 47.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

ポテンシャル：距離の 6 乗と 12 乗を使う

公開参照解（関数本体）

```
def U_ij(r, sigma, epsilon):
    q6 = (sigma / r) ** 6
    q12 = q6 ** 2
    U = 4 * epsilon * (q12 - q6)
    return U
```

配布テストは r = 0.5 、 σ = 1 、 ε = 3 。参照解の出力は 48,384 。主課題 47 では、原子対のポテンシャルを集計して内部エネルギーを求める。

Tian et al. SciCode / validation. 主課題 47 、部分問題 47.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

実例３：振り子の角度と角速度の変化を返す

公開された部分問題（原文の抜粋）

The motion of a forced, damped single pendulum can be described by the second-order differential equation.

重力による復元力、速度に比例する減衰、周期的な外力を持つ振り子。角度 θ と角速度 ω から、それぞれの時間変化を返す。

Tian et al. SciCode / validation. 主課題 78 、部分問題 78.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

振り子：復元力・減衰・外力を組み合わせる

公開参照解（関数本体）

```
def pendulum_derivs(state, t, g, L, beta, A, alpha):
    theta, omega = state
    dtheta_dt = omega
    domega_dt = (
        -(g / L) * np.sin(theta) - beta * omega
        + A * np.cos(alpha * t))
    state_matrix = np.array([dtheta_dt, domega_dt])
    return state_matrix
```

β が減衰係数、 A が外力の振幅、 α がその角振動数。主課題 78 では、この関数を数値積分し、振り子の動きを調べる。

Tian et al. SciCode / validation. 主課題 78 、部分問題 78.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

2. 数値テストの採点とモデル評価

計算値と科学的な性質をテストする

テストの種類	確かめる内容
数値テスト	入力に対する出力を参照値と比較する
分野固有の検証	既知の理論や論文の結果を再現する

分野固有の検証の例： 2 次元 Ising モデルの相転移温度や、
分子系のエネルギー・運動量の性質を確かめる。

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

正規化のテストは配列を参照値と比較する

```
v = np.array([3,4])
assert np.allclose(normalize(v), target)
```

部分問題 29.1 の配布テストをそのまま掲載。 target には、別ファイルの test_data.h5 に保存された期待値を読み込む。

Tian et al. SciCode / validation. 主課題 29 、部分問題 29.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

全段階と統合した計算を採点する

- 部分問題では、生成した関数をテストして正誤を判定する。前の部分問題の関数も、後のコードと一緒に読み込む。
- 主課題では、部分問題の解に加えて、組み合わせた主課題全体の解が正しいことを求める。
- 標準設定では、科学的な背景説明を与えず、前段階にはモデル自身が生成したコードを使う。

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

主課題と部分問題をそれぞれ集計する

採点例	部分問題の正解数	主課題の正解
A	3 問中 3 問	○
B	2 問中 1 問	×

この例の主課題正解率は 1/2 = 50% 。
部分問題正解率は 4/5 = 80% 。

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

現行モデルの公式比較にも使われている

モデル／推論設定	SciCode
Gemini 3.1 Pro / High	59%
Claude Opus 4.6 / Max	52%
GPT-5.2 / xhigh	52%

Google DeepMind の公式 Performance 表。
High ・ Max ・ xhigh は各モデルの推論設定。

Google DeepMind (2026). Gemini 3.1 Pro. Performance: SciCode. 2026-10-16 参照。 https://deepmind.google/models/gemini/pro/

登場時は主課題を解くことが難しかった

2024 年のモデル	部分問題	主課題
Claude 3.5 Sonnet	26.0%	4.6%
GPT-4o	25.0%	1.5%
Gemini 1.5 Pro	21.9%	1.5%

Tian ら（ 2024 ）の標準設定、 pass@1 。
背景説明なし・前段階にはモデルの生成コードを使う。

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

背景説明と、前段階のコードを切り替えられる

- 背景説明の有無と、前段階のコードの出所という 2 つの軸で、科学知識とコード生成を調べる。
- 背景説明ありでは、科学者が書いた科学的な知識や計算手順をプロンプトへ加える。なしでは、モデル自身が必要な知識を補う。
- 前段階に参照解を使う設定では、対象の部分問題の実装能力に焦点を当てる。生成コードを使う設定では、前の段階からの誤りも引き継ぐ。

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

3. 科学者による作成とデータの構成

研究で使うスクリプトから課題を選ぶ

- SciCode は、科学者が日々の研究で使う計算や、既存の理論・論文の結果を再現する手順をもとに作られた。
- 複雑な系を計算する数値手法、系の動きを追うシミュレーション、観測量を求める科学計算を主な対象とする。
- 科学の知識と推論が必要な課題を選び、入力・出力を持つ Python 関数に分解する。

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

問題文・背景説明・参照解・テストを作る

- 主課題を部分問題へ分け、各段階の入力、出力、関数の形式と、それまでの関数との関係を記述する。
- 科学者が参照解とテストを書き、 NumPy ・ SciPy ・ SymPy などの科学計算ライブラリを用いて実装する。
- 科学的な背景説明も用意し、必要な知識を与える設定と、モデルが自力で補う設定の両方を評価できるようにする。

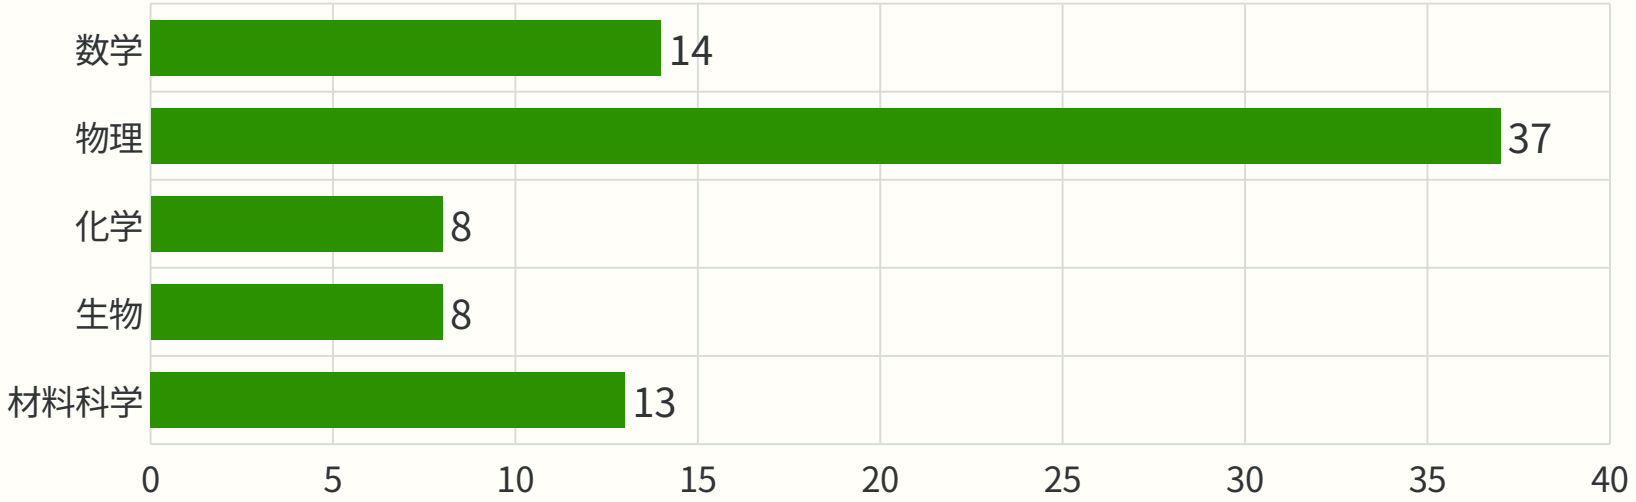
Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

3 段階の検証で問題とテストを修正する

検証する人・方法	確認・修正する内容
同じ分野の科学者 2 人以上	科学的な正確さ、参照解、分野固有テスト
別分野の科学者 1 人	問題文と背景説明の明確さ・必要な情報
GPT-4 で生成し、科学者が分析	生成の誤りを調べ、設問・数値テストを改善

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

80 の主課題は 5 分野にまたがる



Tian ら（2024）の 16 小分野の分類を、5 分野へまとめた。

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

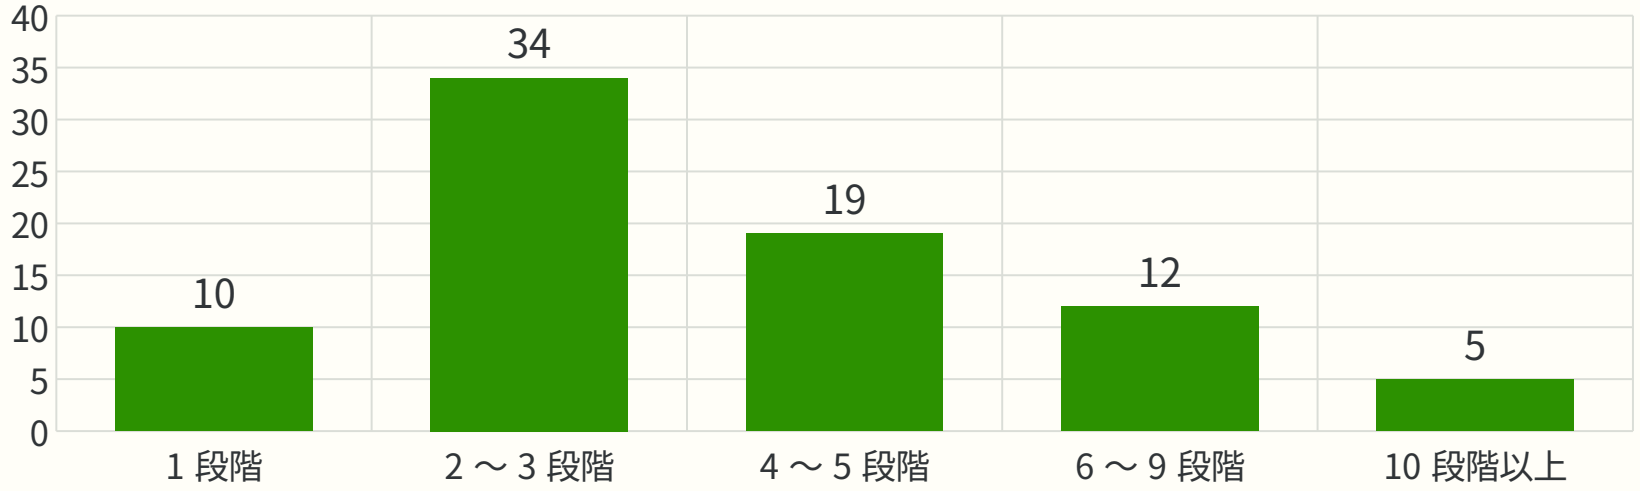
開発 15 主課題、テスト 65 主課題に分ける

集合	主課題	生成対象の部分問題	固定コード
開発 / validation	15	50	0
テスト / test	65	288	3
合計	80	338	3

配布レコードは合計 341 段階。うち 3 段階は固定コードを渡す。

SciCode team. SciCode: validation 15 主課題・ test 65 主課題を全件集計。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/tree/4510f6a

1 主課題あたりの生成対象は中央値 3 段階



縦軸は主課題数。 80 主課題を集計し、固定コードの 3 段階を除いた生成段階数で分類する。

SciCode team. SciCode: validation 15 主課題・ test 65 主課題を全件集計。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/tree/4510f6a

4. 公開後の拡張と評価の利用

背景説明と評価ツールの整備が進んだ

時期	公開・追加されたもの
2024 年 7 月	論文・データ、科学者が書いた背景説明
2024 年 11 月	公式リーダーボード
2025 年 1 月	Inspect AI による評価の連携
2025 年 2 月	Hugging Face Datasets での配布

SciCode team. SciCode: evaluation code and instructions. 改訂 e3158ea 。 https://github.com/scicode-bench/SciCode

Inspect AI で生成とテストを実行する

```
inspect eval scicode.py \
    --model openai/gpt-4o \
    -T split=test \
    -T with_background=False
```

公式の Inspect AI 連携例。モデル、分割、背景説明の有無を指定し、生成コードとテスト結果を保存する。数値参照値の test_data.h5 を別途用意する。

SciCode team. SciCode Evaluation using inspect_ai: README. 改訂 e3158ea 。 https://github.com/scicode-bench/SciCode/blob/e3158ea/eval/inspect_ai/README.md

3 つの段階で、固定コードを後続の計算へ渡す

段階	渡される内容
13.6 / Maxwell 方程式	場をまとめるオブジェクト
62.1 / DMRG	量子系のブロックを表すクラス
76.3 / タンパク質と DNA	DNA 配列の生成器

公式実装はこの 3 段階の生成を省き、配布コードを読み込む。
DMRG は、量子系の状態を段階的に近似する計算法。

SciCode team. SciCode Evaluation using inspect_ai. 改訂 e3158ea 。 https://github.com/scicode-bench/SciCode/blob/e3158ea/eval/inspect_ai/scicode.py

科学の計算を段階的な実装と統合で評価する

- SciCode は、科学者が作成した 80 の主課題を、生成対象となる 338 の部分問題に分けたものである。
- モデルは関数を順に生成し、それまでのコードを使って研究課題全体の計算を完成させる。
- 数値テストと科学的な検証を使い、背景知識の有無や前段階のコードの出所も切り替えて評価できる。

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

Appendix

1. 分野の異なる追加例

2. 分布・形式と実装の詳細

3. 著者と参考文献

1. 分野の異なる追加例

追加例 1 ： Ewald 和の分割パラメータを決める

公開参照解（計算部分の抜粋）

```
alpha = alpha_scaling * np.max(np.linalg.norm(recvec, axis=1))
return alpha
```

化学：周期系の電荷の相互作用を求める主課題 10 の最初の段階。逆格子ベクトルの最大の長さを 5 倍し、実空間と逆空間の分割を決める。

Tian et al. SciCode / validation. 主課題 10 、部分問題 10.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

追加例 2 ：共役勾配法で連立方程式を解く

公開参照解（計算部分の抜粋）

```
res = b - np.dot(A, x)
search_direction = res.copy()
old_res_norm = np.linalg.norm(res)
```

数学： Ax = b を反復計算で解く主課題 1 。参照解は、初期の残差と探索方向を作り、解と残差を更新しながら収束させる。

Tian et al. SciCode / validation. 主課題 1 、部分問題 1.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

追加例３：下三角行列を使って解を更新する

公開参照解（計算部分の抜粋）

```
M = D+L
N = U
xi1 = np.linalg.solve(M, b) - np.linalg.solve(M, np.matmul(N,xi))
```

数学：主課題３の Gauss–Seidel 法。 D は対角成分、 L ・ U は下・上三角成分。 M を使って解を順に更新し、収束するまで反復する。

Tian et al. SciCode / validation. 主課題３、部分問題 3.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

追加例 4 ：不完全 Cholesky 分解を計算する

公開参照解（計算部分の抜粋）

```
for k in range(nrow):
    A[k, k] = np.sqrt(A[k, k])
    for i in range(k+1, nrow):
        if A[i, k] != 0:
            A[i, k] = A[i, k] / A[k, k]
```

数学：主課題 4 では、行列のゼロ成分を保ちながら三角因子を作る。この抜粋は、対角成分と同じ列の非ゼロ成分を更新する部分。

Tian et al. SciCode / validation. 主課題 4 、部分問題 4.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

追加例 5 ：レーザー像の高い空間周波数を除く

公開参照解（計算部分の抜粋）

```
input_f_image = fftshift(fft2(image_array))
filtered_f_image[i, j] = T[i, j] * input_f_image[i, j]
filtered_image = np.real(ifft2(ifftshift(filtered_f_image)))
```

物理：主課題 6 の空間フィルター。像をフーリエ変換し、円形の低周波領域だけを通すマスク T を掛け、逆変換する計算部分を抜粋。

Tian et al. SciCode / validation. 主課題 6 、部分問題 6.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

追加例 6 ：量子状態のもつれを数値化する

公開参照解（計算部分の抜粋）

```
n = int(np.log2(len(psi)))
sigma_y = np.array([[0,-1j],[1j,0]])
product = sigma_y
for i in range(n-1):
    product = tensor(product,sigma_y)
psi_star = product @ np.conj(psi)
tangle = (abs(np.inner(psi,psi_star)))**2
```

物理：主課題 19 の n-tangle は、偶数個の量子ビットのもつれを表す。19.1 の tensor 関数で、行列のテンソル積を組み立てる。

Tian et al. SciCode / validation. 主課題 19 、部分問題 19.2 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

追加例 7 ：結晶の逆格子ベクトルを作る

公開参照解（計算部分の抜粋）

```
deno = np.dot(a1,cross(a2,a3))
b_i = []
b_i.append(2*np.pi*cross(a2,a3)/deno)
b_i.append(2*np.pi*cross(a3,a1)/deno)
b_i.append(2*np.pi*cross(a1,a2)/deno)
```

物理：主課題 38 の 3 次元逆格子。格子の 3 ベクトルから、結晶の周期を波数空間で表すベクトルを作る。 cross は 38.1 で実装する外積。

Tian et al. SciCode / validation. 主課題 38 、部分問題 38.2 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

追加例 8 ：分子鎖の結合と分解の変化率を返す

公開参照解（計算部分の抜粋）

```
li = c - np.sum(d, axis=0)
ri = c - np.sum(d, axis=1)
dcomp = GetComp(d)
ystep_2d = (
    lig * np.tile(ri, (Z, 1)).T
    * np.tile(li, (Z, 1)) * dcomp - d)
```

生物：主課題 44 は、 2 単位の分子鎖である 2-mer の濃度とエントロピーを追う。鎖の両端と相補鎖の濃度から、結合で増える量と分解で減る量を計算する。

Tian et al. SciCode / validation. 主課題 44 、部分問題 44.2 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

追加例 9 ：天体間の重力を成分ごとに集計する

公開参照解（計算部分の抜粋）

```
deltaxyz = xin[i,0:3] - xin[:,0:3]
r = np.sqrt(np.sum(deltaxyz*deltaxyz,axis=1))
r[i] = -1
f[i,0] = -ggrav * np.sum(
    deltaxyz[:,0] * mass*mass[i]/(r**3))
```

物理：主課題 49 は、多天体系の位置と速度を時間発展させる。これは、各天体に働く重力の x 成分を他の天体について足し合わせる部分。

Tian et al. SciCode / validation. 主課題 49 、部分問題 49.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

追加例 10 ：原子間の力を計算する

公開参照解（計算部分の抜粋）

```
s = np.linalg.norm(r)
q6 = (sigma/s)**6
q12 = q6**2
f = (48*epsilon/s**2)*(q12 - 0.5*q6)*r
return f
```

材料科学：主課題 51 の最初の段階。 3 次元の変位 r から Lennard–Jones ポテンシャルによる力を返す。後の段階では原子ごとの合力を求め、位置と速度を更新する。

Tian et al. SciCode / validation. 主課題 51 、部分問題 51.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

2. 分布・形式と実装の詳細

論文で示された 16 小分野（前半）

小分野	主課題数
数値線形代数	8
計算力学	5
計算ファイナンス	1
物性物理	13
光学	10
量子情報・量子計算	6
計算物理	5
天体物理	2

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

論文で示された 16 小分野（後半）

小分野	主課題数
素粒子物理	1
量子化学	5
計算化学	3
生態学	6
生化学	1
遺伝学	1
半導体材料	7
分子モデリング	6

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

部分問題 1 件あたりのテストは中央値 3 件

集合	部分問題	テストコード数
開発 / validation	50	167
テスト / test	288	915
合計	338	1,082

各部分問題の test_cases 配列の長さを集計。
部分問題あたりの中央値は、両集合とも 3 件。

SciCode team. SciCode: validation 15 主課題・ test 65 主課題を全件集計。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/tree/4510f6a

各段階は問題文・関数形式・テストを持つ

フィールド	保存される内容
step_description_prompt	その段階で計算する内容
function_header	引数・戻り値と関数の形式
step_background	科学者が書いた背景説明
test_cases	関数を呼ぶ入力と assert 文

Tian et al. SciCode. Hugging Face 公式配布データ、改訂 4510f6a 。 2026-10-16 参照。 https://huggingface.co/datasets/SciCode1/SciCode

数値の比較には許容誤差を使う

```
assert np.allclose(normalize(v), target)
```

29.1 のテストは NumPy の allclose を使う。既定では rtol = 10^{-5} 、 atol = 10^{-8} で、差の絶対値を atol + rtol × |target| と比較する。

Tian et al. SciCode / validation. 主課題 29 、部分問題 29.1 。改訂 4510f6a 。 https://huggingface.co/datasets/SciCode1/SciCode/blob/4510f6a/problems_dev.jsonl

参照した Inspect 連携では分母に固定段階が残る

主課題	配布の段階数	生成・採点する段階数
13 ： Maxwell 方程式	15	14
62 ： DMRG	6	5
76 ：タンパク質と DNA	4	3

改訂 e3158ea は固定段階を採点から省く一方、
主課題の完全正解判定には配布の段階数を使っている。

SciCode team. SciCode Evaluation using inspect_ai. 改訂 e3158ea 。 https://github.com/scicode-bench/SciCode/blob/e3158ea/eval/inspect_ai/scicode.py

参照値・生成コード・テスト結果を保存する

- JSONL には問題文、関数の形式、テストの入力と assert 文を置く。数値の参照値は test_data.h5 から読み込む。
- 公式の評価コードは、生成した関数と前段階のコードを保存し、テストコードを付けた Python スクリプトを実行する。
- Inspect AI 連携ではモデル、 split 、背景説明、コードとログの保存先を指定できる。

SciCode team. SciCode Evaluation using inspect_ai: README. 改訂 e3158ea 。 https://github.com/scicode-bench/SciCode/blob/e3158ea/eval/inspect_ai/README.md

3. 著者と参考文献

科学者と AI 研究者が共同で課題を設計した

- 共同第一著者は Minyang Tian と Luyu Gao 。論文の責任著者は Minyang Tian 、 Eliu Huerta 、 Hao Peng 。
- 著者には自然科学の各分野で課題を作成した研究者と、言語モデル・評価を研究する研究者が含まれる。
- 2024 年 7 月に公開し、 NeurIPS 2024 Datasets and Benchmarks Track で発表した。

Tian, Gao et al. (2024). SciCode: A Research Coding Benchmark Curated by Scientists. NeurIPS 2024 Datasets and Benchmarks. https://arxiv.org/abs/2407.13168

参考文献

SciCode: A Research Coding Benchmark Curated by Scientists

Minyang Tian, Luyu Gao et al. / NeurIPS 2024 Datasets and Benchmarks

研究の計算手順を部分問題へ分解し、科学知識とコード生成の評価を提案した。

https://arxiv.org/abs/2407.13168

SciCode

SciCode team / Hugging Face Datasets / 改訂 4510f6a

問題文・関数形式・背景説明・テストと、開発用の参照解を配布する。

https://huggingface.co/datasets/SciCode1/SciCode

参考文献

SciCode: evaluation code and instructions

SciCode team / GitHub / 改訂 e3158ea

生成コードの組み立てと、数値テスト・参照値による採点の公式実装。

https://github.com/scicode-bench/SciCode

FAQ

SciCode team / 2026-10-16 参照

科学者による検証、背景説明、固定コードの役割を補足する。

https://scicode-bench.github.io/faq/

参考文献

SciCode Evaluation using inspect_ai

SciCode team / GitHub README / 改訂 e3158ea

分割・背景説明・参照解の指定方法と、 Inspect AI による評価手順を説明する。

https://github.com/scicode-bench/SciCode/blob/e3158ea/eval/inspect_ai/README.md

Gemini 3.1 Pro

Google DeepMind / 2026 / Model performance

SciCode を含む現行モデルの公式比較と、各モデルの推論設定を掲載する。

https://deepmind.google/models/gemini/pro/