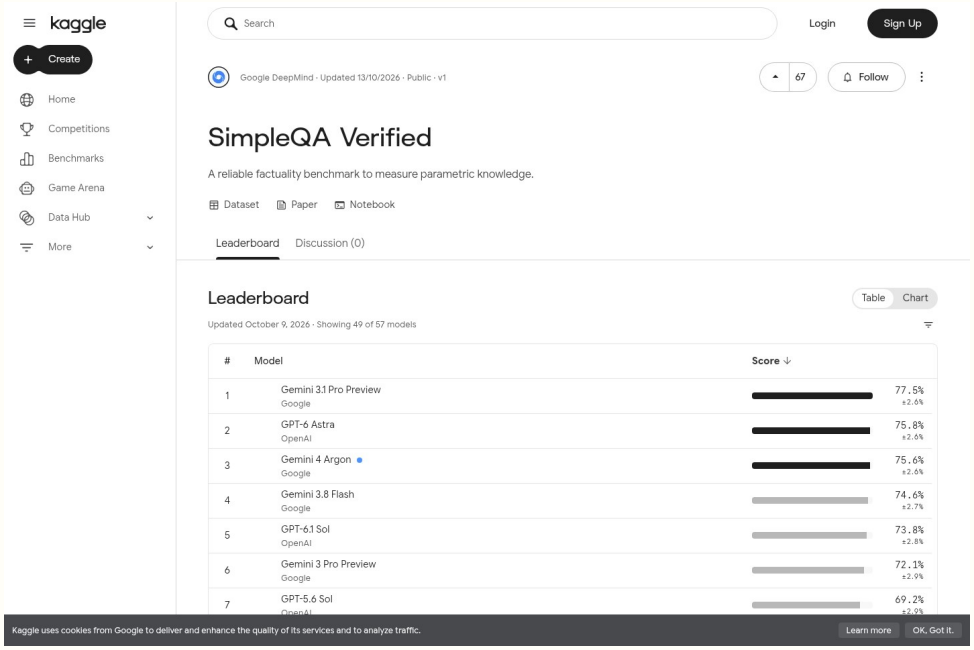
SimpleQA Verified

モデルが蓄えた知識で、短い事実質問に答える
重複・偏り・正解を見直した 1,000 問の評価データ

sasakiy84

SimpleQA Verified の公式サイト



https://www.kaggle.com/benchmarks/deepmind/simpleqa-verified

1. 事実質問と公開実例

2. 正誤・回答保留と評価指標

3. データの再検証と構成

4. 利用方法とまとめ

1. 事実質問と公開実例

外部検索を使わず、事実の知識を測る

- SimpleQA Verified は、英語の短い事実質問 1,000 問で、モデルが内部に蓄えた知識の正確さを測る評価データセット。Google DeepMind と Google Research が 2025 年に公開した。
- 入力は質問文、出力はその問いへの回答。 Web 検索や検索拡張は使わず、モデル自身の知識から答える。正解と照合するための参照 URL も配布する。
- 人物、日付、数量、場所などの事実を問い、モデルの正答・誤答・回答保留を集計する。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

SimpleQA の 4,326 問から、正解と構成を見直す

- 元の SimpleQA は、 OpenAI が 2024 年に公開した事実質問の評価。難しい質問を人が作り、正答・誤答・未回答でモデルを採点する。
- Google の Verified では、同じ出典や似た問題の重複、話題と答えの種類の偏り、資料間で食い違う正解を見直した。
- 重複の整理から出典の再確認まで、著者自身が段階的に実施したと報告する。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

公開 1,000 問から、本編 3 件と追加 10 件を選ぶ

- 実例は公式 CSV の公開問題。英語の質問全文に、日本語訳と配布正解を添える。
- 人物、日付、数値や許容範囲など、答え方の異なる問題を扱う。参照元の original_index は、元の SimpleQA での問題番号である。
- 使用する配布改訂は 2026 年 3 月 9 日。問題数は 1,000 のまま、 Lilongwe の座標を問う文が修正されている。

Google DeepMind / Google Research. SimpleQA Verified. MIT 、改訂 0dc97e0 。 https://huggingface.co/datasets/google/simpleqa-verified

実例 1 ：芸術家の生年月日を答える

質問（原文・全文）

On what day, month, and year was Algerian artist Mohammed Racim born?

質問の日本語訳

アルジェリアの芸術家 Mohammed Racim は、何年何月何日に生まれたか。

配布正解： 1896 年 6 月 24 日

Google. SimpleQA Verified / original_index 43 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=13

実例２：店を開いたドラマーを特定する

質問（原文・全文）

Which famous drummer opened a Wahoo's Fish Taco restaurant in Norco, California, in 2004?

質問の日本語訳

2004 年、カリフォルニア州 Norco で Wahoo’s Fish Taco の店を開いた有名なドラマーは誰か。

配布正解： Travis Barker

Google. SimpleQA Verified / original_index 337 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=82

実例３：都市の経度を小数で答える

質問（原文・全文）

What is the longitude of Lilongwe in decimal format?

質問の日本語訳

Lilongwe の経度を、小数表記で答えよ。

配布正解： 33.7738°E （許容範囲 33.7586 〜 33.8022 ）

Google. SimpleQA Verified / original_index 55 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=15

2. 正誤・回答保留と評価指標

回答を、正答・誤答・未回答の 3 種類に判定する

判定	生年月日の問題への説明用の回答
正答： CORRECT	「1896 年 6 月 24 日」
誤答： INCORRECT	「1897 年 6 月 24 日」
未回答： NOT_ATTEMPTED	「わかりません」

GPT-4.1 の判定器が、質問・参照正解・モデルの回答を照合する。
質問に直接答える部分を中心に判定する。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

100 問で、 40 正答・ 10 誤答・ 50 未回答なら

判定	説明用の件数（問）
正答	40
誤答	10
未回答	50

全 100 問のうち、正答は 40 問。
答えを出した 50 問に限ると、正答は 40 問。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

全問での正答率と、答えた中での正答率を使う

指標	説明用の 100 問での計算
全問での正答率	40 / 100 = 40%
回答した中での正答率	40 / 50 = 80%
F1 （2 つの調和平均）	2 × 40 × 80 / (40 + 80) ≈ 53.3%

F1 は、正答を広く出せることと、出した答えの正確さをまとめる。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

論文の比較では、 Gemini 2.5 Pro の F1 が 55.6

モデル（ 2025 年評価）	正答率	回答内正答率	F1
Gemini 2.5 Pro	55.3%	55.9%	55.6
GPT-5	50.9%	53.8%	52.3
o3	51.6%	52.0%	51.9
Claude Opus 4	19.2%	54.1%	28.3

論文 v2 。 1,000 問、ツールなし、標準 API 設定。
判定器は gpt-4.1-2025-04-14 。 F1 は 0 〜 100 で表示。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

Gemini 3 Pro の公式比較でも使われている

モデル	掲載スコア
Gemini 3 Pro	72.1%
Gemini 2.5 Pro	54.5%
Claude Sonnet 4.5	29.3%
GPT-5.1	34.9%

公式モデルカード、 2025 年 11 月の比較。
公式 Kaggle リーダーボードの掲載値を引用。

Google DeepMind (2025/2026). Gemini 3 Pro: Model Card. 2026-10-17 参照。 https://deepmind.google/models/model-cards/gemini-3-pro/

答える範囲の違いも、得点に現れる

- 論文の Claude Opus 4 は、全問での正答率 19.2% 、答えた問題での正答率 54.1% 。回答を出した割合は 35.5% である。
- Gemini 2.5 Pro は 98.9% に回答し、全問で 55.3% を正答した。得点と一緒に回答率を見ると、どこまで答えを出したかも把握できる。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

3. データの再検証と構成

同じ出典と、似た質問を順に減らす

処理	残った問題数
元の SimpleQA	4,326
参照 URL が重なる問題を整理	3,095
意味が近い質問を整理	2,871
単語が似た質問を確認・整理	2,664

意味の類似には Gemini Embeddings 、単語の類似には TF-IDF を使う。
同じ群では、複数モデルが答えられない問題を優先して残す。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

意味と単語の両方から、重複を探す

- 元データには、コロンビアの自治体の創設日を問う質問が 119 件あった。同じ出典文書や似た型の問題が繰り返されることを減らす。
- 意味をベクトルにした Gemini Embeddings では、コサイン類似度 0.77 を基準に似た質問を探す。
- 単語の重要度を使う TF-IDF では、類似度 0.4 を超える組を人が確認する。表現の違いと、内容の近さを両方から調べる。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

出典サイトの選択と、問題の偏りを確認する

- 出典 URL のサイトが、 Google ・ OpenAI ・ Anthropic に対する学習・利用の制御を robots.txt で指定している場合、その URL に依存する問題を除く。 2,664 問から 1,855 問になる。
- 次に、答えの種類を優先し、話題も考慮して比率を調整する。日付や人物、科学技術の問題への集中を減らす。
- 同じ分類の中では難しい質問を優先して選び、 1,218 問を残す。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

出典が食い違う問題は、正解を再確認する

対象	確認・修正したこと
人物・日付・場所	曖昧な質問や、正解が分かれる質問を除く
数量	検索付きモデルと参照 URL の答えを照合する
数値の参照正解	問題ごとに、採点で許容する範囲を書き込む

非数値の確認で 1,218 → 1,117 問、数値の確認で 1,073 問。
最後に難しい 1,000 問を選び、 URL と日付の精度も人が確認する。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

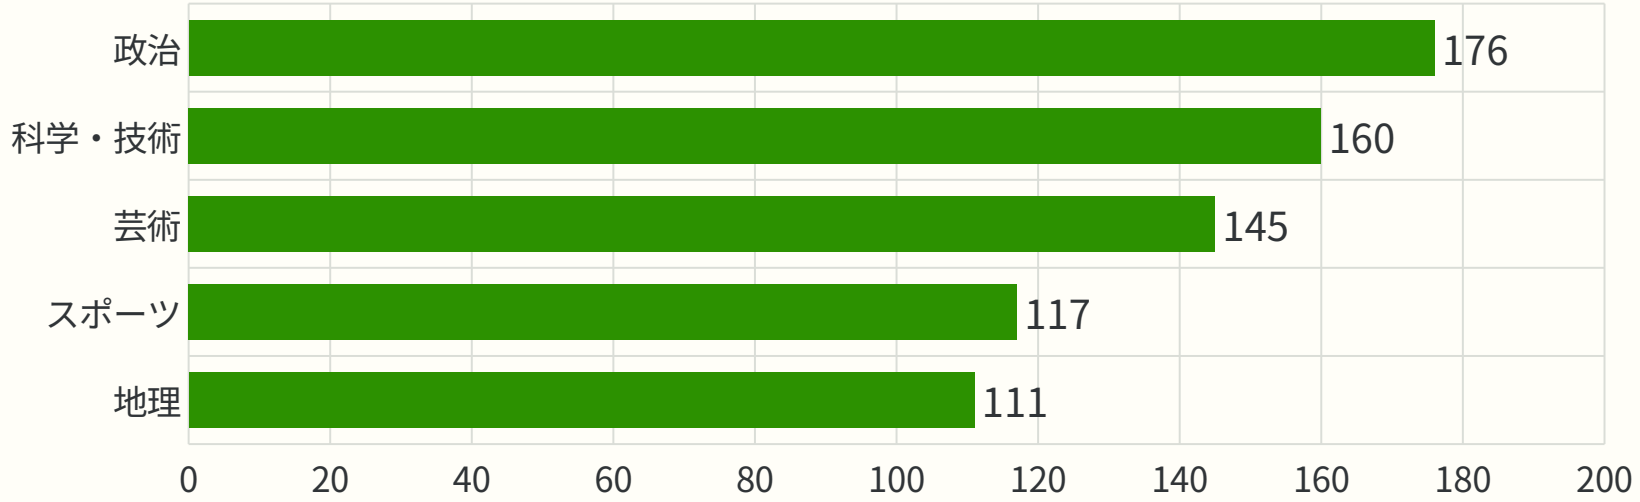
数値の許容範囲は、問題ごとに指定する

種類	採点の考え方
小さい個数・固定値	原則として正確な一致を求める
中程度の数量・連続量	おおむね ±1% 程度の範囲を設ける
大きな総量・集計値	おおむね ±5% 程度の範囲を設ける

参照正解に書かれた許容範囲を採点に使う。
例： 150 枚の版画なら 148 〜 152 枚を許容する。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

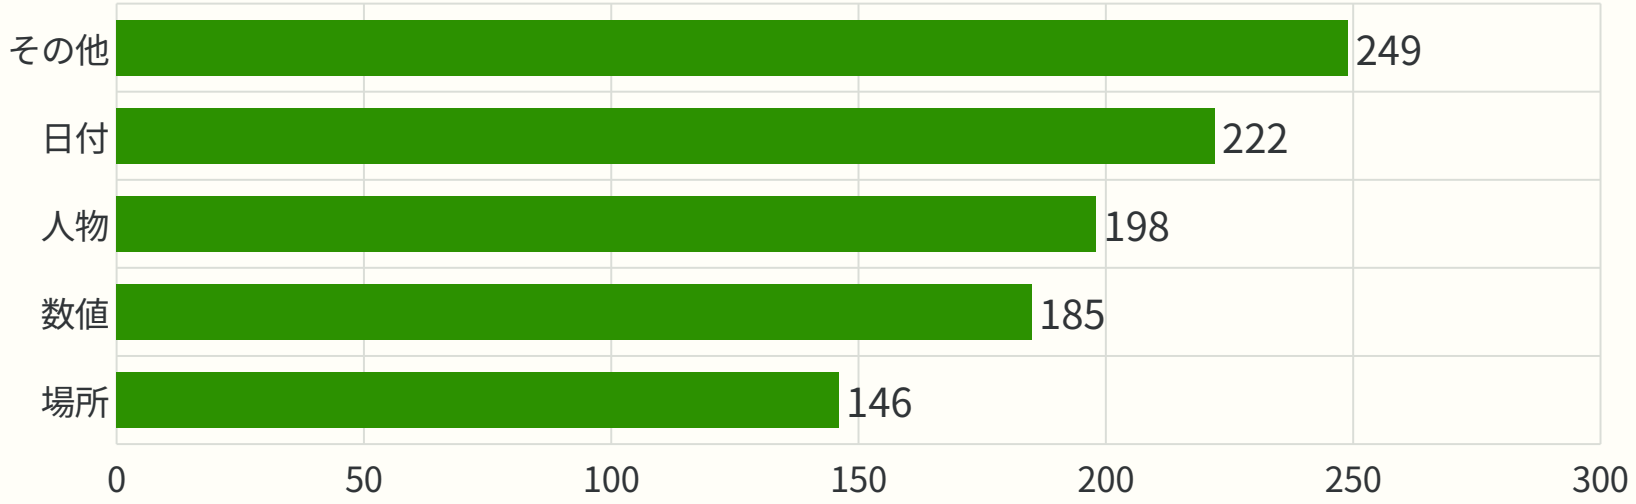
質問は、政治・科学技術・芸術などに広がる



現行 CSV 全 1,000 問から集計した、件数上位 5 話題。

Google DeepMind / Google Research. SimpleQA Verified. MIT 、改訂 0dc97e0 。 https://huggingface.co/datasets/google/simpleqa-verified

答えの種類は、日付・人物・数値・場所を含む



現行 CSV 全 1,000 問。縦軸は配布データの分類、横軸は問題数。

Google DeepMind / Google Research. SimpleQA Verified. MIT 、改訂 0dc97e0 。 https://huggingface.co/datasets/google/simpleqa-verified

2026 年の修正では、緯度と経度を直した

- 2025 年 9 月の配布では「 Lilongwe の緯度」を問う文に、経度の値 33.7738 が正解として付いていた。
- 2026 年 3 月 9 日の改訂では、質問文を「経度」に修正した。正解・許容範囲・元問題番号 55 は同じである。
- 論文も 2026 年 3 月 10 日のバージョン 2 （ v2 ）で、対応する例を修正した。

Google. SimpleQA Verified: 配布データの改訂履歴。 2026-03-09 修正。 https://huggingface.co/datasets/google/simpleqa-verified/commits/main

4. 利用方法とまとめ

モデルの知識と、回答保留の傾向を調べる

- 質問をモデルへ渡し、検索や外部資料を付けずに回答を生成する。判定器へは質問・参照正解・モデル出力を渡す。
- 正答率、回答した中での正答率、 F1 、回答率を記録する。判定器のモデルとプロンプトも条件としてそろえる。
- 配布 CSV には、話題・答えの種類・複数段階の情報が必要か・推論が必要かというメタデータがあり、問題の性質ごとの分析にも使える。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

公式 CSV から、質問と参照正解を読み込む

```
from datasets import load_dataset

ds = load_dataset("google/simpleqa-verified",
                  split="eval")
print(ds[0]["problem"])
print(ds[0]["answer"])
```

公式配布は MIT 。 original_index で元の SimpleQA と対応付ける。
評価時は使用した配布改訂を固定し、参照正解を採点側へ渡す。

Google DeepMind / Google Research. SimpleQA Verified. MIT 、改訂 0dc97e0 。 https://huggingface.co/datasets/google/simpleqa-verified

質問と正解を整え、知識の正確さを測る

- SimpleQA Verified は、検索を使わず、モデルの内部知識から短い事実質問へ答える 1,000 問の評価である。
- SimpleQA から出典・質問の重複と構成の偏りを減らし、資料間の正解を照合した。数量には問題ごとの許容範囲を付けている。
- 正答・誤答・未回答を判定し、全問での正答率と、答えた中での正答率を F1 でまとめる。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

Appendix

1. 話題の異なる追加例
2. 分布と採点の詳細
3. 著者と参考文献

1. 話題の異なる追加例

追加例 1 ：客室乗務員だった首相を特定する

質問（原文・全文）

What is the name of the former Prime Minister of Iceland who worked as a cabin crew member until 1971?

質問の日本語訳

1971 年まで客室乗務員として働いていた、アイスランドの元首相は誰か。

配布正解： Jóhanna Sigurðardóttir

Google. SimpleQA Verified / original_index 8 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=1

追加例２：選手が出場した試合数を答える

質問（原文・全文）

In how many games did Matija Radović appear for the Hofstra Pride during the 2017-18 season?

質問の日本語訳

2017–18 年シーズン、 Matija Radović は Hofstra Pride で何試合に出場したか。

配布正解： 25 試合

Google. SimpleQA Verified / original_index 254 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=59

追加例３：作品集に含まれる版画の数を答える

質問（原文・全文）

In 1810, François Aimé Louis Dumoulin published a collection of how many engravings themed on the journey of "Robinson Crusoe"?

質問の日本語訳

1810 年、 François Aimé Louis Dumoulin が刊行した、 Robinson Crusoe の旅を題材にした版画集は何枚か。

配布正解： 150 枚（許容範囲 148 〜 152 枚）

Google. SimpleQA Verified / original_index 31 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=8

追加例 4 ：独立運動のスローガンを問う

質問（原文・全文）

Who gave the slogan "Quit India"?

質問の日本語訳

「 Quit India 」というスローガンを提唱したのは誰か。

配布正解： Yusuf Meherally

Google. SimpleQA Verified / original_index 4114 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=946

追加例 5 ：数学賞の受賞者を答える

質問（原文・全文）

Who won the Heinz Hopf Prize in 2019?

質問の日本語訳

2019 年の Heinz Hopf Prize を受賞したのは誰か。

配布正解： Ehud Hrushovski

Google. SimpleQA Verified / original_index 552 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=129

追加例 6 ：バンドの最初の EP を答える

質問（原文・全文）

What is Kinoko Teikoku's first EP?

質問の日本語訳

きのこ帝国の最初の EP は何か。

配布正解： Long Good Bye

Google. SimpleQA Verified / original_index 3306 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=764

追加例 7 ：ゲームのコンテストは何段階か

質問（原文・全文）

How many stages were in the original DS game's Pokémon Diamond and Pearl Pokémon contests?

質問の日本語訳

ニンテンドー DS のオリジナル版 Pokémon Diamond and Pearl のコンテストは何段階か。

配布正解： 3 段階

Google. SimpleQA Verified / original_index 1842 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=418

追加例 8 ：番組から派生したシリーズを特定する

質問（原文・全文）

Which DropoutTV series is a spin-off of "Game Changer" inspired by its "Noise Boys" episodes?

質問の日本語訳

Game Changer の「 Noise Boys 」の回を基にした、 DropoutTV の派生シリーズは何か。

配布正解： Make Some Noise

Google. SimpleQA Verified / original_index 596 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=136

追加例 9 ：数学のメダル受賞者を答える

質問（原文・全文）

Who won the ICA's Hall Medal in 2011?

質問の日本語訳

2011 年に ICA の Hall Medal を受賞したのは誰か。

配布正解： Olga Polverino

Google. SimpleQA Verified / original_index 1111 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=253

追加例 10 ：画家と最初の妻の年齢差を答える

質問（原文・全文）

What was the age gap between George Frederic Watts and his first wife, Ellen Terry?

質問の日本語訳

George Frederic Watts と、最初の妻 Ellen Terry の年齢差は何歳か。

配布正解： 30 歳

Google. SimpleQA Verified / original_index 342 / MIT 。日本語は翻訳・要約。
https://huggingface.co/datasets/google/simpleqa-verified/viewer/simpleqa_verified/eval?row=83

2. 分布と採点の詳細

公開 1,000 問の話題別の構成

配布分類	日本語名	問題数
Politics	政治	176
Science and technology	科学・技術	160
Art	芸術	145
Sports	スポーツ	117
Geography	地理	111

配布 CSV の topic 列を集計。全 10 分類、合計 1,000 問。

Google DeepMind / Google Research. SimpleQA Verified. MIT 、改訂 0dc97e0 。 https://huggingface.co/datasets/google/simpleqa-verified

公開 1,000 問の話題別の構成

配布分類	日本語名	問題数
Music	音楽	102
Other	その他	102
History	歴史	52
TV shows	テレビ番組	20
Video games	ゲーム	15

配布 CSV の topic 列を集計。全 10 分類、合計 1,000 問。

Google DeepMind / Google Research. SimpleQA Verified. MIT 、改訂 0dc97e0 。 https://huggingface.co/datasets/google/simpleqa-verified

判定器は、質問への直接の答えを照合する

- 大文字・小文字、句読点、語順などは意味が同じなら許容する。参照正解に必要な内容を含み、それに矛盾しないことを確認する。
- 質問に直接答える部分へ注目し、付け加えられた背景説明を切り分ける。数値は参照正解に指定された範囲で判定する。
- 複数候補を挙げる場合は、最も有力な一つへ回答を定めていれば採点する。決めずに並べる回答や答えを出さない回答は、未回答とする。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

判定が揺れる回答から、採点指示を見直した

- 複数のモデルの回答を集め、元の SimpleQA の判定指示で各回答を 10 回ずつ採点する。温度を 2.0 にして、判定の一致しない回答を探した。
- 不一致の大きい回答を人が確認し、余分な説明、近似した数値、情報が見つからないという回答などを整理した。
- 直接の答えと補足を切り分ける指示、数値範囲の扱い、未回答の例を追加した。判定指示の全文は論文付録と公式ノートブックで公開する。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

3. 著者と参考文献

Google の研究者が、元データを再検証した

- 第一著者は Lukas Haas 。 Giovanni D’Antonio 、 Dipanjan Das とともに Google DeepMind に所属する。 Gal Yona と Sasha Goldshtein は Google Research 。
- 論文は 2025 年 9 月に公開。著者自身が重複整理、分類の調整、出典と正解の照合を実施したと報告する。
- 元の SimpleQA は OpenAI の Jason Wei 、 Nguyen Karina らによる 2024 年の研究。 Verified は、この事実質問評価を再検証して公開したもの。

Haas, Yona et al. (2025/2026). SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge 論文 v2 。 https://arxiv.org/abs/2509.07968v2

参考文献

SimpleQA Verified: A Reliable Factuality Benchmark to Measure Parametric Knowledge

Lukas Haas, Gal Yona et al. / Google DeepMind ・ Google Research / 2025 / 論文 v2: 2026

データの再検証、数値の許容範囲、判定指示とモデル評価を報告する。

https://arxiv.org/abs/2509.07968v2

SimpleQA Verified

Google / Hugging Face Datasets / MIT / 改訂 0dc97e0

公開 1,000 問、参照正解、出典 URL と問題のメタデータを配布する。

https://huggingface.co/datasets/google/simpleqa-verified

参考文献

Measuring Short-Form Factuality in Large Language Models

Jason Wei, Nguyen Karina et al. / OpenAI / 2024

元の SimpleQA の作成と、正答・誤答・未回答による事実性評価。

https://arxiv.org/abs/2411.04368

SimpleQA: reference implementation

OpenAI / simple-evals / MIT / 改訂 652c89d

元の SimpleQA の判定・集計実装。 F1 などの計算を公開する。

https://github.com/openai/simple-evals/blob/652c89d/simpleqa_eval.py

参考文献

Gemini 3 Pro: Model Card

Google DeepMind / 2025 年 11 月公開・ 2026 年 5 月更新

SimpleQA Verified を含むモデル比較と、モデルの仕様・評価を掲載する。

https://deepmind.google/models/model-cards/gemini-3-pro/

Gemini 3 Pro: Evaluation Methodology

Google DeepMind / 2025 年 11 月

公式比較の評価条件と、 Kaggle の SimpleQA Verified 結果の採用を説明する。

https://deepmind.google/models/evals-methodology/gemini-3-pro/