自然言語推論用データセット
Stanford Natural Language Inference Corpus
SNLI

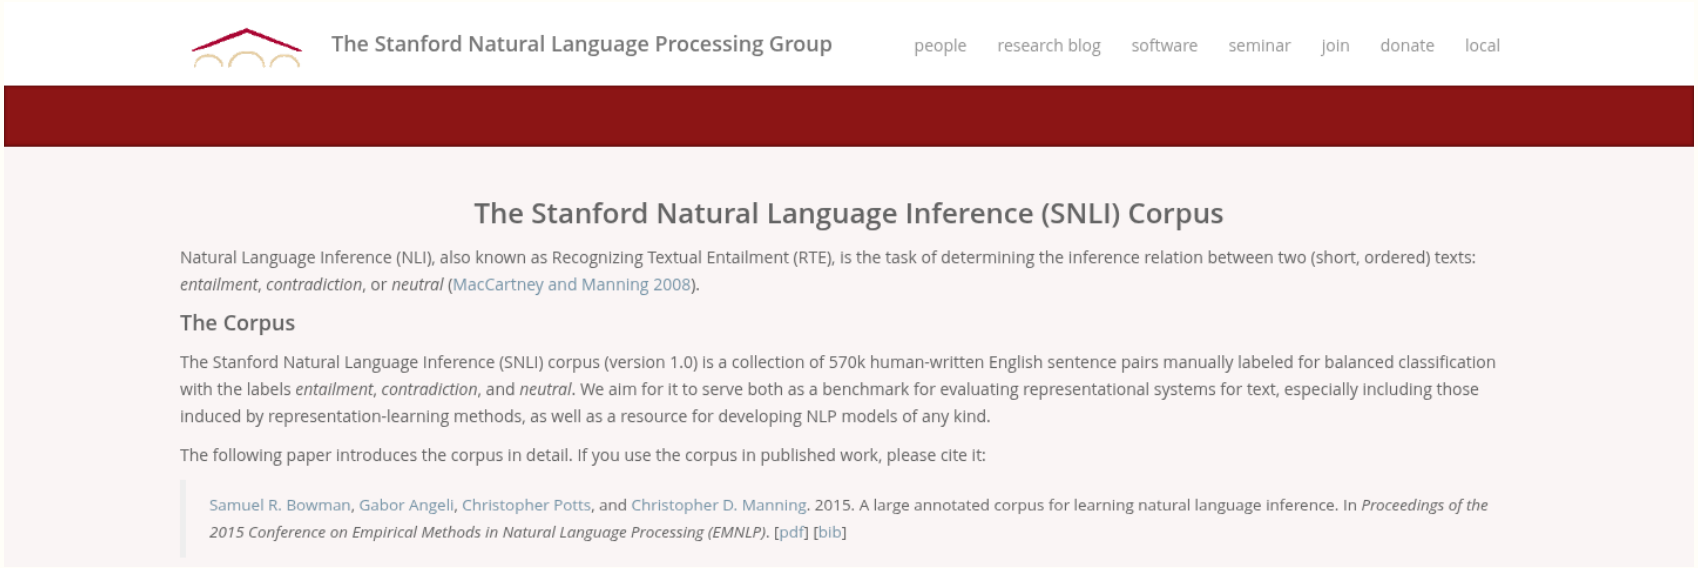
sasakiy84

本編の構成

1. 概要とタスク
2. 作成方法と規模
3. 評価と性能
4. 利用の変遷と現在
5. 入手方法とまとめ

1 概要とタスク

SNLI の公式サイト



[1] SNLI 公式サイト . https://nlp.stanford.edu/projects/snli/

英語の文対を 3 種類の関係に分類する

- SNLI は自然言語推論（ NLI ）のデータセットである。
- 入力には前提文と仮説文の 2 つのテキストを使う。
  - 仮説が前提から導けるかを含意・中立・矛盾で判断する。
- 画像の説明文を利用するが、モデルの入力に画像は含まれない。
- 約 57 万組を収録し、 2015 年の EMNLP で発表された [1] 。

[1] Bowman et al. (2015), EMNLP. https://aclanthology.org/D15-1075/

含意の例

前提文

A man playing an electric guitar on stage.

仮説文

A man playing guitar on stage.

正解は含意

電気ギターを弾いているなら、ギターを弾いている。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/　文対 ID 1034985636.jpg#3r1e

中立の例

前提文

A man reads the paper in a bar with green lighting.

仮説文

The man is reading the sportspage.

正解は中立

新聞のどの面を読んでいるかは、前提に書かれていない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/　文対 ID 2096485764.jpg#0r1n

矛盾の例

前提文

> 3 young man in hoods standing in the middle of a quiet street facing the camera.

仮説文

> Three people sit by a busy street bareheaded.

正解は矛盾

立っていることと座っていることなどが両立しない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/　文対 ID 4460943467.jpg#0r1c

「片手」と「両手」の違いは矛盾か

前提文の一部

> with one hand holding a skinny but long stick

仮説文の一部

> with both hands holding a skinny but long stick

正解は矛盾

「片手だけ」と読むなら、両手で持つ仮説と矛盾する。片手という表現が、他方の手を排除するかは曖昧である。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/　文対 ID 71651754.jpg#0r1c

2 作成方法と規模

大規模な学習データが必要だった

- 先行する含意判定の課題である RTE は、評価用の規模だった。
  - 大規模なニューラルモデルの教師あり学習には限界があった。
- これに対して SNLI は、人手で 570,152 組を作った [1]。
  - 語彙・構文・意味を扱う文表現モデルの学習と評価に使う。
- 写真の同じ状況を想定し、文の関係を判断しやすくした。

[1] SNLI dataset card. https://github.com/huggingface/datasets/blob/1.18.4/datasets/snli/README.md

写真説明文から 3 種類の仮説を作成した

- 写真に英語の説明文を付けた Flickr30k などを素材にした [1]。
  - 物体や関係を注釈した Visual Genome の初期データも使った。
- 作業者には説明文だけを提示し、写真は見せなかった。
  - 確実に真・真かもしれない・確実に偽の文を各 1 つ書く。
- この仮説文の作成には約 2,500 人の作業者が参加した [1]。

[1] Bowman et al. (2015), §2.1. https://aclanthology.org/D15-1075/

追加の 4 人が一部の文対を判定した

- 56,951 組について、 4 人の判定を追加した [1, 2] 。
  - 作成者のラベルを含め、 1 組あたり 5 票を得た。
- 3 票以上が一致したクラスを正解ラベルとした。
  - 検証対象の 98% で 3 票以上が一致し、 58.3% は全員一致。
- 検証は約 30 人の信頼された作業者が担当した [1] 。
- 一致しない文対には「 - 」を付け、通常の 3 分類から除く。

[1] Bowman et al. (2015), §2.2 / Table 3. https://aclanthology.org/D15-1075/
[2] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

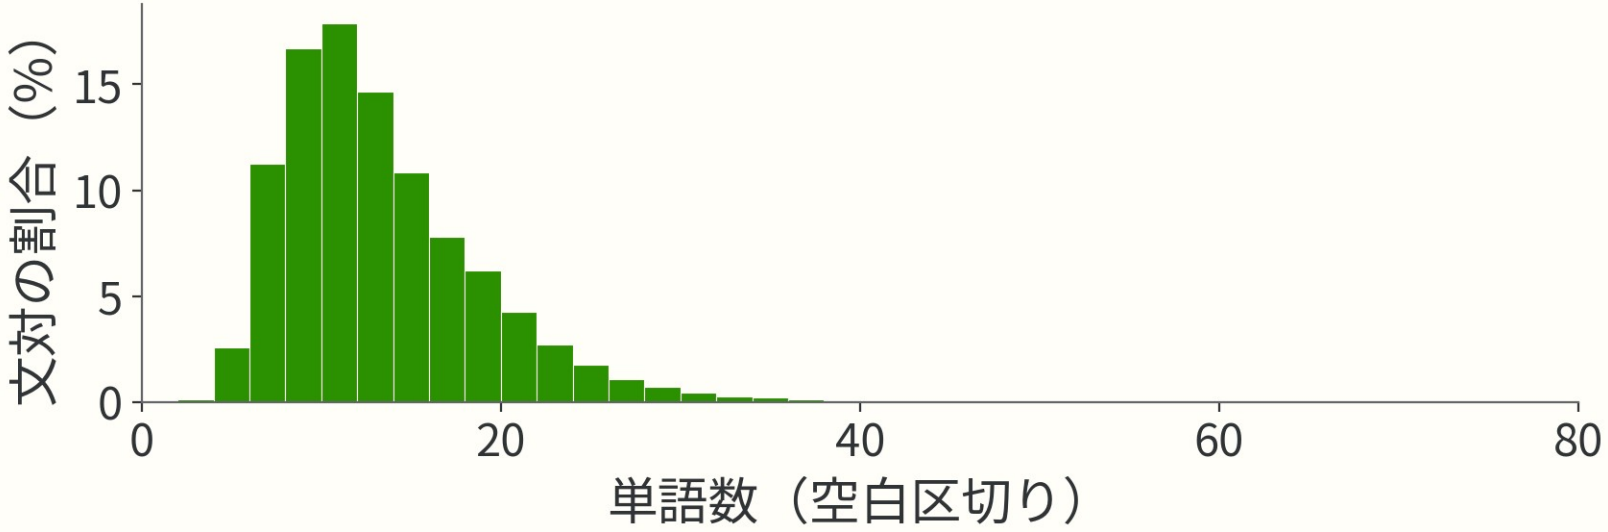
収録規模と 3 分類に使う文対数

分割	元の収録数	正解ラベル付き
学習用	550,152	549,367
開発用	10,000	9,842
テスト用	10,000	9,824
合計	570,152	569,033

右列は、正解ラベルが付いた SNLI 1.0 の文対数。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

前提文の単語数の分布



平均 12.89 語、中央値 12 語、最大 78 語。

[1] SNLI 1.0. https://nlp.stanford.edu/projects/snli/
正解付き 569,033 文対。同じ前提文が複数の文対に現れる場合も、それぞれ数えた。 棒 1 本は 0 〜 1 語、 2 〜 3 語…の区間を表す。

仮説文の単語数の分布



平均 7.42 語、中央値 7 語、最大 56 語。

[1] SNLI 1.0. https://nlp.stanford.edu/projects/snli/
正解付き 569,033 文対の仮説文を集計した。 棒 1 本は 0 〜 1 語、 2 〜 3 語…の区間を表す。

3 評価と性能

分類性能を正解率で評価する

- 1 組の予測クラスが正解と一致すれば 1 、不一致なら 0 。
- 正解率は正解した組数を評価対象の組数で割る。 3 組中 2 組が正解なら、正解率は 66.7% となる。
- 正解ラベルがない「 - 」の文対は 3 分類の評価から除く。
- テスト用では正解付き 9,824 組を評価対象とする [1] 。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

2015 年の LSTM の正解率は 77.6% だった

原著のモデル	テスト正解率
単語埋め込みの和	75.3%
単純な再帰型ネットワーク	72.2%
長期依存を扱う LSTM	77.6%

いずれも SNLI の学習用で学習し、テスト用で評価した [1]。

[1] Bowman et al. (2015), Table 6. https://aclanthology.org/D15-1075/

SNLI で報告されたモデルの正解率

モデル	方式	テスト正解率
ESIM 2017 [1]	双方向 LSTM ＋注意	88.0%
SemBERT 2020 [2]	BERT ＋意味役割	91.9%

文間の注意を計算する ESIM と、 BERT を意味役割で拡張した SemBERT 。各公開実装の報告値であり、学習条件は異なる。

[1] ESIM 公開実装 . https://github.com/coetaur0/ESIM
[2] SemBERT 著者実装 . https://github.com/cooelf/SemBERT

正解率だけでは文の理解を判断できない

- 写真説明文に偏り、長文・専門文書を代表しない。
- 仮説文だけでもラベルを推測できる注釈の偏りがある [1]。
  - 仮説だけを使う分類器で約 67% という報告がある。
- 中立と矛盾の境界には、場面の解釈が関わる。
- 文対全体の性能と、推論の種類ごとの性能を分けて見る。

[1] Gururangan et al. (2018), NAACL. https://aclanthology.org/N18-2017/
[2] SNLI dataset card. https://github.com/huggingface/datasets/blob/1.18.4/datasets/snli/README.md

4 利用の変遷と現在

先行する RTE と SNLI の規模の違い

- 含意を判定する先行ベンチマークとして RTE があった [1]。
  - RTE 第 3 回（2007 年）は、開発 800 組＋テスト 800 組だった。
- それに対して SNLI （2015 年）は 570,152 組を収録した。
  - 合計 1,600 組の RTE 第 3 回に対し、収録数は約 356 倍となる。
- その結果、ニューラルモデルを学習しやすくなった。

[1] Giampiccolo et al. (2007), §2. https://aclanthology.org/W07-1401/
[2] Bowman et al. (2015). https://aclanthology.org/D15-1075/

その後の MultiNLI はジャンルを広げた

- その後、多ジャンルの推論データ MultiNLI が登場した [1]。
  - 2018 年の論文で発表された。
- SNLI は写真説明を扱った。これに対し、会話・小説など 10 ジャンルへ広げた [2]。
- さらに、未知のジャンルへの汎化も評価する。

[1] Williams et al. (2018). https://aclanthology.org/N18-1101/
[2] MultiNLI 著者リポジトリ . https://github.com/nyu-mll/multiNLI

e-SNLI と ANLI では何を追加したか

- 判断理由を付けた拡張データ e-SNLI も作られた [1]。
  - SNLI の文対を使い、クラスに加えて自然言語の説明を学習する。
- 一方、人がモデルを誤らせる例を作るデータ ANLI もある [2]。
  - モデルと作業者を交互に用い、難しい推論例を増やす。
- いずれも SNLI の版の更新ではなく、別のデータである。

[1] Camburu et al. (2018), NeurIPS. https://github.com/OanaMariaCamburu/e-SNLI
[2] Nie et al. (2020), ACL. https://github.com/facebookresearch/anli

SNLI は現在も文埋め込みの学習に使われる

- 2015 年には、 3 分類の学習と評価を目的として登場した。
- その後、文埋め込みを学ぶ SimCSE にも利用された [1] 。
  - 2021 年には、含意を正例、矛盾を難しい負例に使った。
- 2026 年現在も、 Sentence Transformers に AllNLI を用いる学習手順がある [2] 。
  - AllNLI は SNLI と MultiNLI をまとめた学習データである。
- 2024 年の GISTEmbed では、負例を選び直す損失にも用いられる。

[1] Gao et al. (2021), EMNLP. https://github.com/princeton-nlp/SimCSE
[2] Sentence Transformers NLI 学習例 . https://github.com/UKPLab/sentence-transformers

5 入手方法とまとめ

Hugging Face から文対を取得する

```
from datasets import load_dataset

ds = load_dataset("stanfordnlp/snli")
valid = ds.filter(lambda row: row["label"] >= 0)

print(valid["test"][0])
print(ds["train"].features["label"].names)
```

データ配布サービスの Hugging Face を利用する。前提は premise 、仮説は hypothesis 、クラスは label に入る。

[1] Hugging Face SNLI loader. https://github.com/huggingface/datasets/blob/1.18.4/datasets/snli/snli.py

SNLI の特徴と役割

- 英語の文対を、含意・中立・矛盾に分類する。
- 2015 年に、大規模な学習用データとして作られた。
- 写真説明文から人が仮説を作り、一部を再検証した。
- MultiNLI はジャンル、 e-SNLI は説明を拡張した。
- 現在も、文埋め込みの教師データとして使われる。

Appendix の目次

1. 著者と発表先
2. 追加の実例
3. 件数・長さの統計と実例
4. モデル・入手・作成の補足
5. 参考文献と集計条件

著者と発表先

- SNLI は 2015 年 9 月の EMNLP で発表された（リスボン） [1] 。
- 第一著者の Samuel R. Bowman は自然言語推論を研究する。
  - SNLI に加え、多ジャンルの MultiNLI の共著者である [2] 。
- 最終著者の Christopher D. Manning は単語表現などを研究する。
  - 単語ベクトルを学習する GloVe の共著者である [3] 。

[1] Bowman et al. (2015), EMNLP. https://aclanthology.org/D15-1075/
[2] Williams et al. (2018), MultiNLI. https://aclanthology.org/N18-1101/
[3] Pennington et al. (2014), GloVe. https://aclanthology.org/D14-1162/

追加例 1 含意

前提文

> This church choir sings to the masses as they sing joyous songs from the book at a church.

仮説文

> The church is filled with song.

正解は含意

合唱していることを、教会が歌で満たされていると言い換える。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 2677109430.jpg#1r1e

追加例 2 中立

前提文

A woman with a green headscarf, blue shirt and a very big grin.

仮説文

The woman is young.

正解は中立

服装や表情だけでは、若いかどうかは判断できない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 6160193920.jpg#4r1n

追加例 3 含意

前提文

An old man with a package poses in front of an advertisement.

仮説文

A man poses in front of an ad.

正解は含意

advertisement と ad は同じ内容を表す。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 4791890474.jpg#3r1e

追加例 4 中立

前提文

A statue at a museum that no seems to be looking at.

仮説文

The statue is offensive and people are mad that it is on display.

正解は中立

見られていない理由や人々の感情は、前提から分からない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 6526219567.jpg#4r1n

追加例 5 矛盾

前提文

A land rover is being driven across a river.

仮説文

A sedan is stuck in the middle of a river.

正解は矛盾

車種と動作が、同じ場面の説明として両立しない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 2832076014.jpg#2r1c

追加例 6 中立

前提文

A blond-haired doctor and her African american assistant looking threw new medical manuals.

仮説文

A doctor is studying

正解は中立

正解は中立だが「勉強している」と読めるかは解釈に依存する。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 3856149623.jpg#1r1n

追加例 7 矛盾

前提文

A young family enjoys feeling ocean waves lap at their feet.

仮説文

A family is out at a restaurant.

正解は矛盾

海の波を感じる場面と、レストランの場面を区別している。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 2946464027.jpg#0r1c

追加例 8 含意

前提文

A couple walk hand in hand down a street.

仮説文

A couple is walking together.

正解は含意

手をつないで歩くことから、一緒に歩くことが導ける。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 3572548523.jpg#4r1e

追加例 9 中立

前提文

> Three firefighter come out of subway station.

仮説文

> Three firefighters putting out a fire inside of a subway station.

正解は中立

消防士が駅を出ることから、消火しているとは限らない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 4679111230.jpg#2r1n

追加例 10 中立

前提文

> This church choir sings to the masses as they sing joyous songs from the book at a church.

仮説文

> The church has cracks in the ceiling.

正解は中立

合唱の説明からは、天井のひびの有無は分からない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 2677109430.jpg#1r1n

統計と実例の対象範囲

- SNLI 1.0 の公式データに含まれる文対を集計した [1]。
  - 正解付き 569,033 組を使い、ラベルが「 - 」の組は除く。
- sentence1 と sentence2 を加工せずに数えた。
  - Python の len() で空白・句読点を含む Unicode 文字を数える。
  - str.split() で空白区切りの単語を数える。
- 前提は文対ごとに繰り返し数える。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

正解ラベル付きのクラス別件数

分割	含意	中立	矛盾	合計
学習用	183,416	182,764	183,187	549,367
開発用	3,329	3,235	3,278	9,842
テスト用	3,368	3,219	3,237	9,824

ラベルが付いた 569,033 組を集計。各クラスは約 3 分の 1 となる。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

文対数と前提文の種類数は異なる

分割	正解付き文対	異なる前提文字列
学習用	549,367	150,736
開発用	9,842	3,319
テスト用	9,824	3,323

同じ前提から複数の仮説が作られるため、前提は繰り返し現れる。種類数は完全一致の文字列数。写真数や説明文 ID 数とは異なる。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

単語数の記述統計

文	平均	標準偏差	最小	25%	中央	75%	95%	最大
前提	12.89	5.68	2	9	12	16	23	78
仮説	7.42	3.07	1	5	7	9	13	56

569,033 組を集計。標準偏差は母標準偏差（分母 N ）。
前提を文対ごとに数える。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

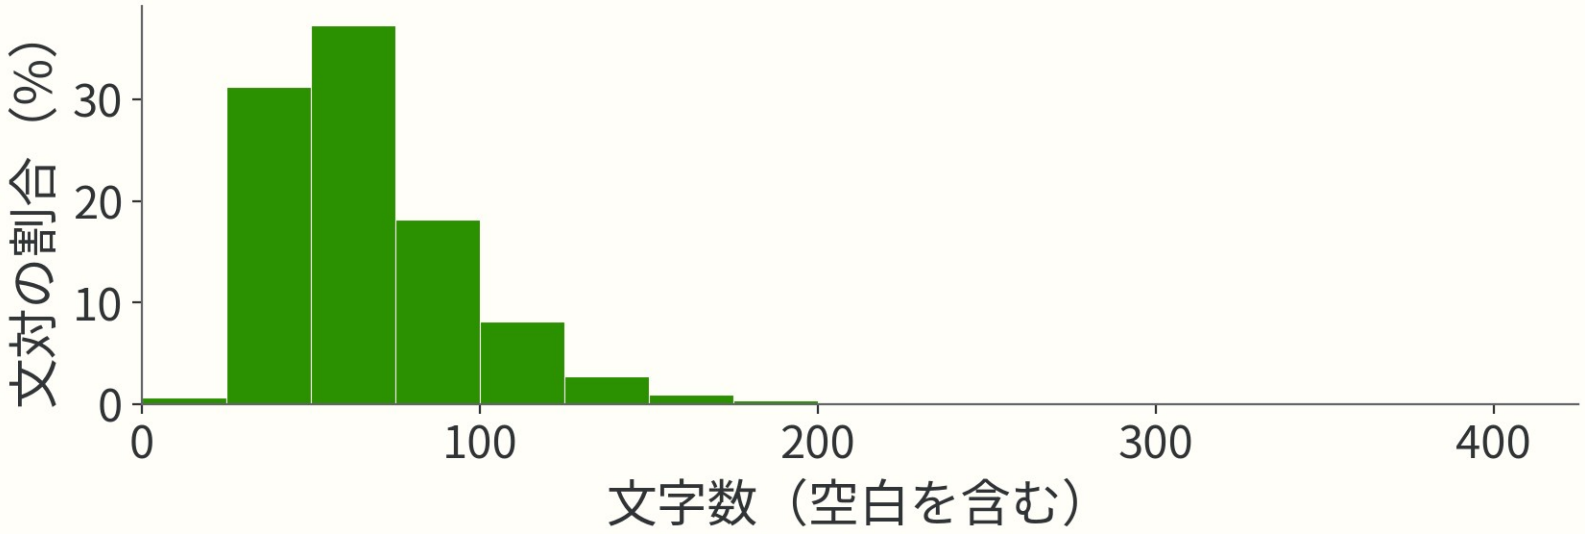
文字数の記述統計

文	平均	標準偏差	最小	25%	中央	75%	95%	最大
前提	66.48	29.52	7	46	60	81	121	402
仮説	37.49	15.88	1	26	34	45	68	295

569,033 組を集計。標準偏差は母標準偏差（分母 N ）。
前提を文対ごとに数える。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

前提文の文字数の分布



平均 66.48 文字、中央値 60 文字、最大 402 文字。

[1] SNLI 1.0. https://nlp.stanford.edu/projects/snli/
正解付き 569,033 文対。同じ前提文が複数の文対に現れる場合も、それぞれ数えた。 棒 1 本は 0 〜 24 文字、 25 〜 49 文字…の区間を表す。

分割別の前提の単語数

分割	件数	平均	標準偏差	中央	95% 点
学習	549,367	12.85	5.66	12	23
開発	9,842	13.94	6.32	12	25
テスト	9,824	13.91	6.18	13	25

単語は Python の str.split() による空白区切り。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

前提が最長の実例

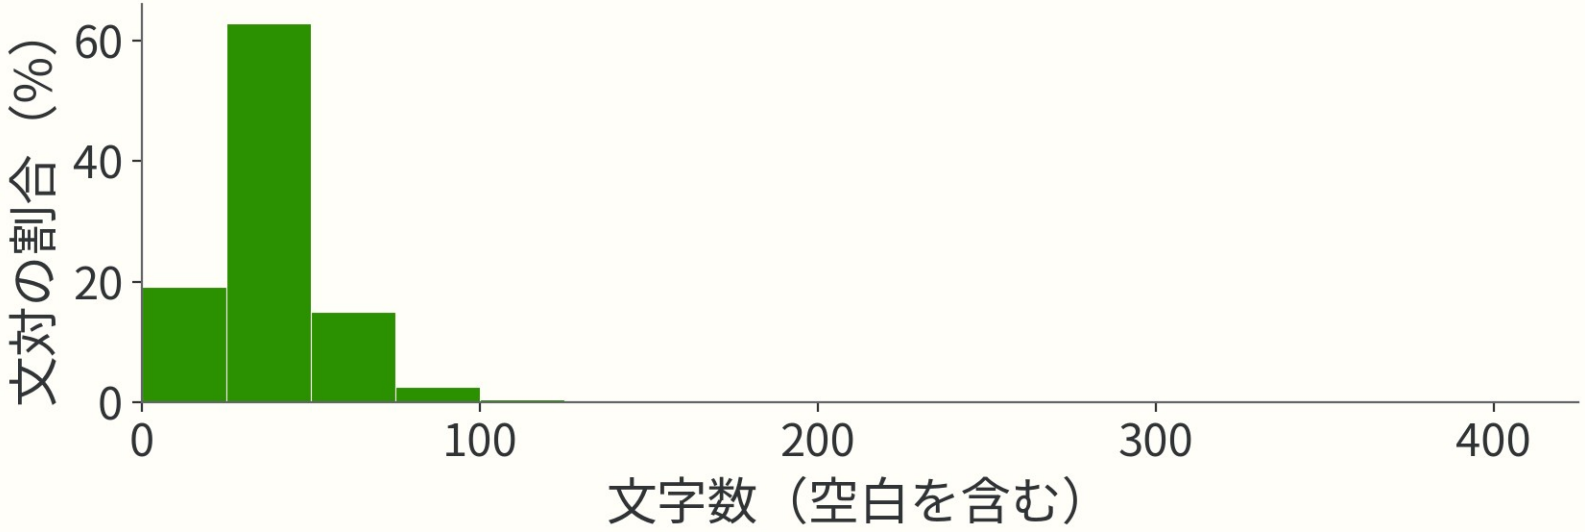
正解付き文対中で 402 文字・ 78 語。

> A man wearing a helmet, red pants with white stripes going down the sides and a white and red shirt is on a small bicycle using only his hands while his legs are up in the air, while another man wearing a light blue shirt with dark blue trim and black pants with red stripes going up the sides is standing nearby, gesturing toward the first man and holding a small figurine of one of the seven dwarves.

仮説は “ The people who are shown are not all doing the exact same thing. ”正解は含意。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 207344485.jpg#0r5e

仮説文の文字数の分布



平均 37.49 文字、中央値 34 文字、最大 295 文字。

[1] SNLI 1.0. https://nlp.stanford.edu/projects/snli/
正解付き 569,033 文対の仮説文を集計した。 棒 1 本は 0 〜 24 文字、 25 〜 49 文字…の区間を表す。

分割別の仮説の単語数

分割	件数	平均	標準偏差	中央	95% 点
学習	549,367	7.42	3.07	7	13
開発	9,842	7.51	3.13	7	13
テスト	9,824	7.48	3.08	7	13

単語は Python の str.split() による空白区切り。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

仮説の文字数が最大の実例

正解付き文対中で 295 文字。

> The cat toys with the catastrophically injured yet alive mouse before putting it out of it's misery. Just a few more broken ribs and guts coming out the anus, and Kitty Kat will let you die, mouse. Then the cat will go leave a steaming pile of parasitic feces in the litterbox. Cats are cute!

前提は “ A doberman bites a large blue ball. ”正解は矛盾。仮説には前提と無関係な描写が多い。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/　文対 ID 248994078.jpg#4r1c

仮説が 56 語の実例の前提全文

仮説の単語数が最大の実例の前提文。

> It is a photo of a young girl wearing pink pants and a jacket that's pink, red, blue and white the little girl is on one knee sitting on some big rocks smiling posing for a picture with one hand holding a skinny but long stick behind her there is what looks like a wooded area.

前提には “ one hand ” とある。正解ラベルは矛盾。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 71651754.jpg#0r1c

仮説が 56 語の実例の仮説全文

正解付き文対中で単語数が最大の仮説文。

> It is a photo of a young girl wearing pink pants and a jacket that's pink, red, blue and white the little girl is on one knee sitting on some big rocks smiling posing for a picture with both hands holding a skinny but long stick behind her there is what looks like a wooded area.

仮説では “ both hands ” に変わっている。正解ラベルは矛盾。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 71651754.jpg#0r1c

単語の対応を用いる RE2 の評価結果

モデル	SNLI の正解率	報告条件
RE2	88.9 ± 0.1%	10 回の平均と標準偏差

ACL 2019 の手法。著者リポジトリ掲載の報告値。
比較には前処理、学習条件、単一実行か平均かの確認が必要。

[1] RE2 著者実装 . https://github.com/alibaba-edu/simple-effective-text-matching

公式 ZIP では文対 ID と投票を確認できる

```
import json
from urllib.request import urlretrieve
from zipfile import ZipFile

url = "https://nlp.stanford.edu/projects/snli/snli_1.0.zip"
urlretrieve(url, "snli_1.0.zip")
with ZipFile("snli_1.0.zip") as z:
    path = "snli_1.0/snli_1.0_test.jsonl"
    row = json.loads(next(z.open(path)))
print(row["pairID"], row["annotator_labels"])
```

公式の JSONL には sentence1 、 sentence2 、 gold_label などを含む。

[1] Hugging Face SNLI loader. https://github.com/huggingface/datasets/blob/1.18.4/datasets/snli/snli.py

作成時の指示と品質確認の補足

- 作業者は前提の説明に合う同じ写真を想定して仮説を書く。
  - 画像を見せず、３つの関係に対応する文を作る [1]。
- 規約を守らない作業者を外し、自動の大量投稿を拒否した。
- 追加検証の多数決と、作成者のラベルを区別する。
  - 開発用とテスト用には複数の判定が付いた文対を使う。
- 自然な場面の読みと形式的な論理関係は必ずしも一致しない。

[1] Bowman et al. (2015), §2.1–2.2. https://aclanthology.org/D15-1075/

参考文献と参照した内容

Bowman et al. (2015). SNLI. EMNLP.
構築目的、作成・検証方法、初期モデルの評価を示す原著。

https://aclanthology.org/D15-1075/

Williams et al. (2018). MultiNLI. NAACL.
写真説明から 10 ジャンルへ対象を広げた後続データの原著。

https://aclanthology.org/N18-1101/

Camburu et al. (2018). e-SNLI. NeurIPS.
SNLI の判断に自然言語の説明を加えた拡張の根拠。

https://github.com/OanaMariaCamburu/e-SNLI

Nie et al. (2020). ANLI. ACL.
モデルが誤る例を人が作る後続データの構築方法。

https://github.com/facebookresearch/anli

参考文献と参照した内容

Gururangan et al. (2018). Annotation Artifacts. NAACL.
仮説文だけでも予測できる注釈の偏りを示した研究。

https://aclanthology.org/N18-2017/

Giampiccolo et al. (2007). RTE 第 3 回 .
SNLI 以前の含意認識ベンチマークと規模の比較。

https://aclanthology.org/W07-1401/

ESIM 公開実装と SNLI の評価結果
SNLI 上の分類性能を比較するためのモデル実装と報告値。

https://github.com/coetaur0/ESIM

Zhang et al. (2020). SemBERT. AAAI.
意味役割を加えたモデルの SNLI 評価結果。

https://github.com/cooelf/SemBERT

参考文献と参照した内容

Yang et al. (2019). RE2. ACL.
単語間の対応を利用したモデルの反復評価結果。

https://github.com/alibaba-edu/simple-effective-text-matching

Gao et al. (2021). SimCSE. EMNLP.
SNLI を文埋め込みの教師データに使う利用例。

https://github.com/princeton-nlp/SimCSE

Sentence Transformers の AllNLI 学習例
SNLI を含む学習手順が現在も公開されている根拠。

https://github.com/UKPLab/sentence-transformers/tree/master/examples/sentence_transformer/training/nli

Solatorio (2024). GISTEmbed.
文埋め込みの負例を選ぶために含意データを用いる利用例。

https://arxiv.org/abs/2402.16829