自然言語推論用データセット

SNLI

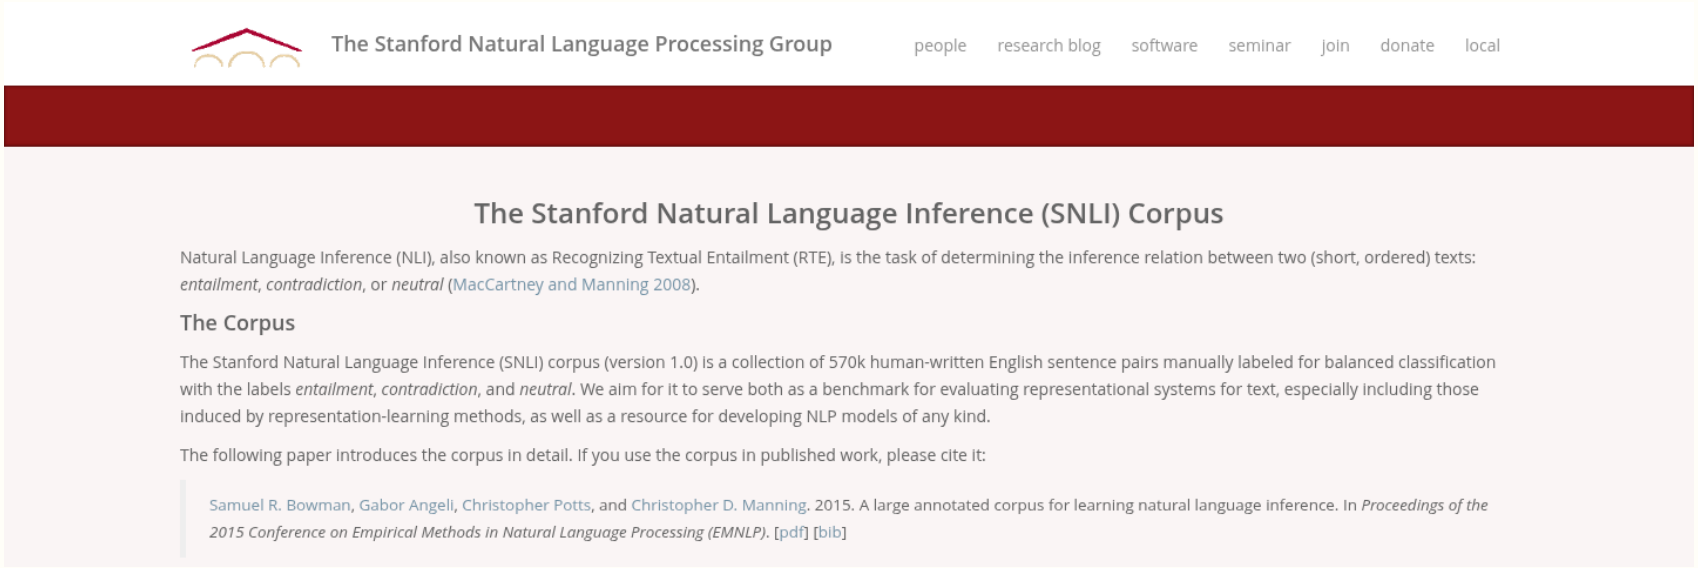
Stanford Natural Language Inference Corpus

sasakiy84

1. SNLI の文対と 3 つの推論関係
2. 文対の作成方法と収録規模
3. 自然言語推論の評価とモデル性能
4. SNLI の利用動向と後続データ
5. 文対データの入手方法と利用条件

1. SNLI の文対と 3 つの推論関係

SNLI の公式サイト



[1] SNLI 公式サイト . https://nlp.stanford.edu/projects/snli/

前提文と仮説文の関係を 3 種類に分類する

- 自然言語推論（ Natural Language Inference 、 NLI ）は、前提の記述をもとに別の記述が成り立つかを判断する課題である。
- SNLI では、状況を述べる前提文と、成り立つかを調べる仮説文を入力する。写真説明文から作られたデータだが、モデルの入力は 2 つの文だけである。
- 判断の選択肢は、仮説が導ける「含意」、真偽が決まらない「中立」、両立しない「矛盾」の 3 つである。

[1] Bowman et al. (2015). EMNLP, pp. 632–642. A large annotated corpus for learning natural language inference.
https://aclanthology.org/D15-1075/

実例 1 ：前提から仮説が導ける含意

前提文

A man playing an electric guitar on stage.

仮説文

A man playing guitar on stage.

正解は含意

電気ギターを弾いているなら、ギターを弾いている。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 1034985636.jpg#3r1e

実例 2 ：仮説の真偽が決まらない中立

前提文

A man reads the paper in a bar with green lighting.

仮説文

The man is reading the sportspage.

正解は中立

新聞のどの面を読んでいるかは、前提に書かれていない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 2096485764.jpg#0r1n

実例 3 ：前提と仮説が両立しない矛盾

前提文

> 3 young man in hoods standing in the middle of a quiet street facing the camera.

仮説文

> Three people sit by a busy street bareheaded.

正解は矛盾

立っていることと座っていることなどが両立しない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 4460943467.jpg#0r1c

語の一致ではなく文が述べる関係を判定する

- 電気ギターを弾く人は、ギターを弾く人でもある。このように前提の情報から仮説が導ける場合が含意である。
- 新聞を読むという情報だけでは、スポーツ面を読むかは決まらない。情報が足りない場合が中立である。
- 同じ場面で立っていることと座っていることが両立しないように、前提と仮説が衝突する場合が矛盾である。

[1] Bowman et al. (2015). EMNLP, pp. 632–642. A large annotated corpus for learning natural language inference.
https://aclanthology.org/D15-1075/

「片手」と「両手」の違いは矛盾か

前提文の一部

> with one hand holding a skinny but long stick

仮説文の一部

> with both hands holding a skinny but long stick

正解は矛盾

「片手だけ」と読むなら、両手で持つ仮説と矛盾する。片手という表現が、他方の手を排除するかは曖昧である。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 71651754.jpg#0r1c

2. 文対の作成方法と収録規模

先行する RTE と SNLI の規模の違い

- 含意を判定する先行ベンチマークとして RTE があった [1]。
  - RTE 第 3 回（2007 年）は、開発 800 組＋テスト 800 組だった。
- それに対して SNLI （2015 年）は 570,152 組を収録した。
  - 合計 1,600 組の RTE 第 3 回に対し、収録数は約 356 倍となる。
- その結果、ニューラルモデルを学習しやすくなった。

[1] Giampiccolo et al. (2007). ACL-PASCAL Workshop on Textual Entailment and Paraphrasing. The Third PASCAL Recognizing Textual Entailment Challenge. §2. https://aclanthology.org/W07-1401/

[2] Bowman et al. (2015). EMNLP, pp. 632–642. A large annotated corpus for learning natural language inference. https://aclanthology.org/D15-1075/

大規模な人手作成の文対で学習と評価を行う

- 先行する含意判定課題 RTE に対し、 SNLI はニューラルモデルを学習できる規模の文対を用意した。
- 写真の説明文を前提とし、人が 3 種類の関係に対応する仮説を書いた。写真の同じ状況を想定して関係を判断する。
- Stanford Natural Language Inference Corpus として、570,152 組を収録し、 2015 年の EMNLP で発表された。

[1] Bowman et al. (2015). EMNLP, pp. 632–642. A large annotated corpus for learning natural language inference.
https://aclanthology.org/D15-1075/

写真説明文をもとに 3 種類の仮説を書く

- 写真に英語の説明文を付けたデータ Flickr30k と、写真の物体や関係を注釈する Visual Genome の初期データを素材にした。
- 作業者には写真を見せず、その説明文だけを提示した。同じ写真の状況について、確実に真・真かもしれない・確実に偽の文を各 1 つ書いた。
- この仮説文の作成には約 2,500 人が参加した。各文対には、作成した仮説に対応するラベルが付いた。

[1] Bowman et al. (2015). EMNLP, pp. 632–642. A large annotated corpus for learning natural language inference.
https://aclanthology.org/D15-1075/

5 人の票から正解ラベルを決める

判定者	含意	中立	矛盾
作成者＋追加の 4 人	3 票	1 票	1 票
正解ラベル	含意	—	—

3 票以上が一致すれば、そのクラスを正解とする。3 票に達するクラスがなければ「-」を付ける。票の配分は規則を示す例。

[1] Bowman et al. (2015). EMNLP, pp. 632–642. A large annotated corpus for learning natural language inference.
https://aclanthology.org/D15-1075/

追加検証の合意がない文対を 3 分類から除く

- 56,951 組には追加の 4 人が判定を行い、作成者のラベルと合わせて 1 組 5 票を得た。
- 検証対象の 98% では 3 票以上が一致し、 58.3% では全員が一致した。検証は約 30 人の信頼された作業者が担当した。
- したがって、配布された文対の総数と、正解ラベル付きで 3 分類に使う文対数は異なる。

[1] Bowman et al. (2015). EMNLP, pp. 632–642. A large annotated corpus for learning natural language inference. https://aclanthology.org/D15-1075/
[2] https://nlp.stanford.edu/projects/snli/

収録規模と 3 分類に使う文対数

分割	元の収録数	正解ラベル付き
学習用	550,152	549,367
開発用	10,000	9,842
テスト用	10,000	9,824
合計	570,152	569,033

右列は、正解ラベルが付いた SNLI 1.0 の文対数。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

文対数と前提文の種類数は異なる

分割	正解付き文対	異なる前提文字列
学習用	549,367	150,736
開発用	9,842	3,319
テスト用	9,824	3,323

同じ前提から複数の仮説が作られるため、前提は繰り返し現れる。種類数は完全一致の文字列数。写真数や説明文 ID 数とは異なる。

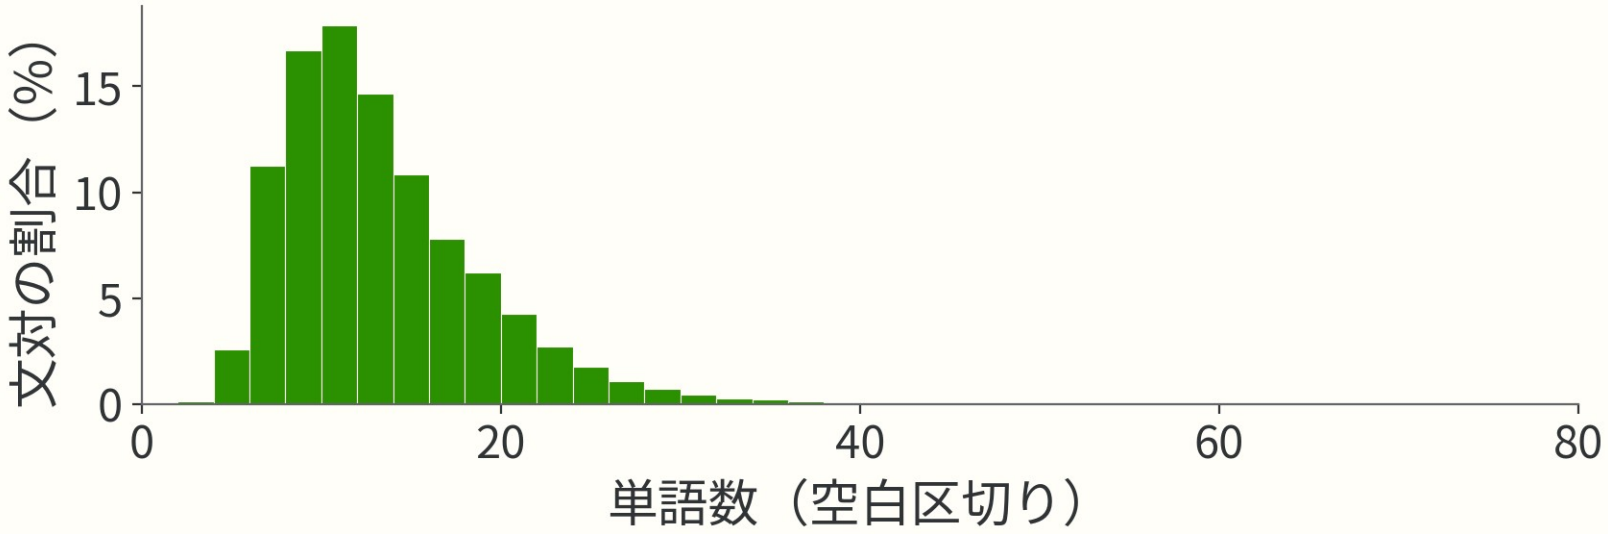
[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

前提文・仮説文の単語数と集計単位

- 含意の例では、前提の “ A man playing an electric guitar on stage.” は 8 語、仮説の “ A man playing guitar on stage.” は 6 語である。
- 単語数は空白で区切って数える。前提と仮説は役割が違うため、それぞれの分布を調べる。
- 全体の集計では正解付き 569,033 文対を対象とし、同じ前提が複数の文対に現れる場合も文対ごとに数える。

[1] https://nlp.stanford.edu/projects/snli/

前提文の単語数の分布



平均 12.89 語、中央値 12 語、最大 78 語。

[1] SNLI 1.0. https://nlp.stanford.edu/projects/snli/

正解付き 569,033 文対。同じ前提文が複数の文対に現れる場合も、それぞれ数えた。棒 1 本は 0 〜 1 語、 2 〜 3 語…の区間を表す。

前提が最長の実例

正解付き文対中で 402 文字・ 78 語。

> A man wearing a helmet, red pants with white stripes going down the sides and a white and red shirt is on a small bicycle using only his hands while his legs are up in the air, while another man wearing a light blue shirt with dark blue trim and black pants with red stripes going up the sides is standing nearby, gesturing toward the first man and holding a small figurine of one of the seven dwarves.

仮説は “ The people who are shown are not all doing the exact same thing.” 正解は含意。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 207344485.jpg#0r5e

仮説文の単語数の分布



平均 7.42 語、中央値 7 語、最大 56 語。

[1] SNLI 1.0. https://nlp.stanford.edu/projects/snli/

正解付き 569,033 文対の仮説文を集計した。 棒 1 本は 0 〜 1 語、 2 〜 3 語…の区間を表す。

3. 自然言語推論の評価とモデル性能

文対 3 組の予測から正解率を計算する

正解	予測	得点
含意	含意	1
中立	矛盾	0
矛盾	矛盾	1

正解した 2 組を評価した 3 組で割り、 2÷3×100 ＝ 66.7% となる。

[1] https://nlp.stanford.edu/projects/snli/

正解率は正解付き文対について集計する

- 各文対では、予測クラスと正解ラベルが一致すれば 1 、不一致なら 0 とする。
- その得点を評価対象の文対全体で平均し、百分率で報告する。正解ラベルがない「 - 」の文対は除く。
- SNLI のテスト用では、正解付き 9,824 組を評価対象とする。

[1] https://nlp.stanford.edu/projects/snli/

文を数値表現へ変換して関係を予測する

- ニューラルモデルは、まず単語を数値のベクトルへ変換し、単語列から文の特徴を計算する。
- LSTM は、語を順に処理して離れた位置の情報を保持する再帰型ネットワークである。 ESIM （ 2017 ）は双方向 LSTM と、文間の語の対応を重み付けする注意機構を使う。
- BERT は大量の文で事前学習した言語モデルである。 SemBERT （ 2020 ）は、誰が何をしたかなどの意味役割を BERT へ加える。

[1] Bowman et al. (2015). EMNLP, pp. 632–642. A large annotated corpus for learning natural language inference. https://aclanthology.org/D15-1075/

[2] https://github.com/coetaur0/ESIM

[3] https://github.com/cooelf/SemBERT

2015 年の LSTM の正解率は 77.6% だった

原著のモデル	テスト正解率
単語埋め込みの和	75.3%
単純な再帰型ネットワーク	72.2%
長期依存を扱う LSTM	77.6%

いずれも SNLI の学習用で学習し、テスト用で評価した [1]。

[1] Bowman et al. (2015). EMNLP, pp. 632–642. A large annotated corpus for learning natural language inference. Table 6
https://aclanthology.org/D15-1075/

SNLI で報告されたモデルの正解率

モデル	方式	テスト正解率
ESIM 2017 [1]	双方向 LSTM ＋注意	88.0%
SemBERT 2020 [2]	BERT ＋意味役割	91.9%

文間の注意を計算する ESIM と、 BERT を意味役割で拡張した SemBERT 。各公開実装の報告値であり、学習条件は異なる。

[1] ESIM 公開実装 . https://github.com/coetaur0/ESIM
[2] SemBERT 著者実装 . https://github.com/cooelf/SemBERT

正解率だけでは文の理解を判断できない

- 写真説明文に偏り、長文・専門文書を代表しない。
- 仮説文だけでもラベルを推測できる注釈の偏りがある[1]。
  - 仮説だけを使う分類器で約 67% という報告がある。
- 中立と矛盾の境界には、場面の解釈が関わる。
- 文対全体の性能と、推論の種類ごとの性能を分けて見る。

[1] Gururangan et al. (2018). NAACL-HLT, pp. 107–112. Annotation Artifacts in Natural Language Inference Data. https://aclanthology.org/N18-2017/

[2] SNLI dataset card. https://github.com/huggingface/datasets/blob/1.18.4/datasets/snli/README.md

4. SNLI の利用動向と後続データ

MultiNLI による 10 ジャンルへの対象拡張

- その後、多ジャンルの推論データ MultiNLI が登場した [1] 。
  - 2018 年の論文で発表された。
- SNLI は写真説明を扱った。これに対し、会話・小説など 10 ジャンルへ広げた [2] 。
- さらに、未知のジャンルへの汎化も評価する。

[1] Williams et al. (2018). NAACL-HLT, pp. 1112–1122. A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference. https://aclanthology.org/N18-1101/

[2] MultiNLI 著者リポジトリ . https://github.com/nyu-mll/multiNLI

e-SNLI は関係ラベルに判断理由を加えた

- e-SNLI （ 2018 ）は、 SNLI の文対へ自然言語で書いた判断理由を追加した拡張データである。
- 含意・中立・矛盾というラベルに加えて、なぜその関係になるかを文章として収録する。
- SNLI の文対を利用するが、 SNLI そのものの版更新ではない。

[1] Camburu et al. (2018). Advances in Neural Information Processing Systems, 31, pp. 9539–9549. e-SNLI: Natural Language Inference with Natural Language Explanations.
https://github.com/OanaMariaCamburu/e-SNLI

ANLI はモデルが誤る文対を反復して集める

- Adversarial NLI （ ANLI 、 2020 ）は、人がモデルを誤らせる文対を作る推論データである。
- モデルの予測を作業者へ返し、難しい例を集める。この例でモデルを学び直す工程を繰り返す。
- 多ジャンルへ広げた MultiNLI 、説明を加えた e-SNLI とは、推論例を増やす方法が異なる。

[1] https://github.com/facebookresearch/anli

推論ラベルを文の類似度の学習にも使う

- 文埋め込みは、文全体を 1 つの数値ベクトルで表す方法である。近い意味の文が近い位置になるように学習する。
- SimCSE （ 2021 ）の教師あり学習では、前提と含意の仮説を近付ける正例、前提と矛盾の仮説を区別する難しい負例として使う。
- この利用では、 3 分類の正解率を上げるだけでなく、文同士の類似度に使える表現を学習する。

[1] https://github.com/princeton-nlp/SimCSE

SNLI と MultiNLI をまとめて学習に使う

- AllNLI は、 SNLI と MultiNLI をまとめた学習データである。写真説明文と多ジャンルの文対を含む。
- 文埋め込み用ライブラリ Sentence Transformers は、2026-10-15 の確認時点でも AllNLI による学習例を公開している。
- その学習例には、比較する負例を選び直す GISTEmbed（2024）の損失関数を用いる構成も含まれる。

[1] https://github.com/UKPLab/sentence-transformers

5. 文対データの入手方法と利用条件

配布データでは文・クラス・識別子を対応させる

- Hugging Face 版では premise が前提文、 hypothesis が仮説文、 label が正解クラスを表す。
- 公式 ZIP は 1 行に 1 件を格納する JSONL 形式で、文対 ID と作業者の判定も含む [1]。
- カード掲載の容量は取得時約 20.4 MB 、展開後約 68.4 MB である [2]。
- データの利用条件は CC BY-SA 4.0 である [2]。

[1] https://nlp.stanford.edu/projects/snli/

[2] Stanford NLP, SNLI — Dataset Card. https://huggingface.co/datasets/stanfordnlp/snli

公式 ZIP には文対 ID と作業者の票も入る

- sentence1 は前提文、 sentence2 は仮説文、 gold_label は正解ラベルである。
- pairID は文対の識別子、 annotator_labels は作業者による判定の一覧を表す。
- 正解ラベルが「 - 」の文対は、 3 分類の学習・評価から除く。数値でラベルを返す配布サービスでは、未確定のラベルは負の値で表される。

[1] https://nlp.stanford.edu/projects/snli/

Hugging Face から文対を取得する

```
from datasets import load_dataset

ds = load_dataset("stanfordnlp/snli")
valid = ds.filter(lambda row: row["label"] >= 0)

print(valid["test"][0])
print(ds["train"].features["label"].names)
```

データ配布サービスの Hugging Face を利用する。前提は premise 、仮説は hypothesis 、クラスは label に入る。

[1] Hugging Face SNLI loader. https://github.com/huggingface/datasets/blob/1.18.4/datasets/snli/snli.py

SNLI の目的・文対の特徴と評価上の限界

- 英語の文対を、含意・中立・矛盾に分類する。
- 2015 年に、大規模な学習用データとして作られた。
- 写真説明文から人が仮説を作り、一部を再検証した。
- MultiNLI はジャンル、 e-SNLI は説明を拡張した。
- 現在も、文埋め込みの教師データとして使われる。

Appendix

1.開発者の研究と発表先
2.前提・仮説と推論ラベルの追加例
3.文対数・文長の統計と極値の実例
4.推論モデルの評価と文対の配布・作成仕様
5.自然言語推論の関連文献

SNLI の開発者と研究分野

- SNLI は 2015 年 9 月の EMNLP で発表された（リスボン） [1] 。
- 第一著者の Samuel R. Bowman は自然言語推論を研究する。
  - SNLI に加え、多ジャンルの MultiNLI の共著者である [2] 。
- 最終著者の Christopher D. Manning は単語表現などを研究する。
  - 単語ベクトルを学習する GloVe の共著者である [3] 。

[1] Bowman et al. (2015). EMNLP, pp. 632–642. A large annotated corpus for learning natural language inference.
https://aclanthology.org/D15-1075/

[2] Williams et al. (2018). NAACL-HLT, pp. 1112–1122. A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference.
https://aclanthology.org/N18-1101/

[3] Pennington et al. (2014). EMNLP. GloVe: Global Vectors for Word Representation.
https://aclanthology.org/D14-1162/

追加例 1 含意

前提文

This church choir sings to the masses as they sing joyous songs from the book at a church.

仮説文

The church is filled with song.

正解は含意

合唱していることを、教会が歌で満たされていると言い換える。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 2677109430.jpg#1r1e

追加例 2 中立

前提文

A woman with a green headscarf, blue shirt and a very big grin.

仮説文

The woman is young.

正解は中立

服装や表情だけでは、若いかどうかは判断できない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 6160193920.jpg#4r1n

追加例 3 含意

前提文

An old man with a package poses in front of an advertisement.

仮説文

A man poses in front of an ad.

正解は含意

advertisement と ad は同じ内容を表す。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 4791890474.jpg#3r1e

追加例 4 中立

前提文

A statue at a museum that no seems to be looking at.

仮説文

The statue is offensive and people are mad that it is on display.

正解は中立

見られていない理由や人々の感情は、前提から分からない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 6526219567.jpg#4r1n

追加例 5 矛盾

前提文

A land rover is being driven across a river.

仮説文

A sedan is stuck in the middle of a river.

正解は矛盾

車種と動作が、同じ場面の説明として両立しない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 2832076014.jpg#2r1c

追加例 6 中立

前提文

A blond-haired doctor and her African american assistant looking threw new medical manuals.

仮説文

A doctor is studying

正解は中立

正解は中立だが「勉強している」と読めるかは解釈に依存する。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 3856149623.jpg#1r1n

追加例 7 矛盾

前提文

A young family enjoys feeling ocean waves lap at their feet.

仮説文

A family is out at a restaurant.

正解は矛盾

海の波を感じる場面と、レストランの場面を区別している。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 2946464027.jpg#0r1c

追加例 8 含意

前提文

A couple walk hand in hand down a street.

仮説文

A couple is walking together.

正解は含意

手をつないで歩くことから、一緒に歩くことが導ける。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 3572548523.jpg#4r1e

追加例 9 中立

前提文

> Three firefighter come out of subway station.

仮説文

> Three firefighters putting out a fire inside of a subway station.

正解は中立

消防士が駅を出ることから、消火しているとは限らない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 4679111230.jpg#2r1n

追加例 10 中立

前提文

This church choir sings to the masses as they sing joyous songs from the book at a church.

仮説文

The church has cracks in the ceiling.

正解は中立

合唱の説明からは、天井のひびの有無は分からない。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 2677109430.jpg#1r1n

文長を集計した版・分割と文対数

- SNLI 1.0 の公式データに含まれる文対を集計した [1]。
  - 正解付き 569,033 組を使い、ラベルが「 - 」の組は除く。
- sentence1 と sentence2 を加工せずに数えた。
  - Python の len() で空白・句読点を含む Unicode 文字を数える。
  - str.split() で空白区切りの単語を数える。
- 前提は文対ごとに繰り返し数える。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

正解ラベル付きのクラス別件数

分割	含意	中立	矛盾	合計
学習用	183,416	182,764	183,187	549,367
開発用	3,329	3,235	3,278	9,842
テスト用	3,368	3,219	3,237	9,824

ラベルが付いた 569,033 組を集計。各クラスは約 3 分の 1 となる。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

前提文・仮説文の単語数の記述統計

文	平均	標準偏差	最小	25%	中央	75%	95%	最大
前提	12.89	5.68	2	9	12	16	23	78
仮説	7.42	3.07	1	5	7	9	13	56

569,033 組を集計。標準偏差は母標準偏差（分母 N ）。
前提を文対ごとに数える。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

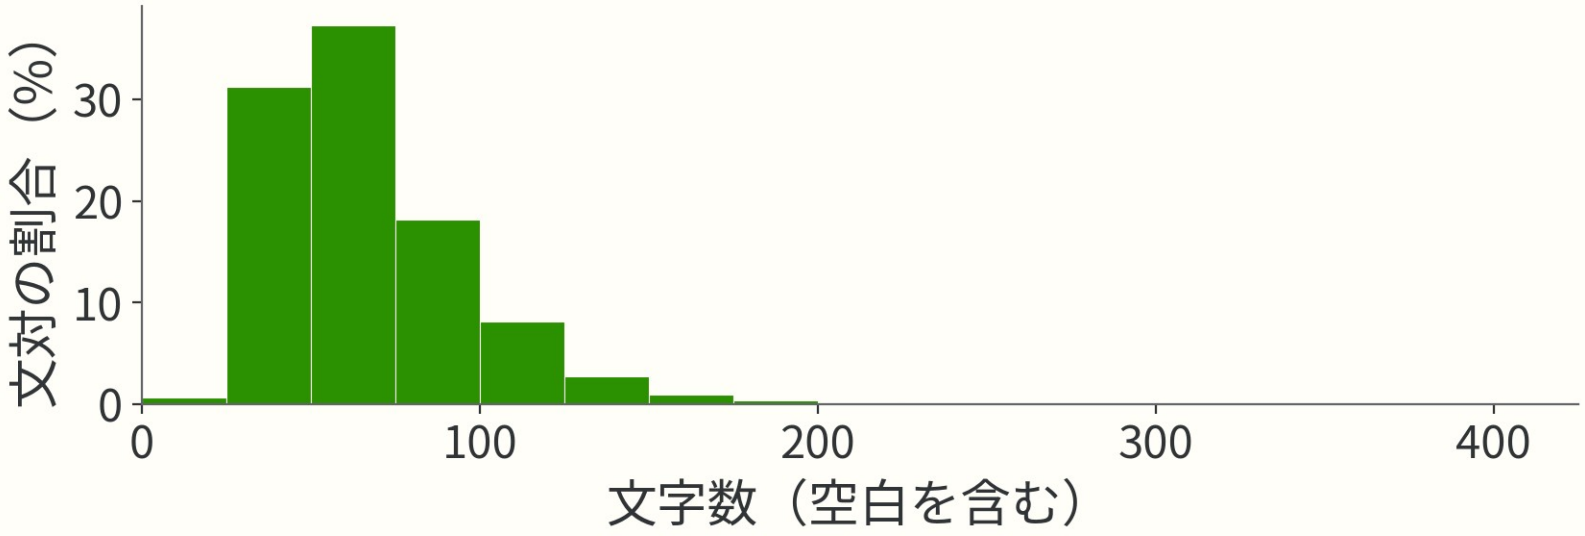
前提文・仮説文の文字数の記述統計

文	平均	標準偏差	最小	25%	中央	75%	95%	最大
前提	66.48	29.52	7	46	60	81	121	402
仮説	37.49	15.88	1	26	34	45	68	295

569,033 組を集計。標準偏差は母標準偏差（分母 N ）。
前提を文対ごとに数える。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

前提文の文字数の分布



平均 66.48 文字、中央値 60 文字、最大 402 文字。

[1] SNLI 1.0. https://nlp.stanford.edu/projects/snli/

正解付き 569,033 文対。同じ前提文が複数の文対に現れる場合も、それぞれ数えた。棒 1 本は 0 〜 24 文字、 25 〜 49 文字…の区間を表す。

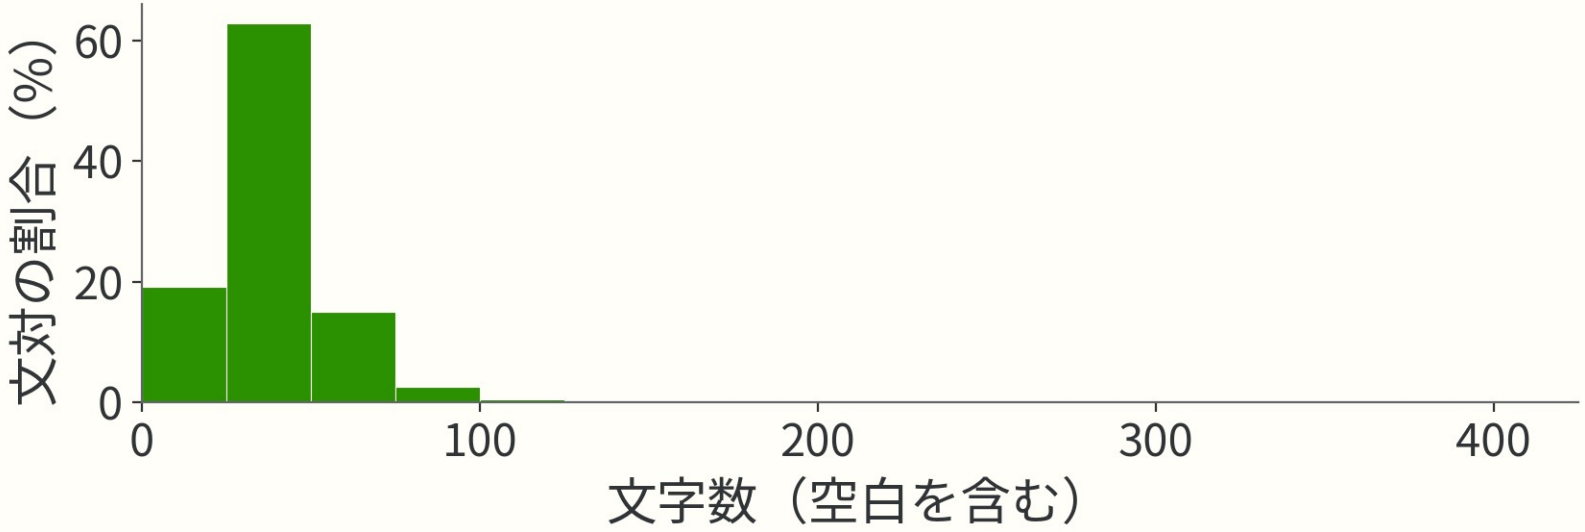
分割別の前提の単語数

分割	件数	平均	標準偏差	中央	95% 点
学習	549,367	12.85	5.66	12	23
開発	9,842	13.94	6.32	12	25
テスト	9,824	13.91	6.18	13	25

単語は Python の str.split() による空白区切り。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

仮説文の文字数の分布



平均 37.49 文字、中央値 34 文字、最大 295 文字。

[1] SNLI 1.0. https://nlp.stanford.edu/projects/snli/

正解付き 569,033 文対の仮説文を集計した。 棒 1 本は 0 〜 24 文字、 25 〜 49 文字…の区間を表す。

分割別の仮説の単語数

分割	件数	平均	標準偏差	中央	95% 点
学習	549,367	7.42	3.07	7	13
開発	9,842	7.51	3.13	7	13
テスト	9,824	7.48	3.08	7	13

単語は Python の str.split() による空白区切り。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/

仮説の文字数が最大の実例

正解付き文対中で 295 文字。

> The cat toys with the catastrophically injured yet alive mouse before putting it out of it's misery. Just a few more broken ribs and guts coming out the anus, and Kitty Kat will let you die, mouse. Then the cat will go leave a steaming pile of parasitic feces in the litterbox. Cats are cute!

前提は “ A doberman bites a large blue ball.” 正解は矛盾。仮説には前提と無関係な描写が多い。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 248994078.jpg#4r1c

仮説が 56 語の実例の前提全文

仮説の単語数が最大の実例の前提文。

> It is a photo of a young girl wearing pink pants and a jacket that's pink, red, blue and white the little girl is on one knee sitting on some big rocks smiling posing for a picture with one hand holding a skinny but long stick behind her there is what looks like a wooded area.

前提には “ one hand” とある。正解ラベルは矛盾。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 71651754.jpg#0r1c

仮説が 56 語の実例の仮説全文

正解付き文対中で単語数が最大の仮説文。

> It is a photo of a young girl wearing pink pants and a jacket that's pink, red, blue and white the little girl is on one knee sitting on some big rocks smiling posing for a picture with both hands holding a skinny but long stick behind her there is what looks like a wooded area.

仮説では “ both hands” に変わっている。正解ラベルは矛盾。

[1] SNLI 1.0 公式データ . https://nlp.stanford.edu/projects/snli/ 文対 ID 71651754.jpg#0r1c

単語の対応を用いる RE2 の評価結果

モデル	SNLI の正解率	報告条件
RE2	88.9 ± 0.1%	10 回の平均と標準偏差

ACL 2019 の手法。著者リポジトリ掲載の報告値。
比較には前処理、学習条件、単一実行か平均かの確認が必要。

[1] RE2 著者実装 . https://github.com/alibaba-edu/simple-effective-text-matching

公式 ZIP では文対 ID と投票を確認できる

```
import json
from urllib.request import urlretrieve
from zipfile import ZipFile

url = "https://nlp.stanford.edu/projects/snli/snli_1.0.zip"
urlretrieve(url, "snli_1.0.zip")
with ZipFile("snli_1.0.zip") as z:
    path = "snli_1.0/snli_1.0_test.jsonl"
    row = json.loads(next(z.open(path)))
print(row["pairID"], row["annotator_labels"])
```

公式の JSONL には sentence1 、 sentence2 、 gold_label などを含む。

[1] Hugging Face SNLI loader. https://github.com/huggingface/datasets/blob/1.18.4/datasets/snli/snli.py

作成時の指示と品質確認の補足

- 作業者は前提の説明に合う同じ写真を想定して仮説を書く。
  - 画像を見せず、３つの関係に対応する文を作る [1]。
- 規約を守らない作業者を外し、自動の大量投稿を拒否した。
- 追加検証の多数決と、作成者のラベルを区別する。
  - 開発用とテスト用には複数の判定が付いた文対を使う。
- 自然な場面の読みと形式的な論理関係は必ずしも一致しない。

[1] Bowman et al. (2015). EMNLP, pp. 632–642. A large annotated corpus for learning natural language inference. §2.1
https://aclanthology.org/D15-1075/

A large annotated corpus for learning natural language inference

Bowman, S. R., Angeli, G., Potts, C., & Manning, C. D. (2015). EMNLP, pp. 632–642.

SNLI の原著論文。文対の収集、 3 種類の関係の注釈と検証、初期モデルの評価を報告する。

https://aclanthology.org/D15-1075/

A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference

Williams, A., Nangia, N., & Bowman, S. R. (2018). NAACL-HLT, pp. 1112–1122.

MultiNLI の原著論文。 10 ジャンルの文対を収集し、分野内・分野間の汎化を評価する。

https://aclanthology.org/N18-1101/

Annotation Artifacts in Natural Language Inference Data

Gururangan, S., Swayamdipta, S., Levy, O., Schwartz, R., Bowman, S. R., & Smith, N. A. (2018). NAACL-HLT, pp. 107–112.

NLI の注釈に伴う偏りを分析した研究。仮説文だけでもラベルを予測できることを示す。

https://aclanthology.org/N18-2017/

Natural Language Inference

Sentence Transformers contributors (n.d.). Sentence Transformers documentation. 参照 2026-10-15.

Sentence Transformers の公式学習例。 NLI 文対を使う文埋め込みの損失関数と実装を示す。

https://github.com/UKPLab/sentence-transformers/tree/master/examples/sentence_transformer/training/nli

Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks

Reimers, N., & Gurevych, I. (2019). EMNLP-IJCNLP, pp. 3982–3992.

Sentence-BERT の原著論文。 BERT から文埋め込みを生成し、文間の類似度を計算する。

https://aclanthology.org/D19-1410/

SimCSE: Simple Contrastive Learning of Sentence Embeddings

Gao, T., Yao, X., & Chen, D. (2021). EMNLP.

文埋め込みの対照学習手法を提案した論文。ドロップアウトと NLI 文対を正例の構成に用いる。

https://aclanthology.org/2021.emnlp-main.552/

Right for the Wrong Reasons: Diagnosing Syntactic Heuristics in Natural Language Inference

McCoy, R. T., Pavlick, E., & Linzen, T. (2019). ACL, pp. 3428–3448.

HANS の提案論文。語の重なりや部分列などの統語的な近道に NLI モデルが依存するかを検査する。

https://aclanthology.org/P19-1334/

Adversarial NLI: A New Benchmark for Natural Language Understanding

Nie, Y., Williams, A., Dinan, E., Bansal, M., Weston, J., & Kiela, D. (2020). ACL.

ANLI の原著論文。人がモデルを誤らせる文対を作る反復的なデータ収集を提案する。

https://aclanthology.org/2020.acl-main.441/

e-SNLI: Natural Language Inference with Natural Language Explanations

Camburu, O.-M., Rocktäschel, T., Lukasiewicz, T., & Blunsom, P. (2018). Advances in Neural Information Processing Systems, 31, pp. 9539–9549.

SNLI に自然言語の説明を追加した論文。関係ラベルに加えて、その判断理由を収録する。

https://github.com/OanaMariaCamburu/e-SNLI