読解型質問応答用データセット

SQuAD

Stanford Question Answering Dataset

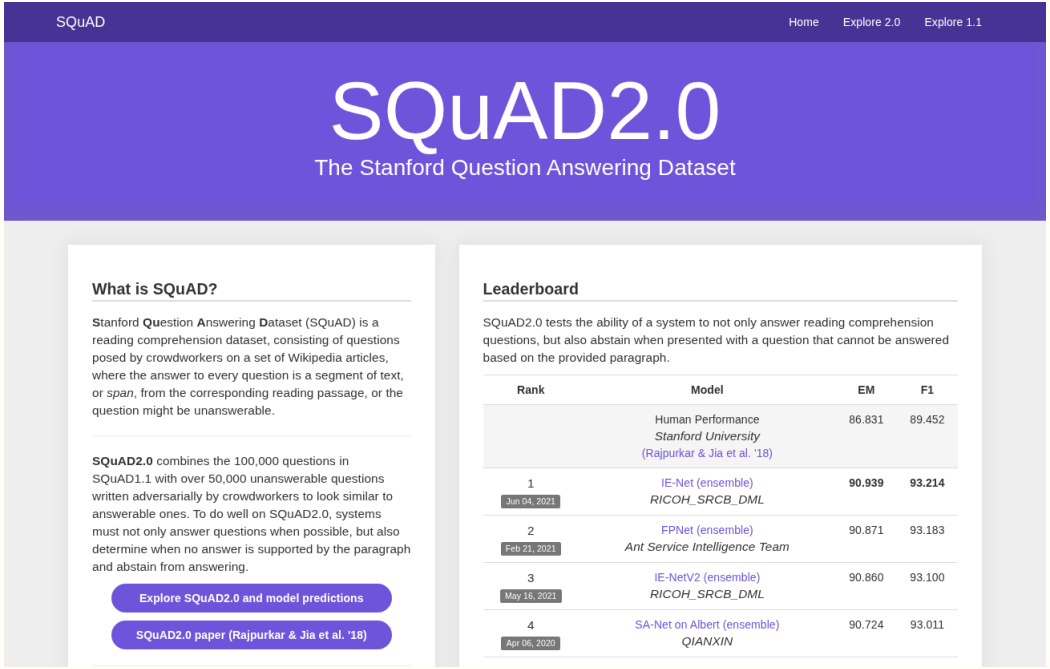
sasakiy84

本編の構成

1. 目的とタスク
2. 作成方法と規模
3. 評価と性能
4. 利用の変遷と現在
5. 入手方法とまとめ

1 目的とタスク

SQuAD の公式サイト



https://rajpurkar.github.io/SQuAD-explorer/

開発当時の課題と SQuAD の目的

- 人が書いた質問で、文章の読解を大規模に評価する [1]。
- 当時は、人手作成の読解データが小規模だった。
  - 大規模な自動作成データでは、質問・正解の形式が限定的。
- Wikipedia の段落に、人が質問と回答範囲を付ける。
  - 正解は単語 1 個や固有名詞に限らず、連続した語句を許す
- 論文では 10 万問以上・ 500 以上の記事を報告。

[1] Rajpurkar et al. (2016), § 1–3 https://aclanthology.org/D16-1264/

SQuAD のタスク

- 入力には Wikipedia 記事の 1 段落と、その段落への質問を使う [1]。
- 質問に対応する原文の表現を回答する
  - 本文中の連続した範囲を正解として指定する。
- 答えは固有名詞・年・数量・語句など。
- 元データの文章・質問・正解は英語。

[1] タスク・入力単位　https://aclanthology.org/D16-1264/

実例 1 スポーツ記事の質問

Wikipedia 記事の段落（抜粋）

> The American Football Conference (AFC) champion **Denver Broncos** defeated the National Football Conference (NFC) champion Carolina Panthers 24–10 to earn their third Super Bowl title. The game was played on February 7, 2016, at Levi's Stadium in the San Francisco Bay Area at Santa Clara, California.

質問 Which NFL team represented the AFC at Super Bowl 50?

質問の日本語訳 第 50 回スーパーボウルで AFC を代表したチームは？

正解は Denver Broncos

[1] SQuAD バージョン 1.1 / dev / 記事名 Super_Bowl_50 https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 56be4db0acb8001400a502ec

実例 2 人物記事の質問

Wikipedia 記事の段落（抜粋）

> Tesla gained experience in telephony and electrical engineering before emigrating to the United States in **1884** to work for Thomas Edison in New York City. He soon struck out on his own with financial backers, setting up laboratories and companies to develop a range of electrical devices.

質問 In what year did Nikola Tesla emigrate to the United States?

質問の日本語訳 ニコラ・テスラがアメリカへ移住したのは何年か？

正解は 1884

[1] SQuAD バージョン 1.1 / dev / 記事名 Nikola_Tesla https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 56df9ee138dc421700152108

実例３ 技術記事の質問

Wikipedia 記事の段落（抜粋）

> Steam engines are **external combustion** engines, where the working fluid is separate from the combustion products. Non-combustion heat sources such as solar power, nuclear power or geothermal energy may be used.

質問 What types of engines are steam engines?

質問の日本語訳 蒸気機関はどのような種類の機関か？

正解は external combustion

[1] SQuAD バージョン 1.1 / dev / 記事名 Steam_engine https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （ CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 57112686b654c5140001fbd7

実例 4 文章から回答できない質問

Wikipedia 記事の段落（抜粋）

> They were descended from Norse ("Norman" comes from "Norseman") raiders and pirates from Denmark, Iceland and Norway who, under their leader Rollo, agreed to swear fealty to King Charles III of West Francia.

質問 Who did King Charles III swear fealty to?

質問の日本語訳 シャルル 3 世は誰に忠誠を誓ったか？

正解は 回答不能（文章に根拠がない）

Rollo の側が王に忠誠を誓う。王が誰に誓ったかは記載されていない。

[1] SQuAD バージョン 2.0 / dev / 記事名 Normans https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v2.0.json （ CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5ad39d53604f3c001a3fe8d3

2 作成方法と規模

Wikipedia の記事と段落の選定方法

- 2016 年論文で報告された収集設計 [1]。
- 英語 Wikipedia の記事を、 PageRank を用いて順位付け。
  - 上位 10,000 記事から 536 記事を無作為に選ぶ。
- 各記事から段落を取り出し、 500 文字未満の段落を除く。
- 学習・開発・テストを記事単位で分ける。
- 入力 context は記事全文ではなく、選ばれた段落。
  - この選定条件は初版論文の設計。現在の公開 JSON の長さとは区別する。

[1] Rajpurkar et al. (2016), § 3 Dataset collection https://aclanthology.org/D16-1264/

質問と回答の作成方法

- Amazon Mechanical Turk の作業者が質問と回答を作成 [1]。
- 提示した段落について、最大 5 問を作るよう指示。
  - 段落だけから回答できる質問にする。
  - 本文のコピーではなく、自分の言葉で質問を書く。
  - 答えとなる最小限の連続した範囲を、段落内で選択する。
- 開発・テストでは、別の作業者による追加回答も収集。
  - 表現の違う正解を認め、複数正解のうち最良の一致で評価する。

[1] Rajpurkar et al. (2016), § 3 Dataset collection https://aclanthology.org/D16-1264/

バージョン 2.0 を作った理由と作成方法

- 初版では、どの質問にも段落内に答えがあった [1]。
- 作業者が各段落に対し、回答不能な質問を最大 5 問作成した。
  - 段落の話題に関連し、回答可能な質問に見えるようにする。
  - 段落内に、答えに見える候補がある質問にする。
- 記事・段落ごとの作業を分配し、人手で 50,000 問以上を追加。
- 回答範囲の抽出と、回答保留の判断を評価する。

[1] Rajpurkar, Jia & Liang (2018), § 1 ・ § 3　https://aclanthology.org/P18-2124/

SQuAD のバージョン 1.1 と 2.0

- バージョン 1.1 では、文章中に答えがある質問を扱う [1]。
  - 質問に対応する本文中の範囲を回答する
- バージョン 2.0 では、回答不能な質問を追加する [2]。
  - 既存の質問に似た、答えられない質問を人が作成。
  - 答えられるかを判定し、答えがなければ回答を控える。
- 異なるバージョンの得点は、そのまま比較できない。

[1] https://aclanthology.org/D16-1264/
[2] https://aclanthology.org/P18-2124/

公開データの規模

版・分割 [1]	質問数	回答不能	Wikipedia 記事数
1.1 ・学習用	87,599	0	442
1.1 ・開発用	10,570	0	48
2.0 ・学習用	130,319	43,498	442
2.0 ・開発用	11,873	5,945	35

- 記事数は、質問の元となった Wikipedia 記事の数。
- バージョン 2.0 は同じ記事に回答不能な質問を追加。

[1] 公式 train / dev JSON の全件集計　https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

質問と回答の長さ

長さ [1]	平均	中央値	95% 点	最大
質問の文字数	59.3	56.0	98.0	270
質問の単語数	10.1	10.0	17.0	40
回答の文字数	20.1	14.0	63.0	239
回答の単語数	3.1	2.0	10.0	43

- 公開データ 98,169 問の先頭正解を 1 問 1 件で集計。
- 最大の回答は 43 単語・ 239 文字。

[1] バージョン 1.1 の train と dev を集計。文字数は前後空白を除去し、単語数は空白で分割。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

入力段落（ context ）の長さ

context の長さ [1]	平均	中央値	95% 点	最大
文字数	739.6	679.0	1312.0	4063
単語数	117.2	108.0	210.0	653

- バージョン 1.1 train ＋ dev 、 20,963 段落を各 1 回集計。
- 同じ段落への複数質問による重複カウントはしない。
- 最長は 4,063 文字／ 653 単語。

[1] 文字数は前後空白を除去／単語数は空白分割。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

質問に大量の空白が含まれる実例

- 前後に大量の空白が含まれる質問を 1 件確認 [1]。
  - 元文字列 25,651 文字 → 前後空白を除去 59 文字。
- What radiates two lobes perpendicular to the antennas axis?
  - アンテナの軸に垂直な 2 つのローブを放射するものは何か。
- 主要統計は前後空白だけを除去し、本文の文字は保持。
- 長さの比較では、空白を含めるかで結果が大きく変わる。

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 572fdefb947a6a140053cd8d

3 評価と性能

評価手法は EM と F1 の 2 種類

- EM は、 1 問では完全一致なら 1 、不一致なら 0 [1]。
  - 正解が Denver Broncos なら、一致は 1 、 Denver は 0 。
- F1 は、共通する単語の適合率・再現率の調和平均。
  - 上の例では、完全一致なら 1 、 Denver だけなら 2/3 。
- 報告値は、全問の得点の平均 × 100 （ % ）。
  - 2 問中 1 問が完全一致なら、集合の EM は 50% 。
- 小文字化・句読点・冠詞除去・空白正規化。複数正解の最良値。

[1] 評価実装 https://github.com/huggingface/evaluate/blob/main/metrics/squad/compute_score.py

2016 年の原著のモデルは F1 が 51.0% だった

原著のモデル・人の回答	EM （%）	F1 （%）
単語一致を使う Sliding Window	12.5	19.7
ロジスティック回帰	40.4	51.0
人の回答	77.0	86.8

SQuAD バージョン 1.0 のテスト用で評価した [1]。人の得点は、追加の正解回答を予測として採点した。

[1] Rajpurkar et al. (2016), Table 5 ・ §6.2. https://aclanthology.org/D16-1264/

バージョン 1.1 のベンチマーク結果

モデル [1]	提出日	EM	F1
BiDAF	2016-11-28	68.0	77.3
BERT	2018-10-05	85.1	91.8
XLNet	2019-05-21	89.9	95.1

- SQuAD 運営者の非公開テストで採点。
- 開発用とは別のデータ。各行は単一モデルの提出結果。

[1] 掲載された提出結果（EM ・ F1 は %）。
https://rajpurkar.github.io/SQuAD-explorer/

SQuAD 2.0 では抽出型モデルも比較されている

モデル [1]	EM （%）	F1 （%）
BERT-Large	79.0	81.8
RoBERTa-Large	86.5	89.4
DeBERTa-V3-Large	89.0	91.5

- SQuAD 2.0 の学習用で微調整し、開発用で評価した公表値。
- Llama の生成評価や、運営者の非公開テストとは条件が異なる。

[1] Microsoft の公開結果で、 SQuAD 2.0 開発用の EM ・ F1 を掲載。
https://github.com/microsoft/DeBERTa

Llama 3.1 でも SQuAD 2 を評価している

事前学習モデル [1]	EM （%）
Llama 3.1 8B	77.0
Llama 3.1 70B	81.8
Llama 3.1 405B	89.3

- 2024-07-23 公開、事前学習モデルを 1-shot で生成評価。
- 先行 QA の正解を含むため、運営者のテストとは条件が異なる [2]。

[1] https://github.com/meta-llama/llama-models/blob/main/models/llama3_1/MODEL_CARD.md
[2] https://github.com/meta-llama/llama-models/blob/main/models/llama3_1/eval_details.md

4 利用の変遷と現在

SQuAD 以前にも読解用データセットがあった

- MCTest は 2013 年に公開された。
  - 短い物語を読んで 4 択質問に答える。 SQuAD は Wikipedia の段落から回答範囲を選ぶ [1]。
- CNN / Daily Mail は 2015 年に公開された。
  - ニュースの要約の固有表現を伏せて質問を自動生成する。 SQuAD では人が質問を書き、回答は任意の連続範囲を認める [2]。

[1] Richardson et al. (2013) https://aclanthology.org/D13-1020/
[2] Hermann et al. (2015) https://github.com/deepmind/rc-data

後続データセットでは入力と質問が広がった

- HotpotQA は 2018 年に公開された。
  - 複数の Wikipedia 記事にまたがる推論と、根拠文の特定を扱う。SQuAD の 1 段落の読解より、文書間の情報を組み合わせる [1]。
- Natural Questions は 2019 年に公開された。
  - Google の検索質問と Wikipedia ページを使う。 SQuAD と異なり、長い回答と短い回答を指定する [2]。

[1] Yang et al. (2018) https://github.com/hotpotqa/hotpot
[2] Kwiatkowski et al. (2019) https://github.com/google-research-datasets/natural-questions

発表当時と 2026 年時点の位置付け

- SQuAD は、生成型言語モデルの読解評価にも使われている。
- 2026 年も、 SQuAD 2.0 の評価実装が公開されている [1]。
- 一方、長い文脈を扱う LongBench v2 が 2024 年に登場した [2]。
  - 8 千〜 200 万語の文脈から選択肢を選ぶ。短い段落から回答範囲を抽出する SQuAD とは、文脈長と回答形式が異なる。

[1] Hugging Face Evaluate, SQuAD 2.0. https://github.com/huggingface/evaluate/blob/main/metrics/squad_v2/squad_v2.py
[2] LongBench v2. https://github.com/THUDM/LongBench

5 入手方法とまとめ

SQuAD の入手方法

- 公式サイトから JSON をダウンロードできる [1]。
  - 学習用 train と開発用 dev をバージョンごとに配布。
- Hugging Face Datasets からも取得できる [2]。
  - バージョン 1.1 では、 rajpurkar/squad を使う。
  - バージョン 2.0 では、 rajpurkar/squad_v2 を使う。
- データの利用条件は CC BY-SA 4.0 。

[1] https://rajpurkar.github.io/SQuAD-explorer/
[2] https://huggingface.co/datasets/rajpurkar/squad / https://huggingface.co/datasets/rajpurkar/squad_v2
[3] https://creativecommons.org/licenses/by-sa/4.0/

まとめ

- SQuAD は、英語の読解型質問応答データセット [1]。
  - Wikipedia の段落から、質問の答えとなる範囲を選ぶ。
- 人手作成の質問を大規模に評価するため、 2016 年に発表。
- バージョン 1.1 では、回答可能な質問の答えを抽出。
- バージョン 2.0 では、回答不能な質問と回答保留を追加 [2]。
- EM ・ F1 で評価。 LLM にも利用され、評価条件の確認が必要。

初版は https://aclanthology.org/D16-1264/ バージョン 2 https://aclanthology.org/P18-2124/

Appendix の目次

1. 著者と発表先
2. 追加の実例
3. 詳細統計と極値
4. 追加の評価結果
5. Wikipedia 記事一覧
6. 入手コードと参考文献

発表先と著者

- 初版は Pranav Rajpurkar らが EMNLP 2016 で発表した [1]。
- バージョン 2 は、 2018 年の ACL で発表された [2]。
- 両論文の第一著者は Pranav Rajpurkar 、最終著者は Percy Liang である。
- 2026 年に初版が ACL Test of Time Award を受賞した [1]。

[1] EMNLP 2016 https://aclanthology.org/D16-1264/
[2] ACL 2018 Short Papers https://aclanthology.org/P18-2124/

主な著者の研究分野と実績

- 第一著者の Pranav Rajpurkar は、読解型 QA と医療 AI を研究している [1,2]。
- SQuAD と、胸部 X 線のデータセット CheXpert に貢献した（2019 年） [5]。
- 最終著者の Percy Liang は、自然言語処理・機械学習を研究している。
- SQuAD と、言語モデルを幅広く評価する HELM に取り組んだ [3]。

[1] https://aclanthology.org/D16-1264/ [2] https://aclanthology.org/P18-2124/
[3] https://github.com/stanford-crfm/helm
[5] https://github.com/stanfordmlgroup/chexpert-labeler

補足実例 1 Apollo program

Wikipedia 記事の段落（抜粋）

> The first manned flight of Apollo was in **1968**.

質問 What year did the first manned Apollo flight occur?

質問の日本語訳 アポロ計画の最初の有人飛行が行われたのは何年か？

正解は 1968

[1] SQuAD バージョン 1.1 / dev / 記事名 Apollo_program https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5725b41838643c19005acb81

補足実例 2 Amazon rainforest

Wikipedia 記事の段落（抜粋）

> This region includes territory belonging to **nine nations**. The majority of the forest is contained within Brazil, with 60% of the rainforest, followed by Peru with 13%, Colombia with 10%, and with minor amounts in Venezuela, Ecuador, Bolivia, Guyana, Suriname and French Guiana.

質問 How many nations are within the Amazon Basin?

質問の日本語訳 アマゾン盆地には何か国が含まれるか？

正解は nine nations

[1] SQuAD バージョン 1.1 / dev / 記事名 Amazon_rainforest https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5729e2316aef0514001550c6

補足実例 3 Prime number

Wikipedia 記事の段落（抜粋）

> A prime number (or a prime) is a natural number greater than 1 that has no positive divisors other than 1 and **itself**. A natural number greater than 1 that is not a prime number is called a composite number.

質問 What is the only divisor besides 1 that a prime number can have?

質問の日本語訳 素数が 1 以外に持つことのできる約数は何か？

正解は itself

[1] SQuAD バージョン 1.1 / dev / 記事名 Prime_number https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 57296d571d04691400779413

補足実例 4 Black Death

Wikipedia 記事の段落（抜粋）

> Spreading throughout the Mediterranean and Europe, the Black Death is estimated to have killed **30–60% of Europe's total population**. In total, the plague reduced the world population from an estimated 450 million down to 350–375 million in the 14th century.

質問 How much of the European population did the black death kill?

質問の日本語訳 黒死病でヨーロッパ人口のどのくらいが死亡したか？

正解は 30–60% of Europe's total population

[1] SQuAD バージョン 1.1 / dev / 記事名 Black_Death https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5726468470898414009 4c125

補足実例 5 Warsaw

Wikipedia 記事の段落（抜粋）

> One of the most famous people born in Warsaw was Maria Skłodowska-Curie, who achieved international recognition for her research on radioactivity and was the first female recipient of the **Nobel Prize**. Famous musicians include Władysław Szpilman and Frédéric Chopin.

質問 What was Maria Curie the first female recipient of?

質問の日本語訳 マリ・キュリーが女性として初めて受賞した賞は何か？

正解は Nobel Prize

[1] SQuAD バージョン 1.1 / dev / 記事名 Warsaw https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （ CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5733a5f54776f41900660f45

補足実例 6 Genghis Khan

Wikipedia 記事の段落（抜粋）

> After founding **the Mongol Empire** and being proclaimed "Genghis Khan", he started the Mongol invasions that resulted in the conquest of most of Eurasia. These included raids or invasions of the Qara Khitai, Caucasus, Khwarezmid Empire, Western Xia and Jin dynasties.

質問 What do we call the empire that Genghis Khan founded?

質問の日本語訳 チンギス・ハンが建てた帝国を何と呼ぶか？

正解は the Mongol Empire

[1] SQuAD バージョン 1.1 / dev / 記事名 Genghis_Khan https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （ CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 57269e8a5951b619008f77f5

補足実例 7 Chloroplast

Wikipedia 記事の段落（抜粋）

> Chloroplasts' main role is **to conduct photosynthesis**, where the photosynthetic pigment chlorophyll captures the energy from sunlight and converts it and stores it in the energy-storage molecules ATP and NADPH while freeing oxygen from water.

質問 What is the primary purpose of chloroplasts?

質問の日本語訳 葉緑体の主な役割は何か？

正解は to conduct photosynthesis

[1] SQuAD バージョン 1.1 / dev / 記事名 Chloroplast https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 572953013f37b3190047824d

補足実例 8 University of Chicago

Wikipedia 記事の段落（抜粋）

> The University of Chicago (UChicago, Chicago, or U of C) is **a private research university** in Chicago. The university, established in 1890, consists of The College, various graduate programs, interdisciplinary committees organized into four academic research divisions and seven professional schools.

質問 What kind of university is the University of Chicago?

質問の日本語訳 シカゴ大学はどのような種類の大学か？

正解は a private research university

[1] SQuAD バージョン 1.1 / dev / 記事名 University_of_Chicago https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 57283c464b864d19001647c8

補足実例 9 Steam engine

Wikipedia 記事の段落（抜粋）

> Steam engines are external combustion engines, where the working fluid is separate from the combustion products.

質問 What types of engines are solar engines?

質問の日本語訳 太陽熱機関はどのような種類の機関か？

正解は 回答不能（文章に根拠がない）

原文は蒸気機関を説明する。太陽熱機関の種類は書かれていない。

[1] SQuAD バージョン 2.0 / dev / 記事名 Steam_engine https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v2.0.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5ad3bd8f604f3c001a3fef31

補足実例 10 Oxygen

Wikipedia 記事の段落（抜粋）

> Diatomic oxygen gas constitutes 20.8% of the Earth's atmosphere.

質問 What constitutes 28.0% of the Earth's atmosphere?

質問の日本語訳 地球の大気の 28.0% を占めるものは何か？

正解は 回答不能（文章に根拠がない）

原文の割合は 20.8% 。 28.0% に対応する記述はない。

[1] SQuAD バージョン 2.0 / dev / 記事名 Oxygen https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v2.0.json （ CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5ad21646d7d075001a4283c7

記述統計 バージョン 1.1 ・学習用

質問 87,599 件／回答あり 87,599 件／回答不能 0 件

指標 [1]	平均	標準偏差	最小	25% 点	中央値	75% 点	95% 点	最大
質問文字	59.2	21.2	1	44.0	56.0	71.0	98.0	270
質問単語	10.1	3.6	1	8.0	10.0	12.0	17.0	40
回答文字	20.1	21.6	1	7.0	14.0	23.0	63.0	239
回答単語	3.2	3.4	1	1.0	2.0	3.0	10.0	43

- 文字数は前後の空白だけを除いた文字列の長さ。
- 単語数は空白区切り。回答は先頭の正解を 1 問 1 件、回答不能は除外。

[1] 公式 JSON を全件集計　https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

記述統計 バージョン 1.1 ・開発用

質問 10,570 件／回答あり 10,570 件／回答不能 0 件

指標 [1]	平均	標準偏差	最小	25% 点	中央値	75% 点	95% 点	最大
質問文字	60.0	21.2	12	45.0	57.0	72.0	99.0	197
質問単語	10.2	3.6	3	8.0	10.0	12.0	17.0	33
回答文字	19.4	19.3	1	8.0	14.0	23.0	57.0	160
回答単語	3.0	3.0	1	1.0	2.0	3.0	9.0	29

- 文字数は前後の空白だけを除いた文字列の長さ。
- 単語数は空白区切り。回答は先頭の正解を 1 問 1 件、回答不能は除外。

[1] 公式 JSON を全件集計　https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

記述統計 バージョン 2.0 ・学習用

質問 130,319 件／回答あり 86,821 件／回答不能 43,498 件

指標 [1]	平均	標準偏差	最小	25% 点	中央値	75% 点	95% 点	最大
質問文字	58.3	20.4	1	44.0	55.0	69.0	96.0	270
質問単語	9.9	3.4	1	7.0	9.0	12.0	16.0	40
回答文字	20.1	21.6	1	7.0	14.0	23.0	63.0	239
回答単語	3.2	3.4	1	1.0	2.0	4.0	10.0	43

- 文字数は前後の空白だけを除いた文字列の長さ。
- 単語数は空白区切り。回答は先頭の正解を 1 問 1 件、回答不能は除外。

[1] 公式 JSON を全件集計　https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

記述統計 バージョン 2.0 ・開発用

質問 11,873 件／回答あり 5,928 件／回答不能 5,945 件

指標 [1]	平均	標準偏差	最小	25% 点	中央値	75% 点	95% 点	最大
質問文字	59.4	20.8	11	45.0	57.0	71.0	98.0	197
質問単語	10.0	3.5	3	8.0	10.0	12.0	16.0	31
回答文字	20.9	21.4	1	8.0	14.0	24.0	64.0	160
回答単語	3.2	3.3	1	1.0	2.0	4.0	10.0	29

- 文字数は前後の空白だけを除いた文字列の長さ。
- 単語数は空白区切り。回答は先頭の正解を 1 問 1 件、回答不能は除外。

[1] 公式 JSON を全件集計　https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

回答長の集計単位 バージョン 1.1

対象・指標 [1]	件数	平均	中央値	95% 点	最大
1 問 1 件・文字	98,169	20.1	14.0	63.0	239
1 問 1 件・単語	98,169	3.1	2.0	10.0	43
全正解注釈・文字	122,325	19.7	14.0	61.0	239
全正解注釈・単語	122,325	3.1	2.0	9.0	43

- 学習用＋開発用を集計。回答不能の質問は除外。
- 全正解注釈では、同じ質問の複数正解・重複注釈も数える。

https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

回答長の集計単位 バージョン 2.0

対象・指標 [1]	件数	平均	中央値	95% 点	最大
1 問 1 件・文字	92,749	20.2	14.0	63.0	239
1 問 1 件・単語	92,749	3.2	2.0	10.0	43
全正解注釈・文字	107,123	20.1	14.0	63.0	239
全正解注釈・単語	107,123	3.1	2.0	10.0	43

- 学習用＋開発用を集計。回答不能の質問は除外。
- 全正解注釈では、同じ質問の複数正解・重複注釈も数える。

https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

入力段落の記述統計 バージョン 1.1 ・ train

context [1]	件数	平均	SD	中央値	95% 点	最大
文字数	18896	735.8	310.0	678.0	1311.0	3706
単語数	18896	116.6	49.7	107.0	210.0	653

- 各段落を 1 回ずつ集計（質問数による重複は含めない）。
- 文字数は前後空白除去／単語数は空白分割。

[1] 各行の最大値に対応する ID と具体例は、以降の「最大値の実例」に掲載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

入力段落の記述統計 バージョン 1.1 ・ dev

context [1]	件数	平均	SD	中央値	95% 点	最大
文字数	2067	774.3	342.9	700.0	1338.0	4063
単語数	2067	122.8	54.8	111.0	213.0	629

- 各段落を 1 回ずつ集計（質問数による重複は含めない）。
- 文字数は前後空白除去／単語数は空白分割。

[1] 各行の最大値に対応する ID と具体例は、以降の「最大値の実例」に掲載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

入力段落の記述統計 バージョン 2.0 ・ train

context [1]	件数	平均	SD	中央値	95% 点	最大
文字数	19035	735.5	309.8	677.0	1310.3	3706
単語数	19035	116.6	49.7	107.0	209.0	653

- 各段落を 1 回ずつ集計（質問数による重複は含めない）。
- 文字数は前後空白除去／単語数は空白分割。

[1] 各行の最大値に対応する ID と具体例は、以降の「最大値の実例」に掲載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

入力段落の記述統計 バージョン 2.0 ・ dev

context [1]	件数	平均	SD	中央値	95% 点	最大
文字数	1204	802.6	359.6	711.5	1425.9	4063
単語数	1204	126.6	57.4	113.0	223.8	629

- 各段落を 1 回ずつ集計（質問数による重複は含めない）。
- 文字数は前後空白除去／単語数は空白分割。

[1] 各行の最大値に対応する ID と具体例は、以降の「最大値の実例」に掲載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

最大値の実例 1 Age of Enlightenment

- 質問文字数 270 ／質問単語数 40 [1]
- 質問 Which century is considered by some as a "drab" period, however saw significant advancements in the practice of medicine, mathematics, and physics, the development of biological taxonomy, a new understanding of magnetism, and the maturation of chemistry as a discipline?
- 正解は the 18th century
- 対象の版と分割は 1.1/train 、 2.0/train 。

[1] 記事名 Age_of_Enlightenment https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5710dcb5b654c5140001fa10

最大値の原文 1 Age of Enlightenment

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> Philosophes introduced the public to many scientific theories, most notably through the Encyclopédie and the popularization of Newtonianism by Voltaire and Émilie du Châtelet. Some historians have marked the 18th century as a drab period in the history of science; however, the century saw significant advancements in the practice of medicine, mathematics, and physics; the development of biological taxonomy; a new understanding of magnetism and electricity; and the maturation of chemistry as a discipline, which established the foundations of modern chemistry.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5710dcb5b654c5140001fa10

最大値の実例 2 Sahara

- 段落文字数 3706 ／段落単語数 653 [1]。
- 質問 What is the largest hottest continuously large area worldwide?
- 正解は the Great Desert
- 対象の版と分割は 1.1/train 、 2.0/train 。

[1] 記事名 Sahara https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5728c4163acd2414000dfddf

最大値の原文 2 Sahara

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> A value of 4,300 h or 98% of the time would be recorded in Upper Egypt (Aswan, Luxor) and in the Nubian Desert (Wadi Halfa). The annual average direct solar irradiation is around 2,800 kWh/(m2 year) in the Great Desert. The Sahara has a huge potential for solar energy production. The constantly high position of the sun, the extremely low relative humidity, the lack of vegetation and rainfall make the Great Desert the hottest continuously large area worldwide and certainly the hottest place on Earth during summertime in some spots.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5728c4163acd2414000dfddf

最大値の実例 3 2008 Sichuan earthquake

- 回答文字数 239 ／回答単語数 43 [1]。
- 質問 What was concluded about the construction?
- 正解は that the sudden shift of a huge quantity of water into the region could have relaxed the tension between the two sides of the fault, allowing them to move apart, and could have increased the direct pressure on it, causing a violent rupture
- 対象の版と分割は 1.1/train 、 2.0/train 。

[1] 記事名 2008_Sichuan_earthquake https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 56cec3e8aab44d1400b88a02

最大値の原文 3 2008 Sichuan earthquake

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> An article in Science suggested that the construction and filling of the Zipingpu Dam may have triggered the earthquake. The chief engineer of the Sichuan Geology and Mineral Bureau said that the sudden shift of a huge quantity of water into the region could have relaxed the tension between the two sides of the fault, allowing them to move apart, and could have increased the direct pressure on it, causing a violent rupture. The effect was "25 times more" than a year's worth of natural stress from tectonic movement.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 56cec3e8aab44d1400b88a02

最大値の実例 4 Construction

- 質問文字数 197 [1]
- 質問 What kind of contract is given when the contractor is given a performance specification and must undertake the project from design to construction, while adhering to the performance specifications?
- 正解は "design build" contract
- 対象の版と分割は 1.1/dev 、 2.0/dev 。

[1] 記事名 Construction https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 57274e0d708984140094dbe8

最大値の原文 4 Construction

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> Presently, a firm that is nominally an "architecture" or "construction management" firm may have experts from all related fields as employees, or to have an associated company that provides each necessary skill. Thus, each such firm may offer itself as "one-stop shopping" for a construction project, from beginning to end. This is designated as a "design build" contract where the contractor is given a performance specification and must undertake the project from design to construction, while adhering to the performance specifications.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 57274e0d708984140094dbe8

最大値の実例 5 Super Bowl 50

- 質問単語数 33 [1]
- 質問 What was the name of the event at the The Embarcadero that was held prior to Super Bowl 50 to help show off some of the things that San Francisco has to offer?
- 正解は Super Bowl City
- 対象の版と分割は 1.1/dev 。

[1] 記事名 Super_Bowl_50 https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 56bf53e73aeaaa14008c95ce

最大値の原文 5 Super Bowl 50

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> The annual NFL Experience was held at the Moscone Center in San Francisco. In addition, "Super Bowl City" opened on January 30 at Justin Herman Plaza on The Embarcadero, featuring games and activities that will highlight the Bay Area's technology, culinary creations, and cultural diversity. More than 1 million people are expected to attend the festivities in San Francisco during Super Bowl Week. San Francisco mayor Ed Lee said of the highly visible homeless presence in this area "they are going to have to leave".

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 56bf53e73aeaaa14008c95ce

最大値の実例 6 European Union law

- 段落文字数 4063 ／段落単語数 629 [1]。
- 質問 The freedom to provide services under TFEU article 56 applies to who?
- 正解は to people who give services "for remuneration"
- 対象の版と分割は 1.1/dev 、 2.0/dev 。

[1] 記事名 European_Union_law https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5726c3da708984140094d0d9

最大値の原文 6 European Union law

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> The "freedom to provide services" under TFEU article 56 applies to people who give services "for remuneration", especially commercial or professional activity. For example, in Van Binsbergen v Bestuur van de Bedrijfvereniging voor de Metaalnijverheid a Dutch lawyer moved to Belgium while advising a client in a social security case, and was told he could not continue because Dutch law said only people established in the Netherlands could give legal advice.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5726c3da708984140094d0d9

最大値の実例 7 French and Indian War

- 回答文字数 160 [1]。
- 質問 What was normal British defense?
- 正解は mustered local militia companies, generally ill trained and available only for short periods, to deal with native threats, but did not have any standing forces.
- 対象の版と分割は 1.1/dev 、 2.0/dev 。

[1] 記事名 French_and_Indian_War https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5733dab4d058e614000b640b

最大値の原文 7 French and Indian War

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> New France was defended by about 3,000 troupes de la marine, companies of colonial regulars (some of whom had significant woodland combat experience). The colonial government recruited militia support when needed. Most British colonies mustered local militia companies, generally ill trained and available only for short periods, to deal with native threats, but did not have any standing forces.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5733dab4d058e614000b640b

最大値の実例 8 Ctenophora

- 回答単語数 29 [1]。
- 質問 What does the internal cavity contain?
- 正解は a mouth that can usually be closed by muscles; a pharynx ("throat"); a wider area in the center that acts as a stomach; and a system of internal canals.
- 対象の版と分割は 1.1/dev 、 2.0/dev 。

[1] 記事名 Ctenophora https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 57264b1ddd62a815002e80a3

最大値の原文 8 Ctenophora

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> The internal cavity forms: a mouth that can usually be closed by muscles; a pharynx ("throat"); a wider area in the center that acts as a stomach; and a system of internal canals. These branch through the mesoglea to the most active parts of the animal: the mouth and pharynx; the roots of the tentacles, if present; all along the underside of each comb row; and four branches round the sensory complex at the far end from the mouth – two of these four branches terminate in anal pores.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 57264b1ddd62a815002e80a3

最大値の実例 9 European Union law

- 質問単語数 31 [1]
- 質問 In which case did the Court of Justice state that refusal to admit a lawyer to the Belgian bar because he did not have Belgian heritage wasn't able to be justified?
- 正解は Reyners v Belgium
- 対象の版と分割は 2.0/dev 。

[1] 記事名 European_Union_law https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5726c002708984140094d075

最大値の原文 9 European Union law

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> The Court of Justice has held that both a member state government and a private party can hinder freedom of establishment, so article 49 has both "vertical" and "horizontal" direct effect. In Reyners v Belgium the Court of Justice held that a refusal to admit a lawyer to the Belgian bar because he lacked Belgian nationality was unjustified. TFEU article 49 says states are exempt from infringing others' freedom of establishment when they exercise "official authority", but this did an advocate's work (as opposed to a court's) was not official.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5726c002708984140094d075

バージョン 2.0 のベンチマーク結果

モデル [1]	提出日	EM	F1
BERT	2018-11-08	80.0	83.1
RoBERTa	2019-07-20	86.8	89.8
XLNet	2019-11-15	87.9	90.7

- SQuAD 運営者の非公開テストで採点。
- 開発用とは別のデータ。各行は単一モデルの提出結果。

[1] 掲載された提出結果（EM ・ F1 は %）。
https://rajpurkar.github.io/SQuAD-explorer/

開発用 Wikipedia 記事一覧 1/2

バージョン 1.1 では、 48 記事／ 2.0 このうち 35 記事。

1973_oil_crisis
Amazon_rainforest
American_Broadcasting_Company *
Apollo_program *
Black_Death
Chloroplast *
Civil_disobedience
Computational_complexity_theory
Construction
Ctenophora
Doctor_Who *
Economic_inequality
European_Union_law
Force
French_and_Indian_War
Fresno,_California
Genghis_Khan *
Geology
Harvard_University
Huguenot
Immune_system
Imperialism
Intergovernmental_Panel_on_Climate_Change
Islamism

* はバージョン 1.1 のみに含まれる開発用記事。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

開発用 Wikipedia 記事一覧 2/2

バージョン 1.1 では、 48 記事／ 2.0 このうち 35 記事。

Jacksonville,_Florida
Kenya *
Martin_Luther *
Newcastle_upon_Tyne *
Nikola_Tesla *
Normans
Oxygen
Packet_switching
Pharmacy
Prime_number
Private_school
Rhine
Scottish_Parliament
Sky_(United_Kingdom)
Southern_California
Steam_engine
Super_Bowl_50 *
Teacher *
United_Methodist_Church *
University_of_Chicago
Victoria_(Australia)
Victoria_and_Albert_Museum *
Warsaw
Yuan_dynasty

* はバージョン 1.1 のみに含まれる開発用記事。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 1/19

バージョン 1.1 と 2.0 に共通する 442 記事。

2008_Sichuan_earthquake
2008_Summer_Olympics_torch_relay
51st_state
A_cappella
Adolescence
Adult_contemporary_music
Affirmative_action_in_the_United_States
Age_of_Enlightenment
Aircraft_carrier
Airport
Alaska
Alexander_Graham_Bell
Alfred_North_Whitehead
Alloy
Alps
Alsace
American_Idol
Animal
Ann_Arbor,_Michigan
Annelid
Antarctica
Antenna_(radio)
Anthropology
Anti-aircraft_warfare

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 2/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Antibiotics
Apollo
Appalachian_Mountains
Architecture
Arena_Football_League
Armenia
Armenians
Arnold_Schwarzenegger
Arsenal_F.C.
ASCII
Ashkenazi_Jews
Asphalt
Aspirated_consonant
Association_football
Asthma
Athanasius_of_Alexandria
Atlantic_City,_New_Jersey
Avicenna
Bacteria
Baptists
BBC_Television
Beer
BeiDou_Navigation_Satellite_System
Bermuda

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 3/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Bern
Beyoncé
Bill_%26_Melinda_Gates_Foundation
Biodiversity
Bird
Bird_migration
Black_people
Boston
Botany
Brain
Bras%C3%ADlia
Brigham_Young_University
British_Empire
British_Isles
Buckingham_Palace
Buddhism
Canadian_Armed_Forces
Canadian_football
Canon_law
Capacitor
Capital_punishment_in_the_United_States
Cardinal_(Catholicism)
Carnival
Catalan_language

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 4/19

バージョン 1.1 と 2.0 に共通する 442 記事。

CBC_Television
Central_African_Republic
Central_Intelligence_Agency
Charleston,_South_Carolina
Chicago_Cubs
Chihuahua_(state)
Child_labour
Chinese_characters
Christian
Circadian_rhythm
Classical_music
Clothing
Comcast
Comics
Communication
Communications_in_Somalia
Compact_disc
Comprehensive_school
Computer
Computer_security
Copper
Copyright_infringement
Cork_(city)
Cotton

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 5/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Crimean_War
Crucifixion_of_Jesus
Cubism
Culture
Cyprus
Czech_language
Data_compression
Database
Daylight_saving_time
Dell
Department_store
Detroit
Dialect
Diarrhea
Digestion
Digimon
Dissolution_of_the_Soviet_Union
Dog
Dominican_Order
Dutch_language
Dutch_Republic
Dwight_D._Eisenhower
East_India_Company
East_Prussia

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 6/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Economy_of_Greece
Edmund_Burke
Education
Egypt
Electric_motor
Elevator
Elizabeth_II
Emotion
Empiricism
Endangered_Species_Act
Energy
England_national_football_team
Eritrea
Estonia
Estonian_language
Eton_College
European_Central_Bank
Everton_F.C.
Exhibition_game
FA_Cup
FC_Barcelona
Federal_Aviation_Administration
Federal_Bureau_of_Investigation
Federalism

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 7/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Film_speed
Financial_crisis_of_2007%E2%80%9308
Florida
Flowering_plant
Franco-Prussian_War
Freemasonry
Friedrich_Hayek
Frédéric_Chopin
Galicia_(Spain)
Gamal_Abdel_Nasser
Gene
General_Electric
Genocide
Genome
Geography_of_the_United_States
Geological_history_of_Earth
George_VI
Georgian_architecture
Germans
Glacier
Glass
God
Gothic_architecture
Gramophone_record

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 8/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Grape
Great_Plains
Great_power
Greece
Greeks
Green
Gregorian_calendar
Group_(mathematics)
Guam
Guinea-Bissau
Gymnastics
Han_dynasty
Hanover
Hard_rock
Heian_period
Hellenistic_period
Heresy
High-definition_television
Himachal_Pradesh
Hindu_philosophy
History_of_India
History_of_science
Hokkien
House_music

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 9/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Houston
Human_Development_Index
Humanism
Hunter-gatherer
Hunting
Hyderabad
Hydrogen
IBM
Idealism
Identity_(social_science)
Imamah_(Shia_doctrine)
Immaculate_Conception
Immunology
Imperial_College_London
Incandescent_light_bulb
Indigenous_peoples_of_the_Americas
Infection
Infrared
Insect
Institute_of_technology
Intellectual_property
Internet_service_provider
IPod
Iran

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 10/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Iranian_languages
Israel
Jehovah%27s_Witnesses
Jews
John,_King_of_England
John_Kerry
John_von_Neumann
Josip_Broz_Tito
Kanye_West
Karl_Popper
Kathmandu
Kievan_Rus%27
Korean_War
Labour_Party_(UK)
Lancashire
LaserDisc
Late_Middle_Ages
Law_of_the_United_States
Letter_case
Liberal_Party_of_Australia
Liberia
Light-emitting_diode
Lighting
List_of_numbered_streets_in_Manhattan

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 11/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Literature
London
Macintosh
Madonna_(entertainer)
Madrasa
Mali
Mammal
Mandolin
Marshall_Islands
Marvel_Comics
Mary_(mother_of_Jesus)
Materialism
Matter
Melbourne
Memory
Mesozoic
Mexico_City
Miami
Middle_Ages
Military_history_of_the_United_States
Ministry_of_Defence_(United_Kingdom)
Modern_history
Molotov%E2%80%93Ribbentrop_Pact
Montana

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 12/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Montevideo
Mosaic
MP3
Muammar_Gaddafi
Multiracial_American
Muslim_world
Myanmar
Myocardial_infarction
Namibia
Nanjing
Napoleon
National_Archives_and_Records_Administration
Near_East
Neoclassical_architecture
Neolithic
Neptune
New_Delhi
New_Haven,_Connecticut
New_York_City
Nigeria
Nintendo_Entertainment_System
Nonprofit_organization
Norfolk_Island
North_Carolina

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 13/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Northwestern_University
Nutrition
Oklahoma
Oklahoma_City
Old_English
On_the_Origin_of_Species
Order_of_the_British_Empire
Orthodox_Judaism
Ottoman_Empire
Pacific_War
Pain
Palermo
Paper
Paris
Party_leaders_of_the_United_States_House_of_Representatives。
Pesticide
Pharmaceutical_industry
Philadelphia
Philosophy_of_space_and_time
Phonology
Pitch_(music)
Planck_constant
PlayStation_3

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 14/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Plymouth
Police
Political_corruption
Political_party
Political_philosophy
Pope_John_XXIII
Pope_Paul_VI
Portugal
Post-punk
Poultry
Predation
Premier_League
Presbyterianism
Prime_minister
Printed_circuit_board
Professional_wrestling
Protestantism
Pub
Punjab,_Pakistan
Qing_dynasty
Queen_(band)
Queen_Victoria
Quran
Race_(human_categorization)

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 15/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Race_and_ethnicity_in_the_United_States_Census
Railway_electrification_system
Rajasthan
Raleigh,_North_Carolina
Red
Religion_in_ancient_Rome
Renewable_energy_commercialization
Republic_of_the_Congo
Richard_Feynman
Richmond,_Virginia
Roman_Republic
Royal_assent
Royal_Dutch_Shell
Royal_Institute_of_British_Architects
Rule_of_law
Russian_language
Russian_Soviet_Federative_Socialist_Republic
Sahara
Saint_Barth%C3%A9lemy
Saint_Helena
Samoa
Samurai
San_Diego
Sanskrit

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 16/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Santa_Monica,_California
Seattle
Separation_of_church_and_state_in_the_United_States
Separation_of_powers_under_the_United_States_Constitution
Serbo-Croatian
Seven_Years%27_War
Sexual_orientation
Sichuan
Sino-Tibetan_relations_during_the_Ming_dynasty
Slavs
Software_testing
Solar_energy
Somalis
Somerset
Sony_Music_Entertainment
Southampton
Southeast_Asia
Southern_Europe
Space_Race
Spanish_language_in_the_United_States
Spectre_(2015_film)
St._John%27s,_Newfoundland_and_Labrador

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 17/19

バージョン 1.1 と 2.0 に共通する 442 記事。

States_of_Germany
Steven_Spielberg
Strasbourg
Sumer
Super_Nintendo_Entertainment_System
Supreme_court
Swaziland
Switzerland
Symbiosis
Szlachta
Tajikistan
Tennessee
Textual_criticism
The_Blitz
The_Bronx
The_Legend_of_Zelda _Twilight_Princess
The_Sun_(United_Kingdom)
The_Times
Thuringia
Tibet
Time
To_Kill_a_Mockingbird
Transistor
Translation

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 18/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Treaty
Tristan_da_Cunha
Tuberculosis
Tucson,_Arizona
Turner_Classic_Movies
Tuvalu
Umayyad_Caliphate
Unicode
United_Nations_Population_Fund
United_States_Air_Force
United_States_Army
United_States_dollar
United_States_presidential_election,_2004
Universal_Studios
University
University_of_Kansas
University_of_Notre_Dame
Uranium
USB
Utrecht
Vacuum
Valencia
Videoconferencing
Virgil

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 19/19

バージョン 1.1 と 2.0 に共通する 442 記事。

War_on_Terror
Warsaw_Pact
Washington_University_in_St._Louis
Wayback_Machine
Web_browser
Westminster_Abbey
Windows_8
Wood
Xbox_360
Yale_University
YouTube
Zhejiang
Zinc

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

データを取得する Python コード

```
import json
from urllib.request import urlopen

base = "https://rajpurkar.github.io/SQuAD-explorer/dataset/"
for version in ("1.1", "2.0"):
    for split in ("train", "dev"):
        name = f"{split}-v{version}.json"
        with urlopen(base + name) as response:
            data = json.load(response)
        with open(name, "w", encoding="utf-8") as output:
            json.dump(data, output, ensure_ascii=False)
```

配布元　https://rajpurkar.github.io/SQuAD-explorer/dataset/
バージョン・分割ごとに公式 JSON を取得。 Python 標準ライブラリのみ使用。

参考文献・公式資料

- Rajpurkar et al. (2016), SQuAD
  - https://aclanthology.org/D16-1264/
- Rajpurkar, Jia & Liang (2018), Know What You Don’t Know
  - https://aclanthology.org/P18-2124/
- SQuAD 公式サイト・配布データ・リーダーボード
  - https://rajpurkar.github.io/SQuAD-explorer/
- データのライセンス CC BY-SA 4.0
  - https://creativecommons.org/licenses/by-sa/4.0/

参考資料 近年の評価と著者の関連研究

- Llama 3.1 モデルカード・評価条件
  - https://github.com/meta-llama/llama-models/blob/main/models/llama3_1/MODEL_CARD.md
  - https://github.com/meta-llama/llama-models/blob/main/models/llama3_1/eval_details.md
- LongBench v2 長い文脈の理解・推論評価
  - https://github.com/THUDM/LongBench
- Jia & Liang (2017) 敵対的な読解評価
  - https://github.com/robinjia/adversarial-squad
- Liang et al. HELM による言語モデル評価
  - https://github.com/stanford-crfm/helm