読解型質問応答用データセット

SQuAD

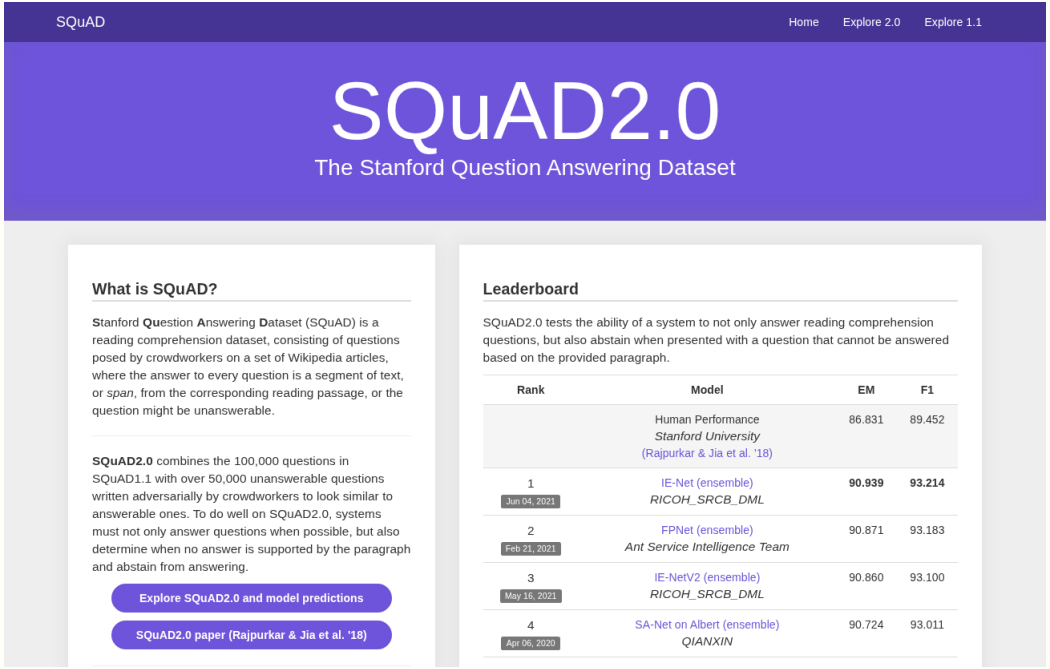
Stanford Question Answering Dataset

sasakiy84

1.SQuAD の読解課題と版ごとの違い
2.質問・回答の作成方法と収録規模
3.読解の評価指標とモデル性能
4.SQuAD の利用動向と後続データ
5.質問応答データの入手方法と利用条件

1. SQuAD の読解課題と版ごとの違い

SQuAD の公式サイト



https://rajpurkar.github.io/SQuAD-explorer/

段落と質問を入力し答えの範囲を選ぶ

- 読解型質問応答は、文章を根拠に質問へ答える課題である。 SQuAD では、英語 Wikipedia の記事から選んだ 1 段落と、その段落に対する質問を入力する。
- 答えは、段落内にある連続した語句を選ぶ。固有名詞・年・数量に限らず、複数語からなる表現も正解となる。
- バージョン 2.0 には段落から答えられない質問もあり、答えの抽出に加えて回答を控える判断を行う。

[1] Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text. https://aclanthology.org/D16-1264/

[2] Rajpurkar et al. (2018). ACL, pp. 784–789. Know What You Don’t Know: Unanswerable Questions for SQuAD. https://aclanthology.org/P18-2124/

記事の中の段落に複数の質問と正解が付く

- 配布データの全体は記事の集合である。各記事には複数の段落があり、それぞれの段落に質問と正解回答が付く。
- context は入力となる 1 段落、 question はその段落への質問、 answers は正解の文字列と段落内の開始位置を表す。
- 同じ段落へ複数の質問を作れるため、記事数・段落数・質問数・正解注釈数は異なる。モデルには記事全体ではなく、その質問に対応する段落を渡す。

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

実例 1　スポーツ記事の質問

Wikipedia 記事の段落（抜粋）

> The American Football Conference (AFC) champion **Denver Broncos** defeated the National Football Conference (NFC) champion Carolina Panthers 24–10 to earn their third Super Bowl title. The game was played on February 7, 2016, at Levi's Stadium in the San Francisco Bay Area at Santa Clara, California.

質問　Which NFL team represented the AFC at Super Bowl 50?

質問の日本語訳 第 50 回スーパーボウルで AFC を代表したチームは？

正解は　Denver Broncos

[1] SQuAD　記事名　Super_Bowl_50　https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json　（CC BY-SA 4.0 ／抜粋・強調・質問訳を追加）　ID 56be4db0acb8001400a502ec

実例 2 人物記事の質問

Wikipedia 記事の段落（抜粋）

> Tesla gained experience in telephony and electrical engineering before emigrating to the United States in **1884** to work for Thomas Edison in New York City. He soon struck out on his own with financial backers, setting up laboratories and companies to develop a range of electrical devices.

質問 In what year did Nikola Tesla emigrate to the United States?

質問の日本語訳 ニコラ・テスラがアメリカへ移住したのは何年か？

正解は 1884

[1] SQuAD 記事名 Nikola_Tesla https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 56df9ee138dc421700152108

実例 3 技術記事の質問

Wikipedia 記事の段落（抜粋）

> Steam engines are **external combustion** engines, where the working fluid is separate from the combustion products. Non-combustion heat sources such as solar power, nuclear power or geothermal energy may be used.

質問 What types of engines are steam engines?

質問の日本語訳 蒸気機関はどのような種類の機関か？

正解は external combustion

[1] SQuAD 記事名 Steam_engine https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 57112686b654c5140001fbd7

実例 4 文章から回答できない質問

Wikipedia 記事の段落（抜粋）

> They were descended from Norse ("Norman" comes from "Norseman") raiders and pirates from Denmark, Iceland and Norway who, under their leader Rollo, agreed to swear fealty to King Charles III of West Francia.

質問 Who did King Charles III swear fealty to?

質問の日本語訳 シャルル 3 世は誰に忠誠を誓ったか？

正解は 回答不能（文章に根拠がない）

Rollo の側が王に忠誠を誓う。王が誰に誓ったかは記載されていない。

[1] SQuAD 記事名 Normans https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v2.0.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5ad39d53604f3c001a3fe8d3

SQuAD のバージョン 1.1 と 2.0

- バージョン 1.1 は、文章に答えがある質問を扱う [1]。
  - 質問に対応する本文中の範囲を回答する
- バージョン 2.0 では、回答不能な質問を追加する [2]。
  - 既存の質問に似た、答えられない質問を人が作成。
  - 答えられるかを判定し、答えがなければ回答を控える。
- 異なるバージョンの得点は、そのまま比較できない。

[1] Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text. https://aclanthology.org/D16-1264/

[2] Rajpurkar et al. (2018). ACL, pp. 784–789. Know What You Don't Know: Unanswerable Questions for SQuAD. https://aclanthology.org/P18-2124/

2. 質問・回答の作成方法と収録規模

MCTest は物語を読んで 4 択の質問に答える

- MCTest （ 2013 ）は、短い物語を読み、 4 つの選択肢から質問の答えを選ぶ読解データセットである。
- これに対し SQuAD は、百科事典 Wikipedia の段落を読み、答えの表現を本文中から選ぶ。
- 選択肢を選ぶ形式から、段落内の任意の連続した回答範囲を特定する形式へ変わる。

[1] Richardson et al. (2013). EMNLP. MCTest: A Challenge Dataset for the Open-Domain Machine Comprehension of Text. https://aclanthology.org/D13-1020/

[2] Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text. https://aclanthology.org/D16-1264/

ニュースから穴埋め問題を作る CNN ／ Daily Mail

- CNN ／ Daily Mail （2015）は、ニュースの要約文で固有表現を伏せ、元記事を根拠に埋める問題を自動作成した。
- これに対し SQuAD では、人が段落を読んで質問を書き、固有表現に限らない回答範囲を選ぶ。
- 人手による質問の多様性と、ニューラルモデルを学習・評価できる規模の両立を目指した。

[1] Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text.
https://aclanthology.org/D16-1264/

人手による多様な読解問題を大規模に収集する

- 先行する読解データは、人手作成では小規模、自動作成では質問や正解の形式が限定されていた。
- SQuAD は、 Wikipedia の段落に人が質問と回答範囲を付け、自然な読解問題を大量に用意することを目的とした。
- 2016 年の原著は、 500 以上の記事から 10 万問以上を作成したと報告した。

[1] Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text.
https://aclanthology.org/D16-1264/

記事を選び段落単位で質問の素材にする

- 英語 Wikipedia の記事を、リンク関係に基づく重要度 PageRank で順位付けし、上位 10,000 記事から 536 記事を無作為に選んだ。
- 原著は、各記事から段落を取り出し、 500 文字未満を除いたと説明する。学習・開発・テストは記事単位で分けた。
- 公開バージョン 1.1 の学習用・開発用を実測すると、 20,963 段落のうち 2,874 段落は 500 文字未満である。原著の収集説明と公開版の実測は範囲が異なる。

[1] Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text. https://aclanthology.org/D16-1264/

[2] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

段落を読んで質問と最小限の回答範囲を作る

- オンラインで作業を依頼する Amazon Mechanical Turk を使い、作業者へ段落を提示した。
- 作業者は、その段落だけから答えられる質問を最大 5 問作った。段落の文をコピーせず、自分の言葉で質問を書くよう指示された。
- 答えとなる最小限の連続した範囲を段落内で選んだ。この範囲が、回答位置を予測するモデルの学習用の正解となる。

[1] Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text.
https://aclanthology.org/D16-1264/

追加の正解回答で表現の違いを許容する

- 開発用・テスト用では、作成済みの質問へ別の作業者が追加の回答範囲を指定した。
- 同じ質問にも、長さや表現が異なる妥当な回答がありうるため、１問に複数の正解を持たせる。
- 評価では各正解との一致を計算し、その中で最も高い得点を質問の得点とする。正解注釈数は質問数と一致しない。

[1] Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text. https://aclanthology.org/D16-1264/

バージョン 2.0 を作った理由と作成方法

- 初版では、どの質問にも段落内に答えがあった [1]。
- 作業者が各段落に対し、回答不能な質問を最大 5 問作成した。
  - 段落の話題に関連し、回答可能な質問に見えるようにする。
  - 段落内に、答えに見える候補がある質問にする。
- 記事・段落ごとの作業を分配し、人手で 50,000 問以上を追加。
- 回答範囲の抽出と、回答保留の判断を評価する。

[1] Rajpurkar et al. (2018). ACL, pp. 784–789. Know What You Don’t Know: Unanswerable Questions for SQuAD. §1, §3
https://aclanthology.org/P18-2124/

SQuAD 各版の質問数・回答不能数・記事数

版・分割 [1]	質問数	回答不能	Wikipedia 記事数
1.1 ・学習用	87,599	0	442
1.1 ・開発用	10,570	0	48
2.0 ・学習用	130,319	43,498	442
2.0 ・開発用	11,873	5,945	35

- 記事数は、質問の元となった Wikipedia 記事の数。
- バージョン 2.0 は同じ記事に回答不能な質問を追加。

[1] 公式 train / dev JSON の全件集計 https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

質問に大量の空白が含まれる実例

- 前後に大量の空白が含まれる質問を 1 件確認 [1]。
  - 元文字列 25,651 文字 → 前後空白を除去 59 文字。
- What radiates two lobes perpendicular to the antennas axis?
  - アンテナの軸に垂直な 2 つのローブを放射するものは何か。
- 主要統計は前後空白だけを除去し、本文の文字は保持。
- 長さの比較では、空白を含めるかで結果が大きく変わる。

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 572fdefb947a6a140053cd8d

長い入力段落の例 Sahara

- 段落文字数 3706 ／段落単語数 653 [1] 。
- 質問 What is the largest hottest continuously large area worldwide?
- 正解は the Great Desert
- 対象の版と分割は 1.1/train 、 2.0/train 。

[1] 記事名 Sahara https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5728c4163acd2414000dfddf

長い段落の原文抜粋 Sahara

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

A value of 4,300 h or 98% of the time would be recorded in Upper Egypt (Aswan, Luxor) and in the Nubian Desert (Wadi Halfa). The annual average direct solar irradiation is around 2,800 kWh/(m2 year) in the Great Desert. The Sahara has a huge potential for solar energy production. The constantly high position of the sun, the extremely low relative humidity, the lack of vegetation and rainfall make the Great Desert the hottest continuously large area worldwide and certainly the hottest place on Earth during summertime in some spots.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5728c4163acd2414000dfddf

入力段落（ context ）の長さ

context の長さ [1]	平均	中央値	95% 点	最大
文字数	739.6	679.0	1312.0	4063
単語数	117.2	108.0	210.0	653

- バージョン 1.1 train ＋ dev 、 20,963 段落を各 1 回集計。
- 同じ段落への複数質問による重複カウントはしない。
- 最大 4,063 文字／ 653 単語。別々の段落。

[1] 文字数は前後空白を除去／単語数は空白分割。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

長い質問の例 Age of Enlightenment

- 質問文字数 270 ／質問単語数 40 [1]
- 質問 Which century is considered by some as a "drab" period, however saw significant advancements in the practice of medicine, mathematics, and physics, the development of biological taxonomy, a new understanding of magnetism, and the maturation of chemistry as a discipline?
- 正解は the 18th century
- 対象の版と分割は 1.1/train 、 2.0/train 。

[1] 記事名 Age_of_Enlightenment https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5710dcb5b654c5140001fa10

長い質問の根拠となる原文抜粋

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> Philosophes introduced the public to many scientific theories, most notably through the Encyclopédie and the popularization of Newtonianism by Voltaire and Émilie du Châtelet. Some historians have marked the 18th century as a drab period in the history of science; however, the century saw significant advancements in the practice of medicine, mathematics, and physics; the development of biological taxonomy; a new understanding of magnetism and electricity; and the maturation of chemistry as a discipline, which established the foundations of modern chemistry.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5710dcb5b654c5140001fa10

質問と回答の長さ

長さ [1]	平均	中央値	95% 点	最大
質問の文字数	59.3	56.0	98.0	270
質問の単語数	10.1	10.0	17.0	40
回答の文字数	20.1	14.0	63.0	239
回答の単語数	3.1	2.0	10.0	43

- 公開データ 98,169 問の先頭正解を 1 問 1 件で集計。
- 最大の回答は 43 単語・ 239 文字。

[1] バージョン 1.1 の train と dev を集計。文字数は前後空白を除去し、単語数は空白で分割。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

3. 読解の評価指標とモデル性能

完全一致と単語の重なりを別々に評価する

- SQuAD の評価には、回答文字列が一致するかを測る Exact Match （ EM ）と、単語の重なりを測る F1 がある。
- EM は、予測が正解に完全一致すれば 1 、それ以外は 0 である。 F1 は、一致した単語の割合を予測側と正解側で計算して組み合わせる。
- どちらも、各質問で得た 0 〜 1 の得点を全質問について平均し、百分率で報告する。

[1] https://github.com/huggingface/evaluate/blob/main/metrics/squad/compute_score.py

Denver だけを答えると部分一致になる

予測（正解は Denver Broncos ）	EM	F1
Denver Broncos	1	1
Denver	0	2/3
Carolina Panthers	0	0

Denver だけなら、予測 1 語中 1 語が一致し、正解 2 語中 1 語を含む。適合率 1 と再現率 1/2 の調和平均は 2/3 となる。

[1] https://github.com/huggingface/evaluate/blob/main/metrics/squad/compute_score.py

表記の違いを正規化して複数正解と照合する

- 採点では、小文字化、句読点の除去、英語の冠詞 a ・ an ・ the の除去、空白の正規化を行う。
- F1 の適合率 P は一致語数 ÷ 予測の語数、再現率 R は一致語数 ÷ 正解の語数である。両者の調和平均 2PR÷ （ P ＋ R ）を使う。
- 複数正解がある質問は最良の得点を採用する。バージョン 2.0 では、回答不能な質問に回答を控えた場合を正解として採点する。

[1] https://github.com/huggingface/evaluate/blob/main/metrics/squad/compute_score.py
[2] https://github.com/huggingface/evaluate/blob/main/metrics/squad_v2/squad_v2.py

2016 年の原著のモデルは F1 が 51.0% だった

原著のモデル・人の回答	EM （%）	F1 （%）
単語一致を使う Sliding Window	12.5	19.7
ロジスティック回帰	40.4	51.0
人の回答	77.0	86.8

SQuAD バージョン 1.0 のテスト用で評価した [1]。人の得点は、追加の正解回答を予測として採点した。

[1] Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text. Table 5, §6.2.
https://aclanthology.org/D16-1264/

バージョン 1.1 のベンチマーク結果

モデル [1]	提出日	EM	F1
BiDAF	2016-11-28	68.0	77.3
BERT	2018-10-05	85.1	91.8
XLNet	2019-05-21	89.9	95.1

- SQuAD 運営者の非公開テストで採点。
- 開発用とは別のデータ。各行は単一モデルの提出結果。

[1] 掲載された提出結果（EM ・ F1 は %）。
https://rajpurkar.github.io/SQuAD-explorer/

過去の抽出型モデルの評価結果

モデル [1]	EM （%）	F1 （%）
BERT-Large （2018）	79.0	81.8
RoBERTa-Large （2019）	86.5	89.4
DeBERTa-V3-Large （2021）	89.0	91.5

- SQuAD 2.0 の学習用で微調整し、開発用で評価した公表値。答えの開始・終了位置を予測する抽出型モデルを比較する。

[1] Microsoft の公開結果で、 SQuAD 2.0 開発用の EM ・ F1 を掲載。
https://github.com/microsoft/DeBERTa

Llama 3.1 でも SQuAD 2 を評価している

事前学習モデル [1]	EM （%）
Llama 3.1 8B	77.0
Llama 3.1 70B	81.8
Llama 3.1 405B	89.3

- 2024-07-23 公開、答え付きの例を 1 件示す 1-shot で生成評価。
- 同じ段落に付いた先行する全質問と正解を入力に含めるため、 SQuAD 運営者の非公開テストとは条件が異なる [2] 。

[1] https://github.com/meta-llama/llama-models/blob/main/models/llama3_1/MODEL_CARD.md
[2] https://github.com/meta-llama/llama-models/blob/main/models/llama3_1/eval_details.md

回答範囲を選ぶ方式と文章を生成する方式がある

- 抽出型は、段落中の開始・終了位置を予測する。読解モデル BiDAF や言語モデル BERT を使い、原文中の回答範囲を選ぶ。
- 生成型は、段落と質問を受け取り、答えの文字列を生成する。大規模言語モデル Llama も、この方式で評価される。
- 抽出型は原文中の位置を、生成型は出力する語句を予測する。どちらも、得られた回答文字列を EM ・ F1 で採点する。

[1] Devlin et al. (2019). NAACL-HLT, pp. 4171–4186. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. https://aclanthology.org/N19-1423/

[2] https://github.com/meta-llama/llama-models/blob/main/models/llama3_1/eval_details.md

SQuAD による微調整と例示付きの生成評価

- 微調整では、 SQuAD の学習用の質問と正解を使い、モデルのパラメータを更新する。
- 1-shot では、答え付きの例を 1 件入力に提示してから別の質問へ答えさせる。この提示だけではモデルのパラメータを更新しない。
- 同じ EM ・ F1 でも、学習・提示の条件や評価データが異なる結果は直接比較できない。

[1] https://github.com/meta-llama/llama-models/blob/main/models/llama3_1/eval_details.md

4. SQuAD の利用動向と後続データ

HotpotQA は複数記事の情報を組み合わせる

- HotpotQA （ 2018 ）は、複数の Wikipedia 記事にまたがる推論と、回答の根拠となる文の特定を扱う。
- SQuAD が基本的に 1 段落を根拠とするのに対し、HotpotQA では文書をまたいで情報を組み合わせる。
- 回答文字列の正しさに加え、根拠文を選べるかも評価対象となる。

[1] https://github.com/hotpotqa/hotpot

Natural Questions は実際の検索質問を使う

- Natural Questions （2019）は、 Google 検索に入力された質問と、その回答を含む Wikipedia ページを使う。
- 回答を含む段落などの長い回答と、必要に応じて語句や固有名詞などの短い回答を指定する。
- SQuAD のように段落を見て質問を作るのではなく、実際の情報要求とページ全体を対応付ける。

[1] https://github.com/google-research-datasets/natural-questions

SQuAD は生成型モデルの読解評価にも使われる

- SQuAD は、回答範囲を選ぶモデルから、答えを生成する大規模言語モデルの評価へも用途が広がった。
- 2024 年の Llama 3.1 の評価にも SQuAD 2 が含まれる。回答形式や提示例の条件は、抽出型モデルの微調整評価と異なる。
- 2026-10-15 の確認時点でも、モデル評価ライブラリ Hugging Face Evaluate は SQuAD 2.0 の採点実装を公開している。

[1] https://github.com/meta-llama/llama-models/blob/main/models/llama3_1/MODEL_CARD.md
[2] https://github.com/huggingface/evaluate/blob/main/metrics/squad_v2/squad_v2.py

LongBench v2 はより長い文脈から回答を選ぶ

- LongBench v2 （2024）は、8 千〜200 万語の長い文脈を与え、選択肢から回答を選ぶ評価データである。
- SQuAD の短い段落からの回答範囲抽出と比べ、文脈長と回答形式が異なる。
- SQuAD の得点は段落単位の読解を測るが、それだけで長い文書全体を扱う能力を示すわけではない。

[1] https://github.com/THUDM/LongBench

5. 質問応答データの入手方法と利用条件

バージョンごとの JSON と評価実装を入手する

- 公式サイトは、構造化データ形式 JSON で学習用 train と開発用 dev を配布する。バージョン 1.1 と 2.0 のファイルを選んで取得する。
- データ配布サービス Hugging Face Datasets では、 1.1 は rajpurkar/squad 、 2.0 は rajpurkar/squad_v2 という名前で取得できる。
- データの利用条件は CC BY-SA 4.0 である。質問への予測は、対応するバージョンの公式採点実装で評価する。

[1] https://rajpurkar.github.io/SQuAD-explorer/
[2] https://creativecommons.org/licenses/by-sa/4.0/

SQuAD の目的・版の違いと評価方法

- SQuAD は、英語の読解型質問応答データセット [1]。
  - Wikipedia の段落から、質問の答えとなる範囲を選ぶ。
- 人手作成の質問を大規模に評価するため、 2016 年に発表。
- バージョン 1.1 では、回答可能な質問の答えを抽出。
- バージョン 2.0 は回答不能な質問と回答保留も扱う [2]。
- EM ・ F1 で評価し、大規模言語モデルの読解評価にも用いられる。

Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text.
https://aclanthology.org/D16-1264/

Rajpurkar et al. (2018). ACL, pp. 784–789. Know What You Don’t Know: Unanswerable Questions for SQuAD.
https://aclanthology.org/P18-2124/

Appendix

1.開発者の研究と発表先
2.段落・質問・回答の追加例
3.段落・質問・回答の統計と極値
4.SQuAD 2.0 のモデル評価結果
5.収録された Wikipedia 記事の全一覧
6.公式 JSON の取得コードと関連文献

SQuAD 各版の著者と発表先

- 初版は Pranav Rajpurkar らが EMNLP 2016 で発表した [1]。
- バージョン 2 は、 2018 年の ACL で発表された [2]。
- 両論文の第一著者は Pranav Rajpurkar 、最終著者は Percy Liang である。
- 2026 年に初版が ACL Test of Time Award を受賞した [1]。

[1] Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text. https://aclanthology.org/D16-1264/

[2] Rajpurkar et al. (2018). ACL, pp. 784–789. Know What You Don’t Know: Unanswerable Questions for SQuAD. https://aclanthology.org/P18-2124/

筆頭・最終著者の研究分野と関連実績

- 第一著者の Pranav Rajpurkar は、読解型 QA と医療 AI を研究している [1,2]。
- SQuAD と、胸部 X 線のデータセット CheXpert に貢献した（2019 年） [5]。
- 最終著者の Percy Liang は、自然言語処理・機械学習を研究している。
- 言語モデルを幅広く評価する HELM にも取り組んだ [3]。

[1] Rajpurkar et al. (2016). EMNLP, pp. 2383–2392. SQuAD: 100,000+ Questions for Machine Comprehension of Text. https://aclanthology.org/D16-1264/

[2] Rajpurkar et al. (2018). ACL, pp. 784–789. Know What You Don't Know: Unanswerable Questions for SQuAD. https://aclanthology.org/P18-2124/

[3] https://github.com/stanford-crfm/helm

[5] https://github.com/stanfordmlgroup/chexpert-labeler

補足実例 1 Apollo program

Wikipedia 記事の段落（抜粋）

> The first manned flight of Apollo was in **1968**.

質問 What year did the first manned Apollo flight occur?

質問の日本語訳 アポロ計画の最初の有人飛行が行われたのは何年か？

正解は 1968

[1] SQuAD 記事名 Apollo_program https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5725b41838643c19005acb81

補足実例 2 Amazon rainforest

Wikipedia 記事の段落（抜粋）

> This region includes territory belonging to **nine nations**. The majority of the forest is contained within Brazil, with 60% of the rainforest, followed by Peru with 13%, Colombia with 10%, and with minor amounts in Venezuela, Ecuador, Bolivia, Guyana, Suriname and French Guiana.

質問 How many nations are within the Amazon Basin?

質問の日本語訳 アマゾン盆地には何か国が含まれるか？

正解は nine nations

[1] SQuAD 記事名 Amazon_rainforest https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5729e2316aef0514001550c6

補足実例 3 Prime number

Wikipedia 記事の段落（抜粋）

> A prime number (or a prime) is a natural number greater than 1 that has no positive divisors other than 1 and **itself**. A natural number greater than 1 that is not a prime number is called a composite number.

質問 What is the only divisor besides 1 that a prime number can have?

質問の日本語訳 素数が 1 以外に持つことのできる約数は何か？

正解は itself

[1] SQuAD 記事名 Prime_number https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 57296d571d04691400779413

補足実例 4 Black Death

Wikipedia 記事の段落（抜粋）

> Spreading throughout the Mediterranean and Europe, the Black Death is estimated to have killed **30–60% of Europe's total population**. In total, the plague reduced the world population from an estimated 450 million down to 350–375 million in the 14th century.

質問 How much of the European population did the black death kill?

質問の日本語訳 黒死病でヨーロッパ人口のどのくらいが死亡したか？

正解は 30–60% of Europe's total population

[1] SQuAD 記事名 Black_Death https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5726468470898414009 4c125

補足実例 5 Warsaw

Wikipedia 記事の段落（抜粋）

> One of the most famous people born in Warsaw was Maria Skłodowska-Curie, who achieved international recognition for her research on radioactivity and was the first female recipient of the **Nobel Prize**. Famous musicians include Władysław Szpilman and Frédéric Chopin.

質問 What was Maria Curie the first female recipient of?

質問の日本語訳 マリ・キュリーが女性として初めて受賞した賞は何か？

正解は Nobel Prize

[1] SQuAD 記事名 Warsaw https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5733a5f54776f41900660f45

補足実例 6 Genghis Khan

Wikipedia 記事の段落（抜粋）

> After founding **the Mongol Empire** and being proclaimed "Genghis Khan", he started the Mongol invasions that resulted in the conquest of most of Eurasia. These included raids or invasions of the Qara Khitai, Caucasus, Khwarezmid Empire, Western Xia and Jin dynasties.

質問 What do we call the empire that Genghis Khan founded?

質問の日本語訳 チンギス・ハンが建てた帝国を何と呼ぶか？

正解は the Mongol Empire

[1] SQuAD 記事名 Genghis_Khan https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 57269e8a5951b619008f77f5

補足実例 7 Chloroplast

Wikipedia 記事の段落（抜粋）

> Chloroplasts' main role is **to conduct photosynthesis**, where the photosynthetic pigment chlorophyll captures the energy from sunlight and converts it and stores it in the energy-storage molecules ATP and NADPH while freeing oxygen from water.

質問 What is the primary purpose of chloroplasts?

質問の日本語訳 葉緑体の主な役割は何か？

正解は to conduct photosynthesis

[1] SQuAD 記事名 Chloroplast https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 572953013f37b3190047824d

補足実例 8 University of Chicago

Wikipedia 記事の段落（抜粋）

The University of Chicago (UChicago, Chicago, or U of C) is **a private research university** in Chicago. The university, established in 1890, consists of The College, various graduate programs, interdisciplinary committees organized into four academic research divisions and seven professional schools.

質問 What kind of university is the University of Chicago?

質問の日本語訳 シカゴ大学はどのような種類の大学か？

正解は a private research university

[1] SQuAD 記事名 University_of_Chicago https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v1.1.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 57283c464b864d19001647c8

補足実例 9 Steam engine

Wikipedia 記事の段落（抜粋）

> Steam engines are external combustion engines, where the working fluid is separate from the combustion products.

質問 What types of engines are solar engines?

質問の日本語訳 太陽熱機関はどのような種類の機関か？

正解は 回答不能（文章に根拠がない）

原文は蒸気機関を説明する。太陽熱機関の種類は書かれていない。

[1] SQuAD 記事名 Steam_engine https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v2.0.json （CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5ad3bd8f604f3c001a3fef31

補足実例 10 Oxygen

Wikipedia 記事の段落（抜粋）

> Diatomic oxygen gas constitutes 20.8% of the Earth's atmosphere.

質問 What constitutes 28.0% of the Earth's atmosphere?

質問の日本語訳 地球の大気の 28.0% を占めるものは何か？

正解は 回答不能（文章に根拠がない）

原文の割合は 20.8% 。 28.0% に対応する記述はない。

[1] SQuAD 記事名 Oxygen https://rajpurkar.github.io/SQuAD-explorer/dataset/dev-v2.0.json （ CC BY-SA 4.0 ／抜粋・強調・質問訳を追加） ID 5ad21646d7d075001a4283c7

記述統計 バージョン 1.1 ・学習用

質問 87,599 件／回答あり 87,599 件／回答不能 0 件

指標 [1]	平均	標準偏差	最小	25% 点	中央値	75% 点	95% 点	最大
質問文字	59.2	21.2	1	44.0	56.0	71.0	98.0	270
質問単語	10.1	3.6	1	8.0	10.0	12.0	17.0	40
回答文字	20.1	21.6	1	7.0	14.0	23.0	63.0	239
回答単語	3.2	3.4	1	1.0	2.0	3.0	10.0	43

- 文字数は前後の空白だけを除いた文字列の長さ。
- 単語数は空白区切り。回答は先頭の正解を 1 問 1 件、回答不能は除外。

[1] 公式 JSON を全件集計　https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

記述統計 バージョン 1.1 ・開発用

質問 10,570 件／回答あり 10,570 件／回答不能 0 件

指標 [1]	平均	標準偏差	最小	25% 点	中央値	75% 点	95% 点	最大
質問文字	60.0	21.2	12	45.0	57.0	72.0	99.0	197
質問単語	10.2	3.6	3	8.0	10.0	12.0	17.0	33
回答文字	19.4	19.3	1	8.0	14.0	23.0	57.0	160
回答単語	3.0	3.0	1	1.0	2.0	3.0	9.0	29

- 文字数は前後の空白だけを除いた文字列の長さ。
- 単語数は空白区切り。回答は先頭の正解を 1 問 1 件、回答不能は除外。

[1] 公式 JSON を全件集計　https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

記述統計 バージョン 2.0 ・学習用

質問 130,319 件／回答あり 86,821 件／回答不能 43,498 件

指標 [1]	平均	標準偏差	最小	25% 点	中央値	75% 点	95% 点	最大
質問文字	58.3	20.4	1	44.0	55.0	69.0	96.0	270
質問単語	9.9	3.4	1	7.0	9.0	12.0	16.0	40
回答文字	20.1	21.6	1	7.0	14.0	23.0	63.0	239
回答単語	3.2	3.4	1	1.0	2.0	4.0	10.0	43

- 文字数は前後の空白だけを除いた文字列の長さ。
- 単語数は空白区切り。回答は先頭の正解を 1 問 1 件、回答不能は除外。

[1] 公式 JSON を全件集計　https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

記述統計 バージョン 2.0 ・開発用

質問 11,873 件／回答あり 5,928 件／回答不能 5,945 件

指標 [1]	平均	標準偏差	最小	25% 点	中央値	75% 点	95% 点	最大
質問文字	59.4	20.8	11	45.0	57.0	71.0	98.0	197
質問単語	10.0	3.5	3	8.0	10.0	12.0	16.0	31
回答文字	20.9	21.4	1	8.0	14.0	24.0	64.0	160
回答単語	3.2	3.3	1	1.0	2.0	4.0	10.0	29

- 文字数は前後の空白だけを除いた文字列の長さ。
- 単語数は空白区切り。回答は先頭の正解を 1 問 1 件、回答不能は除外。

[1] 公式 JSON を全件集計　https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

回答長の集計単位 バージョン 1.1

対象・指標 [1]	件数	平均	中央値	95% 点	最大
1 問 1 件・文字	98,169	20.1	14.0	63.0	239
1 問 1 件・単語	98,169	3.1	2.0	10.0	43
全正解注釈・文字	122,325	19.7	14.0	61.0	239
全正解注釈・単語	122,325	3.1	2.0	9.0	43

- 学習用＋開発用を集計。回答不能の質問は除外。
- 全正解注釈では、同じ質問の複数正解・重複注釈も数える。

https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

回答長の集計単位 バージョン 2.0

対象・指標 [1]	件数	平均	中央値	95% 点	最大
1 問 1 件・文字	92,749	20.2	14.0	63.0	239
1 問 1 件・単語	92,749	3.2	2.0	10.0	43
全正解注釈・文字	107,123	20.1	14.0	63.0	239
全正解注釈・単語	107,123	3.1	2.0	10.0	43

- 学習用＋開発用を集計。回答不能の質問は除外。
- 全正解注釈では、同じ質問の複数正解・重複注釈も数える。

https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

入力段落の記述統計 バージョン 1.1 ・ train

context [1]	件数	平均	SD	中央値	95% 点	最大
文字数	18896	735.8	310.0	678.0	1311.0	3706
単語数	18896	116.6	49.7	107.0	210.0	653

- 各段落を 1 回ずつ集計（質問数による重複は含めない）。
- 文字数は前後空白除去／単語数は空白分割。

[1] SD は母標準偏差。 95% 点は 95 パーセンタイル。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

入力段落の記述統計 バージョン 1.1 ・ dev

context [1]	件数	平均	SD	中央値	95% 点	最大
文字数	2067	774.3	342.9	700.0	1338.0	4063
単語数	2067	122.8	54.8	111.0	213.0	629

- 各段落を 1 回ずつ集計（質問数による重複は含めない）。
- 文字数は前後空白除去／単語数は空白分割。

[1] SD は母標準偏差。 95% 点は 95 パーセンタイル。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

入力段落の記述統計 バージョン 2.0 ・ train

context [1]	件数	平均	SD	中央値	95% 点	最大
文字数	19035	735.5	309.8	677.0	1310.3	3706
単語数	19035	116.6	49.7	107.0	209.0	653

- 各段落を 1 回ずつ集計（質問数による重複は含めない）。
- 文字数は前後空白除去／単語数は空白分割。

[1] SD は母標準偏差。 95% 点は 95 パーセンタイル。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

入力段落の記述統計 バージョン 2.0 ・ dev

context [1]	件数	平均	SD	中央値	95% 点	最大
文字数	1204	802.6	359.6	711.5	1425.9	4063
単語数	1204	126.6	57.4	113.0	223.8	629

- 各段落を 1 回ずつ集計（質問数による重複は含めない）。
- 文字数は前後空白除去／単語数は空白分割。

[1] SD は母標準偏差。 95% 点は 95 パーセンタイル。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

長い回答の例 2008 Sichuan earthquake

- 回答文字数 239 ／回答単語数 43 [1] 。
- 質問 What was concluded about the construction?
- 正解は that the sudden shift of a huge quantity of water into the region could have relaxed the tension between the two sides of the fault, allowing them to move apart, and could have increased the direct pressure on it, causing a violent rupture
- 対象の版と分割は 1.1/train 、 2.0/train 。

[1] 記事名 2008_Sichuan_earthquake https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 56cec3e8aab44d1400b88a02

長い回答の原文抜粋 2008 Sichuan earthquake

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> An article in Science suggested that the construction and filling of the Zipingpu Dam may have triggered the earthquake. The chief engineer of the Sichuan Geology and Mineral Bureau said that the sudden shift of a huge quantity of water into the region could have relaxed the tension between the two sides of the fault, allowing them to move apart, and could have increased the direct pressure on it, causing a violent rupture. The effect was "25 times more" than a year's worth of natural stress from tectonic movement.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 56cec3e8aab44d1400b88a02

開発用で長い質問の例 Construction

- 質問文字数 197 [1]
- 質問 What kind of contract is given when the contractor is given a performance specification and must undertake the project from design to construction, while adhering to the performance specifications?
- 正解は "design build" contract
- 対象の版と分割は 1.1/dev 、 2.0/dev 。

[1] 記事名 Construction https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 57274e0d708984140094dbe8

長い質問の原文抜粋 Construction

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> Presently, a firm that is nominally an "architecture" or "construction management" firm may have experts from all related fields as employees, or to have an associated company that provides each necessary skill. Thus, each such firm may offer itself as "one-stop shopping" for a construction project, from beginning to end. This is designated as a "design build" contract where the contractor is given a performance specification and must undertake the project from design to construction, while adhering to the performance specifications.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 57274e0d708984140094dbe8

開発用で単語数が多い質問の例

- 質問単語数 33 [1]
- 質問 What was the name of the event at the The Embarcadero that was held prior to Super Bowl 50 to help show off some of the things that San Francisco has to offer?
- 正解は Super Bowl City
- 対象の版と分割は 1.1/dev 。

[1] 記事名 Super_Bowl_50 https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 56bf53e73aeaaa14008c95ce

質問の原文抜粋 Super Bowl 50

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> The annual NFL Experience was held at the Moscone Center in San Francisco. In addition, "Super Bowl City" opened on January 30 at Justin Herman Plaza on The Embarcadero, featuring games and activities that will highlight the Bay Area's technology, culinary creations, and cultural diversity. More than 1 million people are expected to attend the festivities in San Francisco during Super Bowl Week. San Francisco mayor Ed Lee said of the highly visible homeless presence in this area "they are going to have to leave".

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 56bf53e73aeaaa14008c95ce

文字数が最も多い入力段落の例

- 段落文字数 4063 ／段落単語数 629 [1] 。
- 質問 The freedom to provide services under TFEU article 56 applies to who?
- 正解は to people who give services "for remuneration"
- 対象の版と分割は 1.1/dev 、 2.0/dev 。

[1] 記事名 European_Union_law https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5726c3da708984140094d0d9

最長段落からの原文抜粋

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> The "freedom to provide services" under TFEU article 56 applies to people who give services "for remuneration", especially commercial or professional activity. For example, in Van Binsbergen v Bestuur van de Bedrijfvereniging voor de Metaalnijverheid a Dutch lawyer moved to Belgium while advising a client in a social security case, and was told he could not continue because Dutch law said only people established in the Netherlands could give legal advice.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5726c3da708984140094d0d9

開発用で長い回答の例 French and Indian War

- 回答文字数 160 [1]。
- 質問 What was normal British defense?
- 正解は mustered local militia companies, generally ill trained and available only for short periods, to deal with native threats, but did not have any standing forces.
- 対象の版と分割は 1.1/dev 、 2.0/dev 。

[1] 記事名 French_and_Indian_War https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5733dab4d058e614000b640b

長い回答の原文抜粋 French and Indian War

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> New France was defended by about 3,000 troupes de la marine, companies of colonial regulars (some of whom had significant woodland combat experience). The colonial government recruited militia support when needed. Most British colonies mustered local militia companies, generally ill trained and available only for short periods, to deal with native threats, but did not have any standing forces.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5733dab4d058e614000b640b

開発用で単語数が多い回答の例

- 回答単語数 29 [1]。
- 質問 What does the internal cavity contain?
- 正解は a mouth that can usually be closed by muscles; a pharynx ("throat"); a wider area in the center that acts as a stomach; and a system of internal canals.
- 対象の版と分割は 1.1/dev 、 2.0/dev 。

[1] 記事名 Ctenophora https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 57264b1ddd62a815002e80a3

回答の原文抜粋 Ctenophora

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> The internal cavity forms: a mouth that can usually be closed by muscles; a pharynx ("throat"); a wider area in the center that acts as a stomach; and a system of internal canals. These branch through the mesoglea to the most active parts of the animal: the mouth and pharynx; the roots of the tentacles, if present; all along the underside of each comb row; and four branches round the sensory complex at the far end from the mouth – two of these four branches terminate in anal pores.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 57264b1ddd62a815002e80a3

バージョン 2.0 開発用の長い質問

- 質問単語数 31 [1]
- 質問 In which case did the Court of Justice state that refusal to admit a lawyer to the Belgian bar because he did not have Belgian heritage wasn't able to be justified?
- 正解は Reyners v Belgium
- 対象の版と分割は 2.0/dev 。

[1] 記事名 European_Union_law https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5726c002708984140094d075

質問の原文抜粋 European Union law

Wikipedia 記事の段落から再抜粋（段落全体の長さとは異なる）。

> The Court of Justice has held that both a member state government and a private party can hinder freedom of establishment, so article 49 has both "vertical" and "horizontal" direct effect. In Reyners v Belgium the Court of Justice held that a refusal to admit a lawyer to the Belgian bar because he lacked Belgian nationality was unjustified. TFEU article 49 says states are exempt from infringing others' freedom of establishment when they exercise "official authority", but this did an advocate's work (as opposed to a court's) was not official.

[1] https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset ID 5726c002708984140094d075

バージョン 2.0 のベンチマーク結果

モデル [1]	提出日	EM	F1
BERT	2018-11-08	80.0	83.1
RoBERTa	2019-07-20	86.8	89.8
XLNet	2019-11-15	87.9	90.7

- SQuAD 運営者の非公開テストで採点。
- 開発用とは別のデータ。各行は単一モデルの提出結果。

[1] 掲載された提出結果（EM ・ F1 は %）。
https://rajpurkar.github.io/SQuAD-explorer/

開発用 Wikipedia 記事一覧 1/2

バージョン 1.1 では、 48 記事／ 2.0 このうち 35 記事。

1973_oil_crisis
Amazon_rainforest
American_Broadcasting_Company *
Apollo_program *
Black_Death
Chloroplast *
Civil_disobedience
Computational_complexity_theory
Construction
Ctenophora
Doctor_Who *
Economic_inequality
European_Union_law
Force
French_and_Indian_War
Fresno,_California
Genghis_Khan *
Geology
Harvard_University
Huguenot
Immune_system
Imperialism
Intergovernmental_Panel_on_Climate_Change
Islamism

* はバージョン 1.1 のみに含まれる開発用記事。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

開発用 Wikipedia 記事一覧 2/2

バージョン 1.1 では、 48 記事／ 2.0 このうち 35 記事。

Jacksonville,_Florida
Kenya *
Martin_Luther *
Newcastle_upon_Tyne *
Nikola_Tesla *
Normans
Oxygen
Packet_switching
Pharmacy
Prime_number
Private_school
Rhine
Scottish_Parliament
Sky_(United_Kingdom)
Southern_California
Steam_engine
Super_Bowl_50 *
Teacher *
United_Methodist_Church *
University_of_Chicago
Victoria_(Australia)
Victoria_and_Albert_Museum *
Warsaw
Yuan_dynasty

* はバージョン 1.1 のみに含まれる開発用記事。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 1/19

バージョン 1.1 と 2.0 に共通する 442 記事。

2008_Sichuan_earthquake
2008_Summer_Olympics_torch_relay
51st_state
A_cappella
Adolescence
Adult_contemporary_music
Affirmative_action_in_the_United_States
Age_of_Enlightenment
Aircraft_carrier
Airport
Alaska
Alexander_Graham_Bell
Alfred_North_Whitehead
Alloy
Alps
Alsace
American_Idol
Animal
Ann_Arbor,_Michigan
Annelid
Antarctica
Antenna_(radio)
Anthropology
Anti-aircraft_warfare

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 2/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Antibiotics
Apollo
Appalachian_Mountains
Architecture
Arena_Football_League
Armenia
Armenians
Arnold_Schwarzenegger
Arsenal_F.C.
ASCII
Ashkenazi_Jews
Asphalt
Aspirated_consonant
Association_football
Asthma
Athanasius_of_Alexandria
Atlantic_City,_New_Jersey
Avicenna
Bacteria
Baptists
BBC_Television
Beer
BeiDou_Navigation_Satellite_System
Bermuda

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 3/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Bern
Beyoncé
Bill_%26_Melinda_Gates_Foundation
Biodiversity
Bird
Bird_migration
Black_people
Boston
Botany
Brain
Bras%C3%ADlia
Brigham_Young_University
British_Empire
British_Isles
Buckingham_Palace
Buddhism
Canadian_Armed_Forces
Canadian_football
Canon_law
Capacitor
Capital_punishment_in_the_United_States
Cardinal_(Catholicism)
Carnival
Catalan_language

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 4/19

バージョン 1.1 と 2.0 に共通する 442 記事。

CBC_Television
Central_African_Republic
Central_Intelligence_Agency
Charleston,_South_Carolina
Chicago_Cubs
Chihuahua_(state)
Child_labour
Chinese_characters
Christian
Circadian_rhythm
Classical_music
Clothing
Comcast
Comics
Communication
Communications_in_Somalia
Compact_disc
Comprehensive_school
Computer
Computer_security
Copper
Copyright_infringement
Cork_(city)
Cotton

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 5/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Crimean_War
Crucifixion_of_Jesus
Cubism
Culture
Cyprus
Czech_language
Data_compression
Database
Daylight_saving_time
Dell
Department_store
Detroit
Dialect
Diarrhea
Digestion
Digimon
Dissolution_of_the_Soviet_Union
Dog
Dominican_Order
Dutch_language
Dutch_Republic
Dwight_D._Eisenhower
East_India_Company
East_Prussia

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 6/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Economy_of_Greece
Edmund_Burke
Education
Egypt
Electric_motor
Elevator
Elizabeth_II
Emotion
Empiricism
Endangered_Species_Act
Energy
England_national_football_team
Eritrea
Estonia
Estonian_language
Eton_College
European_Central_Bank
Everton_F.C.
Exhibition_game
FA_Cup
FC_Barcelona
Federal_Aviation_Administration
Federal_Bureau_of_Investigation
Federalism

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 7/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Film_speed
Financial_crisis_of_2007%E2%80%9308
Florida
Flowering_plant
Franco-Prussian_War
Freemasonry
Friedrich_Hayek
Frédéric_Chopin
Galicia_(Spain)
Gamal_Abdel_Nasser
Gene
General_Electric
Genocide
Genome
Geography_of_the_United_States
Geological_history_of_Earth
George_VI
Georgian_architecture
Germans
Glacier
Glass
God
Gothic_architecture
Gramophone_record

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 8/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Grape
Great_Plains
Great_power
Greece
Greeks
Green
Gregorian_calendar
Group_(mathematics)
Guam
Guinea-Bissau
Gymnastics
Han_dynasty
Hanover
Hard_rock
Heian_period
Hellenistic_period
Heresy
High-definition_television
Himachal_Pradesh
Hindu_philosophy
History_of_India
History_of_science
Hokkien
House_music

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 9/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Houston
Human_Development_Index
Humanism
Hunter-gatherer
Hunting
Hyderabad
Hydrogen
IBM
Idealism
Identity_(social_science)
Imamah_(Shia_doctrine)
Immaculate_Conception
Immunology
Imperial_College_London
Incandescent_light_bulb
Indigenous_peoples_of_the_Americas
Infection
Infrared
Insect
Institute_of_technology
Intellectual_property
Internet_service_provider
IPod
Iran

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 10/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Iranian_languages
Israel
Jehovah%27s_Witnesses
Jews
John,_King_of_England
John_Kerry
John_von_Neumann
Josip_Broz_Tito
Kanye_West
Karl_Popper
Kathmandu
Kievan_Rus%27
Korean_War
Labour_Party_(UK)
Lancashire
LaserDisc
Late_Middle_Ages
Law_of_the_United_States
Letter_case
Liberal_Party_of_Australia
Liberia
Light-emitting_diode
Lighting
List_of_numbered_streets_in_Manhattan

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 11/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Literature
London
Macintosh
Madonna_(entertainer)
Madrasa
Mali
Mammal
Mandolin
Marshall_Islands
Marvel_Comics
Mary_(mother_of_Jesus)
Materialism
Matter
Melbourne
Memory
Mesozoic
Mexico_City
Miami
Middle_Ages
Military_history_of_the_United_States
Ministry_of_Defence_(United_Kingdom)
Modern_history
Molotov%E2%80%93Ribbentrop_Pact
Montana

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 12/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Montevideo
Mosaic
MP3
Muammar_Gaddafi
Multiracial_American
Muslim_world
Myanmar
Myocardial_infarction
Namibia
Nanjing
Napoleon
National_Archives_and_Records_Administration
Near_East
Neoclassical_architecture
Neolithic
Neptune
New_Delhi
New_Haven,_Connecticut
New_York_City
Nigeria
Nintendo_Entertainment_System
Nonprofit_organization
Norfolk_Island
North_Carolina

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 13/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Northwestern_University
Nutrition
Oklahoma
Oklahoma_City
Old_English
On_the_Origin_of_Species
Order_of_the_British_Empire
Orthodox_Judaism
Ottoman_Empire
Pacific_War
Pain
Palermo
Paper
Paris
Party_leaders_of_the_United_States_House_of_Representatives
Pesticide
Pharmaceutical_industry
Philadelphia
Philosophy_of_space_and_time
Phonology
Pitch_(music)
Planck_constant
PlayStation_3

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 14/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Plymouth
Police
Political_corruption
Political_party
Political_philosophy
Pope_John_XXIII
Pope_Paul_VI
Portugal
Post-punk
Poultry
Predation
Premier_League
Presbyterianism
Prime_minister
Printed_circuit_board
Professional_wrestling
Protestantism
Pub
Punjab,_Pakistan
Qing_dynasty
Queen_(band)
Queen_Victoria
Quran
Race_(human_categorization)

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 15/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Race_and_ethnicity_in_the_United_States_Census
Railway_electrification_system
Rajasthan
Raleigh,_North_Carolina
Red
Religion_in_ancient_Rome
Renewable_energy_commercialization
Republic_of_the_Congo
Richard_Feynman
Richmond,_Virginia
Roman_Republic
Royal_assent
Royal_Dutch_Shell
Royal_Institute_of_British_Architects
Rule_of_law
Russian_language
Russian_Soviet_Federative_Socialist_Republic
Sahara
Saint_Barth%C3%A9lemy
Saint_Helena
Samoa
Samurai
San_Diego
Sanskrit

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 16/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Santa_Monica,_California
Seattle
Separation_of_church_and_state_in_the_United_States
Separation_of_powers_under_the_United_States_Constitution
Serbo-Croatian
Seven_Years%27_War
Sexual_orientation
Sichuan
Sino-Tibetan_relations_during_the_Ming_dynasty
Slavs
Software_testing
Solar_energy
Somalis
Somerset
Sony_Music_Entertainment
Southampton
Southeast_Asia
Southern_Europe
Space_Race
Spanish_language_in_the_United_States
Spectre_(2015_film)
St._John%27s,_Newfoundland_and_Labrador

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 17/19

バージョン 1.1 と 2.0 に共通する 442 記事。

States_of_Germany
Steven_Spielberg
Strasbourg
Sumer
Super_Nintendo_Entertainment_System
Supreme_court
Swaziland
Switzerland
Symbiosis
Szlachta
Tajikistan
Tennessee
Textual_criticism
The_Blitz
The_Bronx
The_Legend_of_Zelda:_Twilight_Princess
The_Sun_(United_Kingdom)
The_Times
Thuringia
Tibet
Time
To_Kill_a_Mockingbird
Transistor
Translation

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 18/19

バージョン 1.1 と 2.0 に共通する 442 記事。

Treaty
Tristan_da_Cunha
Tuberculosis
Tucson,_Arizona
Turner_Classic_Movies
Tuvalu
Umayyad_Caliphate
Unicode
United_Nations_Population_Fund
United_States_Air_Force
United_States_Army
United_States_dollar
United_States_presidential_election,_2004
Universal_Studios
University
University_of_Kansas
University_of_Notre_Dame
Uranium
USB
Utrecht
Vacuum
Valencia
Videoconferencing
Virgil

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

学習用 Wikipedia 記事一覧 19/19

バージョン 1.1 と 2.0 に共通する 442 記事。

War_on_Terror
Warsaw_Pact
Washington_University_in_St._Louis
Wayback_Machine
Web_browser
Westminster_Abbey
Windows_8
Wood
Xbox_360
Yale_University
YouTube
Zhejiang
Zinc

記事名は元 JSON の title をそのまま記載。
https://github.com/rajpurkar/SQuAD-explorer/tree/master/dataset

各版の公式 JSON を取得する Python コード

```
import json
from urllib.request import urlopen

base = "https://rajpurkar.github.io/SQuAD-explorer/dataset/"
for version in ("1.1", "2.0"):
    for split in ("train", "dev"):
        name = f"{split}-v{version}.json"
        with urlopen(base + name) as response:
            data = json.load(response)
        with open(name, "w", encoding="utf-8") as output:
            json.dump(data, output, ensure_ascii=False)
```

配布元　https://rajpurkar.github.io/SQuAD-explorer/dataset/

バージョン・分割ごとに公式 JSON を取得。 Python 標準ライブラリのみ使用。

SQuAD: 100,000+ Questions for Machine Comprehension of Text

Rajpurkar, P., Zhang, J., Lopyrev, K., & Liang, P. (2016). EMNLP, pp. 2383–2392.

SQuAD の原著論文。データセットの収集方法、回答範囲の注釈、 EM ・ F1 評価を記載する。

https://aclanthology.org/D16-1264/

Know What You Don’t Know: Unanswerable Questions for SQuAD

Rajpurkar, P., Jia, R., & Liang, P. (2018). ACL, pp. 784–789.

SQuAD 2.0 の原著論文。回答不能な質問の作成方法と、回答保留を含む評価を報告する。

https://aclanthology.org/P18-2124/

Question answering

Hugging Face (n.d.). Hugging Face Course, Chapter 7, Section 7. 参照 2026-10-15.

質問応答の公式教材。長い段落の分割、回答位置の変換、モデルの微調整と評価を扱う。

https://github.com/huggingface/course/blob/main/chapters/en/chapter7/7.mdx

---

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). NAACL-HLT, pp. 4171–4186.

BERT の原著論文。双方向の事前学習と微調整を提案し、 SQuAD などで評価する。

https://aclanthology.org/N19-1423/

Adversarial Examples for Evaluating Reading Comprehension Systems

Jia, R., & Liang, P. (2017). EMNLP, pp. 2021–2031.

読解モデルの頑健性を調べた研究。 SQuAD の段落に紛らわしい文を追加して性能を検証する。

https://aclanthology.org/D17-1215/

SQuAD-explorer

Rajpurkar, P., et al. (n.d.). GitHub repository. 参照 2026-10-15.

SQuAD の公式配布リポジトリ。公開 JSON 、 EM ・ F1 の評価スクリプトと提出形式を提供する。

https://github.com/rajpurkar/SQuAD-explorer