Sudachi 同義語辞書

SudachiDict Synonym

検索語の言い換えを、関係と向きで整理する

sasakiy84

Sudachi の公式リソース一覧



English

ワークス徳島NLPリソース

ワークス徳島人工知能NLP研究所 による自然言語処理のためのソフトウェアと言語資源

ソフトウェア

- Sudachi: 日本語形態素解析器
- sudachi.rs / SudachiPy: rust / Python版Sudachi
- elasticsearch-sudachi: Elasticsearch用Sudachiプラグイン
- Kintoki: 係り受け解析器
- jdartsclone: ダブル配列によるTrieデータ構造

言語資源

- SudachiDict: 日本語形態素解析辞書
- SudachiDict Synonym: 日本語同義語辞書
- chiVe: 事前学習済み日本語単語ベクトル
- chiTra: 事前学習済み日本語言語モデル

コミュニティ

開発者やユーザーの方々が質問したり議論するためのSlackワークスペースを用意しています。

- https://sudachi-dev.slack.com/
- (こちらから招待を受けてください)

Open Data on AWS

SudachiDictとchiVe・chiTraのデータは、AWSのOepn Data Sponsorship Program によりホストしていただいています。

[1] ワークスアプリケーションズ , n.d., ワークス徳島 NLP リソース
https://worksapplications.github.io/Sudachi/

1. 同義語グループと展開の向き
2. CSV と関係情報の読み方
3. 作成方法と収録内容
4. 読み込みと利用方法

1. 同義語グループと展開の向き

検索語を、別の表現へ広げる辞書

- Sudachi 同義語辞書は、 Sudachi 辞書に登録された語句へ、同義語グループと関係情報を付けた日本語の語彙資源。
- 「インフルエンザ」から「インフル」や「流行性感冒」へ、検索に使う表現を広げられる。
- グループへの所属に加え、略語、表記の違い、展開の向きなどを記録する。

[1] ワークスアプリケーションズ , n.d., Sudachi 同義語辞書
https://github.com/WorksApplications/SudachiDict/blob/develop/docs/synonyms.md

英語表記や略語も、同じグループに含む

見出し	グループ内での位置付け
インフルエンザ	代表表記
influenza	元の綴りによる表記
インフル	略語
流行性感冒	意味の近い別の語
流感	流行性感冒の略語

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

入力語から、検索に使う候補を得る

入力：インフルエンザ

influenza
インフル
流行性感冒
流感

CSV の展開制御に従い、入力語自身を除いた候補を列挙した。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

「AI」は展開の出力だけに使う

見出し	展開制御	使い方
人工知能	0	入力・出力に使用
アーティフィシャルインテリジェンス	0	入力・出力に使用
artificial intelligence	0	入力・出力に使用
AI	1	出力だけに使用

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

展開の向きは、同じグループ内でも異なる

「人工知能」を入力した結果

アーティフィシャルインテリジェンス
artificial intelligence
AI

「 AI 」を入力した結果：候補なし

この参照処理では、制御 1 の見出しを展開の開始点にしない。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

同じ「AI」が、複数の語群に登録される

同じ表記を含む語群の例	AI の展開制御
人工知能	1
人工授精	1
アムネスティインターナショナル	1
鳥インフルエンザ	1

これらの語群では、詳しい名称から「AI」を候補に出せる。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

削除した見出しも、履歴として保持する

見出し	制御	使い方
お金	0	入力・出力に使用
マネー	0	入力・出力に使用
money	0	入力・出力に使用
金	1	出力だけに使用
カネ	2	展開に使用しない

制御 2 のレコードは、同じ見出しの誤った再登録を防ぐための履歴。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

2. CSV と関係情報の読み方

1 語 1 行の CSV で、同じ群をまとめる

- ソースは UTF-8 の CSV 。 1 行が一つの見出しを表し、各行は 11 列で構成される。
- 同じグループ番号を持つ行が、一つの同義語グループになる。グループ番号は 6 桁の数字。
- 見出し、関係情報、展開制御などが列に入り、末尾の 2 列は予約されている。

[1] ワークスアプリケーションズ , n.d., Sudachi 同義語辞書
https://github.com/WorksApplications/SudachiDict/blob/develop/docs/synonyms.md

配布 CSV では、関係を数値の列で表す

```
000127,1,0,1,0,0,0,( 医療 ), インフルエンザ ,,
000127,1,0,1,0,0,1,( 医療 ),influenza,,
000127,1,0,1,0,2,0,( 医療 ), インフル ,,
```

インフルエンザのグループから 3 行を抜粋。末尾の 2 列は空欄。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

グループ・制御・見出しを、別の列で持つ

列番号	項目	この辞書での役割
0	グループ番号	同義語グループを識別
2	展開制御	入力・出力への使用を指定
8	見出し	登録する語句
9 ・ 10	予約	取得した CSV では空欄

列番号は 0 から数える。 11 列を、カンマ区切りの CSV として読み込む。

[1] ワークスアプリケーションズ , n.d., Sudachi 同義語辞書
https://github.com/WorksApplications/SudachiDict/blob/develop/docs/synonyms.md

同じ語の表記と、別の語彙を分けて記録する

- 「インフルエンザ」「 influenza 」「インフル」は、同じ語彙素として整理される。語彙素は、表記や語形の違いをまとめる単位。
- 「流行性感冒」と略語の「流感」は、もう一つの語彙素として、同じ同義語グループに入る。
- 語彙素の中では、語形種別、略語・略称、表記ゆれという階層で関係を記録する。

[1] ワークスアプリケーションズ , n.d., Sudachi 同義語辞書
https://github.com/WorksApplications/SudachiDict/blob/develop/docs/synonyms.md

略語の表記ゆれも、階層を重ねて記録する

見出し	略語情報	表記情報
スマートフォン	0	0
スマートホン	0	2
スマフォ	2	0
スマホ	2	2

同じ語群の一部。 0 は各階層の代表形。略語 2 は非アルファベットの略称、表記 2 は異表記。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

同じ見出しでも、語群ごとに制御を持つ

グループ	「支払い」の制御
000008 ：支払い・会計など	0
021742 ：払い込みなど	1

「支払い」は 2 つの群に登録される。入力からの展開では、制御 0 を持つ 000008 を開始点に使う。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

3. 作成方法と収録内容

企業内の全文検索に使う語彙を、人手で整理

- 商用の全文検索で使える同義語資源と、企業内文書の語彙を充実させるために作られた。
- Sudachi 辞書の見出しへ人手で同義関係を付け、不足する語を辞書へ追加する方法を採った。
- 語句を集めるだけでなく、検索での展開を選べるように、関係の種類や代表形を整理した。

[1] 高岡一馬ほか , 2020, 詳細化した同義関係をもつ同義語辞書の作成
https://www.anlp.jp/proceedings/annual_meeting/2020/pdf_dir/P4-14.pdf

代表形は、経験のある作業者が選定する

- 代表語・代表語形・代表表記は、それぞれの階層で関係を記述する基準となる。
- 2020 年の報告では、言語資源の作成経験が豊富な 3 名が代表形を選び、相互に確認した。
- 出現頻度だけで代表を決めず、利用者にとって自然な表記を考慮する方針が述べられている。

[1] 高岡一馬ほか , 2020, 詳細化した同義関係をもつ同義語辞書の作成
https://www.anlp.jp/proceedings/annual_meeting/2020/pdf_dir/P4-14.pdf

2019 年の公開から、語彙の追加・修正へ

- 同義語ソースは 2019 年 11 月に公開リポジトリへ追加され、 2020 年に設計と作成方法が発表された。
- 現在も SudachiDict で、語彙や関係情報の追加・修正を含むソースが配布されている。
- 2026 年 10 月 15 日更新の synonyms.txt には、見出しと関係情報が CSV 形式で収録されている。

[1] ワークスアプリケーションズ , 2019, Add a synonym dictionary
https://github.com/WorksApplications/SudachiDict/commit/e32387bbc0913fd4352e571faa0954605dcf077c

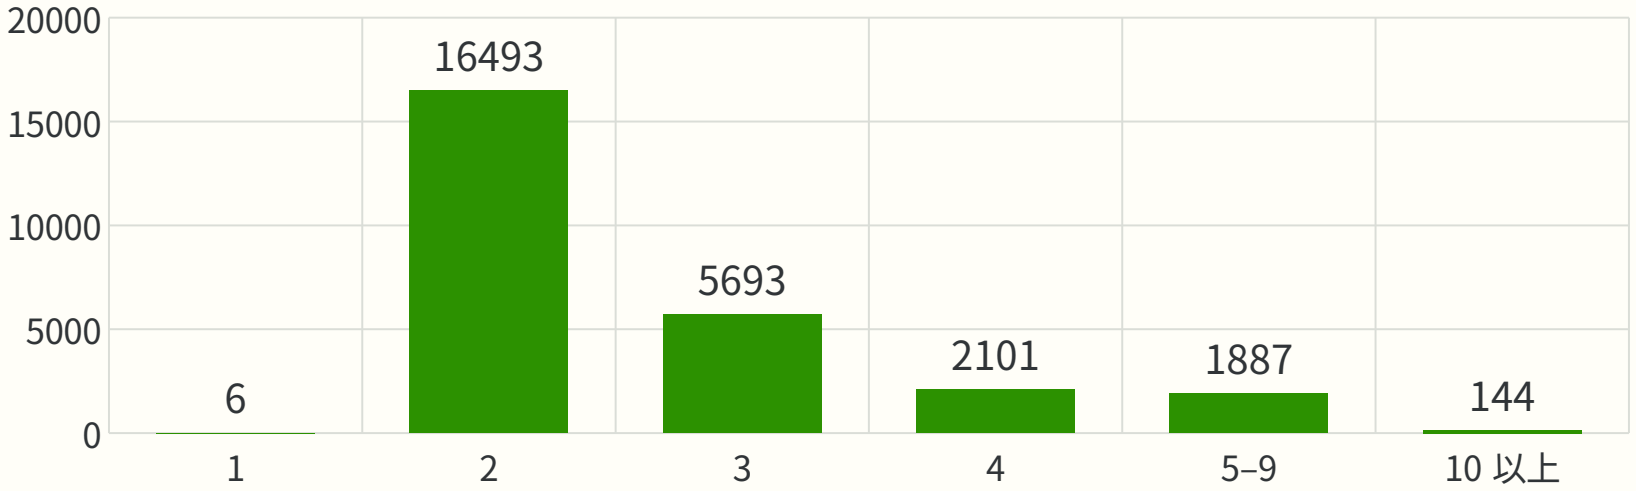
利用対象の見出しレコードは約 7.1 万件

集計対象	件数
見出しレコード	71,368
レコードがあるグループ	26,324
異なる見出し文字列	68,334

2026-10-15 更新の CSV を集計。展開に使わない制御 2 の 507 行を除く。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

2 〜 3 件の見出しを持つグループが多い



横軸は群内の利用対象見出し数、縦軸はグループ数。制御 2 を除く。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

一般語に加え、固有名や専門語も収録

分野の例	見出しレコード数
企業名	10,426
人名	4,244
ビジネス	3,204
IT	2,108
料理	1,973

分野の記載がないレコードは 26,964 件。複数分野の見出しは、各分野へ 1 件ずつ数える。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

4. 読み込みと利用方法

CSV から、見出しの登録行を読む

```
import csv

with open("synonyms.txt", encoding="utf-8") as f:
    rows = [r for r in csv.reader(f) if r]

print([(r[0], r[2]) for r in rows
       if r[8] == "人工知能"])
```

実行結果は [('010717', '0')] 。グループ番号と展開制御を取り出す。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

展開制御に従って、候補を列挙する

```
word = "人工知能"
ids = {r[0] for r in rows
       if r[8] == word and r[2] in ("", "0")}
candidates = [r[8] for r in rows
              if r[0] in ids and r[2] != "2"
              and r[8] != word]
print(list(dict.fromkeys(candidates)))
```

名詞などの体言と、動詞・形容詞などの用言を含め、入力語自身を除いた候補を返す。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

検索処理には、専用ライブラリも使える

- chikkar は、 Sudachi 同義語辞書を使う Java ライブラリ。 CSV からバイナリ辞書を作成して読み込む。
- Python 版の chikkarpy は、単語からの検索に加え、SudachiPy の解析結果への同義語情報の追加に対応する。
- 体言・用言の出力や、複数の辞書の優先順位など、実装側でも検索条件を選べる。

[1] ワークスアプリケーションズ , n.d., chikkarpy
https://github.com/WorksApplications/chikkarpy

検索のほか、語の関係を使う研究にも利用

- 検索では、入力語から同じグループの候補を取り出し、別表現を含む文書を探すために使える。
- 関係情報を選べば、略語や表記ゆれなど、必要な種類の候補を抽出できる。
- 2022 年の yamaMomo では、この辞書の同義関係や分野情報から、日本語の単語ベクトルを評価するデータが作られた。

[1] 野口夏希ほか , 2022, yamaMomo ：日本語分散表現の評価用データセットの作成
https://www.anlp.jp/proceedings/annual_meeting/2022/pdf_dir/PT2-3.pdf

CSV を入手し、用途に合わせて利用する

- 同義語ソースは SudachiDict の src/main/text/synonyms.txt 、列の説明は docs/synonyms.md で公開されている。
- Apache License 2.0 で提供され、商用利用や改変・再配布が可能。再配布ではライセンスと帰属を保ち、変更を明示する。
- 更新した CSV を取り込むときは、見出しだけでなく、展開制御と関係情報も読み込む。

[1] ワークスアプリケーションズ , n.d., SudachiDict — Licenses
https://github.com/WorksApplications/SudachiDict#licenses

語句のつながりと、展開できる向きを使う

- 同義語グループの中に、別の語彙、略語、英語表記、表記ゆれを整理している。
- 展開制御によって、入力に使える語、出力だけに使う語、展開に使わない語を指定する。
- CSV の列を読み、必要な関係を選ぶことで、検索や語彙処理へ組み込める。

[1] ワークスアプリケーションズ , n.d., Sudachi 同義語辞書
https://github.com/WorksApplications/SudachiDict/blob/develop/docs/synonyms.md

Appendix

1. 追加の語群と列仕様
2. 参考文献

パソコン：長い名称と略語の関係

見出しの抜粋	展開制御
パーソナルコンピューター	0
personal computer	0
PC	1
パソコン	0

PC は出力候補に含まれるが、この語群での入力の開始点にはならない。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

自動車：広く使われる短い語は出力側へ

見出しの抜粋	展開制御
自動車	0
車	1
カー	1
car	1

この群は 6 レコード。ひらがなの「くるま」とカタカナの「クルマ」も含む。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

「はやい」は、異なる語群に共通する

語群	代表的な見出し	はやいの制御
024872	早い・ early	1
000404	迅速・速い・ speedy	1

「はやい」は両方の群で出力側に置かれ、入力からの展開を始めない。

[1] ワークスアプリケーションズ , 2026, SudachiDict synonyms.txt （ 2026-10-15 更新）
https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

CSV の列仕様：グループと語形の情報

列	項目	値の意味
0	グループ番号	6 桁の識別番号
1	体言／用言	1 ：体言、 2 ：用言
2	展開制御	0 ：入力・出力、 1 ：出力、 2 ：未使用
3	語彙素番号	群内の語彙素を識別
4	語形種別	代表語・対訳・別称・旧称・誤用

複数の語彙素番号は「 1/2 」のように記す。

[1] ワークスアプリケーションズ , n.d., Sudachi 同義語辞書 https://github.com/WorksApplications/SudachiDict/blob/develop/docs/synonyms.md
[2] ワークスアプリケーションズ , 2026, synonyms.txt https://github.com/WorksApplications/SudachiDict/blob/develop/src/main/text/synonyms.txt

CSV の列仕様：略語・表記・分野

列	項目	値の意味
5	略語・略称	0 ：代表、 1 ：アルファベット 2 ：それ以外
6	表記ゆれ	0 ：代表、 1 ：アルファベット表記 2 ：異表記、 3 ：誤表記
7	分野	企業名・医療・ IT などの参考情報
8	見出し	登録される語句
9 ・ 10	予約	取得した CSV では空欄

[1] ワークスアプリケーションズ , n.d., Sudachi 同義語辞書
https://github.com/WorksApplications/SudachiDict/blob/develop/docs/synonyms.md

参考文献

Sudachi 同義語辞書

ワークスアプリケーションズ , n.d. （参照 2026-10-28 ）

CSV の 11 列と、語形・略語・表記ゆれ・展開制御の意味を定めた公式仕様。

https://github.com/WorksApplications/SudachiDict/blob/develop/docs/synonyms.md

詳細化した同義関係をもつ同義語辞書の作成

高岡一馬・岡部裕子・川原典子・坂本美保・内田佳孝 , 2020. 言語処理学会第 26 回年次大会 , pp. 840–842.

企業内検索の背景、人手による収集、階層のある同義関係と非対称な展開を説明する。

https://www.anlp.jp/proceedings/annual_meeting/2020/pdf_dir/P4-14.pdf

参考文献

chikkar

ワークスアプリケーションズ , n.d. （参照 2026-10-28 ）

Sudachi 同義語辞書をバイナリ化し、 Java から検索するための公式ライブラリ。

https://github.com/WorksApplications/chikkar

chikkarpy

ワークスアプリケーションズ , n.d. （参照 2026-10-28 ）

同義語検索と SudachiPy 連携に対応した Python ライブラリ。体言・用言の出力も制御できる。

https://github.com/WorksApplications/chikkarpy

参考文献

yamaMomo : Sudachi 同義語辞書による日本語分散表現の評価用データセットの作成

野口夏希・勝田哲弘・山村崇・高岡一馬・内田佳孝 , 2022. 言語処理学会第 28 回年次大会 , pp. 970–975.

同義関係と分野情報を使い、語の表記やカテゴリに関する評価データを構築した研究。

https://www.anlp.jp/proceedings/annual_meeting/2022/pdf_dir/PT2-3.pdf

SudachiDict

ワークスアプリケーションズ , 2026 （参照 2026-10-28 ）

同義語ソース、列仕様、配布先とライセンスを公開するリポジトリ。

https://github.com/WorksApplications/SudachiDict