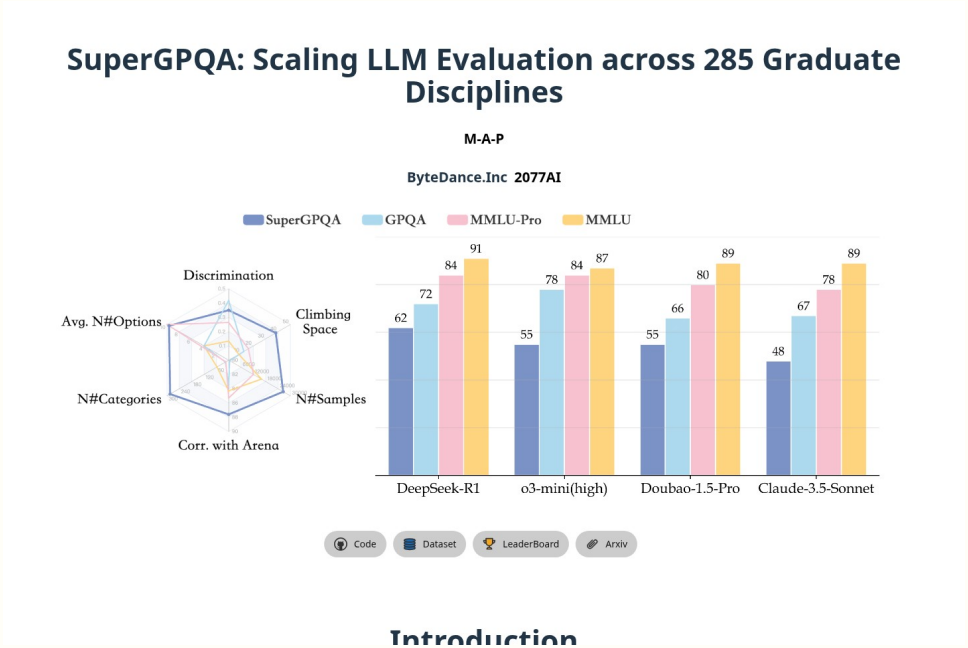
SuperGPQA

285 の専門領域で、大学院水準の知識と推論を評価する

sasakiy84

SuperGPQA の公式サイト



[1] M-A-P (n.d.), SuperGPQA.
https://supergpqa.github.io/

1. 専門知識を問う問題と実例
2. 問題の構築と分野の広がり
3. 採点方法とモデルの到達水準
4. 評価での利用と入手方法

1. 専門知識を問う問題と実例

285 の専門領域で、知識と推論を評価する

- SuperGPQA は、大学院水準の専門知識と推論を問う英語の選択式問題集である。理工系だけでなく、法律、歴史、文学、農学なども含む。
- 各問では、設問と選択肢から正しいものを一つ選ぶ。公開 26,529 問のうち、ここでは 12 の上位分野から 13 問を取り上げる。

[1] M-A-P Team et al. (2025), SuperGPQA.
https://arxiv.org/abs/2502.14739

専門分野を、三つの階層で整理する

- 分類は、 13 の上位分野、 72 の分野、 285 の専門領域からなる。例えば「工学 → 電気工学 → 電力電子・電気駆動」のように、広い分類から細かな専門へ分かれる。
- 問題には分野に関するタグと、難易度・計算を要するかどうかのタグが付く。設問の内容と併せて、得意・不得意な領域を調べられる。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 1 整流回路の電流を求める：原文

問題の原文・選択肢（全文）

For a single-phase fully controlled bridge rectifier circuit with a large inductive load, assuming the average load current is 10A, what are the RMS values of the secondary current of the transformer I2 and the RMS current of the thyristor IVT?
A. I2=5A IVT=5A / B. I2=10A IVT=7.07A
C. I2=7.07A IVT=10A / D. I2=10A IVT=10A
E. I2=5A IVT=7.07A / F. I2=10A IVT=14.14A
G. I2=7.07A IVT=7.07A / H. I2=7.07A IVT=14.14A
I. I2=10A IVT=5A / J. I2=7.07A IVT=5A

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 1 整流回路の電流を求める：日本語訳

設問の日本語訳

単相全制御ブリッジ整流回路に、大きなインダクタンスを持つ負荷を接続する。負荷電流の平均値を 10 A とすると、変圧器二次電流の実効値 I2 と、サイリスタ電流の実効値 IVT はそれぞれいくつか。

正解： B　 I2=10 A 、 IVT=7.07 A

負荷のインダクタンスが大きく、電流がほぼ一定とみなせる。二次側には 10 A が流れ、各サイリスタは半周期だけ導通するため、実効値は 10÷√2≒7.07 A となる。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 2 立法権を心臓にたとえた思想家を選ぶ

問題の原文（括弧内は選択肢の日本語訳）

Who compared legislative power to the "heart of the nation"?
A. Rousseau (ルソー) / B. Spinoza (スピノザ) / C. Descartes (デカルト)
D. Voltaire (ヴォルテール) / E. Kant (カント) / F. Diderot (ディドロ)
G. Montesquieu (モンテスキュー) / H. Locke (ロック)
I. Hobbes (ホッブズ) / J. Hume (ヒューム)

設問訳：立法権を「国家の心臓」にたとえたのは誰か。

正解： A　ルソー

ルソーの『社会契約論』では、立法権を国家の心臓、執行権を脳にたとえている。

[1] M-A-P (2025), SuperGPQA — public dataset. https://huggingface.co/datasets/m-a-p/SuperGPQA
[2] Rousseau (1762), The Social Contract, Book III, Chapter XI. https://www.gutenberg.org/ebooks/46333

例 3 ベルクソンの受賞年を答える

問題の原文・選択肢（全文）

In which year did Henri Bergson win the Nobel Prize in Literature?
A. 1922 / B. 1929 / C. 1920 / D. 1924 / E. 1928
F. 1921 / G. 1923 / H. 1926 / I. 1925 / J. 1927

設問の日本語訳

アンリ・ベルクソンがノーベル文学賞を受賞したのは何年か。

正解：J　1927 年

正解は 1927 年である。ベルクソンは哲学者だが、この設問では文学賞の受賞年を問う。分野をまたいだ人物・歴史の知識も含まれる。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

2. 問題の構築と分野の広がり

専門領域の広がりと、細かな知識を重視する

- 既存の知識問題では、よく使われる分野に評価が偏りやすかった。 SuperGPQA は、大学院の専門領域を細かく分け、農学や軽工業などの領域も対象にした。
- 科学の知識を問う GPQA とは別に、 M-A-P チームが構築したデータである。専門家とモデルを組み合わせ、参考資料の選定、設問の整理、品質確認を進めた。

[1] M-A-P Team et al. (2025), SuperGPQA.
https://arxiv.org/abs/2502.14739

専門家が資料を選び、英語の選択式に整える

- 博士号の取得者や博士課程の学生が、教科書・学術資料などから信頼できる問題の出所を選ぶ。学部生・修士課程の学生が、設問を英語の選択式へ整理する。
- 英語以外の問題は翻訳し、自由回答の問題には選択肢を付ける。国ごとに制度が違う場合は、法律の対象国などを設問に補う。

[1] M-A-P Team et al. (2025), SuperGPQA.
https://arxiv.org/abs/2502.14739

形式、モデルの回答、専門家の再検討で絞る

- まず規則に基づいて書式の問題を調べ、次に複数のモデルで解答し、曖昧さ、必要な情報の不足、分野との対応を点検する。
- 疑わしい設問は、専門家が資料や Web を参照して解き直す。 80 人を超える専門家が参加し、誤答候補の作り方や、答えが一つに定まるかも確認した。

[1] M-A-P Team et al. (2025), SuperGPQA.
https://arxiv.org/abs/2502.14739

選択肢は平均 9.67 個で、近い候補から選ぶ

- 全 26,529 問のうち 23,158 問が 10 択で、残りは 4 〜 9 択である。選択肢の数は平均 9.67 個となる。
- 専門用語のわずかな違いや、近い数値を候補に含む。知識を思い出すだけでなく、条件を読み、似た候補を見分けることも求められる。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

理学・工学・医学が全体の 77.2% を占める

上位分野	問題数	割合
理学	9,838	37.1%
工学	7,892	29.7%
医学	2,755	10.4%
その他 10 分野	6,044	22.8%

公開 26,529 問の内訳。その他には文学・芸術、経済、歴史、法律などを含む。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

難易度と計算のタグから、問題の性質を読む

- 公開データには、易しい問題が 7,731 問、中程度の問題が 11,748 問、難しい問題が 7,050 問ある。理学や工学では、難しい問題と計算問題の割合が高い。
- 全体の 11,229 問、 42.3% は、計算や形式的な推論が必要な問題として分類されている。難易度の区分は構築時の判断であり、分野ごとの内訳と併せて利用する。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

3. 採点方法とモデルの到達水準

回答から選択肢を取り出し、正解と照合する

- 回答指示では、最後の行を Answer: A のような形にする。採点コードは選択肢の記号を取り出し、参照記号と一致すれば正解にする。
- 記号を取り出せない場合には、選択肢の文面も照合する。全問題を分母とし、記号の不一致や答えを取り出せない回答は加点しない。

[1] M-A-P (n.d.), SuperGPQA — evaluation code.
https://github.com/SuperGPQA/SuperGPQA

全問の正解率と、分野を均等に見る平均を示す

- 全問の正解率は、 26,529 問に占める正解の割合である。問題数の多い理学や工学の成績が、全体へ強く反映される。
- 一方、専門領域・分野・上位分野ごとの正解率を求め、各区分を同じ重みで平均した値も報告する。問題の少ない分野にも、同じ重みを与える指標となる。

[1] M-A-P Team et al. (2025), SuperGPQA.
https://arxiv.org/abs/2502.14739

公開時の比較は、推論・対話モデルを例示なしで評価

- 2025 年の主要実験では、推論モデルと対話モデルに解答例を付けずに出題した。温度は 0 とし、推論モデルの出力上限は 32K トークン、その他は 4K だった。
- 基盤モデルには 5 問の解答例を付けた。推論・対話モデルの成績と、基盤モデルの成績では、提示する例の数が異なる。

[1] M-A-P Team et al. (2025), SuperGPQA.
https://arxiv.org/abs/2502.14739

2025 年の公開時、最高正解率は 61.82% だった

モデル	全問の正解率
DeepSeek-R1	61.82%
o1-2024-12-17	60.24%
Claude-3.5-Sonnet-20241022	48.16%
Gemini-2.0-flash	47.73%

解答例を付けない主要実験。正解率は問題ごとの平均。各モデルの結果は 2025 年の論文で公表された。

[1] M-A-P Team et al. (2025), SuperGPQA.
https://arxiv.org/abs/2502.14739

集計する単位で、全体の得点が変わる

DeepSeek-R1 の集計単位	正解率
問題ごとの平均	61.82%
専門領域を均等に平均	62.61%
分野を均等に平均	61.23%
上位分野を均等に平均	59.95%

同じモデル・同じ解答でも、各分野へ与える重みが変わる。

[1] M-A-P Team et al. (2025), SuperGPQA.
https://arxiv.org/abs/2502.14739

4. 評価での利用と入手方法

Qwen3 の公開評価でも、専門知識の指標に使われた

- 2025 年 7 月版の Qwen3-235B-A22B-Thinking-2507 は、公式モデルカードで SuperGPQA のスコア 64.9 を報告した。知識評価の項目として、 MMLU-Pro や GPQA と並べている。
- この報告は、論文公開時より後の採用例である。モデルカードでは知識課題の出力上限を 32,768 トークンとする。

[1] Qwen Team (2025), Qwen3-235B-A22B-Thinking-2507.
https://huggingface.co/Qwen/Qwen3-235B-A22B-Thinking-2507

総合点から、必要な専門領域へ掘り下げる

- モデルの知識評価では、まず全問の成績を見たうえで、業務や研究に必要な分野へ絞る。三段階の分類や難易度タグを使い、誤答の傾向を調べられる。
- 公開データは、設問、選択肢、正解記号・正解文、分類タグを含む。専門用語の理解と数値計算のどちらで失敗したかも、実例を読んで確かめる。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

公式の JSONL から、設問と正解を取得できる

- Hugging Face の公式配布に、 SuperGPQA-all.jsonl がある。 26,529 問を一つの公開集合として配布し、 GitHub に出題・採点の実装を公開している。
- データベースの利用条件は ODC-BY である。ほかのデータセットから取り込んだ内容もあるため、参照元の利用条件と帰属情報も保持する。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

一問の設問・選択肢・正解を読む

```
from datasets import load_dataset

ds = load_dataset("m-a-p/SuperGPQA", split="train")
row = ds[0]
print(row["question"])
print(row["options"])
print(row["answer_letter"], row["answer"])
```

question が設問、 options が選択肢、 answer_letter が正解記号を持つ。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

幅広い専門知識と、選択肢を見分ける推論を評価する

- SuperGPQA は、 285 の専門領域にまたがる 26,529 問を、専門家とモデルの共同作業で構築した英語の選択式問題集である。平均 9.67 個の選択肢から、一つを選ぶ。
- 全問の正解率と分野別の平均から、知識の広がりと偏りを捉える。公開の設問と正解を読み、必要な領域の評価へつなげられる。

[1] M-A-P Team et al. (2025), SuperGPQA.
https://arxiv.org/abs/2502.14739

Appendix

1. 分野の異なる追加例
2. 分野別の問題数
3. 参考文献

1. 分野の異なる追加例

例 4 カントの判断の区別を読む：原文

問題の原文・選択肢（全文）

According to Kant, 'all objects have extension' belongs to which of the following judgments?
A. synthetic a posteriori judgment / B. synthetic analytic judgment
C. empirical analytic judgment / D. synthetic judgment
E. a posteriori judgment / F. synthetic analytic a posteriori judgment
G. empirical judgment / H. synthetic a priori judgment
I. analytic judgment / J. empirical synthetic judgment

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 4 カントの判断の区別を読む：日本語訳

日本語訳（全文）

カントによれば、「すべての物体は延長を持つ」は、次のどの判断に当たるか。
A. ア・ポステリオリな総合判断 / B. 総合的な分析判断
C. 経験的な分析判断 / D. 総合判断
E. ア・ポステリオリな判断 / F. ア・ポステリオリな総合的分析判断
G. 経験判断 / H. ア・プリオリな総合判断
I. 分析判断 / J. 経験的な総合判断

正解：I　分析判断

延長は、空間的な広がりを意味する。カントは、物体という概念を分析するだけで延長を取り出せるため、これを分析判断とする。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 5 年初の積立金の将来価値を計算する：原文

問題の原文・選択肢（全文）

A person deposits money in the bank with an interest rate of 6%, compounded annually. If 2000 yuan is deposited at the beginning of each year for 10 years, the principal and interest at the end of the 10th year will be ().
A. 20000 yuan / B. 27933 yuan / C. 27843.5 yuan / D. 21200 yuan
E. 27943 yuan / F. 27843 yuan / G. 27963 yuan / H. 27863 yuan
I. 26943 yuan / J. 26362 yuan

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 5 年初の積立金の将来価値を計算する：日本語訳

設問の日本語訳

年利 6% の銀行預金を、年 1 回の複利で運用する。各年の初めに 2,000 元ずつ 10 年間預けると、 10 年目の終わりの元利合計はいくらか。

正解： E　27,943 元

最初の積立は 10 年間、最後の積立は 1 年間運用される。
$2{,}000\times(1.06+1.06^{2}+\ldots+1.06^{10})\fallingdotseq 27{,}943.29$ 元なので、選択肢 E となる。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 6 曲線を回転させた体積を求める：原文

問題の原文・選択肢（全文）

The volume of a vase obtained by rotating the curve y=2+sin x from x=0 to x=5 around the x-axis is approximately
A. 79.815 / B. 79.915 / C. 79.515 / D. 33.666
E. 71.113 / F. 79.115 / G. 25.501 / H. 79.615
I. 78.115 / J. 80.115

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 6 曲線を回転させた体積を求める：日本語訳

設問の日本語訳

曲線 y=2+sin x の x=0 から x=5 までを、 x 軸の周りに回転させてできる花瓶の体積は、およそいくつか。

正解：J　80.115

半径が 2+sin x の円板を積み重ねると考え、$\pi\int_0^5(2+\sin x)^2dx$ を計算する。値は約 80.1149 なので、選択肢 J となる。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 7 独立を仮定した期待度数を計算する：原文

問題の原文・選択肢（全文）

The distribution between party identity variables and race variables in the 2004 United States General Social Survey is as follows: 250, 106 and 17 support Democrats, independents and Republicans among blacks and 640, 783 and 775 among whites. What is the expected frequency of the Black Democratic Party when assuming that the two variables are unrelated?
A. 120.5 / B. 150.3 / C. 129.1 / D. 122.8
E. 137.2 / F. 135.7 / G. 115.6 / H. 144.9
I. 130.4 / J. 140.2

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 7 独立を仮定した期待度数を計算する：日本語訳

設問の日本語訳

2004 年の米国一般社会調査で、政党支持と人種の分布は次のとおりだった。黒人の民主党・無党派・共和党支持は 250 人・ 106 人・ 17 人、白人では 640 人・ 783 人・ 775 人である。二つの変数が無関係と仮定したとき、黒人かつ民主党支持の期待度数はいくつか。

正解： C　 129.1

黒人は 373 人、民主党支持は 890 人、全体は 2,571 人である。独立を仮定した期待度数は 373×890÷2,571≒129.1 となる。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 8 戦争と政治の関係を述べた本を選ぶ：原文

問題の原文・選択肢（全文）

Military is the continuation of political relations. Where does this famous saying come from?
A. "The Theory on War" / B. "The Prince"
C. "The Republic" / D. "On Guerrilla Warfare"
E. "The Military Maxims" / F. "The Book of Five Rings"
G. "The History of the Peloponnesian War" / H. "The Art of War"
I. "The Grand Strategy" / J. "The Campaigns of Alexander"

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 8 戦争と政治の関係を述べた本を選ぶ：日本語訳

日本語訳（全文）

「戦争は政治的関係の継続である」という有名な言葉は、どの著作に由来するか。

A. 『戦争論』 / B. 『君主論』
C. 『国家』 / D. 『遊撃戦論』
E. 『軍事箴言集』 / F. 『五輪書』
G. 『戦史（ペロポネソス戦争史）』 / H. 『孫子』
I. 『大戦略』 / J. 『アレクサンドロス大王東征記』

正解： A 『戦争論』

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 8 戦争と政治の関係を述べた本を選ぶ：解説

クラウゼヴィッツは『戦争論』で、戦争を他の手段を交えた政治的交渉の継続と捉えた。

[1] Clausewitz (1832), On War.
https://www.gutenberg.org/ebooks/1946

例 9 帝権と教会の関係を歴史から読む：原文

問題の原文・選択肢（全文）

After the "Crisis of the Third Century", Roman rulers utilized Christianity and made it the spiritual pillar of imperial rule. Which council marked the convergence of the Church and the imperial authority?
A. Council of Ephesus / B. Council of Chalcedon
C. Nisian Conference / D. Synod of Laodicea
E. Synod of Hippo / F. Latran Conference
G. Sadika Conference / H. Diet of Worms
I. Council of Arles / J. Synod of Elvira

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 9 帝権と教会の関係を歴史から読む：日本語訳

日本語訳（全文）

「3 世紀の危機」の後、ローマの支配者はキリスト教を利用し、帝国支配の精神的な支柱とした。教会と皇帝権力の結び付きを画したのは、どの会議か。
A. エフェソス公会議 / B. カルケドン公会議
C. ニカイア公会議 / D. ラオディキア教会会議
E. ヒッポ教会会議 / F. ラテラノ公会議
G. サルディカ教会会議 / H. ヴォルムス帝国議会
I. アルル教会会議 / J. エルビラ教会会議

正解： C　ニカイア公会議

コンスタンティヌス帝が 325 年に招集した第 1 ニカイア公会議を指す。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 10 形態素が最も少ない語を選ぶ：原文

問題の原文・選択肢（全文）

Which of the following words contains the smallest number of morphemes?
A. swiftly / B. engines / C. fruitful / D. diving
E. kindness / F. walked / G. removal / H. happily
I. teaching / J. bench

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 10 形態素が最も少ない語を選ぶ：日本語訳

日本語訳（全文）

次のうち、形態素の数が最も少ない語はどれか。
A. swiftly （素早く） / B. engines （エンジンの複数形）
C. fruitful （実り多い） / D. diving （潜ること）
E. kindness （親切） / F. walked （歩いた）
G. removal （除去） / H. happily （幸せに）
I. teaching （教えること） / J. bench （ベンチ）

正解：J　bench （ベンチ）

形態素は、意味や文法的な働きを持つ最小の単位である。 bench は一つの形態素で、ほかの語は swift+ly や engine+s のように分けられる。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 11 種子の寿命を表す語を選ぶ：原文

問題の原文・選択肢（全文）

What is the lifespan of a seed called from physiological maturity to loss of viability?
A. Seed survival term / B. Seed existence span
C. Seed growth duration / D. Seed development cycle
E. Seed germination period / F. Seed lifespan
G. Seed vitality extent / H. Seed maturation period
I. Seed aging timeline / J. Seed viability phase

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 11 種子の寿命を表す語を選ぶ：日本語訳

日本語訳（全文）

種子が生理的成熟に達してから、発芽能力を失うまでの期間を何と呼ぶか。
A. 種子の生存期間 / B. 種子の存在期間
C. 種子の成長期間 / D. 種子の発育周期
E. 種子の発芽期間 / F. 種子の寿命
G. 種子の活力が及ぶ範囲 / H. 種子の成熟期間
I. 種子の老化過程 / J. 種子の発芽能力が保たれる段階

正解： F　種子の寿命

seed lifespan は種子の寿命を指す。貯蔵温度や含水率などによって、発芽能力を保てる期間は変わる。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 12 輸血後の黄疸の種類を見分ける：原文

問題の原文・選択肢（全文）

A 35-year-old female patient developed fever, headache, and flank pain after blood transfusion, with the passage of dark urine resembling soy sauce and jaundice of the skin. The type of jaundice is
A. Drug-induced yellowing of the skin / B. Hemolytic jaundice
C. Hepatocellular jaundice / D. Post-transfusion jaundice
E. Physiological jaundice / F. Cholestatic jaundice
G. Post-transfusion hemolytic reaction / H. Post-transfusion hyperbilirubinemia
I. Autoimmune hemolytic anemia

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 12 輸血後の黄疸の種類を見分ける：日本語訳

日本語訳（全文）

35 歳の女性が輸血後に発熱、頭痛、側腹部痛を生じ、醤油のように濃い尿と皮膚の黄疸が現れた。この黄疸はどの種類か。
A. 薬剤による皮膚の黄染 / B. 溶血性黄疸
C. 肝細胞性黄疸 / D. 輸血後黄疸
E. 生理的黄疸 / F. 胆汁うっ滞性黄疸
G. 輸血後溶血反応 / H. 輸血後高ビリルビン血症
I. 自己免疫性溶血性貧血

正解： B　溶血性黄疸

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 12 輸血後の黄疸の種類を見分ける：解説

赤血球の破壊によってヘモグロビンが放出され、ヘモグロビン尿や黄疸が生じる。問われているのは反応全体の名称ではなく、黄疸の種類なので B を選ぶ。

[1] Merck Manual Professional Edition (n.d.), Complications of Transfusion.
https://www.merckmanuals.com/professional/hematology-and-oncology/transfusion-medicine/complications-of-transfusion

例 13 条件を満たすチームの組み方を数える：原文

問題の原文・選択肢（全文）

A company has 8 employees, including 3 managers and 5 engineers. How many different ways are there to form a team of 4 employees that includes at least 1 manager and at least 2 engineers?
A. 90 / B. 40 / C. 55 / D. 60 / E. 65
F. 50 / G. 70 / H. 100 / I. 80 / J. 75

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

例 13 条件を満たすチームの組み方を数える：日本語訳

設問の日本語訳

従業員 8 人の会社に、管理職 3 人と技術者 5 人がいる。少なくとも管理職 1 人と技術者 2 人を含む 4 人のチームを作る方法は何通りか。

正解： D　60

管理職 1 人・技術者 3 人なら 3×10=30 通り、管理職 2 人・技術者 2 人なら 3×10=30 通りである。この二つの場合を合わせ、 60 通りとなる。

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

2. 分野別の問題数

上位 13 分野の問題数：理学から法学

上位分野	問題数
理学	9,838
工学	7,892
医学	2,755
文学・芸術	1,676
経済学	873
歴史学	674
法学	656

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

上位 13 分野の問題数：経営・管理から社会学

上位分野	問題数
経営・管理	501
農学	485
教育学	484
哲学	347
軍事学	205
社会学	143

[1] M-A-P (2025), SuperGPQA — public dataset.
https://huggingface.co/datasets/m-a-p/SuperGPQA

3. 参考文献

参考文献

SuperGPQA: Scaling LLM Evaluation across 285 Graduate Disciplines

M-A-P Team et al. (2025). arXiv:2502.14739.

専門領域の分類、問題の構築、品質確認と初期モデルの評価を報告する。

https://arxiv.org/abs/2502.14739

SuperGPQA

M-A-P (2025). Hugging Face dataset. ODC-BY.

公開 26,529 問の設問、選択肢、正解と分類タグを提供する。

https://huggingface.co/datasets/m-a-p/SuperGPQA

参考文献

SuperGPQA: Scaling LLM Evaluation across 285 Graduate Disciplines

M-A-P (n.d.; 2026-10-26 参照). GitHub evaluation code.

回答を提示する形式と、選択肢の抽出・集計を行う実装を公開する。

https://github.com/SuperGPQA/SuperGPQA

Qwen3-235B-A22B-Thinking-2507

Qwen Team (2025). Hugging Face model card.

SuperGPQA を含む知識・推論・コード生成の評価と、利用方法を示す。

https://huggingface.co/Qwen/Qwen3-235B-A22B-Thinking-2507