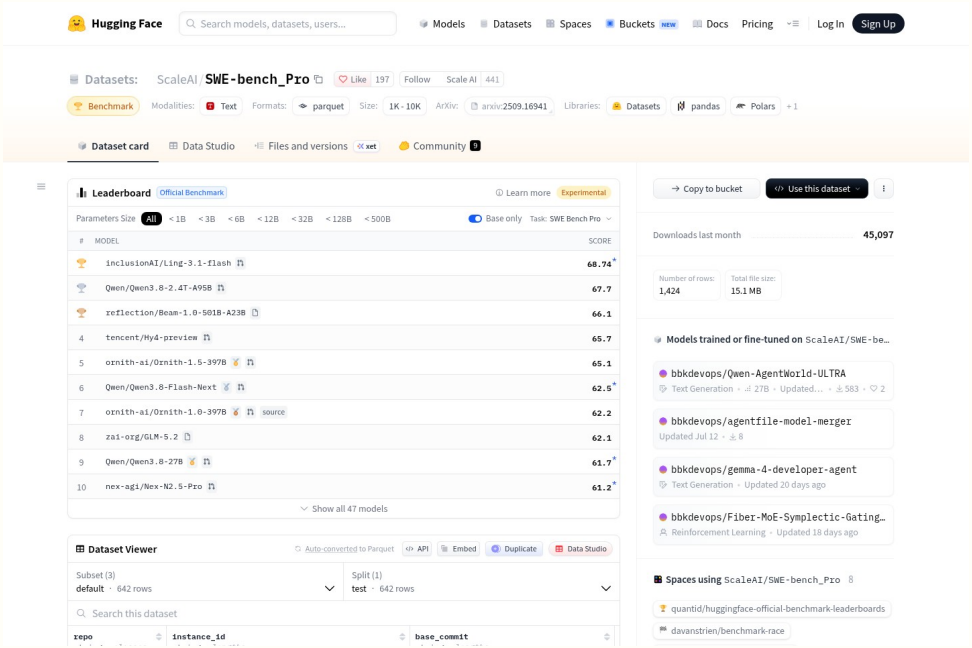
SWE-bench Pro

実際のコードベースで、不具合修正と機能追加を評価する
人が補った要件・テスト・実行環境を持つ開発課題

sasakiy84

SWE-bench Pro の公式配布ページ



Scale AI. SWE-bench_Pro. default = V2 、 hard = HARD-51 、 v1 = 従来 731 課題。 https://huggingface.co/datasets/ScaleAI/SWE-bench_Pro

1. コード修正の課題と実例

2. テストによる採点とモデル評価

3. 作成方法とバージョン２

4. 入手・実行とまとめ

1. コード修正の課題と実例

リポジトリを読み、動く変更を提出する

- SWE-bench Pro は、実際のソフトウェアを対象に、不具合修正や機能追加を行うエージェントの評価データセット。2025 年に Scale AI が公開した。
- エージェントはコードベースと課題文を受け取り、ファイルを調べ、編集し、テストを実行して変更を作る。提出物はコードの差分パッチ。
- Python ・ JavaScript ・ TypeScript ・ Go のプロジェクトを扱い、画面、認証、検索、データ処理などの変更を含む。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

要件を補い、複数ファイルの変更を扱う

- SWE-bench は GitHub の不具合報告からコード修正を評価する枠組み。 SWE-bench Verified は、そのうち人が検証した 500 課題の集合である。
- Pro では、業務アプリや開発ツールなどの対象を広げ、長い修正や複数ファイルの変更を扱う。問題文に人手で要件と必要なインターフェースを補う。
- 公開側はコピーレフトのリポジトリを選び、非公開の商用コードも別集合として用意した。既知のコードへの依存を減らすことも設計の狙いである。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

本資料の実例は、公開バージョン 2 から選ぶ

対象	公開課題数	公開時期
従来バージョン 1	731	2025 年
検証を改めたバージョン 2	642	2026-09-22
バージョン 2 内の HARD-51	51	2026-09-22

実例はバージョン 2 から本編 3 件・ Appendix10 件を選んだ。
HARD-51 は難しい課題を選んだサブセット。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

課題文・コード・テストが 1 課題を構成する

役割	エージェントに渡すもの／判定に使うもの
課題文	変更の背景、満たす要件、必要な関数や型
作業環境	修正前コミットのコードと依存関係
提出物	編集したファイルの差分パッチ
採点	用意されたテストを実行した結果

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

実例 1 ：アップロード先が存在するか確かめる

課題文の抜粋（原文）

The system must validate the existence of the target directory before processing any file upload request.

NodeBB は掲示板ソフト。管理画面で存在しないフォルダーにアップロードするとき、処理を始める前にエラーにする。

SWE-bench Pro V2 / NodeBB/NodeBB / 課題 f9ce92df 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

参照パッチは、保存処理の前に検査を加える

```
if (!await file.exists(path.join(
    nconf.get('upload_path'), params.folder))) {
    return next(new Error('[[error:invalid-path]]'));
}
```

src/controllers/admin/uploads.js の参照差分から抜粋・改行調整。
設定済みの保存先を基準にし、不正なパスには指定のエラーを返す。

SWE-bench Pro V2 / NodeBB/NodeBB / 課題 f9ce92df 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

実例２：アルバムの保存場所を集約する

課題文の抜粋（原文）

The `Album` struct must include an exported `Paths` field of type `string`, holding the aggregated unique directory paths of the album's media files, joined by the platform's list separator (`filepath.ListSeparator`).

Navidrome は音楽サーバー。曲ファイルの親フォルダーを重複なく集め、アルバムから保存場所を参照できるようにする。

SWE-bench Pro V2 / navidrome/navidrome / 課題 c90468b8 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

保存場所と、埋め込み画像の情報を保つ

- 課題文の例では、 /music1/file1.mp3 と /music2/file2.mp3 を含むアルバムの Paths は、 Unix 上で「 /music1:/music2 」になる。
- 埋め込み画像を持つ曲が 2 曲目だけなら、 EmbedArtPath は /music2/file2.mp3 のまま保つ。
- 参照パッチはアルバム型・曲からの集約・ DB 移行・画像探索など 5 ファイルを変更する。採点は TestModel で行う。

SWE-bench Pro V2 / navidrome/navidrome / 課題 c90468b8 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

実例３： Qt の新しいエラー通知に合わせる

課題文の抜粋（原文）

In the WebKit `NetworkReply` implementation, the initial error emission should use the `errorOccurred` signal with the error code, instead of the legacy `error` signal.

qutebrowser はキーボード中心の Web ブラウザー。通信エラーの初回通知を、 Qt の新しいシグナル errorOccurred へ変更する。

SWE-bench Pro V2 / qutebrowser/qutebrowser / 課題 0833b5f6 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

通知名の変更を、テストで確かめる

- 参照パッチでは、 NetworkReply のエラー通知を self.error.emit(error) から self.errorOccurred.emit(error) へ置き換える。
- 関連するダウンロード処理とプロセス間通信にも、 Qt のバージョンに応じた接続・解除処理を加えている。
- 指定テストは、新たに通す 1 件と、既存動作を保つ 9 件。通知が出ることと、周辺の通信処理を確認する。

SWE-bench Pro V2 / qutebrowser/qutebrowser / 課題 0833b5f6 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

2. テストによる採点とモデル評価

必要なテストがすべて通れば、課題の合格

テストの集合	確かめる内容
FAIL_TO_PASS	修正前は失敗し、修正後に通るべきテスト
PASS_TO_PASS	修正の前後で、通り続けるべきテスト

課題ごとに、両集合の全テストが PASSED なら合格（1）。
解決率 = 合格した課題数 / 評価した課題数 × 100 。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

アップロードの例は、 1 件の修正と 34 件の維持

確認するもの	指定テスト数
存在しない保存先へのアップロードを拒否	1
既存のアップロード・削除・取得など	34

NodeBB の実例 1 の tests/config.json 。
35 件すべての通過を求める。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

論文の公開集合では、解決率は約 4 割

モデル／推論設定	解決率
Claude Sonnet 4.5	43.6%
Claude Sonnet 4	42.7%
GPT-5 / high	41.8%
Claude Haiku 4.5	39.5%

2025 年の論文 v2 、従来の公開 731 課題、 SWE-agent 、最大 50 ターン。
問題文・要件・インターフェースを提示した 1 回試行。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

現行モデルの公式比較にも採用されている

モデル／推論設定	解決率
Gemini 3.1 Pro / high	54.2%
Gemini 3 Pro / high	43.3%
GPT-5.2 / xhigh	55.6%
GPT-5.3-Codex / xhigh	56.8%

Google 公式比較（ 2026 年参照）： SWE-Bench Pro (Public) 、 1 回試行。
掲載表にはデータのバージョン指定がない。

Google DeepMind (2026). Gemini 3.1 Pro. Performance. 2026-10-17 参照。 https://deepmind.google/models/gemini/pro/

バージョン 2 は、別の環境で提出差分を採点する

- エージェントの作業時間は 1 課題 50 分。外部 Web 検索・取得を無効にし、通信はモデル API への接続だけを許す。
- 作業後に git diff を保存し、新しいコンテナへ適用する。テストは、この初期状態から作った環境で実行する。
- 作業環境での得点と再採点した得点の両方を報告し、正式な結果には再採点の値を使う。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

公開前に、参照修正と空の修正を全件実行した

バージョン 2 の公開元による確認	課題数
参照パッチで合格	642 / 642
空パッチで不合格	642 / 642
公開コンテナの配布情報を確認	642 / 642

2026 年 9 月 22 日の公開確認。 Harbor 0.22 、 Modal 。
実行基盤の一時エラーは再試行して確認している。

Scale AI (2026). SWE-bench Pro V2: Release gate. Harbor 0.22 / Modal 。
https://github.com/scaleapi/SWE-bench_Pro-os/blob/66f92766bba642462d4bbe5479e83f91f9211862/v2/GATE.md

HARD-51 は、難しい 51 課題を抜き出す

- バージョン 2 の 642 課題のうち、 5 モデル系列中 2 系列以上が失敗した課題を基に選んだサブセット。曖昧さが見つかった 3 課題を除き、 51 課題を収録する。
- 選定に使った系列は Claude Opus 5 、 GLM-5.3 、 Kimi-K3 、 Inkling 、 Gemini 3.8 Flash 。固定の評価手順で実行した結果に基づく。
- Hugging Face の hard 設定、または公開された課題 ID 一覧から利用できる。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

3. 作成方法とバージョン 2

コミット間の変更を、課題と正解へ分ける

- 開発履歴から、問題の解決を含む連続したコミットの組を選ぶ。古い方を、エージェントが作業する修正前の状態にする。
- 差分のうちテスト関連の変更を採点用のテストパッチにし、それ以外を参照修正の gold patch として分ける。
- 公開・留保集合ではコピーレフトのプロジェクトを使い、商用集合では提携したスタートアップの非公開コードを用いた。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

背景・要件・インターフェースを人が補う

- コミット、 Issue 、 PR の説明を集め、変更の動機と問題を課題文にまとめる。元資料だけでは不足する仕様を補う。
- テストで求める動作を、要件として具体化する。 API の名前、入力に応じた返り値、エラー時の振る舞いも必要に応じて示す。
- 新しいクラスや関数を作る課題では、そのインターフェースも記す。実装の自由度を保ちながら、テストが期待する呼び出し方を伝える。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

環境を構築し、テストの関連性を確かめる

- ソフトウェア技術者が、依存ライブラリとビルド手順を含む Docker 環境を作る。参照修正が通ることを繰り返し確認する。
- テストを人が調べ、課題に無関係なものや、要求を広く取りすぎるものを外す。有効なテストが残らない課題は除く。
- バージョン 2 では問題文とテストの対応、テスト環境の復元、依存関係を改めて点検した。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

当初の全 1,865 課題は、 3 集合からなる

集合	課題数	リポジトリ数	公開範囲
公開	731	11	問題・結果
商用	276	18	結果
留保	858	12	非公開

2025 年論文の構成。集合間ではリポジトリを分ける。
バージョン 2 は、このうち公開集合を見直したもの。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

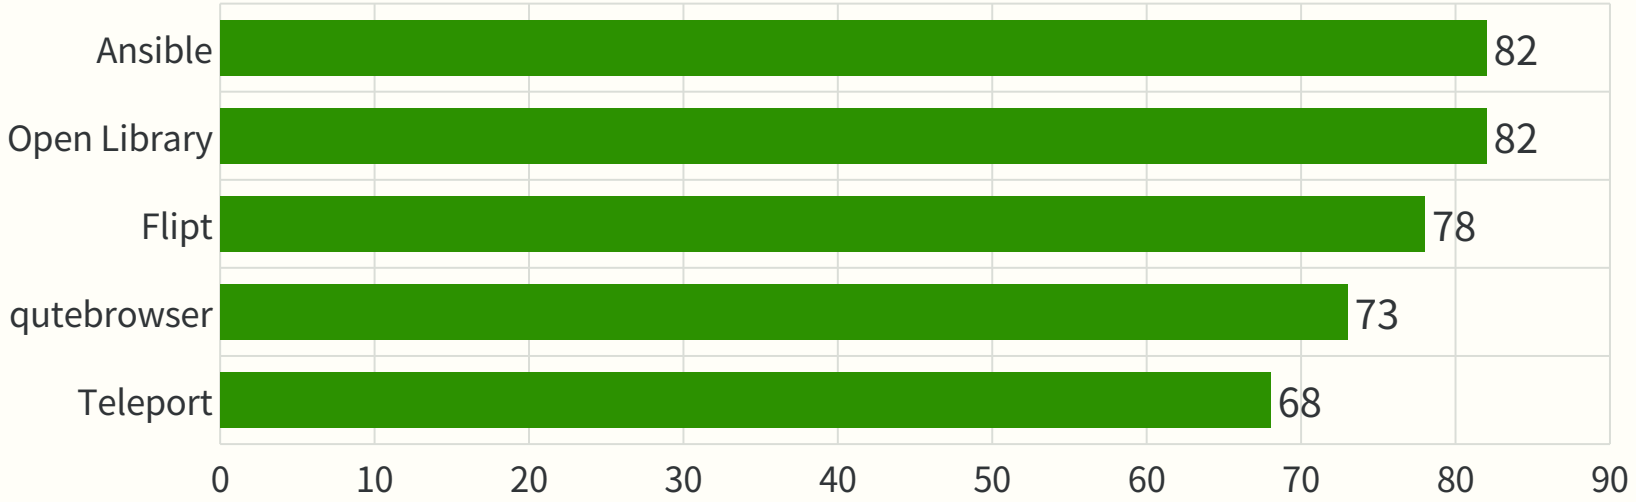
バージョン 2 では、 89 課題を除外した

変更対象	公開元が報告した変更
課題数	731 → 642 （ 11 リポジトリは継続）
課題文	529 件を書き直し、別の技術者が実装・検証
採点用テスト	全 642 件で復元手順を改修、 214 件の差分を修正
参照修正・環境	38 件の参照差分、 211 件の依存関係を修正

要求文と採点条件の対応を確かめ、各課題の修正前コミットは維持。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

公開バージョン 2 は、 11 プロジェクトを扱う



課題数の上位 5 件。計 642 課題を配布ディレクトリから集計。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

4. 入手・実行とまとめ

データ設定と実行手順を対応させる

- Hugging Face では default がバージョン 2 の 642 課題、hard が HARD-51 、 v1 が従来の 731 課題。
- バージョン 2 は GitHub の v2/tasks 以下に、課題文・採点スクリプト・参照パッチをまとめる。公開コンテナは GitHub の配布サービス GHCR で提供する。
- 実行制御に Harbor 、クラウド環境に Modal を使う。モデル、エージェント、通信条件、時間予算、再採点の方法を記録する。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

公開課題と参照修正を取得する

```
git clone https://github.com/scaleapi/SWE-bench_Pro-os
cd SWE-bench_Pro-os
uv tool install 'harbor[modal]>=0.22'
modal setup
harbor run -p v2/tasks -e modal -n 50 -a oracle
```

公式の参照修正による動作確認。モデル評価ではエージェントを指定し、提出差分を新しい環境へ適用して再採点する。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

仕様を読み、実装し、既存の動作も保つ

- SWE-bench Pro は、コードベース全体を調べながら修正や機能追加を行い、テストで合否を決める評価である。
- 人が補った要件とインターフェース、複数言語・用途のプロジェクト、課題ごとの実行環境を組み合わせる。
- 公開バージョン 2 は 642 課題。課題文と採点環境を改めて検証し、難しい 51 課題を選ぶ HARD-51 も提供する。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

Appendix

1. 公開課題の追加例

2. 構成と実行条件

3. 著者と参考文献

1. 公開課題の追加例

追加例 1 ： Python の予約語を名前から除く

課題文の抜粋（原文）

Collection names like `def.collection`, `return.module`, `assert.test`, and `import.utils` are accepted during validation when they should be rejected.

Ansible のコレクション名検証。名前空間と名前の両方を検査し、Python の予約語を受け付けない。

SWE-bench Pro V2 / ansible/ansible / 課題 f327e65d 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

名前空間と名前の両方で予約語を検査する

- is_valid_collection_name は、名前空間とコレクション名の両方について、有効な Python 識別子かつ予約語でないことを判定する。
- 結果は True / False で返す。予約語を含む 4 件を新たに通し、 171 件の既存テストも保つ。

SWE-bench Pro V2 / ansible/ansible / 課題 f327e65d 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 2 ：検索条件の引用符を正規化する

課題文の抜粋（原文）

`q_to_solr_params` must include a parameter named `userWorkQuery` whose value is exactly the user's original query string.

Open Library の蔵書検索。元の検索文字列を保持し、版の ID を指定する条件の引用符とパスを整える。

SWE-bench Pro V2 / internetarchive/openlibrary / 課題 427f1f4e 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

元の検索式を残し、版 ID の表記をそろえる

- 元の検索文字列を userWorkQuery 、版検索向けに変換した文字列を userEdQuery として公開する。
- edition_key の裸 ID ・引用付き ID ・完全パス・括弧・OR を受け付け、 /books/{id} を対象とする標準の引用符へ正規化する。採点は修正確認 5 件と維持 4 件。

SWE-bench Pro V2 / internetarchive/openlibrary / 課題 427f1f4e 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例３：読み取り専用の設定を追加する

課題文の抜粋（原文）

`StorageConfig` must include a `ReadOnly *bool` field exposed as `storage.readOnly`, using `readOnly` as its key in both YAML and JSON configuration.

Flipt は機能フラグを管理するサービス。ストレージ設定に ReadOnly を加え、保存形式と値の検証をそろえる。

SWE-bench Pro V2 / flipt-io/flipt / 課題 abaa5953 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

設定のキー・型・エラー条件をそろえる

- StorageConfig に ReadOnly *bool を加え、 YAML ・ JSON の両方で readOnly というキーを使う。
- 配布課題は、非 DATABASE の保存先で storage.readOnly が false なら、指定のエラーメッセージを返すよう要求する。 TestLoad で設定の読み込みと検証を確認する。

SWE-bench Pro V2 / flipt-io/flipt / 課題 abaa5953 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 4 ：フィルターで除外した脆弱性数を返す

課題文の抜粋（原文）

`FilterByCvssOver`, `FilterByConfidenceOver`, `FilterIgnoreCves`, `FilterUnfixed`, and `FilterIgnorePkgs` must each return two values: the filtered `VulnInfos` and an `int` representing the number of vulnerabilities excluded by the filter.

Vuls は脆弱性検査ツール。フィルター後の一覧に加え、各条件で何件を除外したかも返す。

SWE-bench Pro V2 / future-architect/vuls / 課題 86596681 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

除外した件数を、呼び出し側へ渡す

- 深刻度、検出の信頼度、除外 CVE 、未修正、パッケージ名の 5 種類のフィルターを対象とする。
- 戻り値を VulnInfos と除外数 int の組にし、呼び出し側も合わせる。配布設定では、新たに通す 15 テストを指定する。

SWE-bench Pro V2 / future-architect/vuls / 課題 86596681 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 5 ：入力欄の案内を空のときだけ表示する

課題文の抜粋（原文）

The placeholder must hide as soon as content is entered and must show again if all content is cleared.

Element Web のメッセージ入力欄。未入力時の案内文を、リッチテキストとプレーンテキストの両方で切り替える。

SWE-bench Pro V2 / element-hq/element-web / 課題 7c63d525 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

入力の変化に応じて、表示を切り替える

- placeholder プロパティで案内文を渡す。入力すると隠し、全内容を消すと再び表示する。
- Editor の表示状態を CSS クラスで切り替え、両形式の入力操作に追従させる。修正確認 4 件と既存 81 件を採点する。

SWE-bench Pro V2 / element-hq/element-web / 課題 7c63d525 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 6 ：連絡先の件数表示と複数形を直す

課題文の抜粋（原文）

The label displays “N email addresses,” using correct singular/plural forms based on the number of email addresses shown.

Proton Mail の連絡先グループ。「メンバー数」という表示を、メールアドレス数に合わせる。

SWE-bench Pro V2 / protonmail/webclients / 課題 32ff1099 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

翻訳と複数形の仕組みに合わせる

- Contact Group Details の表示を、 1 件なら email address 、複数なら email addresses にする。
- プロジェクトの翻訳・複数形の仕組みを使い、同じモーダル内の件数表示をそろえる。複数件と単数の 2 テストで確認する。

SWE-bench Pro V2 / protonmail/webclients / 課題 32ff1099 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 7 ：保存した認証情報の復号失敗を伝える

課題文の抜粋（原文）

When the credentials decryption performed by the native credentials encryption fails with the application's `CryptoError`, it must throw a `KeyPermanentlyInvalidatedError`, so that credentials which cannot be decrypted are reported to the caller as permanently invalidated.

Tuta のデスクトップ版。鍵が合わず保存済みの認証情報を復号できないとき、上位の処理が無効化を認識できるようにする。

SWE-bench Pro V2 / tutao/tutanota / 課題 de49d486 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

2 層のエラーを、呼び出し元へ伝える

- 暗号ライブラリが投げる CryptoError を、アプリが定義した同名の CryptoError へ包み直す。
- 認証情報の復号層は、それを KeyPermanentlyInvalidatedError へ変換する。 2 つの層のエラー変換を、それぞれテストで確認する。

SWE-bench Pro V2 / tutao/tutanota / 課題 de49d486 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 8 ： macOS の X11 ソケットを解決する

課題文の抜粋（原文）

When `HostName` begins with `/`, `unixSocket()` must check whether the path `<HostName>:<display_number>` exists on the filesystem and if it does, must return it as the resolved unix socket address.

Teleport の X11 転送。 macOS の XQuartz が使うソケットのパスを解決し、リモートの GUI アプリを起動できるようにする。

SWE-bench Pro V2 / gravitational/teleport / 課題 1b08e7d0 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

ホスト名の形式で、ソケットの扱いを変える

- HostName が unix または空なら、 X11 用ディレクトリと表示番号からソケットを決める。 / で始まるなら、指定パスに表示番号を加えて存在を確かめる。
- / で始まる HostName を TCP へ渡した場合はエラーにする。修正確認 2 件と既存 13 件を採点する。

SWE-bench Pro V2 / gravitational/teleport / 課題 1b08e7d0 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例９：投票者一覧に閲覧権限を適用する

課題文の抜粋（原文）

If the caller lacks `topics:read` on the relevant category for a supplied post ID, `SocketPosts.getUpvoters` must reject with the exact message `[[error:no-privileges]]` and return no upvoter data.

NodeBB の権限検証。投稿を読めない利用者へ、その投稿への賛成投票者を返さない。

SWE-bench Pro V2 / NodeBB/NodeBB / 課題 82562bec 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

投稿のカテゴリから閲覧権限を調べる

- 投稿 ID からカテゴリを調べ、管理者以外にはそのカテゴリの topics:read 権限を要求する。権限がなければ指定のエラーを返す。
- 修正確認 1 件と既存 119 件を採点する。参照パッチはブラウザー側の投票表示とサーバー側の権限処理を変更する。

SWE-bench Pro V2 / NodeBB/NodeBB / 課題 82562bec 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 10 ：複数ポートを 1 規則で指定する

課題文の抜粋（原文）

When `destination_ports` is non-empty, use `append_match` and `append_csv` to generate `-m multiport --dports <comma-separated-ports>`.

Ansible の iptables モジュール。ポート番号や範囲のリストを受け取り、複数ポートを 1 つの規則で扱う。

SWE-bench Pro V2 / ansible/ansible / 課題 83fb24b9 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

指定順序で、複数ポートの引数を組み立てる

- destination_ports を空リスト既定のパラメーターとして追加する。値があれば、 multiport とカンマ区切りの --dports を生成する。
- 生成する引数は -j の後、 -i の前へ置く。 tcp ・ udp ・ udplite ・ dccp ・ sctp で利用する。指定の修正テストと既存テストで確認する。

SWE-bench Pro V2 / ansible/ansible / 課題 83fb24b9 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

2. 構成と実行条件

公開バージョン 2 のリポジトリ別の課題数

リポジトリ	課題数
ansible/ansible	82
internetarchive/openlibrary	82
flipt-io/flipt	78
qutebrowser/qutebrowser	73
gravitational/teleport	68
future-architect/vuls	58

全 642 課題。配布ディレクトリと従来データの課題 ID を照合して集計。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

公開バージョン 2 のリポジトリ別の課題数

リポジトリ	課題数
protonmail/webclients	55
element-hq/element-web	52
navidrome/navidrome	52
NodeBB/NodeBB	38
tutao/tutanota	4

全 642 課題。配布ディレクトリと従来データの課題 ID を照合して集計。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

採点環境は、テストの状態も復元する

- バージョン 2 の採点スクリプトは、隠れたテストのパスを復元・除去してから、配布テストパッチを適用する。
- 作業中に変えられた fixture と snapshot を戻し、古い Python バイトコードを削除する。 Git の index.lock が復元を妨げる問題も修正した。
- 結果の JSON から PASSED のテスト名を集め、FAIL_TO_PASS と PASS_TO_PASS の和集合がすべて含まれるかを判定する。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

データ・コンテナ・元のコードの条件を確認する

- 取得した SWE-bench Pro 公開リポジトリの LICENSE は MIT 。課題文、実行・採点コード、参照修正を同じ改訂で確認できる。
- 各課題が対象とするソフトウェアには、それぞれのライセンスがある。参照コードやコンテナを再配布するときは対象プロジェクトの条件も確認する。
- GitHub の v2/SHA256SUMS は配布ファイルのチェックサム。HARD-51 の ID 一覧と、実行条件を固定するツールも同じディレクトリにある。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

3. 著者と参考文献

Scale AI が、課題と実行環境を公開した

- 論文の共同第一著者は Xiang Deng と Jeff Da 。 Scale AI の研究として、ソフトウェア開発エージェントの実務的な評価を目的に制作した。
- 論文は 2025 年 9 月に公開。本資料の当初データとモデル比較は、 2025 年 11 月 14 日の論文 v2 に基づく。
- データのバージョン 2 は 2026 年 9 月 22 日に公開した別の更新。課題文・テスト・コンテナ・評価手順の修正を含む。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

参考文献

SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks?

Xiang Deng, Jeff Da et al. / Scale AI / 2025 / 論文 v2

当初の設計、課題の作成工程、集合の構成、モデルによる評価。

https://arxiv.org/abs/2509.16941v2

SWE-bench_Pro

Scale AI / Hugging Face Datasets / 改訂 2d52cb3

バージョン 2 、 HARD-51 、従来バージョン 1 の公開データ。

https://huggingface.co/datasets/ScaleAI/SWE-bench_Pro

参考文献

SWE-bench Pro V2: validated tasks and locked protocol

Scale AI / GitHub / 2026 / 改訂 66f9276

642 課題の修正、 50 分の評価手順、再採点と追加サブセット。

https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2

SWE-bench Pro V2: Release gate

Scale AI / Harbor 0.22 ・ Modal / 2026-09-22

参照パッチ・空パッチ・公開コンテナを全件確認した記録。

https://github.com/scaleapi/SWE-bench_Pro-os/blob/66f9276/v2/GATE.md

参考文献

SWE-bench Pro V2: task instructions and verifiers

Scale AI / GitHub / 改訂 66f9276 / 各例の課題 ID は掲載ページに記載

実例の課題文・参照修正・テスト条件と、課題数の集計元。

https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks

Gemini 3.1 Pro

Google DeepMind / 2026 / Model performance

SWE-Bench Pro (Public) の公式モデル比較と推論設定。

https://deepmind.google/models/gemini/pro/