SWE-bench Pro

実際のコードベースで、不具合修正と機能追加を評価する
人が補った要件・テスト・実行環境を持つ開発課題

sasakiy84

SWE-bench Pro の公式サイト



https://labs.scale.com/papers/swe-bench-pro

1. コード修正の課題と実例

2. テストによる採点とモデル評価

3. 作成方法とバージョン２

4. 入手・実行とまとめ

1. コード修正の課題と実例

リポジトリを読み、動く変更を提出する

- SWE-bench Pro は、実際のソフトウェアを対象に、不具合修正や機能追加を行うエージェントの評価データセット。2025 年に Scale AI が公開した。
- エージェントはコードベースと課題文を受け取り、ファイルを調べ、編集し、テストを実行して変更を作る。提出物はコードの差分パッチ。
- Python ・ JavaScript ・ TypeScript ・ Go のプロジェクトを扱い、画面、認証、検索、データ処理などの変更を含む。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

要件を補い、複数ファイルの変更を扱う

- SWE-bench は GitHub の不具合報告からコード修正を評価する枠組み。 SWE-bench Verified は、そのうち人が検証した 500 課題の集合である。
- Pro では、業務アプリや開発ツールなどの対象を広げ、長い修正や複数ファイルの変更を扱う。問題文に人手で要件と必要なインターフェースを補う。
- 公開側はコピーレフトのリポジトリを選び、非公開の商用コードも別集合として用意した。既知のコードへの依存を減らすことも設計の狙いである。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

本資料の実例は、公開バージョン 2 から選ぶ

対象	公開課題数	公開時期
従来バージョン 1	731	2025 年
検証を改めたバージョン 2	642	2026-09-22
バージョン 2 内の HARD-51	51	2026-09-22

実例はバージョン 2 から本編 3 件・ Appendix10 件を選んだ。
HARD-51 は難しい課題を選んだサブセット。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

課題文・コード・テストが 1 課題を構成する

役割	エージェントに渡すもの／判定に使うもの
課題文	変更の背景、満たす要件、必要な関数や型
作業環境	修正前コミットのコードと依存関係
提出物	編集したファイルの差分パッチ
採点	用意されたテストを実行した結果

各実例は、課題と公開元の修正例（参照修正）を 2 枚で説明する。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

実例１：アップロード先が存在するか確かめる

NodeBB は掲示板ソフト。管理画面で存在しないフォルダーにアップロードするとき、処理を始める前にエラーにする。

課題文の抜粋（原文）

> The system must validate the existence of the target directory before processing any file upload request.

SWE-bench Pro V2 / NodeBB/NodeBB / 課題 f9ce92df 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

実例 1 ：参照修正の解説

変更後の動作

存在しないフォルダーを指定したら、保存を始めずに [[error:invalid-path]] を返す。

参照修正が行うこと

設定済みの保存先と指定フォルダーを結合し、その場所の存在を調べる。存在しなければ処理を終える。

テストが確認すること

存在しない保存先を拒否する 1 件と、既存のアップロード・削除・取得など 34 件のテストを通す。

SWE-bench Pro V2 / NodeBB/NodeBB / 課題 f9ce92df 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

実例２：アルバムの保存場所を集約する

Navidrome は音楽サーバー。曲ファイルの親フォルダーを重複なく集め、アルバムから保存場所を参照できるようにする。

課題文の抜粋（原文）

> The `Album` struct must include an exported `Paths` field of type `string`, holding the aggregated unique directory paths of the album's media files, joined by the platform's list separator (`filepath.ListSeparator`).

SWE-bench Pro V2 / navidrome/navidrome / 課題 c90468b8 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

実例２：参照修正の解説

変更後の動作

/music1/file1.mp3 と /music2/file2.mp3 を集約すると、 Unix 上の Paths は /music1:/music2 になる。

参照修正が行うこと

曲ファイルの親フォルダーを重複なく集めて Paths へ保存する。曲を集約する処理と、アルバム型・ DB の保存項目を変える。

テストが確認すること

保存場所の集約と、画像を埋め込んだ曲のパスの保持を確認する。2 曲目だけに画像があれば、そちらのパスを残す。

SWE-bench Pro V2 / navidrome/navidrome / 課題 c90468b8 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

実例３： Qt の新しいエラー通知に合わせる

qutebrowser はキーボード中心の Web ブラウザー。通信エラーの初回通知を、 Qt の新しいシグナル errorOccurred へ変更する。

課題文の抜粋（原文）

> In the WebKit `NetworkReply` implementation, the initial error emission should use the `errorOccurred` signal with the error code, instead of the legacy `error` signal.

SWE-bench Pro V2 / qutebrowser/qutebrowser / 課題 0833b5f6 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

実例 3 ：参照修正の解説

変更後の動作

通信エラーの通知を受け取る側が、 Qt の新しい errorOccurred シグナルでエラーコードを取得できるようにする。

参照修正が行うこと

エラー発生時の通知を error から errorOccurred へ変更する。関連処理も、 Qt のバージョンに合わせて接続・解除する。

テストが確認すること

新しい通知が発生する 1 件と、既存の通信処理を確かめる 9 件のテストを通す。

SWE-bench Pro V2 / qutebrowser/qutebrowser / 課題 0833b5f6 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

2. テストによる採点とモデル評価

必要なテストがすべて通れば、課題の合格

テストの集合	確かめる内容
FAIL_TO_PASS	修正前は失敗し、修正後に通るべきテスト
PASS_TO_PASS	修正の前後で、通り続けるべきテスト

課題ごとに、両集合の全テストが PASSED なら合格（1）。
解決率 = 合格した課題数 / 評価した課題数 × 100 。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

アップロードの例は、 1 件の修正と 34 件の維持

確認するもの	指定テスト数
存在しない保存先へのアップロードを拒否	1
既存のアップロード・削除・取得など	34

NodeBB の実例 1 の tests/config.json 。
35 件すべての通過を求める。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

論文の公開集合では、解決率は約 4 割

モデル／推論設定	解決率
Claude Sonnet 4.5	43.6%
Claude Sonnet 4	42.7%
GPT-5 / high	41.8%
Claude Haiku 4.5	39.5%

2025 年の論文 v2 、従来の公開 731 課題、 SWE-agent 、最大 50 ターン。
問題文・要件・インターフェースを提示した 1 回試行。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

現行モデルの公式比較にも採用されている

モデル／推論設定	解決率
Gemini 3.1 Pro / high	54.2%
Gemini 3 Pro / high	43.3%
GPT-5.2 / xhigh	55.6%
GPT-5.3-Codex / xhigh	56.8%

Google 公式比較（ 2026 年参照）： SWE-Bench Pro (Public) 、 1 回試行。
掲載表にはデータのバージョン指定がない。

Google DeepMind (2026). Gemini 3.1 Pro. Performance. 2026-10-17 参照。 https://deepmind.google/models/gemini/pro/

バージョン 2 は、別の環境で提出差分を採点する

- エージェントの作業時間は 1 課題 50 分。外部 Web 検索・取得を無効にし、通信はモデル API への接続だけを許す。
- 作業後に git diff を保存し、新しいコンテナへ適用する。テストは、この初期状態から作った環境で実行する。
- 作業環境での得点と再採点した得点の両方を報告し、正式な結果には再採点の値を使う。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

公開前に、参照修正と空の修正を全件実行した

バージョン 2 の公開元による確認	課題数
参照パッチで合格	642 / 642
空パッチで不合格	642 / 642
公開コンテナの配布情報を確認	642 / 642

2026 年 9 月 22 日の公開確認。 Harbor 0.22 、 Modal 。
実行基盤の一時エラーは再試行して確認している。

Scale AI (2026). SWE-bench Pro V2: Release gate. Harbor 0.22 / Modal 。
https://github.com/scaleapi/SWE-bench_Pro-os/blob/66f92766bba642462d4bbe5479e83f91f9211862/v2/GATE.md

HARD-51 は、難しい 51 課題を抜き出す

- バージョン 2 の 642 課題のうち、 5 モデル系列中 2 系列以上が失敗した課題を基に選んだサブセット。曖昧さが見つかった 3 課題を除き、 51 課題を収録する。
- 選定に使った系列は Claude Opus 5 、 GLM-5.3 、 Kimi-K3 、 Inkling 、 Gemini 3.8 Flash 。固定の評価手順で実行した結果に基づく。
- Hugging Face の hard 設定、または公開された課題 ID 一覧から利用できる。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

3. 作成方法とバージョン 2

コミット間の変更を、課題と正解へ分ける

- 開発履歴から、問題の解決を含む連続したコミットの組を選ぶ。古い方を、エージェントが作業する修正前の状態にする。
- 差分のうちテスト関連の変更を採点用のテストパッチにし、それ以外を参照修正の gold patch として分ける。
- 公開・留保集合ではコピーレフトのプロジェクトを使い、商用集合では提携したスタートアップの非公開コードを用いた。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

背景・要件・インターフェースを人が補う

- コミット、 Issue 、 PR の説明を集め、変更の動機と問題を課題文にまとめる。元資料だけでは不足する仕様を補う。
- テストで求める動作を、要件として具体化する。 API の名前、入力に応じた返り値、エラー時の振る舞いも必要に応じて示す。
- 新しいクラスや関数を作る課題では、そのインターフェースも記す。実装の自由度を保ちながら、テストが期待する呼び出し方を伝える。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

環境を構築し、テストの関連性を確かめる

- ソフトウェア技術者が、依存ライブラリとビルド手順を含む Docker 環境を作る。参照修正が通ることを繰り返し確認する。
- テストを人が調べ、課題に無関係なものや、要求を広く取りすぎるものを外す。有効なテストが残らない課題は除く。
- バージョン 2 では問題文とテストの対応、テスト環境の復元、依存関係を改めて点検した。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

当初の全 1,865 課題は、 3 集合からなる

集合	課題数	リポジトリ数	公開範囲
公開	731	11	問題・結果
商用	276	18	結果
留保	858	12	非公開

2025 年論文の構成。集合間ではリポジトリを分ける。
バージョン 2 は、このうち公開集合を見直したもの。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

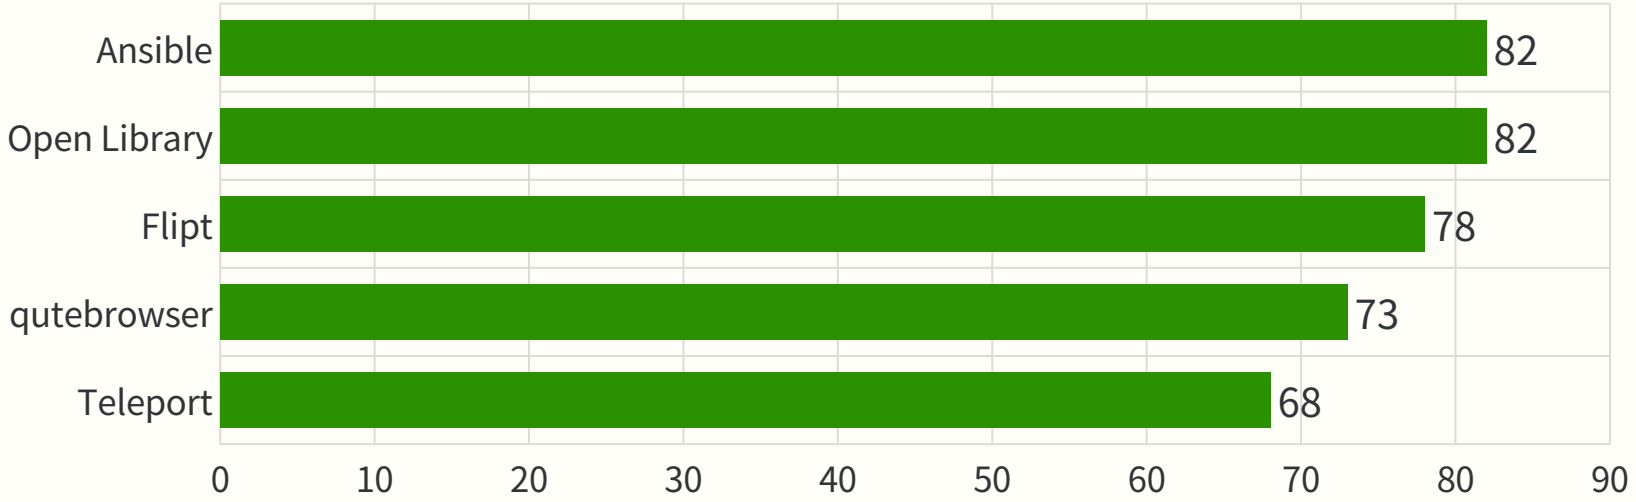
バージョン 2 では、 89 課題を除外した

変更対象	公開元が報告した変更
課題数	731 → 642 （ 11 リポジトリは継続）
課題文	529 件を書き直し、別の技術者が実装・検証
採点用テスト	全 642 件で復元手順を改修、 214 件の差分を修正
参照修正・環境	38 件の参照差分、 211 件の依存関係を修正

要求文と採点条件の対応を確かめ、各課題の修正前コミットは維持。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

公開バージョン 2 は、 11 プロジェクトを扱う



課題数の上位 5 件。計 642 課題を配布ディレクトリから集計。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

4. 入手・実行とまとめ

データ設定と実行手順を対応させる

- Hugging Face では default がバージョン 2 の 642 課題、hard が HARD-51 、 v1 が従来の 731 課題。
- バージョン 2 は GitHub の v2/tasks 以下に、課題文・採点スクリプト・参照パッチをまとめる。公開コンテナは GitHub の配布サービス GHCR で提供する。
- 実行制御に Harbor 、クラウド環境に Modal を使う。モデル、エージェント、通信条件、時間予算、再採点の方法を記録する。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

公開課題と参照修正を取得する

```
git clone https://github.com/scaleapi/SWE-bench_Pro-os
cd SWE-bench_Pro-os
uv tool install 'harbor[modal]>=0.22'
modal setup
harbor run -p v2/tasks -e modal -n 50 -a oracle
```

公式の参照修正による動作確認。モデル評価ではエージェントを指定し、提出差分を新しい環境へ適用して再採点する。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

仕様を読み、実装し、既存の動作も保つ

- SWE-bench Pro は、コードベース全体を調べながら修正や機能追加を行い、テストで合否を決める評価である。
- 人が補った要件とインターフェース、複数言語・用途のプロジェクト、課題ごとの実行環境を組み合わせる。
- 公開バージョン 2 は 642 課題。課題文と採点環境を改めて検証し、難しい 51 課題を選ぶ HARD-51 も提供する。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

Appendix

1. 公開課題の追加例

2. 構成と実行条件

3. 著者と参考文献

1. 公開課題の追加例

追加例 1 ： Python の予約語を名前から除く

Ansible のコレクション名検証。名前空間と名前の両方を検査し、 Python の予約語を受け付けない。

課題文の抜粋（原文）

> Collection names like `def.collection`, `return.module`, `assert.test`, and `import.utils` are accepted during validation when they should be rejected.

SWE-bench Pro V2 / ansible/ansible / 課題 f327e65d 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 1 ：参照修正の解説

変更後の動作

def.collection のように Python の予約語を含む名前は、名前の検証結果を False にする。

参照修正が行うこと

ピリオドで分けた前後の両方を検査する。どちらも Python の識別子として有効で、予約語でない場合だけ True を返す。

テストが確認すること

def や return などを含む 4 件を拒否できるか確認し、正常な名前の検証など 171 件の既存テストも通す。

SWE-bench Pro V2 / ansible/ansible / 課題 f327e65d 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 2 ：検索条件の引用符を正規化する

Open Library の蔵書検索。元の検索文字列を保持し、版の ID を指定する条件の引用符とパスを整える。

課題文の抜粋（原文）

> `q_to_solr_params` must include a parameter named `userWorkQuery` whose value is exactly the user's original query string.

SWE-bench Pro V2 / internetarchive/openlibrary / 課題 427f1f4e 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 2 ：参照修正の解説

変更後の動作

edition_key:OL123M を、 +key:"/books/OL123M" へ変換する。版の ID を、検索側が扱うパスと引用符へそろえる。

参照修正が行うこと

元の検索式を userWorkQuery 、版の検索式を userEdQuery へ保存する。検索式を別の式へ埋め込む際は、この名前で参照する。

テストが確認すること

裸の ID 、引用付き ID 、完全パス、括弧、 OR の 5 形式を正規化できるか確認し、既存 4 件も通す。

SWE-bench Pro V2 / internetarchive/openlibrary / 課題 427f1f4e 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例３：読み取り専用の設定を追加する

Flipt は機能フラグを管理するサービス。ストレージ設定に ReadOnly を加え、保存形式と値の検証をそろえる。

課題文の抜粋（原文）

> `StorageConfig` must include a `ReadOnly *bool` field exposed as `storage.readOnly`, using `readOnly` as its key in both YAML and JSON configuration.

SWE-bench Pro V2 / flipt-io/flipt / 課題 abaa5953 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例３：参照修正の解説

変更後の動作

設定ファイルで storage.readOnly を指定できるようにする。 YAML と JSON で同じ readOnly というキーを使う。

参照修正が行うこと

保存先の設定型に ReadOnly を加える。未指定と false を区別し、false かつ保存先が DATABASE 以外ならエラーにする。

テストが確認すること

TestLoad で、設定が読み込まれることと、許されない組み合わせが指定のエラーメッセージになることを確かめる。

SWE-bench Pro V2 / flipt-io/flipt / 課題 abaa5953 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 4 ：フィルターで除外した脆弱性数を返す

Vuls は脆弱性検査ツール。フィルター後の一覧に加え、各条件で何件を除外したかも返す。

課題文の抜粋（原文）

> `FilterByCvssOver`, `FilterByConfidenceOver`, `FilterIgnoreCves`, `FilterUnfixed`, and `FilterIgnorePkgs` must each return two values: the filtered `VulnInfos` and an `int` representing the number of vulnerabilities excluded by the filter.

SWE-bench Pro V2 / future-architect/vuls / 課題 86596681 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 4 ：参照修正の解説

変更後の動作

脆弱性のフィルター処理が、条件に合う一覧に加えて、条件によって何件を除外したかも返す。

参照修正が行うこと

深刻度・信頼度・除外指定など 5 種類の処理で、残った一覧と除外数を返す。呼び出し側は、その件数をログへ記録する。

テストが確認すること

条件に応じた一覧と除外数になるか、 15 件の修正確認テストで調べる。

SWE-bench Pro V2 / future-architect/vuls / 課題 86596681 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 5 ：入力欄の案内を空のときだけ表示する

Element Web のメッセージ入力欄。未入力時の案内文を、リッチテキストとプレーンテキストの両方で切り替える。

課題文の抜粋（原文）

> The placeholder must hide as soon as content is entered and must show again if all content is cleared.

SWE-bench Pro V2 / element-hq/element-web / 課題 7c63d525 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 5 ：参照修正の解説

変更後の動作

メッセージ入力欄が空なら案内文を表示する。文字を入力すると隠し、すべて消すと再び表示する。

参照修正が行うこと

画面から入力部品へ案内文を渡す。入力内容の有無に応じて案内文と CSS クラスを切り替え、表示状態を更新する。

テストが確認すること

リッチテキストとプレーンテキストの両方で表示の切り替えを確認する。修正確認 4 件と既存 81 件を通す。

SWE-bench Pro V2 / element-hq/element-web / 課題 7c63d525 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 6 ：連絡先の件数表示と複数形を直す

Proton Mail の連絡先グループ。「メンバー数」という表示を、メールアドレス数に合わせる。

課題文の抜粋（原文）

> The label displays “N email addresses,” using correct singular/plural forms based on the number of email addresses shown.

SWE-bench Pro V2 / protonmail/webclients / 課題 32ff1099 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 6 ：参照修正の解説

変更後の動作

連絡先グループの表示を、 1 件なら 1 email address 、複数件なら N email addresses にする。

参照修正が行うこと

「 N members 」の表示を、メールアドレス数の表示へ置き換える。単数・複数の選択には、既存の翻訳の仕組みを使う。

テストが確認すること

グループの詳細画面で、複数件の表示と、メールアドレスが 1 件だけの表示を 2 テストで確認する。

SWE-bench Pro V2 / protonmail/webclients / 課題 32ff1099 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 7 ：保存した認証情報の復号失敗を伝える

Tuta のデスクトップ版。鍵が合わず保存済みの認証情報を復号できないとき、上位の処理が無効化を認識できるようにする。

課題文の抜粋（原文）

> When the credentials decryption performed by the native credentials encryption fails with the application's `CryptoError`, it must throw a `KeyPermanentlyInvalidatedError`, so that credentials which cannot be decrypted are reported to the caller as permanently invalidated.

SWE-bench Pro V2 / tutao/tutanota / 課題 de49d486 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 7 ：参照修正の解説

変更後の動作

保存済みの認証情報を復号できないとき、呼び出し元が「この鍵では復号できない」と判別できるようにする。

参照修正が行うこと

ライブラリの例外をアプリ共通の CryptoError へ変え、上位で KeyPermanentlyInvalidatedError へ変換する。

テストが確認すること

ライブラリからアプリへ、アプリから認証情報の無効化へ、 2 段階の例外変換をそれぞれテストする。

SWE-bench Pro V2 / tutao/tutanota / 課題 de49d486 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 8 ： macOS の X11 ソケットを解決する

Teleport の X11 転送。 macOS の XQuartz が使うソケットのパスを解決し、リモートの GUI アプリを起動できるようにする。

課題文の抜粋（原文）

> When `HostName` begins with `/`, `unixSocket()` must check whether the path `<HostName>:<display_number>` exists on the filesystem and if it does, must return it as the resolved unix socket address.

SWE-bench Pro V2 / gravitational/teleport / 課題 1b08e7d0 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 8 ：参照修正の解説

変更後の動作

macOS の XQuartz が使う、 / で始まるソケットのパスから、画面表示用の通信先を解決できるようにする。

参照修正が行うこと

パスに表示番号を加え、ファイルがあれば Unix ソケットとして扱う。 TCP の接続先としては拒否する。

テストが確認すること

完全パスのソケット解決などの修正確認 2 件と、既存の表示指定・通信処理を確かめる 13 件を通す。

SWE-bench Pro V2 / gravitational/teleport / 課題 1b08e7d0 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 9 ：投票者一覧に閲覧権限を適用する

NodeBB の権限検証。投稿を読めない利用者へ、その投稿への賛成投票者を返さない。

課題文の抜粋（原文）

> If the caller lacks `topics:read` on the relevant category for a supplied post ID, `SocketPosts.getUpvoters` must reject with the exact message `[[error:no-privileges]]` and return no upvoter data.

SWE-bench Pro V2 / NodeBB/NodeBB / 課題 82562bec 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 9 ：参照修正の解説

変更後の動作

その投稿を読む権限のない利用者には、賛成投票者の一覧を返さず、 [[error:no-privileges]] で終了する。

参照修正が行うこと

投稿 ID から所属カテゴリを調べる。管理者以外には、そのカテゴリの topics:read 権限があることを確認する。

テストが確認すること

閲覧権限のない利用者を拒否する 1 件と、既存の投稿操作・投票処理など 119 件を通す。

SWE-bench Pro V2 / NodeBB/NodeBB / 課題 82562bec 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 10 ：複数ポートを 1 規則で指定する

Ansible の iptables モジュール。ポート番号や範囲のリストを受け取り、複数ポートを 1 つの規則で扱う。

課題文の抜粋（原文）

> When `destination_ports` is non-empty, use `append_match` and `append_csv` to generate `-m multiport --dports <comma-separated-ports>`.

SWE-bench Pro V2 / ansible/ansible / 課題 83fb24b9 。配布課題文の抜粋・日本語要約。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

追加例 10 ：参照修正の解説

変更後の動作

ポートごとに規則を作る代わりに、 destination_ports で複数ポートやポート範囲をまとめて指定できるようにする。

参照修正が行うこと

受け取ったリストをカンマで結び、 -m multiport --dports の引数を作る。空リストなら、この引数を加えない。

テストが確認すること

指定したポートが生成コマンドへ入り、既存の引数の順序を保つか確認する。修正確認 1 件と既存 21 件を通す。

SWE-bench Pro V2 / ansible/ansible / 課題 83fb24b9 。配布参照修正・採点テストの解説。
https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks/

2. 構成と実行条件

公開バージョン 2 のリポジトリ別の課題数

リポジトリ	課題数
ansible/ansible	82
internetarchive/openlibrary	82
flipt-io/flipt	78
qutebrowser/qutebrowser	73
gravitational/teleport	68
future-architect/vuls	58

全 642 課題。配布ディレクトリと従来データの課題 ID を照合して集計。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

公開バージョン 2 のリポジトリ別の課題数

リポジトリ	課題数
protonmail/webclients	55
element-hq/element-web	52
navidrome/navidrome	52
NodeBB/NodeBB	38
tutao/tutanota	4

全 642 課題。配布ディレクトリと従来データの課題 ID を照合して集計。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

採点環境は、テストの状態も復元する

- バージョン 2 の採点スクリプトは、隠れたテストのパスを復元・除去してから、配布テストパッチを適用する。
- 作業中に変えられた fixture と snapshot を戻し、古い Python バイトコードを削除する。 Git の index.lock が復元を妨げる問題も修正した。
- 結果の JSON から PASSED のテスト名を集め、FAIL_TO_PASS と PASS_TO_PASS の和集合がすべて含まれるかを判定する。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

データ・コンテナ・元のコードの条件を確認する

- 取得した SWE-bench Pro 公開リポジトリの LICENSE は MIT 。課題文、実行・採点コード、参照修正を同じ改訂で確認できる。
- 各課題が対象とするソフトウェアには、それぞれのライセンスがある。参照コードやコンテナを再配布するときは対象プロジェクトの条件も確認する。
- GitHub の v2/SHA256SUMS は配布ファイルのチェックサム。HARD-51 の ID 一覧と、実行条件を固定するツールも同じディレクトリにある。

Scale AI. SWE-bench Pro V2. 2026-09-22 公開。改訂 66f9276 。 https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f92766bba642462d4bbe5479e83f91f9211862/v2

3. 著者と参考文献

Scale AI が、課題と実行環境を公開した

- 論文の共同第一著者は Xiang Deng と Jeff Da 。 Scale AI の研究として、ソフトウェア開発エージェントの実務的な評価を目的に制作した。
- 論文は 2025 年 9 月に公開。本資料の当初データとモデル比較は、 2025 年 11 月 14 日の論文 v2 に基づく。
- データのバージョン 2 は 2026 年 9 月 22 日に公開した別の更新。課題文・テスト・コンテナ・評価手順の修正を含む。

Deng, Da et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? 論文 v2 。 https://arxiv.org/abs/2509.16941v2

参考文献

SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks?

Xiang Deng, Jeff Da et al. / Scale AI / 2025 / 論文 v2

当初の設計、課題の作成工程、集合の構成、モデルによる評価。

https://arxiv.org/abs/2509.16941v2

SWE-bench_Pro

Scale AI / Hugging Face Datasets / 改訂 2d52cb3

バージョン 2 、 HARD-51 、従来バージョン 1 の公開データ。

https://huggingface.co/datasets/ScaleAI/SWE-bench_Pro

参考文献

SWE-bench Pro V2: validated tasks and locked protocol

Scale AI / GitHub / 2026 / 改訂 66f9276

642 課題の修正、 50 分の評価手順、再採点と追加サブセット。

https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2

SWE-bench Pro V2: Release gate

Scale AI / Harbor 0.22 ・ Modal / 2026-09-22

参照パッチ・空パッチ・公開コンテナを全件確認した記録。

https://github.com/scaleapi/SWE-bench_Pro-os/blob/66f9276/v2/GATE.md

参考文献

SWE-bench Pro V2: task instructions and verifiers

Scale AI / GitHub / 改訂 66f9276 / 各例の課題 ID は掲載ページに記載

実例の課題文・参照修正・テスト条件と、課題数の集計元。

https://github.com/scaleapi/SWE-bench_Pro-os/tree/66f9276/v2/tasks

Gemini 3.1 Pro

Google DeepMind / 2026 / Model performance

SWE-Bench Pro (Public) の公式モデル比較と推論設定。

https://deepmind.google/models/gemini/pro/