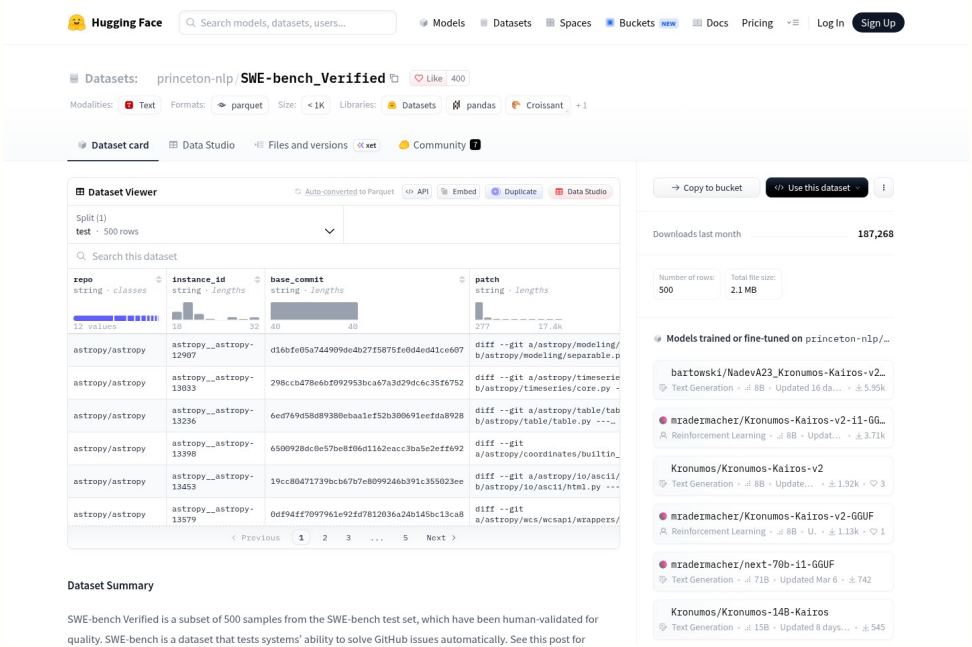
SWE-bench Verified

GitHub の不具合報告を読み、コードを修正する能力を
人間が検証した 500 課題で評価するデータセット

sasakiy84

SWE-bench Verified の公式配布ページ



SWE-bench team. SWE-bench Verified. Hugging Face 公式配布ページ。 2026-10-16 参照。 https://huggingface.co/datasets/princeton-nlp/SWE-bench_Verified

1. 不具合報告とコード修正の実例

2. テストによる採点とモデル評価

3. 課題の作成と 500 件の構成

4. 系列の発展と評価の実行

1. 不具合報告とコード修正の実例

既存のコードベースを直して Issue を解決する

- SWE-bench は、 GitHub にある実際の不具合報告や機能要求を、解決した Pull Request と対応させた評価である。
- モデルには Issue の本文と修正前のリポジトリを与え、変更を表すパッチを提出させる。
- Verified は、問題文・テスト・解決可能性を人が確認して選んだ 500 課題。 2024 年 8 月に公開された。

SWE-bench team. SWE-bench Verified: Overview. 人による検証。 2026-10-16 参照。 https://www.swebench.com/verified.html

入力は Issue とコード、出力は修正パッチ

役割	内容
モデルへの入力	問題文と base_commit 時点のコード
提出するもの	コードの差分を記述したパッチ
採点側が使うもの	参照テストと期待されるテスト結果

base_commit は、修正を始める時点の Git コミットを指定する。

Jimenez et al. (2024). SWE-bench: Can Language Models Resolve Real-World GitHub Issues? ICLR 2024. https://arxiv.org/abs/2310.06770v3

公開テスト集合から 13 課題を紹介する

- 本資料の実例は、公式タスク配布リポジトリで Verified に属する 500 課題から選んだ。
- Flask ・ Requests ・ SymPy の 3 課題を本編、残り 10 課題を Appendix に置く。全体で 12 リポジトリを扱う。
- Issue の原文・要約と、配布されている参照パッチの変更箇所を対応させる。

SWE-bench team. SWE-bench task data. Verified 500 課題、改訂 3d07b46 を集計。 2026-10-16 。 https://github.com/SWE-bench/swe-bench-tasks

実例 1 ：空の Blueprint 名を拒否する

公開 Issue の本文（原文）

Require a non-empty name for Blueprints
Things do not work correctly if a Blueprint is given an empty name (e.g. #4944).
It would be helpful if a `ValueError` was raised when trying to do that.

Flask の Blueprint はルートをまとめる仕組み。名前が空なら ValueError を出してほしい、という要求である。

SWE-bench team. SWE-bench Verified. pallets__flask-5014 / problem_statement.md.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/pallets__flask-5014/problem_statement.md

Flask ：名前の検証に条件を加える

配布参照パッチの変更箇所（抜粋）

```
+         if not name:
+             raise ValueError("'name' may not be empty.")
```

Blueprint の初期化で空の名前を検出する。参照テストは、空の名前で ValueError が出ることを確かめる。

SWE-bench team. SWE-bench Verified. pallets__flask-5014 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/pallets__flask-5014/gold.patch

実例２： None の既定ヘッダーを送らない

```
session = requests.Session()
# Do not send Accept-Encoding
session.headers['Accept-Encoding'] = None
```

公開 Issue の再現コード（抜粋）。 None を指定しても「 Accept-Encoding: None 」が送られるため、ヘッダー自体を除外したい。

SWE-bench team. SWE-bench Verified. psf__requests-1921 / problem_statement.md.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/psf__requests-1921/problem_statement.md

Requests ：結合後のヘッダーから None を除く

配布参照パッチの変更箇所（抜粋）

```
dict((k, v) for (k, v) in merged_setting.items() if v is not None)
```

要求単位の設定とセッション設定を結合した後、 None の項目を除く。
ヘッダーの送信前に修正する。

SWE-bench team. SWE-bench Verified. psf__requests-1921 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/psf__requests-1921/gold.patch

実例３：数字１のモールス符号を直す

公開 Issue の本文（原文）

Morse encoding for "1" is not correct
The current Morse mapping in simpy.crypto.crypto contains an incorrect mapping of
`"----": "1"`
The correct mapping is `".----": "1"`.

SymPy の暗号処理で、数字 1 に対応する符号の先頭の点が欠けている。期待する符号が問題文に明記されている。

SWE-bench team. SWE-bench Verified. sympy__sympy-16886 / problem_statement.md.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/sympy__sympy-16886/problem_statement.md

SymPy ：モールス符号の対応表を修正する

配布参照パッチの変更箇所（抜粋）

```
-    "-----": "0", "----": "1",
+    "-----": "0", ".----": "1",
```

参照パッチは対応表の 1 箇所を置き換える。 test_encode_morse で、符号化の結果を確かめる。

SWE-bench team. SWE-bench Verified. sympy__sympy-16886 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/sympy__sympy-16886/gold.patch

2. テストによる採点とモデル評価

不具合の修正と既存動作の維持を確認する

テストの集合	確認する内容
FAIL_TO_PASS	修正前は失敗し、修正後に成功する
PASS_TO_PASS	修正前に成功していた動作を維持する

Flask の実例には FAIL_TO_PASS が 1 件、 PASS_TO_PASS が 59 件ある。

SWE-bench team. SWE-bench evaluation harness: grading.py. 改訂 02e7a74 。 https://github.com/SWE-bench/SWE-bench/blob/02e7a74/swebench/harness/grading.py

Flask の追加テストは例外の発生を確かめる

```
def test_empty_name_not_allowed(app, client):
    with pytest.raises(ValueError):
        flask.Blueprint("", __name__)
```

配布 test.patch から追加されたテストを抜粋。空の Blueprint 名を渡し、ValueError を期待する。

SWE-bench team. SWE-bench Verified. pallets__flask-5014 / test.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/pallets__flask-5014/test.patch

対象テストを満たした課題だけを解決と数える

採点例	不具合の修正	既存動作の維持	解決
A	全件成功	全件維持	○
B	一部失敗	全件維持	×
C	全件成功	回帰あり	×

公式実装は両集合の条件を満たすと RESOLVED_FULL を返す。

SWE-bench team. SWE-bench evaluation harness: grading.py. 改訂 02e7a74 。 https://github.com/SWE-bench/SWE-bench/blob/02e7a74/swebench/harness/grading.py

解決率は、解決した課題数を全課題数で割って算出する

- 各課題の解決判定を 0 か 1 で集計する。 Verified 全 500 課題で 400 課題を解決した場合、 400 ÷ 500 × 100 = 80% 。
- 1 回の提出で得た解決率は、 1 課題に 1 つの候補パッチを採点する条件に対応する。
- 問題文・コードの探索、変更、テスト実行を含むエージェント全体の結果として評価する。

SWE-bench team. SWE-bench evaluation harness: grading.py. 改訂 02e7a74 。 https://github.com/SWE-bench/SWE-bench/blob/02e7a74/swebench/harness/grading.py

現行モデルの公式比較にも使われている

モデル／推論設定	Verified
Gemini 3.1 Pro / High	80.6%
Claude Opus 4.6 / Max	80.8%
GPT-5.2 / xhigh	80.0%

Google DeepMind の公式表、 Single attempt 条件。
High ・ Max ・ xhigh はモデルの推論設定。

Google DeepMind (2026). Gemini 3.1 Pro. Performance: SWE-Bench Verified / Single attempt. 2026-10-16 参照。 https://deepmind.google/models/gemini/pro/

コードを調べて実行するループを作る

- エージェントは、ファイル検索、コードの閲覧、パッチの適用、テスト実行を繰り返して修正を進める。
- 公式 Verified ページには任意のシステムの比較と、 mini-SWE-agent を使う Bash Only の比較がある。
- Bash Only はシェルを操作する最小限のループにモデルを組み込み、実行環境と設定をそろえて比較する。

SWE-bench team. SWE-bench Verified: Overview. 人による検証。 2026-10-16 参照。 https://www.swebench.com/verified.html

3. 課題の作成と 500 件の構成

解決済み Pull Request から課題を作る

- 元の SWE-bench では、広く使われる 12 の Python リポジトリから約 90,000 件の Pull Request を収集した。
- マージ済みで、 Issue を解決し、テストファイルも変更した Pull Request を候補とした。
- 修正前後でテストを実行し、失敗から成功に変わるテストがあるものを残した。

Jimenez et al. (2024). SWE-bench: Can Language Models Resolve Real-World GitHub Issues? ICLR 2024. https://arxiv.org/abs/2310.06770v3

問題文・参照修正・テストを分けて保存する

- Issue 本文を problem_statement 、修正開始地点を base_commit として保存する。
- Pull Request の変更を、製品コードの参照パッチと、採点用の test_patch に分ける。
- 修正前に失敗して修正後に成功するテストと、前後とも成功するテストを記録する。インストールや実行に失敗する候補は除く。

Jimenez et al. (2024). SWE-bench: Can Language Models Resolve Real-World GitHub Issues? ICLR 2024. https://arxiv.org/abs/2310.06770v3

Verified では人が 3 つの点を確認した

確認対象	人が確かめること
問題文	要求が明確に記述されている
テスト	問題を正しく検証する内容である
解決可能性	与えられた情報で課題を解ける

SWE-bench チームと OpenAI の共同作業で 500 課題を選んだ。

SWE-bench team. SWE-bench Verified: Overview. 人による検証。 2026-10-16 参照。 https://www.swebench.com/verified.html

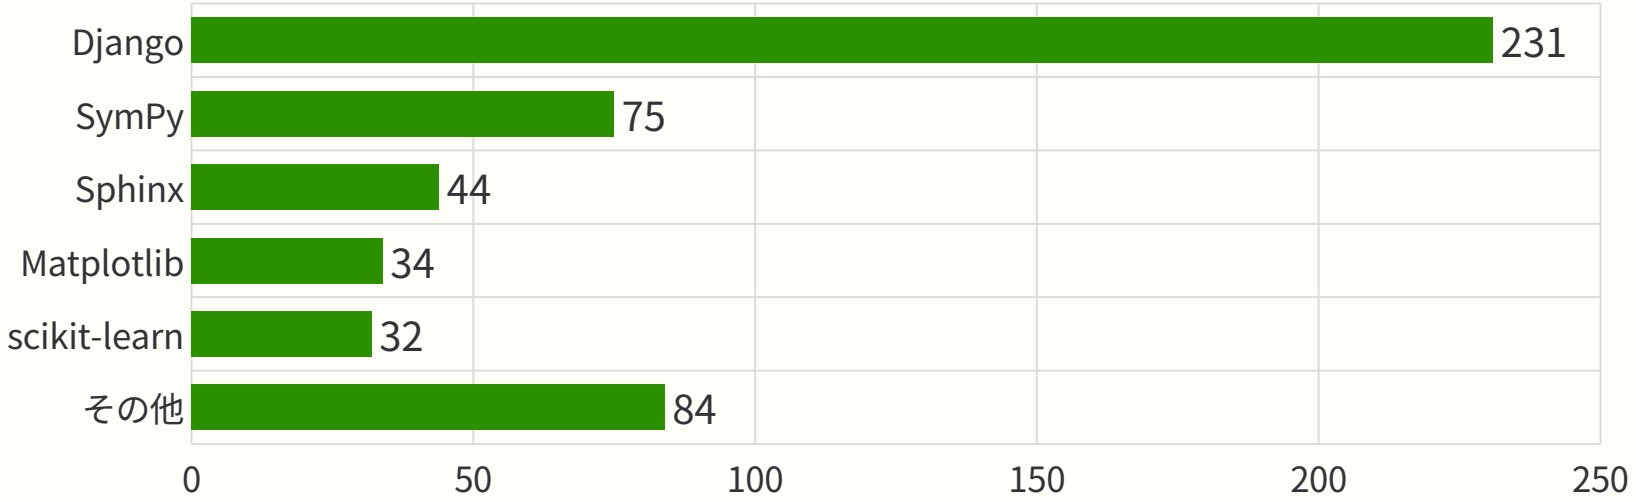
元の SWE-bench から Verified と Lite を選ぶ

データセット	test の課題数	選び方
SWE-bench	2,294	実 Issue と解決した PR
SWE-bench Lite	300	評価費用を抑える部分集合
SWE-bench Verified	500	人が品質を検証した部分集合

SWE-bench は 2023 年、 Lite と Verified は 2024 年に公開。

SWE-bench team. SWE-bench Lite. Selection criteria. 2026-10-16 参照。 https://www.swebench.com/lite.html

500 課題の 46.2% を Django が占める



Verified 全 500 課題を集計。「その他」は残り 7 リポジトリ。

SWE-bench team. SWE-bench task data. Verified 500 課題、改訂 3d07b46 を集計。 2026-10-16 。 https://github.com/SWE-bench/swe-bench-tasks

参照パッチが 1 ファイルの課題は 429 件

参照パッチの変更ファイル数	課題数
1 ファイル	429
2 ファイル	49
3 ファイル以上	22

gold.patch の diff --git 単位で集計。最大は 21 ファイル。

SWE-bench team. SWE-bench task data. Verified 500 課題、改訂 3d07b46 を集計。 2026-10-16 。 https://github.com/SWE-bench/swe-bench-tasks

参照パッチの変更行数は中央値 7 行

統計量	追加行＋削除行
中央値	7 行
平均	14.3 行
最小／最大	1 行／ 232 行

500 課題の gold.patch を集計。差分のヘッダー・文脈行を除く。

SWE-bench team. SWE-bench task data. Verified 500 課題、改訂 3d07b46 を集計。 2026-10-16 。 https://github.com/SWE-bench/swe-bench-tasks

4. 系列の発展と評価の実行

複数言語や画面を使う課題へ広がった

系列	評価する対象
Verified / 2024	人が確認した Python の 500 課題
Multilingual / 2025	9 言語・ 42 リポジトリの 300 課題
Multimodal / 2024	画面の情報を使うソフトウェア修正

Multimodal v2 は 2026 年に公開。 480 課題をローカル実行できる。

SWE-bench team. SWE-bench: README and News. 各データセットの公開情報。 2026-10-16 参照。 https://github.com/SWE-bench/SWE-bench

SWE-Bench Pro は長時間の作業を扱う別の評価

- Scale AI が 2025 年に公開した SWE-Bench Pro は、企業での開発に近い長時間の修正課題を集めた後続ベンチマーク。
- 論文の全 1,865 課題は 41 リポジトリに由来する。公開集合は 11 リポジトリの 731 課題で、非公開・商用の集合もある。
- Gemini 3.1 Pro の公式比較では Pro の Public 集合も使われる。 Verified の 500 課題とは異なる問題集合である。

Deng et al. (2025). SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks? arXiv:2509.16941v2. https://arxiv.org/abs/2509.16941v2

評価実装の第 5 版では課題をフォルダで管理する

- 2026 年 8 月の評価実装 5.0.0 で、課題ごとのファイルを置く task repo 方式が導入された。
- 問題文、テスト一覧、参照パッチ、実行環境の設定を分けて保存し、 Docker で課題環境を作る。
- 本資料の実例・集計は公式 swe-bench-tasks の改訂 3d07b46 、採点は公式コードの改訂 02e7a74 に対応する。

SWE-bench team (2026). SWE-bench Changelog. 評価実装 5.0.0 以降のタスク形式。 https://github.com/SWE-bench/SWE-bench/blob/02e7a74/CHANGELOG.md

候補パッチを渡し、テストを実行してレポートを得る

```
swebench eval verified -p predictions.jsonl \
    --run-id my-run -j 4
swebench report my-run -d verified
```

参照した公式 CLI の実行例。 predictions.jsonl に課題 ID と候補パッチを置き、用意した Docker 環境で評価する。

SWE-bench team. SWE-bench evaluation harness. 改訂 02e7a74 。 https://github.com/SWE-bench/SWE-bench

人が検証した実 Issue を、実行結果で評価する

- Verified は、元の SWE-bench から人が品質を確認した 500 課題を集め、既存 Python コードの修正を評価する。
- モデルは Issue とリポジトリからパッチを作り、不具合の修正と既存動作の維持をテストで確認する。
- 参照修正は 1 ファイル・少数行のものが多い。 12 リポジトリにまたがる実課題として、探索から実行までを評価できる。

SWE-bench team. SWE-bench task data. Verified 500 課題、改訂 3d07b46 を集計。 2026-10-16 。 https://github.com/SWE-bench/swe-bench-tasks

Appendix

1. ライブラリの異なる追加例

2. 分布・形式と採点の詳細

3. 著者と参考文献

1. ライブラリの異なる追加例

追加例 1 ： property の文書を継承する

配布参照パッチの変更箇所（抜粋）

```
inspect.isfunction(val) or inspect.isdatadescriptor(val)
```

Astropy ：関数だけを見ていた継承処理にデータ記述子の判定を加え、property も対象にする。参照パッチの条件式を抜粋。

SWE-bench team. SWE-bench Verified. astropy__astropy-7166 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/astropy__astropy-7166/gold.patch

追加例 2 ： Path 型でも重複を検出する

配布参照パッチの変更箇所（抜粋）

```
-            if app_dir in fixture_dirs:
+            if app_dir in [str(d) for d in fixture_dirs]:
```

Django ： FIXTURE_DIRS に Path オブジェクトがあると重複を検出できない。文字列へそろえて、既定の fixture ディレクトリと比較する。

SWE-bench team. SWE-bench Verified. django__django-15987 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/django__django-15987/gold.patch

追加例 3 ： 1000 未満の年も 4 桁で表示する

配布参照パッチの変更箇所（抜粋）

```
-         return self.data.year
+         return '%04d' % self.data.year
```

Django ：日付の Y 指定子は年を 4 桁で返す。整数の年をそのまま返す代わりに、先頭を 0 で埋めた文字列にする。

SWE-bench team. SWE-bench Verified. django__django-14373 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/django__django-14373/gold.patch

追加例 4 ：消した描画要素の所属を解除する

配布参照パッチの変更箇所（抜粋）

```
-         self._children = []
+         old_children, self._children = self._children, []
+         for chld in old_children:
+             chld.axes = chld.figure = None
```

Matplotlib ： Axes を clear しても、子要素に古い Axes ・ Figure への参照が残る。消した子要素の所属を None に更新する。

SWE-bench team. SWE-bench Verified. matplotlib__matplotlib-24627 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/matplotlib__matplotlib-24627/gold.patch

追加例 5 ：凡例の数値を省略表記しない

配布参照パッチの変更箇所（抜粋）

```
+         formatter.set_useOffset(False)
+         formatter.set_scientific(False)
```

Seaborn ：大きな数の凡例で倍率が表示されず、値が誤って読み取られる。参照修正は、凡例でオフセットと科学表記を使わない設定にする。

SWE-bench team. SWE-bench Verified. mwaskom__seaborn-3187 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/mwaskom__seaborn-3187/gold.patch

追加例 6 ： DataArray を変換して結合する

配布参照パッチの変更箇所（抜粋）

```
other.to_dataset() if isinstance(other, xr.DataArray) else other
```

Xarray ： Dataset.merge に DataArray を渡すと失敗する。結合前に DataArray を Dataset へ変換する。

SWE-bench team. SWE-bench Verified. pydata__xarray-3677 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/pydata__xarray-3677/gold.patch

追加例 7 ：設定値 0 なら重複検査を止める

配布参照パッチの変更箇所（抜粋）

```
+         if self.min_lines == 0:
+             return
```

Pylint ： min-similarity-lines を 0 にすると、逆に多数の重複が報告される。 0 なら類似行を調べる処理を開始せず戻る。

SWE-bench team. SWE-bench Verified. pylint-dev__pylint-4970 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/pylint-dev__pylint-4970/gold.patch

追加例 8 ：リンク先のディレクトリも探索する

配布参照パッチの変更箇所（抜粋）

```
-         if entry.is_dir(follow_symlinks=False) and recurse(entry):
+         if entry.is_dir() and recurse(entry):
```

Pytest ：シンボリックリンクのディレクトリを収集しなくなった回帰。
リンクを追わない指定を外し、以前の探索動作に戻す。

SWE-bench team. SWE-bench Verified. pytest-dev__pytest-7982 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/pytest-dev__pytest-7982/gold.patch

追加例 9 ： None の推定器を検査から除く

配布参照パッチの変更箇所（抜粋）

```
+                    if step is None:
+                        continue
```

Scikit-learn ： VotingClassifier で一部の推定器を None にすると、sample_weight 対応の検査で失敗する。 None の要素を飛ばす。

SWE-bench team. SWE-bench Verified. scikit-learn__scikit-learn-13779 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/scikit-learn__scikit-learn-13779/gold.patch

追加例 10 ： 1 要素のタプルのカンマを残す

配布参照パッチの変更箇所（抜粋）

```
+         elif len(node.elts) == 1:
+             return "(%s,)" % self.visit(node.elts[0])
```

Sphinx ：型やコードの表示で (1,) が (1) になる。要素が 1 つの場合を分岐し、タプルを表す末尾のカンマを出力する。

SWE-bench team. SWE-bench Verified. sphinx-doc__sphinx-9367 / gold.patch.
https://github.com/SWE-bench/swe-bench-tasks/blob/3d07b46/tasks/sphinx-doc__sphinx-9367/gold.patch

2. 分布・形式と採点の詳細

Verified のリポジトリ別課題数（前半）

リポジトリ	課題数	500 件中
django/django	231	46.2%
sympy/sympy	75	15.0%
sphinx-doc/sphinx	44	8.8%
matplotlib/matplotlib	34	6.8%
scikit-learn/scikit-learn	32	6.4%
astropy/astropy	22	4.4%

SWE-bench team. SWE-bench task data. Verified 500 課題、改訂 3d07b46 を集計。 2026-10-16 。 https://github.com/SWE-bench/swe-bench-tasks

Verified のリポジトリ別課題数（後半）

リポジトリ	課題数	500 件中
pydata/xarray	22	4.4%
pytest-dev/pytest	19	3.8%
pylint-dev/pylint	10	2.0%
psf/requests	8	1.6%
mwaskom/seaborn	2	0.4%
pallets/flask	1	0.2%

SWE-bench team. SWE-bench task data. Verified 500 課題、改訂 3d07b46 を集計。 2026-10-16 。 https://github.com/SWE-bench/swe-bench-tasks

変更行数の半数近くは 5 行以下

追加行＋削除行	課題数
1 〜 5 行	223
6 〜 10 行	107
11 〜 20 行	79
21 〜 50 行	65
51 行以上	26

SWE-bench team. SWE-bench task data. Verified 500 課題、改訂 3d07b46 を集計。 2026-10-16 。 https://github.com/SWE-bench/swe-bench-tasks

Issue 本文の長さは中央値約 1177 文字

統計量	文字数
中央値	1,176.5
平均	1,672.2
母標準偏差	2,015.2
最小／最大	129 ／ 24,512

500 件の problem_statement.md から前後の空白を除き、
改行・コードを含め Unicode 文字数を数えた。

SWE-bench team. SWE-bench task data. Verified 500 課題、改訂 3d07b46 を集計。 2026-10-16 。 https://github.com/SWE-bench/swe-bench-tasks

課題には実行開始地点と採点用の情報がある

フィールド／ファイル	内容
base_commit	修正前のコードの Git コミット
problem_statement.md	公開 Issue の本文
gold.patch / test.patch	参照修正／採点用のテスト変更
tests.json	FAIL_TO_PASS ・ PASS_TO_PASS 一覧

SWE-bench team. SWE-bench task data. Verified 500 課題、改訂 3d07b46 を集計。 2026-10-16 。 https://github.com/SWE-bench/swe-bench-tasks

評価実装の第 5 版はファイルを種類別に置く

```
tasks/pallets__flask-5014/
  task.yaml
  problem_statement.md
  gold.patch
  test.patch
  tests.json
  Dockerfile
```

task.yaml に ID ・リポジトリ・コミットなどを置く。問題文・参照修正・テストと実行環境を同じ課題フォルダで管理する。

SWE-bench team (2026). SWE-bench Changelog. 評価実装 5.0.0 以降のタスク形式。 https://github.com/SWE-bench/SWE-bench/blob/02e7a74/CHANGELOG.md

公式コードは修正と維持の条件で解決判定する

```
f2p = compute_fail_to_pass(report)
p2p = compute_pass_to_pass(report)
if f2p == 1 and p2p == 1:
    return ResolvedStatus.FULL.value
```

get_resolution_status から字下げをそろえた抜粋。両集合の全条件を満たした課題が完全解決となる。

SWE-bench team. SWE-bench evaluation harness: grading.py. 改訂 02e7a74 。 https://github.com/SWE-bench/SWE-bench/blob/02e7a74/swebench/harness/grading.py

参照した現行採点実装のテスト状態の扱い

テストの結果	FAIL_TO_PASS	PASS_TO_PASS
PASSED / XFAIL	成功	維持
SKIPPED	失敗	維持
FAILED / ERROR	失敗	回帰

改訂 02e7a74 の test_passed ・ test_maintained に対応。
PASS_TO_PASS が空の課題では、維持条件は満たされたとする。

SWE-bench team. SWE-bench evaluation harness: grading.py. 改訂 02e7a74 。 https://github.com/SWE-bench/SWE-bench/blob/02e7a74/swebench/harness/grading.py

タスクの日付とパッケージの版を記録する

- Verified の created_at は、対応する Pull Request の作成日時。取得した 500 課題では 2013 年 1 月〜 2023 年 8 月に分布する。
- task.yaml の version は、対象リポジトリのパッケージ版。 Verified というデータセットや評価実装の版番号とは別に保存されている。
- base_commit と環境設定のコミットを使い、当時の依存関係とコードの状態を再現する。

SWE-bench team. SWE-bench task data. Verified 500 課題、改訂 3d07b46 を集計。 2026-10-16 。 https://github.com/SWE-bench/swe-bench-tasks

3. 著者と参考文献

実 Issue の修正を評価対象にした研究者たち

- SWE-bench の共同第一著者は Carlos E. Jimenez と John Yang 。 Alexander Wettig 、 Shunyu Yao 、 Kexin Pei 、 Ofir Press 、 Karthik Narasimhan が共著者。
- 2023 年に初公開し、 ICLR 2024 で発表。既存リポジトリと実行可能なテストを使うソフトウェア修正課題を提案した。
- Verified は SWE-bench チームと OpenAI の協力で 2024 年 8 月に公開。人が課題の明確さ・テスト・解決可能性を確認した。

Jimenez et al. (2024). SWE-bench: Can Language Models Resolve Real-World GitHub Issues? ICLR 2024. https://arxiv.org/abs/2310.06770v3

参考文献

SWE-bench: Can Language Models Resolve Real-World GitHub Issues?

Carlos E. Jimenez, John Yang et al. / ICLR 2024

実 Issue ・参照パッチ・テストから、既存コードを修正する評価課題を作った。

https://arxiv.org/abs/2310.06770v3

SWE-bench Verified

SWE-bench team / 2024 公開 / 2026-10-16 参照

人が検証した 500 課題と、 Verified ・ Bash Only の評価条件を説明する。

https://www.swebench.com/verified.html

参考文献

SWE-bench evaluation harness

SWE-bench team / GitHub / 改訂 02e7a74

環境構築、パッチの適用、テスト実行と解決判定を行う公式実装。

https://github.com/SWE-bench/SWE-bench

SWE-bench task data

SWE-bench team / GitHub / 改訂 3d07b46

問題文・参照パッチ・採点テスト・実行環境を課題別に配布する。

https://github.com/SWE-bench/swe-bench-tasks

参考文献

SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks?

Xiang Deng, Jeff Da et al. / 2025 / arXiv:2509.16941v2

企業での開発に近い長時間の修正課題を集め、公開・非公開集合で評価する。

https://arxiv.org/abs/2509.16941v2

Gemini 3.1 Pro

Google DeepMind / 2026 / Model performance

Verified を含む公式モデル比較と、 1 回の試行による解決率を掲載する。

https://deepmind.google/models/gemini/pro/