Synthetic efficiency

固定テキストの長さと生成上限を変え、時間を測る

sasakiy84

推論時間の公開研究記録

Leaderboard: Synthetic efficiency

Scenario introduced in this work to better understand inference runtime performance of various models.

Select a group: Synthetic efficiency

Synthetic efficiency | num_prompt_tokens: 1, num_instances: 10, tokenizer: ai21/j1 | num_prompt_tokens: 1024, num_instances: 10, tokenizer: ai21/j1 | num_prompt_tokens: 1536, num_instances: 10,

Model	# eval	# train	truncated	# prompt tokens	# output tokens	# trials
J1-Jumbo v1 (178B) [max_tokens: 1]	10	0	0	665.8	1	1
J1-Jumbo v1 (178B) [max_tokens: 16]	10	0	0	665.8	16	1
J1-Jumbo v1 (178B) [max_tokens: 2]	10	0	0	665.8	2	1
J1-Jumbo v1 (178B) [max_tokens: 32]	10	0	0	665.8	32	1
J1-Jumbo v1 (178B) [max_tokens: 4]	10	0	0	665.8	4	1
J1-Jumbo v1 (178B)						

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

1. 長さを制御し、生成時間を比べる
2. 入力長と出力上限を変える
3. 三つの時間指標を読み解く
4. 時間の近似と、公開記録の使い方

長さを制御し、生成時間を比べる

長さをそろえた入力で、生成処理の時間を測る

- Synthetic efficiency は、入力トークン数と生成上限を変え、言語モデルの推論時間を調べる課題。 Stanford CRFM の研究チームが 2022 年に設計し、既存の文学作品を切り出して長さをそろえた入力を使う。
- 短い入力と長い入力、短い生成と長い生成を組み合わせる。同じ長さでも複数の入力を送り、実行時間のばらつきや提供方式による違いを調べる。

[1] Liang et al. (2022). Holistic Evaluation of Language Models. arXiv:2211.09110v1. https://arxiv.org/abs/2211.09110v1

入力から、そのまま続きを生成させる

- 学習例や課題指示は加えず、用意した断片をそのまま入力し、指定した上限まで続きを生成する。入力長と生成上限を決め、応答にかかった秒数と実際の出力長を記録する。
- 正解として再現させる参照文は用意せず、生成にかかった時間を比較する。実例では、入力と実際に生成された続きを対応させて示す。

[1] Stanford CRFM (n.d.). SyntheticEfficiencyScenario. https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/synthetic_efficiency_scenario.py

10 入力は、 5 作品の異なる断片からなる

作品	著者・英訳者	実例番号
不思議の国のアリス	Lewis Carroll	1 ・ 6
高慢と偏見	Jane Austen	4 ・ 7
ホームズの冒険	Arthur Conan Doyle	2 ・ 8
モンテ・クリスト伯	Alexandre Dumas	5 ・ 9
罪と罰	Dostoyevsky / Garnett 英訳	3 ・ 10

ここでは、 5 作品から 2 断片ずつ、計 10 入力を紹介する。いずれも 256 トークンの公開入力で、本編 3 件・付録 7 件。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例１：自分を叱るアリスと小さなケーキ

入力テキスト（全文）

crying like that!” said Alice to herself, rather sharply; “I advise you to leave off this minute!” She generally gave herself very good advice, (though she very seldom followed it), and sometimes she scolded herself so severely as to bring tears into her eyes; and once she remembered trying to box her own ears for having cheated herself in a game of croquet she was playing against herself, for this curious child was very fond of pretending to be two people. “But it’s no use now,” thought poor Alice, “to pretend to be two people! Why, there’s hardly enough of me left to make _one_ respectable person!”
Soon her eye fell on a little glass box that was lying under the table: she opened it, and found in it a very small cake, on which the words “EAT ME” were beautifully marked in currants. “Well, I’ll eat it,” said Alice, “and if it makes me grow larger, I can reach the key; and if it makes me grow smaller, I can creep under the

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Lewis Carroll. Alice’s Adventures in Wonderland. Project Gutenberg eBook11 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例１：自分を叱るアリスと小さなケーキ（訳）

入力テキストの日本語訳

「そんなふうに泣くなんて！」とアリスは、かなり厳しく自分に言った。「今すぐやめなさい！」ふだんから自分にはとてもよい忠告をするのだが、従うことはめったになかった。ときには涙が出るほど厳しく自分を叱りもした。一人でクロッケーをして自分をごまかしたため、自分の耳をひっぱたこうとしたことも思い出した。この変わった子は、一人二役を演じるのが大好きだったのだ。「でも、今は無駄だわ」とかわいそうなアリスは思った。「二人のふりをしたって！ まともな一人分にさえ、ほとんど足りないんですもの！」
やがて、テーブルの下にある小さなガラス箱が目に入った。開けると、ごく小さなケーキがあり、干しぶどうで「EAT ME」と美しく書かれていた。「よし、食べちゃおう」とアリスは言った。「大きくなれば鍵に手が届くし、小さくなれば、その下をくぐって――」

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Lewis Carroll. Alice’s Adventures in Wonderland. Project Gutenberg eBook11 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例２：仮面をつけた客がホームズを訪れる

入力テキスト（全文）

blue cloak which was thrown over his shoulders was lined with flame-coloured silk and secured at the neck with a brooch which consisted of a single flaming beryl. Boots which extended halfway up his calves, and which were trimmed at the tops with rich brown fur, completed the impression of barbaric opulence which was suggested by his whole appearance. He carried a broad-brimmed hat in his hand, while he wore across the upper part of his face, extending down past the cheekbones, a black vizard mask, which he had apparently adjusted that very moment, for his hand was still raised to it as he entered. From the lower part of the face he appeared to be a man of strong character, with a thick, hanging lip, and a long, straight chin suggestive of resolution pushed to the length of obstinacy.
“You had my note?” he asked with a deep harsh voice and a strongly marked German accent. “I told you that I would call.” He looked from one to the other of us, as if uncertain which to address.
“Pray take a seat,”

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Arthur Conan Doyle. The Adventures of Sherlock Holmes. Project Gutenberg eBook1661 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例２：仮面をつけた客がホームズを訪れる（訳）

入力テキストの日本語訳

肩に掛けた青い外套には炎の色の絹の裏地があり、首元は、火のように輝くベリルを一つあしらったブローチで留められていた。ふくらはぎの中ほどまであるブーツは、上端が濃い茶色の毛皮で縁取られ、その姿全体が漂わせる荒々しい豪奢さを仕上げていた。片手にはつばの広い帽子を持ち、顔の上半分には頬骨の下まで覆う黒い仮面を着けていた。入ってきたとき、まだ手をそこへ上げていたので、ちょうど今、仮面を直したらしい。顔の下半分からは、厚く垂れた唇と、頑固さの域に達する決意を思わせる長くまっすぐな顎を持つ、意志の強そうな男に見えた。
「私の手紙は受け取ったかね？」と、低く荒々しい声に強いドイツ語なまりを響かせて尋ねた。「伺うとお伝えしたはずだ。」誰に話しかければよいか迷うように、私たちを交互に見た。
「どうぞお掛けください」と、

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Arthur Conan Doyle. The Adventures of Sherlock Holmes. Project Gutenberg eBook1661 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例３：老女の部屋の呼び鈴を鳴らす

入力テキスト（全文）

were not to be dreaded.
“If I am so scared now, what would it be if it somehow came to pass that I were really going to do it?” he could not help asking himself as he reached the fourth storey. There his progress was barred by some porters who were engaged in moving furniture out of a flat. He knew that the flat had been occupied by a German clerk in the civil service, and his family. This German was moving out then, and so the fourth floor on this staircase would be untenanted except by the old woman. “That’s a good thing anyway,” he thought to himself, as he rang the bell of the old woman’s flat. The bell gave a faint tinkle as though it were made of tin and not of copper. The little flats in such houses always have bells that ring like that. He had forgotten the note of that bell, and now its peculiar tinkle seemed to remind him of something and to bring it clearly before him.... He started, his nerves were terribly overstrained by now. In a little while, the door was opened a tiny crack:

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Fyodor Dostoyevsky / Constance Garnett 訳 . Crime and Punishment. Project Gutenberg eBook2554 、2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例３：老女の部屋の呼び鈴を鳴らす（訳）

入力テキストの日本語訳

恐れることはなかった。
「今こんなにおびえているなら、もし本当にあれをやることになったら、どうなるだろう？」四階に着くと、彼は思わず自問した。そこでは、住居から家具を運び出す人夫たちに行く手を塞がれた。その部屋にはドイツ人の役人と家族が住んでいたことを、彼は知っていた。このドイツ人は今、引っ越すところだった。すると、この階段の四階に住むのは老女だけになる。「それなら好都合だ」と彼は思い、老女の部屋のベルを鳴らした。ベルは銅ではなくブリキでできているかのように、かすかな音を立てた。こうした建物の小さな住居には、たいていこんな音のベルがある。そのベルの音を忘れていたが、今その独特の響きが何かを思い出させ、鮮明に浮かび上がらせるようだった……。彼はびくりとした。このときには、神経がひどく張り詰めていた。しばらくすると、扉がほんの少し開いた。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Fyodor Dostoyevsky / Constance Garnett 訳 . Crime and Punishment. Project Gutenberg eBook2554 、2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 1 〜 3 ： 16tokens の生成出力

実例	生成出力	実測秒
1	door; so either way I’ll get into the garden, and	1.193
2	said Holmes. “This is my friend and colleague, Dr. Watson	4.123
3	the chain was not taken off, and an old woman peeped out	1.976

text-davinci-003 / 2022 年の公開測定 / 入力 256 トークン・出力上限 16

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例１～３：生成出力の日本語訳

実例	生成出力の日本語訳
1	扉。どちらになっても庭に入れる。そして、
2	とホームズは言った。「こちらは友人で仕事仲間の、ワトソン博士
3	鎖は外されず、老女が顔をのぞかせた

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

入力長と出力上限を変える

入力 5 通りと、出力上限 7 通りを組み合わせる

入力 tokens ／ 出力上限	1	2	4	8	16	32	64
1	●	●	●	●	●	●	●
256	●	●	●	●	●	●	●
512	●	●	●	●	●	●	●
1024	●	●	●	●	●	●	●
1536	●	●	●	●	●	●	●

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

トークン数は、モデルの分割方法に依存する

- 入力生成コードは、 5 作品の冒頭を飛ばし、モデルごとのトークナイザで連続した部分を切り出す。復号して再び数え、指定したトークン数へ調整する。
- 同じ 256 トークンでも、分割の仕方によって文字数や語の量は異なる。入力長をそろえるときは、対象モデルが使うトークナイザで数える。

[1] Stanford CRFM (n.d.). 入力生成コード。
https://github.com/stanford-crfm/helm/blob/v0.3.0/scripts/efficiency/generate_instances.py

出力上限 64 でも、実生成数は異なる

davinci-003 ／入力長	出力上限	平均出力トークン数
1	64	59.4
256	64	55.7
1,024	64	55.9

公開記録、各 10 入力の平均。時間を推定するときは、上限ではなく実際に生成したトークン数を使う。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

三つの時間指標を読み解く

測った時間と、条件をそろえた推定時間を使う

指標	何を表すか
Raw runtime	API の応答時間、または オフラインのバッチ全体の時間
Denoised runtime	API の変動を除く推定。オフラインではバッチ時間 ÷ 件数
Idealized runtime	A100 GPU 上の最適化実装を仮定した推定

[1] Narayanan et al. (2023). Cheaply Estimating Inference Efficiency Metrics for Autoregressive Transformer Models. NeurIPS.
https://papers.nips.cc/paper_files/paper/2023/hash/d1a14493e5f84d6c6129414f0cd1a7c6-Abstract-Conference.html
[2] Stanford CRFM (n.d.). 推論時間の計算コード。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/basic_metrics.py

バッチ全体の時間を、 1 入力当たりへ換算する

測定と換算	時間・件数
バッチ全体の処理時間	約 12.289 秒
バッチ内の入力数	12 件
Raw runtime	約 12.289 秒
1 入力当たりの Denoised runtime	約 1.024 秒（ 12.289÷12 ）

OPT-175B 、入力 256 トークン・出力上限 16 の公開測定。

[1] Stanford CRFM (n.d.). 推論時間の計算コード。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/basic_metrics.py

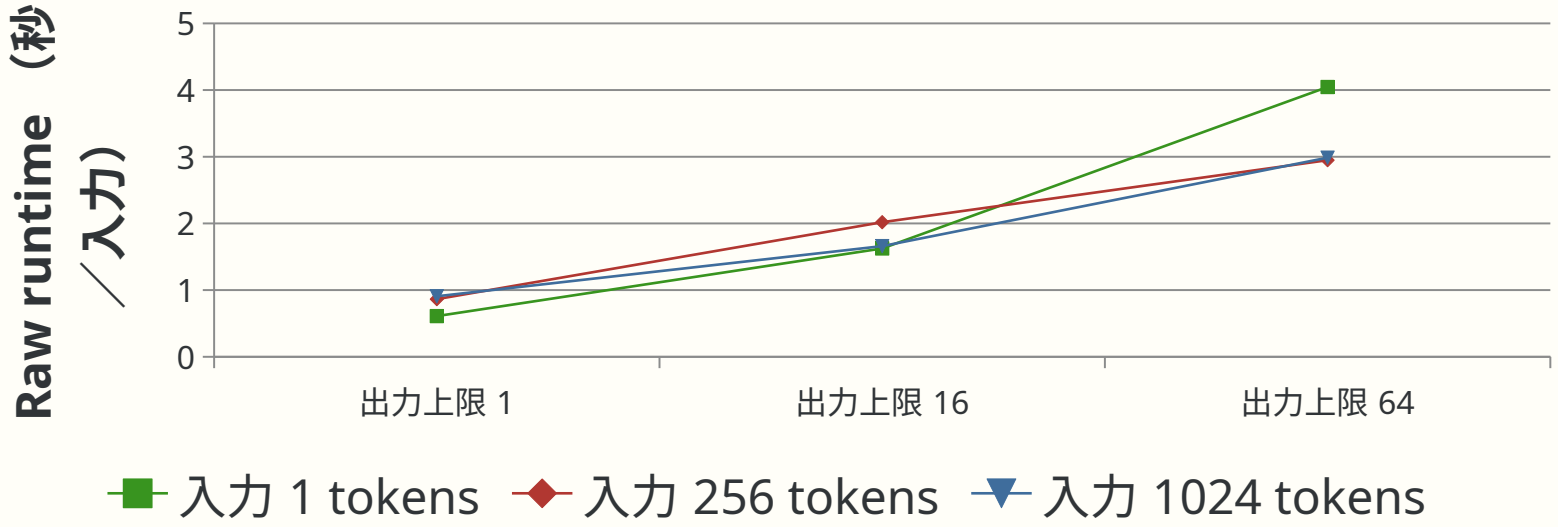
同条件でも、指標ごとに意味が異なる

モデル	Raw 秒	バッチ件数	Denoised 秒	Idealized 秒
davinci-003	2.019	1	—	—
AI21 J1-Jumbo	1.207	1	0.996	1.057
OPT-175B	12.289	12	1.024	1.324

公開記録。入力 256 ・出力上限 16 、 10 入力の平均。—は推定値なし。 OPT の Raw は 12 入力のバッチ全体。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency
[2] Stanford CRFM (n.d.). 推論時間の計算コード。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/basic_metrics.py

davinci-003 ：長さ条件ごとの応答時間



各点は公開記録 10 入力の平均。出力上限 64 でも、実際の生成数は入力ごとに異なる。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

同一条件でも、個々の応答時間は違う

- 2022 年の公開測定では、 davinci-003 の入力 256 ・出力上限 16 で、 10 入力の平均が 2.019 秒、個々の応答は 0.681 〜 4.123 秒だった。通信やサービスの混雑なども、応答時間のばらつきに関わる。
- Denoised は複数回の最短時間を使う回帰で、 API 測定の変動を抑えた推定。 Idealized は共通のハードウェア・実装を使う推定で、比較したい条件に合わせて使う。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency
[2] Narayanan et al. (2023). Cheaply Estimating Inference Efficiency Metrics for Autoregressive Transformer Models. NeurIPS.
https://papers.nips.cc/paper_files/paper/2023/hash/d1a14493e5f84d6c6129414f0cd1a7c6-Abstract-Conference.html

保存記録から、入力・出力・測定秒を読む

```
import json
state = json.load(open("scenario_state.json", encoding="utf-8"))
request = state["request_states"][0]
print(request["instance"]["input"]["text"])
print(request["result"]["completions"][0]["text"])
print(request["result"]["request_time"])
```

公開記録を scenario_state.json として保存して実行する。最初の入力と生成文、応答時間（秒）が得られる。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

時間の近似と、公開記録の使い方

入力処理と、逐次生成の時間を近似する

- 推論時間は、入力をまとめて処理する段階と、出力を 1 トークンずつ生成する段階からなる。入力長と出力長は、この処理時間に異なる形で関わる。
- Narayanan らの 2023 年の研究は、二つの段階を測って時間を近似し、ハードウェアと実装をそろえた Idealized runtime を示した。
- A100 GPU と Megatron を使い、モデル規模に応じた GPU 数を想定する。サービス側の構成や待ち時間を含む応答時間とは、比較する条件が異なる。

[1] Liang et al. (2022). Holistic Evaluation of Language Models. arXiv:2211.09110v1. https://arxiv.org/abs/2211.09110v1

[2] Narayanan et al. (2023). Cheaply Estimating Inference Efficiency Metrics for Autoregressive Transformer Models. NeurIPS. https://papers.nips.cc/paper_files/paper/2023/hash/d1a14493e5f84d6c6129414f0cd1a7c6-Abstract-Conference.html

公開された入力・出力・時間と、生成コードを使う

- 公開研究記録には、モデルと長さ条件ごとの入力、生成文、時間が保存されている。入力生成コードも公開されている。本資料の 10 断片と生成出力は、この公開記録のものである。
- 素材は、公開当時にパブリックドメインの資料として紹介された文学作品。作品や利用する版ごとの条件は、 Project Gutenberg などの公開元で確認できる。

[1] Stanford CRFM (n.d.). SyntheticEfficiencyScenario.
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/synthetic_efficiency_scenario.py
[2] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

まとめ：入力・生成長と、時間の定義をそろえる

- 固定テキストから続きを生成し、入力長と生成上限を変えて推論時間を調べる。実際の生成数が上限より少なくなることも、処理時間に関わる。
- Raw は応答やバッチ全体の実測時間。 Denoised は変動を抑えた推定で、バッチでは 1 入力分へ換算する。 Idealized はハードウェアと実装をそろえた推定で、異なる観点から生成処理を比べられる。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency
[2] Stanford CRFM (n.d.). 推論時間の計算コード。
https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/metrics/basic_metrics.py

Appendix

1. 残り 7 入力の全文と訳
2. 長さ条件ごとの測定値
3. 参考文献

実例 4 ：ベネット夫妻の紹介をめぐる会話

入力テキスト（全文）

the advantage of your friend, and introduce Mr. Bingley to _her_.”
“Impossible, Mr. Bennet, impossible, when I am not acquainted with him myself; how can you be so teasing?”
“I honour your circumspection. A fortnight’s acquaintance is certainly very little. One cannot know what a man really is by the end of a fortnight. But if _we_ do not venture somebody else will; and after all, Mrs. Long and her nieces must stand their chance; and, therefore, as she will think it an act of kindness, if you decline the office, I will take it on myself.”
The girls stared at their father. Mrs. Bennet said only, “Nonsense, nonsense!”
“What can be the meaning of that emphatic exclamation?” cried he.

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Jane Austen. Pride and Prejudice. Project Gutenberg eBook1342 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 4 ：ベネット夫妻の紹介をめぐる会話（訳）

入力テキストの日本語訳

お友達のために、ビングリー氏をあの方にご紹介なさっては。」
「無理ですわ、ベネットさん、無理ですよ。私自身、面識がないのですから。どうしてそんなにからかうの？」
「その慎重さには敬服するよ。知り合って二週間というのは、確かにごく短い。二週間たっただけでは、その人の本当の人柄は分からないからね。だが、私たちが思い切ってやらなければ、誰かほかの人がやるだろう。それに、ロング夫人と姪御さんたちにも、好機をつかむ余地はあってよい。だから結局、あの方には親切なことと思われるだろうし、君がその役を辞退するなら、私が引き受けよう。」
娘たちは父親をまじまじと見た。ベネット夫人はただ、
「ばかばかしい、ばかばかしい！」と言った。
「その力強い叫びは、どういう意味だろうね？」と彼は声を上げた。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Jane Austen. Pride and Prejudice. Project Gutenberg eBook1342 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 5 ：エルバ島で皇帝に会ったダンテス

入力テキスト（全文）

was Policar Morrel, my uncle, who was afterwards a captain. Dantès, you must tell my uncle that the emperor remembered him, and you will see it will bring tears into the old soldier’s eyes. Come, come,” continued he, patting Edmond’s shoulder kindly, “you did very right, Dantès, to follow Captain Leclere’s instructions, and touch at Elba, although if it were known that you had conveyed a packet to the marshal, and had conversed with the emperor, it might bring you into trouble.”
0027m
“How could that bring me into trouble, sir?” asked Dantès; “for I did not even know of what I was the bearer; and the emperor merely made such inquiries as he would of the first comer. But, pardon me, here are the health officers and the customs inspectors coming alongside.” And the young man went to the gangway. As he departed, Danglars approached, and said,—
“Well, it appears that

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Alexandre Dumas. The Count of Monte Cristo. Project Gutenberg eBook1184 、 2026-10-18 取得。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 5 ：エルバ島で皇帝に会ったダンテス（訳）

入力テキストの日本語訳

それはポリカール・モレル、私の叔父で、後に大尉になった者だ。ダンテス、皇帝が覚えていらしたと、叔父に必ず伝えてくれ。あの老兵の目には涙が浮かぶだろう。さあさあ」と彼は続け、親しげにエドモンの肩をたたいた。「ルクレール船長の指示に従い、エルバ島に立ち寄ったのは大変よかった。もっとも、元帥に小包を届け、皇帝と話したと知れれば、面倒に巻き込まれるかもしれないがね。」
0027m
「どうして面倒になるのでしょう、旦那？」とダンテスは尋ねた。「私は何を運んでいたのかさえ知らず、皇帝も、たまたま会った相手にするような質問をなさっただけです。ですが、失礼します。検疫官と税関の検査官たちが、船のそばに来ています。」若者は舷門へ向かった。彼が離れると、ダングラールが近寄って言った。
「さて、どうやら、」

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Alexandre Dumas. The Count of Monte Cristo. Project Gutenberg eBook1184 、 2026-10-18 取得。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 6 ：ケーキを食べた後のアリス

入力テキスト（全文）

door; so either way I’ll get into the garden, and I don’t care which happens!”
She ate a little bit, and said anxiously to herself, “Which way? Which way?”, holding her hand on the top of her head to feel which way it was growing, and she was quite surprised to find that she remained the same size: to be sure, this generally happens when one eats cake, but Alice had got so much into the way of expecting nothing but out-of-the-way things to happen, that it seemed quite dull and stupid for life to go on in the common way.
So she set to work, and very soon finished off the cake.
* * * * * * *
* * * * * *
* * * *

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Lewis Carroll. Alice’s Adventures in Wonderland. Project Gutenberg eBook11 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 6 ：ケーキを食べた後のアリス（訳）

入力テキストの日本語訳

扉。どちらになっても庭に入れるんだから、どうなったって構わないわ！」
少し食べて、「どっち？ どっち？」と心配そうに言いながら、どちらへ伸びるか確かめようと、頭のてっぺんに手を当てた。ところが、大きさが変わらないので、ひどく驚いた。もちろん、ケーキを食べれば普通はそうなるのだが、アリスは何でも途方もないことが起きるのに慣れきっていたので、物事が当たり前のまま進むのは、まるで退屈でつまらなく思えた。
そこで食べることに取りかかり、すぐにケーキをすっかり平らげた。
＊　＊　＊　＊　＊　＊　＊
　＊　＊　＊　＊　＊　＊
＊　＊　＊　＊

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Lewis Carroll. Alice’s Adventures in Wonderland. Project Gutenberg eBook11 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 7 ：メアリーへの問いから、訪問の告白へ

入力テキスト（全文）

“Do you consider the forms of introduction, and the stress that is laid on them, as nonsense? I cannot quite agree with you _there_. What say you, Mary? for you are a young lady of deep reflection, I know, and read great books and make extracts.”
Mary wished to say something very sensible, but knew not how.
“While Mary is adjusting her ideas,” he continued, “let us return to Mr. Bingley.”
“I am sick of Mr. Bingley,” cried his wife.
“I am sorry to hear _that_; but why did not you tell me so before? If I had known as much this morning, I certainly would not have called on him. It is very unlucky; but as I have actually paid the visit, we cannot escape the acquaintance now.”
The

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Jane Austen. Pride and Prejudice. Project Gutenberg eBook1342 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 7 ：メアリーへの問いから、訪問の告白へ（訳）

入力テキストの日本語訳

「紹介の作法や、それを重んじることを、ばかばかしいと思うのかい？ その点には、賛成しかねるね。メアリー、お前はどう思う？ お前は深く物を考える若い女性で、難しい本を読んで抜き書きもすると知っているよ。」
メアリーは大変気の利いたことを言いたかったが、どう言えばよいか分からなかった。
「メアリーが考えを整理している間に」と彼は続けた。「ビングリー氏の話へ戻ろう。」
「あの人の話はもううんざり」と妻が叫んだ。
「それは残念だ。でも、どうしてもっと早く言ってくれなかったんだい？ 朝のうちに分かっていれば、絶対に訪問しなかったのに。実に不運だが、実際にもう訪ねてしまった以上、今さら知り合いになることから逃れられないね。」
その、

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Jane Austen. Pride and Prejudice. Project Gutenberg eBook1342 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 8 ：ボヘミアの貴族が秘密を求める

入力テキスト（全文）

said Holmes. “This is my friend and colleague, Dr. Watson, who is occasionally good enough to help me in my cases. Whom have I the honour to address?”
“You may address me as the Count Von Kramm, a Bohemian nobleman. I understand that this gentleman, your friend, is a man of honour and discretion, whom I may trust with a matter of the most extreme importance. If not, I should much prefer to communicate with you alone.”
I rose to go, but Holmes caught me by the wrist and pushed me back into my chair. “It is both, or none,” said he. “You may say before this gentleman anything which you may say to me.”
The Count shrugged his broad shoulders. “Then I must begin,” said he, “by binding you both to absolute secrecy for two years; at the end of that time the matter will be of no importance. At present it is not too much to say that it is of such weight it may have an influence upon European history.”
“

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Arthur Conan Doyle. The Adventures of Sherlock Holmes. Project Gutenberg eBook1661 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 8 ：ボヘミアの貴族が秘密を求める（訳）

入力テキストの日本語訳

とホームズが言った。「こちらは友人で仕事仲間のワトソン博士です。ときどき親切にも、私の事件を手伝ってくれます。どなたとお呼びすればよいでしょう？」
「ボヘミアの貴族、フォン・クラム伯爵と呼んでもらおう。この方は君の友人で、誠実で分別のある人と聞いている。きわめて重大な件も託せるだろう。そうでなければ、君だけにお話ししたい。」
私は席を立とうとしたが、ホームズは手首をつかみ、椅子へ押し戻した。「二人に話すか、どちらにも話さないかです」と彼は言った。「私に言えることは、この人の前でもお話しになれます。」
伯爵は広い肩をすくめた。「では、まずお二人に、二年間は絶対に秘密にすると約束していただきたい。その後には、重要でなくなる話だ。今のところは、ヨーロッパの歴史を左右しかねないほどの重みがあると言っても、言い過ぎではない。」
「

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Arthur Conan Doyle. The Adventures of Sherlock Holmes. Project Gutenberg eBook1661 、 2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 9 ：船主とダングラールが小包を話題にする

入力テキスト（全文）

he has given you satisfactory reasons for his landing at Porto-Ferrajo?”
“Yes, most satisfactory, my dear Danglars.”
“Well, so much the better,” said the supercargo; “for it is not pleasant to think that a comrade has not done his duty.”
“Dantès has done his,” replied the owner, “and that is not saying much. It was Captain Leclere who gave orders for this delay.”
“Talking of Captain Leclere, has not Dantès given you a letter from him?”
“To me?—no—was there one?”
“I believe that, besides the packet, Captain Leclere confided a letter to his care.”
“Of what packet are you speaking, Danglars?”
“Why, that which Dantès left at Porto-Ferrajo.”
“How do you know he had a packet to leave at Porto-Ferra

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Alexandre Dumas. The Count of Monte Cristo. Project Gutenberg eBook1184 、 2026-10-18 取得。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 9 ：船主とダングラールが小包を話題にする（訳）

入力テキストの日本語訳

彼はポルト・フェラーヨに上陸した理由を、納得のいくように説明したのですか？」
「ああ、十分納得したよ、ダングラール君。」
「それなら結構です」と船荷監督は言った。「仲間が務めを果たさなかったと思うのは、気持ちのよいことではありませんから。」
「ダンテスは務めを果たした」と船主は答えた。「それだけのことだ。寄港を命じたのはルクレール船長だったのだ。」
「ルクレール船長と言えば、ダンテスは船長からの手紙をお渡ししませんでしたか？」
「私に？ いや。手紙があったのか？」
「小包とは別に、船長が手紙を彼に託したと思います。」
「何の小包の話だ、ダングラール？」
「ダンテスがポルト・フェラーヨに置いてきた、あの小包です。」
「どうして、彼がポルト・フェラー…

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Alexandre Dumas. The Count of Monte Cristo. Project Gutenberg eBook1184 、 2026-10-18 取得。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 10 ：ラスコーリニコフを迎え入れる老女

入力テキスト（全文）

the old woman eyed her visitor with evident distrust through the crack, and nothing could be seen but her little eyes, glittering in the darkness. But, seeing a number of people on the landing, she grew bolder, and opened the door wide. The young man stepped into the dark entry, which was partitioned off from the tiny kitchen. The old woman stood facing him in silence and looking inquiringly at him. She was a diminutive, withered up old woman of sixty, with sharp malignant eyes and a sharp little nose. Her colourless, somewhat grizzled hair was thickly smeared with oil, and she wore no kerchief over it. Round her thin long neck, which looked like a hen’s leg, was knotted some sort of flannel rag, and, in spite of the heat, there hung flapping on her shoulders, a mangy fur cape, yellow with age. The old woman coughed and groaned at every instant. The young man must have looked at her with a rather peculiar expression, for a gleam of mistrust came into her eyes again.
“Raskolnikov, a student, I

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Fyodor Dostoyevsky / Constance Garnett 訳 . Crime and Punishment. Project Gutenberg eBook2554 、2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 10 ：ラスコーリニコフを迎え入れる老女（訳）

入力テキストの日本語訳

老女は扉の隙間から、いかにも疑わしそうに客を見た。暗がりで光る小さな目以外は、何も見えなかった。だが踊り場に人が何人もいるのを見ると、気を強くして扉を大きく開けた。若者は暗い玄関へ入った。小さな台所とは仕切られていた。老女は黙って彼に向き合い、問いかけるような目で見た。六十歳の、小さくしなびた老婆で、意地の悪そうな鋭い目と、尖った小さな鼻をしていた。色あせて、いくらか白髪の交じった髪には油がたっぷり塗られ、頭巾はかぶっていなかった。雌鶏の足のように細長い首にはフランネルらしいぼろ布が結ばれ、暑いのに、年を経て黄色くなった、毛の抜けた毛皮の肩掛けが肩でひらひらしていた。老女はしきりに咳をし、うめいた。若者は、いくぶん変わった表情で彼女を見ていたに違いない。老女の目に再び疑いの光が浮かんだからだ。
「学生のラスコーリニコフです。私は、

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。 Fyodor Dostoyevsky / Constance Garnett 訳 . Crime and Punishment. Project Gutenberg eBook2554 、2026-10-18 取得。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 4 〜 7 ： 16tokens の生成出力

実例	生成出力	実測秒
4	“Do you consider the forms of introduction, and the stress that	1.993
5	you have had a pleasant voyage, M. Morrel.”	1.978
6	Alice was now faced with a difficult decision. She had two options:	2.754
7	astonishment of the ladies was just what he wished; that of Mrs	1.200

text-davinci-003 / 2022 年の公開測定 / 入力 256 トークン・出力上限 16

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 4 〜 7 ：生成出力の日本語訳

実例	生成出力の日本語訳
4	「紹介の作法や、それを重んじることを、
5	楽しい航海でしたね、モレルさん。」
6	アリスは今、難しい決断を迫られていた。選択肢は二つあった：
7	女性たちの驚きこそ、まさに彼の望んだものだった。夫人のそれは、

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 8 〜 10 ： 16tokens の生成出力

実例	生成出力	実測秒
8	I promise,” said Holmes. “And I.	2.788
9	jo?” “He told me so himself.”	1.500
10	’ve come to you,” the young man made haste to	0.681

text-davinci-003 / 2022 年の公開測定 / 入力 256 トークン・出力上限 16

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

実例 8 〜 10 ：生成出力の日本語訳

実例	生成出力の日本語訳
8	約束しましょう」とホームズは言った。 「私も。
9	ヨ？」 「本人がそう言いました。」
10	こちらへ伺いました」と、若者は急いで――

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

長さ条件ごとの測定値

davinci-003 ： 9 条件の Raw 平均

入力 tokens	出力上限 1	出力上限 16	出力上限 64
1	0.610	1.625	4.045
256	0.863	2.019	2.949
1024	0.907	1.660	2.986

単位は秒、各条件 10 入力の平均。 API 記録の応答時間。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

AI21 J1-Jumbo ： 9 条件の Raw 平均

入力 tokens	出力上限 1	出力上限 16	出力上限 64
1	0.382	0.929	3.053
256	0.436	1.207	4.017
1024	1.358	1.951	4.413

単位は秒、各条件 10 入力の平均。 API 記録の応答時間。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

OPT-175B ： 9 条件の Raw 平均

入力 tokens	出力上限 1	出力上限 16	出力上限 64
1	9.650	14.525	27.616
256	6.991	12.289	26.272
1024	8.128	11.899	30.626

単位は秒、各条件 10 入力の平均。 OPT は 12 件バッチ全体の時間。

[1] Stanford CRFM (2023). Synthetic efficiency 公開研究記録。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

参考文献

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. · 2022 · arXiv 初稿

入力長と生成上限を制御する Synthetic efficiency の設計を含む原研究。

https://arxiv.org/abs/2211.09110v1

Cheaply Estimating Inference Efficiency Metrics for Autoregressive Transformer Models

Deepak Narayanan, Keshav Santhanam, Peter Henderson, Rishi Bommasani, Tony Lee, Percy Liang · 2023 · NeurIPS

入力処理と自己回帰生成を分けたコストモデルを用い、共通基盤や API の変動を考慮する時間指標を提案する。

https://papers.nips.cc/paper_files/paper/2023/hash/d1a14493e5f84d6c6129414f0cd1a7c6-Abstract-Conference.html

参考文献

Synthetic efficiency — 公開研究記録

Stanford CRFM (2023). 2026-10-18 参照。

長さ条件ごとの入力、生成出力、測定時間を公開する。

https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/synthetic_efficiency

SyntheticEfficiencyScenario

Stanford CRFM (n.d.). 公開コード（ 2026-10-18 参照）。

トークン長とトークナイザごとに、切り出した作品の入力を読み込む。

https://github.com/stanford-crfm/helm/blob/v0.3.0/src/helm/benchmark/scenarios/synthetic_efficiency_scenario.py

参考文献

helm-efficiency

Narayanan et al. (n.d.). 2023 年効率研究の公式コード。参照 2026-10-18 。

時間の測定、回帰、推定係数、効率と能力の分析を公開する。

https://github.com/stanford-crfm/helm-efficiency

Alice’s Adventures in Wonderland

Lewis Carroll · Project Gutenberg eBook11 （電子版公開 2008 ）

アリスが小さくなり、ガラス箱のケーキを食べる場面の英語本文を含む。

https://www.gutenberg.org/ebooks/11

参考文献

Pride and Prejudice

Jane Austen · Project Gutenberg eBook1342 （電子版公開 1998 ）

ベネット夫妻と娘たちが、ビングリー氏への紹介と訪問について話す英語本文を含む。

https://www.gutenberg.org/ebooks/1342

The Adventures of Sherlock Holmes

Arthur Conan Doyle · Project Gutenberg eBook1661 （電子版公開 1999 ）

A Scandal in Bohemia などの短編を収録し、仮面の客がホームズを訪れる場面を含む。

https://www.gutenberg.org/ebooks/1661

参考文献

The Count of Monte Cristo

Alexandre Dumas · Project Gutenberg eBook1184 （英語電子版公開 1998 ）

航海から戻ったダンテスとモレル、ダングラールの会話を含む英語本文を公開する。

https://www.gutenberg.org/ebooks/1184

Crime and Punishment

Fyodor Dostoyevsky · Constance Garnett 英訳 · Project Gutenberg eBook2554 （電子版公開 2006 ）

ラスコーリニコフが老女の住居を訪れる場面を含む英語翻訳を公開する。

https://www.gutenberg.org/ebooks/2554