Synthetic Reasoning

Abstract Symbols / Natural Language

合成した規則と事実で、推論の基本操作を評価する

sasakiy84

公式リポジトリ（v0.4.0）

README License

Holistic Evaluation of Language Models

Welcome! The `crfm-helm` Python package contains code used in the **Holistic Evaluation of Language Models** project (paper, website) by Stanford CRFM. This package includes the following features:

- Collection of datasets in a standard format (e.g., NaturalQuestions)
- Collection of models accessible via a unified API (e.g., GPT-3, MT-NLG, OPT, BLOOM)
- Collection of metrics beyond accuracy (efficiency, bias, toxicity, etc.)
- Collection of perturbations for evaluating robustness and fairness (e.g., typos, dialect)
- Modular framework for constructing prompts from datasets
- Proxy server for managing accounts and providing unified interface to access models

To get started, refer to the documentation on Read the Docs for how to install and run the package.

Directory Structure

The directory structure for this repo is as follows

[1] Stanford CRFM. Holistic Evaluation of Language Models. https://github.com/stanford-crfm/helm/tree/v0.4.0

1. 記号列と自然言語の実例
2. 生成器と固定 seed の設計
3. 採点方法とモデルの到達水準
4. 研究上の位置付けと再現方法

1. 記号列と自然言語の実例

規則を見つけ、適用し、元の規則を推定する

- HELM が作った小さな合成課題で、記号列の照合、変数の置換、規則の帰納を評価する。外部の事実知識をほとんど使わずに解けるよう設計された。
- 自然言語版は、条件文の規則と 1 つの事実から、新たに導ける属性を答える。 easy と hard を用意し、 hard では上位カテゴリや語の言い換えも扱う。
- 抽象版と自然言語版は別の生成器である。同じ問題を英語へ直訳した組ではなく、推論の基本操作を異なる形式で試す。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110
[2] Stanford CRFM. HELM v0.4.0 公式生成器。 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 1 ：変数置換

公式生成器 / seed 42 / test index 0 / 問題全文

Rules: * Y - * X Z | Substitutions: X by " shark " , Y by " stork " , Z by " stork "

正解： * stork - * shark stork

日本語訳（記号・置換文字列は原文のまま）

規則： * Y - * X Z
置換： X を " shark " 、 Y を " stork " 、 Z を " stork "

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 変数置換 / index 6000 https://github.com/stanford-crfm/helm/tree/v0.4.0

記号は計算せず、指定どおりに置き換える

- 実例 1 では X が shark 、 Y と Z が stork に対応する。規則列にある変数をすべて置換し、順番と記号を保って出力する。
- + 、 - 、 * 、 = はこの課題では文字列を作る記号である。計算式として正しいかを判定したり、数値を計算したりする課題ではない。
- 一つの変数に 1 語だけでなく 2 語の文字列を割り当てる例もある。変数の反復位置と、置換する文字列の範囲を対応させる。

[1] Stanford CRFM. SyntheticReasoningScenario, HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/synthetic_reasoning_scenario.py

実例２：規則の照合

公式生成器 / seed 42 / test index 0 / 問題全文

Rules: = Z + - X | - + = X Z | Z - X + = | + - = Z X | Result: = watermelon lion + - zebra

正解： = Z + - X

日本語訳（記号・置換文字列は原文のまま）

候補となる規則： = Z + - X | - + = X Z | Z - X + = | + - = Z X
置換後の文字列： = watermelon lion + - zebra

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 規則の照合 / index 6000 https://github.com/stanford-crfm/helm/tree/v0.4.0

4 候補から、置換後の列に合う規則を選ぶ

- 実例 2 は、 4 つの規則候補と、置換後の文字列を入力にする。正解として番号ではなく、合致する規則列そのものを出力する。
- 帰納課題では、候補や置換辞書を示さず、同じ規則から生成した 2 つの結果だけを見せる。出力は Rule: に続く元の規則列である。
- この 3 課題は同じ形式の記号列を使うが、与えられる情報が異なる。置換では辞書が既知、照合では規則候補が既知、帰納では規則を推定する。

[1] Stanford CRFM. SyntheticReasoningScenario, HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/synthetic_reasoning_scenario.py

実例３：自然言語・ hard

公式生成器 / seed 42 / test index 0 / 問題全文・日本語訳

If Dan is young, then Dan is sad.
If Dan is scary, then Dan is hot.
If person is purple or small, then person is beautiful.
If Dan is clean, then Dan is green.
If Dan is bad, then Dan is soft.
Fact:
Dan is tiny and cool.
The following can be determined about Dan:

正解： Dan is beautiful.

Dan が若ければ、 Dan は悲しい。
Dan が恐ろしければ、 Dan は熱い。
人が紫色であるか、または小さいなら、その人は美しい。
Dan が清潔なら、 Dan は緑色。
Dan が悪ければ、 Dan は柔らかい。
事実：
Dan はとても小さく、涼しい。
Dan について何が導けるか。

Dan は美しい。

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 自然言語・ hard / index 6000 https://github.com/stanford-crfm/helm/tree/v0.4.0

hard では、言い換えと上位カテゴリを対応させる

- 実例 3 では、事実の tiny を規則の small へ、 Dan を人の規則へ対応させる。 purple または small という条件の small が満たされるため、 beautiful を導ける。
- cool は生成器の語彙表では cold の具体的な表現だが、この例の 5 規則から cold に基づく新しい属性は導けない。答えには beautiful だけを含める。
- 規則の帰結は、ほかの規則の条件へ再利用されないように作られる。自然言語版は、規則を何段も連鎖させる課題ではなく、1 段の適用を評価する。

[1] Stanford CRFM. SRNScenario, HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/synthetic_reasoning_natural_scenario.py

2. 生成器と固定 seed の設計

抽象版は短い列と置換辞書から生成する

要素	生成条件
変数	X / Y / Z から、重複を許して 2 〜 3 個
記号	+ / - / * / = から、重複を許して 2 〜 3 個
置換語彙	動物 12 語と果物 10 語の計 22 語
置換文字列	各変数に 1 〜 2 語を割り当てる

変数と記号をシャッフルして 4 〜 6 要素の規則列を作る。同じ変数は同じ文字列に置換される。

[1] Stanford CRFM. SyntheticReasoningScenario, HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/synthetic_reasoning_scenario.py

自然言語版は 5 規則と 2 属性の事実を作る

- 人・動物・植物の 3 カテゴリから対象を選ぶ。 25 の一般属性を使い、 1 属性の条件か、 and/or で結んだ 2 属性の条件から、別の 1 属性を導く規則を 5 つ作る。
- 事実には 2 つの属性を与える。満たされる規則の帰結を集め、対象がそれらを持つという文を正解にする。新たな帰結がなければ Nothing. となる。
- easy は規則と事実で同じ対象・属性の語を使う。 hard では対象を person などのカテゴリで表す規則や、 tiny / small などの語彙対応を使う。

[1] Stanford CRFM. SRNScenario, HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/synthetic_reasoning_natural_scenario.py

各設定を固定 seed で 11,000 例ずつ生成する

分割	生成順の index	件数
train	0 〜 999	1,000
valid	1,000 〜 5,999	5,000
test	6,000 〜 10,999	5,000

既定 seed は 42 。抽象 3 課題と自然言語 2 難度を別々に生成する。同じ seed でも設定が異なれば、同じ問題の対にはならない。

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 https://github.com/stanford-crfm/helm/tree/v0.4.0

機械的な正解を、生成条件と一緒に保存できる

- 抽象版は、規則列への置換処理から正解を作る。自然言語版は、事実が各規則の条件を満たすかを調べ、その帰結の集合から正解文を作る。
- 人が問題文と正解を一件ずつ書く方式ではない。乱数 seed 、生成器のバージョン、モード、生成順の index を固定すれば、同じ入力と参照正解を再生成できる。
- 本資料の 13 例は、 v0.4.0 の公式生成器を seed42 で実行した test の問題全文と参照正解である。 HELM のモデル入力には、問題に指示と提示例が加わる。

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 https://github.com/stanford-crfm/helm/tree/v0.4.0

3. 採点方法とモデルの到達水準

抽象版の主指標は、正規化後の文字列一致

- Classic v0.4.0 の抽象版の主指標は quasi_exact_match 。小文字化し、句読点・英語の冠詞・余分な空白を除いてから、参照正解と一致するかを 0/1 で採点する。
- この句読点除去では + 、 - 、 * 、 = も消える。したがって、主指標の正解率は記号まで正しく再現した割合とは異なる。
- 記号を保った厳密一致 exact_match も公開されている。次の 2 表では、同じモデル・同じ test について、正規化後の一致と厳密一致を分けて示す。

[1] Stanford CRFM. BasicMetric, HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/metrics/basic_metrics.py

抽象版：正規化後の一致率

モデル	置換 %	照合 %	帰納 %
text-davinci-003 (2022)	97.22	42.39	11.13
OPT-175B (2022)	25.24	40.58	1.81
Llama 2 70B (2023)	90.49	48.16	7.96

test 515 例。 text-davinci-003 ・ OPT は 3 試行平均、 Llama 2 は 1 試行。 Classic v0.4.0 、元 run suite v0.3.0 。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

抽象版：記号を含めた厳密一致率

モデル	置換 %	照合 %	帰納 %
text-davinci-003 (2022)	95.02	32.30	11.07
OPT-175B (2022)	1.94	25.37	0.00
Llama 2 70B (2023)	83.50	35.53	7.57

同じ test 515 例。 exact_match は前後の空白だけを除く。 OPT の置換は正規化後 25.24% に対し、厳密一致では 1.94% 。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

自然言語版は、導いた属性の集合を採点する

- 自然言語版の主指標は属性集合の F1 。出力の is より後を and で分け、ピリオドを除いて集合にする。予測と正解で重なる属性数から F1 を求める。
- 正解が {red, happy} 、予測が {red} なら、集合 F1 は 2/3 、積集合を和集合で割る IoU は 1/2 。集合が完全一致する割合も別に集計される。
- 主語は属性集合へ含まれない。 Nothing. は空集合として扱い、正解・予測がともに空なら 1 点。 HELM の説明には IoU も登場するが、 v0.4.0 の主指標は F1 である。

[1] Stanford CRFM. BasicMetric, HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/metrics/basic_metrics.py

自然言語版：属性集合 F1

モデル	easy %	hard %
text-davinci-003 (2022)	82.58	64.13
OPT-175B (2022)	36.05	13.53
Llama 2 70B (2023)	49.97	44.40

test 515 例の例ごとの F1 を平均し、 100 倍して表示。 text-davinci-003 ・ OPT は 3 試行、 Llama 2 は 1 試行。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

提示例と出力条件も、形式に合わせて変わる

条件	抽象版	自然言語版
提示例	5 例	3 例
最大出力	50 トークン	20 トークン
候補数 / 温度	1 候補 / 0	1 候補 / 0
停止条件	改行	改行

各試行は最大 1,000 例： valid 485 + test 515 。比較した 15 実行は、実提示数 5/3 、 prompt_truncated=0 。

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 https://github.com/stanford-crfm/helm/tree/v0.4.0

規則の適用と、採点・生成の癖を分けて読む

- 置換は高得点でも、規則の帰納では低い一致率が残る。帰納の参照正解は生成器が選んだ変数名で、名前を入れ替えた同値な規則を同一視しない。
- 照合の妨害候補は、重複を除いた変数集合から作られる。正解列で変数が反復すると正解だけが長くなり、長さから候補を絞れる例が生まれる。
- 自然言語版が測るのは、定義した語彙対応と 1 段の条件適用である。世界の事実を判断する課題や、長い証明の構築とは対象が異なる。

[1] Stanford CRFM. SyntheticReasoningScenario, HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/synthetic_reasoning_scenario.py
[2] Stanford CRFM. SRNScenario, HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/synthetic_reasoning_natural_scenario.py

4. 研究上の位置付けと再現方法

LIME と自然言語の規則推論を、 HELM へ取り込む

- LIME （ 2021 ）は、合成した演繹・帰納・仮説推論の課題で事前学習し、数学的推論に役立つ帰納バイアスを学ばせる研究である。 HELM の抽象課題は、この基本操作の考え方に着想を得た。
- Clark ら（ 2020 ）は、自然言語で書いた規則と事実から結論を導く研究を行った。 HELM の自然言語版は、その考え方を簡単な語と文型で実装した。
- 本資料は HELM の生成器と評価結果を扱う。 LIME の事前学習データや、先行研究の規則推論課題の全体とは範囲が異なる。

[1] Wu et al. (2021). LIME: Learning Inductive Bias for Primitives of Mathematical Reasoning. ICML. https://proceedings.mlr.press/v139/wu21c.html
[2] Clark, Tafjord & Richardson (2020). Transformers as Soft Reasoners over Language. IJCAI. https://arxiv.org/abs/2002.05867

バージョンと seed を固定し、課題別に再現する

- 公式配布元は Stanford CRFM の HELM リポジトリ。抽象版は SyntheticReasoningScenario 、自然言語版は SRNScenario の実装を使う。
- 再現時にはタグ v0.4.0 、 seed42 、抽象版の mode または自然言語版の difficulty を指定する。生成順で分割が決まり、 test の最初の例は全体 index6000 となる。
- 2026-10-18 時点で公式実装と Classic v0.4.0 の公開結果を取得した。コードは Apache-2.0 。短い語彙表とテンプレートから生成する。

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 https://github.com/stanford-crfm/helm/tree/v0.4.0

何を推論し、何を一致と呼ぶかを対応させる

- Synthetic Reasoning は、短い記号列の照合・置換・帰納と、自然言語の 1 段の規則適用を、再生成可能な課題として用意する。
- 抽象版は文字列一致、自然言語版は属性集合の比較で採点する。正規化の有無、変数名、出力の主語をどう扱うかが、得点の意味を変える。
- 生成器のバージョンと seed だけでなく、提示例数、出力上限、評価集合、試行数と指標を合わせることで、モデルの得意・不得意を具体的に比較できる。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

Appendix

1. 追加の生成例
2. 採点と生成の詳細
3. 制作・関連研究と参考文献

実例 4 ：変数置換

公式生成器 / seed 42 / test index 1 / 問題全文

Rules: X Z X = - - | Substitutions: X by " grape apple " , Z by " penguin "

正解： grape apple penguin grape apple = - -

日本語訳（記号・置換文字列は原文のまま）

規則： X Z X = - -
置換： X を " grape apple " 、 Z を " penguin "

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 変数置換 / index 6001 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 5 ：変数置換

公式生成器 / seed 42 / test index 2 / 問題全文

Rules: X = Y X * | Substitutions: X by " peach " , Y by " cobra eagle "

正解： peach = cobra eagle peach *

日本語訳（記号・置換文字列は原文のまま）

規則： X = Y X *
置換： X を " peach " 、 Y を " cobra eagle "

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 変数置換 / index 6002 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 6 ：規則の照合

公式生成器 / seed 42 / test index 1 / 問題全文

Rules: + = X Y | Y X = + | + Y X = Y | Y X = + | Result: + horse cobra horse = horse

正解： + Y X = Y

日本語訳（記号・置換文字列は原文のまま）

候補となる規則： + = X Y | Y X = + | + Y X = Y | Y X = +
置換後の文字列： + horse cobra horse = horse

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 規則の照合 / index 6001 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 7 ：規則の照合

公式生成器 / seed 42 / test index 2 / 問題全文

Rules: = Z Y = | Z = = Y | = Z Y = | = Y = Z Y | Result: = seal pear = lion seal pear

正解： = Y = Z Y

日本語訳（記号・置換文字列は原文のまま）

候補となる規則： = Z Y = | Z = = Y | = Z Y = | = Y = Z Y
置換後の文字列： = seal pear = lion seal pear

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 規則の照合 / index 6002 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 8 ：規則の帰納

公式生成器 / seed 42 / test index 0 / 問題全文

Two results: * stork - * shark stork | * horse - * buffalo penguin horse

正解： Rule: * Y - * X Z

日本語訳（記号・置換文字列は原文のまま）

同じ規則から得た 2 つの文字列： * stork - * shark stork | * horse - * buffalo penguin horse

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 規則の帰納 / index 6000 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 9 ：規則の帰納

公式生成器 / seed 42 / test index 1 / 問題全文

Two results: grape apple penguin grape apple = - - | pear shark eagle pear shark = - -

正解： Rule: X Z X = - -

日本語訳（記号・置換文字列は原文のまま）

同じ規則から得た 2 つの文字列： grape apple penguin grape apple = - - | pear shark eagle pear shark = - -

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 規則の帰納 / index 6001 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 10 ：自然言語・ easy

公式生成器 / seed 42 / test index 0 / 問題全文

If a dandelion is small, then the dandelion is good.
If a dandelion is strong, then the dandelion is hot.
If a dandelion is big and soft, then the dandelion is boring.
If a dandelion is red and scary, then the dandelion is old.
If a dandelion is clean or young, then the dandelion is purple.
Fact:
The dandelion is purple and boring.
The following can be determined about the dandelion:

正解： Nothing.

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 自然言語・ easy / index 6000 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 10 ：自然言語・ easy （訳）

問題全文の日本語訳 / 同じ seed ・ index

タンポポが小さければ、そのタンポポはよい。
タンポポが強ければ、そのタンポポは熱い。
タンポポが大きく、かつ柔らかいなら、そのタンポポは退屈。
タンポポが赤く、かつ恐ろしいなら、そのタンポポは古い。
タンポポが清潔であるか、または若いなら、そのタンポポは紫色。
事実：
そのタンポポは紫色で、退屈。
そのタンポポについて何が導けるか。

正解：新たに導ける属性はない。

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 自然言語・ easy / index 6000 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 11 ：自然言語・ easy

公式生成器 / seed 42 / test index 1 / 問題全文・日本語訳

If a rose is hot, then the rose is blue.
If a rose is scary or small, then the rose is happy.
If a rose is smart, then the rose is red.
If a rose is slow or green, then the rose is old.
If a rose is bad, then the rose is cold.
Fact:
The rose is beautiful and hot.
The following can be determined about the rose:

正解： The rose is blue.

バラが熱ければ、そのバラは青い。
バラが恐ろしいか、または小さいなら、そのバラは幸せ。
バラが賢ければ、そのバラは赤い。
バラが遅いか、または緑色なら、そのバラは古い。
バラが悪ければ、そのバラは冷たい。
事実：
そのバラは美しく、熱い。
そのバラについて何が導けるか。

バラは青い。

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 自然言語・ easy / index 6001 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 12 ：自然言語・ hard

公式生成器 / seed 42 / test index 1 / 問題全文・日本語訳

If a poppy is green and hot, then the poppy is cold.
If a poppy is blue, then the poppy is sad.
If a plant is red, then the plant is bad.
If a poppy is strong, then the poppy is old.
If a plant is small, then the plant is beautiful.
Fact:
The poppy is glad and sluggish.
The following can be determined about the poppy:

正解： Nothing.

ケシが緑色で、かつ熱いなら、そのケシは冷たい。
ケシが青ければ、そのケシは悲しい。
植物が赤ければ、その植物は悪い。
ケシが強ければ、そのケシは古い。
植物が小さければ、その植物は美しい。
事実：
そのケシはうれしく、のろい。
そのケシについて何が導けるか。

新たに導ける属性はない。

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 自然言語・ hard / index 6001 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 13 ：自然言語・ hard

公式生成器 / seed 42 / test index 2 / 問題全文

If a plant is green or slow, then the plant is small.
If a poppy is purple, then the poppy is boring.
If a poppy is big, then the poppy is scary.
If a poppy is strong and happy, then the poppy is soft.
If a plant is old, then the plant is red.
Fact:
The poppy is sad and antique.
The following can be determined about the poppy:

正解： The poppy is red.

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 自然言語・ hard / index 6002 https://github.com/stanford-crfm/helm/tree/v0.4.0

実例 13 ：自然言語・ hard （訳）

問題全文の日本語訳 / 同じ seed ・ index

植物が緑色であるか、または遅いなら、その植物は小さい。
ケシが紫色なら、そのケシは退屈。
ケシが大きければ、そのケシは恐ろしい。
ケシが強く、かつ幸せなら、そのケシは柔らかい。
植物が古ければ、その植物は赤い。
事実：
そのケシは悲しく、古い。
そのケシについて何が導けるか。

正解：ケシは赤い。

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 自然言語・ hard / index 6002 https://github.com/stanford-crfm/helm/tree/v0.4.0

採点と生成の詳細

正規化すると、異なる記号列も一致する

採点方法の説明例：実例 1 の正解を使い、比較用の予測を置く

参照正解： * stork - * shark stork
比較する予測： + stork = + shark stork

正規化後はいずれも stork shark stork

quasi_exact_match = 1 / exact_match = 0

[1] Stanford CRFM. BasicMetric, HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/metrics/basic_metrics.py

属性集合では、主語を比較しない

採点方法の説明例：実例 3 の正解を使い、比較用の予測を置く

参照正解： Dan is beautiful.
比較する予測： Alice is beautiful.

両方から属性集合 {beautiful} を取り出す。

属性集合 F1 = 1 / 文字列の厳密一致 = 0

[1] Stanford CRFM. BasicMetric, HELM v0.4.0. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/metrics/basic_metrics.py

自然言語版：属性集合 IoU

モデル	easy %	hard %
text-davinci-003 (2022)	80.69	61.87
OPT-175B (2022)	35.21	13.24
Llama 2 70B (2023)	48.83	43.79

test 515 例。 F1 と同じ予測を使う。 text-davinci-003 ・ OPT は 3 試行平均、Llama 2 は 1 試行。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

照合候補の構造を test 全件で数える

特徴	seed42 / test 5,000 例
候補の文字列に重複がある	973 例（ 19.46% ）
正解だけが最長の候補になる	2,826 例（ 56.52% ）

v0.4.0 公式生成器の出力を独自集計。長さは空白で区切った要素数。正解と同じ候補文字列は 1 種類として扱う。

[1] Stanford CRFM. SyntheticReasoningScenario, HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/synthetic_reasoning_scenario.py

Nothing. の比率は生成結果から数える

設定	全生成例	Nothing.	比率 %
easy	11,000	1,899	17.26
hard	11,000	1,910	17.36

seed42 、 train/valid/test の合計。帰結が空のときに再抽選する処理を含むため、空の答えの割合は出力を数えて求めた。

[1] Stanford CRFM. SRNScenario, HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/synthetic_reasoning_natural_scenario.py

自然言語版は、語彙表で具体語を対応させる

- 一般属性 25 種の下に、 big→huge / giant 、 small→tiny / little 、 old→ancient / antique などの語を登録する。 hard の事実は、この具体語で表現される。
- 規則で使う属性は一般語である。正解の属性も一般語で出力され、採点時に同義語を別途まとめる処理はない。
- medium は公式実装の説明に登場するが、 Classic v0.4.0 の公開 run 仕様は easy と hard を使う。本資料もこの 2 設定を対象とする。

[1] Stanford CRFM. SRNScenario, HELM v0.4.0.
https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/synthetic_reasoning_natural_scenario.py

公式クラスを固定 seed で初期化する

```
from helm.benchmark.scenarios import (
    synthetic_reasoning_scenario as sym,
    synthetic_reasoning_natural_scenario as nl,
)
a = sym.SyntheticReasoningScenario(
    mode="variable_substitution", random_seed=42
)
example = a.get_instances("unused")[6000]
```

HELM v0.4.0 を使う。 index6000 は、生成順で最初の test 例。

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 https://github.com/stanford-crfm/helm/tree/v0.4.0

生成器の初期化と乱数系列を固定する

- 抽象版は NumPy の RandomState をインスタンスの初期化時に作る。同じオブジェクトで get_instances を繰り返すと乱数の位置が進むため、再生成には同じ seed で新たに初期化する。
- 自然言語版は get_instances の開始時に Python random.seed を設定する。呼出しごとに同じ seed から生成を始める。
- 本資料は各モード・難度を新規に初期化した。入力・正解・モード・ seed ・ index と、未改変の公式ソースの SHA-256 を原記録に保存した。

[1] Stanford CRFM. HELM v0.4.0 公式生成器。 https://github.com/stanford-crfm/helm/tree/v0.4.0

HELM の範囲と公開実行を対応させる

- Classic v0.4.0 の公開 run 仕様は、抽象 3 課題と自然言語 2 難度に各 69 実行、合計 345 実行を含む。比較表には 3 系列のモデルから計 15 実行を選んだ。
- 元 run suite はすべて v0.3.0 。 15 実行の評価対象は各試行 valid485 + test515 で、本文の表は test515 だけを使う。
- Llama 2 70B は各 1 試行、 text-davinci-003 と OPT-175B は各 3 試行。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

HELM の制作と、先行研究の役割

- HELM は Stanford CRFM の Percy Liang らによる評価基盤で、2022 年に公開され、 2023 年に TMLR へ掲載された。Synthetic Reasoning の生成器と結果も、その基盤の一部として公開された。
- HELM の貢献者一覧には、 Eric Zelikman と Qian Huang が合成推論シナリオを実装したことが記されている。
- LIME の第一著者 Yuhuai Wu らは合成課題での事前学習を研究し、 Clark 、 Tafjord 、 Richardson は自然言語による規則推論を研究した。これらは HELM の課題設計の出発点となった。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110
[2] Wu et al. (2021). LIME: Learning Inductive Bias for Primitives of Mathematical Reasoning. ICML. https://proceedings.mlr.press/v139/wu21c.html

参考文献

Liang et al. (2023). Holistic Evaluation of Language Models. TMLR.

複数のシナリオと指標を用いて汎用言語モデルを評価する。抽象・自然言語の合成推論課題も、この評価枠組みに含まれる。
https://arxiv.org/abs/2211.09110

Wu et al. (2021). LIME: Learning Inductive Bias for Primitives of Mathematical Reasoning. ICML.

演繹・帰納・仮説推論の基本操作を合成データで事前学習し、数学的推論への効果を検証した。
https://proceedings.mlr.press/v139/wu21c.html

参考文献

Clark, Tafjord & Richardson (2020). Transformers as Soft Reasoners over Language. IJCAI.

自然言語で記した規則と事実を Transformer へ与え、推論を言語の処理として扱う枠組みと実験を示した。
https://arxiv.org/abs/2002.05867

Stanford CRFM. HELM v0.4.0 公式生成器。

抽象版と自然言語版の生成器、課題の設定、採点実装を含む固定タグの公式コード。

https://github.com/stanford-crfm/helm/tree/v0.4.0