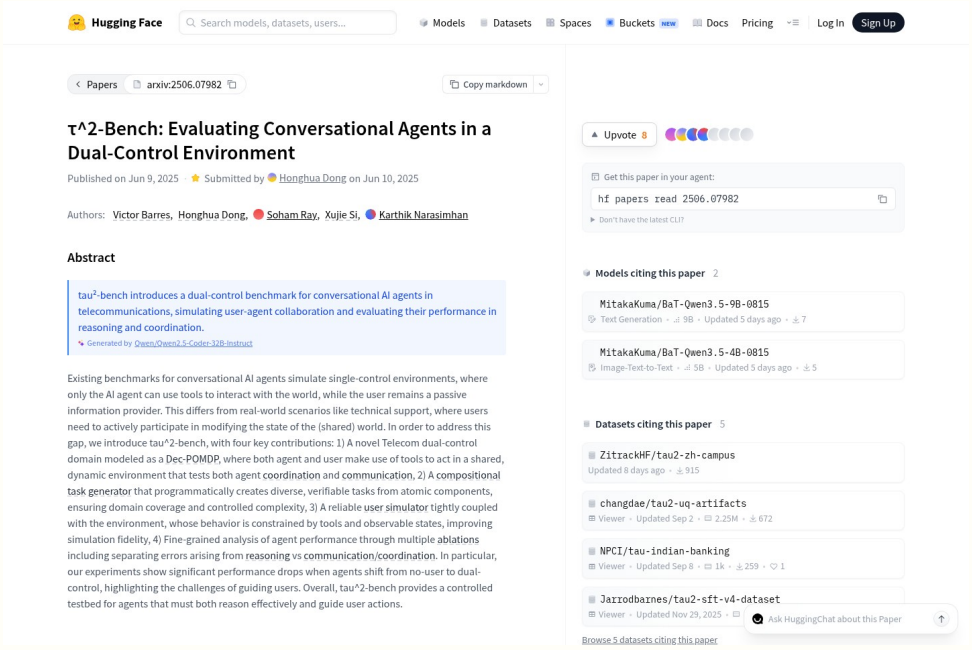
τ^2-bench

顧客と協力して問題を解く会話エージェント評価
τ^3-bench への拡張も含めて

sasakiy84

論文の紹介ページ



Barres et al. (2025). τ²-Bench: Evaluating Conversational Agents in a Dual-Control Environment. Hugging Face Papers 掲載ページ。
https://huggingface.co/papers/2506.07982

1. 顧客と協力する課題と実例
2. 完了の判定とモデルの成績
3. 課題の作成方法と構成
4. τ^3-bench への発展と利用

1. 顧客と協力する課題と実例

τ^2-bench は顧客対応の完了を評価する

- τ（タウ）は、 Tool ・ Agent ・ User のやり取りを評価するベンチマークの系列名である。
- 担当者役の AI は、顧客との会話、業務ルール、ツールを使い、小売・航空・通信の課題を解く。
- τ^2-bench では、通信障害の解決などで顧客自身も端末を操作する。担当者は、相手へ必要な操作を伝え、結果を確かめる。

Barres et al. (2025). τ^2-Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982. https://arxiv.org/abs/2506.07982

顧客と担当者が、それぞれの環境を操作する

顧客役の言語モデル ← 会話 → 担当者の言語モデル

↓ ↓

顧客の端末
通信・ローミングの設定

企業の顧客管理
契約・利用量・追加データ

端末の設定と企業側の契約情報が、通信の状態を決める。

Barres et al. (2025). τ²-Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982. https://arxiv.org/abs/2506.07982

課題に顧客の目標・初期状態・完了条件が付く

- 担当者役には業務ルールと操作ツールを渡す。別の言語モデルが顧客役となり、用意された目標・知識・振る舞いに従う。
- 企業のデータベースと顧客の端末状態を設定し、会話とツール呼出しを進める。
- 本編の最初の 3 例は τ^2-bench の公開課題。後半では、τ^3-bench に加わった文書検索付きの銀行課題も扱う。

Barres et al. (2025). τ^2-Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982. https://arxiv.org/abs/2506.07982

実例１：条件に合う商品へ交換する

顧客役に渡す設定（英語・抜粋）

> You received your order #W2378156 and wish to exchange the mechanical keyboard for a similar one but with clicky switches and the smart thermostat for one compatible with Google Home instead of Apple HomeKit. If there is no keyboard that is clicky, RGB backlight, full size, you'd go for no backlight.

課題の内容：キーボードとサーモスタットを交換する。キーの方式、照明、サイズ、対応するスマートホームの条件を満たす商品を探す。

Sierra. τ^2-bench / retail / v0.2.0. ID: 0. https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/retail/tasks.json

実例 1 では、希望条件を確認して 2 商品を交換

対象	課題と参照解法の内容
顧客の特定	氏名と郵便番号を使い、注文を確認する
キーボード	clicky 方式・フルサイズ。 RGB がなければ照明なし
サーモスタット	Apple HomeKit 対応から Google Home 対応へ
完了状態	注文内の 2 商品を、指定された交換先へ変更

Sierra. τ^2-bench / retail / v0.2.0. ID: 0. https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/retail/tasks.json

実例２：スマートフォンの通信を復旧する

顧客役に渡す設定（英語・抜粋）

> You mobile data is not working properly. It either stops working or is very slow.
> You are willing to refuel 2.0 GB of data if necessary, but you do not want to change your mobile data plan.

課題の内容：端末のデータ通信が OFF で、会社側のデータ利用量も上限を超えている。顧客の設定変更と、担当者による追加データの処理を組み合わせる。

Sierra. τ^2-bench / telecom / v0.2.0. ID: [mobile_data_issue]data_mode_off|data_usage_exceeded.
https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/telecom/tasks.json

実例 2 は、顧客と担当者の両方が操作する

主体・判定	公開課題にある操作・完了条件
顧客の端末	toggle_data でデータ通信を ON にする
担当者の顧客管理	refuel_data で 2.0 GB を追加する
通信状態の検査	データ通信が有効である
速度・購入量の検査	速度 200 Mbps 以上・ excellent 、追加 2.0 GB

Sierra. τ^2-bench / telecom / v0.2.0. ID: [mobile_data_issue]data_mode_off|data_usage_exceeded.
https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/telecom/tasks.json

実例３：航空券の取消と追加質問に対応する

顧客役に渡す設定（英語・抜粋）

> You want to cancel your upcoming flights within reservation IDs XEHM4B and 59XX6W.
> If the agent says either of the two reservations is basic economy, ask to upgrade to economy first and then cancel the reservation.

課題の内容：２件の予約を取り消す。変更が必要な運賃を扱い、会話途中で加わる別の予約の総額確認にも対応する。

Sierra. τ^2-bench / airline / v0.2.0. ID: 7. https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/airline/tasks.json

実例 3 の完了状態と伝達する金額

対象	参照解法と採点情報
予約 XEHM4B	economy へ変更してから取り消す
予約 59XX6W	予約を取り消す
追加の質問	他の今後の予約について総額を調べる
伝達する情報	総額 1,628 ドルを顧客へ伝える

Sierra. τ^2-bench / airline / v0.2.0. ID: 7. https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/airline/tasks.json

2. 完了の判定とモデルの成績

処理後の状態と、伝えた情報で採点する

- 小売・航空では、参照解法から作ったデータベースの最終状態と、担当者が処理した後の状態を比較する。
- 通信では、端末が接続されたか、必要な速度を得たかなどの検査関数を使う。
- 課題に応じて、必要な情報の伝達や、指定された操作の実施も採点要素に加える。

Sierra (2025). τ^2-bench: evaluator.py. 報酬に用いる採点要素。 https://github.com/sierra-research/tau2-bench/blob/v0.2.0/src/tau2/evaluator/evaluator.py

pass^k は、 k 回とも成功する信頼性を測る

- pass^1 は、 1 回の試行で課題を完了する割合。顧客役との会話を含めて、同じ課題を繰り返し実行する。
- pass^4 は、同じ課題を 4 回行ったときに、 4 回とも成功する割合を表す。
- 複数の試行がある場合は、各課題で k 回を選ぶ組合せのうち、すべて成功する組合せの割合を求め、課題全体で平均する。

Sierra (2025). τ²-bench: agent_metrics.py. pass^k の集計。 https://github.com/sierra-research/tau2-bench/blob/v0.2.0/src/tau2/metrics/agent_metrics.py

説明用の 4 試行から、成功率と安定性を読む

説明用の課題	4 試行の結果	pass^1	pass^4
A	成功・成功・成功・成功	100%	100%
B	成功・成功・成功・失敗	75%	0%
C	成功・失敗・成功・失敗	50%	0%

3 課題の平均： pass^1 は 75% 、 pass^4 は約 33.3% 。

Sierra (2025). τ^2-bench: agent_metrics.py. pass^k の集計。 https://github.com/sierra-research/tau2-bench/blob/v0.2.0/src/tau2/metrics/agent_metrics.py

Barres ら（2025）の通信領域の成績

担当者役のモデル	pass^1
GPT-4.1	約 34%
o4-mini	約 42%
Claude 3.7 Sonnet	約 49%

顧客役は GPT-4.1 。担当者と顧客が操作する通常の設定。

Barres et al. (2025). τ²-Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982. https://arxiv.org/abs/2506.07982

現行 Gemini の公式比較にも τ²-bench を掲載

モデル（ Google 公表表）	小売	通信
Gemini 3.1 Pro	90.8%	99.3%
Claude Opus 4.6	91.9%	99.3%
GPT-5.2	82.0%	98.7%

推論設定： Gemini High 、 Opus Max 、 GPT-5.2 xhigh 。

Google DeepMind (2026). Gemini 3.1 Pro. Performance: τ2-bench. 2026-10-16 参照。 https://deepmind.google/models/gemini/pro/

通信課題では、操作を顧客へ伝える必要がある

- Barres らは、担当者だけで顧客の端末も操作する No-User 設定と、顧客へ操作を依頼する通常設定を比較した。
- 顧客を介した設定では、 GPT-4.1 の pass^1 が 18 ポイント、 o4-mini が 25 ポイント下がった。
- 原因の推定に加え、操作を説明し、顧客が実施した結果を確かめる過程が成績に影響する。

Barres et al. (2025). τ^2-Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982. https://arxiv.org/abs/2506.07982

3. 課題の作成方法と構成

顧客が環境を変える場面を加えた

- τ-bench （2024）は、業務ルールに従う担当者と顧客役の対話を、小売・航空の環境で評価した。
- τ^2-bench （2025）は、通信の技術サポートを加え、顧客にも端末の状態を変えるツールを持たせた。
- 担当者が契約を変更し、顧客が端末を設定するように、二者の操作が同じ問題の解決へつながる。

Barres et al. (2025). τ^2-Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982. https://arxiv.org/abs/2506.07982

企業と顧客の環境を作り、テストで確かめる

- 言語モデルで、業務要件、企業のデータベースと操作関数、テストを作り、人が修正してテストを通した。
- 通信では、顧客の端末もデータベースとして表し、機内モードや通信設定を変える関数を実装した。
- 初期状態、解くための操作、最終状態を調べる検査をそろえ、課題にした。

Barres et al. (2025). τ^2-Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982. https://arxiv.org/abs/2506.07982

15 種類の基本問題群から通信課題を合成する

- 例として、端末のデータ通信 OFF と、契約データ量の使い切りを組み合わせる。
- 各基本問題には、状態を壊す初期化、直す操作、完了を調べる検査を対応させる。
- 15 の基本問題群を組み合わせて 2,285 課題を作り、問題の種類と組合せ数を考慮して 114 課題を選んだ。

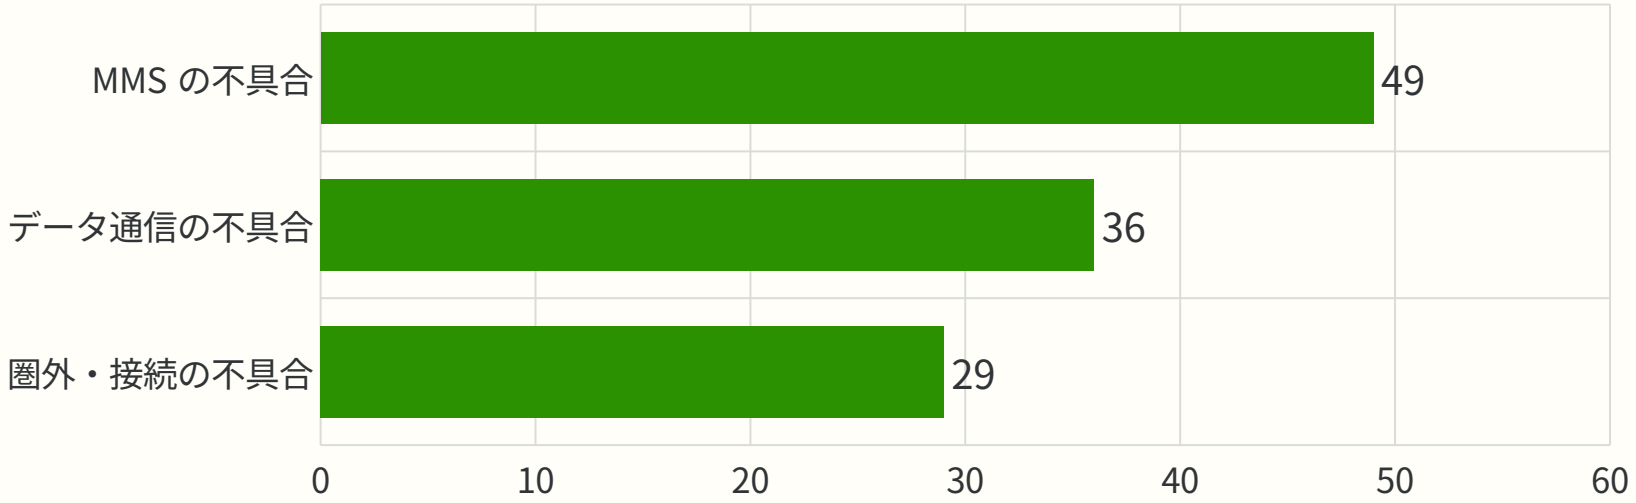
Barres et al. (2025). τ^2-Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982. https://arxiv.org/abs/2506.07982

固定した公開版の基本集合は 278 課題

領域	公開課題数	主な処理
小売	114	返品、交換、注文の変更
航空	50	予約、取消、手荷物や金額の案内
通信	114	圏外、データ通信、 MMS の復旧

Sierra (2025). τ²-bench. 公開版 v0.2.0 、 278 課題。 2026-10-16 集計。 https://github.com/sierra-research/tau2-bench/tree/v0.2.0/data/tau2/domains

通信 114 課題には、 3 種類の相談がある



公開版 v0.2.0 の通信課題を、課題 ID の相談種別で集計。単位：件。

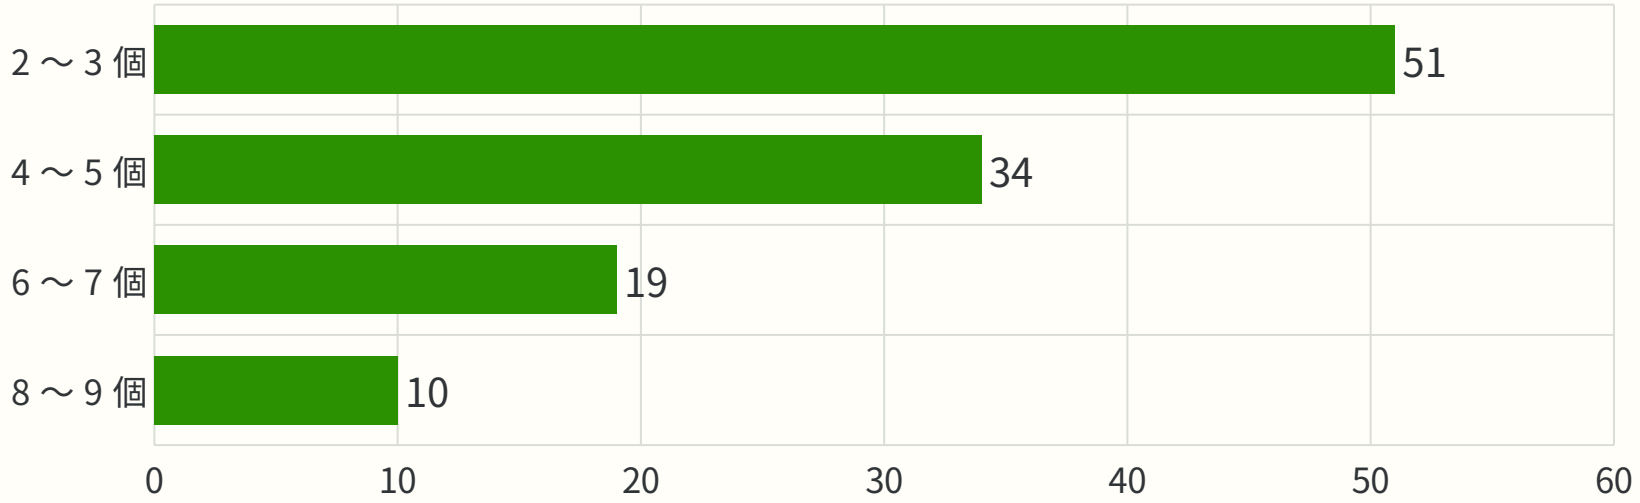
Sierra (2025). τ²-bench. 公開版 v0.2.0 、 278 課題。 2026-10-16 集計。 https://github.com/sierra-research/tau2-bench/tree/v0.2.0/data/tau2/domains

通信課題には、顧客の人物設定も付く

公開ラベル	設定の特徴	課題数
None	追加の人物設定なし	40
Easy	技術的な知識がある顧客	38
Hard	技術に不慣れで、不安を抱く顧客	36

Sierra (2025). τ^2-bench. 公開版 v0.2.0 、 278 課題。 2026-10-16 集計。 https://github.com/sierra-research/tau2-bench/tree/v0.2.0/data/tau2/domains

通信課題は複数の基本問題を組み合わせる



横軸は課題数。各区分は課題 ID に含む基本問題の数。全 114 課題。

Sierra (2025). τ²-bench. 公開版 v0.2.0 、 278 課題。 2026-10-16 集計。 https://github.com/sierra-research/tau2-bench/tree/v0.2.0/data/tau2/domains

顧客役は、ツールの結果から端末状態を答える

- 担当者が状態を尋ねると、顧客役は端末の確認ツールを呼び、その結果を返す。
- 例えば、ステータスバーの表示や MMS 送信の可否は、実装した端末状態と対応する。
- ツールによる状態の確認と変更を、顧客との会話の中に組み込んでいる。

Barres et al. (2025). τ^2-Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982. https://arxiv.org/abs/2506.07982

4. τ³-bench への発展と利用

τ³-bench は音声・知識検索・課題修正を追加

系列と年	加わった内容
τ-bench / 2024	業務ルールとツールを使う顧客対応
τ²-bench / 2025	顧客も操作する通信の技術サポート
τ³-bench / 2026	全二重音声、銀行の知識検索、既存課題の修正

Sierra (2026). τ-bench. 公式 GitHub 。 2026-10-16 参照。 https://github.com/sierra-research/tau2-bench

τ³ の銀行課題では、文書を調べてから操作する

- τ-Knowledge は、商品条件や手続きの文書を検索し、会話とツール操作を組み合わせる評価である。
- 公開版 v1.0.1 の銀行領域は 97 課題と 698 文書。カード、口座、手数料などを扱う。
- τ³-bench の公開実装には、この銀行領域と、音声対話の評価が含まれる。

Shi et al. (2026). τ-Knowledge: Evaluating Conversational Agents over Unstructured Knowledge. arXiv:2603.04370. https://arxiv.org/abs/2603.04370

τ³ の実例：利用条件に合うカードを探す

顧客役に渡す設定（英語・抜粋）

> You're looking for a credit card to use for your everyday purchases. You want the card that gives you the highest cash back available in the company profile. You will not accept a credit card that has any annual fees unless it is the ONLY option available.
> You receive a Rho-Bank+ subscription for free through your company. ONLY MENTION THIS if you are asked about this.

課題の内容：年会費なしで還元率の高いカードを探す。会社の Rho-Bank+ 加入資格を確認し、商品条件と照合する。

Sierra. τ³-bench / banking_knowledge / v1.0.1. ID: task_001.
https://github.com/sierra-research/tau2-bench/blob/v1.0.1/data/tau2/domains/banking_knowledge/tasks.json

銀行の実例は、文書・顧客情報・申込をつなぐ

確認するもの	公開課題の内容
商品文書	Gold Rewards Card ：年会費 0 ドル、還元率 2.5%
利用条件	Rho-Bank+ の加入が必要
顧客への確認	会社が提供する無料の加入資格を持っている
目標の状態	顧客が Gold Rewards Card を申し込む

Sierra (2026). τ³-bench / v1.0.1. task_001 と Gold Rewards Card の商品文書。
https://github.com/sierra-research/tau2-bench/tree/v1.0.1/data/tau2/domains/banking_knowledge

τ³ の銀行 97 課題の公開評価

モデル／推論設定	pass^1	pass^4
Claude Opus 5 / max	48.71%	31.96%
GPT-5.5 / xhigh	44.59%	29.90%
Gemini 3.1 Pro / high	26.03%	9.28%

v1.0.1 。 AllTools ＝語句・意味・シェル検索。顧客役 GPT-5.2 、 4 試行。

Sierra (2026). τ-bench official leaderboard submissions. banking_knowledge / AllTools. 2026-10-16 参照。
https://github.com/sierra-research/tau2-bench/tree/main/web/leaderboard/public/submissions

τ³ の音声評価では、話す・聞くが同時に進む

- τ-Voice は、小売・航空・通信の課題を、同時に発話と聴取が進む全二重音声へ拡張する。割込みや相づちも扱う。
- 2026-10-14 公開の Grok Voice 3.0 にも採用され、Sierra の通信領域の音声評価は 82.46% だった。顧客役は GPT-5.5 xhigh 、各課題 1 試行。

Ray et al. (2026). τ-Voice: Benchmarking Full-Duplex Voice Agents on Real-World Domains. arXiv:2603.13686. https://arxiv.org/abs/2603.13686

Sierra (2026-10-14). Grok Voice 3.0 submission. τ³-bench / full-duplex voice. https://github.com/sierra-research/tau2-bench/tree/main/web/leaderboard/public/submissions/grok-voice-3-0_xai_2026-10-14

v1.0.1 では銀行領域の採点を修正した

- τ³-bench は、ソフトウェアでは v1.0.1 として配布される。ベンチマークの系列名と、実装の版番号はこの対応になる。
- v1.0.1 では、正しい確認操作まで失敗にしていたデータベース比較や、 ATM 手数料の返金額などを修正した。
- 例えば銀行 task_074 の Light Blue 口座は、無料引出しの条件に基づく返金額が 8 ドルから 14.50 ドルへ直された。

Sierra (2026). τ-bench: Release Notes. v1.0.1 、銀行領域の採点と課題の修正。 https://github.com/sierra-research/tau2-bench/blob/v1.0.1/RELEASE_NOTES.md

τ² の公開版を固定して実行する

```
git clone https://github.com/sierra-research/tau2-bench
cd tau2-bench
git checkout v0.2.0
pip install -e .

tau2 run --domain telecom --agent-llm gpt-4.1 \
  --user-llm gpt-4.1 --num-trials 4 --num-tasks 1
```

モデル提供元の API キーを設定して実行する。データとコードは MIT License 。

Sierra (2026). τ-bench. 公式 GitHub 。 2026-10-16 参照。 https://github.com/sierra-research/tau2-bench

τ²-bench は顧客との共同作業を評価する

- 顧客の希望と業務ルールを踏まえ、会話とツール操作で注文・予約・端末の状態を変える。
- 通信では顧客にも操作してもらい、採点は処理後の状態や伝達情報で行う。 pass^k は繰返しの成功も測る。
- 後続の τ³-bench では、知識文書の検索と全二重音声へ評価の範囲が広がっている。

Barres et al. (2025). τ²-Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982. https://arxiv.org/abs/2506.07982

Appendix

1. 追加の顧客対応課題
2. 指標・版・公開データ
3. 開発者と参考文献

1. 追加の顧客対応課題

追加例 1 ：小売：商品数の照会と 3 商品の返品

顧客役に渡す設定（英語・抜粋）

> You want to know how many tshirt options are available in the online store right now. You want to also return the cleaner, headphone, and smart watch.

課題の内容：Ｔシャツの選択肢は 10 種類と伝え、クリーナー・ヘッドホン・スマートウォッチを返品する。

Sierra. τ^2-bench / retail / v0.2.0. ID: 2. https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/retail/tasks.json

追加例２：小売：注文済みのＴシャツを変更

顧客役に渡す設定（英語・抜粋）

> You want to know how many tshirt options are available in the online store right now. You want to modify all your pending small tshirt to purple, same size, same v-neck, and prefer polyester.

課題の内容：未発送の小さいＴシャツを紫色へ変更する。サイズとＶネックを保ち、素材はポリエステルを優先する。

Sierra. τ^2-bench / retail / v0.2.0. ID: 3. https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/retail/tasks.json

追加例３：小売：確認後に交換対象が変わる

顧客役に渡す設定（英語・抜粋）

> You want to exchange the water bottle and the desk lamp. You want to exchange the water bottle to a bigger one, and the desk lamp to a less bright one (prefer battery > USB > AC). If the agent asks for confirmation, only exchange the desk lamp.

課題の内容：水筒と照明の交換を希望するが、確認を求められた後は照明だけを交換する。照明の電源方式にも希望がある。

Sierra. τ^2-bench / retail / v0.2.0. ID: 6. https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/retail/tasks.json

追加例 4 ：航空：取消条件を満たさない予約

顧客役に渡す設定（英語・抜粋）

> You want to cancel reservation EHGLP3. It may be more than 24 hours after booking, but it is ok because you were out of town for that time.

課題の内容：保険に入らなかった経緯を伝えて取消を求める。課題の目標は、ルールに基づいて取消を断り、予約を変更しないこと。

Sierra. τ^2-bench / airline / v0.2.0. ID: 0. https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/airline/tasks.json

追加例 5 ：航空：預けられる手荷物の数を調べる

顧客役に渡す設定（英語・抜粋）

> You want to figure out the total number of suitcases the reservation allows you to take on your upcoming flight. You have a lot of things you need to bring with you on this trip. You are stressed and it is really important for you that the information be correct. You're pretty sure that you're a Gold member.

課題の内容：会員ランクを含む予約情報から、預けられる手荷物数を確認し、４個と案内する。

Sierra. τ^2-bench / airline / v0.2.0. ID: 3. https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/airline/tasks.json

追加例 6 ：通信：機内モードと SIM の不具合

顧客役に渡す設定（英語・抜粋）

> Your phone has been showing 'No Service' for the past few hours.

課題の内容：圏外の原因として、機内モード ON と SIM の接続不良を設定する。機内モードを切り、 SIM を入れ直して接続を確認する。

Sierra. τ^2-bench / telecom / v0.2.0. ID: [service_issue]airplane_mode_on|unseat_sim_card.
https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/telecom/tasks.json

追加例 7 ：通信：海外の MMS を復旧する

顧客役に渡す設定（英語・抜粋）

> You are unable to send MMS messages using your messaging app for the past few hours. You want to fix it and successfully send an MMS message.

課題の内容：端末のネットワーク選択と、企業側のローミング設定を直す。 4G ・ 5G 優先とローミング有効化を組み合わせる。

Sierra. τ^2-bench / telecom / v0.2.0. ID: [mms_issue]bad_network_preference|user_abroad_roaming_disabled_on.
https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/telecom/tasks.json

追加例 8 ：通信： MMS の権限と通信を直す

顧客役に渡す設定（英語・抜粋）

> You are unable to send MMS messages using your messaging app for the past few hours. You want to fix it and successfully send an MMS message.

課題の内容：メッセージアプリの SMS 権限がなく、データ通信も OFF 。権限の許可と通信 ON の後に MMS 送信を確認する。

Sierra. τ^2-bench / telecom / v0.2.0. ID: [mms_issue]break_app_sms_permission|data_mode_off.
https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/telecom/tasks.json

追加例 9 ：通信：技術に不慣れな顧客を案内する

顧客役に渡す設定（英語・抜粋）

> Your phone has been showing 'No Service' for the past few hours. Your technical knowledge is quite limited. Step-by-step instructions often confuse you, and technical terms like "VPN" or "APN" might as well be a foreign language. You only share information when specifically asked.

課題の内容：技術への不安が強い Hard 設定の顧客。機内モードと APN 設定の問題を、操作の説明と確認を通じて直す。

Sierra. τ^2-bench / telecom / v0.2.0. ID: [service_issue]airplane_mode_on|break_apn_settings.
https://github.com/sierra-research/tau2-bench/blob/v0.2.0/data/tau2/domains/telecom/tasks.json

追加例 10 ： τ³ 銀行： ATM 手数料を返金する

顧客役に渡す設定（英語・抜粋）

> You have four checking accounts with Rho-Bank - a Purple Account, a Light Blue Account, a Dark Green Account, and an Evergreen Account. You were looking at your November transaction history and some of the ATM fees don't look right to you.

課題の内容： 4 口座の条件と履歴を調べる。 v1.0.1 の参照解法では、 27.00 、 14.50 、 4.75 、 3.70 ドルの手数料を返金する。

Sierra. τ³-bench / banking_knowledge / v1.0.1. ID: task_074.
https://github.com/sierra-research/tau2-bench/blob/v1.0.1/data/tau2/domains/banking_knowledge/tasks.json

2. 指標・版・公開データ

通信課題に含まれる基本問題数（２～５）

基本問題の数	課題数
2	25
3	26
4	21
5	13

Sierra (2025). τ^2-bench. 公開版 v0.2.0 、 278 課題。 2026-10-16 集計。 https://github.com/sierra-research/tau2-bench/tree/v0.2.0/data/tau2/domains

通信課題に含まれる基本問題数（6〜9）

基本問題の数	課題数
6	11
7	8
8	4
9	6

Sierra (2025). τ²-bench. 公開版 v0.2.0 、 278 課題。 2026-10-16 集計。 https://github.com/sierra-research/tau2-bench/tree/v0.2.0/data/tau2/domains

公開版の読取・更新ツールの数

領域	担当者：読取／更新	顧客：読取／更新
小売	6 ／ 7	なし
航空	6 ／ 6	なし
通信	6 ／ 6	15 ／ 15

Sierra (2025). τ²-bench: domain tools. 公開版 v0.2.0 の READ ・ WRITE 指定を集計。 https://github.com/sierra-research/tau2-bench/tree/v0.2.0/src/tau2/domains

参照操作を再生して、目標の状態を作る

- 小売・航空の actions には、課題を解く参照操作列が入る。初期環境にその操作を適用して、目標のデータベース状態を作る。
- 評価対象の担当者による処理結果を、この目標状態と比較する。
- 通信の env_assertions には、端末の接続、速度、データ追加量などの検査関数を指定する。

Sierra (2025). τ²-bench: evaluator.py. 報酬に用いる採点要素。 https://github.com/sierra-research/tau2-bench/blob/v0.2.0/src/tau2/evaluator/evaluator.py

pass^k は成功する試行の組合せから求める

```
from math import comb

# 4 試行中 3 回成功した課題
pass_1 = comb(3, 1) / comb(4, 1)  # 0.75
pass_2 = comb(3, 2) / comb(4, 2)  # 0.50
pass_4 = comb(3, 4) / comb(4, 4)  # 0.00
```

各課題で計算し、全課題で平均する。公式 pass_hat_k の計算式。

Sierra (2025). τ²-bench: agent_metrics.py. pass^k の集計。 https://github.com/sierra-research/tau2-bench/blob/v0.2.0/src/tau2/metrics/agent_metrics.py

系列名とソフトウェアの版の対応

対象	本資料で使う版・資料
τ-bench	2024 年の小売・航空と会話評価の提案
τ^2-bench	2025 年の通信・共同操作。公開版 v0.2.0
τ^3-bench	2026 年の音声・知識検索。公開版 v1.0.1

Sierra (2026). τ-bench. 公式 GitHub 。 2026-10-16 参照。 https://github.com/sierra-research/tau2-bench

τ^3 の銀行は 97 課題と 698 文書を公開

公開物	役割
tasks.json / 97 課題	顧客設定・初期状態・参照操作・完了条件
documents / 698 文書	商品条件、業務ルール、操作の説明
db.json などの環境	口座・取引・申込結果などの状態

Sierra (2026). τ^3-bench: banking_knowledge. 公開版 v1.0.1 、 97 課題。 https://github.com/sierra-research/tau2-bench/tree/v1.0.1/data/tau2/domains/banking_knowledge

τ^3 は v1.0.1 の公開実装から利用できる

```
git checkout v1.0.1
uv sync --extra knowledge

tau2 run --domain banking_knowledge \
  --agent-llm gpt-5.2 --user-llm gpt-5.2 \
  --num-trials 4 --num-tasks 1
```

銀行の検索方式や提供元の API 設定は、公式の Knowledge 文書で指定する。

Sierra (2026). τ-bench. 公式 GitHub 。 2026-10-16 参照。 https://github.com/sierra-research/tau2-bench

3. 開発者と参考文献

Sierra が共同操作の顧客対応環境を提案した

- 共同第一著者は Victor Barres と Honghua Dong 。発表時の所属は、 Sierra 、および Sierra ・ University of Toronto ・ Vector Institute である。
- 最終著者の Karthik Narasimhan は Sierra 所属。先行する τ-bench と、後続の知識検索・音声評価にも携わる。
- τ^2-bench は 2025 年 6 月公開。業務上の問題解決と顧客への操作説明を、制御できる環境で調べる研究である。

Barres et al. (2025). τ^2-Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982. https://arxiv.org/abs/2506.07982

参考文献

τ^2-Bench: Evaluating Conversational Agents in a Dual-Control Environment

Victor Barres, Honghua Dong et al. / 2025 / arXiv:2506.07982

顧客と担当者が共同で操作する環境、通信課題の合成、採点と初期評価を説明する。

https://arxiv.org/abs/2506.07982

参考文献

τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains

Shunyu Yao, Noah Shinn et al. / 2024 / arXiv:2406.12045

小売・航空の会話とツール操作を評価し、繰返しの信頼性を測る pass^k を導入した。

https://arxiv.org/abs/2406.12045

参考文献

τ-Knowledge: Evaluating Conversational Agents over Unstructured Knowledge

Quan Shi, Alexandra Zytek et al. / 2026 / arXiv:2603.04370

文書検索、業務ルールの適用、銀行の状態変更を組み合わせる評価を説明する。

https://arxiv.org/abs/2603.04370

参考文献

τ-Voice: Benchmarking Full-Duplex Voice Agents on Real-World Domains

Soham Ray, Keshav Dhandhania, Victor Barres et al. / 2026 / arXiv:2603.13686

実際の処理の完了と、割込みなどの音声対話の進め方を合わせて評価する。

https://arxiv.org/abs/2603.13686

参考文献

τ-bench: Official implementation

Sierra / 2026 参照 / GitHub

公開課題、模擬環境、評価コード、各系列の利用方法を確認できる。

https://github.com/sierra-research/tau2-bench

Gemini 3.1 Pro

Google DeepMind / 2026 / Model performance

τ^2-bench の小売・通信を含む、プロプライエタリモデルの公式比較表。

https://deepmind.google/models/gemini/pro/

参考文献

τ-bench: Release Notes

Sierra / 2026 / v1.0.1

銀行の状態比較と参照解法の修正内容を説明する。

https://github.com/sierra-research/tau2-bench/blob/v1.0.1/RELEASE_NOTES.md

τ-bench leaderboard submissions

Sierra / 2026 参照 / Public submissions

銀行の検索付き評価、音声評価、顧客役と試行数などの条件を公開する。

https://github.com/sierra-research/tau2-bench/tree/main/web/leaderboard/public/submissions