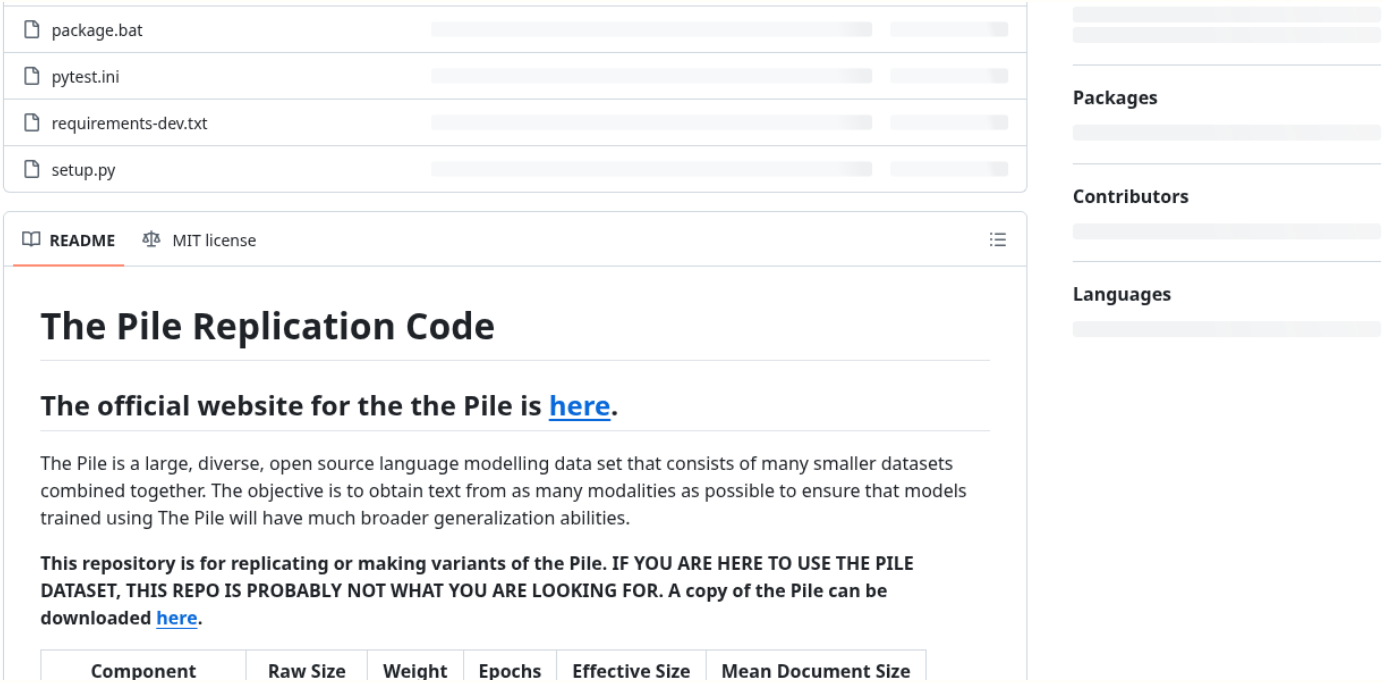
The Pile

An 800GB Dataset of Diverse Text
for Language Modeling

22 の文章集合からなる英語の事前学習コーパス

sasakiy84

公式リポジトリ



[1] EleutherAI. The Pile Replication Code. https://github.com/EleutherAI/the-pile

1. 多様な文章を次の語の予測へ
2. 22 の構成要素と混合の設計
3. 多分野の文章で学習する効果
4. 研究利用と入手条件

1. 多様な文章を次の語の予測へ

専門的な文章まで学習対象を広げる

- The Pile は、 Web 、論文、書籍、コード、会話など 22 の構成要素を混ぜた、主に英語の事前学習用テキストである。
- Web 以外の専門的な文章まで学習対象を広げ、幅広い分野で文章を予測できる言語モデルを目指した。 Leo Gao ら EleutherAI の共同研究として 2020 年末に公開された。
- 文章に続くトークンを予測するために、本文そのものを学習信号として使う。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

Web の告知文 | Pile-CC

公開サンプルの本文から抜粋

Topic: reinvent midnight madness

Amazon announced a new service at the AWS re:Invent Midnight Madness event. Amazon Sumerian is a solution that aims to make it easier for developers to build virtual reality, augmented reality, and 3D applications.

日本語訳

話題： re:Invent の Midnight Madness

Amazon は AWS re:Invent の Midnight Madness イベントで新サービスを発表した。 Amazon Sumerian は、開発者が仮想現実、拡張現実、3D アプリケーションを構築しやすくすることを目指したサービスだ。

Web の告知では、サービス名と用途が続けて述べられる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

コード由来の設定ファイル｜ Github

公開サンプルの本文から抜粋

```
{
  "fpsLimit": 60,
  "preset": "basic",
  "background": {
    "color": "#0d47a1",
```

日本語訳

fpsLimit は 60 、 preset は basic 。background の color は #0d47a1 と指定されている。

Github には自然文だけでなく、 JSON の記号やキーも含まれる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

医学論文の抄録｜ PubMed Abstracts

公開サンプルの本文から抜粋

Standardised protocol for primate faecal analysis.
Macroscopic analysis of primate faeces as a way to study diet is well established, but lack of standardisation of methods may handicap comparative studies of the resulting data.

日本語訳

霊長類の糞便分析の標準化プロトコル。
食性を調べる方法として霊長類の糞便を肉眼で分析することは確立しているが、手法が標準化されていないため、得られたデータの比較研究に支障が生じる可能性がある。

抄録では、専門用語を含む研究の記述を予測する。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

本文が、そのまま予測の対象になる

- モデルは直前までのトークンを読み、次のトークンへ確率を割り当てる。トークンは単語の一部や記号を含む単位で、 JSON の括弧や句読点も予測の対象になる。
- 学習では、実際に続くトークンへ高い確率を与えるようにする。評価では、学習に使わずに残した文書へ、どれだけ高い確率を与えられるかを測る。
- 前の 3 例は、 Web 、コード、医学論文という文章の違いを示す公開サンプルの抜粋である。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

2. 22 の構成要素と混合の設計

元の容量と、学習で読む量は異なる

量	定義	値
Raw size	反復前の構成要素の合計	825.18 GiB
Effective size	反復回数を掛けた合計	1,254.20 GiB
文書の平均長	反復前の全体平均	5.91 KiB

いずれも検証・テスト用の文書を取り分ける前の値。 GiB は 2^{30} byte 。重みは混合後のバイト比率である。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

文書の種類に合わせて収集・抽出する

- Pile-CC は Common Crawl から本文を抽出し、ナビゲーションなどの定型部分を抑える。 OpenWebText2 は Reddit で共有された外部ページを用いる。
- ArXiv では LaTeX からテキストを作り、 PubMed Central では論文全文を取り込む。特許は背景説明、 NIH は研究助成の要約と、出所に合わせて収録部分を選ぶ。
- 構成要素ごとに抽出・フィルタ・整形し、反復回数を設定した後、文書を混合・シャッフルする。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

大きな容量と大きな混合比は一致しない

構成要素	元容量 GiB	反復数	混合比 %
Pile-CC	227.12	1.0	18.11
PubMed Central	90.27	2.0	14.40
Books3	100.96	1.5	12.07
OpenWebText2	62.77	2.0	10.01
Wikipedia (en)	6.38	3.0	1.53

混合比は反復後のバイト比率。 Wikipedia は元容量の 3 倍を読む。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

検証・テスト文書で分野別に評価する

- 混合用の文書から検証・テスト用の文書を取り分ける。データは 1 行 1 文書の JSON Lines 形式で、本文と構成要素名が含まれる。
- 書籍や IRC ログは長く、百科事典や抄録は短い。平均文書サイズは、 Books3 が 538.36 KiB 、 Wikipedia が 1.11 KiB と大きく異なる。
- 長文の分割方法や、学習文との重複は評価結果に関わる。後には、元の Pile から重複文書を除いたバージョンも作られた。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

3. 多分野の文章で学習する効果

1 バイト当たりの予測損失で比べる

- Bits per byte （ BPB ）は、正解の文章へ割り当てた負の対数確率を、 UTF-8 のバイト数で割った値。小さいほど予測しやすかったことを示す。
- BPB = $-\Sigma \log_2 p$ （実際のトークン｜直前の文脈） / 採点対象のバイト数。文書ごとの BPB の単純平均ではなく、損失とバイト数を合算する。
- Perplexity はトークン数で正規化する。トークンの切り方が異なるモデル間では、 BPB の方が比較しやすい。ただし、使える文脈長などの条件も結果に影響する。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

40 GB の学習データで多分野へ汎化した

学習データ	Pile test BPB ↓	WikiText PPL ↓	LAMBADA % ↑
The Pile	0.9433	5.59	50.1
CC-100 (en)	1.3293	8.27	49.7
Raw CC	1.1275	11.75	43.8

同じ 1.3B モデルを各データの約 40 GB で学習。評価集合と重複する学習データを除去。 LAMBADA は末尾の単語を当てる正解率。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

4. 研究利用と入手条件

Pile は学習過程を調べる共通基盤にもなる

- Pythia は、 70M から 12B まで 8 サイズのモデルを、同じ Pile の文書順で学習した。各モデルの学習量は約 300B トークンである。
- 標準 Pile 版に加え、約 207B トークンの重複除去版を使う系列も公開した。約 300B トークンの学習は、標準版で 1 周弱、重複除去版で約 1.5 周に当たる。
- 学習途中のチェックポイントとデータ順を公開し、知識の獲得や記憶、モデル規模が学習に与える影響を調べる基盤になった。

[1] Biderman et al. (2023). Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. ICML. https://arxiv.org/abs/2304.01373
[2] EleutherAI. Pythia: Interpreting Transformers Across Time and Scale. https://github.com/EleutherAI/pythia

構成要素ごとに、本文の利用条件が異なる

- 公式 GitHub は再構築・変種作成のコードを MIT License で提供する。収録本文の権利は、 22 の出所ごとに異なる。
- 書籍、字幕、コード、公開メールなどには、それぞれの著作権、ライセンス、利用規約、本人の同意に関わる条件がある。
- 特定の構成要素を除いたバージョンも作れるが、個別文書の権利を判定するためのメタデータは不足している。データカードと元資料の条件を確かめる必要がある。

[1] EleutherAI. The Pile Replication Code. https://github.com/EleutherAI/the-pile
[2] Biderman et al. (2022). Datasheet for the Pile. arXiv. https://arxiv.org/abs/2201.07311

公式コードと公開サンプルから内容を調べられる

- 公式リポジトリから、構成要素の収集コードや配布先をたどれる。再構築では、どの構成要素を何回使うかを設定する。
- 内容を小さく試すには、先頭 10,000 文書を収めた公開サンプル pile-10k が使える。本資料の 13 例も、このサンプルの本文から選んだ抜粋である。
- 標準版・重複除去版・構成要素を除いたバージョンでは、収録文書や学習条件が変わる。利用する版と文書の出所を確かめる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

多分野の文章と、その混合条件が価値になる

- The Pile は、 22 の出所から 825.18 GiB のテキストを集め、反復回数を変えて約 1,254.20 GiB 相当を混合した英語の事前学習コーパスである。
- 約 40 GB にそろえた実験でも、 Web だけの学習より幅広い分野の予測損失が改善した。文章の種類と混合比が、何を学べるかに関わる。
- 多様な文章を混ぜる設計は、学習後の性能比較だけでなく、Pythia のように学習過程を調べる研究にも使われている。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

Appendix

1. 公開サンプルの追加例
2. 構成要素と利用条件
3. 参考文献

投資記事 | OpenWebText2

公開サンプルの本文から抜粋

Article content

Human behavior has a tremendous impact on investing — more so than most realize — and one of our biggest weaknesses is the tendency to constantly compare and contrast ourselves to others.

日本語訳

記事本文

人間の行動は、ほとんどの人が認識する以上に投資へ大きく影響する。私たちの大きな弱点の一つは、自分を常に他人と比べてしまう傾向だ。

OpenWebText2 は Reddit で共有された外部ページを収集した。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

物語についての質問｜ StackExchange

公開サンプルの本文から抜粋

Q:

Why was Mundungus banned from the Hog's Head?

日本語訳

質問：

マンダンガスはなぜホッグズ・ヘッドへの出入りを禁止されたのか。

StackExchange の Q/A も、この用途では本文の一部として扱う。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

百科事典の記事｜ Wikipedia (en)

公開サンプルの本文から抜粋

Major League Baseball All-Century Team

In 1999, the Major League Baseball All-Century Team was chosen by popular vote of fans.

日本語訳

メジャーリーグ・ベースボールの 20 世紀オールセンチュリー・チーム

1999 年、このチームはファンの人気投票で選ばれた。

Wikipedia のタイトルと本文が一続きのテキストになる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

特許の背景説明｜ USPTO Backgrounds

公開サンプルの本文から抜粋

In general, absorbent articles should comfortably fit the body of a wearer. Most absorbent articles include an absorbent pad formed by an absorbent core contained in a wrap comprising a barrier tissue and/or a forming tissue.

日本語訳

一般に、吸収性製品は着用者の身体に快適にフィットする必要がある。多くの吸収性製品は、バリアティッシュや成形ティッシュからなる包材に収めた吸収体を含む吸収パッドを備える。

USPTO Backgrounds は、発明の背景を説明する特許文書の部分集合。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

医学論文の本文｜ PubMed Central

公開サンプルの本文から抜粋

```
Introduction {#sec1-1}
============

Infliximab (IFX), a chimeric anti-TNFα antibody, is effective in inducing and maintaining remission in a considerable proportion of IBD patients refractory to any other treatments \[[@ref1],[@ref2]\].
```

日本語訳

```
序論 {#sec1-1}
============

キメラ型抗 TNFα 抗体のインフリキシマブ（IFX）は、他のどの治療にも抵抗性を示す IBD 患者のかなりの割合で、寛解の導入と維持に有効である。［参照 1 、 2 ］
```

PMC の全文には、見出しや変換時の参照記法も残る。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

業務メールの本文 | Enron Emails

公開サンプルの本文から抜粋

Ben-
This is a lengthy info/doc request - please give me feedback on how best we
can close the loop.

Thanks
Susan Flanagan

日本語訳

ベンへ
これは長文の情報・文書提供依頼です。この依頼への対応をどのように完了させるのがよいか、ご意見をください。

ありがとう。
スーザン・フラナガン

Enron Emails には、公開された企業の業務メールが収められている。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

ニュースの議論 | HackerNews

公開サンプルの本文から抜粋

Facebook has hired the Patriot Act's co-author as a general counsel - Jerry2
https://boingboing.net/2019/04/22/mass-surveillance-r-us.html
======

日本語訳

Facebook が愛国者法の共同起草者を法務責任者に採用した — Jerry2
https://boingboing.net/2019/04/22/mass-surveillance-r-us.html
======

HackerNews では投稿タイトル、リンク、コメントの構造が現れる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

判決の短い記録｜ FreeLaw

公開サンプルの本文から抜粋

477 F.2d 598
Zukowskiv.State Bar Grievance
Board, State Bar ofMichigan
73-1072
UNITED STATES COURT OF APPEALS
Sixth Circuit
4/18/73

日本語訳

477 F.2d 598
Zukowski 対ミシガン州弁護士会懲戒
委員会
73-1072
米国第 6 巡回区控訴裁判所
1973 年 4 月 18 日

FreeLaw は判例。裁判所名、事件番号、処分のような定型表現もある。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

研究助成の要約｜ NIH ExPorter

公開サンプルの本文から抜粋

Autosomal dominant polycystic kidney disease (ADPKD) is a common monoallelic disorder associated with progressive cyst development and resulting in end stage renal failure (ESRD) in 50% of patients by 60y.

日本語訳

常染色体優性多発性嚢胞腎（ADPKD）は、進行する嚢胞形成に関連する比較的よくみられる単一アレル性疾患であり、60 歳までに患者の 50% が末期腎不全（ESRD）に至る。

NIH ExPorter は研究助成の要約。医学論文とは文書の目的が異なる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

スポーツ大会の記録｜ Wikipedia (en)

公開サンプルの本文から抜粋

2017 XIXO Ladies Open Hódmezővásárhely – Doubles

Laura Pigossi and Nadia Podoroska were the defending champions, but both players chose not to participate.

日本語訳

2017 XIXO Ladies Open Hódmezővásárhely — ダブルス

前年優勝者は Laura Pigossi と Nadia Podoroska だったが、ともに出場を見送った。

同じ Wikipedia でも、人名や地名が本文の中心となる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

22 構成要素の容量と混合比（1/4）

構成要素	元容量 GiB	反復数	混合比 %
Pile-CC	227.12	1.0	18.11
PubMed Central	90.27	2.0	14.40
Books3	100.96	1.5	12.07
OpenWebText2	62.77	2.0	10.01
ArXiv	56.21	2.0	8.96
Github	95.16	1.0	7.59

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

22 構成要素の容量と混合比（2/4）

構成要素	元容量 GiB	反復数	混合比 %
FreeLaw	51.15	1.5	6.12
StackExchange	32.20	2.0	5.13
USPTO Backgrounds	22.90	2.0	3.65
PubMed Abstracts	19.26	2.0	3.07
Gutenberg (PG-19)	10.88	2.5	2.17
OpenSubtitles	12.98	1.5	1.55

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

22 構成要素の容量と混合比（3/4）

構成要素	元容量 GiB	反復数	混合比 %
Wikipedia (en)	6.38	3.0	1.53
DM Mathematics	7.75	2.0	1.24
Ubuntu IRC	5.52	2.0	0.88
BookCorpus2	6.30	1.5	0.75
EuroParl	4.59	2.0	0.73
HackerNews	3.90	2.0	0.62

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

22 構成要素の容量と混合比（4/4）

構成要素	元容量 GiB	反復数	混合比 %
YoutubeSubtitles	3.73	2.0	0.60
PhilPapers	2.38	2.0	0.38
NIH ExPorter	1.89	2.0	0.30
Enron Emails	0.88	2.0	0.14

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

構成要素が収録する文章（ 1/4 ）

構成要素	収録内容
Pile-CC	Common Crawl の Web 本文
PubMed Central	生物医学論文の全文
Books3	書籍の本文
OpenWebText2	Reddit で共有された外部ページ
ArXiv	LaTeX から抽出した学術論文
Github	公開リポジトリのコード

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

構成要素が収録する文章（2/4）

構成要素	収録内容
FreeLaw	裁判所の判決文
StackExchange	分野別の質問と回答
USPTO Backgrounds	米国特許の背景説明
PubMed Abstracts	生物医学論文の抄録
Gutenberg (PG-19)	Project Gutenberg の古典書籍
OpenSubtitles	映画・テレビ作品の字幕

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

構成要素が収録する文章（3/4）

構成要素	収録内容
Wikipedia (en)	英語の百科事典記事
DM Mathematics	生成器が作る数学の問題と答え
Ubuntu IRC	Ubuntu コミュニティのチャット
BookCorpus2	オンラインの小説
EuroParl	欧州議会の議事録
HackerNews	技術ニュースとコメント

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

構成要素が収録する文章（ 4/4 ）

構成要素	収録内容
YoutubeSubtitles	YouTube 動画の字幕
PhilPapers	哲学分野の学術論文
NIH ExPorter	米国 NIH の研究助成要約
Enron Emails	公開された企業の業務メール

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

公開・規約・同意の分類： 2020 年（ 1/4 ）

構成要素	公開	規約整合	著者同意
Pile-CC	○	○	—
PubMed Central	○	○	○
Books3	○	—	—
OpenWebText2	○	—	—
ArXiv	○	○	○
Github	○	○	—

2020 年の構築者による分類。○は該当、—は該当すると判断されていない。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling.
https://arxiv.org/abs/2101.00027

公開・規約・同意の分類： 2020 年（ 2/4 ）

構成要素	公開	規約整合	著者同意
FreeLaw	○	○	○
StackExchange	○	○	○
USPTO Backgrounds	○	○	○
PubMed Abstracts	○	○	○
Gutenberg (PG-19)	○	○	—
OpenSubtitles	○	—	—

2020 年の構築者による分類。○は該当、—は該当すると判断されていない。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling.
https://arxiv.org/abs/2101.00027

公開・規約・同意の分類： 2020 年（ 3/4 ）

構成要素	公開	規約整合	著者同意
Wikipedia (en)	○	○	○
DM Mathematics	○	○	○
Ubuntu IRC	○	○	○
BookCorpus2	○	—	—
EuroParl	○	○	○
HackerNews	○	○	—

2020 年の構築者による分類。○は該当、—は該当すると判断されていない。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling.
https://arxiv.org/abs/2101.00027

公開・規約・同意の分類： 2020 年（ 4/4 ）

構成要素	公開	規約整合	著者同意
YoutubeSubtitles	○	—	—
PhilPapers	○	○	○
NIH ExPorter	○	○	○
Enron Emails	○	○	—

2020 年の構築者による分類。○は該当、—は該当すると判断されていない。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling.
https://arxiv.org/abs/2101.00027

JSONL から本文と構成要素名を読み出す

```
import json
with open("sample.jsonl", encoding="utf-8") as f:
    doc = json.loads(next(f))
print(doc["meta"]["pile_set_name"])
print(doc["text"])
```

sample.jsonl は、 1 行に 1 文書の JSON を収めたファイル。 text が本文、meta.pile_set_name が出所の構成要素名を表す。

[1] EleutherAI (n.d.). The Pile Replication Code. https://github.com/EleutherAI/the-pile

公開・規約・著者の同意は別の軸である

- 2020 年の構築時には、インターネットで読めること、取得元の利用規約と整合すること、元の著者が利用に同意したことを調べた。前の一覧は、そのときの構築者による分類である。
- Github は公開かつ規約に整合すると整理された一方、著者の同意は一律には認められていない。書籍や字幕にも、公開されていても規約・同意の欄を満たさないものがある。
- この分類は個別文書のライセンス一覧ではないため、利用時には本文の出所に応じた条件の確認が必要になる。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

参考文献

Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. arXiv.

22 種類のテキストを収集・混合する設計と、分野別の言語モデル評価、内容の統計・社会的影響を記述した。

https://arxiv.org/abs/2101.00027

Biderman et al. (2022). Datasheet for the Pile. arXiv.

構成、収集・処理方法、利用目的、配布、倫理的検討をデータシートの形式で整理した。

https://arxiv.org/abs/2201.07311

参考文献

Biderman et al. (2023). Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. ICML.

同じデータ順で異なる規模のモデルを学習し、途中のチェックポイントとともに学習過程の比較基盤を公開した。

https://arxiv.org/abs/2304.01373

EleutherAI (n.d.). The Pile Replication Code. （2026-10-18 参照）

The Pile の再構築コード、各構成要素の収集実装、反復回数と容量表を公開する公式リポジトリ。

https://github.com/EleutherAI/the-pile

参考文献

Neel Nanda (2022). pile-10k: The first 10K elements of The Pile.

The Pile の先頭 10,000 文書を、デバッグ向けに公開した小規模サンプル。本文と構成要素名の形式を試せる。

https://huggingface.co/datasets/NeelNanda/pile-10k