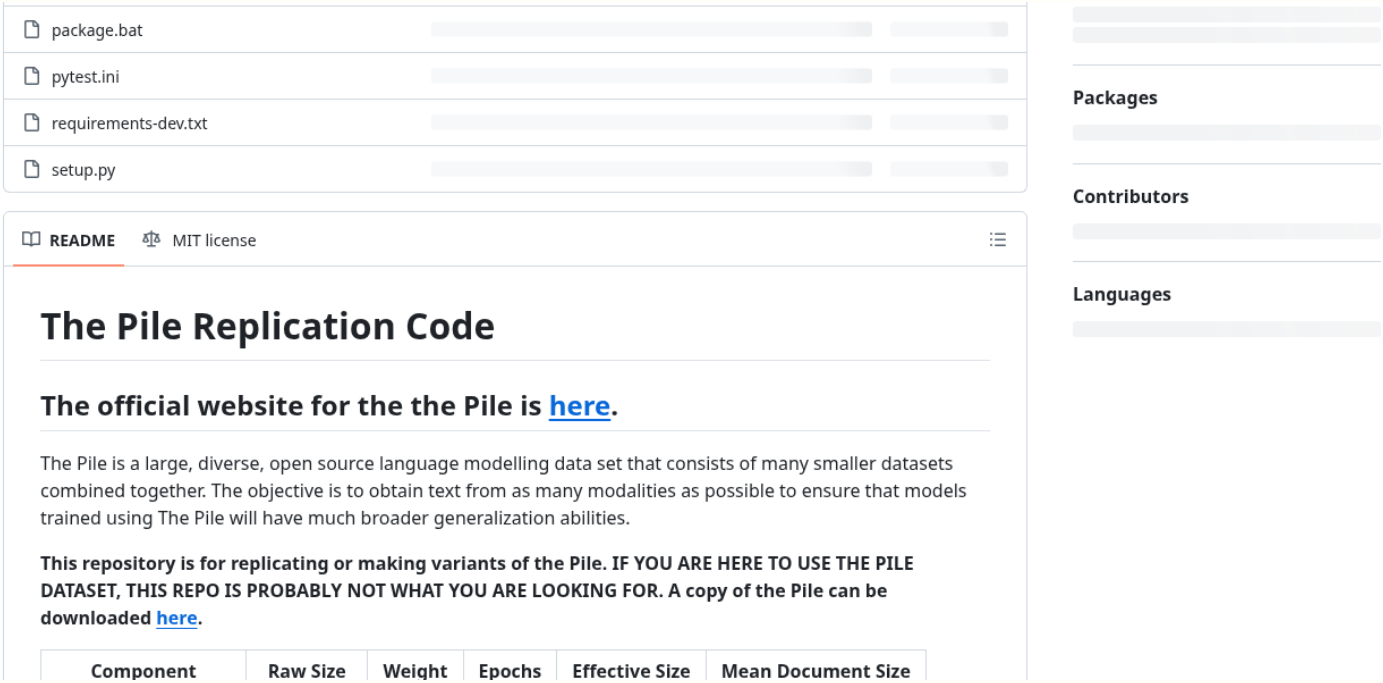
The Pile

An 800GB Dataset of Diverse Text
for Language Modeling

22 の文章集合からなる英語の事前学習コーパス

sasakiy84

公式リポジトリ



[1] EleutherAI. The Pile Replication Code. https://github.com/EleutherAI/the-pile

1. 多様な文章を次の語の予測へ
2. 22 の構成要素と混合の設計
3. 学習効果と HELM での評価
4. 研究利用と入手条件

1. 多様な文章を次の語の予測へ

専門的な文章まで学習対象を広げる

- The Pile は、 Web 、論文、書籍、コード、会話など 22 の構成要素を混ぜた、主に英語の事前学習用テキストである。
- 幅広い分野の文章を使い、特定の Web 文体に偏らない言語モデルを目指した。 Leo Gao ら EleutherAI の共同研究として 2020 年末に公開された。
- 質問に答えを付けた問題集ではない。文章に続くトークンを予測するために、文章自体を学習信号として使う。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

Web の告知文 | Pile-CC

公開 10k サンプル / row 3 / 全文 384 字からの連続抜粋

Topic: reinvent midnight madness

Amazon announced a new service at the AWS re:Invent Midnight Madness event. Amazon Sumerian is a solution that aims to make it easier for developers to build virtual reality, augmented reality, and 3D applications.

日本語訳

話題： re:Invent の Midnight Madness

Amazon は AWS re:Invent の Midnight Madness イベントで新サービスを発表した。 Amazon Sumerian は、開発者が仮想現実、拡張現実、3D アプリケーションを簡単に構築できるようにする。

Web の告知では、サービス名と用途が続けて述べられる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

コード由来の設定ファイル｜ Github

公開 10k サンプル / row 11 / 全文 179 字からの連続抜粋

```
{
  "fpsLimit": 60,
  "preset": "basic",
  "background": {
    "color": "#0d47a1",
```

日本語訳

fpsLimit は 60 、 preset は basic 。 background の color は #0d47a1 と指定されている。

Github には自然文だけでなく、 JSON の記号やキーも含まれる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

医学論文の抄録｜ PubMed Abstracts

公開 10k サンプル / row 20 / 全文 543 字からの連続抜粋

Standardised protocol for primate faecal analysis.
Macroscopic analysis of primate faeces as a way to study diet is well established, but lack of standardisation of methods may handicap comparative studies of the resulting data.

日本語訳

霊長類の糞便分析の標準化プロトコル。
食性を調べる方法として霊長類の糞便を肉眼で分析することは確立しているが、手法が標準化されていないため、得られたデータの比較研究に支障が生じる可能性がある。

抄録では、専門用語を含む研究の記述を予測する。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

本文が、そのまま予測の対象になる

- 入力は文書のテキスト。モデルは直前までのトークンを条件に、次のトークンへ確率を割り当てる。 JSON の括弧や句読点も対象となる。
- 学習時には各位置の実際のトークンとの負の対数尤度を小さくする。評価時には、固定した保留文書へ与えた確率を集計する。
- 前の 3 例は公開 10k サンプルの本文抜粋で、 HELM が選んだテスト文書ではない。 HELM では長い文書をモデルの文脈長に合わせて窓へ分け、本文の尤度を計算する。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027
[2] Stanford CRFM. HELM v0.4.0: ThePileScenario. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/the_pile_scenario.py

2. 22 の構成要素と混合の設計

元の容量と、学習で読む量は異なる

量	定義	値
Raw size	反復前の構成要素の合計	825.18 GiB
Effective size	反復回数を掛けた合計	1,254.20 GiB
平均文書サイズ	反復前の全体平均	5.91 KiB

いずれも保留集合を作る前の値。 GiB は 2^{30} byte 。重みは混合後のバイト比率である。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

文書の種類に合わせて収集・抽出する

- Pile-CC は Common Crawl から本文を抽出し、ナビゲーションなどの定型部分を抑える。 OpenWebText2 は Reddit で共有された外部ページを用いる。
- ArXiv では LaTeX からテキストを作り、 PubMed Central では論文全文を取り込む。特許は背景説明、 NIH は研究助成の要約と、必要な部分を選ぶ。
- 注釈者が正解ラベルを付ける方式ではない。構成要素別の抽出、フィルタ、整形の後に反復回数を設定し、文書を混合・シャッフルする。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

大きな容量と大きな混合比は一致しない

構成要素	元容量 GiB	反復数	混合比 %
Pile-CC	227.12	1.0	18.11
PubMed Central	90.27	2.0	14.40
Books3	100.96	1.5	12.07
OpenWebText2	62.77	2.0	10.01
Wikipedia (en)	6.38	3.0	1.53

混合比は反復後のバイト比率。 Wikipedia は元容量の 3 倍を読む。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

文書単位の保留集合で分野別に評価する

- 混合用の文書から検証・テスト用の文書を取り分ける。データは JSON Lines 形式で、各行に text と meta.pile_set_name が含まれる。
- 書籍や IRC ログは長く、百科事典や抄録は短い。平均文書サイズは、 Books3 が 538.36 KiB 、 Wikipedia が 1.11 KiB と大きく異なる。
- 長い文書をどう窓に分けるか、学習データの重複をどう除くかが評価結果に関わる。元の Pile と重複除去版は、別の学習条件として区別する。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

3. 学習効果と HELM での評価

1 バイト当たりの予測損失で比べる

- Bits per byte （ BPB ）は、正解の文章へ割り当てた負の対数確率を、 UTF-8 のバイト数で割った値。小さいほど予測しやすかったことを示す。
- BPB = $-\Sigma \log_2 p$ （実際のトークン｜直前の文脈） / 採点対象のバイト数。文書ごとの BPB の単純平均ではなく、損失とバイト数を合算する。
- Perplexity はトークン数で正規化する。トークンの切り方が異なるモデル間では、 BPB の方が比較しやすい。ただし、使える文脈長などの条件も結果に影響する。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027
[2] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

40 GB の学習データで多分野へ汎化した

学習データ	Pile test BPB ↓	WikiText PPL ↓	LAMBADA % ↑
The Pile	0.9433	5.59	50.1
CC-100 (en)	1.3293	8.27	49.7
Raw CC	1.1275	11.75	43.8

同じ 1.3B モデルを各データの約 40 GB で学習。評価集合との 13-gram 重複を除去。 LAMBADA は末尾の単語を当てる正解率。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

HELM は 6 分野のテスト本文を使う

- HELM Classic v0.4.0 の公開 run 仕様では、 ArXiv 、 BookCorpus2 、 Enron Emails 、 Github 、 PubMed Central 、 Wikipedia (en) の 6 構成要素を評価する。
- テスト集合の構成要素別文書を読み、 lm_perplexity の group0 の索引で部分抽出する。 BookCorpus2 は文書数が少ないため、この 10 分割を行わない。
- 採点は language_modeling 方式。学習例は 0 、試行は 1 、最大評価文書数は 1,000 。生成する回答はなく、 max_tokens は 0 に設定される。

[1] Stanford CRFM. HELM v0.4.0: ThePileScenario. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/the_pile_scenario.py

HELM の BPB は分野ごとに傾向が異なる

モデル	ArXiv	Github	Wikipedia
text-davinci-003 (2022)	0.5551	0.2045	0.5573
BLOOM (2022)	0.5773	0.2689	0.5879
OPT-175B (2022)	0.7296	0.4434	0.5522

Classic v0.4.0 掲載、元 run suite v0.3.0 。各 1 試行。 ArXiv は 238 文書、他は各 1,000 文書。モデル別の文脈長・分割条件を含む結果。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

評価条件まで合わせて損失を読む

- ArXiv では text-davinci-003 の BPB が 0.5551 、 BLOOM が 0.5773 。 Github でも text-davinci-003 が小さく、 Wikipedia では OPT-175B が 0.5522 と最小だった。
- これは 2023 年の HELM Classic 公開実行の比較である。 2026 年時点のモデル順位を示す値ではない。
- 同じテスト文書でもモデルの文脈窓とトークン化が異なる。今回の 9 実行の prompt_truncated 平均はいずれも 0 だが、長文はアダプター内で複数の窓へ分割される。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110
[2] Stanford CRFM. HELM v0.4.0: ThePileScenario. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/the_pile_scenario.py

4. 研究利用と入手条件

Pile は学習過程を調べる共通基盤にもなる

- Pythia は、 70M から 12B まで 8 サイズのモデルを、同じ Pile の文書順で学習した。各モデルの学習量は約 300B トークンである。
- 標準 Pile 版に加え、約 207B トークンの重複除去版を使う系列も公開した。同じ約 300B トークンは、標準版で 1 周弱、重複除去版で約 1.5 周に当たる。
- 学習途中のチェックポイントとデータ順を対応させ、知識の獲得、記憶、学習規模の影響を調べる。公式リポジトリは 2025 年の派生研究も案内している。

[1] Biderman et al. (2023). Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. ICML. https://arxiv.org/abs/2304.01373
[2] EleutherAI. Pythia: Interpreting Transformers Across Time and Scale. https://github.com/EleutherAI/pythia

再構築コードと本文の権利を分けて確認する

- 公式 GitHub は再構築・変種作成のコードを提供し、 README から配布先を案内している。コードの MIT License は、収録本文すべての利用許諾を意味しない。
- 本文の出所は 22 通りあり、著作権、ライセンス、利用規約、本人の同意の扱いが異なる。書籍、字幕、コード、公開メールを一つの条件で扱うことはできない。
- 特定の構成要素を除いた変種を作れるが、個別文書の権利を精密に判定できるメタデータは不足している。データカードと各元資料の条件を組み合わせて確認する。

[1] EleutherAI. The Pile Replication Code. https://github.com/EleutherAI/the-pile
[2] Biderman et al. (2022). Datasheet for the Pile. arXiv. https://arxiv.org/abs/2201.07311

入手時には構成要素と分割を固定する

- 再現する対象が元の Pile か、重複除去版か、構成要素を除いた変種かを決める。学習・検証・テストの分割とファイルのハッシュを保存する。
- HELM v0.4.0 の実装は the-eye.eu の test.jsonl.zst と、lm_perplexity の索引を参照する。配布 URL や権利条件は取得時に再確認する。
- 本資料の 13 例は、公開 pile-10k の先頭 100 行だけを取得したもの。原文・連続した表示範囲・訳・行番号・ハッシュは付属の examples.json に保存した。

[1] Stanford CRFM. HELM v0.4.0: ThePileScenario. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/the_pile_scenario.py
[2] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

多分野の文章と、その混合条件が価値になる

- The Pile は、 22 の出所から 825.18 GiB のテキストを集め、反復回数を変えて約 1,254.20 GiB 相当を混合した英語の事前学習コーパスである。
- 約 40 GB にそろえた実験でも、 Web だけの学習より幅広い分野の予測損失が改善した。 HELM はその一部を、分野別の本文尤度評価に用いている。
- 文書の種類、混合比、重複除去、評価時の文脈窓、出所ごとの利用条件を対応させると、得点と研究利用の意味を具体的に把握できる。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

Appendix

1. 公開サンプルの追加例
2. 構成要素と評価条件
3. 制作機関と参考文献

投資記事 | OpenWebText2

公開 10k サンプル / row 2 / 全文 1235 字からの連続抜粋

Article content

Human behavior has a tremendous impact on investing — more so than most realize — and one of our biggest weaknesses is the tendency to constantly compare and contrast ourselves to others.

日本語訳

記事本文

人間の行動は、ほとんどの人が認識する以上に投資へ大きく影響する。私たちの大きな弱点の一つは、自分を常に他人と比べてしまう傾向だ。

OpenWebText2 は Reddit で共有された外部ページを収集した。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

物語についての質問｜ StackExchange

公開 10k サンプル / row 5 / 全文 2016 字からの連続抜粋

Q:

Why was Mundungus banned from the Hog's Head?

日本語訳

質問：

マンダンガスはなぜホッグズ・ヘッドへの出入りを禁止されたのか。

StackExchange の Q/A も、この用途では本文の一部として扱う。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

百科事典の記事｜ Wikipedia (en)

公開 10k サンプル / row 10 / 全文 2665 字からの連続抜粋

Major League Baseball All-Century Team

In 1999, the Major League Baseball All-Century Team was chosen by popular vote of fans.

日本語訳

メジャーリーグ・ベースボールの 20 世紀オールセンチュリー・チーム

1999 年、このチームはファンの人気投票で選ばれた。

Wikipedia のタイトルと本文が一続きのテキストになる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

特許の背景説明｜ USPTO Backgrounds

公開 10k サンプル / row 18 / 全文 1711 字からの連続抜粋

In general, absorbent articles should comfortably fit the body of a wearer. Most absorbent articles include an absorbent pad formed by an absorbent core contained in a wrap comprising a barrier tissue and/or a forming tissue.

日本語訳

一般に、吸収性製品は着用者の身体に快適にフィットする必要がある。多くの吸収性製品は、バリアティッシュや成形ティッシュからなる包材に収めた吸収体を含む吸収パッドを備える。

USPTO Backgrounds は、発明の背景を説明する特許文書の部分集合。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

医学論文の本文｜ PubMed Central

公開 10k サンプル / row 54 / 全文 12919 字からの連続抜粋

```
Introduction {#sec1-1}
============

Infliximab (IFX), a chimeric anti-TNFα antibody, is effective in inducing and maintaining remission in a considerable proportion of IBD patients refractory to any other treatments \[[@ref1],[@ref2]\].
```

日本語訳

```
序論 {#sec1-1}
============

キメラ型抗 TNFα 抗体のインフリキシマブ（IFX）は、他のどの治療にも抵抗性を示す IBD 患者のかなりの割合で、寛解の導入と維持に有効である。［参照 1 、 2 ］
```

PMC の全文には、見出しや変換時の参照記法も残る。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

業務メールの本文｜ Enron Emails

公開 10k サンプル / row 55 / 全文 362 字からの連続抜粋

Ben-
This is a lengthy info/doc request - please give me feedback on how best we
can close the loop.

Thanks
Susan Flanagan

日本語訳

ベンへ
これは長文の情報・文書提供依頼です。どのように対応を完結させるのが最善か、ご意見をください。

ありがとう。
スーザン・フラナガン

Enron Emails は公開された業務メール。ここでは本文だけを抜粋する。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

ニュースの議論 | HackerNews

公開 10k サンプル / row 63 / 全文 2867 字からの連続抜粋

Facebook has hired the Patriot Act's co-author as a general counsel - Jerry2
https://boingboing.net/2019/04/22/mass-surveillance-r-us.html
======

日本語訳

Facebook が愛国者法の共同起草者を法務責任者に採用した — Jerry2
https://boingboing.net/2019/04/22/mass-surveillance-r-us.html
======

HackerNews では投稿タイトル、リンク、コメントの構造が現れる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

判決の短い記録｜ FreeLaw

公開 10k サンプル / row 70 / 全文 155 字からの連続抜粋

477 F.2d 598
Zukowskiv.State Bar Grievance
Board, State Bar ofMichigan
73-1072
UNITED STATES COURT OF APPEALS
Sixth Circuit
4/18/73

日本語訳

477 F.2d 598
Zukowski 対ミシガン州弁護士会懲戒
委員会
73-1072
米国第 6 巡回区控訴裁判所
1973 年 4 月 18 日

FreeLaw は判例。裁判所名、事件番号、処分のような定型表現もある。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

研究助成の要約｜ NIH ExPorter

公開 10k サンプル / row 74 / 全文 4010 字からの連続抜粋

Autosomal dominant polycystic kidney disease (ADPKD) is a common monoallelic disorder associated with progressive cyst development and resulting in end stage renal failure (ESRD) in 50% of patients by 60y.

日本語訳

常染色体優性多発性嚢胞腎（ADPKD）は、進行する嚢胞形成に関連する一般的な単一アレル性疾患であり、 60 歳までに患者の 50% が末期腎不全（ ESRD ）に至る。

NIH ExPorter は研究助成の要約。医学論文とは文書の目的が異なる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

スポーツ大会の記録｜ Wikipedia (en)

公開 10k サンプル / row 36 / 全文 358 字からの連続抜粋

2017 XIXO Ladies Open Hódmezővásárhely – Doubles

Laura Pigossi and Nadia Podoroska were the defending champions, but both players chose not to participate.

日本語訳

2017 XIXO Ladies Open Hódmezővásárhely — ダブルス

前年優勝者は Laura Pigossi と Nadia Podoroska だったが、ともに出場しなかった。

同じ Wikipedia でも、人名や地名が本文の中心となる。

[1] Neel Nanda (2022). pile-10k: The first 10K elements of The Pile. https://huggingface.co/datasets/NeelNanda/pile-10k

22 構成要素の容量と混合比（1/4）

構成要素	元容量 GiB	反復数	混合比 %
Pile-CC	227.12	1.0	18.11
PubMed Central	90.27	2.0	14.40
Books3	100.96	1.5	12.07
OpenWebText2	62.77	2.0	10.01
ArXiv	56.21	2.0	8.96
Github	95.16	1.0	7.59

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

22 構成要素の容量と混合比（2/4）

構成要素	元容量 GiB	反復数	混合比 %
FreeLaw	51.15	1.5	6.12
StackExchange	32.20	2.0	5.13
USPTO Backgrounds	22.90	2.0	3.65
PubMed Abstracts	19.26	2.0	3.07
Gutenberg (PG-19)	10.88	2.5	2.17
OpenSubtitles	12.98	1.5	1.55

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

22 構成要素の容量と混合比（3/4）

構成要素	元容量 GiB	反復数	混合比 %
Wikipedia (en)	6.38	3.0	1.53
DM Mathematics	7.75	2.0	1.24
Ubuntu IRC	5.52	2.0	0.88
BookCorpus2	6.30	1.5	0.75
EuroParl	4.59	2.0	0.73
HackerNews	3.90	2.0	0.62

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

22 構成要素の容量と混合比（4/4）

構成要素	元容量 GiB	反復数	混合比 %
YoutubeSubtitles	3.73	2.0	0.60
PhilPapers	2.38	2.0	0.38
NIH ExPorter	1.89	2.0	0.30
Enron Emails	0.88	2.0	0.14

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

構成要素が収録する文章（ 1/4 ）

構成要素	収録内容
Pile-CC	Common Crawl の Web 本文
PubMed Central	生物医学論文の全文
Books3	書籍の本文
OpenWebText2	Reddit で共有された外部ページ
ArXiv	LaTeX から抽出した学術論文
Github	公開リポジトリのコード

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

構成要素が収録する文章（2/4）

構成要素	収録内容
FreeLaw	裁判所の判決文
StackExchange	分野別の質問と回答
USPTO Backgrounds	米国特許の背景説明
PubMed Abstracts	生物医学論文の抄録
Gutenberg (PG-19)	Project Gutenberg の古典書籍
OpenSubtitles	映画・テレビ作品の字幕

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

構成要素が収録する文章（3/4）

構成要素	収録内容
Wikipedia (en)	英語の百科事典記事
DM Mathematics	生成器が作る数学の問題と答え
Ubuntu IRC	Ubuntu コミュニティのチャット
BookCorpus2	オンラインの小説
EuroParl	欧州議会の議事録
HackerNews	技術ニュースとコメント

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

構成要素が収録する文章（ 4/4 ）

構成要素	収録内容
YoutubeSubtitles	YouTube 動画の字幕
PhilPapers	哲学分野の学術論文
NIH ExPorter	米国 NIH の研究助成要約
Enron Emails	公開された企業の業務メール

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

公開・規約・同意の分類： 2020 年（ 1/4 ）

構成要素	公開	規約整合	著者同意
Pile-CC	○	○	—
PubMed Central	○	○	○
Books3	○	—	—
OpenWebText2	○	—	—
ArXiv	○	○	○
Github	○	○	—

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. 構築者の整理：○は該当、—は該当すると判断されていない。
https://arxiv.org/abs/2101.00027

公開・規約・同意の分類： 2020 年（ 2/4 ）

構成要素	公開	規約整合	著者同意
FreeLaw	○	○	○
StackExchange	○	○	○
USPTO Backgrounds	○	○	○
PubMed Abstracts	○	○	○
Gutenberg (PG-19)	○	○	—
OpenSubtitles	○	—	—

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. 構築者の整理：○は該当、—は該当すると判断されていない。
https://arxiv.org/abs/2101.00027

公開・規約・同意の分類： 2020 年（ 3/4 ）

構成要素	公開	規約整合	著者同意
Wikipedia (en)	○	○	○
DM Mathematics	○	○	○
Ubuntu IRC	○	○	○
BookCorpus2	○	—	—
EuroParl	○	○	○
HackerNews	○	○	—

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. 構築者の整理：○は該当、—は該当すると判断されていない。
https://arxiv.org/abs/2101.00027

公開・規約・同意の分類： 2020 年（ 4/4 ）

構成要素	公開	規約整合	著者同意
YoutubeSubtitles	○	—	—
PhilPapers	○	○	○
NIH ExPorter	○	○	○
Enron Emails	○	○	—

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. 構築者の整理：○は該当、—は該当すると判断されていない。
https://arxiv.org/abs/2101.00027

HELM は構成要素名で本文を分類する

- ThePileScenario は各行の meta.pile_set_name を読み、本文を構成要素別の CSV へキャッシュする。 references は空のまま、本文を input として test に割り当てる。
- 22 構成要素を実装上は受け付けるが、 Classic v0.4.0 公開 run 仕様は 6 構成要素・ 168 モデル実行分だった。実装の対応範囲と、公開結果の範囲は異なる。
- group0 の索引は重複を除いて昇順にし、構成要素内の文書を選ぶ。 Ubuntu IRC 、 BookCorpus2 、 PhilPapers は文書数が少ないため 10 分割の対象外である。

[1] Stanford CRFM. HELM v0.4.0: ThePileScenario. https://github.com/stanford-crfm/helm/blob/v0.4.0/src/helm/benchmark/scenarios/the_pile_scenario.py

9 実行の採点対象トークン数は異なる

モデル	ArXiv	Github	Wikipedia
text-davinci-003 (2022)	3508	1414	639
BLOOM (2022)	1914	1031	576
OPT-175B (2022)	1939	1267	598

各モデル要求の平均採点トークン数。文書数ではなく、文書を窓に分けた後の要求単位で集計される。

[1] Liang et al. (2023). Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

公開・規約・著者の同意は別の軸である

- 構築時の整理では、インターネットで読めること、取得元の利用規約と整合すること、元の著者が利用に同意したことを別々に分類した。
- たとえば Github は公開かつ規約整合と整理された一方、著者の同意は一律には認められていない。書籍や字幕には、公開されていても規約・同意の欄を満たさないものがある。
- これは 2020 年の構築者による整理であり、個別のライセンス一覧ではない。ミラーの表記だけでなく、各本文の出所と条件を確かめる。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027

EleutherAI による共同制作

- Leo Gao を第一著者、 Connor Leahy を最終著者とする 12 名が、 EleutherAI として制作した。著者には Stella Biderman 、 Sid Black 、 Travis Hoppe らが含まれる。
- 新たな Web ・学術データの収集と、既存の書籍・会話・論文データの統合を分担し、前処理と再構築コードを公開した。
- The Pile はその後、 GPT-NeoX や Pythia などの学習基盤となった。 Pythia では同一データ順と多数のチェックポイントを公開し、モデルの学習過程の比較へ役割を広げた。

[1] Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. https://arxiv.org/abs/2101.00027
[2] Biderman et al. (2023). Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. ICML. https://arxiv.org/abs/2304.01373

参考文献

Gao et al. (2020). The Pile: An 800GB Dataset of Diverse Text for Language Modeling. arXiv.

22 種類のテキストを収集・混合する設計と、分野別の言語モデル評価、内容の統計・社会的影響を記述した。
https://arxiv.org/abs/2101.00027

Biderman et al. (2022). Datasheet for the Pile. arXiv.

構成、収集・処理方法、利用目的、配布、倫理的検討をデータシートの形式で整理した。
https://arxiv.org/abs/2201.07311

参考文献

Liang et al. (2023). Holistic Evaluation of Language Models. TMLR.

言語モデルを多様なシナリオと指標で横断評価する枠組み。 The Pile は言語モデリング課題の一部となる。
https://arxiv.org/abs/2211.09110

Biderman et al. (2023). Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling. ICML.

同じデータ順で異なる規模のモデルを学習し、途中のチェックポイントとともに学習過程の比較基盤を公開した。
https://arxiv.org/abs/2304.01373

参考文献

EleutherAI. The Pile Replication Code.

The Pile の再構築コード、各構成要素の収集実装、反復回数と容量表を公開する公式リポジトリ。
https://github.com/EleutherAI/the-pile

Neel Nanda (2022). pile-10k: The first 10K elements of The Pile.

The Pile の先頭 10,000 文書をデバッグ向けに公開したサンプル。本資料の実例はその先頭 100 行から抽出した。
https://huggingface.co/datasets/NeelNanda/pile-10k