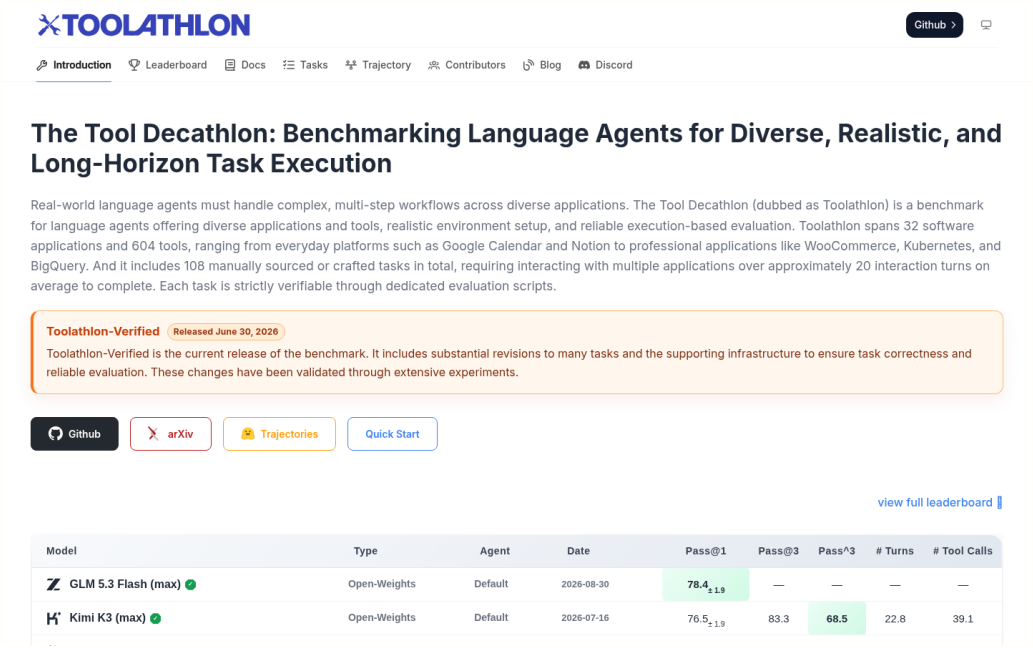
Toolathlon-Verified

The Tool Decathlon

複数のアプリを使い、仕事を最後まで仕上げる

sasakiy84

Toolathlon の公式サイト



[1] Toolathlon，公式サイト（2026-10-21 参照）
https://toolathlon.xyz/

1. 依頼をアプリの操作へつなげる
2. 課題と環境をどう作ったか
3. 成功の判定とモデルの成績
4. 現在の利用と入手方法

1. 依頼をアプリの操作へつなげる

複数のアプリを使い、成果物と状態を更新する

- メールを探し、添付資料を読み、別のアプリを更新する。Toolathlon は、このような一連の仕事をエージェントに任せる評価である。
- 対象は 108 課題。与えられるのは自然言語の依頼と、課題ごとに用意されたアプリやファイルである。
- 採点では、できたと宣言した文章よりも、生成したファイルや更新後のアプリの状態を調べる。

[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

例 1 メールの提出物を Canvas で採点する

依頼の原文（全文）

> Your task is to check your email for homework2 submissions and grade on Canvas. Please download Python files from email attachments to local workspace and execute each Python file in terminal to check for errors. If the Python file is correct, give it a score of 10 in Canvas; otherwise, give it a score of 0. You could check the requirements of homework2 in `assignments/homework2.md`and students' ID in `student_canvas_ids.csv`. For students who submitted multiple times, use the latest submission.

[1] Toolathlon-Verified, canvas-homework-grader-python
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/canvas-homework-grader-python

例 1 最新の提出物だけを採点する

- メールから homework2 の提出を探し、添付の Python ファイルを作業フォルダに保存する。端末で実行し、エラーがないか確かめる。
- 正しく動けば Canvas で 10 点、そうでなければ 0 点を付ける。 homework2.md にある課題条件と、学生 ID の対応表も使う。
- 同じ学生が複数回提出していたら、最新の提出を使う。課題 1 の提出物も混ざっているため、課題番号と提出順を確かめる。

[1] Toolathlon-Verified, canvas-homework-grader-python
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/canvas-homework-grader-python

例 1 正しく実行できても、課題条件を確かめる

確認する資料	その資料で分かること
homework2.md	和が目標値になる 2 数の添字を返す。関数名は twoSum で、添字は昇順
メールと添付	課題 2 かどうかと提出者、再提出の有無
Canvas の学生 ID	採点した結果を書き込む学生

初期資料にある課題条件を読み、提出者と採点先を対応させる。

[1] Toolathlon-Verified, canvas-homework-grader-python
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/canvas-homework-grader-python

例 1 参照される 6 人分の採点結果

学生	点数	参照データの理由
Timothy Ruiz	10	正しい提出
Martha Watson	0	構文エラー
Donald Richardson	0	実行時エラー
Shirley Rodriguez	10	正しい提出
Alice Ward	0	添字の順序が逆
Frank Phillips	0	存在しないモジュール

[1] Toolathlon-Verified, canvas-homework-grader-python
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/canvas-homework-grader-python

例２ メモリにある取引を帳簿へ追記する

依頼の原文（全文）

> Today is January 18, 2024. Please only add the transaction records I have told you in your memory from exactly last week and the week before last to my account book, and do not include any transactions from this week.

日本語訳：今日は 2024 年 1 月 18 日です。メモリで伝えた取引のうち、先週と先々週のものだけを帳簿に追加してください。今週の取引は含めないでください。

[1] Toolathlon-Verified, sales-accounting
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/sales-accounting

例 2 メモリには今週の取引も含まれる

2024 年	種類	商品	金額（元）
1/7	仕入	iPhone 15 Pro	40,000
1/8	仕入	MacBook Air	21,600
1/8	販売	iPhone 15 Pro	19,998
1/9	販売	MacBook Air	8,999
1/10	販売	AirPods Pro	5,697
1/16	販売	iPhone 15 Pro	9,999

課題内の日付は 1 月 18 日。先週と先々週は 1 月 1 日〜 14 日に当たる。

[1] Toolathlon-Verified, sales-accounting
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/sales-accounting

例 2 既存の 120 件を残し、 5 件だけを追加する

- 参照帳簿には 1 月 7 日〜 10 日の 5 件を追加する。 1 月 16 日の取引は今週のため追加しない。
- 評価コードは既存の行を保持していることと、追加した 5 件の日時・商品・数量・単価・金額・相手先を照合する。
- 依頼の期間を解釈し、必要な記録だけを選び、既存ファイルを壊さず更新できたかを見る。

[1] Toolathlon-Verified, sales-accounting
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/sales-accounting

例 3 倉庫の在庫をオンライン店舗へ反映する

依頼の原文（全文）

I am a WooCommerce store owner, and my shop has warehouses in the following cities: New York, Boston, Dallas, LA, San Francisco, Houston. Please help me: Check each warehouse SQLite database (located in the warehouse directory in the workspace) for the latest product inventory list (identified by Product ID) that has been uploaded but not yet updated in the online WooCommerce store. Use the WooCommerce MCP server to synchronize the inventory updates to the WooCommerce online store according to the city-to-region mapping.

[1] Toolathlon-Verified, inventory-sync
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/inventory-sync

例 3 商品 ID と地域を対応させて在庫を同期する

- 私は WooCommerce の店舗オーナーです。倉庫は New York 、 Boston 、 Dallas 、 LA 、 San Francisco 、 Houston にあります。
- 作業フォルダの warehouse ディレクトリにある各倉庫の SQLite データベースから、アップロード済みでオンライン店舗には未反映の最新在庫を、商品 ID で特定してください。
- 都市と地域の対応に従い、 WooCommerce のツールでオンライン店舗の在庫を同期してください。

[1] Toolathlon-Verified, inventory-sync
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/inventory-sync

例 3 同じ地域の倉庫をまとめて反映する

地域	都市	PROD001 の在庫
East	New York ・ Boston	277 + 370 = 647
South	Dallas ・ Houston	274 + 577 = 851
West	LA ・ San Francisco	689 + 297 = 986

初期 SQLite の実値を、評価コードと同じ地域単位で集計した例。

[1] Toolathlon-Verified, inventory-sync
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/inventory-sync

2. 課題と環境をどう作ったか

短い依頼の裏に、資料と既存データがある

- 同じ「メールを処理する」でも、空の受信箱と、大量の無関係なメールが混ざる受信箱では探索の負担が異なる。
- 構築時には、学生の提出物、既存の帳簿、倉庫の在庫などを用意し、仕事を途中の状態から始められるようにした。
- 必要な情報を環境から読み取り、操作の順序を自分で組み立てることを重視している。

[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

研究者が仕事を選び、初期状態と判定を作った

- コンピュータ科学の研究者や学生が、実際の利用目的から課題を収集・設計した。多様なアプリを調べ、少ない分野を追加する 2 段階の選定を行った。
- 必要な課題には初期データを用意し、課題ごとに評価コードを実装した。実装には 1 課題あたり平均 4 〜 6 時間かかり、その後も複数回の確認と修正を重ねた。
- 2026 年 6 月 30 日の Verified 公開では、依頼文・参照データ・評価コードの対応を人手で再確認して最終化した。

[1] Toolathlon-Verified，公式リポジトリ（ 2026-10-21 参照）
https://github.com/hkust-nlp/Toolathlon

業務に使われる実アプリを組み合わせる

用途	アプリの例
文書・予定	Notion 、 Google Sheets 、 Google Calendar
授業・メール	Canvas 、 Poste.io
店舗・基盤管理	WooCommerce 、 Kubernetes
データ・研究	BigQuery 、 Snowflake 、 Weights & Biases

遠隔サービスと、ローカルのコンテナに設置したアプリを併用する。

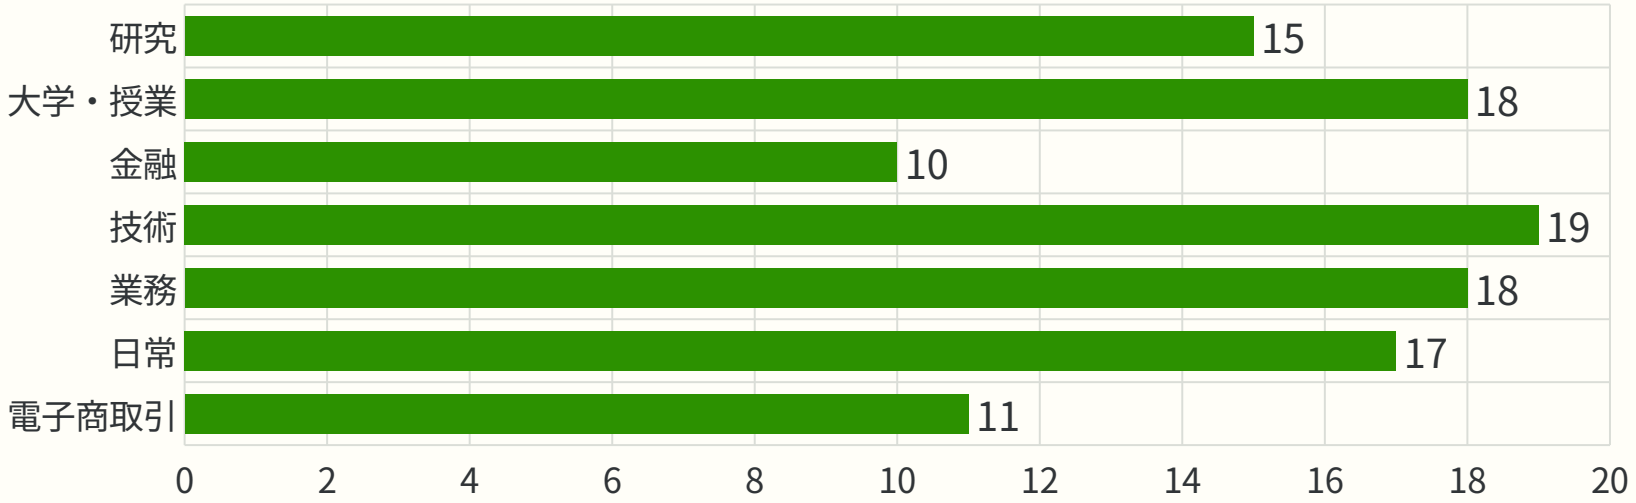
[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

32 のアプリから、課題に必要なツールを使う

- 研究で用意したのは 32 アプリ・ 604 ツール。ほかに Python 実行や検索など、 16 のローカルツールがある。
- 課題ごとに関連するアプリを選び、そのアプリが提供するツールを渡す。毎回すべてのアプリを使わせる設計ではない。
- 実アプリのデータを読んだり書き換えたりする。単にツール名と引数を出力して終わる評価ではない。

[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

108 課題は研究・授業・業務など 7 分野に広がる



研究で公表された分野別内訳。

[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

Verified は課題と採点を確認した最終版

時点	公開された内容
2025 年 10 月	Toolathlon 研究を発表。 108 課題と実アプリ環境を公開
2026 年 2 月	論文の改訂版。構築・評価・分析を説明
2026 年 6 月	Toolathlon-Verified 。依頼・参照・評価コードを最終化

ここで紹介する実例は Verified の公開リポジトリから選んだ。

[1] Toolathlon-Verified，公式リポジトリ（ 2026-10-21 参照）
https://github.com/hkust-nlp/Toolathlon

3. 成功の判定とモデルの成績

課題ごとの判定条件を満たすと成功になる

- ファイルがあるか、表の値が合うか、正しい学生に点を付けたかなどを、課題ごとの評価コードで確認する。
- 参照状態を固定した課題と、その時点の情報から正解を作る課題がある。店舗・予定・データベースなどの変更先も判定に含まれる。
- 最終結果は課題の成否として集計する。判定する項目や許容する差は、それぞれの仕事に合わせて定められている。

[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

3 回の試行から、成功率と安定性を見る

指標	何を数えるか
Pass@1	1 回の実行で成功する割合。 3 試行の平均を報告
Pass@3	3 回のうち少なくとも 1 回成功した課題の割合
$Pass^3$	3 回すべて成功した課題の割合

[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

同じ 3 試行でも、指標は異なる側面を示す

説明用の課題	試行 1	試行 2	試行 3
A	成功	失敗	成功
B	成功	成功	成功

この 2 課題では Pass@1 は 5/6 、 Pass@3 は 2/2 、 $Pass^3$ は 1/2 となる。

[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

登場時は最も高いモデルでも成功率が 4 割未満だった

モデル	Pass@1 (%)	平均ターン数
Claude 4.5 Sonnet	38.6	20.2
GPT-5	30.6	18.7
Grok-4	27.5	20.3
DeepSeek V3.2 Exp	20.1	26.0

2025 年に公開された研究の 108 課題・各 3 回の評価結果。

[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

Verified の公式評価は成功率 7 割台に達した

モデル・設定	Pass@1 (%)	公表日
GLM 5.3 Flash (max)	78.4	2026-08-30
Claude Opus 4.8 (max)	76.2	2026-06-30
GPT-5.5 (xhigh)	73.5	2026-06-30
Gemini 3.5 Flash (high)	67.3	2026-06-30

2026-10-21 確認。公式の Default エージェントで報告された代表的な結果。

[1] Toolathlon，公式サイト（ 2026-10-21 参照）
https://toolathlon.xyz/

Fable 5.1 でも同じ課題を継続して評価している

モデル	Pass@1	Pass@3	$Pass^3$
Claude Fable 5.1	77.8	81.5	73.1
Claude Opus 5	80.6	87.0	73.1
Claude Sonnet 5	74.7	84.3	65.7

単位は % 。 Anthropic の社内実行基盤で 108 課題を各 3 回、 adaptive thinking ・ max effort で評価。

[1] Anthropic, Claude Fable 5.1 & Mythos 5.1 System Card (2026)
https://www.anthropic.com/claude-fable-and-mythos-5-1

Fable の結果は公開リーダーボードと実行条件が異なる

- Fable 5.1 は安全分類器と拒否時の代替モデルを有効にして評価された。 324 試行のうち 11 試行で Opus 4.8 が一部または全部を引き継ぎ、別の 4 試行は終了して失敗扱いとなった。
- 社内実行基盤では外部の金融データやコンテナを固定した。公開ボードには、実行履歴が作られなかった試行も失敗として含まれる。
- Anthropic は、実行履歴のない試行の扱いが、公開ボードと社内評価の約 3 ポイントの差に関係したと報告している。

[1] Anthropic, Claude Fable 5.1 & Mythos 5.1 System Card (2026)
https://www.anthropic.com/claude-fable-and-mythos-5-1

4. 現在の利用と入手方法

長い仕事では、観察と修正を続けられるかが問われる

- ツールの説明から正しい操作を選ぶだけでなく、返されたデータを読み、次の操作へ必要な情報を引き継ぐ。
- 研究時には、存在しないツール名の指定や、長すぎる出力を処理しきれない失敗が見られた。ツール実行中のエラーを手掛かりに立て直す場合もあった。
- 途中でできたことと、依頼された仕事を最後まで完了したことを、実アプリの状態から判定できる。

[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

公開課題から、入力・環境・採点をたどれる

- 公開リポジトリには課題ごとの依頼文、初期ファイル、参照成果物、評価コードがある。課題名を選んで、何を読み、何を変える仕事かを確認できる。
- 自分で評価する場合は、必要なアプリとアカウントを準備する方法と、提供される評価サービスを利用する方法がある。
- Verified の実行履歴は申請付きで公開され、評価・再現・監査向けの利用条件が設けられている。

[1] Toolathlon-Verified，公式リポジトリ（ 2026-10-21 参照）
https://github.com/hkust-nlp/Toolathlon

課題のファイル構成から入出力を確認する

```
tasks/finalpool/sales-accounting/
  docs/task.md
  task_config.json
  initial_workspace/
  groundtruth_workspace/
  evaluation/
```

依頼文、初期状態、期待する帳簿、評価コードを順に確認できる。

[1] Toolathlon-Verified，公式リポジトリ（2026-10-21 参照）
https://github.com/hkust-nlp/Toolathlon

Toolathlon-Verified はアプリをまたぐ仕事の完了を測る

- 108 の現実的な仕事を、事前データのあるアプリやファイルから始める。必要な情報を探し、複数のツールを組み合わせ、成果物と変更後の状態まで仕上げる。
- 依頼・初期状態・判定条件が結び付いているため、短い回答の正しさでは捉えにくい実務上の失敗を調べられる。
- 公開された依頼・初期ファイル・参照成果物・評価コードをたどることで、取引の選別、在庫の同期、提出物の採点など、どの操作を仕上げる課題かを調べられる。

[1] Toolathlon-Verified，公式リポジトリ（2026-10-21 参照）
https://github.com/hkust-nlp/Toolathlon

Appendix

1. 多様な仕事の追加例
2. 評価条件と公開範囲
3. 研究と参考文献

1. 多様な仕事の追加例

例 4 論文を探し、指定名で保存する

依頼の原文（全文）

I'm looking for a paper on arxiv related to agentic reasoning. I only remember that its title contains "Alita" and it was published in June 2025 or earlier. Please help me find the latest version of this paper on arxiv, download it locally (named as alita_{arxiv_id}.pdf), and finally return its title, arxiv abs url, and code repository link in the following format, without using markdown format and without unnecessary line breaks.
title: {title}
arxiv_abs_url: {arxiv_abs_url}
code_url: {code_url}

[1] Toolathlon-Verified, find-alita-paper
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/find-alita-paper

例 4 依頼の日本語訳

- agentic reasoning に関する arXiv 論文を探してください。タイトルに「 Alita 」を含み、 2025 年 6 月以前に公開されたことだけ覚えています。最新版を見つけ、 alita_{arxiv_id}.pdf という名前でローカルに保存してください。最後に、論文名・ arXiv の概要ページ URL ・コードのリポジトリ URL を、指定された 3 行の形式で返してください。 Markdown や不要な改行は使わないでください。

[1] Toolathlon-Verified, find-alita-paper
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/find-alita-paper

例 4 求められる成果物と判定

- 検索結果の要約だけで終わらず、論文 PDF の保存と、タイトル・概要 URL ・コード URL の 3 項目を求める。
- 評価コードは arXiv から参照 PDF を取得し、保存した PDF と一致するかを調べる。依頼では、タイトル・概要 URL ・コード URL の 3 項目も指定形式で返す。

[1] Toolathlon-Verified, find-alita-paper
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/find-alita-paper

例 5 メールの締切から予定を登録する

依頼の原文（全文）

> Check my emails from the past day. If any mention the COML conference main-track camera-ready deadline, schedule a calendar reminder for me three hours before that deadline.

[1] Toolathlon-Verified, set-conf-cr-ddl
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/set-conf-cr-ddl

例 5 依頼の日本語訳

- 過去 1 日のメールを確認してください。 COML 会議のメイントラックの最終原稿の締切に触れたメールがあれば、その締切の 3 時間前にカレンダーのリマインダーを登録してください。

[1] Toolathlon-Verified, set-conf-cr-ddl
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/set-conf-cr-ddl

例 5 求められる成果物と判定

- メール内の締切とタイムゾーンを読み取り、 Google Calendar へ予定を作る。
- 評価は、会議名と camera-ready に対応する予定があり、開始時刻が課題で定めた締切の 3 時間前に合うかを確認する。

[1] Toolathlon-Verified, set-conf-cr-ddl
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/set-conf-cr-ddl

例 6 実験ログから最良の結果を取り出す

依頼の原文（全文）

> Analyze the wandb project https://wandb.ai/mluo/deepscaler-1.5b?nw=nwusermluo, identify the experiment with the best validation set performance, and find which step performed best in that experiment. Save the best_experiment_name, best_step, and best_val_score to a CSV file named `best_experiment.csv` in the workspace.

[1] Toolathlon-Verified, wandb-best-score
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/wandb-best-score

例 6 依頼の日本語訳

- 指定された Weights & Biases のプロジェクトを分析してください。検証データで最も良い成績を収めた実験と、その実験で最良だったステップを探してください。実験名、ステップ、検証スコアを best_experiment.csv に保存してください。

[1] Toolathlon-Verified, wandb-best-score
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/wandb-best-score

例 6 求められる成果物と判定

- 評価コードが期待する実験名は **deepscaler-1.5b-24k** 、ステップは **230** 、検証スコアは **0.43542** 。
- CSV には best_experiment_name 、 best_step 、 best_val_score の 3 列と、結果 1 行が必要になる。

[1] Toolathlon-Verified, wandb-best-score
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/wandb-best-score

例 7 論文の非公式実装を探す

依頼の原文（全文）

> I'm trying to reproduce the experiments from a deep learning paper (paper.pdf). Unfortunately, the paper does not provide an official implementation code repository. To work more efficiently, please help me find the unofficial implementation repository with the most stars on GitHub and update the existing `result.json` with the information.

[1] Toolathlon-Verified, git-repo
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/git-repo

例 7 依頼の日本語訳

- 深層学習の論文 paper.pdf の実験を再現しようとしていますが、公式コードがありません。 GitHub でスター数が最も多い非公式実装を探し、その情報で既存の result.json を更新してください。

[1] Toolathlon-Verified, git-repo
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/git-repo

例 7 求められる成果物と判定

- 論文を読んで対象を特定し、 GitHub の実装を調べて、既存 JSON へ URL を書く。
- この課題の参照 JSON には **astramind-ai/Mixture-of-depths** の URL が保存されている。採点は保存された URL との一致を確認する。

[1] Toolathlon-Verified, git-repo
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/git-repo

例 8 クラスタの監査を表に追記する

依頼の原文（全文）

> Perform a security audit on the Kubernetes cluster and append the results to the `Kubernetes Security Audit` Google Sheet under the Week3 worksheet. The data must follow the same column order and formatting style used in Week1 and Week2. You can find detailed requirements in `guidelines.md` in the workspace.

[1] Toolathlon-Verified, k8s-safety-audit
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/k8s-safety-audit

例 8 依頼の日本語訳

- Kubernetes クラスタのセキュリティ監査を行い、Kubernetes Security Audit という Google Sheet の Week3 ワークシートへ結果を追記してください。列の順序と書式は Week1 ・ Week2 に合わせてください。詳細条件は作業フォルダの guidelines.md にあります。

[1] Toolathlon-Verified, k8s-safety-audit
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/k8s-safety-audit

例 8 求められる成果物と判定

- guidelines.md では、コンテナごとにリスクを採点する。特権モードなら 10 点、そうでなければ権限やホスト設定などを合計し、上限を 10 点とする。
- クラスタの観察結果だけでなく、既存シートの形式に沿って Week3 へ書き込んだ内容を確認する。

[1] Toolathlon-Verified, k8s-safety-audit
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/k8s-safety-audit

例 9 文書の内容で Notion を更新する

依頼の原文（全文）

You need to update a notion page named `Colley Whisson` based on the information provided in the `colley_whisson.docx` document. Please update the following sections based on the information in the docx document. Pay attention that you must include all details:
- About Me section
- Paintings section
- Workshop section
- Prizes section
- Exhibitions section

[1] Toolathlon-Verified, notion-personal-website
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/notion-personal-website

例 9 依頼の日本語訳

- colley_whisson.docx にある情報を使い、 Colley Whisson という Notion ページを更新してください。 About Me 、 Paintings 、 Workshop 、 Prizes 、 Exhibitions の各セクションへ、文書の詳細を漏らさず反映してください。

[1] Toolathlon-Verified, notion-personal-website
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/notion-personal-website

例 9 求められる成果物と判定

- 文書からプロフィール・作品・講習会・受賞・展示情報を読み、ページの対応するセクションへ移す。
- 評価コードはセクションを抽出し、必要な事実や作品名などが含まれるかを確認する。単に文書を添付する課題ではない。

[1] Toolathlon-Verified, notion-personal-website
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/notion-personal-website

例 10 指定された個人情報だけを伏せる 1/2

依頼の原文（全文を分割）

I need to perform privacy data desensitization on my documents. The files may contain sensitive information that needs protection. Please help me scan all documents in my workspace and identify and desensitize privacy information. Create desensitized copies and save them in `desensitized_documents/`. Each file's desensitized copy should be named as `original_filename_desensitized.extension`. All sensitive information should be uniformly replaced with `/hidden/` at its original location, without altering any surrounding content or other contents.

[1] Toolathlon-Verified, privacy-desensitization
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/privacy-desensitization

例 10 指定された個人情報だけを伏せる 2/2

依頼の原文（全文を分割）

Specifically, you only need to process the following sensitive information types, even if they are pseudo, mimic or duplicated:
- Phone/Fax numbers
- Social Security Numbers
- Email addresses
- Credit card numbers
- IP addresses, including directly attached ports

Do not modify any information that is not included in the list above.
Do not add any unrequested file to `desensitized_documents/`.

[1] Toolathlon-Verified, privacy-desensitization
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/privacy-desensitization

例 10 依頼の日本語訳

- 作業フォルダのすべての文書を調べ、電話・ FAX 番号、社会保障番号、メールアドレス、クレジットカード番号、 IP アドレス（直後にポート番号が付く場合は、その番号も含む）を /hidden/ へ置換してください。架空・模擬・重複した情報も対象です。コピーを desensitized_documents/ へ保存し、ファイル名は original_filename_desensitized.extension としてください。周囲の内容や指定以外の情報は変えず、余計なファイルも追加しないでください。

[1] Toolathlon-Verified, privacy-desensitization
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/privacy-desensitization

例 10 求められる成果物と判定

- 入力・参照の各アーカイブには **27 ファイル**がある。文章・CSV ・ JSON などの形を保ちながら、指定された 5 種類の値を置換する。
- 参照文書では氏名や日付を保持している。指定された情報だけを置き換え、元の文章を壊さないことが重要になる。

[1] Toolathlon-Verified, privacy-desensitization
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/privacy-desensitization

例 10 文書の値だけを置換する

入力の抜粋	参照文書の抜粋
Customer A: John Smith	Customer A: John Smith
Phone: (555) 123-4567	**Phone: /hidden/**
Email: john.smith@example.com	**Email: /hidden/**

公開課題の模擬文書 contact_info.txt の同じ箇所を対応させた。

[1] Toolathlon-Verified, privacy-desensitization
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/privacy-desensitization

例 11 横持ちの表を縦持ちへ変換する

依頼の原文（全文）

Please convert the file `Household_Appliances.xlsx` from its current two-dimensional layout—where sales data for household refrigerators, air conditioners, and washing machines are recorded in separate columns—into a one-dimensional format. The new layout must strictly follow the structure an d examples shown in `Format_Example.xlsx`, leaving any unknown fields blank.
Save the transformed data as `Processed.xlsx` in the workspace. List the records in reverse chronological order, starting from December 2024 and moving backward, and include only months with at least some data.

[1] Toolathlon-Verified, excel-data-transformation
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/excel-data-transformation

例 11 依頼の日本語訳

- Household_Appliances.xlsx では、冷蔵庫・エアコン・洗濯機の販売データが別々の列にあります。Format_Example.xlsx の構造と例に厳密に合わせて縦持ちへ変換し、不明な欄は空欄にしてください。 Processed.xlsx として保存し、 2024 年 12 月からさかのぼる順に並べ、何らかのデータがある月だけを含めてください。

[1] Toolathlon-Verified, excel-data-transformation
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/excel-data-transformation

例 11 求められる成果物と判定

- 参照ファイルは **198 行**のデータで、月と家電の種類を 1 行にまとめる。販売数・累計・前年比などの値も対応させる。
- 最初の 3 行は 2024 年 12 月の冷蔵庫、エアコン、洗濯機。たとえば冷蔵庫の当月販売数は **899.1 万台**である。

[1] Toolathlon-Verified, excel-data-transformation
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/excel-data-transformation

例 11 参照ファイルの先頭 3 行

月	家電	当月販売数（万台）
2024-12	冷蔵庫	899.1
2024-12	エアコン	2,369.5
2024-12	洗濯機	1,226.5

Processed.xlsx の参照値。元データでは家電ごとに別の列群がある。

[1] Toolathlon-Verified, excel-data-transformation
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/excel-data-transformation

例 12 A/B テストの結果で次の操作を変える 1/2

依頼の原文（全文を分割）

The A/B test for our new homepage has concluded, and the raw clickstream data has been stored in the `ab_testing` dataset in BigQuery. Analyze the data and fill the `record.csv`, determine which version ('A' or 'B') has the highest overall conversion rate, i.e., the overall conversion rate is defined as the arithmetic mean of the per-scenario conversion rates.

[1] Toolathlon-Verified, ab-testing
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/ab-testing

例 12 A/B テストの結果で次の操作を変える 2/2

依頼の原文（全文を分割）

If version B outperforms, immediately create a new Cloud Storage bucket whose name is prefixed with `promo-assets-for-b` for the full promotion, and you do not need to write any log entry in this process. If version A wins or the results are a tie, no bucket creation is required, but a log entry with the message `{'status': 'AB_Test_Concluded', 'winner': 'A', 'action': 'No_Change'}` must be written to the existing log bucket whose name is prefixed with `abtesting_logging`. During the entire process, there is no need to consider any log entries in the log bucket that existed before the task was executed.

[1] Toolathlon-Verified, ab-testing
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/ab-testing

例 12 依頼の日本語訳

- BigQuery の ab_testing にあるホームページのクリックデータを分析し、 record.csv を埋めてください。各分野のコンバージョン率を計算し、その算術平均で A と B を比べます。 B が上回れば、すぐに promo-assets-for-b で始まる Cloud Storage バケットを作り、ログは書きません。 A が勝つか同率ならバケットを作らず、 abtesting_logging で始まる既存ログバケットへ {'status': 'AB_Test_Concluded', 'winner': 'A', 'action': 'No_Change'} と記録してください。既存の古いログは考慮不要です。

[1] Toolathlon-Verified, ab-testing
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/ab-testing

例 12 求められる成果物と判定

- 参照の全体コンバージョン率は A が **73.840%** 、 B が **74.121%** 。この初期データでは **B が勝ち、配信用バケットを作る**分岐になる。
- 正しい集計値だけでなく、勝者に応じてクラウドの状態を変えたか、不要な新規ログを書いていないかも確認する。

[1] Toolathlon-Verified, ab-testing
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/ab-testing

例 12 全 20 分野の平均から B を選ぶ

参照 record.csv	A (%)	B (%)
Appliances	72.234	73.276
Automotive	75.939	72.842
全体（ 20 分野の平均）	73.840	74.121

各分野の店舗ページ閲覧数 ÷ クリック数を求め、 20 分野を同じ重みで平均する。

[1] Toolathlon-Verified, ab-testing
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/ab-testing

例 13 領収書を台帳に入れ、未払いを知らせる

依頼の原文（全文）

Help me automatically update the two existing tables in the PURCHASE_INVOICE database with all the received receipts in my workspace. For receipts that are not fully paid, send an email to the relevant purchasing manager with the subject "Process Outstanding Invoices". The email body should include all the filenames that the manager still needs to process. Also, set a column description for outstanding_flag precisely as: "0=Paid, 1=Outstanding".

[1] Toolathlon-Verified, payable-invoice-checker
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/payable-invoice-checker

例 13 依頼の日本語訳

- 作業フォルダにある受領済みの全領収書を使い、PURCHASE_INVOICE データベースの既存の 2 表を更新してください。支払いが完了していない書類については、担当の購買管理者へ Process Outstanding Invoices という件名のメールを送り、本文に処理が必要な全ファイル名を含めてください。 outstanding_flag の列の説明は、正確に「 0=Paid, 1=Outstanding 」としてください。

[1] Toolathlon-Verified, payable-invoice-checker
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/payable-invoice-checker

例 13 求められる成果物と判定

- 領収書を読み、支払い状況と担当者を突き合わせ、データベースとメールの両方を更新する。
- 評価コードは Snowflake の表と列の説明、管理者宛てメールの件名とファイル名を確認する。

[1] Toolathlon-Verified, payable-invoice-checker
https://github.com/hkust-nlp/Toolathlon/tree/main/tasks/finalpool/payable-invoice-checker

2. 評価条件と公開範囲

公開されている課題と、実行履歴の利用条件

- GitHub の公開課題から、依頼文・初期ファイル・参照成果物・評価コードを調べられる。
- Hugging Face の Verified 実行履歴は、評価・再現・監査・誤り分析などを目的とする申請付きの配布で、学習利用や生の履歴の再配布を認めない条件が示されている。
- 自分のアプリやアカウントを使って評価する場合は、必要な準備と、課題終了時にどの状態を検査するかを確かめる。

[1] Toolathlon-Verified Trajectories, 公開データカード（ 2026-10-21 参照）
https://huggingface.co/datasets/hkust-nlp/Toolathlon-Verified_Trajectories

固定された参照値と、実行時に取得する値がある

- 実験結果を CSV へまとめる wandb-best-score では、実験名、ステップ 230 、検証スコア 0.43542 が評価コードに参照値として保存されている。
- 一方、研究で紹介された NVIDIA の株主情報などの課題では、その時点で取得した情報を使って判定する。
- 前者は保存済みの値と照合し、後者は実行時の外部情報を反映する。評価コードを読むと、どの値を基準にして成否を判定するかが分かる。

[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

3. 研究と参考文献

HKUST を中心とする研究チームが構築した

- 第一著者群は Junlong Li 、 Wenshuo Zhao 、 Jian Zhao 、 Weihao Zeng 、 Haoze Wu 。最終著者は HKUST の Junxian He である。
- HKUST 、 All Hands AI 、 Carnegie Mellon University 、 Duke University の研究者が参加し、言語エージェントが実アプリで行う仕事を評価対象にした。
- 2025 年に公開され、 ICLR 2026 の研究として紹介されている。 Verified は 2026 年 6 月に最終版として公開された。

[1] Li et al., The Tool Decathlon (2025/2026)
https://arxiv.org/abs/2510.25726

参考文献

The Tool Decathlon: Benchmarking Language Agents for Diverse, Realistic, and Long-Horizon Task Execution

Li et al. (2025/2026). ICLR 2026.

課題の作成、実アプリ環境、実行による採点と初期のモデル比較を説明する。

https://arxiv.org/abs/2510.25726

Toolathlon-Verified: Official Repository

hkust-nlp (2026). GitHub.

依頼・初期ファイル・参照成果物・評価コードと、現在の準備手順を公開する。

https://github.com/hkust-nlp/Toolathlon

参考文献

Claude Fable 5.1 & Claude Mythos 5.1 System Card

Anthropic (2026).

Verified の継続利用と、社内実行基盤・拒否時の代替モデルを含む評価条件を示す。

https://www.anthropic.com/claude-fable-and-mythos-5-1

Toolathlon: Project Website and Leaderboard

Toolathlon authors (2026). 参照日 2026-10-21.

公式 Default エージェントの結果と、課題・ソフトウェア環境の概要を掲載する。

https://toolathlon.xyz/