TwitterAAE

African-American English on Twitter

会話の言語的多様性を捉えるコーパス

sasakiy84

公式サイト：研究と配布への入口



TwitterAAE: Research on African-American English on Twitter

Papers

Demographic Dialectal Variation in Social Media: A Case Study of African-American English. Su Lin Blodgett, Lisa Green, and Brendan O'Connor. Proceedings of EMNLP 2016. [pdf]

Twitter Universal Dependency Parsing for African-American and Mainstream American English. Su Lin Blodgett, Johnny Tian-Zheng Wei, and Brendan O'Connor. Proceedings of ACL 2018. [pdf]

Overview

Though dialectal language is increasingly abundant on social media, few resources exist for developing NLP tools to handle such language. We conduct a case study of dialectal language in online conversational text by investigating African-American English (AAE) on Twitter. We propose a distantly supervised model to identify AAE-like language from demographics associated with geo-located messages, and we verify that this language follows well-known AAE linguistic phenomena. In addition, we analyze the quality of existing language identification and dependency parsing tools on AAE-like text, demonstrating that they perform poorly on such text compared to text associated with white speakers.

Further work on language identification is on our TwitterLangID page.

[1] UMass SLANG Lab (n.d.), TwitterAAE: Research on African-American English on Twitter. https://slanglab.cs.umass.edu/TwitterAAE/

1. 投稿の実例と言語的特徴
2. 人口統計と言語を結ぶ構築方法
3. 公開データと解析への利用

投稿の実例と言語的特徴

AAE を含む会話を NLP の対象にする

TwitterAAE は、 Twitter 上のアフリカ系米国人英語（ AAE ）に関連する表現を調べる言語資源。投稿位置に対応する地域の人口構成と言葉の使い方を結び付けて構築した。

AAE には語彙・発音・文法の体系がある。主流の書き言葉を中心に作られた NLP ツールが、こうした会話をどの程度扱えるかを調べた。

[1] Blodgett, Green & O’Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

AA ・ white は、言語的特徴に基づく名前

本編 3 例と追加 10 例では、異なる 13 件の投稿全文を示す。大文字や独自のつづり、句読点にも会話の特徴が現れる。

aa ／ white は、地域の人口構成に関連する言語の混合比に基づく名前。投稿者の自己申告による人種を表すラベルではない。

[1] Blodgett et al. (n.d.), twitteraae. 人口統計と言語を結ぶ混合モデルの README 。 https://github.com/slanglab/twitteraae

実例 1 ：電話代を払ってでも話したい

投稿全文 / aa 群（言語的特徴で抽出）

> IMA PAY OOMFS FONE BILL ,JUS KUZ I WANNA TALK TO HER

日本語訳

あのフォロワーの子と話したいからってだけで、携帯代を払ってやるつもり。

OOMF は one of my followers （フォロワーの一人）の略。 FONE や JUS など、発音に近づけたつづりも使う。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例２：短い願いと呼びかけ

投稿全文 / aa 群（言語的特徴で抽出）

> I just wanna be happy bruh

日本語訳

ただ幸せになりたいんだよ、なあ。

bruh はくだけた呼びかけ。 wanna は want to の縮約で、短い投稿でも会話の調子が伝わる。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例３： white 側にも語りかけの表現がある

投稿全文 / white 群（言語的特徴で抽出）

> Sweet sleep, how I missed you my love.

日本語訳

ああ愛しい眠り、どれほど恋しかったことか。

sleep を恋人のように呼ぶ、擬人化した語りかけ。 white 抽出集合にもこのような会話が含まれる。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

人口統計と言語を結ぶ構築方法

2013 年の位置付き投稿から会話を集める

2013 年の公開 Twitter ストリーム 160 億件から、米国の国勢調査 block group に位置を対応できる約 9,000 万件を得た。

フォロワーの多いアカウントや、ハッシュタグの多い投稿、リンク・宣伝語を含む投稿、リツイートなどを除いた。

前処理後は約 5,920 万投稿・ 280 万ユーザー。位置情報を公開する利用者の会話が対象となる。

[1] Blodgett, Green & O'Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

地域の人口構成を、言語の手掛かりにする

投稿位置を、通常 600 〜 3,000 人が暮らす block group へ結び付け、 2013 年 American Community Survey の人口構成を参照する。

非ヒスパニック白人・非ヒスパニック黒人・ヒスパニック・アジア系の 4 比率を、各ユーザーの投稿位置で平均した。

近隣地域の人口構成を、投稿の言語的特徴を推定する手掛かりにする。

[1] Blodgett, Green & O'Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

一人の中にも、一つの投稿にも混合を認める

4 集団に対応する単語分布を学習し、各投稿でそれらが占める混合比を推定する。ユーザーに対応付けた地域の人口比率を、その推定の事前分布に使う。

同じ人でも、投稿によって使う表現は変わる。ユーザー単位と投稿単位の混合比で、その変化を表現する。

[1] Blodgett, Green & O'Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

AAE に特徴的な文法が多く現れる

構文	公開された用例	AA ／ white 比
習慣を表す be	I be tripping bruh	11.94
未来を表す gon	Then she gon be single Af	14.26
完了を表す done	I done laughed so hard that I’m weak	8.68

ユーザー単位で作った 2016 年の両コーパスを比較。表記だけでなく、既知の文法現象とも照合した。

[1] Blodgett, Green & O’Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

言語同定では、英語を取りこぼしていた

2016 年の解析では、 langid.py が AA 側の 13.2% 、 white 側の 7.6% を非英語と判定した。 Twitter の識別結果でも、欠損値を非英語に数えるかどうかの両条件で AA 側の割合が高かった。

AA 混合比を 10 段階に分け、各識別条件で非英語とされた投稿から計 1,500 件を人手で調べた。明らかな非英語は 13 件（約 0.87% ）だった。

英語だけを残す前処理そのものが、方言を含む意見や会話を取りこぼす問題につながる。

[1] Blodgett, Green & O’Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

公開データと解析への利用

構文解析のための注釈も公開されている

2016 年は人口統計と言語の混合モデルを作り、言語同定・構文解析の差を調べた。

2018 年には AAE と主流米国英語の各 250 投稿に Universal Dependencies 注釈を付け、構文解析の資源を拡張した。

[1] Blodgett, Wei & O'Connor (2018). Twitter Universal Dependency Parsing for African-American and Mainstream American English. ACL, 1415–1425. https://aclanthology.org/P18-1131/

公式サイトで、コーパスと解析用資源を入手する

公式サイトの全体配布 TwitterAAE-full-v1.zip は表示容量 5.5 GB 。研究目的のみでの提供と 2016 年論文の引用が案内されている。

言語混合比の推定モデルと、 2018 年の構文解析用注釈も、公式ページから入手できる。

推定モデルのコードは MIT ライセンス。投稿本文の利用は、公式サイトの研究目的という条件と、元投稿の権利を確認する。

[1] UMass SLANG Lab (n.d.), TwitterAAE: Research on African-American English on Twitter. https://slanglab.cs.umass.edu/TwitterAAE/

多様な表現を、そのまま評価の対象にする

TwitterAAE は地域人口構成を手掛かりに、 AAE に関連する表現を大規模な会話から取り出し、言語的特徴との対応を検証した。

2016 年の研究は、既知の AAE の文法との対応や、言語同定・構文解析ツールによる扱いの差を調べた。

方言を含む意見や会話も扱える NLP のために、言語的な多様性を研究する資源となる。

[1] Blodgett, Green & O'Connor (2016). Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

Appendix

1. 追加の投稿例
2. 研究と参考文献

追加の投稿例

実例 4 ：終わった数を数える

投稿全文 / aa 群（言語的特徴で抽出）

> 4 down 1 to go

日本語訳

> 4 つ終わった、あと 1 つ。

終わった数と残りの数を、短い対比で伝える。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例５：強い空腹を伝える

投稿全文 / aa 群（言語的特徴で抽出）

I'm hungry af

日本語訳

めちゃくちゃ腹減った。

af は強い強調を加える俗語。 hungry と組み合わせ、空腹の強さを伝える。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 6 ：帰宅を短く伝える

投稿全文 / aa 群（言語的特徴で抽出）

Bk at da crib

日本語訳

家に戻った。

Bk は back 、 da は the 、 crib は家を指すくだけた表現。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 7 ：書き続ける一日

投稿全文 / aa 群（言語的特徴で抽出）

> All day im writen nd writen!!

日本語訳

一日中、書いてはまた書いてる !!

nd は and の略。 writen の反復と感嘆符が、書き続ける調子を作る。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 8 ：歌詞を覚えたい

投稿全文 / aa 群（言語的特徴で抽出）

I gotta learn the words to this song .

日本語訳

この歌の歌詞を覚えなきゃ。

省略形 gotta を含む、日常のひとこと。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 9 ：疲れを否定する

投稿全文 / white 群（言語的特徴で抽出）

> Not tired at all

日本語訳

全然疲れてない。

tired の否定と at all の強調を含む。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 10 ：夜に誰かを思う

投稿全文 / white 群（言語的特徴で抽出）

> It's nights like these that I think about you.

日本語訳

こんな夜には、君のことを考えてしまう。

縮約形と語りかけを含む。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 11 ：続けられるか分からない

投稿全文 / white 群（言語的特徴で抽出）

> I don't know how much longer I can do this.

日本語訳

あとどれくらいこれを続けられるか、分からない。

this の具体的な内容は省かれ、続けることへの迷いを短く伝える。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 12 ：言葉を失う

投稿全文 / white 群（言語的特徴で抽出）

> I cannot even.

日本語訳

もう、言葉も出ない。

I cannot even. は、驚きやあきれなどで言葉が続かないことを表す口語表現。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 13 ：昼寝の後も疲れる

投稿全文 / white 群（言語的特徴で抽出）

I took a 3 hour nap earlier why am I exhausted

日本語訳

さっき 3 時間も昼寝したのに、なんでこんなに疲れてるんだろう。

3 時間という長さと、まだ疲れているという疑問を一息に伝える。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

研究と参考文献

言語学と NLP をつないだ研究

Su Lin Blodgett 、 Lisa Green 、 Brendan O’Connor による 2016 年 EMNLP 論文。 UMass Amherst の計算機科学と言語学の研究として発表された。

既知の AAE の発音・文法上の特徴との対応を検証し、大規模な統計モデルの抽出結果を言語学的分析へ結び付けた。

2018 年の構文解析研究では Johnny Tian-Zheng Wei が加わり、AAE と主流米国英語の UD 注釈を整えた。

[1] Blodgett, Green & O’Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/
[2] Blodgett, Wei & O’Connor (2018), Twitter Universal Dependency Parsing for African-American and Mainstream American English. ACL, 1415–1425. https://aclanthology.org/P18-1131/

参考文献

Demographic Dialectal Variation in Social Media: A Case Study of African-American English

Su Lin Blodgett, Lisa Green, Brendan O'Connor · 2016 · EMNLP, 1119–1130

地域人口統計を用いた言語混合モデルと、 AAE に対する言語同定・構文解析の差を示す。

https://aclanthology.org/D16-1120/

Twitter Universal Dependency Parsing for African-American and Mainstream American English

Su Lin Blodgett, Johnny Tian-Zheng Wei, Brendan O'Connor · 2018 · ACL, 1415–1425

二つの英語変種のツイートに UD 注釈を付け、構文解析モデルを比較する。

https://aclanthology.org/P18-1131/

参考文献

TwitterAAE: Research on African-American English on Twitter

UMass SLANG Lab · n.d.· 公式研究ページ（ 2026-10-18 参照）

論文、研究用コーパス、言語混合比推定モデル、 UD 注釈の配布をまとめる。

https://slanglab.cs.umass.edu/TwitterAAE/