TwitterAAE

African-American English on Twitter

会話の言語的多様性と言語モデルの評価

sasakiy84

公式サイト：研究と配布への入口



TwitterAAE: Research on African-American English on Twitter

Papers

Demographic Dialectal Variation in Social Media: A Case Study of African-American English. Su Lin Blodgett, Lisa Green, and Brendan O'Connor. Proceedings of EMNLP 2016. [pdf]

Twitter Universal Dependency Parsing for African-American and Mainstream American English. Su Lin Blodgett, Johnny Tian-Zheng Wei, and Brendan O'Connor. Proceedings of ACL 2018. [pdf]

Overview

Though dialectal language is increasingly abundant on social media, few resources exist for developing NLP tools to handle such language. We conduct a case study of dialectal language in online conversational text by investigating African-American English (AAE) on Twitter. We propose a distantly supervised model to identify AAE-like language from demographics associated with geo-located messages, and we verify that this language follows well-known AAE linguistic phenomena. In addition, we analyze the quality of existing language identification and dependency parsing tools on AAE-like text, demonstrating that they perform poorly on such text compared to text associated with white speakers.

Further work on language identification is on our TwitterLangID page.

[1] UMass SLANG Lab (n.d.), TwitterAAE: Research on African-American English on Twitter. https://slanglab.cs.umass.edu/TwitterAAE/

1. 投稿の実例と言語モデルの課題
2. 人口統計と言語を結ぶ構築方法
3. HELM の評価条件と結果
4. 利用の変化と公開範囲

投稿の実例と言語モデルの課題

AAE を含む会話を NLP の対象にする

TwitterAAE は、 Twitter 上のアフリカ系米国人英語（ AAE ）に関連する表現を調べる言語資源。投稿の位置に対応する地域の人口構成と、使われる言葉の関係から分析する。

AAE には語彙・発音・文法の体系がある。主流の書き言葉を中心に作られた NLP ツールが、こうした会話をどの程度扱えるかを調べた。

[1] Blodgett, Green & O'Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

HELM では、投稿の予測しやすさを比べる

HELM では、 AA 系・ white 系の言語的特徴が多い投稿をそれぞれ集め、言語モデルがどれだけ予測できるかを比べる。

入力は投稿全文で、直前までの文字列から次のトークンを予測する。参照回答の代わりに、実際に書かれた文字列の確率を評価する。

[1] Stanford CRFM, HELM TwitterAAEScenario.
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/twitter_aae_scenario.py

AA ・ white は、言語の特徴に基づく抽出条件

本編 3 例と追加 10 例は、 HELM の公開評価に使われた 13 件の投稿全文。大文字や独自のつづり、句読点にも会話の特徴が現れる。

aa ／ white は抽出条件の名前。地域の人口構成に関連する言語の混合比を使っており、投稿者の自己申告による人種を表すラベルではない。

[1] Blodgett et al. (n.d.), twitteraae. 人口統計と言語を結ぶ混合モデルの README 。 https://github.com/slanglab/twitteraae

実例 1 ：電話代を払ってでも話したい

HELM test / aa 抽出条件・投稿全文

> IMA PAY OOMFS FONE BILL ‚JUS KUZ I WANNA TALK TO HER

日本語訳

あのフォロワーの子と話したいからってだけで、携帯代を払ってやるつもり。

OOMF は one of my followers （フォロワーの一人）の略。 FONE や JUS など、発音に近づけたつづりも使う。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例２：短い願いと呼びかけ

HELM test / aa 抽出条件・投稿全文

> I just wanna be happy bruh

日本語訳

ただ幸せになりたいんだよ、なあ。

bruh はくだけた呼びかけ。 wanna は want to の縮約で、短い投稿でも会話の調子が伝わる。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例３： white 側にも語りかけの表現がある

HELM test / white 抽出条件・投稿全文

> Sweet sleep, how I missed you my love.

日本語訳

ああ愛しい眠り、どれほど恋しかったことか。

sleep を恋人のように呼ぶ、擬人化した語りかけ。 white 抽出集合にもこのような会話が含まれる。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

人口統計と言語を結ぶ構築方法

2013 年の位置付き投稿から会話を集める

2013 年の公開 Twitter ストリーム 160 億件から、米国の国勢調査 block group に位置を対応できる約 9,000 万件を得た。

フォロワーの多いアカウントや、ハッシュタグの多い投稿、リンク・宣伝語を含む投稿、リツイートなどを除いた。

前処理後は約 5,920 万投稿・ 280 万ユーザー。位置情報を公開する利用者の会話が対象となる。

[1] Blodgett, Green & O'Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

地域の人口構成を、言語の手掛かりにする

投稿位置を、通常 600 〜 3,000 人が暮らす block group へ結び付け、 2013 年 American Community Survey の人口構成を参照する。

非ヒスパニック白人・非ヒスパニック黒人・ヒスパニック・アジア系の 4 比率を、各ユーザーの投稿位置で平均した。

近隣地域の人口構成を、投稿の言語的特徴を推定する手掛かりにする。

[1] Blodgett, Green & O'Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

一人の中にも、一つの投稿にも混合を認める

4 集団に対応する単語分布を学習し、各投稿でそれらが占める混合比を推定する。ユーザーに対応付けた地域の人口比率を、その推定の事前分布に使う。

同じ人でも、投稿によって使う表現は変わる。ユーザー単位と投稿単位の混合比で、その変化を表現する。

[1] Blodgett, Green & O'Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

AAE に特徴的な文法が多く現れる

構文	公開された用例	AA ／ white 比
習慣を表す be	I be tripping bruh	11.94
未来を表す gon	Then she gon be single Af	14.26
完了を表す done	I done laughed so hard that I’m weak	8.68

ユーザー単位で作った 2016 年の両コーパスを比較。表記だけでなく、既知の文法現象とも照合した。

[1] Blodgett, Green & O’Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

HELM は、投稿ごとの言語的特徴で集合を作る

対象	選び方と件数
2016 年の解析集合	ユーザーの対応言語成分 80% 以上、ヒスパニック系・アジア系は計 5% 未満。 AA 約 83 万／ white 約 730 万投稿。
HELM の抽出集合	投稿の AA 比率上位 83 万／ white 比率上位 730 万から、それぞれ 5 万投稿を無作為抽出。

2016 年の分析はユーザーごとに選び、 HELM は投稿ごとの混合比で選ぶ。

[1] Stanford CRFM, HELM TwitterAAEScenario.
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/twitter_aae_scenario.py

HELM の評価条件と結果

BPB が低いほど、投稿を予測しやすい

言語モデルは、先行する文字列を条件に各トークンの確率を付ける。予測対象の負の対数確率を合計し、その byte 数で割って bits へ換算する。

bits per byte （ BPB ）は、 1 byte を表すために必要な平均情報量。低いほど、その文字列に高い確率を与えている。

トークンの区切りがモデル間で異なるため、 HELM の主要指標には byte で正規化した BPB を使う。

[1] Stanford CRFM, HELM BasicMetrics.
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/metrics/basic_metrics.py

HELM では AA 側の BPB が高かった

モデル（公開年）	AA	white	差 AA−white
OPT-175B （ 2022 ）	2.114	1.506	0.608
text-davinci-003 （ 2022 ）	2.522	1.862	0.660

BPB （低いほど良い）。 2022 年公開の 2 モデルを、 AA ・ white 各 1,000 投稿で比較。提示例なし。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

AA 側の投稿では、両モデルとも予測が難しい

byte 数で正規化した予測の難しさは、両モデルとも AA 抽出条件の投稿で大きかった。

二つの集合には、つづり・話題・長さ・会話の形式などの違いがある。得点差には、こうした内容や表現の違いが含まれる。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

言語同定では、英語を取りこぼしていた

2016 年の解析では、 langid.py が AA 側の 13.2% 、 white 側の 7.6% を非英語と判定した。 Twitter の識別結果でも、欠損値を非英語に数えるかどうかの両条件で AA 側の割合が高かった。

AA 混合比を 10 段階に分け、各識別条件で非英語とされた投稿から計 1,500 件を人手で調べた。明らかな非英語は 13 件（約 0.87% ）だった。

英語だけを残す前処理そのものが、方言を含む意見や会話を取りこぼす問題につながる。

[1] Blodgett, Green & O’Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

利用の変化と公開範囲

会話の解析から、言語モデルの格差測定へ

2016 年は人口統計と言語の混合モデルを作り、言語同定・構文解析の差を調べた。

2018 年には AAE と主流米国英語の各 250 投稿に Universal Dependencies 注釈を付け、構文解析の資源を拡張した。

HELM Classic では、同じ元コーパスから投稿を別途抽出し、言語モデルの予測しやすさを比べる評価へ広がった。

[1] Blodgett, Wei & O'Connor (2018), Twitter Universal Dependency Parsing for African-American and Mainstream American English. ACL, 1415–1425. https://aclanthology.org/P18-1131/
[2] Stanford CRFM, HELM TwitterAAEScenario. https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/twitter_aae_scenario.py

研究用コーパスと評価結果を公式サイトで入手する

公式サイトの全体配布 TwitterAAE-full-v1.zip は表示容量 5.5 GB 。研究目的のみでの提供と 2016 年論文の引用が案内されている。

HELM は AA ・ white 各 5 万投稿の CSV を案内し、 Classic の評価ページで、実際に使った投稿とモデルの得点を公開している。

推定モデルのコードは MIT ライセンス。投稿本文の利用は、公式サイトの研究目的という条件と、元投稿の権利を確認する。

[1] UMass SLANG Lab (n.d.), TwitterAAE: Research on African-American English on Twitter. https://slanglab.cs.umass.edu/TwitterAAE/

多様な表現を、そのまま評価の対象にする

TwitterAAE は地域人口構成を手掛かりに、 AAE に関連する表現を大規模な会話から取り出し、言語的特徴との対応を検証した。

HELM は、同じコーパスから言語的特徴で選んだ二つの投稿集合を作り、それぞれの投稿に対する BPB を比べる。

言語モデルの予測しやすさと、言語同定による取りこぼしを調べることで、 NLP が扱える会話の範囲を見直せる。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

Appendix

1. 追加の投稿例
2. 入力と指標の補足
3. 研究と参考文献

追加の投稿例

実例 4 ：終わった数を数える

HELM test / aa 抽出条件・投稿全文

> 4 down 1 to go

日本語訳

4 つ終わった、あと 1 つ。

終わった数と残りの数を、短い対比で伝える。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 5 ：強い空腹を伝える

HELM test / aa 抽出条件・投稿全文

I'm hungry af

日本語訳

めちゃくちゃ腹減った。

af は強い強調を加える俗語。 hungry と組み合わせ、空腹の強さを伝える。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 6 ：帰宅を短く伝える

HELM test / aa 抽出条件・投稿全文

> Bk at da crib

日本語訳

家に戻った。

Bk は back 、 da は the 、 crib は家を指すくだけた表現。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 7 ：書き続ける一日

HELM test / aa 抽出条件・投稿全文

> All day im writen nd writen!!

日本語訳

一日中、書いてはまた書いてる !!

nd は and の略。 writen の反復と感嘆符が、書き続ける調子を作る。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 8 ：歌詞を覚えたい

HELM test / aa 抽出条件・投稿全文

I gotta learn the words to this song .

日本語訳

この歌の歌詞を覚えなきゃ。

省略形 gotta を含む、日常のひとこと。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例９：疲れを否定する

HELM test / white 抽出条件・投稿全文

Not tired at all

日本語訳

全然疲れてない。

tired の否定と at all の強調を含む。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 10 ：夜に誰かを思う

HELM test / white 抽出条件・投稿全文

It's nights like these that I think about you.

日本語訳

こんな夜には、君のことを考えてしまう。

縮約形と語りかけを含む。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 11 ：続けられるか分からない

HELM test / white 抽出条件・投稿全文

> I don't know how much longer I can do this.

日本語訳

あとどれくらいこれを続けられるか、分からない。

this の具体的な内容は省かれ、続けることへの迷いを短く伝える。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 12 ：言葉を失う

HELM test / white 抽出条件・投稿全文

> I cannot even.

日本語訳

もう、言葉も出ない。

I cannot even. は、驚きやあきれなどで言葉が続かないことを表す口語表現。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 13 ：昼寝の後も疲れる

HELM test / white 抽出条件・投稿全文

I took a 3 hour nap earlier why am I exhausted

日本語訳

さっき 3 時間も昼寝したのに、なんでこんなに疲れてるんだろう。

3 時間という長さと、まだ疲れているという疑問を一息に伝える。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

入力と指標の補足

HELM の投稿は、 AA 側が平均約 40 文字

1,000 投稿ずつの文字数	AA	white
平均	39.85	57.17
中央値	33	48
最小／最大	2 ／ 261	2 ／ 422

HELM で使われた各 1,000 投稿の文字数。 Unicode の文字単位で、エスケープ表現も入力のつづりどおり数えた。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

絵文字のエスケープ表現も入力に含む

HELM の入力には、絵文字を「 \ud83d\ude02 」のようなエスケープ表現にした投稿もある。

モデルは、この表現を含む文字列に確率を付ける。画面で絵文字として表示した場合とは、入力の長さやトークンの分割が変わる。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

公開実行の JSON から、投稿全文を読み出す

```
import json
with open("scenario_state.json", encoding="utf-8") as f:
    state = json.load(f)
post = state["request_states"][0]["instance"]
print(post["input"]["text"])
```

公開された scenario_state.json には、評価に使った投稿とリクエストを収める。最初の投稿の input.text を取り出す。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

BPB は、全投稿の総 byte 数で割って求める

予測対象トークンの対数確率の総和を L 、予測対象の byte 数の総和を B とすると、 $BPB = -L / (B \times \ln 2)$ 。

すべての投稿の対数確率と byte 数を合計してから計算するため、長い投稿ほど大きな重みを持つ。

実例 1 の text-davinci-003 では、対数確率の和は− 101.668 、 52 byte 。 1 投稿の BPB は約 2.821 となる。

[1] Stanford CRFM. HELM BasicMetrics. https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/metrics/basic_metrics.py
[2] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

perplexity では分母がトークンになる

モデル	AA	white
OPT-175B	184.99	65.76
text-davinci-003	152.51	77.07

同じ公開実行の perplexity 。モデル間ではトークンの分割が異なるため、主要な比較には BPB を用いた。

[1] Stanford CRFM. HELM Classic v0.4.0 — TwitterAAE. https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

研究と参考文献

言語学と NLP をつないだ研究

Su Lin Blodgett 、 Lisa Green 、 Brendan O’Connor による 2016 年 EMNLP 論文。 UMass Amherst の計算機科学と言語学の研究として発表された。

既知の AAE の発音・文法上の特徴との対応を検証し、大規模な統計モデルの抽出結果を言語学的分析へ結び付けた。

2018 年の構文解析研究では Johnny Tian-Zheng Wei が加わり、AAE と主流米国英語の UD 注釈を整えた。

[1] Blodgett, Green & O’Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/
[2] Blodgett, Wei & O’Connor (2018), Twitter Universal Dependency Parsing for African-American and Mainstream American English. ACL, 1415–1425. https://aclanthology.org/P18-1131/

参考文献

Demographic Dialectal Variation in Social Media: A Case Study of African-American English

Su Lin Blodgett, Lisa Green, Brendan O'Connor · 2016 · EMNLP, 1119–1130

地域人口統計を用いた言語混合モデルと、 AAE に対する言語同定・構文解析の差を示す。

https://aclanthology.org/D16-1120/

Twitter Universal Dependency Parsing for African-American and Mainstream American English

Su Lin Blodgett, Johnny Tian-Zheng Wei, Brendan O'Connor · 2018 · ACL, 1415–1425

二つの英語変種のツイートに UD 注釈を付け、構文解析モデルを比較する。

https://aclanthology.org/P18-1131/

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. · 2023 · Transactions on Machine Learning Research

多様なシナリオと指標をそろえ、言語モデルの能力と格差を測る HELM の評価設計。

https://arxiv.org/abs/2211.09110

TwitterAAE: Research on African-American English on Twitter

UMass SLANG Lab · n.d.· 公式研究ページ（ 2026-10-18 参照）

論文、研究用コーパス、言語混合比推定モデル、 UD 注釈の配布をまとめる。

https://slanglab.cs.umass.edu/TwitterAAE/