TwitterAAE

African-American English on Twitter

会話の言語的多様性と言語モデルの評価

sasakiy84

公式サイト：研究と配布への入口



TwitterAAE: Research on African-American English on Twitter

Papers

Demographic Dialectal Variation in Social Media: A Case Study of African-American English. Su Lin Blodgett, Lisa Green, and Brendan O'Connor. Proceedings of EMNLP 2016. [pdf]

Twitter Universal Dependency Parsing for African-American and Mainstream American English. Su Lin Blodgett, Johnny Tian-Zheng Wei, and Brendan O'Connor. Proceedings of ACL 2018. [pdf]

Overview

Though dialectal language is increasingly abundant on social media, few resources exist for developing NLP tools to handle such language. We conduct a case study of dialectal language in online conversational text by investigating African-American English (AAE) on Twitter. We propose a distantly supervised model to identify AAE-like language from demographics associated with geo-located messages, and we verify that this language follows well-known AAE linguistic phenomena. In addition, we analyze the quality of existing language identification and dependency parsing tools on AAE-like text, demonstrating that they perform poorly on such text compared to text associated with white speakers.

Further work on language identification is on our TwitterLangID page.

[1] UMass SLANG Lab (n.d.), TwitterAAE: Research on African-American English on Twitter. 2026-10-18 参照。 https://slanglab.cs.umass.edu/TwitterAAE/

1. 投稿の実例と言語モデルの課題
2. 人口統計と言語を結ぶ構築方法
3. HELM の評価条件と結果
4. 利用の変化と公開範囲

投稿の実例と言語モデルの課題

AAE を含む会話を NLP の対象にする

TwitterAAE は、 Twitter 上の African-American English （ AAE ）に関連する言語を、地域の人口統計と言葉の共起から分析する資源。

AAE には語彙・発音・文法の体系がある。主流の書き言葉を中心に作られた NLP ツールが、こうした会話をどの程度扱えるかを調べた。

[1] Blodgett, Green & O'Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

HELM では、投稿の予測しやすさを比べる

HELM は、 AA 寄り・ white 寄りの言語混合比で抽出した二つの投稿集合に、言語モデルが付ける確率を測る。

入力は投稿全文で、直前までの文字列から次のトークンを予測する。参照回答の代わりに、実際に書かれた文字列の確率を評価する。

[1] Stanford CRFM, HELM TwitterAAEScenario. AA ／ white の抽出と test インスタンス。 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/twitter_aae_scenario.py

実例は HELM の公開実行入力から示す

以下の 3 例と Appendix の 10 例は、公開された scenario_state から選んだ別々の投稿。元の大文字・つづり・句読点を保って全文を示す。

aa ／ white はデータの抽出条件名。元の推定値は、人口統計に関連付けられた言語が文中で占める割合であり、話者の自己申告人種ではない。

[1] Blodgett et al. (n.d.), twitteraae. 人口統計と言語を結ぶ混合モデルの README 。 2026-10-18 参照。 https://github.com/slanglab/twitteraae

実例１：電話代を払ってでも話したい

HELM test / aa 抽出条件・投稿全文

> IMA PAY OOMFS FONE BILL ,JUS KUZ I WANNA TALK TO HER

日本語訳

あのフォロワーの子と話したいからってだけで、携帯代を払ってやるつもり。

OOMF は one of my followers の略。大文字やつづりの工夫も、実際に採点された文字列の一部。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: aa/id19602 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例２：短い願いと呼びかけ

HELM test / aa 抽出条件・投稿全文

> I just wanna be happy bruh

日本語訳

ただ幸せになりたいんだよ、なあ。

bruh という呼びかけと wanna の縮約を含む。語りかけの調子を保って訳した。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: aa/id15055 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例３： white 側にもくだけた会話がある

HELM test / white 抽出条件・投稿全文

> Sweet sleep, how I missed you my love.

日本語訳

ああ愛しい眠り、どれほど恋しかったことか。

sleep を恋人のように呼ぶ、擬人化した語りかけ。 white 抽出集合にもこのような会話が含まれる。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: white/id12363 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

人口統計と言語を結ぶ構築方法

2013 年の位置付き投稿から会話を集める

2013 年の公開 Twitter ストリーム 160 億件から、米国の国勢調査 block group に位置を対応できる約 9,000 万件を得た。

フォロワー 1,000 人以上の著者、 3 個以上のハッシュタグ、 http ・ follow ・ mention を含む投稿、リツイートなどを除いた。

前処理後は約 5,920 万投稿・ 280 万ユーザー。位置情報を公開する利用者の会話が対象となる。

[1] Blodgett, Green & O'Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

地域の人口構成を、言語の手掛かりにする

投稿位置を、通常 600 〜 3,000 人が暮らす block group へ結び付け、 2013 年 American Community Survey の人口構成を参照する。

非ヒスパニック白人・非ヒスパニック黒人・ヒスパニック・アジア系の 4 比率を、各ユーザーの投稿位置で平均した。

これは近隣地域の人口構成を介した遠隔教師信号。個人に人種を尋ねた注釈は付けていない。

[1] Blodgett, Green & O'Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

一人の中にも、一つの投稿にも混合を認める

4 集団に対応する単語分布を学習し、各投稿でそれらが占める混合比を推定する。ユーザーに対応付けた地域の人口比率を、その推定の事前分布に使う。

同じ人が投稿ごとに異なる表現を使える設計。特定のキーワードを一度使っただけで、その人の全投稿を同じ言語に固定しない。

[1] Blodgett, Green & O'Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

言語的特徴との対応を確かめた

構文	公開された用例	AA ／ white 比
習慣を表す be	I be tripping bruh	11.94
未来を表す gon	Then she gon be single Af	14.26
完了を表す done	I done laughed so hard that I’m weak	8.68

ユーザー単位で作った 2016 年の両コーパスを比較。表記だけでなく、既知の文法現象とも照合した。

[1] Blodgett, Green & O’Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

2016 年の集合と HELM の集合は作り方が違う

対象	選び方と件数
2016 年の解析集合	ユーザーの対応言語比率 80% 以上、他 2 成分の合計 5% 未満。 AA 約 83 万／ white 約 730 万投稿。
HELM の抽出集合	投稿の AA 比率上位 83 万／ white 比率上位 730 万から、それぞれ 5 万投稿を無作為抽出。

HELM の公開コードが記載する二段階の抽出。 2016 年の解析集合をそのまま 5 万件にしたものではない。

[1] Stanford CRFM, HELM TwitterAAEScenario. AA ／ white の抽出と test インスタンス。 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/twitter_aae_scenario.py

HELM の評価条件と結果

低い bits per byte ほど投稿を予測できる

言語モデルは、先行する文字列を条件に各トークンの確率を付ける。予測対象の対数確率を合計し、その byte 数で割って bits へ換算する。

bits per byte （ BPB ）は、 1 byte を表すために必要な平均情報量。低いほど、その文字列に高い確率を与えている。

トークンの区切りがモデル間で異なるため、 HELM の主要指標には byte で正規化した BPB を使う。

[1] Stanford CRFM, HELM BasicMetrics. 対数確率・ byte 数からの集約。 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/metrics/basic_metrics.py

HELM では AA 側の BPB が高かった

モデル（公開年）	AA	white	差 AA−white
OPT-175B （ 2022 ）	2.114	1.506	0.608
text-davinci-003 （ 2022 ）	2.522	1.862	0.660

BPB 、低いほど良い。 Classic v0.4.0 収録・ suite v0.3.0 、各条件 1,000 投稿、提示例 0 、各 1 試行。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

得点差は、二つの抽出集合での予測の差

byte 数で正規化した予測の難しさは、両モデルとも AA 抽出条件の投稿で大きかった。

集合にはつづり、話題、長さ、会話の形式などの違いも含まれる。同じ内容だけを方言で書き換えた対訳実験ではない。

この値が示すのは公開実行時の投稿集合での差であり、 2026 年のモデルの順位ではない。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

言語同定では、英語を取りこぼしていた

2016 年の解析では、 langid.py が AA 側の 13.2% 、 white 側の 7.6% を非英語と判定した。 Twitter の識別結果でも、欠損値を非英語に数えるかどうかの両条件で AA 側の割合が高かった。

AA 混合比を 10 段階に分け、各識別条件で非英語とされた投稿から計 1,500 件を人手で調べた。明らかな非英語は 13 件（約 0.87% ）だった。

英語だけを残す前処理そのものが、方言を含む意見や会話を取りこぼす問題につながる。

[1] Blodgett, Green & O’Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/

利用の変化と公開範囲

会話の解析から、言語モデルの格差測定へ

2016 年は人口統計と言語の混合モデルを作り、言語同定・構文解析の差を調べた。

2018 年には AAE と主流米国英語の各 250 投稿に Universal Dependencies 注釈を付け、構文解析の資源を拡張した。

HELM Classic は別途抽出した投稿を言語モデリングに用いる。2026-10-18 確認の公開実装にも AA ／ white の両条件が残る。

[1] Blodgett, Wei & O'Connor (2018), Twitter Universal Dependency Parsing for African-American and Mainstream American English. ACL, 1415–1425. https://aclanthology.org/P18-1131/
[2] Stanford CRFM, HELM TwitterAAEScenario. AA ／ white の抽出と test インスタンス。 2026-10-18 確認。 https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/twitter_aae_scenario.py

公式配布と HELM の公開記録を使い分ける

公式サイトの全体配布 TwitterAAE-full-v1.zip は表示容量 5.5 GB 。研究目的のみでの提供と 2016 年論文の引用が案内されている。

HELM の 5 万件 CSV は CodaLab の URL を参照する。今回の取得では双方 503 となったが、公開実行の 1,000 投稿ずつと得点は取得できた。

推定モデルのコードには MIT ライセンスがある。投稿本文の権利や再配布範囲は、コードの MIT ライセンスとは別に扱う。

[1] UMass SLANG Lab (n.d.), TwitterAAE: Research on African-American English on Twitter. 2026-10-18 参照。 https://slanglab.cs.umass.edu/TwitterAAE/

多様な表現を、そのまま評価の対象にする

TwitterAAE は地域人口構成を手掛かりに、 AAE に関連する表現を大規模な会話から取り出し、言語的特徴との対応を検証した。

HELM は、同じコーパスから二つの言語抽出集合を作り、それぞれの投稿に対する BPB を比べる。

元の集合の作り方と公開実行の範囲を押さえると、投稿の予測しにくさと、既存 NLP 処理の取りこぼしを具体的に捉えられる。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. TMLR. https://arxiv.org/abs/2211.09110

Appendix

1. 追加の投稿例
2. 版・実行条件の補足
3. 研究と参考文献

追加の投稿例

実例 4 ：終わった数を数える

HELM test / aa 抽出条件・投稿全文

> 4 down 1 to go

日本語訳

> 4 つ終わった、あと 1 つ。

何を数えているかは、この投稿だけでは分からない。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: aa/id42642 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 5 ：強い空腹を伝える

HELM test / aa 抽出条件・投稿全文

> I'm hungry af

日本語訳

めちゃくちゃ腹減った。

af の強調を、日本語でも強い話し言葉で表した。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: aa/id8369 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 6 ：帰宅を短く伝える

HELM test / aa 抽出条件・投稿全文

> Bk at da crib

日本語訳

家に戻った。

Bk は back 、 da は the 、 crib は家を指すくだけた表現。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: aa/id46250 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 7 ：書き続ける一日

HELM test / aa 抽出条件・投稿全文

> All day im writen nd writen!!

日本語訳

一日中、書いてはまた書いてる !!

nd は and に相当する。反復と感嘆符も表現の一部。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: aa/id24647 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 8 ：歌詞を覚えたい

HELM test / aa 抽出条件・投稿全文

> I gotta learn the words to this song .

日本語訳

この歌の歌詞を覚えなきゃ。

省略形 gotta を含む、日常のひとこと。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: aa/id29079 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 9 ：疲れを否定する

HELM test / white 抽出条件・投稿全文

> Not tired at all

日本語訳

全然疲れてない。

tired の否定と at all の強調を含む。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: white/id32104 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 10 ：夜に誰かを思う

HELM test / white 抽出条件・投稿全文

> It's nights like these that I think about you.

日本語訳

こんな夜には、君のことを考えてしまう。

縮約形と語りかけを含む。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: white/id46712 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 11 ：続けられるか分からない

HELM test / white 抽出条件・投稿全文

> I don't know how much longer I can do this.

日本語訳

あとどれくらいこれを続けられるか、分からない。

this の指す内容は公開された一文からは特定できない。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: white/id42460 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 12 ：言葉を失う

HELM test / white 抽出条件・投稿全文

> I cannot even.

日本語訳

もう、言葉も出ない。

I cannot even. は文脈に依存する口語表現として訳した。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: white/id19412 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

実例 13 ：昼寝の後も疲れる

HELM test / white 抽出条件・投稿全文

I took a 3 hour nap earlier why am I exhausted

日本語訳

さっき 3 時間も昼寝したのに、なんでこんなに疲れてるんだろう。

時間の数値と疑問の調子を保った。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 instance: white/id5140 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

版・実行条件の補足

公開実行入力の長さを確かめた

1,000 投稿ずつの文字数	AA	white
平均	39.85	57.17
中央値	33	48
最小／最大	2 ／ 261	2 ／ 422

Unicode コードポイント数。エスケープ文字列は入力のまま数えた。元の 2013 年ツイート表示上の文字数ではない。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

文字の表現も、評価入力の一部になる

公開入力には、絵文字を文字列のまま表した「 \ud83d\ude02 」のようなエスケープ表現もある。

本資料の実例はそれらを復号・訂正せず、公開実行で使われた input.text を保存する。短い自然文だけを選び、本文の実例で表記を追いやすくした。

HELM 内の id11841 などは投稿の Twitter ID ではなく、条件内のインスタンス ID 。同じ番号でも AA と white で本文が異なる。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

公開実行の設定は両モデルで共通

設定	値
method	language_modeling
max_eval_instances	1,000 （ test ）
max_train_instances / 試行数	0 / 1
temperature / max_tokens	0 / 0
prompt_truncated	0 （両モデル・両条件）

生成した回答の採点ではなく、 echo_prompt で既存の投稿の確率を取得する。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

BPB は投稿ごとの比を単純平均しない

予測対象トークンの対数確率の総和を L 、予測対象の byte 数の総和を B とすると、 BPB = −L / (B × ln 2) 。

投稿ごとの長さで重みが変わる、総 byte 数による集約。トークン単位の perplexity とは分母が異なる。

実例 1 の text-davinci-003 では、対数確率の和は− 101.668 、 52 byte 。 1 投稿の BPB は約 2.821 となる。

[1] Stanford CRFM, HELM BasicMetrics. 対数確率・ byte 数からの集約。 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/metrics/basic_metrics.py
[2] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

perplexity では分母がトークンになる

モデル	AA	white
OPT-175B	184.99	65.76
text-davinci-003	152.51	77.07

同じ公開実行の perplexity 。モデル間ではトークンの分割が異なるため、主要な比較には BPB を用いた。

[1] Stanford CRFM, HELM Classic v0.4.0, TwitterAAE. 公開実行 suite v0.3.0 。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/twitter_aae

公開範囲と取得できた範囲

公式の全体 ZIP （ 5.5 GB ）は未取得。公式 UD 配布 ZIP と公開 HELM 入力 2,000 件を取得し、 13 実例は後者から選定した。

公式サイトは研究目的での利用と論文の引用を求めている。投稿本文についての包括的な再配布許諾は確認できなかった。

原文、訳、条件内 ID 、固定実行 URL 、原レコード、取得ファイルの SHA-256 を制作記録へ保存した。

[1] UMass SLANG Lab (n.d.), TwitterAAE: Research on African-American English on Twitter. 2026-10-18 参照。 https://slanglab.cs.umass.edu/TwitterAAE/

研究と参考文献

言語学と NLP をつないだ研究

Su Lin Blodgett 、 Lisa Green 、 Brendan O’Connor による 2016 年 EMNLP 論文。 UMass Amherst の計算機科学と言語学の研究として発表された。

既知の AAE の発音・文法上の特徴との対応を検証し、大規模な統計モデルの抽出結果を言語学的分析へ結び付けた。

2018 年の構文解析研究では Johnny Tian-Zheng Wei が加わり、AAE と主流米国英語の UD 注釈を整えた。

[1] Blodgett, Green & O’Connor (2016), Demographic Dialectal Variation in Social Media: A Case Study of African-American English. EMNLP, 1119–1130. https://aclanthology.org/D16-1120/
[2] Blodgett, Wei & O’Connor (2018), Twitter Universal Dependency Parsing for African-American and Mainstream American English. ACL, 1415–1425. https://aclanthology.org/P18-1131/

参考文献

Demographic Dialectal Variation in Social Media: A Case Study of African-American English

Su Lin Blodgett, Lisa Green, Brendan O'Connor · 2016 · EMNLP, 1119–1130

地域人口統計を用いた言語混合モデルと、 AAE に対する言語同定・構文解析の差を示す。

https://aclanthology.org/D16-1120/

Twitter Universal Dependency Parsing for African-American and Mainstream American English

Su Lin Blodgett, Johnny Tian-Zheng Wei, Brendan O'Connor · 2018 · ACL, 1415–1425

二つの英語変種のツイートに UD 注釈を付け、構文解析モデルを比較する。

https://aclanthology.org/P18-1131/

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. · 2023 · Transactions on Machine Learning Research

多様なシナリオと指標をそろえ、言語モデルの能力と格差を測る HELM の評価設計。

https://arxiv.org/abs/2211.09110

TwitterAAE: Research on African-American English on Twitter

UMass SLANG Lab · n.d.· 公式研究ページ（ 2026-10-18 参照）

論文、研究用コーパス、言語混合比推定モデル、 UD 注釈の配布をまとめる。

https://slanglab.cs.umass.edu/TwitterAAE/