動画の行動認識用データセット

UCF101

UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild

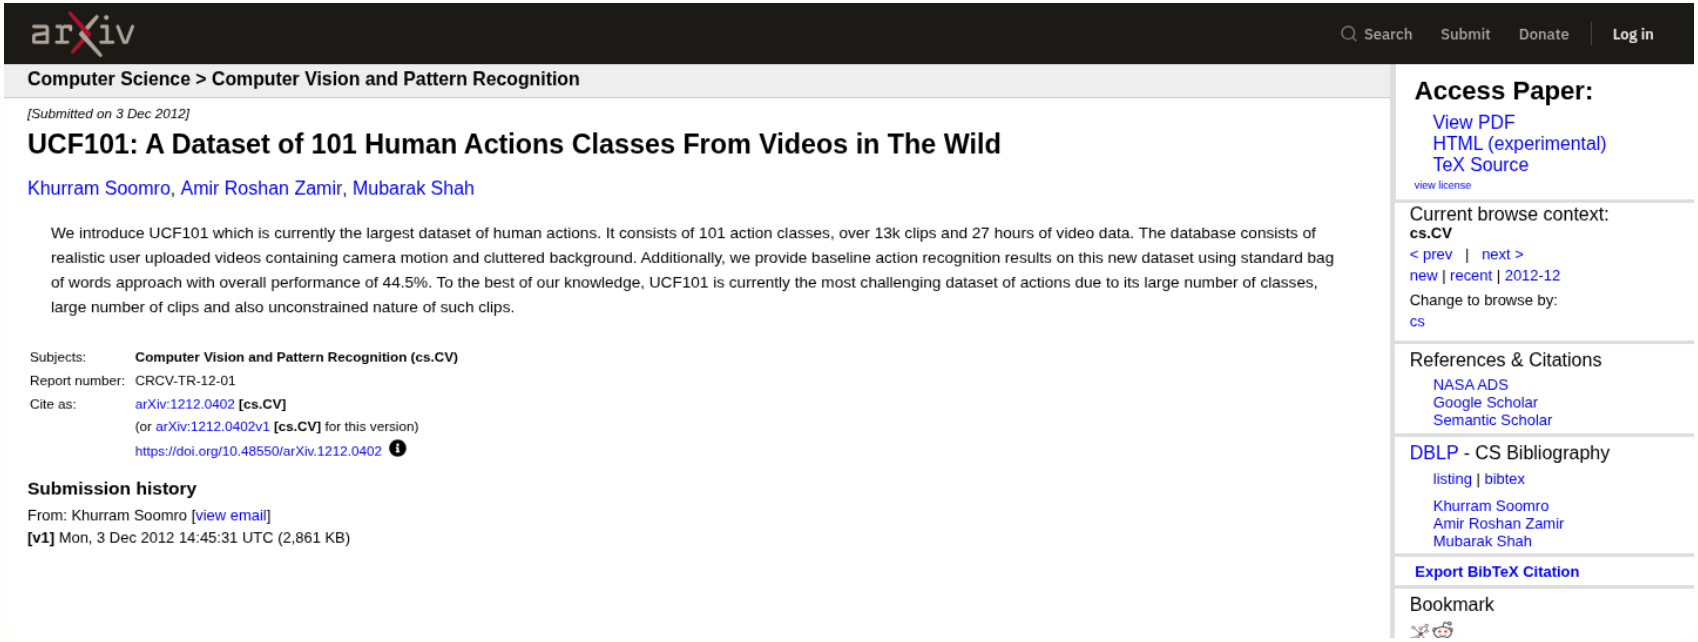
sasakiy84

本編の構成

1. 概要とタスク
2. 作成方法と規模
3. 評価とモデルの性能
4. 利用の変遷と現在
5. 入手方法とまとめ

1 概要とタスク

UCF101 の原著の公開ページ



arXiv Search Submit Donate Log in

Computer Science > Computer Vision and Pattern Recognition

[Submitted on 3 Dec 2012]

UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild

Khurram Soomro, Amir Roshan Zamir, Mubarak Shah

We introduce UCF101 which is currently the largest dataset of human actions. It consists of 101 action classes, over 13k clips and 27 hours of video data. The database consists of realistic user uploaded videos containing camera motion and cluttered background. Additionally, we provide baseline action recognition results on this new dataset using standard bag of words approach with overall performance of 44.5%. To the best of our knowledge, UCF101 is currently the most challenging dataset of actions due to its large number of classes, large number of clips and also unconstrained nature of such clips.

Subjects: **Computer Vision and Pattern Recognition (cs.CV)**
Report number: CRCV-TR-12-01
Cite as: arXiv:1212.0402 **[cs.CV]**
(or arXiv:1212.0402v1 **[cs.CV]** for this version)
https://doi.org/10.48550/arXiv.1212.0402

Submission history
From: Khurram Soomro [view email]
[v1] Mon, 3 Dec 2012 14:45:31 UTC (2,861 KB)

Access Paper:
View PDF
HTML (experimental)
TeX Source
view license

Current browse context:
cs.CV
< prev | next >
new | recent | 2012-12
Change to browse by:
cs

References & Citations
NASA ADS
Google Scholar
Semantic Scholar

DBLP - CS Bibliography
listing | bibtex
Khurram Soomro
Amir Roshan Zamir
Mubarak Shah

Export BibTeX Citation

Bookmark

[1] https://arxiv.org/abs/1212.0402

動画クリップを 101 種類の行動へ分類する

- UCF101 は、動画の行動認識用データセットである [1]。
- 入力は短い動画クリップで、正解は 1 つの行動カテゴリ。
- スポーツ、楽器の演奏、日常動作などを含む。
- 2012 年に公開され、 YouTube から集めた 13,320 クリップを収録した。

[1] Soomro et al. (2012), § 1–2. https://arxiv.org/abs/1212.0402

クリケットの打撃をフレーム列から捉える

正解は CricketShot （クリケットの打撃）



左から時間順に、打者がバットを振る場面を示す。

[1] I3D 公開例 . https://github.com/google-deepmind/kinetics-i3d
v_CricketShot_g04_c01.avi に由来する RGB 入力。 224×224 へ処理済み。 79 フレーム中の 0 ・ 19 ・ 39 ・ 59 ・ 78 番。 split 1 のテスト用。

目元の化粧の例

クリップの代表フレーム



正解は目元の化粧

ApplyEyeMakeup

手と化粧道具が目元に向かう動作を扱う。道具と身体部位の関係も手がかりになる。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / ApplyEyeMakeup / class ID 1

逆立ち歩きの例

クリップの代表フレーム



正解は逆立ち歩き

HandstandWalking

逆立ちで移動する行動を扱う。
姿勢だけでなく、移動を含む時間的な変化が関係する。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / HandstandWalking / class ID 38

多様な行動を自然な映像で評価するために作られた

- 当時は、カテゴリ数の少ない行動認識データが多かった [1]。
- 統制された環境で撮影した映像では、背景や撮影条件の変動が限られた。
- そこで YouTube の映像を集め、カメラの動き、遮蔽、背景の混雑を含む行動認識を評価する。
- UCF50 の 50 行動から 101 行動へ、カテゴリ数を約 2 倍に広げた。

[1] Soomro et al. (2012), § 1–2. https://arxiv.org/abs/1212.0402

2 作成方法と規模

YouTube の映像を収集し、無関係な動画を除いた

- YouTube から動画をダウンロードした [1]。
- 対象と無関係な動画を人手で除去した。
- 動画を 320×240 ピクセル・ 25 fps へ統一した。
- カテゴリごとにフォルダを分け、 AVI 形式で配布した。
- 追加した 51 行動の動画では音声も保持した。

[1] Soomro et al. (2012), § 2 / Table 1. https://arxiv.org/abs/1212.0402

同じ背景や人物のクリップをグループで管理する

- 各行動カテゴリには 25 グループがある [1]。
- 1 グループは 4 〜 7 クリップで、背景や人物などの特徴を共有する。
- ファイル名の g04 はグループ番号、 c01 はグループ内のクリップ番号。
- 近い映像が学習とテストの両方に入ることを避けるため、グループ単位で分ける。

[1] Soomro et al. (2012), §2–4. https://arxiv.org/abs/1212.0402

101 種類の行動は 5 つの型に整理されている

行動の型 [1]	カテゴリ数	クリップ数 [2]
人と物との相互作用	20	2619
身体の動き	16	1910
人と人との相互作用	5	690
楽器の演奏	10	1428
スポーツ	50	6673

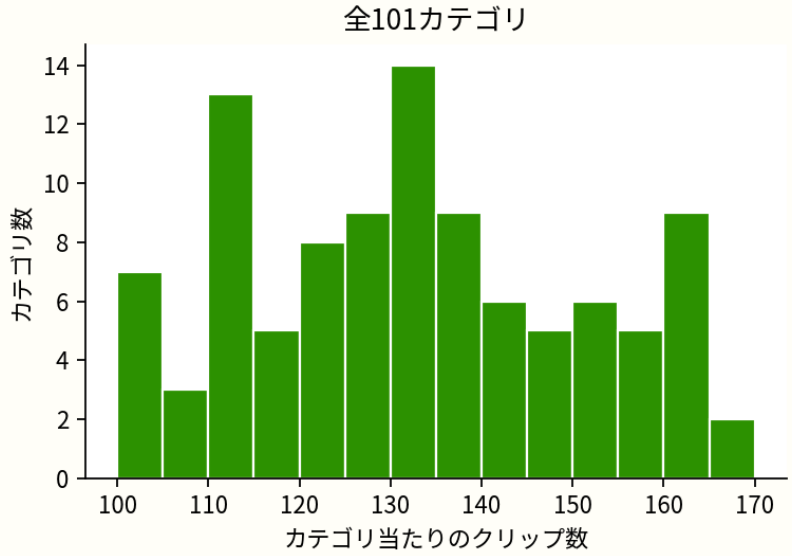
[1] 原著 Figure 2 の分類と分割リストの全件集計 . https://arxiv.org/abs/1212.0402
[2] https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

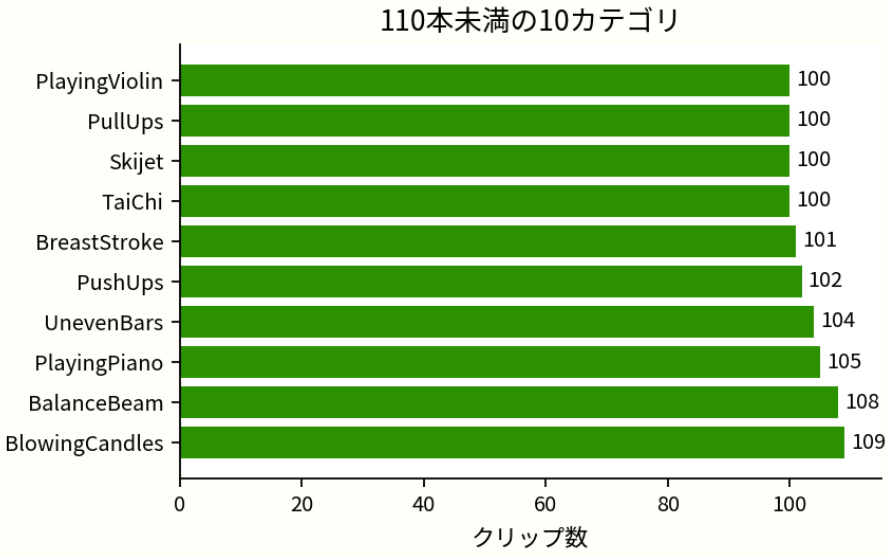
平均 7.21 秒の 13,320 クリップを収録する

- 101 カテゴリ、 13,320 クリップを収録する [1]。
- 原著の平均クリップ長は 7.21 秒、総時間は 1,600 分。
- 映像は 25 fps 、 320×240 ピクセル。
- 各カテゴリには 25 グループあり、合計 2,525 グループ [2]。
- 1 本の動画に 1 つの行動ラベルが付く。

[1] Soomro et al. (2012), Table 1. https://arxiv.org/abs/1212.0402
[2] グループ数は分割リストを全件集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

110 本未満のカテゴリは 10 種類





中央値は 131 本。 110 本未満は 10 カテゴリ [1]。

[1] 3 分割に共通する 13,320 クリップを、カテゴリごとに 1 回集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

3 つの分割で学習用とテスト用を入れ替える

分割 [1]	学習用	テスト用
split 1	9,537	3,783
split 2	9,586	3,734
split 3	9,624	3,696

各分割の合計は 13,320 。各カテゴリで同じグループが学習とテストへまたがらない。

[1] 配布分割リストの集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

3 評価とモデルの性能

正解率は動画ごとの正解を全体で平均する

- 最上位の予測が正解カテゴリと一致した動画を正解とする。
- 正解率は、正解した動画数を評価した動画数で割り、百分率にする。
- 3 動画中 2 動画が正解なら、正解率は 66.7% となる。
- 公式の 3 分割を使う評価では、分割ごとの値とその平均を区別する [1]。

[1] Carreira & Zisserman (2017), § 4 / Table 5. https://arxiv.org/abs/1705.07750

2012 年の原著の正解率は 44.5% だった

- 原著は局所的な動きと見た目を特徴量にして、映像を特徴の出現頻度で表した [1]。
- 分類にはサポートベクトルマシンを使った。
- 25 グループのうち 1 グループをテストにし、 25 回入れ替える交差検証を行った。
- 平均正解率は 44.5% 。後の 3 分割評価とは評価条件が異なる。

[1] Soomro et al. (2012), § 3–4. https://arxiv.org/abs/1212.0402

2017 年の I3D は 2 種類の入力を組み合わせた

I3D の入力 [1]	Top-1 正解率
RGB 画像	95.6%
フレーム間の動きを表す光学フロー	96.7%
RGB 画像と光学フロー	98.0%

ImageNet と Kinetics で事前学習し、 UCF101 で微調整した。公式 3 分割の平均。

[1] Carreira & Zisserman (2017), CVPR, Table 5. https://arxiv.org/abs/1705.07750

VideoMAE の結果は事前学習データで変わる

ViT-B の事前学習データ [1]	Top-1 正解率
UCF101 のみ	91.3%
Kinetics-400	96.1%

どちらも UCF101 で微調整した報告値。映像の隠した部分を復元する VideoMAE を使う。

[1] Tong et al. (2022), NeurIPS, Table 13. https://arxiv.org/abs/2203.12602

2024 年には映像特徴の評価にも使われた

固定する特徴モデル [1]	Top-1 正解率
DINOv2-g	91.2%
TVTSv2-H	91.8%
InternVideo2 第 2 段階・ 6B	97.3%

特徴を固定し、 UCF101 の学習用で線形分類器を学習する。特徴モデルの事前学習条件は異なる。

[1] Wang et al. (2024), InternVideo2, Table 4. https://arxiv.org/abs/2403.15377

高い正解率だけで時間順序の理解は示せない

- 映像には、行動の動きだけでなく物体や背景も写る。
- 背景や道具だけでも、行動カテゴリの手がかりになりうる。
- 2024 年の比較では画像特徴モデル DINOv2 を使う方式も 91.2% だった [1]。
- 行動分類の正解率と、動作の順序や細かな変化を理解できるかを分けて評価する。

[1] Wang et al. (2024), InternVideo2, Table 4. https://arxiv.org/abs/2403.15377

4 利用の変遷と現在

先行データより多くの行動と撮影条件を扱った

- 先行する KTH は、同じ撮影条件で 6 種類の行動を扱った [1]。
- これに対して UCF101 は、 YouTube の自然な映像で 101 種類を扱う。
- また、映画などから集めた HMDB51 は 51 種類だった。
- UCF101 は約 2 倍の行動カテゴリを設け、より多くの種類を区別する評価へ広げた。

[1] Soomro et al. (2012), § 1 / Table 2. https://arxiv.org/abs/1212.0402

後続データでは規模と動作の細かさが広がった

- 2017 年の Kinetics は 400 行動・ 306,245 クリップを扱った [1]。
  - UCF101 の約 4 倍の行動数、約 23 倍のクリップ数へ規模を広げた。
- 同年の Something-Something は、物を動かすなど 174 種類の細かい行動を扱った [2]。
  - UCF101 のスポーツや日常動作に対し、手と物の関係や移動方向を細かく区別する。

[1] Kay et al. (2017), Table 1. https://arxiv.org/abs/1705.06950
[2] Goyal et al. (2017), ICCV. https://arxiv.org/abs/1706.04261

現在は小規模な転移先や再現実験にも使われる

- 登場時は、自然な映像の多クラス行動認識を評価する資源だった。
- その後は、 Kinetics などで学んだ動画モデルの転移先にも使われた [1]。
- 2024 年の InternVideo2 も、線形分類・ゼロショット評価に用いた。
- 2026 年時点でも、 MMAction2 には UCF101 の取得・前処理・評価用ファイルを作る手順がある [2]。

[1] Carreira & Zisserman (2017). https://arxiv.org/abs/1705.07750 / Wang et al. (2024). https://arxiv.org/abs/2403.15377
[2] MMAction2 の UCF101 手順 . https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

5 入手方法とまとめ

動画本体と 3 分割のリストを取得する

- 公式配布元から、動画のアーカイブと学習・テスト分割の ZIP を取得する [1]。
- 展開したカテゴリ別フォルダと分割リストを対応させる。
- データを扱う MMAction2 などの手順で、フレーム抽出と入力用リストを準備できる [2]。
- 利用条件は公式配布元で確認する。

[1] UCF101 公式配布元 . https://www.crcv.ucf.edu/data/UCF101.php
[2] MMAction2 の UCF101 手順 . https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

UCF101 は動画モデルの行動認識と転移を評価する

- 101 種類の行動を扱う 13,320 クリップのデータセット。
- 自然な YouTube 映像で、多様な行動を評価するため 2012 年に作られた。
- 同じ背景や人物を共有するグループを単位に分割する。
- 登場時の分類評価から、事前学習モデルの転移・特徴評価にも用途が広がった。
- 正解率を比較するときは、分割・事前学習・評価方式をそろえる。

Appendix の目次

1. 著者と発表先
2. 追加の行動例
3. 101 カテゴリの一覧
4. 本数とグループの統計
5. 評価の補足
6. 入手と集計のコード
7. 参考文献

2012 年の技術報告として発表された

- CRCV-TR-12-01 としてまとめ、 2012-12-03 に arXiv へ投稿した [1]。
- 第一著者の Khurram Soomro は、 UCF101 を構築した行動認識研究者。
- 最終著者の Mubarak Shah は、動画の行動認識を研究し、UCF50 や UCF Sports にも取り組んだ。
- 当時の著者の所属は、セントラルフロリダ大学のコンピュータビジョン研究センター。

[1] Soomro et al. (2012), 表紙・参考文献 [9–10]. https://arxiv.org/abs/1212.0402

編み物の例

クリップの代表フレーム



正解は編み物

Knitting

手と道具を使う細かな作業を扱う。手元の見え方が行動の手がかりになる。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / Knitting / class ID 50

ヨーヨーの例

クリップの代表フレーム



正解はヨーヨー

YoYo

手とヨーヨーの関係を扱う。小さい物体の移動も行動に関係する。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / YoYo / class ID 101

赤ちゃんのはいはいの例

クリップの代表フレーム



正解は赤ちゃんのはいはい

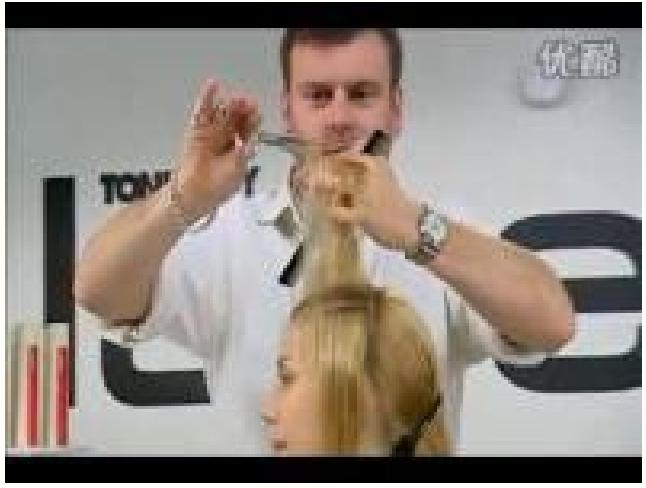
BabyCrawling

床に近い姿勢での移動を扱う。
年齢に特徴のある行動もカテゴリに含む。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / BabyCrawling / class ID 4

散髪の例

クリップの代表フレーム



正解は散髪

Haircut

人が別の人に行う作業を扱う。
複数の人物が写る映像も対象となる。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / Haircut / class ID 34

ギターの演奏の例

クリップの代表フレーム



正解はギターの演奏

PlayingGuitar

楽器と演奏者を扱う。楽器の種類もカテゴリを区別する手がかりになる。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / PlayingGuitar / class ID 63

ビリヤードの例

クリップの代表フレーム



正解はビリヤード

Billiards

台やキューなど、競技に特徴的な物体と動きを扱う。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / Billiards / class ID 12

バスケットボールのダンクの例

クリップの代表フレーム



正解はバスケットボールのダンク

BasketballDunk

一般的なバスケットボールと、ダンクを別カテゴリとして扱う。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / BasketballDunk / class ID 9

サーフィンの例

クリップの代表フレーム



正解はサーフィン

Surfing

人と波の動きがあり、屋外の背景と撮影条件も変化する。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / Surfing / class ID 88

タイピングの例

クリップの代表フレーム



正解はタイピング

Typing

手元の小さな動きとキーボードを扱う。身体全体の大きな動きに限らない。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / Typing / class ID 95

スケートボードの例

クリップの代表フレーム



正解はスケートボード

SkateBoarding

人と板が移動する行動を扱う。
スポーツ以外の公式区分に整理されている。

[1] Soomro et al. (2012), Figure 2. https://arxiv.org/abs/1212.0402 / SkateBoarding / class ID 80

人と物との相互作用のカテゴリ

ApplyEyeMakeup	1	Mixing	54
ApplyLipstick	2	MoppingFloor	55
BlowDryHair	13	Nunchucks	56
BrushingTeeth	20	PizzaTossing	58
CuttingInKitchen	25	ShavingBeard	78
Hammering	35	SkateBoarding	80
HulaHoop	43	SoccerJuggling	84
JugglingBalls	46	Typing	95
JumpRope	48	WritingOnBoard	100
Knitting	50	YoYo	101

[1] 配布 classInd.txt の全 101 カテゴリ。右側はクラス ID. https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 5 つの型は原著 Figure 2 に基づく . https://arxiv.org/abs/1212.0402

身体の動きのカテゴリ

BabyCrawling	4	PushUps	72
BlowingCandles	14	RockClimbingIndoor	74
BodyWeightSquats	15	RopeClimbing	75
HandstandPushups	37	Swing	89
HandstandWalking	38	TaiChi	91
JumpingJack	47	TrampolineJumping	94
Lunges	52	WalkingWithDog	98
PullUps	70	WallPushups	99

[1] 配布 classInd.txt の全 101 カテゴリ。右側はクラス ID. https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 5 つの型は原著 Figure 2 に基づく . https://arxiv.org/abs/1212.0402

人と人との相互作用のカテゴリ

BandMarching 6
Haircut 34
HeadMassage 39
MilitaryParade 53
SalsaSpin 77

[1] 配布 classInd.txt の全 101 カテゴリ。右側はクラス ID. https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 5 つの型は原著 Figure 2 に基づく . https://arxiv.org/abs/1212.0402

楽器の演奏のカテゴリ

Drumming	27	PlayingGuitar	63
PlayingCello	59	PlayingPiano	64
PlayingDaf	60	PlayingSitar	65
PlayingDhol	61	PlayingTabla	66
PlayingFlute	62	PlayingViolin	67

[1] 配布 classInd.txt の全 101 カテゴリ。右側はクラス ID. https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 5 つの型は原著 Figure 2 に基づく . https://arxiv.org/abs/1212.0402

スポーツのカテゴリ 1/3

Archery	3	BoxingPunchingBag	17
BalanceBeam	5	BoxingSpeedBag	18
BaseballPitch	7	BreastStroke	19
Basketball	8	CleanAndJerk	21
BasketballDunk	9	CliffDiving	22
BenchPress	10	CricketBowling	23
Biking	11	CricketShot	24
Billiards	12	Diving	26
Bowling	16	Fencing	28

[1] 配布 classInd.txt の全 101 カテゴリ。右側はクラス ID. https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 5 つの型は原著 Figure 2 に基づく . https://arxiv.org/abs/1212.0402

スポーツのカテゴリ 2/3

FieldHockeyPenalty	29	HorseRiding	42
FloorGymnastics	30	IceDancing	44
FrisbeeCatch	31	JavelinThrow	45
FrontCrawl	32	Kayaking	49
GolfSwing	33	LongJump	51
HammerThrow	36	ParallelBars	57
HighJump	40	PoleVault	68
HorseRace	41	PommelHorse	69

[1] 配布 classInd.txt の全 101 カテゴリ。右側はクラス ID. https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 5 つの型は原著 Figure 2 に基づく . https://arxiv.org/abs/1212.0402

スポーツのカテゴリ 3/3

Punch	71	StillRings	86
Rafting	73	SumoWrestling	87
Rowing	76	Surfing	88
Shotput	79	TableTennisShot	90
Skiing	81	TennisSwing	92
Skijet	82	ThrowDiscus	93
SkyDiving	83	UnevenBars	96
SoccerPenalty	85	VolleyballSpiking	97

[1] 配布 classInd.txt の全 101 カテゴリ。右側はクラス ID. https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 5 つの型は原著 Figure 2 に基づく . https://arxiv.org/abs/1212.0402

カテゴリ当たりの本数の記述統計

対象 [1]	平均	SD	中央値	最小	最大
101 カテゴリ	131.9	18.2	131	100	167

25% 点は 117 本、 75% 点は 145 本、 95% 点は 163 本。

[1] 13,320 クリップをカテゴリごとに 1 回集計。 SD は母標準偏差 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

最少側と最多のカテゴリの例

バイオリンの演奏



PlayingViolin は 100 クリップ

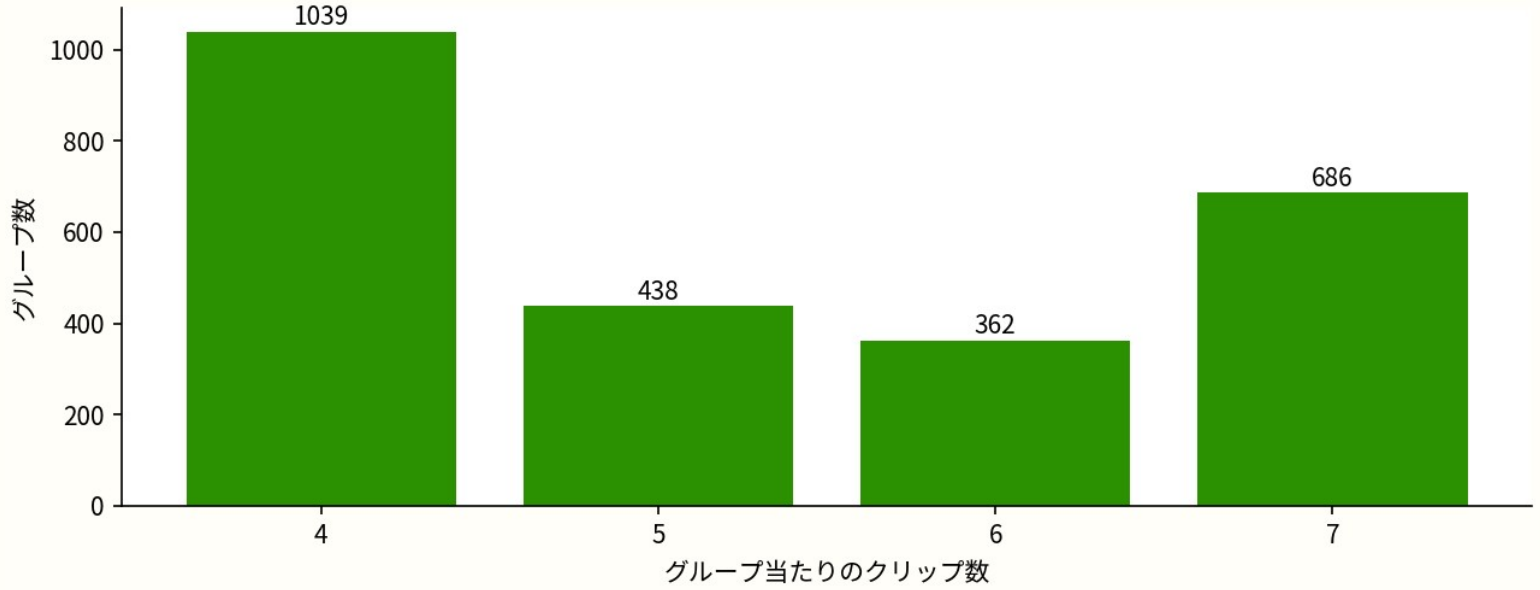
クリケットの打撃



CricketShot は 167 クリップ

[1] カテゴリの全件集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 代表フレームは原著 Figure 2. https://arxiv.org/abs/1212.0402 / PlayingViolin ・ CricketShot

4 クリップのグループが最も多い



[1] カテゴリとグループ番号の組を単位に、全 2,525 グループを集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

3 分割ではテストにするグループが異なる

分割 [1]	テスト用グループ
split 1	g01 〜 g07
split 2	g08 〜 g14
split 3	g15 〜 g21

それ以外の 18 グループを学習用に使う。各分割で学習とテストのグループは重ならない。

[1] 全 101 カテゴリの分割リストを照合 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

動画単位の正解率を計算する例

正解カテゴリ	予測カテゴリ	得点
PlayingViolin	PlayingViolin	1
PlayingGuitar	PlayingGuitar	1
CricketShot	CricketBowling	0

3 動画中 2 動画が正解なので、正解率は 2÷3×100 ＝ 66.7% となる。

原著では行動の型によって成績が異なった

行動の型 [1]	正解率
人と物との相互作用	38.52%
身体の動き	36.26%
人と人との相互作用	44.14%
楽器の演奏	37.42%
スポーツ	50.54%

[1] Soomro et al. (2012), § 3. 25 グループの交差検証 . https://arxiv.org/abs/1212.0402

近年はゼロショット評価にも用いられる

手法 [1]	Top-1 正解率
CLIP	68.9%
TVTSv2	78.0%
InternVideo2clip-1B	88.8%
InternVideo2clip-6B	89.5%

UCF101 で微調整せず、行動名と映像を照合する。事前学習・入力フレーム数は手法で異なる。

[1] Wang et al. (2024), Table 5. https://arxiv.org/abs/2403.15377

配布リストからカテゴリ別の本数を集計する

```
from pathlib import Path
from collections import Counter

root = Path("ucfTrainTestlist")
train = (root / "trainlist01.txt").read_text().splitlines()
test = (root / "testlist01.txt").read_text().splitlines()
clips = {line.split()[0] for line in train + test}
counts = Counter(path.split("/")[0] for path in clips)
print(len(clips), len(counts))
for label, n in sorted(counts.items()):
    print(label, n)
```

[1] https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

動画と分割リストのアーカイブを取得する

```
curl -L --fail -O \
  https://www.crcv.ucf.edu/data/UCF101/UCF101.rar
curl -L --fail -O \
  https://www.crcv.ucf.edu/data/UCF101/UCF101TrainTestSplits-RecognitionTask.zip

unrar x UCF101.rar
unzip UCF101TrainTestSplits-RecognitionTask.zip
```

[1] 公式配布元 . https://www.crcv.ucf.edu/data/UCF101.php
[2] 配布 URL は MMAction2 の取得手順に基づく . https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

UCF101 とモデル評価の参考文献

Soomro et al. (2012). UCF101. CRCV-TR-12-01.
https://arxiv.org/abs/1212.0402

Carreira & Zisserman (2017). I3D. CVPR.
https://arxiv.org/abs/1705.07750

Tong et al. (2022). VideoMAE. NeurIPS.
https://arxiv.org/abs/2203.12602

Wang et al. (2024). InternVideo2.
https://arxiv.org/abs/2403.15377

周辺データと配布物の参考文献

Kay et al. (2017). The Kinetics Human Action Video Dataset.
https://arxiv.org/abs/1705.06950

Goyal et al. (2017). Something-Something. ICCV.
https://arxiv.org/abs/1706.04261

UCF101 の配布リスト（ TSN 公開実装）
https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

MMAction2 の UCF101 手順
https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

I3D の公開入力例
https://github.com/google-deepmind/kinetics-i3d