# 動画の行動認識用データセット

# UCF101

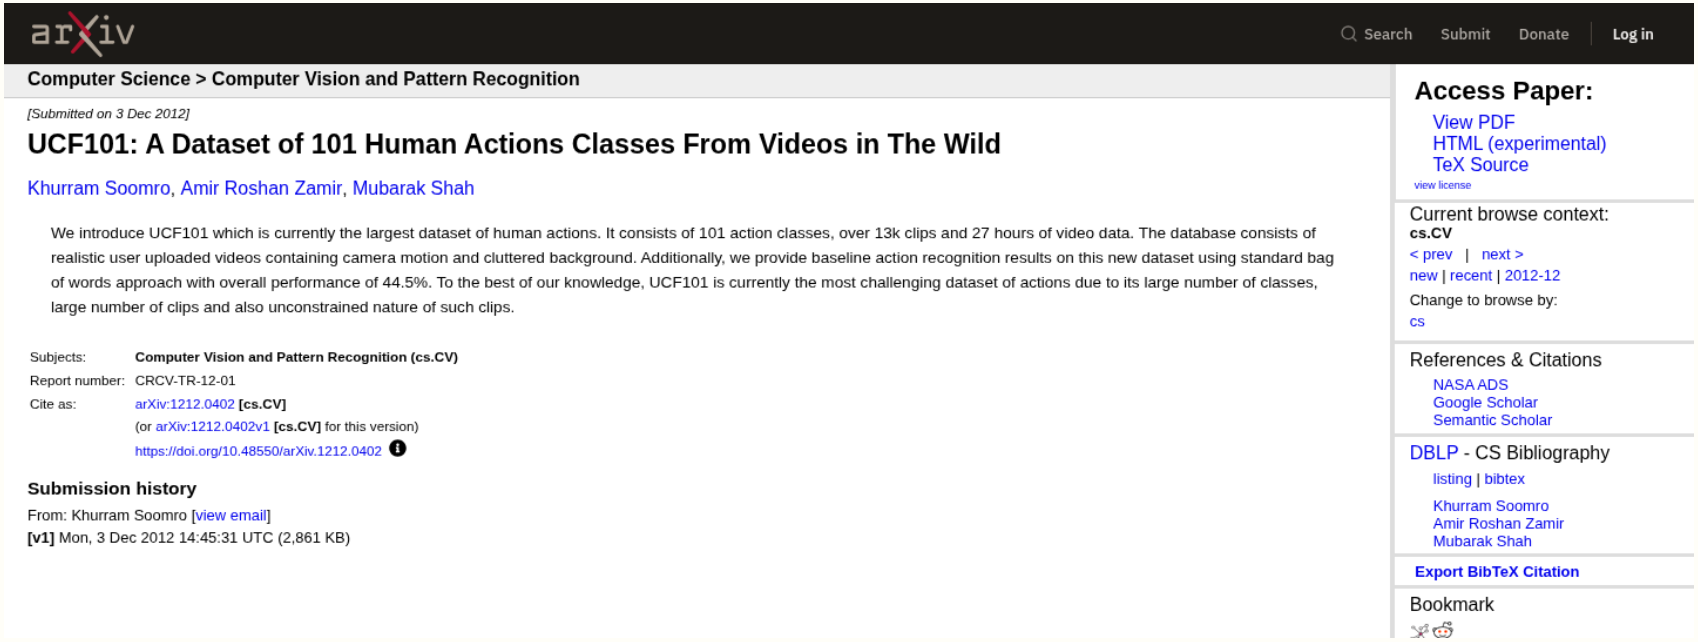
UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild

sasakiy84

1. UCF101 の行動分類と動画の構造
2. 動画の収集方法とカテゴリ別の規模
3. 行動認識の評価指標とモデル性能
4. UCF101 の利用動向と後続データ
5. 配布動画と評価分割の入手方法

# 1 UCF101 の行動分類と動画の構造

# UCF101 の原著の公開ページ



arXiv Search Submit Donate Log in

Computer Science > Computer Vision and Pattern Recognition

[Submitted on 3 Dec 2012]

## UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild

Khurram Soomro, Amir Roshan Zamir, Mubarak Shah

We introduce UCF101 which is currently the largest dataset of human actions. It consists of 101 action classes, over 13k clips and 27 hours of video data. The database consists of realistic user uploaded videos containing camera motion and cluttered background. Additionally, we provide baseline action recognition results on this new dataset using standard bag of words approach with overall performance of 44.5%. To the best of our knowledge, UCF101 is currently the most challenging dataset of actions due to its large number of classes, large number of clips and also unconstrained nature of such clips.

Subjects: **Computer Vision and Pattern Recognition (cs.CV)**
Report number: CRCV-TR-12-01
Cite as: arXiv:1212.0402 **[cs.CV]**
(or arXiv:1212.0402v1 **[cs.CV]** for this version)
https://doi.org/10.48550/arXiv.1212.0402

**Submission history**
From: Khurram Soomro [view email]
**[v1]** Mon, 3 Dec 2012 14:45:31 UTC (2,861 KB)

**Access Paper:**
View PDF
HTML (experimental)
TeX Source
view license

Current browse context:
**cs.CV**
< prev | next >
new | recent | 2012-12
Change to browse by:
cs

References & Citations
NASA ADS
Google Scholar
Semantic Scholar

DBLP - CS Bibliography
listing | bibtex
Khurram Soomro
Amir Roshan Zamir
Mubarak Shah

**Export BibTeX Citation**

Bookmark

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. https://arxiv.org/abs/1212.0402

# 動画クリップを 101 種類の行動へ分類する

- 動画の行動認識には、クリップ全体の行動を分類する課題と、行動が起こる時間範囲を特定する課題がある。
- UCF101 が扱うのは前者である。入力は短い動画クリップ、正解はその動画が表す 1 つの行動カテゴリとなる。
- スポーツ・楽器演奏・日常動作を含む 13,320 クリップを、動画共有サービス YouTube から集め、 2012 年に公開した。

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. https://arxiv.org/abs/1212.0402

# 101 種類の行動は 5 つの型に整理されている

| 行動の型 [1] | カテゴリ数 | クリップ数 [2] |
|---|---|---|
| 人と物との相互作用 | 20 | 2619 |
| 身体の動き | 16 | 1910 |
| 人と人との相互作用 | 5 | 690 |
| 楽器の演奏 | 10 | 1428 |
| スポーツ | 50 | 6673 |

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. Figure 2
https://arxiv.org/abs/1212.0402
[2] https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

# クリケットの打撃（ CricketShot ）の例




0.00 秒




1.56 秒




3.12 秒

[1] https://github.com/google-deepmind/kinetics-i3d v_CricketShot_g04_c01.avi

# 行動の型から動画クリップまでの包含関係

| 単位 [1] | 何を表すか | 具体例 |
|---|---|---|
| 型 | カテゴリの大区分。全 5 種類 | スポーツ |
| カテゴリ | 全 101 種類の行動ラベル | CricketShot |
| グループ | 撮影場所や人物などが似た動画のまとまり。各カテゴリに 25 組 | CricketShot の g04 |
| クリップ | 1 本の動画。各グループに 4 〜 7 本 | g04 の c01 |

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. §2. https://arxiv.org/abs/1212.0402

# 目元の化粧（ ApplyEyeMakeup ）の例



0.04 秒　3.28 秒　6.52 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification　v_ApplyEyeMakeup_g01_c01.avi

# 逆立ち歩き（ HandstandWalking ）の例



0.00 秒　2.16 秒　4.32 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification　v_HandstandWalking_g01_c01.avi

# 2 動画の収集方法とカテゴリ別の規模

# 先行データより行動と撮影条件を広げた

- KTH （2004）は、統制された撮影条件で 6 行動を扱う先行データである。 HMDB51 （2011）は、映画などの映像で 51 行動を扱った。
- また、先行する UCF50 は YouTube 映像の 50 行動を収録した。 UCF101 は 101 行動へ、カテゴリ数を約 2 倍に広げた。
- UCF101 は、多種類の行動をカメラの動き・遮蔽・混雑した背景などの変動を含む映像で評価する。

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. https://arxiv.org/abs/1212.0402

# 自然な映像の多様な行動を評価する

- 撮影条件を統制した小規模なデータだけでは、日常の映像に見られる変動を十分に扱えなかった。
- そこで、 YouTube から行動カテゴリに合う動画を集め、見た目や撮影条件の変化を含む認識用データを作った。
- カテゴリの選定、不要動画の除去、形式の統一、撮影条件が似たクリップのグループ化を行った。

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. https://arxiv.org/abs/1212.0402

# 収集した動画を選別して形式を統一する

- YouTube から動画をダウンロードし、収集する行動カテゴリに該当しない動画を人手で除去した。
- 映像は 320×240 画素、 1 秒当たり 25 フレーム（ 25 fps ）へ統一し、動画ファイル形式 AVI でカテゴリ別に配布した。
- 追加した 51 行動の動画では、音声も保持した。

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. https://arxiv.org/abs/1212.0402

# 撮影条件の似たクリップをグループにまとめる

- 各行動カテゴリには 25 グループがある [1]。
- 1 グループには、撮影場所や映る人物、カメラの視点などが似た 4 〜 7 クリップをまとめる。
- ファイル名の g04 はグループ番号、 c01 はグループ内のクリップ番号。
- 近い映像が学習とテストの両方に入ることを避けるため、グループ単位で分ける。

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. §2
https://arxiv.org/abs/1212.0402

# 平均 7.21 秒の 13,320 クリップを収録する

- 101 カテゴリ、 13,320 クリップを収録する [1] 。
- 平均クリップ長は 7.21 秒、総時間は 1,600 分。映像は 25 fps 、 320×240 ピクセル。
- 動画をまとめた圧縮 ZIP は約 7 GB [3] 。
- 25 グループ ×101 カテゴリで計 2,525 グループ [2] 。
- 1 本の動画に 1 つの行動ラベルが付く。

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. Table 1 https://arxiv.org/abs/1212.0402

[2] グループ数は分割リストの集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

[3] ZIP は 6,960,400,115 bytes. https://github.com/tensorflow/datasets/blob/master/tensorflow_datasets/url_checksums/ucf101.txt

# バイオリンの演奏（ PlayingViolin ）は 100 本 [2]



0.00 秒



3.72 秒



7.40 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_PlayingViolin_g01_c01.avi
[2] カテゴリ別集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

# クリケットの打撃（ CricketShot ）は 167 本 [2]




0.00 秒



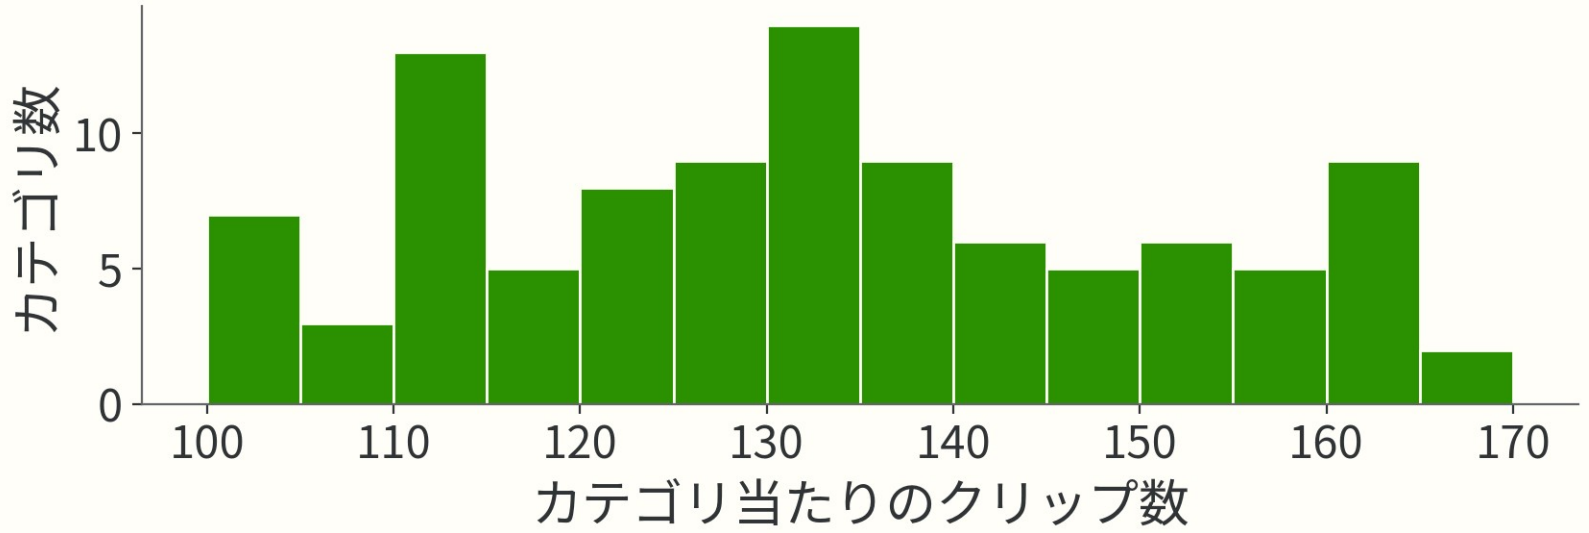

1.68 秒




3.32 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_CricketShot_g01_c01.avi
[2] カテゴリ別集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

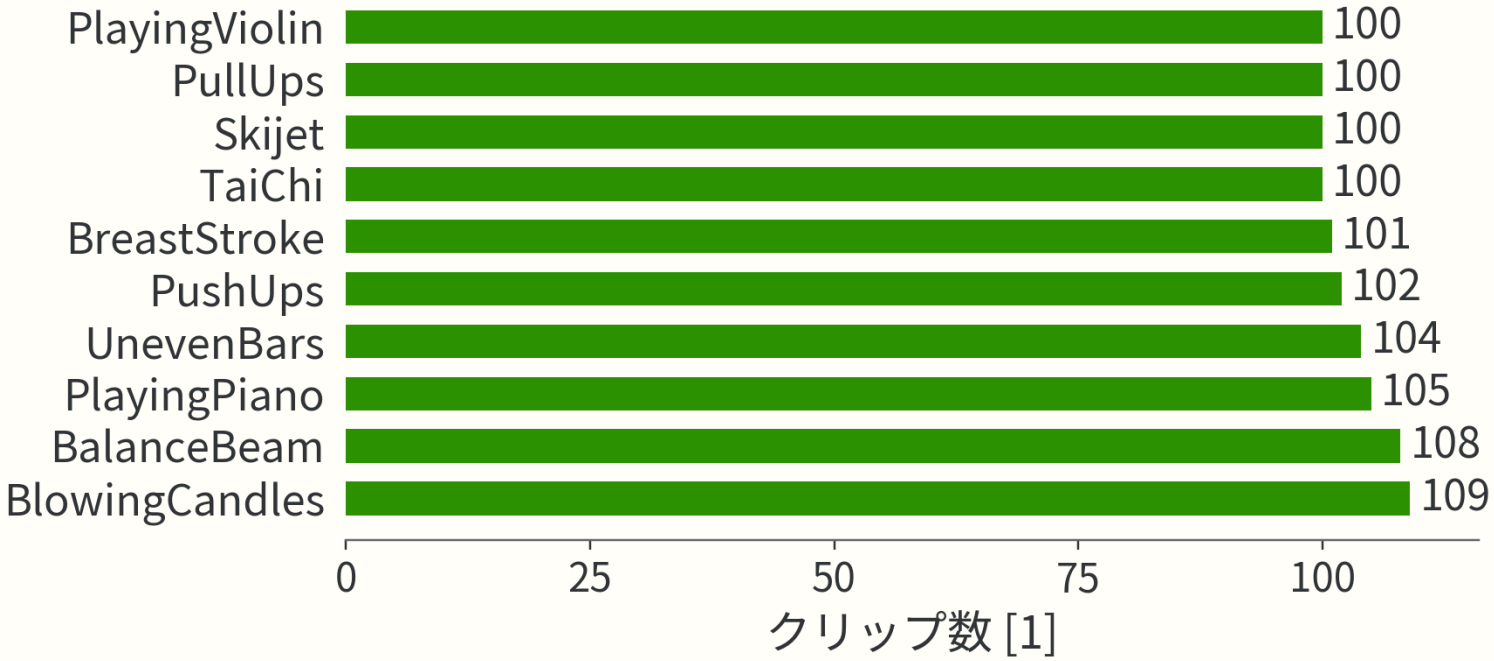
# カテゴリ当たりのクリップ数の中央値は 131 本




全 101 カテゴリ。最少は 100 本、最多は 167 本 [1]。

[1] 13,320 クリップをカテゴリ別に集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

# 110 本未満のカテゴリは 10 種類




[1] 13,320 クリップをカテゴリ別に集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

# 3 分割ではテストにするグループが異なる

| 分割 [1] | テスト用グループ |
|---|---|
| split 1 | g01 〜 g07 |
| split 2 | g08 〜 g14 |
| split 3 | g15 〜 g21 |

それ以外の 18 グループを学習用に使う。各分割で学習とテストのグループは重ならない。

[1] 全 101 カテゴリの分割リストを照合 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

# 3 つの分割で学習用とテスト用を入れ替える

| 分割 [1] | 学習用 | テスト用 |
|---|---|---|
| split 1 | 9,537 | 3,783 |
| split 2 | 9,586 | 3,734 |
| split 3 | 9,624 | 3,696 |

各分割の合計は 13,320 。各カテゴリで同じグループが学習とテストへまたがらない。

[1] 配布分割リストの集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

# 3 行動認識の評価指標とモデル性能

# 動画単位の正解率を計算する例

| 正解カテゴリ | 予測カテゴリ | 得点 |
|---|---|---|
| PlayingViolin | PlayingViolin | 1 |
| PlayingGuitar | PlayingGuitar | 1 |
| CricketShot | CricketBowling | 0 |

3 動画中 2 動画が正解なので、正解率は 2÷3×100 ＝ 66.7% となる。

# 動画の正解率を分割ごとに求めて平均する

- 各動画の最上位予測が正解カテゴリと一致すれば 1 、不一致なら 0 とする。全動画の得点を平均し、百分率で正解率を報告する。
- 公式の 3 分割では、それぞれ別の学習用で学習し、対応するテスト用で評価する。
- 3 分割の平均は、分割ごとの正解率を平均した値である。 1 分割の結果や、別の交差検証による結果と区別する。

[1] Carreira et al. (2017). CVPR. Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset.
https://arxiv.org/abs/1705.07750

# 2012 年の原著の正解率は 44.5% だった

- 原著は局所的な動きと見た目を特徴量にして、映像を特徴の出現頻度で表した [1]。
- 分類にはサポートベクトルマシンを使った。
- 25 グループのうち 1 グループをテストにし、 25 回入れ替える交差検証を行った。
- 平均正解率は 44.5% 。後の 3 分割評価とは評価条件が異なる。

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. §3
https://arxiv.org/abs/1212.0402

# 事前学習したモデルを転用して評価する

- 事前学習は、別の画像や映像から特徴の取り出し方を先に学ぶ工程である。微調整では、 UCF101 の学習用でそのモデルを更新する。
- 線形分類では特徴モデルを固定し、行動を選ぶ分類器だけを UCF101 で学習する。
- ゼロショットでは UCF101 による学習を行わず、映像と行動名の対応などから予測する。これらは学習に使う情報が異なる評価方式である。

[1] Carreira et al. (2017). CVPR. Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset. https://arxiv.org/abs/1705.07750

[2] Wang et al. (2024). arXiv:2403.15377. InternVideo2: Scaling Foundation Models for Multimodal Video Understanding. https://arxiv.org/abs/2403.15377

# I3D は見た目とフレーム間の動きを利用する

- I3D （ 2017 ）は、画像の畳み込みを時間方向へ広げた動画認識モデルである。
- RGB 画像は各フレームの色と見た目を表す。光学フローは、連続するフレームの間で画素がどの方向へ動いたかを表す。
- 大規模な 400 行動の動画データ Kinetics-400 と、画像分類用 ImageNet で事前学習し、 UCF101 で微調整した結果が報告されている。

[1] Carreira et al. (2017). CVPR. Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset.
https://arxiv.org/abs/1705.07750

# 2017 年の I3D は 2 種類の入力を組み合わせた

| I3D の入力 [1] | Top-1 正解率 |
|---|---|
| RGB 画像 | 95.6% |
| フレーム間の動きを表す光学フロー | 96.7% |
| RGB 画像と光学フロー | 98.0% |

ImageNet と Kinetics で事前学習し、 UCF101 で微調整した。公式 3 分割の平均。

[1] Carreira et al. (2017). CVPR. Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset. Table 5
https://arxiv.org/abs/1705.07750

# VideoMAE は隠した映像領域の復元で学習する

- VideoMAE （2022）は、動画の一部を隠し、見えている部分から復元する自己教師あり事前学習の手法である。
- ViT は、画像や映像を小さな領域に分け、その間の関係を Transformer で扱うモデルである。表の ViT-B は基本サイズを表す。
- 同じモデルでも、 UCF101 だけで事前学習する場合と、大規模な Kinetics-400 で学ぶ場合とで、微調整後の正解率が変わる。

[1] Tong et al. (2022). Advances in Neural Information Processing Systems, 35. VideoMAE: Masked Autoencoders are Data-Efficient Learners for Self-Supervised Video Pre-Training.
https://arxiv.org/abs/2203.12602

# VideoMAE （ 2022 ）の事前学習データ別の結果

| ViT-B の事前学習データ [1] | Top-1 正解率 |
|---|---|
| UCF101 のみ | 91.3% |
| Kinetics-400 | 96.1% |

どちらも UCF101 で微調整した報告値。映像の隠した部分を復元する VideoMAE を使う。

[1] Tong et al. (2022). Advances in Neural Information Processing Systems, 35. VideoMAE: Masked Autoencoders are Data-Efficient Learners for Self-Supervised Video Pre-Training. Table 13
https://arxiv.org/abs/2203.12602

# 2024 年には映像特徴の評価にも使われた

| 固定する特徴モデル [1] | Top-1 正解率 |
|---|---|
| DINOv2-g | 91.2% |
| TVTSv2-H | 91.8% |
| InternVideo2 第 2 段階・ 6B | 97.3% |

特徴を固定し、 UCF101 の学習用で線形分類器を学習する。特徴モデルの事前学習条件は異なる。

[1] Wang et al. (2024). arXiv:2403.15377. InternVideo2: Scaling Foundation Models for Multimodal Video Understanding. Table 4
https://arxiv.org/abs/2403.15377

# 高い正解率だけで時間順序の理解は示せない

- 映像には、行動の動きだけでなく物体や背景も写る。
- 背景や道具だけでも、行動カテゴリの手がかりになりうる。
- 2024 年の比較では画像特徴モデル DINOv2 を使う方式も 91.2% だった [1]。
- 行動分類の正解率と、動作の順序や細かな変化を理解できるかを分けて評価する。

[1] Wang et al. (2024). arXiv:2403.15377. InternVideo2: Scaling Foundation Models for Multimodal Video Understanding. Table 4
https://arxiv.org/abs/2403.15377

# 4 UCF101 の利用動向と後続データ

# Kinetics は行動数と動画数を拡大した

- Kinetics （2017）は、 YouTube から多様な人物・撮影条件の行動クリップを集めた大規模データである。
- 最初の 400 行動版は 306,245 クリップを扱い、 UCF101 の約 4 倍の行動数、約 23 倍のクリップ数となる。
- 大規模な映像から事前学習し、 UCF101 へ微調整する利用を支えた。

[1] Kay et al. (2017). arXiv:1705.06950. The Kinetics Human Action Video Dataset.
https://arxiv.org/abs/1705.06950

# 手と物の動きを扱う Something-Something

- Something-Something （2017）は、物を押す・持ち上げるなど、人と物の相互作用を 174 種類に分けた動画データである。
- UCF101 のスポーツや日常動作に対し、手と物の関係や移動方向を細かく区別する。
- 物体や背景が似ていても動きの違いで答えが変わるため、時間方向の変化を捉える評価へ対象を広げる。

[1] Goyal et al. (2017). ICCV. The “something something” video database for learning and evaluating visual common sense.
https://arxiv.org/abs/1706.04261

# UCF101 の転移学習・特徴評価への利用

- 2012 年の公開後、行動分類から事前学習モデルの転移評価へ用途が広がった [1]。
- InternVideo2 （2024）は、固定特徴の線形分類とゼロショットの評価に用いた [1]。
- 2026-10-15 の確認時点でも、 MMAction2 は取得・前処理・評価手順を公開している [2]。

[1] Carreira et al. (2017). CVPR. Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset. https://arxiv.org/abs/1705.07750

Wang et al. (2024). arXiv:2403.15377. InternVideo2: Scaling Foundation Models for Multimodal Video Understanding. https://arxiv.org/abs/2403.15377

[2] MMAction2 contributors (n.d.). MMAction2 documentation. 参照 2026-10-15. Preparing UCF-101. https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

# 5 配布動画と評価分割の入手方法

# 動画本体と 3 分割のリストを取得する

- 公式配布元から、動画のアーカイブと学習・テスト分割の ZIP を取得する [1]。
- 展開したカテゴリ別フォルダと分割リストを対応させる。
- データを扱う MMAction2 などの手順で、フレーム抽出と入力用リストを準備できる [2]。
- 利用条件は公式配布元で確認する。

[1] MMAction2 contributors (n.d.). MMAction2 documentation. 参照 2026-10-15. Preparing UCF-101. https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

# カテゴリ別の動画を分割リストと対応付ける

- 配布動画は行動カテゴリごとのフォルダに置かれ、ファイル名にはカテゴリ・グループ番号・クリップ番号が入る。
- 学習用とテスト用のリストは、そのフォルダ名とファイル名で動画を指定する。同じカテゴリ内でも、グループ番号によって役割が変わる。
- 動画認識用ライブラリ MMAction2 の手順では、動画からフレームを抽出し、分割リストに沿って学習・評価用ファイルを準備する。

[1] MMAction2 contributors (n.d.). MMAction2 documentation. 参照 2026-10-15. Preparing UCF-101. https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

# UCF101 は動画モデルの行動認識と転移を評価する

- 101 種類の行動を扱う 13,320 クリップのデータセット。
- 自然な YouTube 映像で、多様な行動を評価するため 2012 年に作られた。
- 撮影場所・人物・カメラの視点が似た動画のグループを単位に分割する。
- 登場時の分類評価から、事前学習モデルの転移・特徴評価にも用途が広がった。
- 正解率を比較するときは、分割・事前学習・評価方式をそろえる。

# Appendix

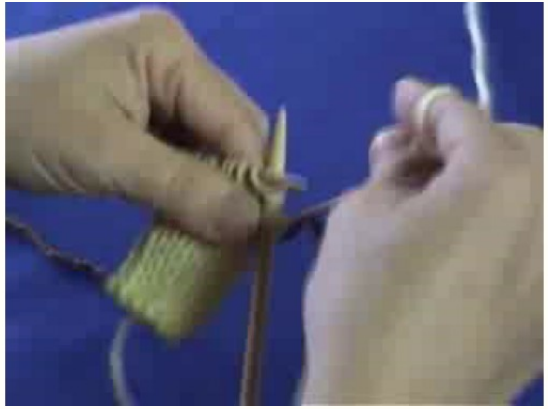
1.開発者の研究と発表先
2.動画と行動ラベルの追加例
3.5 つの型に属する全 101 行動カテゴリ
4.行動の型・グループごとの動画数
5.行動の型別・ゼロショットの評価結果
6.動画の取得と本数の集計コード
7.動画の行動認識に関連する文献

# UCF101 の開発者と 2012 年の技術報告

- CRCV-TR-12-01 としてまとめ、 2012-12-03 に arXiv へ投稿した [1]。
- 第一著者の Khurram Soomro は、 UCF101 を構築した行動認識研究者。
- 最終著者の Mubarak Shah は、動画の行動認識を研究し、 UCF50 や UCF Sports にも取り組んだ。
- 当時の著者の所属は、セントラルフロリダ大学のコンピュータビジョン研究センター。

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. https://arxiv.org/abs/1212.0402

# 編み物（ Knitting ）の例



0.00 秒



5.32 秒



10.60 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_Knitting_g01_c01.avi

# ヨーヨー（ YoYo ）の例




0.00 秒




3.72 秒




7.44 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_YoYo_g01_c01.avi

# 赤ちゃんのはいはい（ BabyCrawling ）の例



0.00 秒



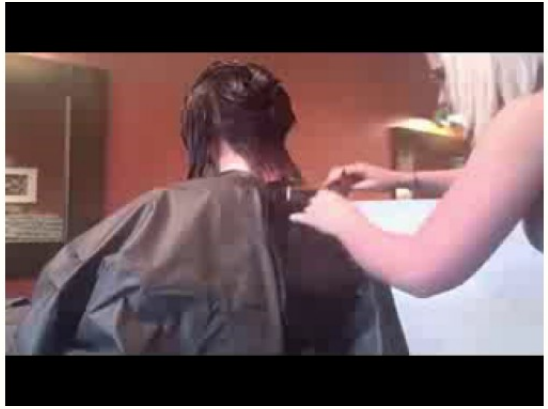
3.28 秒



6.56 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_BabyCrawling_g01_c01.avi

# 散髪（ Haircut ）の例



0.00 秒



2.68 秒



5.36 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_Haircut_g01_c01.avi

# ギターの演奏（ PlayingGuitar ）の例



0.00 秒



5.00 秒



9.96 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_PlayingGuitar_g01_c01.avi

# ビリヤード（ Billiards ）の例




0.00 秒




5.48 秒




10.92 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_Billiards_g01_c01.avi

# バスケットボールのダンク（ BasketballDunk ）



0.00 秒



1.20 秒



2.40 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_BasketballDunk_g01_c01.avi

# サーフィン（ Surfing ）の例



0.00 秒



5.08 秒



10.12 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_Surfing_g01_c01.avi

# タイピング（ Typing ）の例



0.00 秒



2.52 秒



5.04 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_Typing_g01_c01.avi

# スケートボード（SkateBoarding）の例



0.00 秒



4.04 秒



8.04 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_SkateBoarding_g01_c01.avi

# 人と物との相互作用という型の全 20 カテゴリ

ApplyEyeMakeup
ApplyLipstick
BlowDryHair
BrushingTeeth
CuttingInKitchen
Hammering
HulaHoop
JugglingBalls
JumpRope
Knitting
Mixing
MoppingFloor
Nunchucks
PizzaTossing
ShavingBeard
SkateBoarding
SoccerJuggling
Typing
WritingOnBoard
YoYo

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. Figure 2
https://arxiv.org/abs/1212.0402

# 身体の動きという型の全 16 カテゴリ

BabyCrawling
BlowingCandles
BodyWeightSquats
HandstandPushups
HandstandWalking
JumpingJack
Lunges
PullUps
PushUps
RockClimbingIndoor
RopeClimbing
Swing
TaiChi
TrampolineJumping
WalkingWithDog
WallPushups

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. Figure 2
https://arxiv.org/abs/1212.0402

# 人と人との相互作用という型の全 5 カテゴリ

BandMarching
Haircut
HeadMassage
MilitaryParade
SalsaSpin

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. Figure 2
https://arxiv.org/abs/1212.0402

# 楽器の演奏という型の全 10 カテゴリ

Drumming
PlayingCello
PlayingDaf
PlayingDhol
PlayingFlute
PlayingGuitar
PlayingPiano
PlayingSitar
PlayingTabla
PlayingViolin

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. Figure 2
https://arxiv.org/abs/1212.0402

# スポーツという型の全 50 カテゴリ 1/3

Archery
BalanceBeam
BaseballPitch
Basketball
BasketballDunk
BenchPress
Biking
Billiards
Bowling
BoxingPunchingBag
BoxingSpeedBag
BreastStroke
CleanAndJerk
CliffDiving
CricketBowling
CricketShot
Diving
Fencing

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. Figure 2
https://arxiv.org/abs/1212.0402

# スポーツという型の全 50 カテゴリ 2/3

FieldHockeyPenalty
FloorGymnastics
FrisbeeCatch
FrontCrawl
GolfSwing
HammerThrow
HighJump
HorseRace
HorseRiding
IceDancing
JavelinThrow
Kayaking
LongJump
ParallelBars
PoleVault
PommelHorse

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. Figure 2
https://arxiv.org/abs/1212.0402

# スポーツという型の全 50 カテゴリ 3/3

Punch
Rafting
Rowing
Shotput
Skiing
Skijet
SkyDiving
SoccerPenalty
StillRings
SumoWrestling
Surfing
TableTennisShot
TennisSwing
ThrowDiscus
UnevenBars
VolleyballSpiking

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. Figure 2
https://arxiv.org/abs/1212.0402

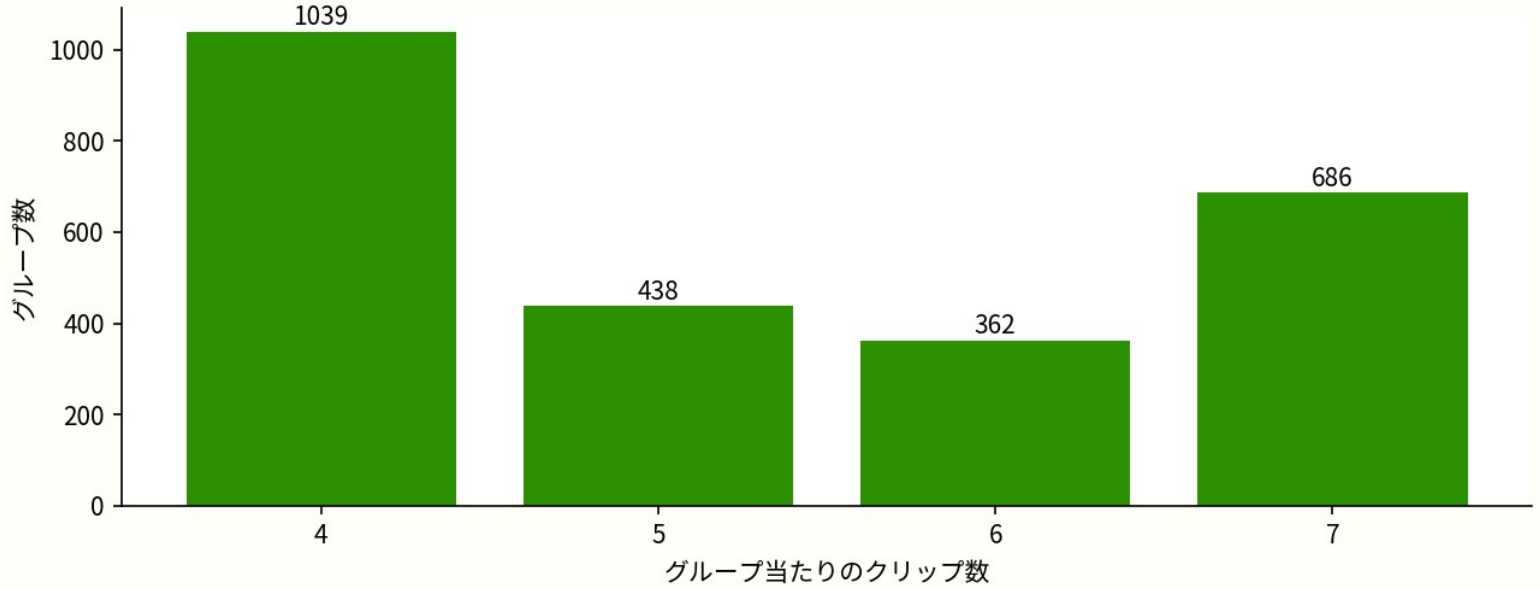
# 型ごとにカテゴリ数とクリップ数を比較する

| 型 [1] | カテゴリ数 | 合計本数 | 最少 | 平均 | 最多 |
|---|---|---|---|---|---|
| 人と物との相互作用 | 20 | 2,619 | 110 | 131.0 | 161 |
| 身体の動き | 16 | 1,910 | 100 | 119.4 | 144 |
| 人と人との相互作用 | 5 | 690 | 125 | 138.0 | 155 |
| 楽器の演奏 | 10 | 1,428 | 100 | 142.8 | 164 |
| スポーツ | 50 | 6,673 | 100 | 133.5 | 167 |
| 全 101 カテゴリ | 101 | 13,320 | 100 | 131.9 | 167 |

カテゴリ当たりの本数は中央値 131 本、母標準偏差 18.2 本。 25% 点は 117 本、75% 点は 145 本、 95% 点は 163 本。

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. Figure 2
https://arxiv.org/abs/1212.0402 https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

# 4 クリップのグループが最も多い




[1] カテゴリとグループ番号の組を単位に、全 2,525 グループを集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

# 原著における行動の型別の正解率

| 行動の型 [1] | 正解率 |
|---|---|
| 人と物との相互作用 | 38.52% |
| 身体の動き | 36.26% |
| 人と人との相互作用 | 44.14% |
| 楽器の演奏 | 37.42% |
| スポーツ | 50.54% |

[1] Soomro et al. (2012). CRCV-TR-12-01; arXiv:1212.0402. UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild. §3. https://arxiv.org/abs/1212.0402

# 2024 年の報告におけるゼロショット評価

| 手法 [1] | Top-1 正解率 |
|---|---|
| CLIP | 68.9% |
| TVTSv2 | 78.0% |
| InternVideo2clip-1B | 88.8% |
| InternVideo2clip-6B | 89.5% |

UCF101 で微調整せず、行動名と映像を照合する。事前学習・入力フレーム数は手法で異なる。

[1] Wang et al. (2024). arXiv:2403.15377. InternVideo2: Scaling Foundation Models for Multimodal Video Understanding. Table 5
https://arxiv.org/abs/2403.15377

# 配布リストからカテゴリ別の本数を集計する

```
from pathlib import Path
from collections import Counter

root = Path("ucfTrainTestlist")
train = (root / "trainlist01.txt").read_text().splitlines()
test = (root / "testlist01.txt").read_text().splitlines()
clips = {line.split()[0] for line in train + test}
counts = Counter(path.split("/")[0] for path in clips)
print(len(clips), len(counts))
for label, n in sorted(counts.items()):
    print(label, n)
```

[1] https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

# 動画と分割リストのアーカイブを取得する

```
base=https://www.crcv.ucf.edu/data/UCF101
curl -L --fail -O "$base/UCF101.rar"
curl -L --fail -O \
  "$base/UCF101TrainTestSplits-RecognitionTask.zip"

unrar x UCF101.rar
unzip UCF101TrainTestSplits-RecognitionTask.zip
```

[1] MMAction2 contributors (n.d.). MMAction2 documentation. 参照 2026-10-15. Preparing UCF-101. https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

## UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild

Soomro, K., Zamir, A. R., & Shah, M. (2012). CRCV-TR-12-01; arXiv:1212.0402.

UCF101 の原著論文。 101 行動の収集、グループの設計、初期の行動認識評価を報告する。

https://arxiv.org/abs/1212.0402

---

## Two-Stream Convolutional Networks for Action Recognition in Videos

Simonyan, K., & Zisserman, A. (2014). Advances in Neural Information Processing Systems, 27.

Two-Stream モデルの原著論文。 RGB 画像とオプティカルフローを別々のネットワークで扱う。

https://arxiv.org/abs/1406.2199

## Temporal Segment Networks: Towards Good Practices for Deep Action Recognition

Wang, L., et al. (2016). ECCV.

TSN の原著論文。動画の複数区間からフレームを抽出し、長い時間範囲の情報を統合する。

https://arxiv.org/abs/1608.00859

---

## Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset

Carreira, J., & Zisserman, A. (2017). CVPR.

I3D の原著論文。画像の畳み込みを 3 次元へ拡張し、 Kinetics からの転移を評価する。

https://arxiv.org/abs/1705.07750

## VideoMAE: Masked Autoencoders are Data-Efficient Learners for Self-Supervised Video Pre-Training

Tong, Z., Song, Y., Wang, J., & Wang, L. (2022). Advances in Neural Information Processing Systems, 35.

VideoMAE の原著論文。高いマスク率の映像復元により、自己教師あり事前学習を行う。

https://arxiv.org/abs/2203.12602

---

## Preparing UCF-101

MMAction2 contributors (n.d.). MMAction2 documentation. 参照 2026-10-15.

MMAction2 の公式データ準備手順。 UCF101 の取得、フレーム抽出、分割リスト作成を記載する。

https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

## The Kinetics Human Action Video Dataset

Kay, W., et al. (2017). arXiv:1705.06950.

Kinetics の原著論文。 YouTube の大規模な行動クリップの収集と品質管理を報告する。

https://arxiv.org/abs/1705.06950

---

## The “something something” video database for learning and evaluating visual common sense

Goyal, R., et al. (2017). ICCV.

Something-Something の原著論文。人と物の相互作用を、時間的な関係を含む動作ラベルで扱う。

https://arxiv.org/abs/1706.04261

## Training and Test

MMAction2 contributors (n.d.). MMAction2 documentation. 参照 2026-10-15.

MMAction2 の公式実行手順。設定ファイル、チェックポイントを用いた学習・テストを記載する。

https://github.com/open-mmlab/mmaction2/blob/main/docs/en/user_guides/train_test.md