動画の行動認識用データセット

UCF101

UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild

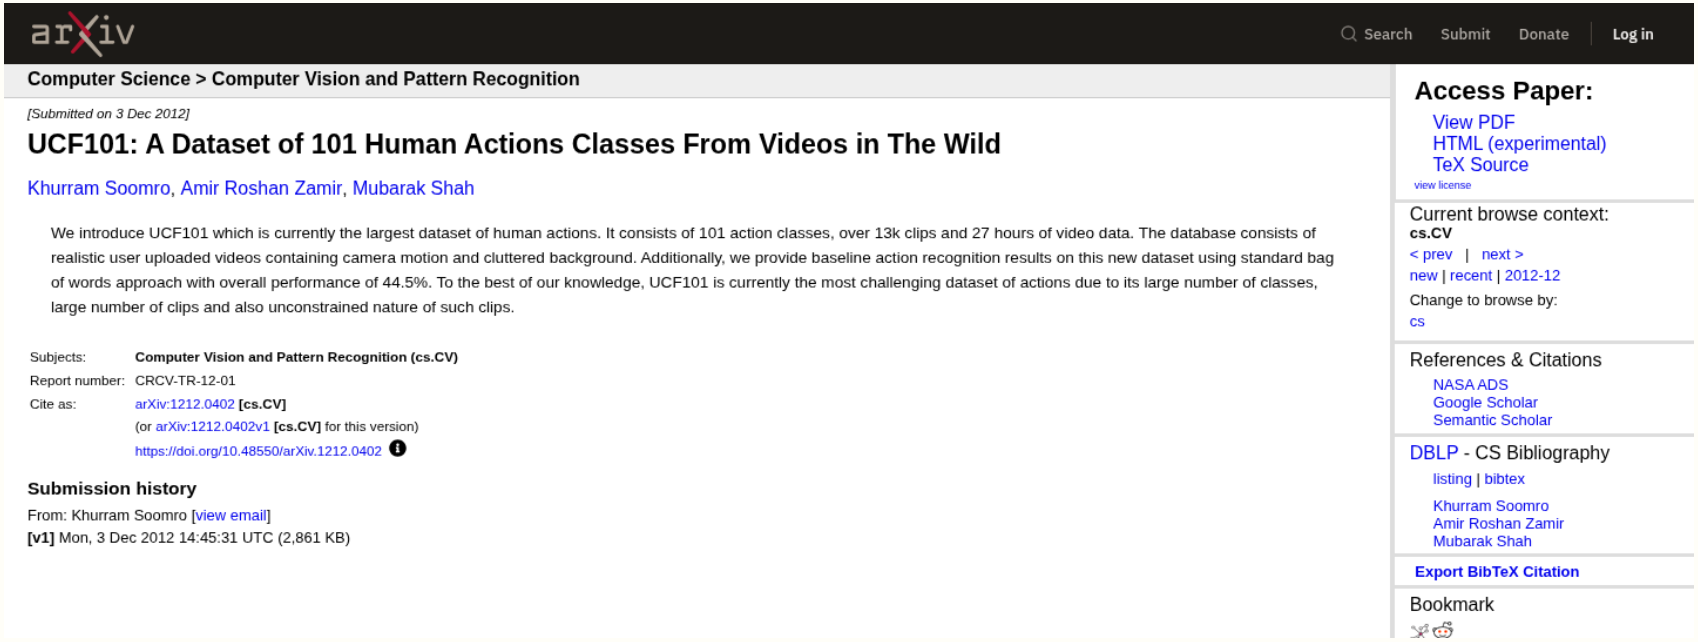
sasakiy84

本編の構成

1. 概要とタスク
2. 作成方法と規模
3. 評価とモデルの性能
4. 利用の変遷と現在
5. 入手方法とまとめ

1 概要とタスク

UCF101 の原著の公開ページ



arXiv Search Submit Donate Log in

Computer Science > Computer Vision and Pattern Recognition

[Submitted on 3 Dec 2012]

UCF101: A Dataset of 101 Human Actions Classes From Videos in The Wild

Khurram Soomro, Amir Roshan Zamir, Mubarak Shah

We introduce UCF101 which is currently the largest dataset of human actions. It consists of 101 action classes, over 13k clips and 27 hours of video data. The database consists of realistic user uploaded videos containing camera motion and cluttered background. Additionally, we provide baseline action recognition results on this new dataset using standard bag of words approach with overall performance of 44.5%. To the best of our knowledge, UCF101 is currently the most challenging dataset of actions due to its large number of classes, large number of clips and also unconstrained nature of such clips.

Subjects: **Computer Vision and Pattern Recognition (cs.CV)**
Report number: CRCV-TR-12-01
Cite as: arXiv:1212.0402 **[cs.CV]**
(or arXiv:1212.0402v1 **[cs.CV]** for this version)
https://doi.org/10.48550/arXiv.1212.0402

Submission history
From: Khurram Soomro [view email]
[v1] Mon, 3 Dec 2012 14:45:31 UTC (2,861 KB)

Access Paper:
View PDF
HTML (experimental)
TeX Source
view license

Current browse context:
cs.CV
< prev | next >
new | recent | 2012-12
Change to browse by:
cs

References & Citations
NASA ADS
Google Scholar
Semantic Scholar

DBLP - CS Bibliography
listing | bibtex
Khurram Soomro
Amir Roshan Zamir
Mubarak Shah

Export BibTeX Citation

Bookmark

[1] https://arxiv.org/abs/1212.0402

動画クリップを 101 種類の行動へ分類する

- UCF101 は動画の行動認識用データセット [1] 。
- 入力は短い動画クリップで、正解は 1 つの行動カテゴリ。
- スポーツ、楽器の演奏、日常動作などを含む。
- 2012 年に公開され、 YouTube から集めた 13,320 クリップを収録した。

[1] Soomro et al. (2012), §1–2. https://arxiv.org/abs/1212.0402

クリケットの打撃（ CricketShot ）の例



0.00 秒



1.56 秒



3.12 秒

[1] https://github.com/google-deepmind/kinetics-i3d　v_CricketShot_g04_c01.avi

目元の化粧（ ApplyEyeMakeup ）の例



0.04 秒



3.28 秒



6.52 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification　v_ApplyEyeMakeup_g01_c01.avi

逆立ち歩き（ HandstandWalking ）の例



0.00 秒



2.16 秒



4.32 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification　v_HandstandWalking_g01_c01.avi

多様な行動を自然な映像で評価するために作られた

- 当時の行動認識データはカテゴリ数が少なかった [1]。
- 統制された環境で撮影した映像では、背景や撮影条件の変動が限られた。
- そこで YouTube の映像を集め、カメラの動き、遮蔽、背景の混雑を含む行動認識を評価する。
- UCF50 の 50 行動から 101 行動へ、カテゴリ数を約 2 倍に広げた。

[1] Soomro et al. (2012), §1–2. https://arxiv.org/abs/1212.0402

2 作成方法と規模

行動カテゴリと無関係な動画を除いて収集した

- YouTube から動画をダウンロードした [1]。
- 収集する行動カテゴリに該当しない動画を、人手で除去した。
- 動画を 320×240 ピクセル・ 25 fps へ統一した。
- カテゴリごとにフォルダを分け、 AVI 形式で配布した。
- 追加した 51 行動の動画では音声も保持した。

[1] Soomro et al. (2012), §2 / Table 1. https://arxiv.org/abs/1212.0402

型・カテゴリ・グループ・クリップを区別する

単位 [1]	何を表すか	具体例
型	カテゴリの大区分。全 5 種類	スポーツ
カテゴリ	全 101 種類の行動ラベル	CricketShot
グループ	撮影場所や人物などが似た動画のまとまり。各カテゴリに 25 組	CricketShot の g04
クリップ	1 本の動画。各グループに 4 〜 7 本	g04 の c01

[1] Soomro et al. (2012), §2. https://arxiv.org/abs/1212.0402

撮影条件の似たクリップをグループにまとめる

- 各行動カテゴリには 25 グループがある [1]。
- 1 グループには、撮影場所や映る人物、カメラの視点などが似た 4 〜 7 クリップをまとめる。
- ファイル名の g04 はグループ番号、 c01 はグループ内のクリップ番号。
- 近い映像が学習とテストの両方に入ることを避けるため、グループ単位で分ける。

[1] Soomro et al. (2012), §2–4. https://arxiv.org/abs/1212.0402

101 種類の行動は 5 つの型に整理されている

行動の型 [1]	カテゴリ数	クリップ数 [2]
人と物との相互作用	20	2619
身体の動き	16	1910
人と人との相互作用	5	690
楽器の演奏	10	1428
スポーツ	50	6673

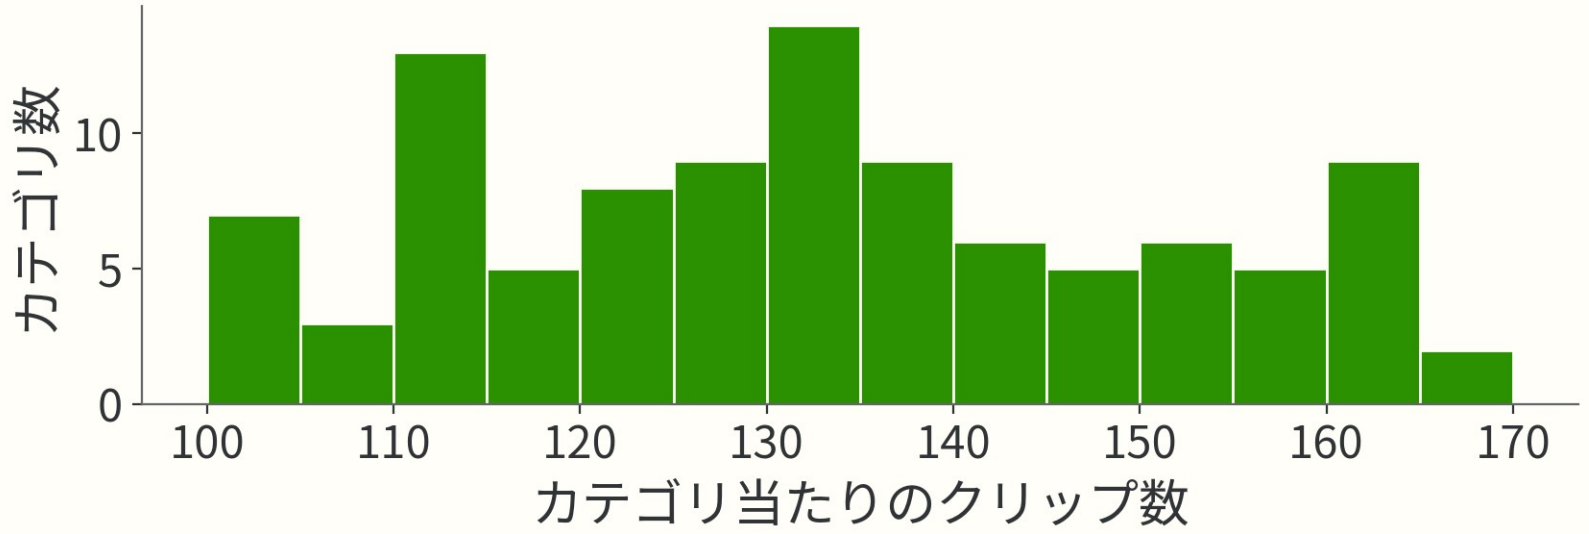
[1] 原著 Figure 2 の分類と分割リストの全件集計 . https://arxiv.org/abs/1212.0402
[2] https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

平均 7.21 秒の 13,320 クリップを収録する

- 101 カテゴリ、 13,320 クリップを収録する [1] 。
- 平均クリップ長は 7.21 秒、総時間は 1,600 分。映像は 25 fps 、 320×240 ピクセル。
- 動画をまとめた圧縮 ZIP は約 7 GB [3] 。
- 25 グループ ×101 カテゴリで計 2,525 グループ [2] 。
- 1 本の動画に 1 つの行動ラベルが付く。

[1] Soomro et al. (2012), Table 1. https://arxiv.org/abs/1212.0402
[2] グループ数は分割リストの集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[3] ZIP は 6,960,400,115 bytes. https://github.com/tensorflow/datasets/blob/master/tensorflow_datasets/url_checksums/ucf101.txt

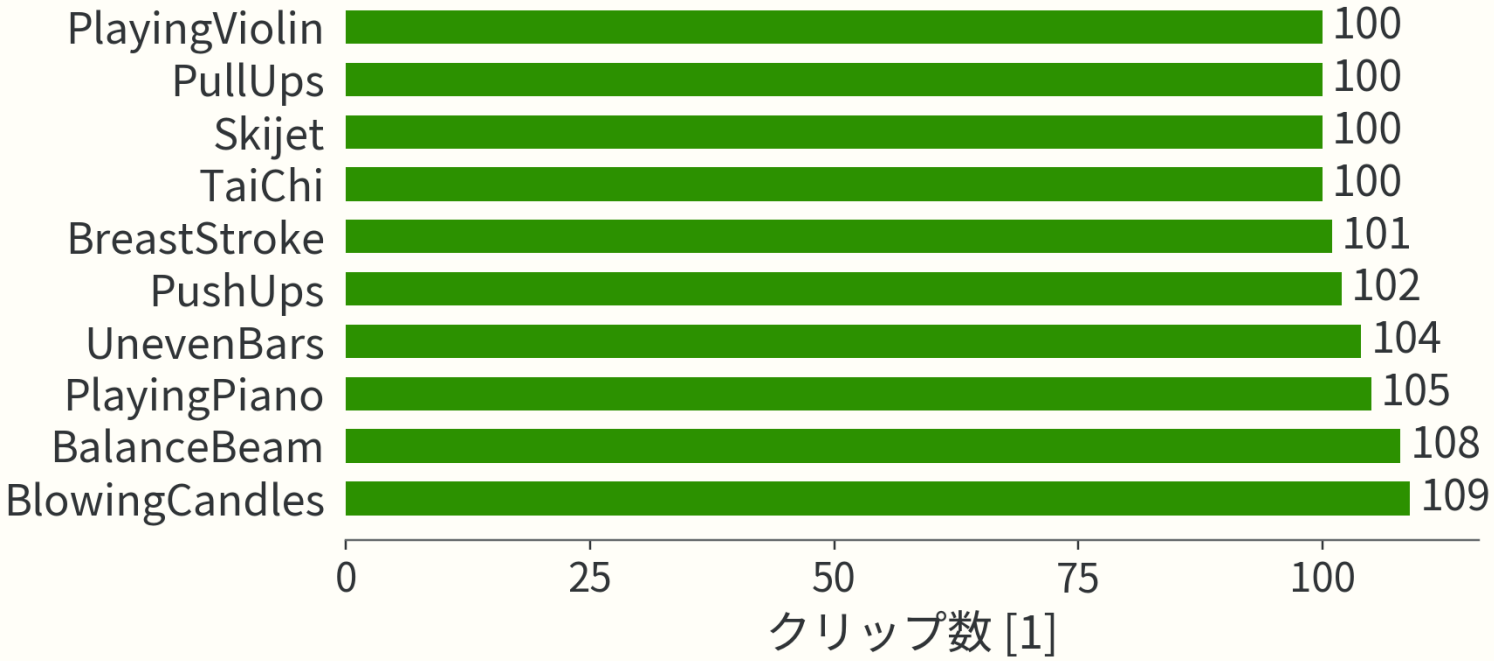
カテゴリ当たりのクリップ数の中央値は 131 本



全 101 カテゴリ。最少は 100 本、最多は 167 本 [1]。

[1] 13,320 クリップをカテゴリ別に集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

110 本未満のカテゴリは 10 種類



[1] 13,320 クリップをカテゴリ別に集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

3 つの分割で学習用とテスト用を入れ替える

分割 [1]	学習用	テスト用
split 1	9,537	3,783
split 2	9,586	3,734
split 3	9,624	3,696

各分割の合計は 13,320 。各カテゴリで同じグループが学習とテストへまたがらない。

[1] 配布分割リストの集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

3 評価とモデルの性能

正解率は動画ごとの正解を全体で平均する

- 最上位の予測が正解カテゴリと一致した動画を正解とする。
- 正解率は、正解した動画数を評価した動画数で割り、百分率にする。
- 3 動画中 2 動画が正解なら、正解率は 66.7% となる。
- 公式の 3 分割を使う評価では、分割ごとの値とその平均を区別する [1]。

[1] Carreira & Zisserman (2017), §4 / Table 5. https://arxiv.org/abs/1705.07750

2012 年の原著の正解率は 44.5% だった

- 原著は局所的な動きと見た目を特徴量にして、映像を特徴の出現頻度で表した [1]。
- 分類にはサポートベクトルマシンを使った。
- 25 グループのうち 1 グループをテストにし、 25 回入れ替える交差検証を行った。
- 平均正解率は 44.5% 。後の 3 分割評価とは評価条件が異なる。

[1] Soomro et al. (2012), §3–4. https://arxiv.org/abs/1212.0402

2017 年の I3D は 2 種類の入力を組み合わせた

I3D の入力 [1]	Top-1 正解率
RGB 画像	95.6%
フレーム間の動きを表す光学フロー	96.7%
RGB 画像と光学フロー	98.0%

ImageNet と Kinetics で事前学習し、 UCF101 で微調整した。公式 3 分割の平均。

[1] Carreira & Zisserman (2017), CVPR, Table 5. https://arxiv.org/abs/1705.07750

VideoMAE の結果は事前学習データで変わる

ViT-B の事前学習データ [1]	Top-1 正解率
UCF101 のみ	91.3%
Kinetics-400	96.1%

どちらも UCF101 で微調整した報告値。映像の隠した部分を復元する VideoMAE を使う。

[1] Tong et al. (2022), NeurIPS, Table 13. https://arxiv.org/abs/2203.12602

2024 年には映像特徴の評価にも使われた

固定する特徴モデル [1]	Top-1 正解率
DINOv2-g	91.2%
TVTSv2-H	91.8%
InternVideo2 第 2 段階・ 6B	97.3%

特徴を固定し、 UCF101 の学習用で線形分類器を学習する。特徴モデルの事前学習条件は異なる。

[1] Wang et al. (2024), InternVideo2, Table 4. https://arxiv.org/abs/2403.15377

高い正解率だけで時間順序の理解は示せない

- 映像には、行動の動きだけでなく物体や背景も写る。
- 背景や道具だけでも、行動カテゴリの手がかりになりうる。
- 2024 年の比較では画像特徴モデル DINOv2 を使う方式も 91.2% だった [1] 。
- 行動分類の正解率と、動作の順序や細かな変化を理解できるかを分けて評価する。

[1] Wang et al. (2024), InternVideo2, Table 4. https://arxiv.org/abs/2403.15377

4 利用の変遷と現在

先行データより多くの行動と撮影条件を扱った

- 先行する KTH は、同じ撮影条件で 6 行動を扱った [1]。
- これに対して UCF101 は、 YouTube の自然な映像で 101 種類を扱う。
- また、映画などから集めた HMDB51 は 51 種類だった。
- UCF101 は約 2 倍の行動カテゴリを設け、より多くの種類を区別する評価へ広げた。

[1] Soomro et al. (2012), §1 / Table 2. https://arxiv.org/abs/1212.0402

後続データでは規模と動作の細かさが広がった

- 2017 年に Kinetics が登場した。 400 行動・ 306,245 クリップを扱う [1] 。
  - UCF101 の約 4 倍の行動数、約 23 倍のクリップ数へ規模を広げた。
- 同年の Something-Something は、物を動かすなど 174 種類の細かい行動を扱った [2] 。
  - UCF101 のスポーツや日常動作に対し、手と物の関係や移動方向を細かく区別する。

[1] Kay et al. (2017), Table 1. https://arxiv.org/abs/1705.06950
[2] Goyal et al. (2017), ICCV. https://arxiv.org/abs/1706.04261

現在は小規模な転移先や再現実験にも使われる

- 登場時は、自然な映像の多クラス行動認識を評価する資源だった。
- その後は、 Kinetics などで学んだ動画モデルの転移先にも使われた [1] 。
- 2024 年の InternVideo2 も、線形分類・ゼロショット評価に用いた。
- 2026 年時点でも、 MMAction2 には UCF101 の取得・前処理・評価用ファイルを作る手順がある [2] 。

[1] Carreira & Zisserman (2017). https://arxiv.org/abs/1705.07750 / Wang et al. (2024). https://arxiv.org/abs/2403.15377
[2] MMAction2 の UCF101 手順 . https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

5 入手方法とまとめ

動画本体と 3 分割のリストを取得する

- 公式配布元から、動画のアーカイブと学習・テスト分割の ZIP を取得する [1]。
- 展開したカテゴリ別フォルダと分割リストを対応させる。
- データを扱う MMAction2 などの手順で、フレーム抽出と入力用リストを準備できる [2]。
- 利用条件は公式配布元で確認する。

[1] UCF101 公式配布元 . https://www.crcv.ucf.edu/data/UCF101.php
[2] MMAction2 の UCF101 手順 . https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

UCF101 は動画モデルの行動認識と転移を評価する

- 101 種類の行動を扱う 13,320 クリップのデータセット。
- 自然な YouTube 映像で、多様な行動を評価するため 2012 年に作られた。
- 同じ背景や人物を共有するグループを単位に分割する。
- 登場時の分類評価から、事前学習モデルの転移・特徴評価にも用途が広がった。
- 正解率を比較するときは、分割・事前学習・評価方式をそろえる。

Appendix の目次

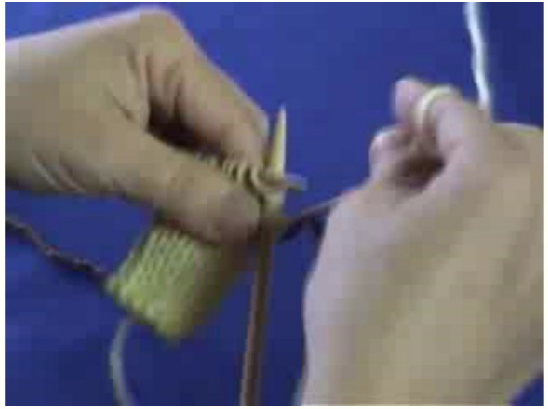
1. 著者と発表先
2. 追加の行動例
3. 101 カテゴリの一覧
4. 本数とグループの統計
5. 評価の補足
6. 入手と集計のコード
7. 参考文献

2012 年の技術報告として発表された

- CRCV-TR-12-01 としてまとめ、 2012-12-03 に arXiv へ投稿した [1]。
- 第一著者の Khurram Soomro は、 UCF101 を構築した行動認識研究者。
- 最終著者の Mubarak Shah は、動画の行動認識を研究し、 UCF50 や UCF Sports にも取り組んだ。
- 当時の著者の所属は、セントラルフロリダ大学のコンピュータビジョン研究センター。

[1] Soomro et al. (2012), 表紙・参考文献 [9–10]. https://arxiv.org/abs/1212.0402

編み物（ Knitting ）の例



0.00 秒



5.32 秒



10.60 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_Knitting_g01_c01.avi

ヨーヨー（YoYo）の例



0.00 秒



3.72 秒



7.44 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_YoYo_g01_c01.avi

赤ちゃんのはいはい（ BabyCrawling ）の例



0.00 秒



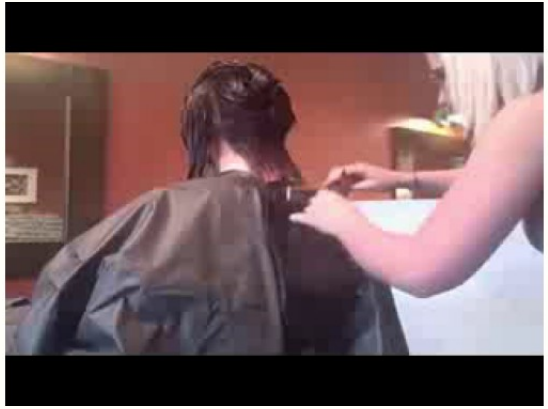
3.28 秒



6.56 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_BabyCrawling_g01_c01.avi

散髪（ Haircut ）の例



0.00 秒



2.68 秒



5.36 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_Haircut_g01_c01.avi

ギターの演奏（ PlayingGuitar ）の例



0.00 秒



5.00 秒



9.96 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_PlayingGuitar_g01_c01.avi

ビリヤード（ Billiards ）の例



0.00 秒



5.48 秒



10.92 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_Billiards_g01_c01.avi

バスケットボールのダンク（ BasketballDunk ）



0.00 秒



1.20 秒



2.40 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_BasketballDunk_g01_c01.avi

サーフィン（ Surfing ）の例



0.00 秒



5.08 秒



10.12 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_Surfing_g01_c01.avi

タイピング（Typing）の例



0.00 秒



2.52 秒



5.04 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_Typing_g01_c01.avi

スケートボード（SkateBoarding）の例



0.00 秒



4.04 秒



8.04 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_SkateBoarding_g01_c01.avi

人と物との相互作用という型の全 20 カテゴリ

ApplyEyeMakeup
ApplyLipstick
BlowDryHair
BrushingTeeth
CuttingInKitchen
Hammering
HulaHoop
JugglingBalls
JumpRope
Knitting
Mixing
MoppingFloor
Nunchucks
PizzaTossing
ShavingBeard
SkateBoarding
SoccerJuggling
Typing
WritingOnBoard
YoYo

[1] 全 101 カテゴリ . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 型の区分は原著 Figure 2. https://arxiv.org/abs/1212.0402

身体の動きという型の全 16 カテゴリ

BabyCrawling
BlowingCandles
BodyWeightSquats
HandstandPushups
HandstandWalking
JumpingJack
Lunges
PullUps
PushUps
RockClimbingIndoor
RopeClimbing
Swing
TaiChi
TrampolineJumping
WalkingWithDog
WallPushups

[1] 全 101 カテゴリ . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 型の区分は原著 Figure 2. https://arxiv.org/abs/1212.0402

人と人との相互作用という型の全 5 カテゴリ

BandMarching
Haircut
HeadMassage
MilitaryParade
SalsaSpin

[1] 全 101 カテゴリ . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 型の区分は原著 Figure 2. https://arxiv.org/abs/1212.0402

楽器の演奏という型の全 10 カテゴリ

Drumming
PlayingCello
PlayingDaf
PlayingDhol
PlayingFlute
PlayingGuitar
PlayingPiano
PlayingSitar
PlayingTabla
PlayingViolin

[1] 全 101 カテゴリ . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 型の区分は原著 Figure 2. https://arxiv.org/abs/1212.0402

スポーツという型の全 50 カテゴリ 1/3

Archery
BalanceBeam
BaseballPitch
Basketball
BasketballDunk
BenchPress
Biking
Billiards
Bowling
BoxingPunchingBag
BoxingSpeedBag
BreastStroke
CleanAndJerk
CliffDiving
CricketBowling
CricketShot
Diving
Fencing

[1] 全 101 カテゴリ . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 型の区分は原著 Figure 2. https://arxiv.org/abs/1212.0402

スポーツという型の全 50 カテゴリ 2/3

FieldHockeyPenalty
FloorGymnastics
FrisbeeCatch
FrontCrawl
GolfSwing
HammerThrow
HighJump
HorseRace
HorseRiding
IceDancing
JavelinThrow
Kayaking
LongJump
ParallelBars
PoleVault
PommelHorse

[1] 全 101 カテゴリ . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 型の区分は原著 Figure 2. https://arxiv.org/abs/1212.0402

スポーツという型の全 50 カテゴリ 3/3

Punch
Rafting
Rowing
Shotput
Skiing
Skijet
SkyDiving
SoccerPenalty
StillRings
SumoWrestling
Surfing
TableTennisShot
TennisSwing
ThrowDiscus
UnevenBars
VolleyballSpiking

[1] 全 101 カテゴリ . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits
[2] 型の区分は原著 Figure 2. https://arxiv.org/abs/1212.0402

型ごとにカテゴリ数とクリップ数を比較する

型 [1]	カテゴリ数	合計本数	最少	平均	最多
人と物との相互作用	20	2,619	110	131.0	161
身体の動き	16	1,910	100	119.4	144
人と人との相互作用	5	690	125	138.0	155
楽器の演奏	10	1,428	100	142.8	164
スポーツ	50	6,673	100	133.5	167
全 101 カテゴリ	101	13,320	100	131.9	167

カテゴリ当たりの本数は中央値 131 本、母標準偏差 18.2 本。 25% 点は 117 本、 75% 点は 145 本、 95% 点は 163 本。

[1] 原著 Figure 2 の型と配布リストの集計 . https://arxiv.org/abs/1212.0402
https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

バイオリンの演奏（ PlayingViolin ）は 100 本 [2]



0.00 秒



3.72 秒



7.40 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_PlayingViolin_g01_c01.avi
[2] カテゴリ別集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

クリケットの打撃（ CricketShot ）は 167 本 [2]



0.00 秒



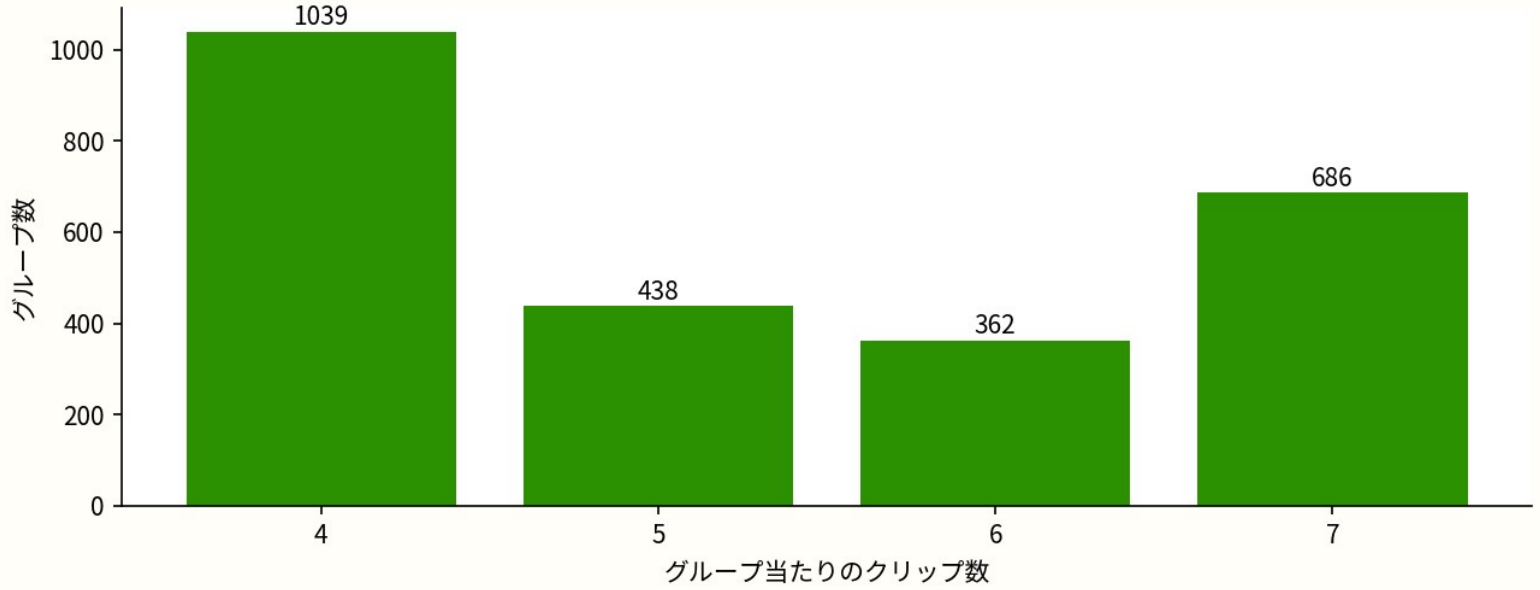
1.68 秒



3.32 秒

[1] https://github.com/RichardMinsooGo-ML/5_TF2_UCF101_video_classification v_CricketShot_g01_c01.avi
[2] カテゴリ別集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

4 クリップのグループが最も多い



[1] カテゴリとグループ番号の組を単位に、全 2,525 グループを集計 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

3 分割ではテストにするグループが異なる

分割 [1]	テスト用グループ
split 1	g01 〜 g07
split 2	g08 〜 g14
split 3	g15 〜 g21

それ以外の 18 グループを学習用に使う。各分割で学習とテストのグループは重ならない。

[1] 全 101 カテゴリの分割リストを照合 . https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

動画単位の正解率を計算する例

正解カテゴリ	予測カテゴリ	得点
PlayingViolin	PlayingViolin	1
PlayingGuitar	PlayingGuitar	1
CricketShot	CricketBowling	0

3 動画中 2 動画が正解なので、正解率は 2÷3×100 ＝ 66.7% となる。

原著では行動の型によって成績が異なった

行動の型 [1]	正解率
人と物との相互作用	38.52%
身体の動き	36.26%
人と人との相互作用	44.14%
楽器の演奏	37.42%
スポーツ	50.54%

[1] Soomro et al. (2012), §3. 25 グループの交差検証 . https://arxiv.org/abs/1212.0402

近年はゼロショット評価にも用いられる

手法 [1]	Top-1 正解率
CLIP	68.9%
TVTSv2	78.0%
InternVideo2clip-1B	88.8%
InternVideo2clip-6B	89.5%

UCF101 で微調整せず、行動名と映像を照合する。事前学習・入力フレーム数は手法で異なる。

[1] Wang et al. (2024), Table 5. https://arxiv.org/abs/2403.15377

配布リストからカテゴリ別の本数を集計する

```
from pathlib import Path
from collections import Counter

root = Path("ucfTrainTestlist")
train = (root / "trainlist01.txt").read_text().splitlines()
test = (root / "testlist01.txt").read_text().splitlines()
clips = {line.split()[0] for line in train + test}
counts = Counter(path.split("/")[0] for path in clips)
print(len(clips), len(counts))
for label, n in sorted(counts.items()):
    print(label, n)
```

[1] https://github.com/yjxiong/temporal-segment-networks/tree/master/data/ucf101_splits

動画と分割リストのアーカイブを取得する

```
base=https://www.crcv.ucf.edu/data/UCF101
curl -L --fail -O "$base/UCF101.rar"
curl -L --fail -O \
  "$base/UCF101TrainTestSplits-RecognitionTask.zip"

unrar x UCF101.rar
unzip UCF101TrainTestSplits-RecognitionTask.zip
```

[1] 公式配布元 . https://www.crcv.ucf.edu/data/UCF101.php
[2] 配布 URL は MMAction2 の取得手順に基づく . https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

読後の学習・研究に向けて

Soomro et al. (2012). UCF101. CRCV-TR-12-01.
まず、 101 行動の定義と、似た映像をグループ化する設計を学ぶ。

https://arxiv.org/abs/1212.0402

Simonyan & Zisserman (2014). Two-Stream. NeurIPS.
見た目とオプティカルフローを分けて学ぶ基本構成を理解する。

https://arxiv.org/abs/1406.2199

Wang et al. (2016). Temporal Segment Networks. ECCV.
離れた時刻のフレームを使い、動画全体を扱う方法を学ぶ。

https://arxiv.org/abs/1608.00859

読後の学習・研究に向けて

Carreira & Zisserman (2017). I3D. CVPR.
画像モデルを 3 次元へ拡張し、動画へ転移する方法を読む。

https://arxiv.org/abs/1705.07750

Tong et al. (2022). VideoMAE. NeurIPS.
隠した映像の復元による自己教師あり事前学習を学ぶ。

https://arxiv.org/abs/2203.12602

MMAction2 公式・ UCF101 データ準備
動画と 3 分割のリストを対応させ、前処理と評価の準備を試す。

https://github.com/open-mmlab/mmaction2/tree/main/tools/data/ucf101

読後の学習・研究に向けて

Kay et al. (2017). Kinetics.
より大規模な事前学習データの収集・品質確認を比較する。

https://arxiv.org/abs/1705.06950

Goyal et al. (2017). Something-Something. ICCV.
物体と手の相互作用を読み、時間的な順序を要する課題を考える。

https://arxiv.org/abs/1706.04261

MMAction2 公式・学習と評価
設定・チェックポイント・分割をそろえ、自分のモデルを評価する。

https://github.com/open-mmlab/mmaction2/blob/main/docs/en/user_guides/train_test.md