UniDic

国語研短単位自動解析用辞書

現代書き言葉 2025.12 ：短単位と見出しの構造

sasakiy84

UniDic の公式サイト



[1] 国立国語研究所 . UniDic. https://clrd.ninjal.ac.jp/unidic/

1. 文を分けて語の情報を読む
2. 見出し構造と短単位
3. 辞書の構築と配布形式
4. 使い方と辞書の選択

1. 文を分けて語の情報を読む

文を区切り、語の情報を対応づける

- UniDic は、国語研の「短単位」に基づく辞書。形態素解析器 MeCab と組み合わせて、文を区切り、品詞や読みを付ける。
- 語彙素という見出しに、表記や活用の異なる形を対応づける。その関係を、階層的な構造で管理している。
- ここでは現代書き言葉 2025.12 を使う。 MeCab を Python から使う fugashi で、本資料の入力文を解析した。

[1] 国立国語研究所 . UniDic とは . https://clrd.ninjal.ac.jp/unidic/about_unidic.html

「本を読んだ。」を解析すると

出現した文字列	品詞（大分類）	語彙素	発音形
本	名詞	本	ホン
を	助詞	を	オ
読ん	動詞	読む	ヨン
だ	助動詞	た	ダ
。	補助記号	。	*

入力は「本を読んだ。」。句点にも情報が付き、「読ん」は「読む」に対応する。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

「読ん」の形と活用を読む

項目	解析結果
書字形出現形	読ん
語彙素	読む
発音形出現形	ヨン
活用型	五段 - マ行
活用形	連用形 - 撥音便

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

「国立国語研究所」は四つの短単位

出現した文字列	品詞	発音形
国立	名詞	コクリツ
国語	名詞	コクゴ
研究	名詞	ケンキュー
所	接尾辞	ショ

短単位は、用例を同じ基準で探し、数えられるように設定された単位。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

区切りの基準をそろえ、用例を集める

- 語の区切り方が資料ごとに異なると、用例の検索条件や語数の数え方も変わってしまう。
- UniDic は、用例収集に適した短単位を定め、表記や活用の違いをまとめて探せる見出しを持たせた。
- 単なる文字列の一致から、語の単位と属性を使った検索へつなげるための辞書である。

[1] 伝康晴ほか . 2007. コーパス日本語学のための言語資源 . 日本語科学 22. https://doi.org/10.15084/00002185
[2] 国立国語研究所 . UniDic 用語集 . https://clrd.ninjal.ac.jp/unidic/glossary.html

2. 見出し構造と短単位

語彙素・語形・書字形を対応づける

階層・情報	まとめるもの	例
語彙素	同じ見出しに属する語形	大きい
語形	表記の違いをまとめる	オオキイ／オッキイ
書字形・発音形	文字と発音の形	大きい／オーキー

書字形と発音形は、語形の下で並列に扱われる。各形には基本形と出現形がある。

[1] 国立国語研究所 . UniDic 用語集 . https://clrd.ninjal.ac.jp/unidic/glossary.html

三つの表記から、同じ語彙素へ

出現した文字列	語彙素	語形基本形	発音形
大きい	大きい	オオキイ	オーキー
おおきい	大きい	オオキイ	オーキー
おっきい	大きい	オッキイ	オッキー

「おっきい」は異なる語形。三つとも、語彙素「大きい」に結び付く。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

活用した形を、基本形へ結び付ける

出現した文字列	書字形基本形	活用形
読む	読む	終止形 - 一般
読ん	読む	連用形 - 撥音便
読め	読む	仮定形 - 一般

入力は「読む。読んだ。読めば分かる。」。「読ん」「読め」から「読む」をたどれる。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

仮名での読みと、発音を別に持つ

項目	「こおりつけ」の解析結果
語彙素	凍り付く
語彙素読み	コオリツク
仮名形出現形	コオリツケ
発音形出現形	コーリツケ

仮名形の「コオリ」に対し、発音形では長音を使って「コーリ」と表す。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

品詞で、取り得る用法をまとめて表す

入力文	「今度」の品詞
今度行く。	名詞ー普通名詞ー副詞可能
今度が最後だ。	名詞ー普通名詞ー副詞可能

「副詞可能」は、副詞としても使えることを表す。文脈ごとに細分せず、共通の品詞で用例を集める。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

検索・集計の目的に合わせて項目を選ぶ

- 活用した形をまとめたいときは基本形を使う。表記そのものを調べたいときは、書字形を保って集計する。
- 「大きい・おおきい・おっきい」をまとめて探すなら、語彙素を使う。異なる語彙素が同じ読みを持つこともあるので、見出しの識別も利用する。
- どの違いをまとめ、どの違いを残すかを選べることが、階層的な見出しの利点である。

[1] 国立国語研究所 . UniDic 用語集 . https://clrd.ninjal.ac.jp/unidic/glossary.html

3. 辞書の構築と配布形式

コーパスの形態論情報付与を支える

- UniDic は、日本語話し言葉コーパスや現代日本語書き言葉均衡コーパスの形態論情報付与を支えてきた。
- 辞書を使った自動解析の結果を人手で修正し、コーパスの形態論情報を整える。語の情報は辞書データベースと対応づけて管理する。
- 辞書と用例の対応を保つことで、同じ語への情報付与をそろえ、用例の検索にもつなげる。

[1] 国立国語研究所 . UniDic とは . https://clrd.ninjal.ac.jp/unidic/about_unidic.html

設計・データベース・解析用辞書

UniDic が指すもの	役割
設計方針	短単位と階層的な見出しを定める
UniDic データベース	語の情報と対応関係を管理する
解析用 UniDic	MeCab で解析するために配布する辞書

公式サイトで公開・配布されているのは、解析用 UniDic 。

[1] 国立国語研究所 . UniDic とは . https://clrd.ninjal.ac.jp/unidic/about_unidic.html

2025.12 版は見出し語と品詞を更新

- 現代書き言葉 UniDic 2025.12 は、見出し語を追加し、一部の品詞を見直したバージョン。
- 配布パッケージには、解析用のバイナリ辞書、文字種や未知語の情報、出力などの設定が入る。
- 以前のバージョンもバックナンバーから入手できる。解析結果を共有するときは、使用した辞書の種類とバージョンを添える。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

配布フォルダの主なファイル

ファイル	役割
sys.dic	見出しと特徴情報を持つシステム辞書
matrix.bin	語のつながりを選ぶための連接コスト
char.bin / unk.dic	文字種と未知語候補の情報
dicrc	出力形式などの動作設定
rewrite.def / feature.def	特徴情報の変換・学習用の設定

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

2025.12 版の配布規模

対象	規模
辞書エントリ	1,027,505
配布 ZIP	696.1 MB
展開した配布物	1,313.7 MB

辞書エントリ数は MeCab の辞書情報による。容量は実測で、 MB は 10^6 bytes 。エントリ数には活用形などの登録を含む。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

4. 使い方と辞書の選択

解析したい文章に合う辞書を選ぶ

種類	主な対象
現代書き言葉	書籍・新聞・ Web 文章など
現代話し言葉	会話などを書き起こしたテキスト
古文・方言用	時代・文体・地域に応じたテキスト

現代話し言葉用は日本語日常会話コーパス（ CEJC ）を学習に使用。対象と利用条件は辞書ごとに異なる。

[1] 国立国語研究所 . UniDic 最新版ダウンロード . https://clrd.ninjal.ac.jp/unidic/download_all.html

Python から解析結果を取り出す

```
from fugashi import GenericTagger
args = "-r ./unidic-cwj/dicrc -d ./unidic-cwj"
tagger = GenericTagger(args)
for word in tagger("本を読んだ。"):
    print(word.surface, word.feature[7], sep="\t")
```

公式 ZIP の辞書ファイルを unidic-cwj に置き、 fugashi を導入した例。
出現した文字列と語彙素を取り出す。

[1] Paul McCann. 2020. fugashi, a Tool for Tokenizing Japanese in Python. https://aclanthology.org/2020.nlposs-1.7/

語の形を保ちながら、検索や集計へ

- 語彙素を使って語の頻度を集計したり、品詞を指定して名詞や動詞の用例を取り出したりできる。
- 書字形や発音形を残せば、同じ見出しの中で、どの表記や読みが使われたかも調べられる。
- オンラインの Web 茶まめでも、複数の UniDic を使った解析を試せる。手元に環境を作る前の入口として利用できる。

[1] 国立国語研究所 . UniDic. https://clrd.ninjal.ac.jp/unidic/

取得先と利用条件

- 公式サイトから、対象の文章とバージョンに合う解析用辞書を取得する。
- ここで使った現代書き言葉 2025.12 は、 GPL ・ LGPL ・修正 BSD から選んで利用できる。本資料の辞書出力は修正 BSD に基づき、国立国語研究所をクレジットする。
- 古文用などには別の条件で配布される辞書もある。利用するパッケージに付いたライセンスを確認する。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html
[2] 国立国語研究所 . UniDic 商用利用について . https://clrd.ninjal.ac.jp/unidic/commerce_use.html

UniDic の要点

- 短単位の区切りと語の属性をそろえ、コーパスの用例検索や語彙調査を支える辞書。
- 語彙素・語形・書字形・発音形を対応づけ、活用や表記の違いを、目的に合わせてまとめられる。
- 文章に合った解析用辞書を選び、 MeCab などの解析環境から、その見出しと特徴情報を利用する。

[1] 国立国語研究所 . UniDic とは . https://clrd.ninjal.ac.jp/unidic/about_unidic.html

Appendix

1. 追加の解析例
2. 特徴列と参考資料

表記の違い：「引っ越し」と「引越し」

出現した文字列	語彙素	語形基本形
引っ越し	引っ越し	ヒッコシ
引越し	引っ越し	ヒッコシ

入力は「引っ越しと引越し。」。表記を残しながら、共通の見出しへ結び付ける。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

語種：「山」「学校」「テレビ」

出現した文字列	語彙素	語種
山	山	和
学校	学校	漢
テレビ	テレビ -TV	外

語種の「和・漢・外」は、和語・漢語・外来語を表す。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

同じ読みでも、見出しを区別できる

出現した文字列	語彙素	語彙素読み
橋	橋	ハシ
箸	箸	ハシ

入力は「橋と箸。」。読みが同じ「ハシ」でも、語彙素は別に識別される。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

固有名詞も短単位と属性で扱う

文字列	品詞（主要部）	語彙素
東京	名詞ー固有名詞ー地名	トウキョウ
都	名詞ー普通名詞	都

入力は「東京都で働く。」。ここでは「東京」と「都」に区切られた。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

未知語では、文字種から候補を作る

- 「OpenStreetMap を調べる。」を解析すると、OpenStreetMap は未知語として扱われた。品詞候補は「名詞ー普通名詞ーー般」だった。
- この候補には、登録語のような語彙素や読みは入っていない。未知語の出力を扱うときは、得られた項目に合わせて処理する。
- MeCab は文字種などの設定から未知語候補を作る。品詞の推定と、辞書に見出しが登録されていることは別の情報になる。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html
[2] 工藤拓 . MeCab: オリジナル辞書／コーパスからのパラメータ推定 . https://taku910.github.io/mecab/learn.html

活用した形を、語彙素 ID でも結べる

出現した文字列	語彙素	語彙素 ID
読む	読む	39484
読ん	読む	39484
読め	読む	39484

語彙素 ID は見出しを識別する。個々の辞書エントリには、別に語彙表 ID が付く。

[1] 国立国語研究所 . 2025. 現代書き言葉 UniDic 2025.12 （修正 BSD ） . https://clrd.ninjal.ac.jp/unidic/download.html

解析結果の主な特徴情報

情報のまとまり	主な項目
品詞・活用	pos1–pos4 / cType / cForm
見出し	lemma / lForm / formBase
文字と発音	orth / pron / orthBase / pronBase
語種・アクセント	goshu / aType など
識別子	lid / lemma_id

この配布版の既知語は 29 項目。出力形式は dicrc などで選べる。

[1] 国立国語研究所 . UniDic FAQ. https://clrd.ninjal.ac.jp/unidic/faq.html

参考文献

UniDic とは

国立国語研究所 . n.d. （参照： 2026-10-28 ） .

設計方針・辞書データベース・解析用辞書の関係を説明する。

https://clrd.ninjal.ac.jp/unidic/about_unidic.html

UniDic 用語集

国立国語研究所 . n.d. （参照： 2026-10-28 ） .

短単位と階層的な見出し構造、品詞体系を解説する。

https://clrd.ninjal.ac.jp/unidic/glossary.html

参考文献

現代書き言葉 UniDic ／現代話し言葉 UniDic 最新版ダウンロード

国立国語研究所 . n.d. （参照： 2026-10-28 ） .

現代語の解析用辞書と、その利用条件を提供する。

https://clrd.ninjal.ac.jp/unidic/download.html

UniDic FAQ

国立国語研究所 . n.d. （参照： 2026-10-28 ） .

特徴列の読み方、ライセンス、語彙の数え方をまとめる。

https://clrd.ninjal.ac.jp/unidic/faq.html

参考文献

コーパス日本語学のための言語資源：形態素解析用電子化辞書の開発とその応用

伝康晴ほか . 2007. 日本語科学 22, pp.101–123.

単位の斉一性と、表記・語形の変異を扱う辞書設計を示す。

https://doi.org/10.15084/00002185

MeCab: オリジナル辞書／コーパスからのパラメータ推定

工藤拓 . n.d. MeCab. （参照： 2026-10-28 ） .

辞書の特徴情報、未知語処理、学習と配布形式を説明する。

https://taku910.github.io/mecab/learn.html

参考文献

fugashi, a Tool for Tokenizing Japanese in Python

Paul McCann. 2020. Proceedings of Second Workshop for NLP Open Source Software (NLP-OSS), pp.44–51. ACL.

MeCab の Python ラッパーと、日本語の単語分割を紹介する。

https://aclanthology.org/2020.nlposs-1.7/

UniDic 商用利用について

国立国語研究所 . n.d. （参照： 2026-10-28 ） .

辞書の種類・バージョンと、商用利用の条件を案内する。

https://clrd.ninjal.ac.jp/unidic/commerce_use.html