VQA v2

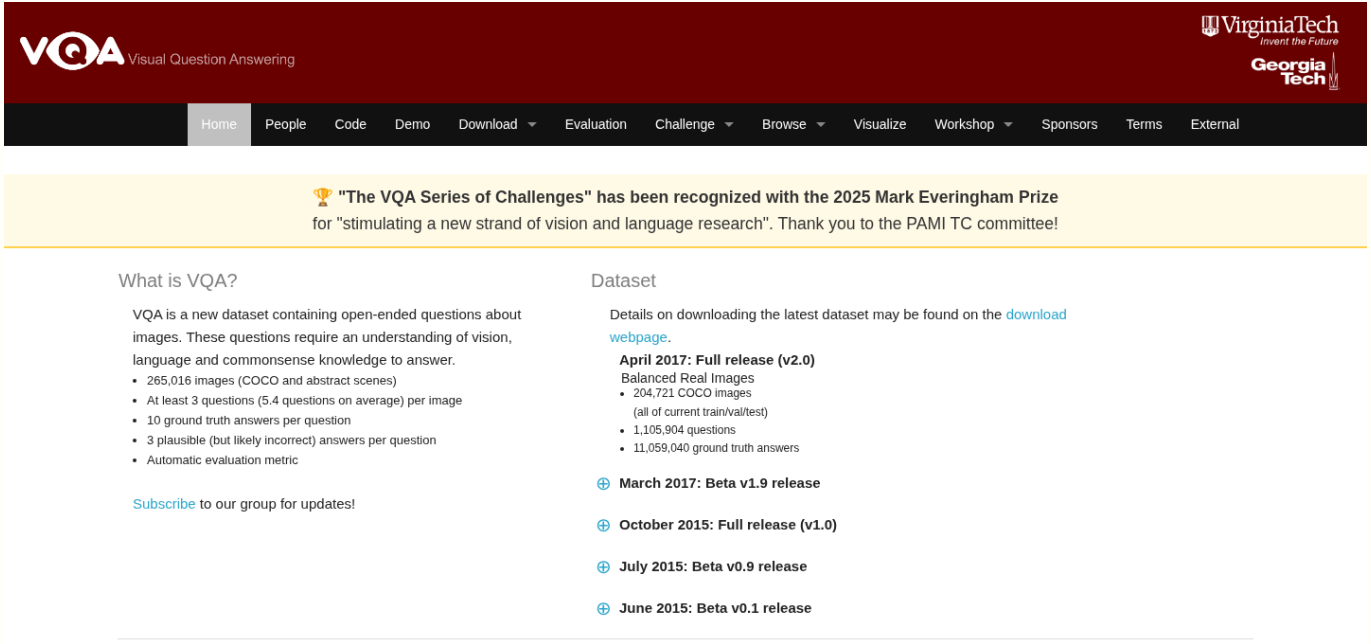
Visual Question Answering, version 2

同じ質問でも、画像が変われば

答えが変わる視覚質問応答

sasakiy84

VQA v2 の公式サイト



[1] VQA Team. VQA: Visual Question Answering. 2026-10-17 参照。 https://visualqa.org/

1. 画像を見て答える課題と実例
2. 人の回答に基づく採点と成績
3. 画像ペアの収集とデータの規模
4. 画像と言語の学習・評価への利用

1. 画像を見て答える課題と実例

写真と英語の質問から、短い答えを生成する

- VQA v2 は、日常の写真について英語で質問し、短い自然言語の答えを返す視覚質問応答のデータセットである。2017 年に公開された。
- モデルへの入力は画像と質問。学習・検証用の各問には、10 人が独立に記した回答が付いている。
- 同じ質問に対して答えが異なる画像を集め、質問文だけから答えを推測する偏りを減らすことを目指した。

[1] Goyal et al. (2017). Making the V in VQA Matter: Elevating the Role of Image Understanding in Visual Question Answering. CVPR. https://arxiv.org/abs/1612.00837

実例１：壁の落書き：あり



質問の原文（全文）

> Is there a graffiti on the wall?

壁に落書きはあるか。

yes （はい）

10 人中 9 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] COCO val2014 収録写真 . COCO 画像 ID 28714 。 CC BY-ND 2.0 。 question_id = 28714002 。 https://www.flickr.com/photo.gne?id=8614354814

実例１：壁の落書き：なし



質問の原文（全文）

> Is there a graffiti on the wall?

壁に落書きはあるか。

no （いいえ）

10 人中 10 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] Rusty Darbonne. Blue Bike. COCO 画像 ID 426166 。 CC BY 2.0 。 question_id = 426166003 。 https://www.flickr.com/photos/rustydarbonne/2319776213/

同じ質問に、異なる答えを持つ画像を組み合わせる

- 「壁に落書きはあるか」という同じ質問でも、落書きのある画像には yes 、ない画像には no と答える。
- この 2 問は、公式の complementary pairs に対応が記録されたペアである。画像を見分けなければ、両方を正しく答えられない。
- VQA v2 は、このようなペアを追加して、質問と答えの組合せへの偏りを小さくした。

[1] Goyal et al. (2017). Making the V in VQA Matter: Elevating the Role of Image Understanding in Visual Question Answering. CVPR. https://arxiv.org/abs/1612.00837

実例２：人数を数える



質問の原文（全文）

How many are playing ball?

ボール遊びをしているのは何人か。

1 （1 人）

10 人中 9 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] riz94107. IMG_9593. COCO 画像 ID 131089 。 CC BY-NC-SA 2.0 。 question_id = 131089002 。 https://www.flickr.com/photos/riz94107/4866736626/

実例３：視線の向きを答える



質問の原文（全文）

Where is he looking?

彼はどこを見ているか。

down （下）

10 人中 7 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] Ketil Johansen. Sk8 with boardshop & DC shoe. COCO 画像 ID 262148 。 CC BY-NC-SA 2.0 。 question_id = 262148000 。
https://www.flickr.com/photos/litek/4549977479/

視線の問いには、方向と対象を答えた人がいる

実際に書かれた回答	人数
down	7
at table	1
skateboard	1
table	1

question_id = 262148000 の 10 回答。方向を答えるか、見ている対象を答えるかにも幅がある。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html

2. 人の回答に基づく採点と成績

採点では、 10 人の回答との一致度を使う

- モデルが 1 つの答えを出し、人が書いた 10 個の回答と照合する。大文字・小文字、句読点、数詞や冠詞などは規則に沿って正規化する。
- 10 人から 1 人を外し、残る 9 人と一致した件数 m から min(m / 3, 1) を計算する。外す人を替えた 10 通りの平均が、その問の得点となる。
- 各問の得点を平均し、百分率で VQA accuracy として報告する。

[1] VQA Team. VQA Evaluation. 2026-10-17 参照。 https://visualqa.org/evaluation.html
[2] GT-Vision-Lab. VQA: vqaEval.py. 改訂 a013f00 。 https://github.com/GT-Vision-Lab/VQA/blob/a013f00/PythonEvaluationTools/vqaEvaluation/vqaEval.py

同じ答えが 3 人なら 0.9 、 4 人以上なら 1.0

正規化後に一致する回答数（10 人中）	1 問の得点
0	0.0
1	0.3
2	0.6
3	0.9
4 〜 10	1.0

[1] GT-Vision-Lab. VQA: vqaEval.py. 改訂 a013f00 。 https://github.com/GT-Vision-Lab/VQA/blob/a013f00/PythonEvaluationTools/vqaEvaluation/vqaEval.py

3 人が一致する場合は、平均すると 0.9 になる

- 一致した 3 人のうち 1 人を外す場合は、残る一致が 2 件なので 2 / 3 点となる。この場合が 3 通りある。
- 一致していない 7 人のうち 1 人を外す場合は、一致が 3 件なので 1 点となる。この場合が 7 通りある。
- したがって、 (3 × 2 / 3 + 7 × 1) / 10 = 0.9 。 10 人中の一致件数を直接 3 で割る計算とは異なる。

[1] GT-Vision-Lab. VQA: vqaEval.py. 改訂 a013f00 。 https://github.com/GT-Vision-Lab/VQA/blob/a013f00/PythonEvaluationTools/vqaEvaluation/vqaEval.py

2017 年：質問だけの偏りを減らすと成績も変わる

MCB モデルの学習集合 → 評価集合	VQA accuracy
v1 で学習／ v1 で評価	60.36%
v1 で学習／ v2 で評価	54.22%
v2 で学習（ v1 と同規模）／ v2 で評価	56.08%
v2 の全データで学習／ v2 で評価	59.14%

Goyal ら（ 2017 ）の val 結果。 MCB は画像と言語の特徴を組み合わせる方式。

[1] Goyal et al. (2017). Making the V in VQA Matter: Elevating the Role of Image Understanding in Visual Question Answering. CVPR. https://arxiv.org/abs/1612.00837

2021 ～ 2023 年：学習したモデルの test 成績

モデル	test-dev	test-standard
ALBEF （2021）	75.84%	76.04%
BLIP （2022）	78.25%	78.32%
BLIP-2 ViT-g OPT-6.7B （2023）	82.19%	82.30%

VQA の学習データで微調整した結果。非公開の正解を使い、サーバ側で採点。

[1] Li, Li, Savarese & Hoi (2023). BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models. ICML. https://arxiv.org/abs/2301.12597

ゼロショットと微調整後の成績は分けて読む

- BLIP-2 は、画像エンコーダと大規模言語モデルを固定し、両者をつなぐ小さなモデルを事前学習する方式である。
- ViT-g と FlanT5-XXL を使った構成は、 VQA で微調整しないゼロショット条件で、 test-dev の 65.0% を報告した。
- 82.19% の結果は、 OPT-6.7B を使い、 VQA v2 の train ・ val と Visual Genome で微調整した別の構成である。

[1] Li, Li, Savarese & Hoi (2023). BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models. ICML. https://arxiv.org/abs/2301.12597

3. 画像ペアの収集とデータの規模

同じ質問に別の答えが出る画像を探す

- 既存の画像・質問・答えに対し、画像特徴が近い 24 枚を候補として作業者へ見せた。
- 作業者は、元の質問がそのまま意味を持ち、元の答えとは異なる答えになる画像を選ぶ。質問は書き換えない。
- 選んだ画像と質問の組を、新たな 10 人が回答する。似た場面でも答えを変えるには、何が写っているかを見る必要がある。

[1] Goyal et al. (2017). Making the V in VQA Matter: Elevating the Role of Image Understanding in Visual Question Answering. CVPR. https://arxiv.org/abs/1612.00837

ペアの条件と、回答の収集を分けて確認した

- 画像の選定と回答の収集には Amazon Mechanical Turk を使い、作業者へ例を示して、質問が有効で答えが変わるかを確認した。
- 候補に適切な画像がない質問や、質問の解釈が曖昧な場合もある。全ての質問に、必ず 1 つの補完画像が付くわけではない。
- 元の画像と追加した画像の双方を含むデータにし、質問ごとに 10 個の人の回答を収録した。

[1] Goyal et al. (2017). Making the V in VQA Matter: Elevating the Role of Image Understanding in Visual Question Answering. CVPR. https://arxiv.org/abs/1612.00837

204,721 枚の画像に、約 111 万問が対応する

集合	画像数	質問数	公開された人の回答数
train	82,783	443,757	4,437,570
val	40,504	214,354	2,143,540
test	81,434	447,793	非公開

VQA v2.0 の公式配布値。 train ・ val では各質問に 10 回答。

[1] VQA Team. VQA v2.0 Download. 2026-10-17 参照。 https://visualqa.org/download.html

v1 から v2 では、質問数と画像への依存が増した

項目	VQA v1	VQA v2
train の質問数	248,349	443,757
val の質問数	121,512	214,354
答えが変わる補完画像	なし	追加
回答形式	自由回答・選択式	自由回答

[1] VQA Team. VQA v2.0 Download. 2026-10-17 参照。 https://visualqa.org/download.html

val では、数値回答が約 13% を占める

公式の回答タイプ	質問数	構成比
yes/no	80,541	37.6%
number	28,134	13.1%
other	105,679	49.3%

val の 214,354 問を answer_type で集計。 other には物体・色・場所などを含む。

[1] VQA Team. VQA v2.0 val の 214,354 問・回答注釈を全件集計。 https://visualqa.org/download.html

4. 画像と言語の学習・評価への利用

画像と言語を結び付けるモデルの基準になった

- 登場時は、質問の言い回しから答えを推測する偏りを抑え、画像の違いを使う能力を測ることを目指した。
- その後は、画像と言語を事前学習したモデルを、視覚質問応答へ適応させるための学習・評価データとして使われてきた。
- BLIP-2 は画像・言語の接続を事前学習し、 VQA v2 と Visual Genome を使った微調整でも評価した。

[1] Goyal et al. (2017). Making the V in VQA Matter: Elevating the Role of Image Understanding in Visual Question Answering. CVPR. https://arxiv.org/abs/1612.00837
[2] Li, Li, Savarese & Hoi (2023). BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models. ICML. https://arxiv.org/abs/2301.12597

現在の公開実装でも、評価手順を確認できる

- LAVIS の VQA タスクは、モデルの回答を集め、 VQA の公式評価ツールで検証用の accuracy を計算する。
- test では質問 ID と回答を保存して提出する。公式の test-dev と test-standard では、公開されていない人の回答を用いて採点する。
- 公式サイトでは質問・注釈・補完ペアを配布し、画像は COCO 2014 の配布先へ案内している。

[1] Salesforce. LAVIS: VQA task. 改訂 05cb670 、 2026-10-17 参照。 https://github.com/salesforce/LAVIS/blob/main/lavis/tasks/vqa.py
[2] VQA Team. VQA v2.0 Download. 2026-10-17 参照。 https://visualqa.org/download.html

質問と画像は、 image_id で結び付ける

```
import json
from pathlib import Path

questions = json.load(open("questions.json"))["questions"]
q = questions[0]
name = f'COCO_val2014_{q["image_id"]:012d}.jpg'
image_path = Path("val2014") / name
```

questions.json は展開した val 用質問 JSON の保存名。注釈とは question_id で対応させる。

[1] VQA Team. VQA v2.0 Download. 2026-10-17 参照。 https://visualqa.org/download.html

質問・回答の注釈と、写真の利用条件を確認する

- VQA の質問・回答注釈は CC BY 4.0 で公開されている。配布 JSON の license にも利用条件へのリンクが含まれる。
- 写真は COCO 由来で、画像ごとの元のライセンスに従う。VQA 注釈のライセンスを、そのまま全画像に適用しない。
- 問題を再現するときは、 VQA の question_id 、 COCO の image_id 、質問と回答の注釈を対応させて記録する。

[1] VQA Team. VQA v2.0 Download. 2026-10-17 参照。 https://visualqa.org/download.html
[2] COCO Consortium. COCO: Common Objects in Context. 2026-10-17 参照。 https://cocodataset.org/

答えが変わる画像から、視覚の役割を確かめる

- VQA v2 は、写真と英語の質問から短い答えを生成する、約 111 万問の視覚質問応答データである。
- 同じ質問に異なる答えを持つ画像を追加し、質問の言い回しだけで解く偏りを減らした。
- 1 つの参照語だけではなく、 10 人の回答との一致度で採点する。成績は評価集合と学習条件を対応させて読む。

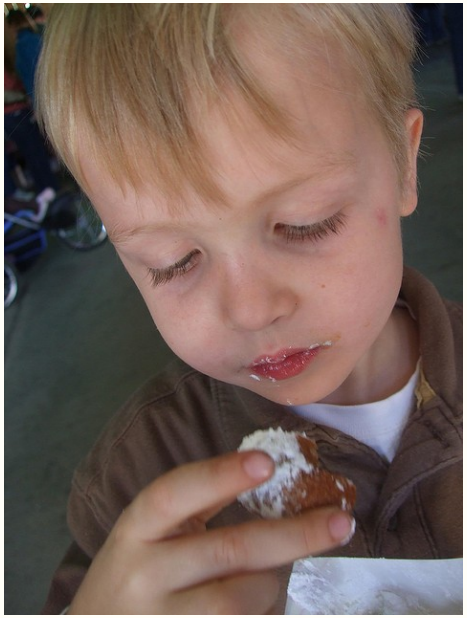
[1] Goyal et al. (2017). Making the V in VQA Matter: Elevating the Role of Image Understanding in Visual Question Answering. CVPR. https://arxiv.org/abs/1612.00837

Appendix

1. 見る対象の異なる追加 10 例
2. 質問と人の回答の集計
3. 研究と参考文献

1. 見る対象の異なる追加 10 例

追加例 1 ：髪の色を答える



質問の原文（全文）

What color is the kids hair?

この子の髪は何色か。

blonde （金髪）

10 人中 10 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] COCO val2014 収録写真 . COCO 画像 ID 393243 。 CC BY-NC-SA 2.0 。 question_id = 393243003 。 https://www.flickr.com/photo.gne?id=1562760533

追加例２：スポーツの種類を答える



質問の原文（全文）

> What sport is the man doing?

男性は何のスポーツをしているか。

snowboarding（スノーボード）

10 人中 10 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] BlueLight1990. DCIM_1. COCO 画像 ID 393284 。 CC BY-ND 2.0 。 question_id = 393284003 。 https://www.flickr.com/photos/klingele/4872033447/

追加例３：動作を答える



質問の原文（全文）

What is the man doing?

男性は何をしているか。

skiing （スキー）

10 人中 9 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] Trong Ton. End of ski season. COCO 画像 ID 132024 。 CC BY 2.0 。 question_id = 132024002 。 https://www.flickr.com/photos/trongton/8653774735/

追加例 4 ：動物の種類を答える



質問の原文（全文）

What animal is in the picture?

画像には何の動物が写っているか。

giraffe （キリン）

10 人中 9 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] Valerio Pillar. DSC_4172.JPG. COCO 画像 ID 524621 。 CC BY-NC-SA 2.0 。 question_id = 524621008 。 https://www.flickr.com/photos/vpillar/2873582007/

追加例 5 ：部屋の種類を答える



質問の原文（全文）

What room is this?

これは何の部屋か。

bathroom （浴室）

10 人中 10 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html

[2] geeksquadthe. Master Bedroom Bathroom Walk-In Shower - Village Lofts. COCO 画像 ID 262284 。 CC BY-NC-ND 2.0 。 question_id = 262284003 。 https://www.flickr.com/photos/101095425@N08/9627540643/

追加例 6 ：物がないことを答える



質問の原文（全文）

> Is there a mirror in the room?

部屋に鏡はあるか。

no （いいえ）

10 人中 10 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] COCO val2014 収録写真 . COCO 画像 ID 262162 。 CC BY-NC-ND 2.0 。 question_id = 262162016 。 https://www.flickr.com/photo.gne?id=4918042336

追加例 7 ：何の上に座るかを答える



質問の原文（全文）

> What is the woman sitting on?

女性は何に座っているか。

bench （ベンチ）

10 人中 10 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] DarkB4Dawn. Istanbul. COCO 画像 ID 524436 。 CC BY-NC-ND 2.0 。 question_id = 524436003 。 https://www.flickr.com/photos/darkb4dawn/6981041686/

追加例 8 ：建物の種類を答える



質問の原文（全文）

> What kind of building is this?

これは何の建物か。

church （教会）

10 人中 9 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html

[2] ell brown. St John's RC Cathedral - Alfred Road, Portsmouth - statue - St John. COCO 画像 ID 393288 。 CC BY 2.0 。 question_id = 393288000 。 https://www.flickr.com/photos/ell-r-brown/9324458628/

追加例 9 ：場所を答える



質問の原文（全文）

Where is the setting?

ここはどんな場所か。

kitchen （台所）

10 人中 10 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] J0nny_t. Kitchen. COCO 画像 ID 262682 。 CC BY-NC-ND 2.0 。 question_id = 262682015 。 https://www.flickr.com/photos/j0nny_t/7556152056/

追加例 10 ：服の模様を答える



質問の原文（全文）

Is the man wearing plaid pants?

男性はチェック柄のズボンをはいているか。

yes （はい）

10 人中 10 人の回答が一致。

[1] VQA Team. VQA v2.0 、 COCO val2014 の質問・回答注釈。 https://visualqa.org/download.html
[2] Bananaguay. Snow. COCO 画像 ID 200058 。 CC BY-SA 2.0 。 question_id = 200058000 。 https://www.flickr.com/photos/platano/2456758025/

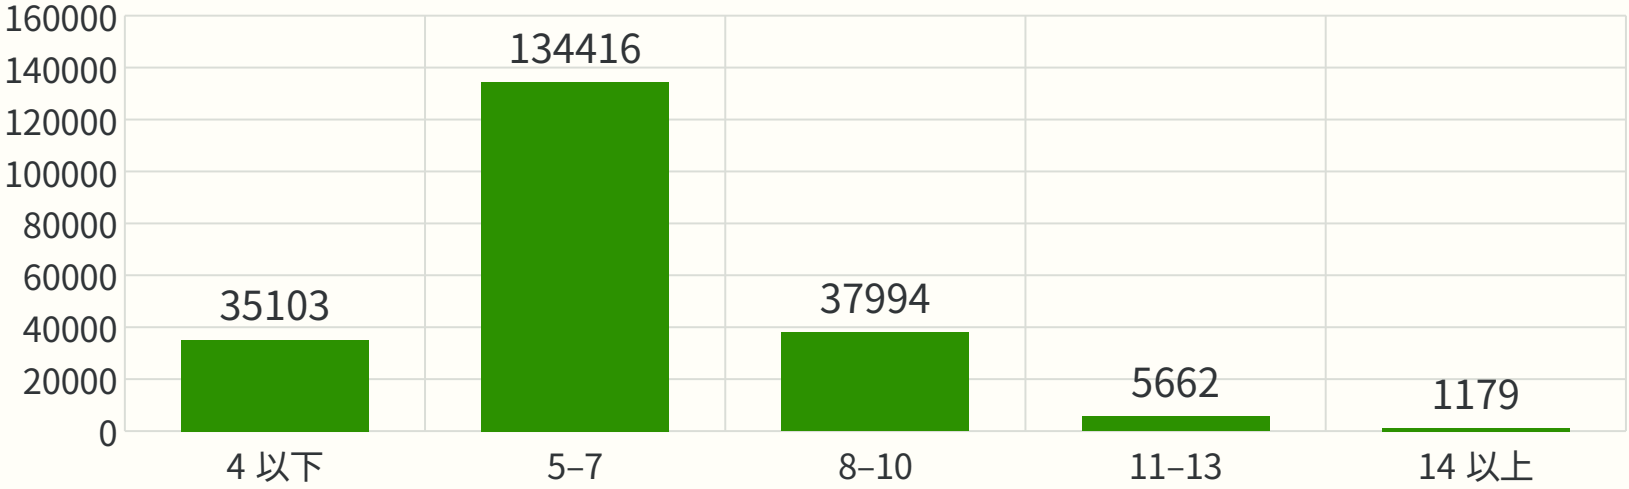
2. 質問と人の回答の集計

val の質問は、中央値で 6 単語

指標	質問の単語数
平均	6.2
中央値	6
母標準偏差	1.9
25 〜 75% 点	5 〜 7
95% 点	10

[1] VQA Team. VQA v2.0 val の 214,354 問・回答注釈を全件集計。 https://visualqa.org/download.html

質問の約 63% は 5 〜 7 単語で書かれている



横軸は空白区切りの単語数、縦軸は質問数。 val の 214,354 問を全件集計。

[1] VQA Team. VQA v2.0 val の 214,354 問・回答注釈を全件集計。 https://visualqa.org/download.html

回答が 10 人で完全に一致する質問は約 33%

最多の同一回答の件数	質問数
1 〜 3	27,778
4 〜 6	47,185
7 〜 9	69,163
10	70,228

正規化前の回答文字列を各問で集計。最多件数を求めて分類。採点の得点とは別の量。

[1] VQA Team. VQA v2.0 val の 214,354 問・回答注釈を全件集計。 https://visualqa.org/download.html

よくある質問の型も、見る対象が異なる

公式の question_type	val での質問数
how many	20,462
is the	17,265
what	15,897
what color is the	14,061
what is the	11,353

[1] VQA Team. VQA v2.0 val の 214,354 問・回答注釈を全件集計。 https://visualqa.org/download.html

3. 研究と参考文献

Goyal らが、質問への偏りを画像ペアで見直した

- Yash Goyal 、 Tejas Khot 、 Douglas Summers-Stay 、 Dhruv Batra 、 Devi Parikh が、 CVPR 2017 で VQA v2 の設計を発表した。
- 既存の VQA では、質問だけでも答えを推測できる偏りがあった。答えが変わる似た画像を追加し、画像理解の役割を高めた。
- 新たな問題を増やすだけでなく、質問と画像と答えの対応を作り直した点に特徴がある。

[1] Goyal et al. (2017). Making the V in VQA Matter: Elevating the Role of Image Understanding in Visual Question Answering. CVPR. https://arxiv.org/abs/1612.00837

参考文献

Making the V in VQA Matter: Elevating the Role of Image Understanding in Visual Question Answering

Goyal, Khot, Summers-Stay, Batra & Parikh (2017). CVPR.

補完画像の収集、 v1 と v2 の違い、モデルによる比較を説明する論文。

https://arxiv.org/abs/1612.00837

参考文献

BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models

Li, Li, Savarese & Hoi (2023). ICML.

画像モデルと言語モデルを接続し、 VQA v2 でゼロショットと微調整後を評価する。

https://arxiv.org/abs/2301.12597

参考文献

VQA v2.0 Download / Evaluation

VQA Team (n.d.). 2026-10-17 参照。

質問・注釈・画像の入手先と、回答の正規化・採点方法を確認できる。

https://visualqa.org/download.html

LAVIS: VQA task

Salesforce (n.d.). 改訂 05cb670 。 2026-10-17 参照。

モデルの回答の保存と、 VQA 評価ツールを用いる実装を確認できる。

https://github.com/salesforce/LAVIS/blob/main/lavis/tasks/vqa.py