WikiFact

知識基盤の事実を、文の続きとして答える

sasakiy84

1. 事実を文の続きで答える
2. 知識基盤から問題を作る
3. 参照回答に一致するかを評価する
4. データの入手と利用条件

事実を文の続きで答える

知識を、短い文の補完で尋ねる

WikiFact は、知識基盤 Wikidata の「主語・関係・目的語」という三つ組を、英語の短い文に変換した事実補完データである。

モデルは「作品の著者は」「国の通貨は」といった文の続きを生成する。根拠となる文章を与えず、モデルが覚えている事実を名前として答えられるかを測る。
Stanford CRFM を中心とする研究チームが 2022 年に設計した。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

正解の対象も、その呼び名も複数ある

同じ作品に複数の著者がいるように、一つの入力に複数の正解がある。また、一つの対象が複数の名前や略号を持つこともある。

正解となる対象の名前や別名のいずれかに一致すれば正解とする。次の 3 例は、公開されている入力と参照回答の全文である。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

実例 1 ：複数の著者と別名が正解になる

入力原文（全文）

The author of The Glass Inferno is

日本語訳（入力・答えの意味）

『 The Glass Inferno 』の著者は

参照回答（全文）

Thomas N. Scortia / Thomas Nicholas Scortia / Frank M. Robinson

Thomas N. Scortia Frank M. Robinson

2 人の著者のうち 1 人を答えればよい。 Thomas Nicholas Scortia と Thomas N. Scortia は、同じ著者の別名である。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例２：通貨の名前とコードを認める

入力原文（全文）

The currency of Indonesia is

日本語訳（入力・答えの意味）

インドネシアの通貨は

参照回答（全文）

rupiah / Rp / IDR / Indonesian rupiah

ルピア

名前、通貨記号 Rp 、通貨コード IDR を、いずれも参照回答として認める。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例３：事件名から原告を答える

入力原文（全文）

The plaintiff in USL v. BSDi is

参照回答（全文）

Unix System Laboratories

日本語訳（入力・答えの意味）

USL 対 BSDi 事件の原告は

Unix System Laboratories

事件名から、原告となった組織の名前を答える。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

知識基盤から問題を作る

一般的な関係から、専門領域の関係へ

2019 年の LAMA は、文の穴埋めを通して言語モデルの事実知識を調べる方法を広めた。

WikiFact では対象を法律・経済・生物医学などへ広げ、関係と英語テンプレートを人手で選んだ。

[1] Petroni et al. (2019), Language Models as Knowledge Bases? EMNLP-IJCNLP, 2463–2473. https://aclanthology.org/D19-1250/
[2] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

2022 年 1 月の Wikidata を使って変換する

選んだ関係の三つ組を、 2022 年 1 月の Wikidata dump から取得した。主語か目的語のいずれかに対応する Wikipedia ページがない三つ組を除いた。

関係ごとの英語テンプレートへ主語名を埋め込み、目的語の名前と別名を参照回答にする。関係・書式の選定は人手、各問題への変換は自動で行う。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

12 分野に 86 種類の関係を設けた

分野	関係数	分野	関係数
芸術	6	数学	2
法律	7	計算機科学	4
哲学	2	物理	2
政治	8	化学	5
地理	6	生物医学	5
経済	5	一般的事項	34

一般的事項には、出生地・職業・所属・分類などを含む。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

関係ごとに、学習・開発・テストへ分ける

用途	関係 1 種類当たりの設計
train	100 問：プロンプトに示す例の候補
dev	50 問：開発用
test	850 問：テスト用

通常は、関係ごとに 1,000 問を抽出して分割する。公開テストでは、問題数がこれより少ない関係もある。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

参照回答に一致するかを評価する

参照のいずれかに一致すれば正解になる

生成した名前が、参照回答のいずれかに一致した割合で正答率を求める。照合では英字の大小、冠詞、句読点、余分な空白をならす。

一つの答えだけを見る Accuracy@1 と、複数候補のどれかが合えばよい Accuracy@K では、正解とする条件が変わる。次の出力例では、先頭候補と 5 候補全体を比べる。

[1] Stanford CRFM. evaluate_reference_metrics 。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/metrics/evaluate_reference_metrics.py

略称が、参照回答に含まれない場合

順位	生成候補（全文）	正規化後の一致
1	USL	0
2	Unisys Corporation	0
3	Unisys Corporation	0
4	Unix System Laboratories.	1
5	The United States of America	0

2023 年の公開出力例（ text-davinci-003 ）。先頭候補は不一致、 5 候補の中には一致する答えがある。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

参照に含まれる名前が、正誤を左右する

実例 3 の USL という略称は、参照回答に含まれていない。人が同じ組織を思い浮かべても、参照に一致する名前でなければ正解にならない。

知識基盤の名前や別名の収録範囲が、評価に影響する。複数の参照を持つ場合は、そのうち一つに合う補完を求める。

[1] Stanford CRFM. evaluate_reference_metrics 。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/metrics/evaluate_reference_metrics.py

データの入手と利用条件

配布 JSONL と、公開例から利用を始める

全 86 関係の問題は、 CodaLab の train ・ dev ・ test JSONL として案内されている。データの読込実装は、関係を指定して文章と参照回答を取り出す。

公式サイトでは、 10 関係の公開入力・参照回答・出力を閲覧できる。問題の形を調べたり、名前の照合を試したりするために使える。

[1] Stanford CRFM. WIKIFactScenario 。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/wikifact_scenario.py

読込コードと、加工済みデータの利用条件

公開されている読込実装は Apache License 2.0 で提供される。加工済み WikiFact データの専用ライセンスは、論文と読込コードには明記されていない。

データを再配布・再利用する際の条件は、配布元への確認が必要である。

[1] Stanford CRFM. Apache License 2.0 （読込コード）。 https://github.com/stanford-crfm/helm/blob/main/LICENSE

専門領域の知識を、名前の補完で測る

WikiFact は、 Wikidata 由来の 86 関係を文の補完へ変え、一般的な事実から法律・経済・生物医学までを扱う。複数の対象や別名を正解として持つ。

根拠文を与えず、モデルが事実を表す名前を答えられるかを調べる。入力の関係や知識の時点、参照に含まれる名前の範囲が評価の意味を決める。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

Appendix

1. 追加の実例
2. 公開例のデータ形式
3. 研究と参考文献

追加の実例

実例 4 ：固有名をカテゴリに結び付ける

入力原文（全文）

WZRO-LP is an instance of

日本語訳（入力・答えの意味）

WZRO-LP は次の種類に当たる：

参照回答（全文）

radio station / radio broadcasting station

ラジオ局

二つの英語表現が同じカテゴリを表す参照になっている。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 5 ：薬剤と治療対象を結び付ける

入力原文（全文）

caramiphen has effects on diseases such as

日本語訳（入力・答えの意味）

カラミフェンが作用する疾患・症状には、次がある：

参照回答（全文）

cough / coughing

咳

Wikidata の関係を補完する課題。ここでは cough と coughing が参照に入る。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 6 ：役職と組織の包含関係

入力原文（全文）

Taoiseach is part of

参照回答（全文）

Government of Ireland / Cabinet of Ireland

日本語訳（入力・答えの意味）

アイルランド首相（ Taoiseach ）が属するのは

アイルランド政府

Government of Ireland と Cabinet of Ireland を参照とする。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例７：出生地を地名で答える

入力原文（全文）

AURORA was born in

日本語訳（入力・答えの意味）

AURORA が生まれた場所は

参照回答（全文）

Stavanger / Stavanger, Rogaland, Norway / Stavanger, Norway

スタヴァンゲル

都市名だけの表記と、国名・地域名を添えた表記を認める。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 8 ：医学的評価法の考案者を答える

入力原文（全文）

Apgar score was discovered by

日本語訳（入力・答えの意味）

アプガースコアを考案したのは

参照回答（全文）

Virginia Apgar / Virginia Agpar / Virginia Apgar

バージニア・アプガー

医学的評価法の考案者を「 discovered by 」というテンプレートで尋ねる。参照には Virginia Agpar という表記や、同じ名前の重複が含まれる。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例９：人物が務める役職を答える

入力原文（全文）

The position held by Alison Foster is

日本語訳（入力・答えの意味）

アリソン・フォスターの役職は

参照回答（全文）

High Court judge

高等法院判事

人物と役職の関係を尋ねる。参照回答は高等法院判事である。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 10 ：病態から症状・徴候を答える

入力原文（全文）

secondary hypertrophic osteoarthropathy has symptoms such as

日本語訳（入力・答えの意味）

続発性肥大性骨関節症の症状・徴候には、次がある：

参照回答（全文）

nail clubbing / digital clubbing / clubbing of fingers / Hippocratic fingers / finger clubbing

ばち指

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 11 ：古典作品の著者を答える

入力原文（全文）

The author of Dialectics of Nature is

日本語訳（入力・答えの意味）

『自然弁証法』の著者は

フリードリヒ・エンゲルス

参照回答（全文）

Friedrich Engels / F. Engels / Frederik Engels / Friedrich Engles

イニシャル表記などを含む複数の別名が参照になる。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 12 ：歴史上の地域の通貨

入力原文（全文）

The currency of British Cyprus is

日本語訳（入力・答えの意味）

イギリス領キプロスの通貨は

参照回答（全文）

Cypriot pound / Cypriot lira

キプロス・ポンド

イギリス領キプロスで用いられた通貨を尋ねる。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 13 ：参照に日本語表記が含まれる

入力原文（全文）

(5353) 1989 YT was discovered by

日本語訳（入力・答えの意味）

(5353) 1989 YT を発見したのは

参照回答（全文）

Yoshiaki Oshima / おおしま よしあき

大島良明

入力は英語のテンプレートだが、参照の別名には日本語表記も含まれる。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

公開例のデータ形式

公開例の JSON から、入力と参照を読む

```
import json
with open("scenario_state.json", encoding="utf-8") as f:
    state = json.load(f)
example = state["request_states"][0]["instance"]
print(example["input"]["text"])
print([r["output"]["text"] for r in example["references"]])
```

scenario_state.json は、公開された評価記録の JSON 。各問の入力、参照回答、モデル出力を収める。

[1] Stanford CRFM (2023). WikiFact — 公開入力・参照回答。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

研究と参考文献

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. · 2023 · Transactions on Machine Learning Research

多面的な言語モデル評価を設計し、知識評価の新規データとして WikiFact を構築した。

https://arxiv.org/abs/2211.09110

Language Models as Knowledge Bases?

Fabio Petroni et al. · 2019 · EMNLP-IJCNLP, 2463–2473

文の穴埋めを通して事実知識を取り出す LAMA を提案し、言語モデルの知識表現を分析する。

https://aclanthology.org/D19-1250/

参考文献

WikiFact

Stanford CRFM (2023). 公開入力・参照回答。参照 2026-10-18 。

関係ごとの入力、参照回答、既存モデル出力を閲覧できる。

https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

WIKIFactScenario

Stanford CRFM (n.d.). 公開読込実装。参照 2026-10-18 。

86 関係の ID と、問題・参照回答を JSONL から読み込む手順を定義する。

https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/wikifact_scenario.py