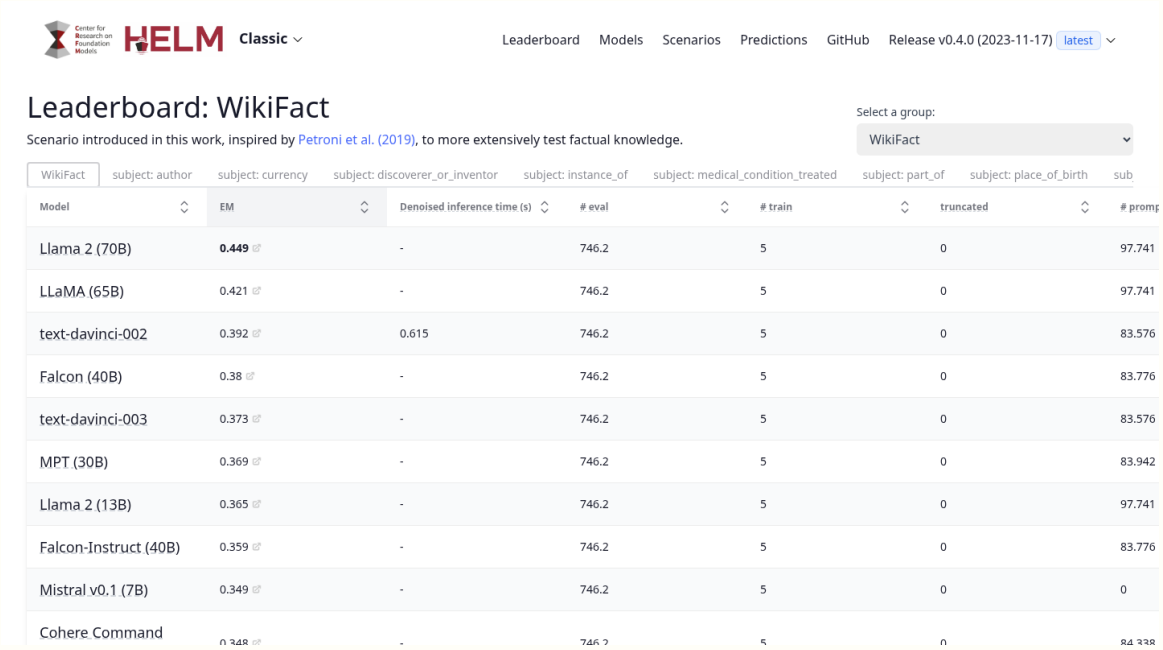
WikiFact

知識基盤の事実を、文の続きとして答える

sasakiy84

公式 HELM サイト： WikiFact の公開結果



HELM Classic — Leaderboard Models Scenarios Predictions GitHub Release v0.4.0 (2023-11-17) latest

Leaderboard: WikiFact

Scenario introduced in this work, inspired by Petroni et al. (2019), to more extensively test factual knowledge.

Select a group: WikiFact

WikiFact | subject: author | subject: currency | subject: discoverer_or_inventor | subject: instance_of | subject: medical_condition_treated | subject: part_of | subject: place_of_birth | sub

Model	EM	Denoised inference time (s)	# eval	# train	truncated	# promp
Llama 2 (70B)	**0.449**	-	746.2	5	0	97.741
LLaMA (65B)	0.421	-	746.2	5	0	97.741
text-davinci-002	0.392	0.615	746.2	5	0	83.576
Falcon (40B)	0.38	-	746.2	5	0	83.776
text-davinci-003	0.373	-	746.2	5	0	83.576
MPT (30B)	0.369	-	746.2	5	0	83.942
Llama 2 (13B)	0.365	-	746.2	5	0	97.741
Falcon-Instruct (40B)	0.359	-	746.2	5	0	83.776
Mistral v0.1 (7B)	0.349	-	746.2	5	0	0
Cohere Command	0.348	-	746.2	5	0	84.338

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

1. 事実を文の続きで答える
2. 知識基盤から問題を作る
3. HELM の採点と公開成績
4. 利用の位置付けと入手方法

事実を文の続きで答える

知識を、短い文の補完で尋ねる

WikiFact は、知識基盤 Wikidata の「主語・関係・目的語」という三つ組を、英語の短い文に変換した事実補完データである。

モデルは「作品の著者は」「国の通貨は」といった文の続きを生成する。根拠となる文章を与えず、モデルが覚えている事実を名前として答えられるかを測る。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

正解の対象も、その呼び名も複数ある

同じ作品に複数の著者がいるように、一つの入力に複数の正解がある。また、一つの対象が複数の名前や略号を持つこともある。

正解となる対象の名前や別名のいずれかに一致すれば正解とする。次の 3 例は、公開実行の入力と参照回答の全文である。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

実例１：複数の著者と別名が正解になる

入力原文（全文）

The author of The Glass Inferno is

日本語訳（入力・答えの意味）

『The Glass Inferno』の著者は

参照回答（全文）

Thomas N. Scortia / Thomas Nicholas Scortia / Frank M. Robinson

Thomas N. Scortia Frank M. Robinson

2 人の著者のうち 1 人を答えればよい。 Thomas Nicholas Scortia と Thomas N. Scortia は、同じ著者の別名である。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例２：通貨の名前とコードを認める

入力原文（全文）

The currency of Indonesia is

日本語訳（入力・答えの意味）

インドネシアの通貨は

参照回答（全文）

rupiah / Rp / IDR / Indonesian rupiah

ルピア

名前、通貨記号 Rp 、通貨コード IDR を、いずれも参照回答として認める。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例３：事件名から原告を答える

入力原文（全文）

The plaintiff in USL v. BSDi is

参照回答（全文）

Unix System Laboratories

日本語訳（入力・答えの意味）

USL 対 BSDi 事件の原告は

Unix System Laboratories

事件名から、原告となった組織の名前を答える。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

候補を五つ作り、対数確率で順位を付ける

HELM では、 1 問当たり 5 候補を生成する設定を使う。出力の対数確率の和で並べ、最上位の候補を Accuracy@1 で採点する。

Accuracy@5 では、最大 5 候補のどれかが参照回答に一致すれば正解。文字列を小文字化し、冠詞・句読点・余分な空白を除いて照合する。

[1] Stanford CRFM. HELM evaluate_reference_metrics 。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/metrics/evaluate_reference_metrics.py

実例 3 の公開モデル出力と採点

順位	生成候補（全文）	正規化後の一致
1	USL	0
2	Unisys Corporation	0
3	Unisys Corporation	0
4	Unix System Laboratories.	1
5	The United States of America	0

text-davinci-003 、第 1 試行。 @1 は 0 、 @5 は 1 （ USL は参照にない）。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （ 2023 ）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

知識基盤から問題を作る

一般的な関係から、専門領域の関係へ

2019 年の LAMA は、文の穴埋めを通して言語モデルの事実知識を調べる方法を広めた。

HELM ではより幅広い知識を対象にするため、法律・経済・生物医学などの関係とテンプレートを手で選び、 WikiFact を作った。

[1] Petroni et al. (2019), Language Models as Knowledge Bases? EMNLP-IJCNLP, 2463–2473. https://aclanthology.org/D19-1250/
[2] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

2022 年 1 月の Wikidata を使って変換する

選んだ関係の三つ組を、 2022 年 1 月の Wikidata dump から取得した。主語か目的語のいずれかに対応する Wikipedia ページがない三つ組を除いた。

関係ごとの英語テンプレートへ主語名を埋め込み、目的語の名前と別名を参照回答にする。関係・書式の選定は人手、各問題への変換は自動で行う。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

12 分野に 86 種類の関係を設けた

分野	関係数	分野	関係数
芸術	6	数学	2
法律	7	計算機科学	4
哲学	2	物理	2
政治	8	化学	5
地理	6	生物医学	5
経済	5	一般的事項	34

一般的事項には、出生地・職業・所属・分類などを含む。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

関係ごとに、学習・開発・テストへ分ける

用途	関係 1 種類当たりの設計
train	100 問：プロンプトに示す例の候補
dev	50 問：開発用
test	850 問：テスト用

通常は、関係ごとに 1,000 問を抽出して分割する。公開テストでは、問題数がこれより少ない関係もある。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

Classic の公開実行は 10 関係を含む

関係群	test 件数／関係	関係数
著者・通貨など	850	8
原告	96	1
症状・徴候	566	1

公開テストは計 7,462 問で、 86 関係のうち 10 関係を対象とする。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

HELM の採点と公開成績

公開結果は、関係ごとの正答率を平均する

各関係の test で、最上位候補が参照回答に一致した割合を求める。その後、 10 関係の正答率を同じ重みで平均する。

96 問の原告も、 850 問の著者も、全体の得点には同じ重みで反映される。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （ 2023 ）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

モデルごとに、候補数と評価回数が異なる

OPT-175B と text-davinci-003 は、 1 問につき 5 候補を生成し、対数確率が最大の候補を採点する。異なる提示例を使う 3 試行の正答率を平均した。

Llama 2 70B の公開出力は 1 問につき 1 候補で、評価は 1 試行である。そのため Accuracy@1 と @5 は同じ値になる。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

HELM Classic の Accuracy@1

モデル（公開年）	10 関係平均（%）
OPT-175B （2022）	22.03
text-davinci-003 （2022）	37.34
Llama 2 70B （2023）	44.92

HELM Classic で 2023 年に公開された結果。各問に最大 5 例を提示。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

関係によって正答率は大きく違う

関係	OPT-175B	davinci-003	Llama 2 70B
通貨	42.16	57.10	62.71
発見者・発明者	6.27	17.88	26.12
出生地	3.33	16.43	22.94
原告	50.69	60.42	68.75

Accuracy@1 （％）。各関係を独立に評価。候補数は 5 ／ 5 ／ 1 、試行数は 3 ／ 3 ／ 1 。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

短い補完でも、参照と生成形式が効く

実例 3 では USL という略称は参照に含まれず、会社名の全文が必要だった。正規化は略語の展開や、意味の同一性の推論を行わない。

出力上限は 8 トークンなので、長い固有名や複数の答えをまとめる出力は途中で切れる場合がある。参照のいずれか一つに合う短い補完を求める評価となる。

[1] Stanford CRFM. HELM evaluate_reference_metrics 。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/metrics/evaluate_reference_metrics.py

利用の位置付けと入手方法

根拠文を与えずに、事実知識を尋ねる

WikiFact は、主語と関係を示す短い文から、目的語となる名前を生成する。文章中の根拠を読み取る読解課題や、検索器で根拠を探す課題とは入力が異なる。

HELM の公開実装は 86 関係に対応する。ここで紹介した 2023 年の公開成績は、そのうち 10 関係に対するものである。

[1] Stanford CRFM. HELM WIKIFactScenario 。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/wikifact_scenario.py

公式サイトで、関係別の成績と出力を見られる

公式 HELM ページでは、 WikiFact の関係別・モデル別成績と、各問の入力・参照回答・生成結果を閲覧できる。

全 86 関係の問題は、 CodaLab の train ・ dev ・ test JSONL として案内されている。公式サイトでは、 10 関係の公開実行に含まれる入力・参照回答・出力を利用できる。

[1] Stanford CRFM. HELM WIKIFactScenario 。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/wikifact_scenario.py

実装コードは Apache 2.0 で公開される

HELM の実装コードは Apache License 2.0 で公開される。加工済み WikiFact データの専用ライセンスは、公式論文と読込コードには明記されていない。

データを再配布・再利用する際の条件は、配布元への確認が必要である。

[1] Stanford CRFM, HELM. Apache License 2.0 （コード）。 https://github.com/stanford-crfm/helm/blob/main/LICENSE

専門領域の知識を、名前の補完で測る

WikiFact は、 Wikidata 由来の 86 関係を文の補完へ変え、一般的な事実から法律・経済・生物医学までを扱う。複数の対象や別名を正解として持つ。

HELM Classic の公開成績は 10 関係の正答率を同じ重みで平均する。候補数の違いと、参照に含まれる名前の範囲が得点に影響する。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

Appendix

1. 追加の実例
2. 関係別成績とデータの読込
3. 研究と参考文献

追加の実例

実例 4 ：固有名をカテゴリに結び付ける

入力原文（全文）

WZRO-LP is an instance of

日本語訳（入力・答えの意味）

WZRO-LP は次の種類に当たる：

参照回答（全文）

radio station / radio broadcasting station

ラジオ局

二つの英語表現が同じカテゴリを表す参照になっている。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 5 ：薬剤と治療対象を結び付ける

入力原文（全文）

caramiphen has effects on diseases such as

日本語訳（入力・答えの意味）

カラミフェンが作用する疾患・症状には、次がある：

参照回答（全文）

cough / coughing

咳

Wikidata の関係を補完する課題。ここでは cough と coughing が参照に入る。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （ 2023 ）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 6 ：役職と組織の包含関係

入力原文（全文）

Taoiseach is part of

参照回答（全文）

Government of Ireland / Cabinet of Ireland

日本語訳（入力・答えの意味）

アイルランド首相（ Taoiseach ）が属するのは

アイルランド政府

Government of Ireland と Cabinet of Ireland を参照とする。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （ 2023 ）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 7 ：出生地を地名で答える

入力原文（全文）

AURORA was born in

日本語訳（入力・答えの意味）

AURORA が生まれた場所は

参照回答（全文）

Stavanger / Stavanger, Rogaland, Norway / Stavanger, Norway

スタヴァンゲル

都市名だけの表記と、国名・地域名を添えた表記を認める。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 8 ：医学的評価法の考案者を答える

入力原文（全文）

Apgar score was discovered by

日本語訳（入力・答えの意味）

アプガースコアを考案したのは

参照回答（全文）

Virginia Apgar / Virginia Agpar / Virginia Apgar

バージニア・アプガー

医学的評価法の考案者を「 discovered by 」というテンプレートで尋ねる。参照には Virginia Agpar という表記や、同じ名前の重複が含まれる。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （ 2023 ）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例９：人物が務める役職を答える

入力原文（全文）

The position held by Alison Foster is

日本語訳（入力・答えの意味）

アリソン・フォスターの役職は

参照回答（全文）

High Court judge

高等法院判事

人物と役職の関係を尋ねる。参照回答は高等法院判事である。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 10 ：病態から症状・徴候を答える

入力原文（全文）

secondary hypertrophic osteoarthropathy has symptoms such as

日本語訳（入力・答えの意味）

続発性肥大性骨関節症の症状・徴候には、次がある：

参照回答（全文）

nail clubbing / digital clubbing / clubbing of fingers / Hippocratic fingers / finger clubbing

ばち指

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 11 ：古典作品の著者を答える

入力原文（全文）

The author of Dialectics of Nature is

日本語訳（入力・答えの意味）

『自然弁証法』の著者は

フリードリヒ・エンゲルス

参照回答（全文）

Friedrich Engels / F. Engels / Frederik Engels / Friedrich Engles

イニシャル表記などを含む複数の別名が参照になる。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 12 ：歴史上の地域の通貨

入力原文（全文）

The currency of British Cyprus is

日本語訳（入力・答えの意味）

イギリス領キプロスの通貨は

参照回答（全文）

Cypriot pound / Cypriot lira

キプロス・ポンド

イギリス領キプロスで用いられた通貨を尋ねる。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 13 ：参照に日本語表記が含まれる

入力原文（全文）

(5353) 1989 YT was discovered by

日本語訳（入力・答えの意味）

(5353) 1989 YT を発見したのは

参照回答（全文）

Yoshiaki Oshima / おおしま よしあき

大島良明

入力は英語のテンプレートだが、参照の別名には日本語表記も含まれる。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

関係別成績とデータの読込

10 関係の Accuracy@1 （前半）

関係	OPT-175B	davinci-003	Llama 2
著者	17.06	53.76	61.53
通貨	42.16	57.10	62.71
発見者・発明者	6.27	17.88	26.12
分類	34.24	45.73	60.47
治療対象	19.65	46.67	52.12

単位は % 。候補数は 5 ／ 5 ／ 1 、試行数は 3 ／ 3 ／ 1 。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （ 2023 ）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

10 関係の Accuracy@1 （後半）

関係	OPT-175B	davinci-003	Llama 2
部分・所属先	18.00	30.63	18.24
出生地	3.33	16.43	22.94
原告	50.69	60.42	68.75
役職	9.02	16.31	31.29
症状・徴候	19.91	28.45	45.05

単位は % 。候補数は 5 ／ 5 ／ 1 、試行数は 3 ／ 3 ／ 1 。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （ 2023 ）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

5 候補のどれかが合えば正解となる評価

モデル	Accuracy@1（%）	Accuracy@5（%）
OPT-175B	22.03	32.28
text-davinci-003	37.34	44.03

10 関係を同じ重みで平均し、3 試行を平均した値。

[1] Stanford CRFM. HELM Classic v0.4.0 — WikiFact （2023）。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

公開実行の JSON から、入力と参照を読む

```
import json
with open("scenario_state.json", encoding="utf-8") as f:
    state = json.load(f)
example = state["request_states"][0]["instance"]
print(example["input"]["text"])
print([r["output"]["text"] for r in example["references"]])
```

scenario_state.json は、公式 HELM の公開実行に付随する JSON ファイル。各問の入力、参照回答、モデル出力を収める。

[1] Stanford CRFM. HELM WIKIFactScenario 。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/wikifact_scenario.py

研究と参考文献

専門領域まで広げた、 HELM の事実知識評価

WikiFact は、 HELM の事実知識評価のために新しく作られた。 Hongyu Ren 、 Lucia Zheng 、 Michihiro Yasunaga らが制作に参加した。

文の補完という LAMA の形式を受け継ぎ、法律・経済・生物医学など幅広い分野へ対象を広げた。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. · 2023 · Transactions on Machine Learning Research

多面的な言語モデル評価を設計し、知識評価の新規データとして WikiFact を構築した。

https://arxiv.org/abs/2211.09110

Language Models as Knowledge Bases?

Fabio Petroni et al. · 2019 · EMNLP-IJCNLP, 2463–2473

文の穴埋めを通して事実知識を取り出す LAMA を提案し、言語モデルの知識表現を分析する。

https://aclanthology.org/D19-1250/

参考文献

HELM Classic — WikiFact

Stanford CRFM (2023). v0.4.0 （ 2023-11-17 ）。参照 2026-10-18 。

関係別・モデル別の公開成績と予測記録をまとめる。

https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

HELM WIKIFactScenario

Stanford CRFM (n.d.). 公開実装。参照 2026-10-18 。

86 関係の ID と、問題・参照回答を JSONL から読み込む手順を定義する。

https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/wikifact_scenario.py