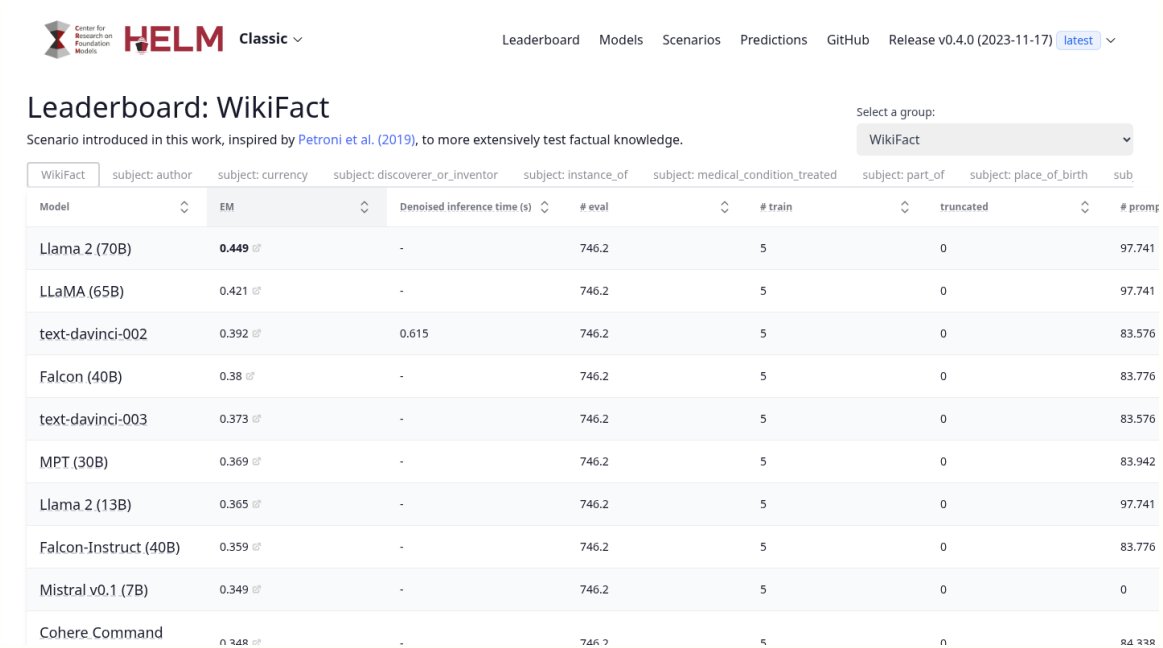
WikiFact

知識基盤の事実を、文の続きとして答える

sasakiy84

公式 HELM サイト： WikiFact の公開結果



HELM Classic — Leaderboard Models Scenarios Predictions GitHub Release v0.4.0 (2023-11-17) latest

Leaderboard: WikiFact

Scenario introduced in this work, inspired by Petroni et al. (2019), to more extensively test factual knowledge.

Select a group: WikiFact

WikiFact | subject: author | subject: currency | subject: discoverer_or_inventor | subject: instance_of | subject: medical_condition_treated | subject: part_of | subject: place_of_birth | sub

Model	EM	Denoised inference time (s)	# eval	# train	truncated	# promp
Llama 2 (70B)	**0.449**	-	746.2	5	0	97.741
LLaMA (65B)	0.421	-	746.2	5	0	97.741
text-davinci-002	0.392	0.615	746.2	5	0	83.576
Falcon (40B)	0.38	-	746.2	5	0	83.776
text-davinci-003	0.373	-	746.2	5	0	83.576
MPT (30B)	0.369	-	746.2	5	0	83.942
Llama 2 (13B)	0.365	-	746.2	5	0	97.741
Falcon-Instruct (40B)	0.359	-	746.2	5	0	83.776
Mistral v0.1 (7B)	0.349	-	746.2	5	0	0
Cohere Command	0.348	-	746.2	5	0	84.338

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

1. 事実を文の続きで答える
2. 知識基盤から問題を作る
3. HELM の採点と公開成績
4. 利用の位置付けと入手方法

事実を文の続きで答える

知識を、短い文の補完で尋ねる

WikiFact は、知識基盤 Wikidata の「主語・関係・目的語」という三つ組を、英語の短い文に変換した事実補完データ。

モデルは「作品の著者は」「国の通貨は」といった文の続きを生成する。本文を検索する段階を設けず、知識を表す名前を出力できるかを測る。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

正解の対象も、その呼び名も複数ある

同じ作品に複数の著者がいるように、同じ入力から複数の対象を答えられる。また、一つの対象が複数の名前や略号を持つこともある。

いずれかの許容対象の、いずれかの別名に一致すれば正解とする。次の 3 例は、公開実行の入力と参照回答の全文を示す。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

実例１：複数の著者と別名が正解になる

入力原文（全文）

The author of The Glass Inferno is

日本語訳（入力・答えの意味）

『The Glass Inferno』の著者は

参照回答（全文・重複を含む）

Thomas N. Scortia / Thomas Nicholas Scortia / Frank M. Robinson

Thomas N. Scortia
Frank M. Robinson

2 人の著者のうち 1 人を答えればよい。 Thomas Nicholas Scortia は Thomas N. Scortia の別名で、 3 人目ではない。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / author/id151 （HELM 内 ID）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例２：通貨の名前とコードを認める

入力原文（全文）

The currency of Indonesia is

日本語訳（入力・答えの意味）

インドネシアの通貨は

参照回答（全文・重複を含む）

rupiah / Rp / IDR / Indonesian rupiah

ルピア

名前、通貨記号 Rp 、通貨コード IDR を、いずれも参照回答として認める。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / currency/id156 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例３：事件名から原告を答える

入力原文（全文）

The plaintiff in USL v. BSDi is

参照回答（全文・重複を含む）

Unix System Laboratories

日本語訳（入力・答えの意味）

USL 対 BSDi 事件の原告は

Unix System Laboratories

訴訟の当事者という関係を扱う。参照は 1 文字列。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / plaintiff/id47 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

候補を五つ作り、対数確率で順位を付ける

HELM では、 1 問当たり 5 候補を生成する設定を使う。出力の対数確率の和で並べ、最上位の候補を Accuracy@1 で採点する。

Accuracy@5 では、最大 5 候補のどれかが参照回答に一致すれば正解。文字列を小文字化し、冠詞・句読点・余分な空白を除いて照合する。

[1] Stanford CRFM, HELM evaluate_reference_metrics. 候補の順位付け・正規化・ @K 採点。 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/metrics/evaluate_reference_metrics.py

実例 3 の公開モデル出力と採点

順位	生成候補（全文）	正規化後の一致
1	USL	0
2	Unisys Corporation	0
3	Unisys Corporation	0
4	Unix System Laboratories.	1
5	The United States of America	0

text-davinci-003 、第 1 試行。 @1 は 0 、 @5 は 1 （ USL は参照にない）。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

知識基盤から問題を作る

一般的な関係から、専門領域の関係へ

2019 年の LAMA は、文の穴埋めを通して言語モデルの事実知識を調べる方法を広めた。

HELM ではより幅広い知識を対象にするため、法律・経済・生物医学などの関係とテンプレートを手で選び、 WikiFact を作った。

[1] Petroni et al. (2019), Language Models as Knowledge Bases? EMNLP-IJCNLP, 2463–2473. https://aclanthology.org/D19-1250/
[2] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

2022 年 1 月の Wikidata を使って変換する

選んだ関係の三つ組を、 2022 年 1 月の Wikidata dump から取得した。主語か目的語のいずれかに対応する Wikipedia ページがない三つ組を除いた。

関係ごとの英語テンプレートへ主語名を埋め込み、目的語の名前と別名を参照回答にする。関係・書式の選定は人手、各問題への変換は自動で行う。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

12 分野に 86 種類の関係を設けた

分野	関係数	分野	関係数
芸術	6	数学	2
法律	7	計算機科学	4
哲学	2	物理	2
政治	8	化学	5
地理	6	生物医学	5
経済	5	一般的事項	34

一般的事項には、出生地・職業・所属・分類などを含む。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

通常の分割は 100 ／ 50 ／ 850 問

用途	関係 1 種類当たりの設計
train	100 問：プロンプトに示す例の候補
dev	50 問：開発用
test	850 問：テスト用

1 関係 1,000 問を標本抽出する設計。公開実行では、これより少ない関係もある。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

Classic の公開実行は 10 関係を含む

関係群	test 件数／関係	関係数
著者・通貨など	850	8
原告	96	1
症状・徴候	566	1

試行間の同一 ID をまとめた test は計 7,462 問。実装が対応する 86 関係の全件実行ではない。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

HELM の採点と公開成績

公開結果は、関係ごとの正答率を平均する

各関係の test に対し、最上位候補が参照に一致した割合を計算する。その後、 10 関係の正答率を同じ重みで平均した値が全体の指標。

96 問の原告も、 850 問の著者も、全体平均では同じ 1 関係として扱われる。全 7,462 問の正誤をそのまま平均した値ではない。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

候補数と試行数も、モデルで違っていた

OPT と text-davinci-003 は、 5 候補から対数確率最大の候補を選び、各 3 試行の正答率を平均した。

Llama 2 70B は 1 試行。設定上は 5 出力だが、取得した全 7,462 件の test レコードには、それぞれ 1 候補の出力が含まれていた。

そのため、 Llama 2 の公開 Accuracy@1 と @5 は同じ値になる。 5 候補を生成した条件として比較する値ではない。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

HELM Classic の Accuracy@1

モデル（公開年）	10 関係平均（%）
OPT-175B （2022）	22.03
text-davinci-003 （2022）	37.34
Llama 2 70B （2023）	44.92

v0.4.0 収録・ suite v0.3.0 。最大 5 提示例、 temperature 1 、出力上限 8 トークン。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

関係によって正答率は大きく違う

関係	OPT-175B	davinci-003	Llama 2 70B
通貨	42.16	57.10	62.71
発見者・発明者	6.27	17.88	26.12
出生地	3.33	16.43	22.94
原告	50.69	60.42	68.75

Accuracy@1 （%）。各関係を独立に評価。候補数は 5 ／ 5 ／ 1 、試行数は 3 ／ 3 ／ 1 。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

短い補完でも、参照と生成形式が効く

実例 3 では USL という略称は参照に含まれず、会社名の全文が必要だった。正規化は略語の展開や、意味の同一性の推論を行わない。

出力上限は 8 トークンなので、長い固有名や複数の答えをまとめる出力は途中で切れる場合がある。参照のいずれか一つに合う短い補完を求める評価となる。

[1] Stanford CRFM, HELM evaluate_reference_metrics. 候補の順位付け・正規化・ @K 採点。 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/metrics/evaluate_reference_metrics.py

利用の位置付けと入手方法

文脈の読解と切り分けて、事実知識を測る

WikiFact は、文章に根拠が含まれる読解や、検索器が根拠を探す課題と異なり、主語と関係だけから目的語名を生成する。

2026-10-18 確認の HELM 実装にも 86 関係の読込がある。今回扱う公開成績は 2023 年の Classic 固定版で、現在の知識や最新モデルを評価したものではない。

[1] Stanford CRFM, HELM WIKIFactScenario. 86 関係の辞書と配布ファイルの読込。 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/wikifact_scenario.py

配布ファイルと、実行記録への入口

公式 HELM ページから WikiFact の条件別成績と予測へ進める。シナリオコードは CodaLab の train/dev/test JSONL を読み込む。

今回、 CodaLab は 3 ファイルとも 503 となった。一方、公開 run の 10 関係の入力・参照・生成結果と、 3 モデル 30 条件の得点は取得できた。

全 86 関係の元 JSONL は未取得で、全体の総件数や全関係のデータ分布は今回の実測対象に含めていない。

[1] Stanford CRFM, HELM WIKIFactScenario. 86 関係の辞書と配布ファイルの読込。 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/wikifact_scenario.py

権利条件はコードとデータを区別する

HELM の実装コードは Apache License 2.0 で公開される。元の Wikidata と、加工された WikiFact 配布物の権利条件は、コードの条件とは別に確認する。

今回取得したシナリオコードと論文では、 WikiFact の加工済みデータ全体への専用ライセンス表示は確認できなかった。利用する配布物の条件は、配布元へ照会する必要がある。

[1] Stanford CRFM, HELM. Apache License 2.0 （コード）。 https://github.com/stanford-crfm/helm/blob/main/LICENSE

知識の範囲と、答え方をそろえて読む

WikiFact は、専門領域を含む 86 関係を、 Wikidata 由来の事実補完へ変えたデータ。複数対象と別名を参照として持つ。

Classic で実行された 10 関係では、問題数も候補数も条件によって違う。各関係を同じ重みで平均する方法と、文字列の正規化、生成候補数をそろえて、公開成績を解釈する。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

Appendix

1. 追加の実例
2. 関係別成績と実行条件
3. 制作チームと参考文献

追加の実例

実例 4 ：固有名をカテゴリに結び付ける

入力原文（全文）

WZRO-LP is an instance of

日本語訳（入力・答えの意味）

WZRO-LP は次の種類に当たる：

参照回答（全文・重複を含む）

radio station / radio broadcasting station

ラジオ局

二つの英語表現が同じカテゴリを表す参照になっている。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / instance_of/id150 （HELM 内 ID）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 5 ：薬剤と治療対象を結び付ける

入力原文（全文）

caramiphen has effects on diseases such as

日本語訳（入力・答えの意味）

カラミフェンが作用する疾患・症状には、次がある：

参照回答（全文・重複を含む）

cough / coughing

咳

Wikidata の関係を補完する課題。ここでは cough と coughing が参照に入る。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / medical_condition_treated/id152 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 6 ：役職と組織の包含関係

入力原文（全文）

Taoiseach is part of

日本語訳（入力・答えの意味）

アイルランド首相（ Taoiseach ）が属するのは

参照回答（全文・重複を含む）

Government of Ireland / Cabinet of Ireland

アイルランド政府

Government of Ireland と Cabinet of Ireland を参照とする。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / part_of/id151 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 7 ：出生地を地名で答える

入力原文（全文）

AURORA was born in

日本語訳（入力・答えの意味）

AURORA が生まれた場所は

参照回答（全文・重複を含む）

Stavanger / Stavanger, Rogaland, Norway / Stavanger, Norway

スタヴァンゲル

都市名だけの表記と、国名・地域名を添えた表記を認める。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / place_of_birth/id150 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 8 ：発明者を、決まった形式で答える

入力原文（全文）

Apgar score was discovered by

日本語訳（入力・答えの意味）

アプガースコアを考案したのは

参照回答（全文・重複を含む）

Virginia Apgar / Virginia Agpar / Virginia Apgar

バージニア・アプガー

「 discovered by 」というテンプレートで、医学的評価法の考案者を尋ねる。別表記と重複も配布参照のまま示す。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / discoverer_or_inventor/id154 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例９：人物が務める役職を答える

入力原文（全文）

The position held by Alison Foster is

日本語訳（入力・答えの意味）

アリソン・フォスターが務めた役職は

参照回答（全文・重複を含む）

High Court judge

高等法院判事

役職名が参照になる。地位の就任日や退任日は、この入力には含まれない。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / position_held/id150 （HELM 内 ID）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 10 ：病態から症状・徴候を答える

入力原文（全文）

secondary hypertrophic osteoarthropathy has symptoms such as

日本語訳（入力・答えの意味）

続発性肥大性骨関節症の症状・徴候には、次がある：

参照回答（全文・重複を含む）

nail clubbing / digital clubbing / clubbing of fingers / Hippocratic fingers / finger clubbing

ばち指

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / symptoms_and_signs/id156 （HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 11 ：古典作品の著者を答える

入力原文（全文）

The author of Dialectics of Nature is

日本語訳（入力・答えの意味）

『自然弁証法』の著者は

フリードリヒ・エンゲルス

参照回答（全文・重複を含む）

Friedrich Engels / F. Engels / Frederik Engels / Friedrich Engles

イニシャル表記などを含む複数の別名が参照になる。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / author/id153 （ HELM 内 ID ）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 12 ：歴史上の地域の通貨

入力原文（全文）

The currency of British Cyprus is

日本語訳（入力・答えの意味）

イギリス領キプロスの通貨は

参照回答（全文・重複を含む）

Cypriot pound / Cypriot lira

キプロス・ポンド

歴史上の地域も含む。現在の国の通貨を一律に尋ねる集合ではない。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / currency/id154 （HELM 内 ID）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

実例 13 ：参照に日本語表記が含まれる

入力原文（全文）

(5353) 1989 YT was discovered by

日本語訳（入力・答えの意味）

(5353) 1989 YT を発見したのは

参照回答（全文・重複を含む）

Yoshiaki Oshima / おおしま よしあき

大島良明

入力は英語のテンプレートだが、参照の別名には日本語表記も含まれる。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 test / discoverer_or_inventor/id155 （HELM 内 ID）
https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

関係別成績と実行条件

10 関係の Accuracy@1 （前半）

関係	OPT-175B	davinci-003	Llama 2
著者	17.06	53.76	61.53
通貨	42.16	57.10	62.71
発見者・発明者	6.27	17.88	26.12
分類	34.24	45.73	60.47
治療対象	19.65	46.67	52.12

単位は % 。候補数は 5 ／ 5 ／ 1 、試行数は 3 ／ 3 ／ 1 。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

10 関係の Accuracy@1 （後半）

関係	OPT-175B	davinci-003	Llama 2
部分・所属先	18.00	30.63	18.24
出生地	3.33	16.43	22.94
原告	50.69	60.42	68.75
役職	9.02	16.31	31.29
症状・徴候	19.91	28.45	45.05

単位は % 。候補数は 5 ／ 5 ／ 1 、試行数は 3 ／ 3 ／ 1 。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

5 候補を許すと、得点が上がる

モデル	Accuracy@1（%）	Accuracy@5（%）
OPT-175B	22.03	32.28
text-davinci-003	37.34	44.03

10 関係の単純平均、 3 試行平均。 Llama 2 は実出力が 1 候補なので、この 5 候補比較から外した。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

公開実行で使う関係と Wikidata の ID

関係	ID	関係	ID
著者	P50	部分・所属先	P361
通貨	P38	出生地	P19
発見者・発明者	P61	原告	P1620
分類	P31	役職	P39
治療対象	P2175	症状・徴候	P780

subject 引数は関係名を指定する。

[1] Stanford CRFM, HELM WIKIFactScenario. 86 関係の辞書と配布ファイルの読込。 2026-10-18 確認。
https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/wikifact_scenario.py

設定の 5 出力と、返った候補数

モデル	num_outputs	実出力／問	試行数
OPT-175B	5	5	3
text-davinci-003	5	5	3
Llama 2 70B	5	1	1

Llama 2 の全 10 関係 test7,462 件を取得して確認。 max_tokens 8 、 stop は改行、最大提示例数 5 。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

取得した入力と参照から再照合できる

13 実例は、公開 text-davinci-003 の test ・第 1 試行から選んだ。全 10 関係を少なくとも 1 件ずつ含むが、頻度を代表する無作為標本ではない。

原文、全参照、全 5 候補、対数確率、条件内 ID 、固定 run URL 、取得 SHA-256 を保存した。参照に同じ名前が重複していても、原レコードでは保持した。

入力にある古い国・過去の役職も、 2022 年 1 月の知識基盤を基にした設計の一部として示す。

[1] Stanford CRFM, HELM Classic v0.4.0, WikiFact. 2023-11-17 の固定版。 2026-10-18 参照。 https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

制作チームと参考文献

HELM の知識評価として新規に構築した

WikiFact は HELM 論文で導入されたデータセット。論文の貢献記録では、 Hongyu Ren が設計・実装、 Lucia Zheng がデータ注釈・前処理を担当したとされる。

Michihiro Yasunaga が知識評価チームを率い、 Neel Guha らも設計に参加。プロジェクト全体は Percy Liang が統括した。

文の補完形式は LAMA を受け継ぎつつ、法律・経済・生物医学を含む幅広い関係へ対象を広げた。

[1] Liang et al. (2023), Holistic Evaluation of Language Models. Transactions on Machine Learning Research. https://arxiv.org/abs/2211.09110

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. · 2023 · Transactions on Machine Learning Research

多面的な言語モデル評価を設計し、知識評価の新規データとして WikiFact を構築した。

https://arxiv.org/abs/2211.09110

Language Models as Knowledge Bases?

Fabio Petroni et al. · 2019 · EMNLP-IJCNLP, 2463–2473

文の穴埋めを通して事実知識を取り出す LAMA を提案し、言語モデルの知識表現を分析する。

https://aclanthology.org/D19-1250/

参考文献

HELM Classic — WikiFact

Stanford CRFM · v0.4.0 （2023-11-17）· 2026-10-18 参照

関係別・モデル別の公開成績と予測記録をまとめる。

https://crfm.stanford.edu/helm/classic/v0.4.0/#/groups/wikifact

HELM WIKIFactScenario

Stanford CRFM · 公開実装 · 2026-10-18 確認

86 関係の ID と、問題・参照回答を JSONL から読み込む手順を定義する。

https://github.com/stanford-crfm/helm/blob/main/src/helm/benchmark/scenarios/wikifact_scenario.py