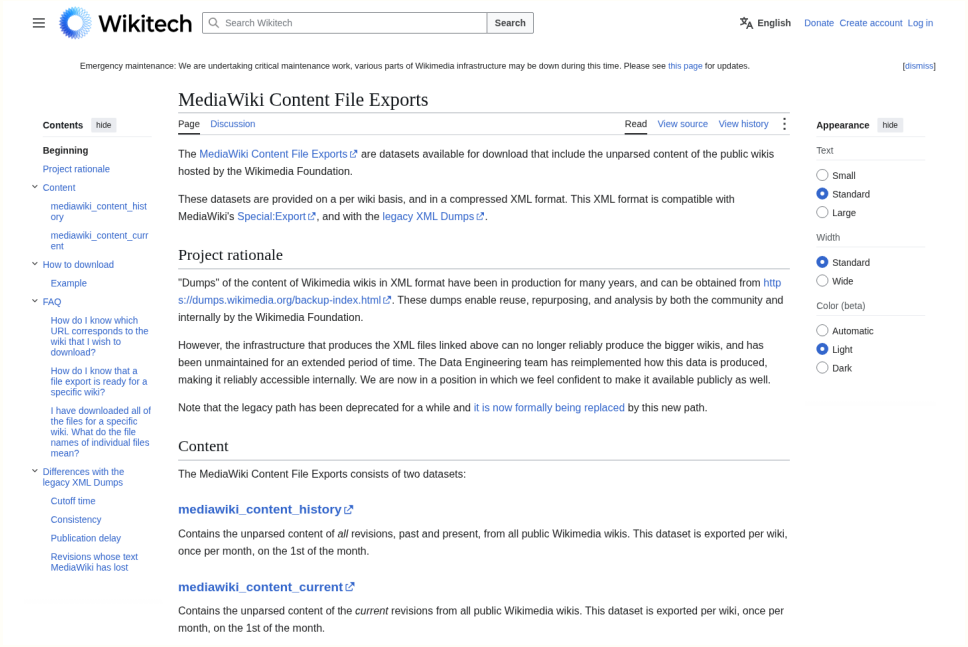
Wikipedia 本文データ

MediaWiki Content File Exports

記事の XML から本文コーパスを作る

sasakiy84

本文データの公式配布案内



[1] Wikimedia. MediaWiki Content File Exports. https://wikitech.wikimedia.org/wiki/MediaWiki_Content_File_Exports

1. 記事本文をデータとして読む
2. ページと版を XML で表す
3. コーパスを作るときの選択
4. 取得先と更新・利用条件

1. 記事本文をデータとして読む

百科事典の記事を、まとめて取得する

- Wikipedia の記事は、人が編集する百科事典のページ。公式の本文データを取得すれば、検索や言語分析などにまとめて利用できる。
- ダンプは、サイトのデータを書き出したファイル。記事の文章だけでなく、ページ名や編集された版の情報も含む。
- ここでは、月次 XML の MediaWiki Content File Exports を使い、本文をコーパスとして利用するまでを見ていく。

[1] Wikimedia. MediaWiki Content File Exports. https://wikitech.wikimedia.org/wiki/MediaWiki_Content_File_Exports

小さな言語版を、一式読んでみる

- 実例には、ビスラマ語版 Wikipedia の 2026 年 10 月 1 日分を使う。ビスラマ語は、バヌアツで使われる言語。
- biwiki は、この言語版の識別名。 current の全ファイルを取得し、 XML 内のページを集計した。
- 日本語版や英語版でも、同じ形式で記事を取り出せる。ここで示す件数や容量は、ビスラマ語版の取得分に限る。

[1] Wikipedia contributors. biwiki current, 2026-10-01. 本資料で集計 . https://dumps.wikimedia.org/other/mediawiki_content_current/biwiki/
[2] Wikipedia contributors. Bislama, rev.44441. 抜粋：本資料 . CC BY-SA 4.0. https://bi.wikipedia.org/w/index.php?title=Bislama&oldid=44441

取得した XML は、記事だけではない

対象	ページ数
全ページ	3,485
標準名前空間（ ns=0 ）	1,896
そのうち転送ページを除くもの	1,614

標準名前空間には、通常の記事などが入る。ここでの件数は、公式の「記事数」とは定義が異なる。

[1] Wikipedia contributors. biwiki current, 2026-10-01. 本資料で集計 . https://dumps.wikimedia.org/other/mediawiki_content_current/biwiki/

Port Vila の記事本文を読む

ビスラマ語の本文（冒頭段落・原文のまま）

'''Port Vila''', o jes '''Vila''', hem i kapital blong [[Vanuatu]]. Hem i stap long [[Efate]] aelan. [[Gavman]] blong [[Vanuatu]] i stap long ples ia mo hed blong stet blong [[kaontri]] ia i stap long ples ia tu.

日本語訳：ポートビラ、または単にビラは、バヌアツの首都。エファテ島にある。バヌアツの政府が置かれ、国家元首もここにいる。

[1] Wikipedia contributors. Port Vila, rev.41596. 抜粋・日本語説明：本資料 . CC BY-SA 4.0. https://bi.wikipedia.org/w/index.php?title=Port_Vila&oldid=41596

文章の周囲に、構造を表す記法がある

実データの記法	表すもの
'''Port Vila'''	強調する文字列
[[Vanuatu]]	Vanuatu の記事へのリンク
{{Siti … }}	都市の情報を入れるテンプレート
== Populaesen blong Port Vila ==	人口に関する節の見出し

wikitext は、ページを編集するための記法。配布される本文は、読みやすく整えた平文ではない。

[1] Wikipedia contributors. Port Vila, rev.41596. 抜粋・日本語説明：本資料 . CC BY-SA 4.0. https://bi.wikipedia.org/w/index.php?title=Port_Vila&oldid=41596

2. ページと版を XML で表す

ページの中に、編集された版が入る

要素	主な内容
siteinfo	サイト名・言語・名前空間の定義
page	タイトル・ページ ID ・名前空間
revision	版 ID ・日時・本文・内容モデル

page はページ、 revision はそのページの一つの版。ページ ID と版 ID は別の識別子。

[1] MediaWiki. Help:Export. https://www.mediawiki.org/wiki/Help:Export

Port Vila のページと版を対応づける

項目	実データの値
title	Port Vila
page / id	842
revision / id	41596
revision / timestamp	2022-06-10T07:00:07Z
model / format	wikitext / text/x-wiki

版の日時は 2022 年。 2026 年 10 月のダンプだからといって、全記事がその月に更新されたわけではない。

[1] Wikipedia contributors. biwiki current, 2026-10-01. 本資料で集計 . https://dumps.wikimedia.org/other/mediawiki_content_current/biwiki/

最新の本文か、過去の本文も含めるか

配布データ	収録する版	主な用途
content_current	各ページの最新の版	本文検索・語彙調査
content_history	過去・現在の版	文章変化の分析

正式名は mediawiki_content_current / mediawiki_content_history 。非公開の版の本文は含まない。

[1] Wikimedia. MediaWiki Content File Exports. https://wikitech.wikimedia.org/wiki/MediaWiki_Content_File_Exports

名前空間で、ページの役割を区別する

- 記事、会話ページ、利用者ページ、テンプレートなどは、名前空間という区分を持つ。 XML では ns の数値で分かる。
- 記事本文のコーパスを作るなら、まず標準名前空間の ns=0 を対象にする。全ページをそのまま記事として数えない。
- 転送ページは、別の記事へ案内するページ。本文の分析では除き、見出しの別名が必要なら対応関係を残す。

[1] MediaWiki. Help:Export. https://www.mediawiki.org/wiki/Help:Export
[2] Wikipedia contributors. biwiki current, 2026-10-01. 本資料で集計 . https://dumps.wikimedia.org/other/mediawiki_content_current/biwiki/

別名から、転送先の記事へつながる

転送ページ	転送先
Australia	Ostrelia
Canada	Kanada
New Zealand	Niusilan
Kapital	Kaptel

いずれも取得した XML 内の実例。転送先は page 内の redirect 要素にも記録される。

[1] Wikipedia contributors. biwiki current, 2026-10-01. 本資料で集計 . https://dumps.wikimedia.org/other/mediawiki_content_current/biwiki/

3. コーパスを作るときの選択

配布データから、目的に合う本文へ

- 言語版と月を選び、必要なページと版を取り出す。次に、転送ページやテンプレートなどを、目的に応じて扱う。
- wikitext から文章を取り出す場合は、リンクの表示文字列、節、表、注釈などをどう残すか決める。
- 最後に、記事と段落の単位を保って検索や集計へ渡す。どの処理をしたかを残すと、結果の解釈もしやすい。

[1] Wikimedia. MediaWiki Content File Exports. https://wikitech.wikimedia.org/wiki/MediaWiki_Content_File_Exports

記法を消すだけでは、意味が変わる

処理するもの	考えるべきこと
内部リンク	表示文字列を文章に残す
テンプレート	展開するか、用途を決めて除く
表・箇条書き	項目の対応や順番を保つ
注釈・出典	本文と区別し、対応を残す

テンプレートは別ページの内容を参照する。参照先をそろえずに描画すると、元の表示を再現できないことがある。

[1] MediaWiki. Help:Export. https://www.mediawiki.org/wiki/Help:Export

HTML と wikitext では、使いやすい場面が違う

- wikitext は、編集用の記法やテンプレートの呼び出しを持つ。編集内容や記事の作り方を調べるときに役立つ。
- HTML は、テンプレートなどを展開して表示するための形式。節や表の構造を利用して、読者が見る文章を取り出す入口になる。
- Wikimedia Enterprise は HTML を含むデータの取得手段を提供する。現在の取得条件は、旧 HTML ダンプのアーカイブとは異なる。

[1] MediaWiki. Help:Export. https://www.mediawiki.org/wiki/Help:Export
[2] Wikimedia Enterprise. API Products. https://enterprise.wikimedia.com/api/

同じ記事の中に、異なる首相名が残る

Japan の記事内の位置	原文の抜粋
冒頭テンプレート	praem minista = [[Sanae Takaichi]]
本文	Praem Minista: [[Fumio Kishida]]

同じ版に高市早苗と岸田文雄の名前がある実例。ダンプの本文を、整合性の確認済みの事実一覧として扱わない。

[1] Wikipedia contributors. Japan, rev.44104. 抜粋：本資料 . CC BY-SA 4.0. https://bi.wikipedia.org/w/index.php?title=Japan&oldid=44104

公式の配布と、加工されたコーパスを分ける

- 公式の XML は、サイトの内容と版の情報を書き出したデータ。平文の選別や重複除去が済んだ学習用コーパスではない。
- 第三者が配布する Wikipedia 由来のコーパスには、文章抽出、言語判定、品質選別など独自の処理が入る。
- 言語版・取得月・加工方法が違えば、収録内容も変わる。目的に合う配布物を選ぶ。

[1] Wikimedia. MediaWiki Content File Exports. https://wikitech.wikimedia.org/wiki/MediaWiki_Content_File_Exports

4. 取得先と更新・利用条件

言語版と月を選び、圧縮 XML を取得する

- 公式の配布案内から、 current か history を選ぶ。次に、jawiki などの言語版 ID と、対象の月を指定する。
- 一つの言語版が複数ファイルに分かれることもある。ファイル一覧が公開されてから、その月に必要な分割ファイルを取得する。
- 大きな XML は、ページ単位で順に読む。全体を一度にメモリへ載せる方法は、大きな言語版には向かない。

[1] Wikimedia. MediaWiki Content File Exports. https://wikitech.wikimedia.org/wiki/MediaWiki_Content_File_Exports
[2] MediaWiki. Help:Export. https://www.mediawiki.org/wiki/Help:Export

配布日は、収録した時点と区別する

項目	MediaWiki Content File Exports
基準となる時点	月初 1 日 00:00 UTC
公開までの待機	2026 年 11 月分から 7 〜 10 日程度
待機中の反映	削除・秘匿された版を除く
通常の編集	基準時点より後の編集は翌月分へ

公開時点の最新状態ではなく、月初時点を基準にしたデータ。内部データとの照合により、公開が遅れることもある。

[1] Wikimedia. Legacy content dumps sunset. https://wikitech.wikimedia.org/wiki/Legacy_content_dumps_sunset

旧方式から、新しい配布への移行が進む

- 2026 年 1 月に新しい配布方式が始まった。最新の本文や全版の本文など、旧 XML の一部の出力から移行するための方式である。
- 移行対象の六つの旧出力は、 2027 年 1 月に公開を終了する予定。本文や履歴の収録範囲を確認して、新しい取得先へ切り替える。
- pages-articles など他の XML や、 SQL ・ JSON ・ RDF まで、すべて廃止されるという告知ではない。

[1] Wikimedia. Legacy content dumps sunset. https://wikitech.wikimedia.org/wiki/Legacy_content_dumps_sunset

現行 HTML と、過去のアーカイブを区別する

- dumps サイトの HTML Dumps Archive は、過去の HTML 配布の保存先。 Enterprise データの同サイトへの複製は、2025 年 3 月 24 日に終了している。
- 現行の一括 HTML は、 Wikimedia Enterprise の Snapshot API などで取得する。無料アカウントで利用できる月次の配布がある。
- 古いアーカイブを現在の月次データだと思って使わず、配布日・対象プロジェクト・利用条件を確認する。

[1] Wikimedia Downloads. HTML Dumps Archive. https://dumps.wikimedia.org/other/enterprise_html/
[2] Wikimedia Enterprise. API Products. https://enterprise.wikimedia.com/api/

本文の再利用には、出典とライセンスを添える

- Wikipedia の本文は、一般に CC BY-SA 4.0 などの条件で再利用できる。転載部分などには、別の条件が付く場合もある。
- 記事へのリンクなどで著者を表示し、ライセンスを示す。加工・翻訳にも同じ条件が適用され、変更したことを明記する。
- 画像などは、ファイルごとに条件が異なる。本文 XML の画像名から画像ファイルも利用する場合は、その配布先と利用条件を別に確認する。

[1] Wikimedia Foundation. Terms of Use, §7 Licensing of Content. https://foundation.wikimedia.org/wiki/Policy:Terms_of_Use

Wikipedia 本文データの要点

- 記事の文章に加え、ページ・版・リンク・節などの構造を持つ、百科事典由来の言語資源。
- 最新の本文を使うか、文章の変化を追うかで、 current と history を選ぶ。名前空間や転送を見て、収録対象を整える。
- 言語版・取得月・抽出方法・利用条件を確認し、目的に合う本文データとして使う。

[1] Wikimedia. MediaWiki Content File Exports. https://wikitech.wikimedia.org/wiki/MediaWiki_Content_File_Exports

Appendix

1. 実データの追加例
2. 形式と参考資料

追加例 1 ： Bislama の言語情報

実データの項目	値
title	Bislama
speakers （話者数）	200,000
iso1 （ 2 字の言語コード）	bi
iso3 （ 3 字の言語コード）	bis
glotto （言語の識別子）	bisl1239

Toktok テンプレートの値を抜粋。話者数はこの記事の記載値。

[1] Wikipedia contributors. Bislama, rev.44441. 抜粋：本資料 . CC BY-SA 4.0. https://bi.wikipedia.org/w/index.php?title=Bislama&oldid=44441

追加例２： Ostrelia の国情報

テンプレートの項目	実際の値
nem ofisial	Komenwelth blong Ostrelia
kaptel	[[Canberra]]
lanwis	[[Inglis]]
eria	7 692 024

Ostrelia はオーストラリア。国名・首都・言語・面積の欄を抜粋。リンクの値も、ただの数値も同じテンプレート内に入る。

[1] Wikipedia contributors. Ostrelia, rev.43876. 抜粋・説明：本資料 . CC BY-SA 4.0. https://bi.wikipedia.org/w/index.php?title=Ostrelia&oldid=43876

追加例 3 ： Vanuatu の表には列の対応がある

州	面積 (km²)	人口（2000 年）	州都
Malampa	2 779	36 100	Lakatoro
Penama	1 198	28 960	Saratamata
Sanma	4 248	32 340	Luganville

Vanuatu の州別表から 3 行を抜粋し、見出しを日本語化。人口は 2000 年の列。

[1] Wikipedia contributors. Vanuatu, rev.44216. 抜粋・見出し訳：本資料 . CC BY-SA 4.0. https://bi.wikipedia.org/w/index.php?title=Vanuatu&oldid=44216

追加例 4 ： Efate の記事内リンク

原文内の記法	リンク先・役割
[[Vanuatu]]	バヌアツの記事
[[Shefa]]	シェファ州の記事
[[Port Vila]]	首都ポートビラの記事
{{Ol aelan blong Vanuatu}}	関連する島のテンプレート

リンクとテンプレートは異なる構造。末尾には Shefa と Vanuatu のカテゴリも記録されている。

[1] Wikipedia contributors. Efate, rev.41761. 抜粋・説明：本資料 . CC BY-SA 4.0. https://bi.wikipedia.org/w/index.php?title=Efate&oldid=41761

追加例 5 ：テンプレートも独立したページ

XML の項目	実データの値
title	Template:Delete
ns	10
model	wikitext
本文の一部	Samwan wantem rabemaot pej ia!

Template:Delete は、削除を求める案内を表示する。抜粋は「このページの削除を求める人がいる」の意。

[1] Wikipedia contributors. Template:Delete, rev.41593. 抜粋・訳：本資料 . CC BY-SA 4.0. https://bi.wikipedia.org/w/index.php?title=Template:Delete&oldid=41593

圧縮 XML から、ページ名を順に読む

```
import bz2
import xml.etree.ElementTree as ET
ns = "{http://www.mediawiki.org/xml/export-0.11/}"
with bz2.open("biwiki.xml.bz2", "rb") as f:
    for _, page in ET.iterparse(f, events=("end",)):
        if page.tag == ns + "page":
            print(page.findtext(ns + "title"))
            page.clear()
```

取得したファイルを biwiki.xml.bz2 として置く例。本資料の集計では、ページ名・名前空間・版・本文も取り出した。

[1] MediaWiki. Help:Export. https://www.mediawiki.org/wiki/Help:Export

今回取得したビスラマ語版の容量

対象	容量
bzip2 圧縮ファイル	1.05 MB
展開した XML	6.40 MB

MB は 10^6 bytes 。 2026 年 10 月 1 日分の current を一式取得して実測。他の言語版の容量を表す値ではない。

[1] Wikipedia contributors. biwiki current, 2026-10-01. 本資料で集計 . https://dumps.wikimedia.org/other/mediawiki_content_current/biwiki/

参考文献

MediaWiki Content File Exports

Wikimedia. n.d. （参照： 2026-10-28 ） .

月次本文データの収録範囲、取得方法、従来形式との違いを説明する。

https://wikitech.wikimedia.org/wiki/MediaWiki_Content_File_Exports

Legacy content dumps sunset

Wikimedia. n.d. （参照： 2026-10-28 ） .

旧出力の移行対象、終了時期、公開待機期間を案内する。

https://wikitech.wikimedia.org/wiki/Legacy_content_dumps_sunset

参考文献

Data dumps

Wikimedia. n.d. （参照： 2026-10-28 ） .

公式ダンプの全体像と、利用目的・形式の入口をまとめる。

https://meta.wikimedia.org/wiki/Data_dumps

Help:Export

MediaWiki. n.d. （参照： 2026-10-28 ） .

ページ・版を XML で出力する形式と処理方法を解説する。

https://www.mediawiki.org/wiki/Help:Export

参考文献

HTML Dumps Archive

Wikimedia Downloads. n.d. （参照： 2026-10-28 ） .

過去の HTML 配布を保存し、現行 Enterprise API への導線を示す。

https://dumps.wikimedia.org/other/enterprise_html/

Wikipedia & Wikimedia APIs

Wikimedia Enterprise. n.d. （参照： 2026-10-28 ） .

Snapshot など、現行のコンテンツ取得サービスを案内する。

https://enterprise.wikimedia.com/api/

参考文献

Terms of Use — Licensing of Content

Wikimedia Foundation. n.d. （参照： 2026-10-28 ） .

本文・媒体のライセンス、著者表示、加工時の条件を定める。

https://foundation.wikimedia.org/wiki/Policy:Terms_of_Use

Attribution-ShareAlike 4.0 International

Creative Commons. n.d. （参照： 2026-10-28 ） .

本文抜粋・本資料の日本語訳に適用するライセンス。記事へのリンクで著者を表示。

https://creativecommons.org/licenses/by-sa/4.0/