Wikipedia Clickstream

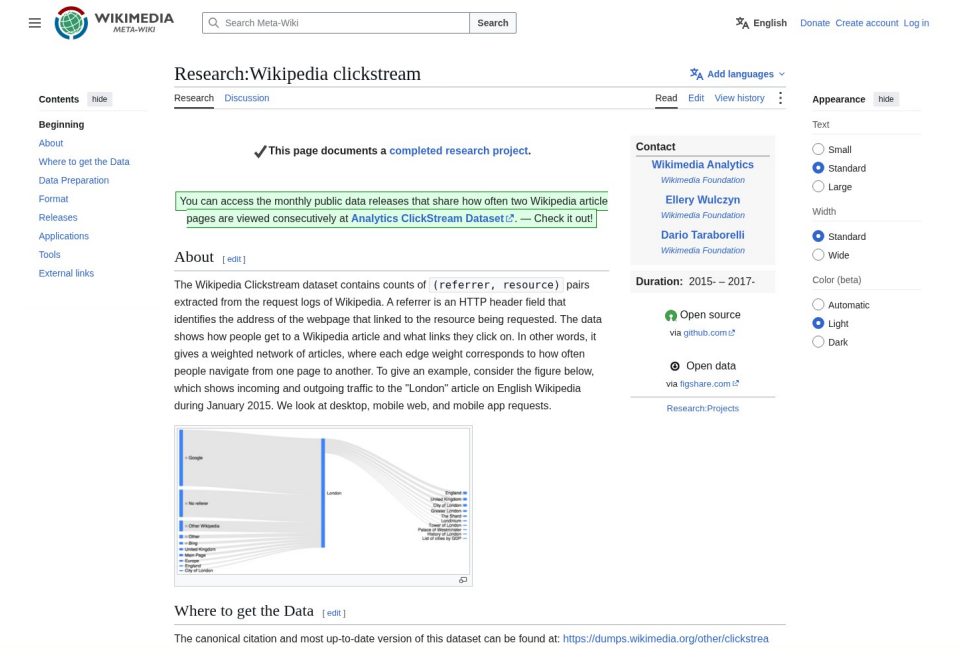
Wikipedia の記事への流入と記事間遷移

sasakiy84

1. 記事間の移動を集計する
2. ファイルとデータの作り方
3. 利用方法と公開範囲

1. 記事間の移動を集計する

Wikipedia Clickstream



[1] Wulczyn & Taraborelli (2015), Wikipedia Clickstream. Meta-Wiki. https://meta.wikimedia.org/wiki/Research:Wikipedia_clickstream

どの記事から、どの記事へ移ったか

- Wikipedia へのアクセスを、参照元と移動先の記事の組ごとに月単位で集計した公式データである。
- 記事間のつながりに、その月の遷移回数が付く。検索エンジンなどからの記事への流入も含む。
- 以下では、日本語版の 2026 年 9 月の配布データを使う。

[1] Wulczyn & Taraborelli (2015), Wikipedia Clickstream. Meta-Wiki. https://meta.wikimedia.org/wiki/Research:Wikipedia_clickstream
[2] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

「富士山」への流入

参照元	回数
other-search	13,798
other-empty	4,047
メインページ	858
other-external	716
other-internal	495

日本語版・ 2026 年 9 月。公開された組の上位を表示。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

検索からの流入と記事間の移動が分かる

- 「富士山」には、検索エンジンを参照元とするアクセスが 13,798 回ある。検索サイト名や検索語は公開されない。
- other-empty は参照元が空または解析できないアクセスで、4,047 回ある。ブックマークや直接入力だけとは特定できない。
- 記事名が入る行では、どの Wikipedia 記事を参照して到達したかを読める。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/
[2] Wikimedia, ClickstreamBuilder.scala. analytics-refinery-source. https://github.com/wikimedia/analytics-refinery-source

「富士山」からの移動

移動先	回数
富士山 - 信仰の対象と芸術の源泉	405
玉山 _(台湾)	241
富士登山	232
剣ヶ峰 _(富士山)	229
富士山の噴火史	200

日本語版・ 2026 年 9 月。公開された組の上位を表示。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

「人工知能」からの移動

移動先	回数
人工知能の歴史	1,413
AI がもたらす未来のシナリオ	431
生成的人工知能	325
フィクションにおける人工知能	269
ジョン・マッカーシー	224

日本語版・ 2026 年 9 月。公開された組の上位を表示。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

「ネコ」と「イヌ」の移動は方向ごとに数える

参照元	移動先	回数
ネコ	イヌ	366
イヌ	ネコ	205

同じ 2 記事でも、移動する方向ごとに別の行になる。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

「富士山」からどの記事へ移ったか



日本語版・ 2026 年 9 月。移動先の上位 4 件、線の太さは回数に対応。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

2. ファイルとデータの作り方

1 行は参照元と移動先の組を表す

- 1 か月分が言語ごとの gzip 圧縮 TSV で配布される。区切り文字はタブで、先頭に列名の行はない。
- 列は prev 、 curr 、 type 、 n の 4 つ。記事名では空白がアンダースコアで表される。
- n はその組に該当するアクセスの回数である。人数や読者数ではない。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/
[2] Wulczyn & Taraborelli (2015), Wikipedia Clickstream. Meta-Wiki. https://meta.wikimedia.org/wiki/Research:Wikipedia_clickstream

TSV には 4 つの列がある

列	内容	実際の値
prev	参照元	富士山
curr	移動先	富士登山
type	組の種類	link
n	月間の回数	232

この行は「富士山」から「富士登山」への遷移が 232 回あったことを示す。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

type は参照元と移動先の関係を示す

値	意味
link	同じ言語版の記事間で、参照元に移動先へのリンクがある
other	記事名の組だが、参照元にそのリンクが確認されない
external	参照元を other-* の区分へ集約した行

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/
[2] Wikimedia, ClickstreamBuilder.scala. analytics-refinery-source. https://github.com/wikimedia/analytics-refinery-source

記事名以外の参照元を 5 区分へまとめる

prev の値	参照元の区分
other-search	検索エンジン
other-external	その他の外部サイト
other-internal	Wikimedia 内部のその他のページ
other-empty	空または解析できない参照元
other-other	その他の参照元

[1] Wikimedia, ClickstreamBuilder.scala. analytics-refinery-source. https://github.com/wikimedia/analytics-refinery-source

アクセスの記録を加工して公開する

- Wikimedia のアクセス記録から、ページ閲覧と判定されたものを選び、既知のボットなどの自動アクセスを除いて集計する。
- 記事を収録する標準名前空間を対象とし、リダイレクト先へまとめる。記事のリンク情報を使って type を付ける。
- 2026 年 9 月の日本語版には 10 回以上の組が含まれる。回数が少ない組や同じ記事への遷移は省かれる。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/
[2] Wikimedia, ClickstreamBuilder.scala. analytics-refinery-source. https://github.com/wikimedia/analytics-refinery-source

日本語版は約 627 万組を収録する

種類	組の数	回数の合計
link	4,026,660	232,736,382
other	113,762	4,750,122
external	2,129,084	591,995,780

2026 年 9 月の日本語版を全件集計。全 6,269,506 組、合計 829,482,284 回。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

集計の対象月と言語を選べる

- 2026 年 9 月の配布先には 40 言語版がある。日本語版、英語版のほか、アラビア語版や中国語版なども含む。
- 月ごとに独立したファイルを提供する。記事名やリンク構造も変わるため、複数月を比べるときは対象記事の改名などを確認する。
- 今回の日本語版は圧縮約 94.9 MB である。 1 言語・ 1 か月単位で取得できる。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

3. 利用方法と公開範囲

流入、回遊、記事間の関連を調べる

- 特定の記事へ、検索や他の記事からどの程度アクセスがあるかを調べられる。
- ある記事から読まれている関連記事を取り出し、記事間の移動を重み付きのネットワークとして扱える。
- リンクの有無と、参照元の記事から移動先の記事への遷移回数を対応させられる。

[1] Wulczyn & Taraborelli (2015), Wikipedia Clickstream. Meta-Wiki. https://meta.wikimedia.org/wiki/Research:Wikipedia_clickstream

個々の読者の閲覧履歴は含まない

- 公開ファイルには、ユーザー ID 、 IP アドレス、各アクセスの時刻、検索語は含まれない。
- 公開されるのは月間の組と回数である。記事 A から B への行と、 B から C への行があっても、それらが同じ読者による一連の移動だったかは分からない。
- 少数の組が省かれるため、公開行の合計は元のアクセス記録全体を表すものではない。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/
[2] Wulczyn & Taraborelli (2015), Wikipedia Clickstream. Meta-Wiki. https://meta.wikimedia.org/wiki/Research:Wikipedia_clickstream

ファイルを取得して 4 列として読む

- 公式配布先で対象月を開き、言語版の TSV.gz を取得する。今回のファイル名は clickstream-jawiki-2026-09.tsv.gz である。
- Python の gzip と csv で展開しながら読める。数値の n は文字列から整数へ変換する。
- 記事名には引用符も現れるので、 TSV の引用符解釈を無効にして読み込む。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

「富士山」から「富士登山」への行を読む

```
import csv, gzip
path = "clickstream-jawiki-2026-09.tsv.gz"
with gzip.open(path, "rt", encoding="utf-8") as f:
    rows = csv.reader(
        f, delimiter="\t", quoting=csv.QUOTE_NONE)
    for prev, curr, kind, n in rows:
        if prev == "富士山" and curr == "富士登山":
            print(prev, curr, kind, int(n))
```

出力　富士山 富士登山 link 232

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

公開データは CC0 で提供される

- 配布先の説明では、 Analytics の公開データに CC0 を適用している。データの加工・再配布にも利用できる。
- Wikipedia の記事本文を別途転載する場合は、本文側のライセンス条件を確認する。 Clickstream の CC0 が記事本文へそのまま適用されるわけではない。
- 分析や図には、対象の言語版と月、 Wikipedia Clickstream を使ったことを示すと出所が伝わる。

[1] Wikimedia, Analytics Datasets: Clickstream. https://dumps.wikimedia.org/other/clickstream/readme.html
[2] Creative Commons, CC0 1.0 Universal. https://creativecommons.org/publicdomain/zero/1.0/

記事間の移動を月次の表として使う

- Wikipedia Clickstream は、記事間遷移と集約された流入元を、４列の TSV として提供する公式データである。
- 参照元と移動先の組に月間回数が付き、リンクの有無との関係も分かる。
- 記事本文、ページごとの閲覧数、個別の編集履歴とは異なる。読まれ方を記事間の関係から調べるためのデータである。

[1] Wulczyn & Taraborelli (2015), Wikipedia Clickstream. Meta-Wiki. https://meta.wikimedia.org/wiki/Research:Wikipedia_clickstream
[2] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

Appendix

1. 追加の遷移例
2. 関連データと参考文献

1. 追加の遷移例

「京都市」からの移動

移動先	回数
京都府	624
京都市出身の人物一覧	376
宇治市	252
神戸市	235
左京区	229

日本語版・ 2026 年 9 月。公開された組の上位を表示。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

「太陽系」からの移動

移動先	回数
金星	723
水星	683
木星	663
海王星	650
火星	630

日本語版・ 2026 年 9 月。公開された組の上位を表示。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

「村上春樹」からの移動

移動先	回数
1Q84	878
夏帆 _The_Tale_of_KAHO	826
ノルウェイの森	810
街とその不確かな壁	653
世界の終りとハードボイルド・ワンダーランド	650

日本語版・ 2026 年 9 月。公開された組の上位を表示。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

「北海道」からの移動

移動先	回数
札幌市	1,250
北海道出身の人物一覧	576
道 _(行政区画)	512
旭川市	384
青森県	379

日本語版・ 2026 年 9 月。公開された組の上位を表示。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

「国際連合」からの移動

移動先	回数
国際連盟	673
連合国 _(第二次世界大戦)	445
国際連合加盟国	299
アントニオ・グテーレス	272
国際連合本部ビル	236

日本語版・ 2026 年 9 月。公開された組の上位を表示。

[1] Wikimedia, Clickstream September 2026. 日本語版を集計。 https://dumps.wikimedia.org/other/clickstream/2026-09/

2. 関連データと参考文献

2015 年の研究公開から月次配布へ

- Ellery Wulczyn と Dario Taraborelli が 2015 年に Wikipedia Clickstream を公開した。
- 初期の 2015 年 1 月・2 月はデスクトップのみだったが、その後はモバイル Web とアプリのアクセスも対象になった。
- 2017 年 11 月から自動的な月次配布となった。現行ファイルの列と対象言語は、利用する月の配布先で確認できる。

[1] Wulczyn & Taraborelli (2015), Wikipedia Clickstream. Meta-Wiki. https://meta.wikimedia.org/wiki/Research:Wikipedia_clickstream

WikiNav は記事の流入と移動先を表示する

- Wikimedia Research の WikiNav は、 Clickstream を使って記事への流入元と記事からの移動先を表示するツールである。
- Pageviews は記事ごとの閲覧数、 Clickstream は参照元と記事の組を提供する。個別記事の時系列と、記事間の移動では調べる対象が異なる。

[1] Wulczyn & Taraborelli (2015), Wikipedia Clickstream. Meta-Wiki. https://meta.wikimedia.org/wiki/Research:Wikipedia_clickstream
[2] Wikimedia Research, WikiNav. https://wikinav.toolforge.org/

参考文献

Wikipedia Clickstream

Ellery Wulczyn and Dario Taraborelli, 2015. figshare.

Wikipedia の参照元と移動先を集計したデータの初期公開。

https://doi.org/10.6084/m9.figshare.1305770

Research:Wikipedia clickstream

Wikimedia contributors, n.d. Meta-Wiki. 参照 2026-10-28.

データの目的、４列の定義、初期の公開履歴と利用例をまとめる。

https://meta.wikimedia.org/wiki/Research:Wikipedia_clickstream

参考文献

Analytics Datasets: Clickstream

Wikimedia Foundation, n.d. 参照 2026-10-28.

月次配布への入口と、公開データの CC0 の案内。

https://dumps.wikimedia.org/other/clickstream/readme.html

analytics-refinery-source

Wikimedia Foundation, n.d. GitHub. 参照 2026-10-28.

アクセスの選別、参照元の分類、リンク判定と集計処理を含む実装。

https://github.com/wikimedia/analytics-refinery-source