WMT14

2014 Workshop on Statistical Machine Translation

ニュースの対訳で、機械翻訳の品質を比較する

sasakiy84

WMT14 の公開ページ



ACL 2014 NINTH WORKSHOP
ON STATISTICAL MACHINE TRANSLATION

Shared Task: Machine Translation

26-27 June 2014
Baltimore, USA

[HOME] | [TRANSLATION TASK] | [METRICS TASK] | [QUALITY ESTIMATION TASK] | [MEDICAL TRANSLATION TASK] | [SCHEDULE] | [PAPERS] | [AUTHORS] | [RESULTS]

The recurring translation task of the WMT workshops focuses mainly on European language pairs, but this year we have introduced English-Hindi as an experimental, low resource language pair. Translation quality will be evaluated on a shared, unseen test set of news stories. We provide a parallel corpus as training data, a baseline system, and additional resources for download. Participants may augment the baseline system or use their own system.

GOALS

The goals of the shared translation task are:

- To investigate the applicability of current MT techniques when translating into languages other than English
- To examine special challenges in translating between European languages, including word order differences and morphology
- To investigate the translation of low-resource, morphologically rich languages
- To create publicly available corpora for machine translation and machine translation evaluation
- To generate up-to-date performance numbers for European languages in order to provide a basis of comparison in future research
- To offer newcomers a smooth start with hands-on experience in state-of-the-art statistical machine translation methods

We hope that both beginners and established research groups will participate in this task.

TASK DESCRIPTION

We provide training data for five language pairs, and a common framework (including a baseline system). The task is to improve methods current methods. This can be done in many ways. For instance participants could try to:

- improve word alignment quality, phrase extraction, phrase scoring
- add new components to the open source software of the baseline system
- augment the system otherwise (e.g. by preprocessing, reranking, etc.)
- build an entirely new translation systems

Participants will use their systems to translate a test set of unseen sentences in the source language. The translation quality is measured by a manual evaluation and various automatic evaluation metrics. Participants agree to contribute to the manual evaluation about eight hours of work.

You may participate in any or all of the following language pairs:

- French-English
- Hindi-English
- German-English
- Czech-English
- Russian-English

For all language pairs we will test translation in both directions. To have a common framework that allows for comparable results, and also to lower the barrier to entry, we provide a common training set and baseline system.

We also strongly encourage your participation, if you use your own training corpus, your own sentence alignment, your own language model, or your own decoder.

[1] WMT14 公式公開ページ。 2026-10-18 参照。 https://www.statmt.org/wmt14/translation-task.html

1. 課題と実際のデータ
2. 作成方法とデータの構成
3. 採点方法とモデルの成績
4. 利用の変化と入手方法

課題と実際のデータ

英語と 5 言語の間で、ニュースを翻訳する

- 2014 年の翻訳共有タスクで使われた学習用の対訳、開発用・テスト用のニュース文を扱う。
- 英語とドイツ語、フランス語、チェコ語、ヒンディー語、ロシア語の 5 組。各言語組を双方向で評価すると、合計 10 方向の翻訳になる。

[1] Ondřej Bojar et al. (2014). Findings of the 2014 Workshop on Statistical Machine Translation. WMT 2014. https://aclanthology.org/W14-3302/

入力・出力と配布フィールド

フィールド	意味
translation	言語コードをキーにした対訳
en / de など	英語と、対応するもう一方の言語
test / validation	newstest2014 ／ newstest2013 に対応

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 https://huggingface.co/datasets/wmt/wmt14

実例１：英語・ドイツ語

関連する入力・回答／原文と日本語

Gutach: Increased safety for pedestrians
Gutach: Noch mehr Sicherheit für Fußgänger

英語：グータッハ：歩行者の安全性をさらに向上
ドイツ語の参照訳：グータッハ：歩行者の安全性をさらに向上

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 de-en / test 行 0 。 https://huggingface.co/datasets/wmt/wmt14

実例２：英語・ドイツ語

関連する入力・回答／左：原文　右：日本語

Two sets of lights so close to one another: intentional or just a silly error?
Zwei Anlagen so nah beieinander: Absicht oder Schildbürgerstreich?

英語：これほど近接した２組の信号機。意図的なのか、それとも単なる間抜けな失敗なのか。
ドイツ語の参照訳：これほど近接した２組の信号機。意図的なのか、それとも単なる間抜けな失敗なのか。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 de-en / test 行 2 。 https://huggingface.co/datasets/wmt/wmt14

実例３：英語・ドイツ語

関連する入力・回答／原文と日本語

> Yesterday, Gutacht's Mayor gave a clear answer to this question.
> Diese Frage hat Gutachs Bürgermeister gestern klar beantwortet.

英語：昨日、グータッハの市長はこの質問に明確に答えた。
ドイツ語の参照訳：昨日、グータッハの市長はこの質問に明確に答えた。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 de-en / test 行 3 。 https://huggingface.co/datasets/wmt/wmt14

作成方法とデータの構成

作成の背景

- 統計的機械翻訳の方式を、同じ学習資源とニュース文で比較する共有タスクとして整備された。
- ニュースの翻訳を人手で評価する一方、自動指標も用い、言語方向ごとの性能を比べた。

[1] Ondřej Bojar et al. (2014). Findings of the 2014 Workshop on Statistical Machine Translation. WMT 2014. https://aclanthology.org/W14-3302/

収集と品質の確認

- 学習には Europarl 、 Common Crawl 、 News Commentary などの公開対訳を使い、言語ごとに利用できる資源をまとめた。
- テスト用にはニュース記事を収集し、専門の翻訳者が直接翻訳した。原文の言語や記事 ID も公開ファイルに含まれる。 人手評価では、匿名化されたシステム出力を順位付けした。

[1] Ondřej Bojar et al. (2014). Findings of the 2014 Workshop on Statistical Machine Translation. WMT 2014. https://aclanthology.org/W14-3302/

分割と件数

集合・対象	件数	役割
train	言語組による	公開の複数対訳コーパス
validation	newstest2013	翻訳方式の調整
test	newstest2014	本資料は 5 言語組の配布版

[1] Ondřej Bojar et al. (2014). Findings of the 2014 Workshop on Statistical Machine Translation. WMT 2014. https://aclanthology.org/W14-3302/

取得した test の言語組と対訳数

言語組	対訳レコード数
cs-en	3003
de-en	3003
fr-en	3003
hi-en	2507
ru-en	3003

[1] WMT14 、 five language pairs/test 全 14,519 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/wmt/wmt14

採点方法とモデルの成績

何を 1 件として、どう採点するか

- BLEU は、生成訳と参照訳の間で一致する 1 〜 4 語の連続列の適合率を幾何平均し、短すぎる訳への係数を掛ける。
- 参照が the cat is here 、生成が the cat sleeps なら、 2 語列の一致は the cat 。実際の BLEU は文ごとの値を平均せず、集合全体の一致数を集計する。

[1] Ondřej Bojar et al. (2014). Findings of the 2014 Workshop on Statistical Machine Translation. WMT 2014. https://aclanthology.org/W14-3302/

登場時と、その後の代表的な比較

英語→ドイツ語／ newstest2014	BLEU
PBMT	20.7
GNMT WPM-32K （2016）	24.61
GNMT WPM-16K （2016）	24.36

[1] Wu et al. (2016). Google's Neural Machine Translation System: Bridging the Gap between Human and Machine Translation. arXiv:1609.08144. https://arxiv.org/abs/1609.08144

Transformer の翻訳条件

- Transformer big は、英独約 450 万文対、英仏約 3,600 万文対を使って学習した。英独 28.4 、英仏 41.8 BLEU を報告している。

[1] Vaswani et al. (2017). Attention Is All You Need. NeurIPS. https://arxiv.org/abs/1706.03762

HELM の収録範囲と、翻訳の比較条件

- HELM Classic v0.4.0 のスキーマに wmt_14 の定義があるが、公開 run_specs には対応する実行が 0 件だった。
- シナリオ実装は英語と 5 言語の相互方向を扱う。学習データは seed 42 で最大 20,000 件を抽出し、出力文の重複を除く。

[1] Stanford CRFM. HELM Classic v0.4.0. 公開 run_specs 。 2023-11-17 のリリース。
https://storage.googleapis.com/crfm-helm-public/classic/benchmark_output/releases/v0.4.0/run_specs.json

利用の変化と入手方法

統計翻訳からニューラル翻訳の共通評価へ

- WMT14 は、統計翻訳に加え、 GNMT や Transformer の英独・英仏翻訳を比較する代表的な条件になった。
- 2026-10-18 時点でも SacreBLEU が wmt14 を扱う。言語方向、トークン化、大文字小文字などを署名として残し、BLEU を再現できる。

[1] Matt Post (2018). A Call for Clarity in Reporting BLEU Scores. WMT. https://aclanthology.org/W18-6319/

入手方法と利用条件

- 公式ページから学習・開発・テストの対訳へ進める。コーパスごとに利用条件を確認する。
- 本資料は wmt/wmt14 の 5 言語組の test を取得した。同じ英語文が複数組に現れるため、合計件数は対訳レコード数として数える。

[1] WMT14 公式公開ページ。 2026-10-18 参照。 https://www.statmt.org/wmt14/translation-task.html

WMT14 の要点

- 英語と 5 言語のニュース翻訳を、対訳と共通の評価集合で比較する。
- 言語方向とデータの前処理が評価条件になる。人の翻訳評価と、自動指標 BLEU の両方から品質を捉える。

[1] Ondřej Bojar et al. (2014). Findings of the 2014 Workshop on Statistical Machine Translation. WMT 2014. https://aclanthology.org/W14-3302/

Appendix

1. 題材の異なる追加例
2. 集計と評価条件
3. 研究と参考文献

題材の異なる追加例

追加例１：英語・フランス語

関連する入力・回答／原文と日本語

Spectacular Wingsuit Jump Over Bogota
Spectaculaire saut en "wingsuit" au-dessus de Bogota

英語：ボゴタ上空での壮観なウイングスーツ・ジャンプ
フランス語の参照訳：ボゴタ上空での壮観なウイングスーツ・ジャンプ

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 fr-en / test 行 0 。 https://huggingface.co/datasets/wmt/wmt14

追加例２：英語・フランス語

関連する入力・回答／左：原文　右：日本語

And while Congress can't agree on whether to proceed, several states are not waiting.
Et tandis que les membres du Congrès n'arrivent pas à se mettre d'accord pour savoir s'il faut continuer, plusieurs États n'ont pas attendu.

英語：続行をめぐり連邦議会の合意が得られない一方、いくつかの州は待とうとしていない。
フランス語の参照訳：続行をめぐり連邦議会の合意が得られない一方、いくつかの州は待たずに進めた。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 fr-en / test 行 10 。 https://huggingface.co/datasets/wmt/wmt14

追加例３：英語・フランス語

関連する入力・回答／原文と日本語

> This really is a must for our nation.
> Cela est vraiment indispensable pour notre nation.

英語：これは私たちの国に本当に必要なことだ。
フランス語の参照訳：これは私たちの国に本当に必要なことだ。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 fr-en / test 行 13 。 https://huggingface.co/datasets/wmt/wmt14

追加例 4 ：英語・チェコ語

関連する入力・回答／原文と日本語

There is going to be a change in how we pay these taxes.
Změní se způsob, jakým platíme tyto daně.

英語：これらの税金の支払い方が変わることになる。
チェコ語の参照訳：これらの税金の支払い方が変わることになる。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 cs-en / test 行 12 。 https://huggingface.co/datasets/wmt/wmt14

追加例 5 ：英語・チェコ語

関連する入力・回答／原文と日本語

The technology is there to do it.
Slouží k tomu tato technologie.

英語：それを実現する技術は存在する。
チェコ語の参照訳：それを実現する技術は存在する。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 cs-en / test 行 13 。 https://huggingface.co/datasets/wmt/wmt14

追加例 6 ：英語・チェコ語

関連する入力・回答／原文と日本語

Americans don't buy as much gas as they used to.
Američané nekupují tolik benzínu, jako dříve.

英語：アメリカ人は、以前ほど多くのガソリンを買わなくなっている。
チェコ語の参照訳：アメリカ人は、以前ほど多くのガソリンを買わなくなっている。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 cs-en / test 行 15 。 https://huggingface.co/datasets/wmt/wmt14

追加例 7 ：英語・ヒンディー語

関連する入力・回答／左：原文　右：日本語

Cars get many more miles to the gallon.
अब एक गैलन गैस में कार पहले से अधिक मील चलती है।

英語：車は、 1 ガロンでずっと長い距離を走れる。
ヒンディー語の参照訳：車は、 1 ガロンで以前よりずっと長い距離を走れる。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 hi-en / test 行 16 。 https://huggingface.co/datasets/wmt/wmt14

追加例 8 ：英語・ヒンディー語（ 1/2 ）

英語／左：原文　右：日本語

The federal tax itself, 18.4 cents per gallon, hasn't gone up in 20 years.

連邦税自体は 1 ガロン当たり 18.4 セント。
20 年間据え置かれている。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 hi-en / test 行 17 。 https://huggingface.co/datasets/wmt/wmt14

追加例 8 ：英語・ヒンディー語（ 2/2 ）

ヒンディー語の参照訳／原文と日本語

फेडरल टैक्स में पिछले 20 वर्षों में कोई बढ़ोतरी नहीं हुई, जो 18.4 सेंट प्रति गैलन है।

連邦税自体は 1 ガロン当たり 18.4 セント。
20 年間据え置かれている。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 hi-en / test 行 17 。 https://huggingface.co/datasets/wmt/wmt14

追加例 9 ：英語・ロシア語

関連する入力・回答／原文と日本語

> In Kineshma and environs two men have committed suicide
> В Кинешме и районе двое мужчин покончили жизнь самоубийством

英語：キネシマとその周辺で、男性 2 人が自殺した。
ロシア語の参照訳：キネシマとその周辺で、男性 2 人が自殺した。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 ru-en / test 行 0 。 https://huggingface.co/datasets/wmt/wmt14

追加例 10 ：英語・ロシア語

関連する入力・回答／原文と日本語

One of the hanged men had previously attempted suicide.
Ранее один из повешенных уже совершал попытку суицида.

英語：首をつって亡くなった男性の 1 人には、過去に自殺未遂があった。
ロシア語の参照訳：首をつって亡くなった男性の 1 人には、過去に自殺未遂があった。

[1] wmt/wmt14 、改訂 b199e406 。 2026-10-18 参照。 ru-en / test 行 1 。 https://huggingface.co/datasets/wmt/wmt14

集計と評価条件

同じニュースが、複数の言語組に現れる

- 5 言語組の test を足すと 14,519 レコード。英語文が共通する組があるため、異なるニュース文の総数とは一致しない。
- 掲載 13 例では、英語文が重ならないよう選んだ。対訳を日本語で説明し、英語を含む両言語の表現を原文として保持した。

[1] WMT14 、 five language pairs/test 全 14,519 件を集計。 2026-10-18 取得。 https://huggingface.co/datasets/wmt/wmt14

研究と参考文献

研究者と発表の位置付け

- WMT 2014 の報告は、第一著者 Ondřej Bojar 、最終著者 Aleš Tamchyna ら、 13 名の運営者による共同研究。
- Charles University 、 University of Edinburgh などの研究者が、翻訳タスクの資源、人手評価、システム比較をまとめた。

[1] Ondřej Bojar et al. (2014). Findings of the 2014 Workshop on Statistical Machine Translation. WMT 2014. https://aclanthology.org/W14-3302/

参考文献

Findings of the 2014 Workshop on Statistical Machine Translation

Ondřej Bojar, Christian Buck, Christian Federmann, Barry Haddow, Philipp Koehn, Johannes Leveling, Christof Monz, Pavel Pecina, Matt Post, Herve Saint-Amand, Radu Soricut, Lucia Specia, Aleš Tamchyna / WMT 2014

WMT14 の目的、作成方法、評価をまとめた研究。

https://aclanthology.org/W14-3302/

参考文献

Holistic Evaluation of Language Models

Percy Liang et al. / TMLR 2023

複数のシナリオと指標で、言語モデルを比較する HELM の研究。

https://arxiv.org/abs/2211.09110

参考文献

WMT14 ：公開データ

wmt/wmt14 / 改訂 b199e406 / 2026-10-18 参照

掲載した 13 件の対訳と、言語組ごとの全件集計に用いた公開資源。

https://huggingface.co/datasets/wmt/wmt14

参考文献

Google's Neural Machine Translation System: Bridging the Gap between Human and Machine Translation

Yonghui Wu et al. / arXiv 2016

語の分割法などを比べ、 WMT14 の翻訳結果を報告した。

https://arxiv.org/abs/1609.08144

参考文献

Attention Is All You Need

Ashish Vaswani et al. / NeurIPS 2017

注意機構を中心とする Transformer と、 WMT14 での評価を報告。

https://arxiv.org/abs/1706.03762

参考文献

A Call for Clarity in Reporting BLEU Scores

Matt Post / WMT 2018

前処理条件と BLEU の再現性を整理し、 SacreBLEU を紹介する。

https://aclanthology.org/W18-6319/